El proyecto final: una propuesta de investigación predictiva

Big Data y Machine Learning para Economía Aplicada — 60-121 (NRC 10-993)

Universidad Icesi — Departamento de Economía
Prof. Eduard Fernando Martínez González

Información general

- **Peso:** 60 % de la nota final del curso, sobre 100 puntos: la idea (10), el documento (50) y la presentación (40). Trabajo **en parejas** (pueden ser las de los problem sets).
- **Entrega 1 — la idea en una página:** martes 3 de noviembre de 2026, a las 11:59 p. m., por el campus virtual. Ese día no hay clase: la entrega es digital.
- **Entrega 2 — el documento (máximo 8 páginas):** martes 24 de noviembre de 2026, a las 8:00 a. m., por el campus virtual.
- **La presentación:** martes 24 de noviembre en clase, 20 minutos por pareja más 10 de preguntas.
- **IA:** permitida, declarando qué se usó y para qué.

1. Qué es (y qué no es) el proyecto

El proyecto es el **diseño completo de un estudio predictivo**: una pregunta de economía aplicada en la que la cantidad de interés es $\hat{y}$ — no el efecto de nada —, los datos con que se respondería, y el plan que sobreviviría a las reglas del curso: referencia explícita, validación acorde con la estructura de los datos y una prueba que se toca una sola vez.

No es un informe de resultados. No se piden modelos estimados ni tablas finales: se pide un diseño tan bien argumentado que otro equipo podría ejecutarlo. Una tabla preliminar suma — demuestra que los datos existen y que la referencia es vencible — pero no reemplaza el diseño. La nota premia la calidad de las decisiones: qué se predice y para qué decisión, contra qué se compara, cómo se valida sin engañarse y qué puede salir mal.

Para la propuesta no hace falta tener los datos montados: hace falta demostrar que existen y son accesibles, o un plan creíble para recolectarlos — y si tocaría generarlos (datos sintéticos o simulados), decirlo y justificar qué estructura real imitarían. La pregunta debe ser distinta a la del caso del curso y a la de los problem sets.

2. Entrega 1 — La idea en una página (10 pts)

Una página en prosa, por pareja, que yo pueda leer en dos minutos. Responde cuatro cosas, en este orden:

1. **La pregunta y la decisión que la motiva:** qué se quiere anticipar y quién haría algo distinto si lo supiera (un banco que valora garantías, una alcaldía que focaliza, una empresa que asigna inventario).
2. **La unidad y la y:** qué se predice exactamente, para qué unidad (persona, hogar, inmueble, municipio, mes) y en qué momento. Si y es una categoría, cuál es la clase de interés y qué tan frecuente es.
3. **El método o los métodos del curso que usarían** y por qué ese tipo de modelo le queda a esa pregunta.
4. **Los datos:** si ya existen (fuente, acceso y tamaño aproximado), si habría que recolectarlos o si

tocaría generarlos — y qué se sabría *en el momento de predecir* (una variable que se conoce sólo después del resultado es filtración, no un predictor).

Las tres preguntas que la idea debe sobrevivir: ¿qué decisión cambia con la predicción?, ¿qué información existe en el momento de predecir y cuál es filtración disfrazada?, ¿contra qué referencia y con qué prueba se sabrá si funcionó? El Anexo A trae un ejemplo del formato.

3. Entrega 2 — El documento (50 pts)

Máximo **8 páginas** (sin contar referencias y anexos), letra de 11 puntos. Sus secciones son los pasos del flujo de trabajo del curso:

1. **La pregunta y la decisión.** Refinadas con la retroalimentación de la idea.
2. **Los datos.** Fuente, unidad, tamaño, los predictores por bloques, y qué se sabría en el momento de predecir. Si los datos se recolectarían o generarían: el plan, el costo y el calendario.
3. **Métrica, referencia y validación.** Con qué se mide el error (RMSE, MAE, AUC, o una métrica con costos); contra qué se compara (la media o la clase mayoritaria, un modelo lineal con las variables obvias y, si existe, la regla que hoy se usa); y el esquema de validación que la estructura de los datos exige — grupos, tiempo o espacio: ¿los pliegues al azar responderían la pregunta equivocada? ¿Qué queda bajo llave como prueba?
4. **Los métodos y por qué.** Al menos dos familias del curso que se compararían, con las perillas que habría que afinar y cómo las elegiría la validación.
5. **Qué se interpretaría y qué no.** Qué herramientas de la caja abierta se usarían (importancia, dependencia parcial, SHAP) y la advertencia de qué no dicen.
6. **Los riesgos.** Filtración, extrapolación, cambio de régimen entre el período de entrenamiento y el de uso, y — si hay personas — subgrupos donde el modelo podría fallar y a quién le costaría.
7. **El plan de trabajo.** Etapas, tiempos y qué entregaría cada una.

4. La presentación (40 pts)

El 24 de noviembre, en clase: **20 minutos por pareja y 10 de preguntas**. Es la defensa del diseño, no una lectura del documento: la sala debe salir convencida de que la pregunta vale, de que los datos alcanzan y de que la validación no se engaña. Las preguntas de la sala empiezan siempre por las tres de la Entrega 1, y siguen por los riesgos: qué pasa si los datos no llegan, dónde extrapolaría el modelo, qué subgrupo pagaría los errores.

5. Los datos: qué sirve y qué no

- Datos reales, del orden de miles de observaciones, con una y bien definida y al menos una decena de predictores. Fuentes públicas que funcionan bien: DANE (GEIH, censo, Encuesta de Calidad de Vida), SECOP, datos abiertos de alcaldías, Registraduría, avisos inmobiliarios, registros administrativos con acceso autorizado.
- Las bases del curso (puestos de votación, vivienda en Cali) sólo con una pregunta distinta a la de las clases y los problem sets.
- Una propuesta con datos por recolectar o por generar es válida si el plan es creíble y el diseño no depende de un milagro: diga cuánto costaría, cuánto tardaría y qué haría si no llegan.
- Texto e imágenes, sólo si la pareja ya sabe representarlos; no se recomienda aprenderlo dentro del proyecto.

6. Rúbrica (100 puntos del proyecto)

Entrega 1 — la idea en una página (10 pts): (4) la pregunta y la decisión, con la unidad y la y bien definidas; (3) los datos, con su disponibilidad contada con honestidad; (3) el método propuesto y qué se sabría en el momento de predecir.

Entrega 2 — el documento (50 pts): (8) pregunta y decisión; (8) datos; (12) métrica, referencia y validación acorde con la estructura; (10) métodos y perillas; (6) interpretación y sus advertencias; (6) riesgos y plan de trabajo. Un documento que supere las 8 páginas pierde 5 puntos.

La presentación (40 pts): (15) claridad del diseño en los 20 minutos (la decisión, los datos, la validación); (15) la defensa: respuestas a las preguntas de la sala con criterio técnico; (10) manejo del tiempo y materiales legibles.

Anexo A: ejemplo de la idea en una página

La pregunta y la decisión. ¿Cuánto vale un apartamento en Cali? Una entidad financiera debe valorar la garantía de cada crédito hipotecario sin enviar un perito a cada inmueble: un modelo que anticipe el precio de mercado reemplazaría el avalúo en los casos de bajo riesgo y lo priorizaría en los demás. Es una pregunta de $\hat{y}$: no interesa el efecto de ninguna característica, sólo la precisión de la valoración.

La unidad y la y. La unidad es el aviso de venta de un apartamento; y es el precio pedido, en millones de pesos. Se estimaría sobre el logaritmo y el error se reportaría en millones.

El método. Una referencia lineal (área, estrato, habitaciones) contra dos familias flexibles: bosques y *boosting*, que capturan sin escribirlas las interacciones entre ubicación y características; las perillas se afinarían con validación espacial.

Los datos. Avisos de un portal inmobiliario (datos abiertos de Properati), unos 20 mil apartamentos con área, habitaciones, baños, estrato, coordenadas y texto del aviso. Todo se conoce en el momento de predecir; el riesgo principal es el duplicado del mismo inmueble entre entrenamiento y prueba — la validación sería por bloques espaciales, no al azar, porque el uso real es valorar inmuebles en zonas con pocos créditos.