

Proyecto final del curso

Big Data y Machine Learning para Economía Aplicada — 60-121 (NRC 10-993)

Universidad Icesi — Departamento de Economía

Prof. Eduard Fernando Martínez González

1. Lógica y objetivo del proyecto

El proyecto final consiste en construir, de principio a fin y de forma reproducible, un ejercicio de **predicción** que responda una pregunta concreta de economía aplicada o de política pública. El énfasis está en tres cosas: la **pregunta** (qué se predice, para quién y para qué decisión), el **flujo de trabajo** del curso (partición, preprocesamiento dentro del *pipeline*, validación, ajuste, evaluación en una prueba intocada contra una referencia) y la **lectura** de los resultados (qué dice el modelo, qué no dice y dónde no debería usarse).

A diferencia de los problem sets, aquí el equipo elige la pregunta y los datos. No se pide un método nuevo: se pide usar bien los del curso, compararlos con honestidad y defender la comparación ante el grupo. El proyecto pesa el 60 % de la nota y se desarrolla en tres entregas encadenadas: la propuesta, la presentación de avances y el informe final con su repositorio.

2. Dinámica y cronograma

- **Martes 13 de octubre (sesión 5) — Entrega 1: propuesta.** Un documento de una a dos páginas y cinco minutos de exposición en clase. El grupo y el docente dan retroalimentación sobre la pregunta, los datos y la estrategia de validación.
- **Martes 10 de noviembre (sesión 9) — Presentación de avances.** Cada equipo presenta el diseño, el *pipeline*, el modelo de referencia y al menos un modelo flexible con su validación, y defiende la pertinencia de los métodos. La retroalimentación recibida se incorpora en el informe final.
- **Martes 24 de noviembre — Entrega 2: informe final y repositorio.** Documento de máximo diez páginas con el repositorio reproducible, hasta las 11:59 p. m.

Trabajo [POR DEFINIR: en parejas (los mismos equipos de los problem sets) o individual]. Envíe cada entrega también al correo efmartinez@icesi.edu.co con el asunto “Entrega N – Proyecto BDML”.

3. Entrega 1 — La propuesta (10 % del proyecto)

3.1 El documento (una a dos páginas)

Es un texto en prosa, sin resultados ni código. Debe contener, en este orden:

- **La pregunta predictiva y la decisión que la motiva.** Qué se quiere anticipar y quién haría algo distinto si lo supiera (un banco que valora garantías, una alcaldía que focaliza, una empresa que asigna inventario). Deje claro que es una pregunta de $\hat{y}$ y no de β : no se busca el efecto de nada.
- **La unidad de observación y la variable de resultado y .** Persona, hogar, inmueble, mesa, municipio, mes; con qué se mide y , en qué unidades y en qué período. Si y es una categoría, diga cuál es la clase de interés y qué tan frecuente es.
- **Los datos.** Fuente, acceso y licencia; número de observaciones y de predictores; qué bloques de predictores hay y cuáles podrían no estar disponibles en el momento de predecir (una variable que se conoce sólo después del resultado es filtración, no un predictor).

- **La métrica y la referencia.** Con qué se medirá el error (RMSE, MAE, AUC, o una métrica con costos) y contra qué se comparará: la media o la clase mayoritaria, un modelo lineal con las variables obvias y, si existe, la regla que hoy se usa en la práctica.
- **La estrategia de validación.** Cómo se partirá la muestra y qué estructura tienen los datos (temporal, espacial, por grupos) que obligue a validar por bloques y no al azar. Qué queda bajo llave como prueba.
- **Los riesgos.** Filtración, extrapolación, cambios entre el período de entrenamiento y el de uso, y subgrupos en los que el modelo podría fallar.

Al final del documento (Anexo A) hay un ejemplo del formato esperado.

3.2 La exposición (cinco minutos)

El foco es la pregunta y la validación: qué se predice, para qué decisión, con qué datos, contra qué referencia y cómo se evitará engañarse. Tras cada exposición el grupo discute qué puede salir mal; ese *feedback* es el insumo de la siguiente etapa.

4. Presentación de avances (30 % del proyecto)

En la sesión 9 cada equipo dispone de [POR DEFINIR: 15 minutos de exposición y 5 de preguntas]. Lo que el grupo espera ver:

- La pregunta y los datos, ya refinados con la retroalimentación de la propuesta.
- La partición y el *pipeline*: qué se hizo con los faltantes, las categorías y las escalas, y dónde vive ese preprocesamiento (dentro de la validación, no antes).
- La tabla de validación con la referencia, el modelo lineal y al menos un modelo flexible del curso (regularización, k -NN, árboles, bosques, *boosting* o redes) con sus hiperparámetros elegidos por validación.
- Una primera lectura: predicho vs. observado, error por decil o por subgrupo, y una importancia de variables.
- Lo que falta y lo que preocupa: es una presentación de avances, no de resultados finales. La prueba todavía no se ha tocado.

5. Entrega 2 — El informe final y el repositorio (60 % del proyecto)

5.1 El informe (máximo diez páginas, sin contar anexos)

1. **Pregunta y motivación** (una página): la decisión, la unidad, y , y por qué predecir ayuda.
2. **Datos** (una página): fuente, construcción de la muestra, descripción de y y de los bloques de predictores, faltantes, y el rango de los predictores en el entrenamiento.
3. **Metodología** (dos páginas): partición, *pipeline*, esquema de validación y su justificación, modelos comparados y cómo se afinaron sus hiperparámetros. Nada se eligió mirando la prueba.
4. **Resultados** (dos a tres páginas): la tabla canónica sobre la misma prueba (referencia, modelo lineal, modelos flexibles), con intervalos *bootstrap* para la métrica principal; predicho vs. observado; error por decil de y y por el subgrupo relevante; dónde falla el mejor modelo.
5. **Interpretación** (una a dos páginas): importancia de variables, dependencia parcial y valores SHAP del mejor modelo, con la advertencia explícita de que describen el modelo y no la causalidad.

6. **Limitaciones e implicaciones** (una página): extrapolación, cambios en el tiempo, subgrupos, equidad, y qué recomendaría a quien toma la decisión.

5.2 El repositorio

El análisis debe ejecutarse desde un único script documentado (`00_run.R`) que reproduzca todas las tablas y figuras del informe en un entorno limpio: rutas relativas, semilla fija, versiones del software (`sessionInfo()` o `renv`), datos en `input/` (o instrucciones para descargarlos si la licencia no permite redistribuirlos) y salidas en `output/tables` y `output/figures` con nombres cortos y asociables al informe. Sin rutas absolutas y sin archivos editados a mano.

6. Los datos: qué sirve y qué no

- Datos reales, del orden de miles de observaciones o más, con una y bien definida y al menos una decena de predictores. Fuentes públicas colombianas que funcionan bien: DANE (GEIH, censo, Encuesta de Calidad de Vida), SECOP, datos abiertos de alcaldías, Registraduría, avisos inmobiliarios, registros administrativos con acceso autorizado.
- Las tres bases del curso (mesas electorales, vivienda, imágenes satelitales) se pueden usar sólo con una pregunta distinta a la de los problem sets y las aplicaciones.
- Texto e imágenes son bienvenidos si el equipo ya sabe representarlos (sesión 8); no se recomienda aprender a hacerlo en el proyecto.
- Lecturas de referencia sobre cómo comparar muchos algoritmos con honestidad: Gu, Kelly & Xiu (2020); Medeiros, Vasconcelos, Veiga & Zilberman (2021); Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022).

7. Rúbrica (100 puntos del proyecto)

Entrega 1 — Propuesta (10 pts)

- (4 pts) Pregunta predictiva clara, con la decisión, la unidad y y bien definidas.
- (3 pts) Datos y predictores identificados, con los riesgos de filtración y extrapolación.
- (3 pts) Métrica, referencia y estrategia de validación coherentes con la estructura de los datos.

Presentación de avances (30 pts)

- (10 pts) Partición y *pipeline* correctos; validación acorde con la estructura de los datos.
- (10 pts) Tabla de validación con referencia, modelo lineal y al menos un modelo flexible afinado.
- (10 pts) Defensa: claridad, pertinencia de los métodos, respuesta a las preguntas e incorporación del *feedback* de la propuesta.

Entrega 2 — Informe final y repositorio (60 pts)

- (8 pts) Pregunta, datos y construcción de la muestra.
- (12 pts) Metodología: *pipeline*, validación, hiperparámetros elegidos sin tocar la prueba.
- (14 pts) Resultados: tabla canónica sobre la misma prueba con intervalos, figuras de diagnóstico, lectura de dónde falla el modelo.
- (10 pts) Interpretación: importancia, dependencia parcial y SHAP, con sus advertencias.
- (8 pts) Limitaciones e implicaciones para la decisión.

- (8 pts) Reproducibilidad: `00_run.R`, rutas relativas, `sessionInfo()`/`renv`, salidas generadas automáticamente.

Nota. Se permite el uso de IA con declaración explícita de qué se usó y para qué.

Anexo A: ejemplo de propuesta

Pregunta predictiva y decisión. ¿Cuánto vale un apartamento en Cali? Una entidad financiera necesita valorar la garantía de cada crédito hipotecario sin enviar un perito a cada inmueble; un modelo que anticipe el precio de mercado a partir de las características del aviso reemplazaría el avalúo en los casos de bajo riesgo y lo priorizaría en los demás. Es una pregunta de $\hat{y}$: no interesa el efecto de ninguna característica, sólo la precisión de la valoración.

Unidad y variable de resultado. La unidad es el aviso de venta de un apartamento; y es el precio pedido en millones de pesos de 2024. Como referencia, el logaritmo del precio se usará para estimar y el error se reportará en pesos.

Datos. Avisos de un portal inmobiliario (Properati, datos abiertos), 2023–2024, alrededor de 20 mil apartamentos en Cali con área, habitaciones, baños, parqueaderos, estrato, barrio, coordenadas y el texto del aviso. El texto se conoce en el momento de predecir; el precio de cierre no se observa, de modo que el modelo predice el precio pedido y la entidad aplicará después su propio descuento.

Métrica y referencia. RMSE y MAE en millones, y R^2 de prueba. Referencias: la mediana del precio por estrato y una regresión lineal con área, estrato y habitaciones. Si la entidad comparte sus avalúos históricos, la regla vigente será la tercera referencia.

Validación. Partición 80/20 con la prueba bajo llave. Los avisos de un mismo edificio comparten casi todo, así que la validación cruzada será por bloques espaciales (barrio o celdas de la cuadrícula), no aleatoria: el uso real es valorar inmuebles en zonas donde la entidad tiene pocos créditos.

Riesgos. Duplicados de un mismo inmueble publicado varias veces (filtración entre entrenamiento y prueba); avisos de más de 300 m² y de estratos 1 y 2, escasos en la muestra (extrapolación); cambio de precios entre 2023 y 2024 (deriva temporal) y errores sistemáticos por barrio que deberán reportarse en el mapa de residuos.