

Big Data y Machine Learning para Economía Aplicada

Week 01: Fundamentos del Aprendizaje Estadístico

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 22, 2026

Acerca de este curso

1 Al finalizar el curso podrás:

- ▶ Predecir y clasificar variables económicas con métodos de ML.
- ▶ Elegir, ajustar y validar modelos con desempeño *out-of-sample*.
- ▶ Implementar todo el flujo en R (traducción opcional a Python).
- ▶ Leer críticamente investigación económica que usa ML.

2 Bloques principales:

- ▶ Fundamentos del aprendizaje estadístico.
- ▶ Métodos supervisados: regularización, árboles y *boosting*.
- ▶ Clasificación, ML causal y aprendizaje no supervisado.
- ▶ Datos no estructurados: redes neuronales, texto y LLMs.

3 Metodología:

- ▶ Exposición teórica del profesor: intuición antes que formalismo.
- ▶ Aplicaciones guiadas en R con datos reales.
- ▶ Discusión de artículos aplicados.

4 Evaluación:

- ▶ Taller 1: 20%. Taller 2: 20%. Proyecto final: 60%.

El mapa de las 9 sesiones

#	Tema
1	Fundamentos del aprendizaje estadístico ← hoy
2	Validación cruzada, selección de modelos y regularización
3	Modelos lineales de alta dimensión: la teoría del Lasso
4	Árboles, Random Forest y <i>boosting</i>
5	Clasificación y métricas de desempeño
6	Machine learning para inferencia causal
7	Aprendizaje no supervisado y reducción de dimensión
8	Redes neuronales y visión por computadora
9	Texto como datos y LLMs + presentaciones finales

- **Taller 1** cubre las sesiones 1–5; **Taller 2** cubre las sesiones 6–9.
- El **proyecto final** corre en paralelo durante todo el semestre.
- Cada sesión introduce un método, lo formaliza y lo aterriza en una aplicación económica con su propio conjunto de datos.

Talleres ($2 \times 20\%$)

- Se realizarán **2 talleres** en parejas, para desarrollar en casa.
- Cada taller tiene dos componentes:
 - ➊ **Demostración matemática (40%)**: derivaciones formales de los métodos vistos. P. ej.: descomposición sesgo–varianza, soluciones de Ridge/Lasso vía KKT, un paso de *gradient boosting* (Taller 1); PCA como problema de autovalores, un paso de retropropagación (Taller 2).
 - ➋ **Componente aplicado (60%)**: *pipeline* predictivo completo con validación cruzada sobre datos reales.
- **Entrega**: documento .pdf + repositorio reproducible con código .R.
- Se valorará claridad, rigor y notación.
- Las fechas de entrega serán anunciadas con al menos **una semana** de anticipación.

Proyecto final aplicado (60%)

- En grupos de **2–3 estudiantes**: definir una **pregunta económica** concreta, identificar un conjunto de datos, aplicar **varios algoritmos de ML** y evaluar su desempeño **fuera de muestra**.
- **Entregables**:
 - ▶ **Entrega 1 — Propuesta (10% del proyecto)**: pregunta, datos, métrica objetivo y estrategia de validación.
 - ▶ **Entrega 2 — Reporte (60% del proyecto)**: documento de máximo **10 páginas** con resultados, comparación de modelos y diagnósticos, acompañado del repositorio reproducible.
 - ▶ **Presentación (30% del proyecto)**: exposición en la última sesión, discutiendo la pertinencia de los métodos y sus implicaciones de política.
- **Logística**: el detalle paso a paso será cargado en **Intu**.

Nivelación en R y política de IA

Nivelación en R (obligatoria, autónoma, por fuera del horario de clase):

- Introducción a R: [Disponible \[aquí\]](#)
- Manipulación de datos con `dplyr`: [Disponible \[aquí\]](#)
- Lectura y escritura de datos: [Disponible \[aquí\]](#)
- Gestión y organización de datos: [Disponible \[aquí\]](#)
- Buenas prácticas de modelamiento con `tidymodels`: material en **Intu**.
- Para quienes opten por la vía Python, se ofrece material equivalente de referencia.

Nivelación en R y política de IA

Nivelación en R (obligatoria, autónoma, por fuera del horario de clase):

- Introducción a R: [Disponible \[aquí\]](#)
- Manipulación de datos con `dplyr`: [Disponible \[aquí\]](#)
- Lectura y escritura de datos: [Disponible \[aquí\]](#)
- Gestión y organización de datos: [Disponible \[aquí\]](#)
- Buenas prácticas de modelamiento con `tidymodels`: material en **Intu**.
- Para quienes opten por la vía Python, se ofrece material equivalente de referencia.

Política de IA

Se permite el uso de herramientas de IA en cualquier componente del curso, siempre que se **declare explícitamente** qué se usó y para qué.

1 Motivación: ¿por qué ML en economía?

2 El marco del aprendizaje estadístico

3 Sobreajuste y complejidad

4 La descomposición sesgo–varianza

5 Las dos culturas y el mapa del curso

¿Qué entendemos por Big Data?

- **Big n** (muchas observaciones) es solo una parte de la historia.

¿Qué entendemos por Big Data?

- **Big** n (muchas observaciones) es solo una parte de la historia.
- Big también es **big** p : muchas covariables — a veces $p \gg n$ (registros administrativos, genómica de la firma, miles de características de una vivienda).

¿Qué entendemos por Big Data?

- **Big** n (muchas observaciones) es solo una parte de la historia.
- Big también es **big** p : muchas covariables — a veces $p \gg n$ (registros administrativos, genómica de la firma, miles de características de una vivienda).
- Y big también son los **datos que no surgen de fuentes tradicionales** (encuestas, cuentas nacionales):
 - ▶ Datos de la web: búsquedas, precios en línea, redes sociales.
 - ▶ Imágenes satelitales, luces nocturnas, datos geoespaciales.
 - ▶ Texto: comunicados de banca central, noticias, sentencias judiciales.
 - ▶ Registros transaccionales: tarjetas, telefonía móvil, GPS.

¿Qué entendemos por Big Data?

- **Big** n (muchas observaciones) es solo una parte de la historia.
- Big también es **big** p : muchas covariables — a veces $p \gg n$ (registros administrativos, genómica de la firma, miles de características de una vivienda).
- Y big también son los **datos que no surgen de fuentes tradicionales** (encuestas, cuentas nacionales):
 - ▶ Datos de la web: búsquedas, precios en línea, redes sociales.
 - ▶ Imágenes satelitales, luces nocturnas, datos geoespaciales.
 - ▶ Texto: comunicados de banca central, noticias, sentencias judiciales.
 - ▶ Registros transaccionales: tarjetas, telefonía móvil, GPS.

Implicación

Estos datos son masivos, de alta dimensión y sin estructura de encuesta. Los métodos clásicos de la econometría no fueron diseñados para explotarlos — ahí entra el *machine learning*.

¿Y qué es machine learning?

Un cambio de paradigma: de estimar β a predecir y

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .

¿Y qué es machine learning?

Un cambio de paradigma: de estimar β a predecir y

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .
- La parte de “aprendizaje”: **no especificamos** de antemano la forma exacta en que la máquina debe predecir y a partir de x ; eso queda como un problema empírico que el algoritmo resuelve con los datos.

¿Y qué es machine learning?

Un cambio de paradigma: de estimar β a predecir y

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .
- La parte de “aprendizaje”: **no especificamos** de antemano la forma exacta en que la máquina debe predecir y a partir de x ; eso queda como un problema empírico que el algoritmo resuelve con los datos.
- El enfoque es pragmático: nos abstraemos del modelo subyacente.

“Whatever works, works. . .”

¿Y qué es machine learning?

Un cambio de paradigma: de estimar β a predecir y

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .
- La parte de “aprendizaje”: **no especificamos** de antemano la forma exacta en que la máquina debe predecir y a partir de x ; eso queda como un problema empírico que el algoritmo resuelve con los datos.
- El enfoque es pragmático: nos abstraemos del modelo subyacente.

“Whatever works, works. . .”

- ¿En qué se diferencia de la econometría que ya conocen?

¿Y qué es machine learning?

Un cambio de paradigma: de estimar β a predecir y

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .
- La parte de “aprendizaje”: **no especificamos** de antemano la forma exacta en que la máquina debe predecir y a partir de x ; eso queda como un problema empírico que el algoritmo resuelve con los datos.
- El enfoque es pragmático: nos abstraemos del modelo subyacente.

“Whatever works, works. . .”

- **¿En qué se diferencia de la econometría que ya conocen?**
 - ▶ Econometría clásica: estimar **parámetros** (β) con propiedades deseables e interpretarlos.
 - ▶ ML: producir **predicciones** ($\hat{y}$) que funcionen bien en datos **nuevos**.

La primera gran victoria del ML: Google Flu Trends

Contexto (2008): en EE.UU., la vigilancia de la gripe dependía de los reportes que los centros médicos envían a la CDC.

- La CDC agrega los reportes por región y a nivel nacional.
- Todo el proceso tomaba $\approx$ **10 días** $\rightarrow$ demasiado para una epidemia.

La primera gran victoria del ML: Google Flu Trends

Contexto (2008): en EE.UU., la vigilancia de la gripe dependía de los reportes que los centros médicos envían a la CDC.

- La CDC agrega los reportes por región y a nivel nacional.
- Todo el proceso tomaba $\approx$ **10 días** $\rightarrow$ demasiado para una epidemia.

La propuesta de Google (Ginsberg et al., 2009, *Nature*):

- Cruzar los datos oficiales con las **búsquedas** relacionadas con la gripe.
- Evaluaron $\approx$ **50 millones** de términos candidatos y $\approx$ **450 millones** de modelos; el modelo final usaba 45 términos.

La primera gran victoria del ML: Google Flu Trends

Contexto (2008): en EE.UU., la vigilancia de la gripe dependía de los reportes que los centros médicos envían a la CDC.

- La CDC agrega los reportes por región y a nivel nacional.
- Todo el proceso tomaba $\approx$ **10 días** $\rightarrow$ demasiado para una epidemia.

La propuesta de Google (Ginsberg et al., 2009, *Nature*):

- Cruzar los datos oficiales con las **búsquedas** relacionadas con la gripe.
- Evaluaron $\approx$ **50 millones** de términos candidatos y $\approx$ **450 millones** de modelos; el modelo final usaba 45 términos.
- Resultado: predicciones de intensidad de gripe casi en **tiempo real**, para cualquier región.
- A Google le tomaba **1 día** lo que a la CDC **10**.

La primera gran victoria del ML: Google Flu Trends

Contexto (2008): en EE.UU., la vigilancia de la gripe dependía de los reportes que los centros médicos envían a la CDC.

- La CDC agrega los reportes por región y a nivel nacional.
- Todo el proceso tomaba $\approx$ **10 días** $\rightarrow$ demasiado para una epidemia.

La propuesta de Google (Ginsberg et al., 2009, *Nature*):

- Cruzar los datos oficiales con las **búsquedas** relacionadas con la gripe.
- Evaluaron $\approx$ **50 millones** de términos candidatos y $\approx$ **450 millones** de modelos; el modelo final usaba 45 términos.
- Resultado: predicciones de intensidad de gripe casi en **tiempo real**, para cualquier región.
- A Google le tomaba **1 día** lo que a la CDC **10**.

Sin teoría epidemiológica, sin encuestas, sin modelo estructural.

¿Convencidos?

... y su primera gran derrota

“The Parable of Google Flu” (Lazer et al., 2014, Science)

- En la temporada 2012–2013, Google Flu Trends predijo **más del doble** de los casos que efectivamente ocurrieron.

... y su primera gran derrota

“The Parable of Google Flu” (Lazer et al., 2014, Science)

- En la temporada 2012–2013, Google Flu Trends predijo **más del doble** de los casos que efectivamente ocurrieron.
- De hecho, sobreestimó la prevalencia en **100 de las 108 semanas** posteriores a agosto de 2011.

... y su primera gran derrota

“The Parable of Google Flu” (Lazer et al., 2014, Science)

- En la temporada 2012–2013, Google Flu Trends predijo **más del doble** de los casos que efectivamente ocurrieron.
- De hecho, sobreestimó la prevalencia en **100 de las 108 semanas** posteriores a agosto de 2011.
- **¿Qué salió mal?**
 - ▶ Con 50 millones de términos, muchos correlacionan con la gripe **por azar** (p. ej., búsquedas estacionales de baloncesto).
 - ▶ El comportamiento de búsqueda **cambia con el tiempo** (y Google cambia su buscador): el modelo se entrenó en un mundo que dejó de existir.
 - ▶ “*Big data hubris*”: la idea implícita de que el tamaño de los datos sustituye a la medición y a la validación cuidadosas.

... y su primera gran derrota

“The Parable of Google Flu” (Lazer et al., 2014, Science)

- En la temporada 2012–2013, Google Flu Trends predijo **más del doble** de los casos que efectivamente ocurrieron.
- De hecho, sobreestimó la prevalencia en **100 de las 108 semanas** posteriores a agosto de 2011.
- **¿Qué salió mal?**
 - ▶ Con 50 millones de términos, muchos correlacionan con la gripe **por azar** (p. ej., búsquedas estacionales de baloncesto).
 - ▶ El comportamiento de búsqueda **cambia con el tiempo** (y Google cambia su buscador): el modelo se entrenó en un mundo que dejó de existir.
 - ▶ “*Big data hubris*”: la idea implícita de que el tamaño de los datos sustituye a la medición y a la validación cuidadosas.

La lección que organiza este curso

Predecir bien **dentro** de la muestra es fácil; lo difícil es **generalizar** a datos nuevos. Todo el aparato de hoy (riesgo, sobreajuste, sesgo–varianza) existe para **atacar ese problema**.

¿Paraguas o danza de la lluvia?

Kleinberg, Ludwig, Mullainathan & Obermeyer (2015): prediction policy problems

No toda pregunta de política necesita un efecto causal. Comparen:

¿Paraguas o danza de la lluvia?

Kleinberg, Ludwig, Mullainathan & Obermeyer (2015): prediction policy problems

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

¿Paraguas o danza de la lluvia?

Kleinberg, Ludwig, Mullainathan & Obermeyer (2015): prediction policy problems

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

Ejemplos reales de problemas de predicción en política pública:

- **Cirugías fútiles:** miles de reemplazos de cadera/rodilla se hacen a pacientes que fallecen dentro del año siguiente; predecir mortalidad permitiría reasignar el gasto.

¿Paraguas o danza de la lluvia?

Kleinberg, Ludwig, Mullainathan & Obermeyer (2015): prediction policy problems

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

Ejemplos reales de problemas de predicción en política pública:

- **Cirugías fútiles:** miles de reemplazos de cadera/rodilla se hacen a pacientes que fallecen dentro del año siguiente; predecir mortalidad permitiría reasignar el gasto.
- **Libertad provisional** (Kleinberg et al., 2018, QJE): jueces deciden con una predicción implícita de fuga o reincidencia. Un modelo de ML podría reducir el crimen $\approx 25\%$ sin más presos, o la población carcelaria $\approx 42\%$ sin más crimen.

¿Paraguas o danza de la lluvia?

Kleinberg, Ludwig, Mullainathan & Obermeyer (2015): prediction policy problems

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

Ejemplos reales de problemas de predicción en política pública:

- **Cirugías fútiles:** miles de reemplazos de cadera/rodilla se hacen a pacientes que fallecen dentro del año siguiente; predecir mortalidad permitiría reasignar el gasto.
- **Libertad provisional** (Kleinberg et al., 2018, QJE): jueces deciden con una predicción implícita de fuga o reincidencia. Un modelo de ML podría reducir el crimen $\approx 25\%$ sin más presos, o la población carcelaria $\approx 42\%$ sin más crimen.
- **Focalización:** el Sisbén es, en esencia, un **clasificador** de hogares — predice pobreza estructural a partir de características observables.

$\hat{y}$ -problems vs. β -problems

Mullainathan & Spiess (2017)

Econometría I–II les enseñó a estimar β creíbles. Este curso optimiza $\hat{y}$:

	Inferencia causal	Predicción (ML)
Objeto de interés	$\hat{\beta}$	$\hat{y}$
Pregunta típica	¿qué pasa si intervengo?	¿qué valor tomará y ?
Enemigo principal	sesgo (selección, omitidas)	sobreajuste (varianza)
Validación	diseño + supuestos	desempeño <i>out-of-sample</i>
Ejemplo	¿la beca mejora el Saber Pro?	¿qué hogar caerá en pobreza?

$\hat{y}$ -problems vs. β -problems

Mullainathan & Spiess (2017)

Econometría I–II les enseñó a estimar β creíbles. Este curso optimiza $\hat{y}$:

	Inferencia causal	Predicción (ML)
Objeto de interés	$\hat{\beta}$	$\hat{y}$
Pregunta típica	¿qué pasa si intervengo?	¿qué valor tomará y ?
Enemigo principal	sesgo (selección, omitidas)	sobreajuste (varianza)
Validación	diseño + supuestos	desempeño <i>out-of-sample</i>
Ejemplo	¿la beca mejora el Saber Pro?	¿qué hogar caerá en pobreza?

- Son preguntas **distintas** que exigen herramientas distintas: un modelo puede predecir muy bien con coeficientes sin interpretación causal, y viceversa.
- **No son rivales:** en la sesión 6 veremos cómo la buena predicción se pone al servicio de la inferencia causal (*double machine learning*).

El ML ya está en la caja de herramientas del economista

Algunos ejemplos publicados:

- **Pobreza desde el cielo** (Jean et al., 2016, *Science*): imágenes satelitales + *transfer learning* explican entre **37% y 55%** de la variación del consumo promedio en cinco países africanos. Clave donde no hay encuestas frecuentes.

El ML ya está en la caja de herramientas del economista

Algunos ejemplos publicados:

- **Pobreza desde el cielo** (Jean et al., 2016, *Science*): imágenes satelitales + *transfer learning* explican entre **37% y 55%** de la variación del consumo promedio en cinco países africanos. Clave donde no hay encuestas frecuentes.
- **Texto de política monetaria** (Hansen, McMahon & Prat, 2018, QJE): modelos de tópicos sobre las transcripciones del FOMC para medir deliberación y transparencia.

El ML ya está en la caja de herramientas del economista

Algunos ejemplos publicados:

- **Pobreza desde el cielo** (Jean et al., 2016, *Science*): imágenes satelitales + *transfer learning* explican entre **37% y 55%** de la variación del consumo promedio en cinco países africanos. Clave donde no hay encuestas frecuentes.
- **Texto de política monetaria** (Hansen, McMahon & Prat, 2018, QJE): modelos de tópicos sobre las transcripciones del FOMC para medir deliberación y transparencia.
- **Decisiones judiciales** (Kleinberg et al., 2018, QJE): predicción de riesgo para informar decisiones de libertad provisional.

El ML ya está en la caja de herramientas del economista

Algunos ejemplos publicados:

- **Pobreza desde el cielo** (Jean et al., 2016, *Science*): imágenes satelitales + *transfer learning* explican entre **37% y 55%** de la variación del consumo promedio en cinco países africanos. Clave donde no hay encuestas frecuentes.
- **Texto de política monetaria** (Hansen, McMahon & Prat, 2018, QJE): modelos de tópicos sobre las transcripciones del FOMC para medir deliberación y transparencia.
- **Decisiones judiciales** (Kleinberg et al., 2018, QJE): predicción de riesgo para informar decisiones de libertad provisional.

Y en la práctica profesional colombiana:

- *Scoring* de crédito en bancos y *fintech*.
- Focalización de programas sociales (Sisbén IV).
- *Nowcasting* de actividad económica e inflación con datos de alta frecuencia.

- 1 Motivación: ¿por qué ML en economía?
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 La descomposición sesgo–varianza
- 5 Las dos culturas y el mapa del curso

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

Descomposición fundamental: siempre podemos escribir

$$Y = f(X) + \varepsilon, \quad \text{con } f(x) \equiv \mathbb{E}[Y \mid X = x]$$

- f : la **función de regresión** — la parte sistemática de Y .
- $\varepsilon \equiv Y - f(X)$: lo que X no explica. **Por construcción** $\mathbb{E}[\varepsilon \mid X] = 0$, con $\text{Var}(\varepsilon) = \sigma^2$.

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

Descomposición fundamental: siempre podemos escribir

$$Y = f(X) + \varepsilon, \quad \text{con } f(x) \equiv \mathbb{E}[Y \mid X = x]$$

- f : la **función de regresión** — la parte sistemática de Y .
- $\varepsilon \equiv Y - f(X)$: lo que X no explica. **Por construcción** $\mathbb{E}[\varepsilon \mid X] = 0$, con $\text{Var}(\varepsilon) = \sigma^2$.

La meta del aprendizaje supervisado

Usar los datos para construir $\hat{f} \approx f$. En econometría nos importaba un **parámetro dentro** de f ; aquí nos importa la **función completa**, porque con ella predecimos.

¿Qué significa exactamente “aprender”?

Aprender = elegir $\hat{f}$ dentro de una **clase de funciones** $\mathcal{F}$ usando los datos:

- $\mathcal{F}$ puede ser: rectas, polinomios, árboles, redes neuronales. . .
- Cada sesión de este curso es, en el fondo, una clase $\mathcal{F}$ distinta.

¿Qué significa exactamente “aprender”?

Aprender = elegir $\hat{f}$ dentro de una **clase de funciones** $\mathcal{F}$ usando los datos:

- $\mathcal{F}$ puede ser: rectas, polinomios, árboles, redes neuronales. . .
- Cada sesión de este curso es, en el fondo, una clase $\mathcal{F}$ distinta.

¿Y qué es una “buena” $\hat{f}$? Necesitamos una **función de pérdida** $L(y, \hat{f}(x))$ que mida el costo de equivocarse:

- **Cuadrática:** $L = (y - \hat{f}(x))^2$. Castiga fuerte los errores grandes; estándar en regresión.
- **Absoluta:** $L = |y - \hat{f}(x)|$. Más robusta a valores extremos.
- **0–1:** $L = \mathbb{I}\{y \neq \hat{f}(x)\}$. Para clasificación (sesión 5).

¿Qué significa exactamente “aprender”?

Aprender = elegir $\hat{f}$ dentro de una **clase de funciones** $\mathcal{F}$ usando los datos:

- $\mathcal{F}$ puede ser: rectas, polinomios, árboles, redes neuronales. . .
- Cada sesión de este curso es, en el fondo, una clase $\mathcal{F}$ distinta.

¿Y qué es una “buena” $\hat{f}$? Necesitamos una **función de pérdida** $L(y, \hat{f}(x))$ que mida el costo de equivocarse:

- **Cuadrática:** $L = (y - \hat{f}(x))^2$. Castiga fuerte los errores grandes; estándar en regresión.
- **Absoluta:** $L = |y - \hat{f}(x)|$. Más robusta a valores extremos.
- **0–1:** $L = \mathbb{I}\{y \neq \hat{f}(x)\}$. Para clasificación (sesión 5).

La elección de L es una decisión económica

¿Qué error cuesta más? No es lo mismo subestimar la demanda (ventas perdidas) que sobreestimarla (inventario muerto); ni un falso positivo que un falso negativo al focalizar un subsidio.

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

¿Quién minimiza el riesgo bajo pérdida cuadrática? Condicionemos en $X = x$ y busquemos la mejor predicción constante c :

1. Expandimos:

$$\mathbb{E}[(Y - c)^2 \mid X = x] = \text{Var}(Y \mid X = x) + (\mathbb{E}[Y \mid X = x] - c)^2$$

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

¿Quién minimiza el riesgo bajo pérdida cuadrática? Condicionemos en $X = x$ y busquemos la mejor predicción constante c :

1. Expandimos:

$$\mathbb{E}[(Y - c)^2 \mid X = x] = \text{Var}(Y \mid X = x) + (\mathbb{E}[Y \mid X = x] - c)^2$$

2. Minimizamos en c : el primer término no depende de c ; el segundo es ≥ 0 y se anula en

$$c^* = \mathbb{E}[Y \mid X = x]$$

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

¿Quién minimiza el riesgo bajo pérdida cuadrática? Condicionemos en $X = x$ y busquemos la mejor predicción constante c :

1. Expandimos:

$$\mathbb{E}[(Y - c)^2 \mid X = x] = \text{Var}(Y \mid X = x) + (\mathbb{E}[Y \mid X = x] - c)^2$$

2. Minimizamos en c : el primer término no depende de c ; el segundo es ≥ 0 y se anula en

$$c^* = \mathbb{E}[Y \mid X = x]$$

3. Conclusión:

$$f^*(x) = \mathbb{E}[Y \mid X = x] = \arg \min_f R(f)$$

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

¿Quién minimiza el riesgo bajo pérdida cuadrática? Condicionemos en $X = x$ y busquemos la mejor predicción constante c :

1. Expandimos:

$$\mathbb{E}[(Y - c)^2 \mid X = x] = \text{Var}(Y \mid X = x) + (\mathbb{E}[Y \mid X = x] - c)^2$$

2. Minimizamos en c : el primer término no depende de c ; el segundo es ≥ 0 y se anula en

$$c^* = \mathbb{E}[Y \mid X = x]$$

3. Conclusión:

$$f^*(x) = \mathbb{E}[Y \mid X = x] = \arg \min_f R(f)$$

Interpretación

La **media condicional** es el objetivo teórico de todo el curso. Por eso la regresión — que la aproxima — es el punto de partida natural del ML

Error reducible y error irreducible

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

Error reducible y error irreducible

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

1. Sustituimos y expandimos:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \mathbb{E}[(f(x) - \hat{f}(x) + \varepsilon)^2] = (f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x)) \mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2]$$

Error reducible y error irreducible

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

1. Sustituimos y expandimos:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \mathbb{E}[(f(x) - \hat{f}(x) + \varepsilon)^2] = (f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x)) \mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2]$$

2. Como $\mathbb{E}[\varepsilon] = 0$, el término cruzado desaparece:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreducible}}$$

Error reducible y error irreducible

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

1. Sustituimos y expandimos:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \mathbb{E}[(f(x) - \hat{f}(x) + \varepsilon)^2] = (f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x)) \mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2]$$

2. Como $\mathbb{E}[\varepsilon] = 0$, el término cruzado desaparece:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreducible}}$$

- **Reducible:** qué tan lejos está nuestra $\hat{f}$ de la verdadera f . Es lo que un mejor método puede mejorar.
- **Irreducible** (σ^2): ni el modelo perfecto ($\hat{f} = f$) lo elimina. Es el techo de lo aprendible con estos predictores.

Error reducible y error irreducible

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

1. Sustituimos y expandimos:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \mathbb{E}[(f(x) - \hat{f}(x) + \varepsilon)^2] = (f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x)) \mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2]$$

2. Como $\mathbb{E}[\varepsilon] = 0$, el término cruzado desaparece:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreducible}}$$

- **Reducible:** qué tan lejos está nuestra $\hat{f}$ de la verdadera f . Es lo que un mejor método puede mejorar.
- **Irreducible** (σ^2): ni el modelo perfecto ($\hat{f} = f$) lo elimina. Es el techo de lo aprendible con estos predictores.

Mensaje

Si el desempeño de un modelo parece “malo”, la causa puede ser σ^2 alto — no siempre hay un mejor algoritmo; a veces faltan mejores **datos**.

El riesgo empírico y su trampa

Problema: $R(f) = \mathbb{E}[L(Y, f(X))]$ depende de P , que no conocemos.

El riesgo empírico y su trampa

Problema: $R(f) = \mathbb{E}[L(Y, f(X))]$ depende de P , que no conocemos.

Solución natural: estimarlo con el promedio muestral — el **riesgo empírico**:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

y elegir el modelo minimizándolo (*empirical risk minimization*):

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$$

El riesgo empírico y su trampa

Problema: $R(f) = \mathbb{E}[L(Y, f(X))]$ depende de P , que no conocemos.

Solución natural: estimarlo con el promedio muestral — el **riesgo empírico**:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

y elegir el modelo minimizándolo (*empirical risk minimization*):

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$$

La trampa: evaluar $\hat{f}$ con los **mismos datos** con que se eligió.

- $\hat{R}(\hat{f})$ es **optimista**: $\hat{f}$ fue construida *precisamente* para minimizarlo. Es presentar el examen con las respuestas en la mano.

El riesgo empírico y su trampa

Problema: $R(f) = \mathbb{E}[L(Y, f(X))]$ depende de P , que no conocemos.

Solución natural: estimarlo con el promedio muestral — el **riesgo empírico**:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

y elegir el modelo minimizándolo (*empirical risk minimization*):

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$$

La trampa: evaluar $\hat{f}$ con los **mismos datos** con que se eligió.

- $\hat{R}(\hat{f})$ es **optimista**: $\hat{f}$ fue construida *precisamente* para minimizarlo. Es presentar el examen con las respuestas en la mano.
- Con $\mathcal{F}$ suficientemente flexible, $\hat{R}(\hat{f}) = 0$: basta **memorizar** los datos. Y un modelo que memoriza no ha aprendido nada generalizable.

El riesgo empírico y su trampa

Problema: $R(f) = \mathbb{E}[L(Y, f(X))]$ depende de P , que no conocemos.

Solución natural: estimarlo con el promedio muestral — el **riesgo empírico**:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

y elegir el modelo minimizándolo (*empirical risk minimization*):

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$$

La trampa: evaluar $\hat{f}$ con los **mismos datos** con que se eligió.


- $\hat{R}(\hat{f})$ es **optimista**: $\hat{f}$ fue construida *precisamente* para minimizarlo. Es presentar el examen con las respuestas en la mano.
- Con $\mathcal{F}$ suficientemente flexible, $\hat{R}(\hat{f}) = 0$: basta **memorizar** los datos. Y un modelo que memoriza no ha aprendido nada generalizable.

Regla de oro #1

El error de entrenamiento **no** estima el error de generalización.


Entrenamiento vs. prueba

La solución más simple: separar los datos **antes** de tocar cualquier modelo.



Entrenamiento vs. prueba


La solución más simple: separar los datos **antes** de tocar cualquier modelo.



- El conjunto de **prueba** simula los “datos nuevos”: su error sí estima $R(\hat{f})$ honestamente.
- **Regla de oro #2:** el conjunto de prueba se usa **al final y una sola vez**. Si lo usamos muchas veces para escoger el modelo, se convierte — en la práctica — en un segundo conjunto de entrenamiento.

Entrenamiento vs. prueba

La solución más simple: separar los datos **antes** de tocar cualquier modelo.




- El conjunto de **prueba** simula los “datos nuevos”: su error sí estima $R(\hat{f})$ honestamente.
- **Regla de oro #2:** el conjunto de prueba se usa **al final y una sola vez**. Si lo usamos muchas veces para escoger el modelo, se convierte — en la práctica — en un segundo conjunto de entrenamiento.
- ¿Y si la muestra es pequeña y partirla “duele”? De eso se encarga la **validación cruzada** (sesión 2).


- 1 Motivación: ¿por qué ML en economía?
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad**
- 4 La descomposición sesgo–varianza
- 5 Las dos culturas y el mapa del curso

Un mismo conjunto de datos, tres modelos


Ajustemos polinomios de grado creciente a los mismos 9 puntos:



Grado 1: **subajuste**




Grado 3: $\approx f$




Grado 15: **sobreajuste**

Un mismo conjunto de datos, tres modelos


Ajustemos polinomios de grado creciente a los mismos 9 puntos:



Grado 1: **subajuste**




Grado 3: $\approx f$




Grado 15: **sobreajuste**

- **Grado 1:** demasiado rígido — no captura la forma de f (error por **sesgo**).
- **Grado 15:** pasa por *todos* los puntos — ajusta el **ruido** ε , no la señal (error por **varianza**).
- ¿Cuál predice mejor un punto **nuevo**? El del medio. Ni el más simple ni el que “mejor ajusta”.

La curva que resume el curso



La curva que resume el curso



- El error de **entrenamiento** cae *monótonamente* con la complejidad: más flexibilidad siempre ajusta mejor la muestra.
- El error de **prueba** tiene forma de **U**: mejora hasta cierto punto y luego el sobreajuste lo destruye.
- **Todo el curso vive en esta figura**: cada método trae una “perilla” de complejidad y una forma de encontrar el mínimo de la curva roja.

¿Qué es exactamente la “complejidad”?

Informalmente: la **capacidad** de la clase $\mathcal{F}$ para ajustar patrones arbitrarios.

¿Qué es exactamente la “complejidad”?

Informalmente: la **capacidad** de la clase $\mathcal{F}$ para ajustar patrones arbitrarios.

- En regresión polinómica: el **grado** del polinomio.
- En regresión múltiple: el **número de predictores** p .
- Más adelante en el curso, cada método tendrá su propia perilla:
 - ▶ Regularización: el parámetro de penalización λ (sesiones 2–3).
 - ▶ Árboles: la profundidad y el tamaño de las hojas (sesión 4).
 - ▶ k -NN: el número de vecinos k (sesión 5).
 - ▶ Redes neuronales: capas, neuronas, *dropout* (sesión 8).

¿Qué es exactamente la “complejidad”?

Informalmente: la **capacidad** de la clase $\mathcal{F}$ para ajustar patrones arbitrarios.

- En regresión polinómica: el **grado** del polinomio.
- En regresión múltiple: el **número de predictores** p .
- Más adelante en el curso, cada método tendrá su propia perilla:
 - ▶ Regularización: el parámetro de penalización λ (sesiones 2–3).
 - ▶ Árboles: la profundidad y el tamaño de las hojas (sesión 4).
 - ▶ k -NN: el número de vecinos k (sesión 5).
 - ▶ Redes neuronales: capas, neuronas, *dropout* (sesión 8).

Idea clave

Elegir el modelo es elegir **dónde pararse** sobre la curva U. Necesitamos: (i) una perilla de complejidad y (ii) un estimador honesto del error de prueba para girarla. La sesión 2 construye el segundo ingrediente.

- 1 Motivación: ¿por qué ML en economía?
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 La descomposición sesgo–varianza**
- 5 Las dos culturas y el mapa del curso

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

- La muestra de entrenamiento $\mathcal{D}$ es **aleatoria**: con otros n datos, obtendríamos **otra** $\hat{f}$.
- Por lo tanto, $\hat{f}(x_0)$ es una **variable aleatoria**: cambia de muestra a muestra.

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

- La muestra de entrenamiento $\mathcal{D}$ es **aleatoria**: con otros n datos, obtendríamos **otra** $\hat{f}$.
- Por lo tanto, $\hat{f}(x_0)$ es una **variable aleatoria**: cambia de muestra a muestra.
- Dos objetos naturales:
 - ▶ $\mathbb{E}[\hat{f}(x_0)]$: la predicción *promedio* entre muestras posibles.
 - ▶ $\text{Var}(\hat{f}(x_0))$: cuánto *cambia* la predicción de muestra a muestra.

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

- La muestra de entrenamiento $\mathcal{D}$ es **aleatoria**: con otros n datos, obtendríamos **otra** $\hat{f}$.
- Por lo tanto, $\hat{f}(x_0)$ es una **variable aleatoria**: cambia de muestra a muestra.
- Dos objetos naturales:
 - ▶ $\mathbb{E}[\hat{f}(x_0)]$: la predicción *promedio* entre muestras posibles.
 - ▶ $\text{Var}(\hat{f}(x_0))$: cuánto *cambia* la predicción de muestra a muestra.
- Definimos el **sesgo** del método en x_0 :

$$\text{Sesgo}(x_0) = \mathbb{E}[\hat{f}(x_0)] - f(x_0)$$

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

- La muestra de entrenamiento $\mathcal{D}$ es **aleatoria**: con otros n datos, obtendríamos **otra** $\hat{f}$.
- Por lo tanto, $\hat{f}(x_0)$ es una **variable aleatoria**: cambia de muestra a muestra.
- Dos objetos naturales:
 - ▶ $\mathbb{E}[\hat{f}(x_0)]$: la predicción *promedio* entre muestras posibles.
 - ▶ $\text{Var}(\hat{f}(x_0))$: cuánto *cambia* la predicción de muestra a muestra.
- Definimos el **sesgo** del método en x_0 :

$$\text{Sesgo}(x_0) = \mathbb{E}[\hat{f}(x_0)] - f(x_0)$$

Pregunta

Llega un dato nuevo (x_0, Y_0) con $Y_0 = f(x_0) + \varepsilon_0$. ¿Cuál es el error cuadrático esperado $\mathbb{E}[(Y_0 - \hat{f}(x_0))^2]$, promediando sobre muestras $\mathcal{D}$ y sobre ε_0 ?

Derivación (I): separar el error irreducible

Punto de partida (ε_0 es independiente de $\mathcal{D}$, con $\mathbb{E}[\varepsilon_0] = 0$, $\text{Var}(\varepsilon_0) = \sigma^2$):

$$\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2], \quad Y_0 = f(x_0) + \varepsilon_0$$

Derivación (I): separar el error irreducible

Punto de partida (ε_0 es independiente de $\mathcal{D}$, con $\mathbb{E}[\varepsilon_0] = 0$, $\text{Var}(\varepsilon_0) = \sigma^2$):

$$\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2], \quad Y_0 = f(x_0) + \varepsilon_0$$

1. Sustituimos Y_0 y expandimos el cuadrado:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon_0] + \mathbb{E}[\varepsilon_0^2]$$

Derivación (I): separar el error irreducible

Punto de partida (ε_0 es independiente de $\mathcal{D}$, con $\mathbb{E}[\varepsilon_0] = 0$, $\text{Var}(\varepsilon_0) = \sigma^2$):

$$\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2], \quad Y_0 = f(x_0) + \varepsilon_0$$

1. Sustituimos Y_0 y expandimos el cuadrado:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon_0] + \mathbb{E}[\varepsilon_0^2]$$

2. El término cruzado se anula: ε_0 es un ruido *nuevo*, independiente de la muestra con que se construyó $\hat{f}$, y tiene media cero:

$$\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon_0] = \mathbb{E}[f(x_0) - \hat{f}(x_0)] \cdot \underbrace{\mathbb{E}[\varepsilon_0]}_{=0} = 0$$

Derivación (I): separar el error irreducible

Punto de partida (ε_0 es independiente de $\mathcal{D}$, con $\mathbb{E}[\varepsilon_0] = 0$, $\text{Var}(\varepsilon_0) = \sigma^2$):

$$\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2], \quad Y_0 = f(x_0) + \varepsilon_0$$

1. Sustituimos Y_0 y expandimos el cuadrado:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon_0] + \mathbb{E}[\varepsilon_0^2]$$

2. El término cruzado se anula: ε_0 es un ruido *nuevo*, independiente de la muestra con que se construyó $\hat{f}$, y tiene media cero:

$$\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon_0] = \mathbb{E}[f(x_0) - \hat{f}(x_0)] \cdot \underbrace{\mathbb{E}[\varepsilon_0]}_{=0} = 0$$

3. Resultado parcial:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \sigma^2$$

El primer término es el **error de estimación**, nos falta descomponerlo.

Derivación (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\mathbb{E}[(f - \hat{f})^2] = \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2$$

Derivación (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

Derivación (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

5. **Juntando todo:**

$$\text{MSE}(x_0) = \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{\sigma^2}_{\text{Irreducible}}$$

Derivación (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

5. **Juntando todo:**


$$\text{MSE}(x_0) = \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{\sigma^2}_{\text{Irreducible}}$$

Las tres piezas del error de predicción

Sesgo: error sistemático del método (rigidez). **Varianza:** sensibilidad a la muestra particular. σ^2 : ruido que nadie puede eliminar.


Intuición: las cuatro dianas

Cada punto es la predicción $\hat{f}(x_0)$ obtenida con una muestra de entrenamiento distinta; el centro es el valor verdadero $f(x_0)$:




Intuición: las cuatro dianas

Cada punto es la predicción $\hat{f}(x_0)$ obtenida con una muestra de entrenamiento distinta; el centro es el valor verdadero $f(x_0)$:




- **Sesgo:** ¿el *centro* de la nube está sobre el blanco?
- **Varianza:** ¿qué tan *dispersa* es la nube?

El trade-off sesgo-varianza



El trade-off sesgo–varianza



- Más complejidad: el sesgo² **cae** (menos rigidez) pero la varianza **sube** (más sensibilidad a la muestra).
- El MSE total es la **suma** de las tres piezas: su mínimo es un **punto interior** — ni el modelo más simple ni el más flexible.
- Esta es la explicación formal de la curva U de la sección anterior.

¿Por qué un economista aceptaría un estimador sesgado?

El reflejo de Econometría I: bajo Gauss–Markov, OLS es **MELI** — el de mínima varianza... *entre los insesgados*. La insesgadez se impone como restricción **a priori**.

¿Por qué un economista aceptaría un estimador sesgado?

El reflejo de Econometría I: bajo Gauss–Markov, OLS es **MELI** — el de mínima varianza... *entre los insesgados*. La insesgadez se impone como restricción **a priori**.

La lógica de la predicción es distinta: minimizamos el MSE total,

$$\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2,$$

y a nadie le pagan por insesgadez si la varianza explota.

¿Por qué un economista aceptaría un estimador sesgado?

El reflejo de Econometría I: bajo Gauss–Markov, OLS es **MELI** — el de mínima varianza... *entre los insesgados*. La insesgadez se impone como restricción **a priori**.

La lógica de la predicción es distinta: minimizamos el MSE total,

$$\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2,$$

y a nadie le pagan por insesgadez si la varianza explota.

¿Cuándo explota la varianza de OLS?

- Muchos predictores (p grande respecto a n).
- Predictores muy correlacionados (colinealidad).
- Muestras pequeñas o ruidosas.

En esos casos, un estimador **levemente sesgado** pero mucho **más estable** predice mejor.

¿Por qué un economista aceptaría un estimador sesgado?

El reflejo de Econometría I: bajo Gauss–Markov, OLS es **MELI** — el de mínima varianza... *entre los insesgados*. La insesgadez se impone como restricción **a priori**.

La lógica de la predicción es distinta: minimizamos el MSE total,

$$\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2,$$

y a nadie le pagan por insesgadez si la varianza explota.

¿Cuándo explota la varianza de OLS?

- Muchos predictores (p grande respecto a n).
- Predictores muy correlacionados (colinealidad).
- Muestras pequeñas o ruidosas.

En esos casos, un estimador **levemente sesgado** pero mucho **más estable** predice mejor.


Teaser de la sesión 2

Ridge y Lasso hacen exactamente ese intercambio, con una perilla λ que controla cuánto sesgo compramos a cambio de cuánta varianza. (De hecho, ni siquiera en

- 1 Motivación: ¿por qué ML en economía?
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 La descomposición sesgo–varianza
- 5 Las dos culturas y el mapa del curso


Las dos culturas del modelamiento (Breiman, 2001)

Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



Las dos culturas del modelamiento (Breiman, 2001)


Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).

Las dos culturas del modelamiento (Breiman, 2001)


Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).
- **Cultura 2 — modelamiento algorítmico:** tratar la caja como **desconocida**; buscar cualquier $f(x)$ que prediga bien y validar con error *out-of-sample*. Entonces el $\approx 2\%$; hoy, la industria entera.

Las dos culturas del modelamiento (Breiman, 2001)

Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).
- **Cultura 2 — modelamiento algorítmico:** tratar la caja como **desconocida**; buscar cualquier $f(x)$ que prediga bien y validar con error *out-of-sample*. Entonces el $\approx 2\%$; hoy, la industria entera.

¿Dónde se para este curso?

En la frontera, que ya se disolvió: la econometría adoptó los algoritmos (este curso) y el ML aprendió causalidad (sesión 6). Pero adoptamos la **disciplina de validación** de la cultura 2: la prueba de un modelo es predecir datos que no vio.

Supervisado y no supervisado: el mapa de tareas

Tarea	¿Hay y?	Pregunta	Ejemplo	Sesión
Regresión	Sí (continua)	¿cuánto?	precio de vivienda	1–4
Clasificación	Sí (discreta)	¿qué clase?	¿el hogar es pobre?	5
<i>Clustering</i>	No	¿qué grupos?	segmentar clientes	7
Reducción de dim.	No	¿qué estructura?	índice socioeconómico	7

Supervisado y no supervisado: el mapa de tareas

Tarea	¿Hay y ?	Pregunta	Ejemplo	Sesión
Regresión	Sí (continua)	¿cuánto?	precio de vivienda	1–4
Clasificación	Sí (discreta)	¿qué clase?	¿el hogar es pobre?	5
<i>Clustering</i>	No	¿qué grupos?	segmentar clientes	7
Reducción de dim.	No	¿qué estructura?	índice socioeconómico	7

- **Supervisado:** conocemos la respuesta y en los datos de entrenamiento; el algoritmo aprende el mapa $x \rightarrow y$. La “supervisión” es la y observada.
- **No supervisado:** no hay y ; buscamos estructura en los x (grupos, factores latentes, dimensiones).
- Los datos no estructurados (texto, imágenes; sesiones 8–9) combinan ambos mundos: primero se *representan* (no supervisado), luego se predice con ellos (supervisado).

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).
- **Métricas de clasificación (S5):** eligen la pérdida correcta cuando los errores tienen costos asimétricos.

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).
- **Métricas de clasificación (S5):** eligen la pérdida correcta cuando los errores tienen costos asimétricos.
- **ML causal (S6):** usa la buena predicción al servicio de un β creíble.

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).
- **Métricas de clasificación (S5):** eligen la pérdida correcta cuando los errores tienen costos asimétricos.
- **ML causal (S6):** usa la buena predicción al servicio de un β creíble.
- **No supervisado (S7):** comprime la dimensión sin necesidad de y .

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).
- **Métricas de clasificación (S5):** eligen la pérdida correcta cuando los errores tienen costos asimétricos.
- **ML causal (S6):** usa la buena predicción al servicio de un β creíble.
- **No supervisado (S7):** comprime la dimensión sin necesidad de y .
- **Redes, texto y LLMs (S8–S9):** clases $\mathcal{F}$ ultra flexibles + regularización agresiva + muchos datos.

Todo el curso en una diapositiva

Cada sesión responde, con una herramienta distinta, la misma pregunta: **¿cómo controlar la complejidad para generalizar?**

- **Validación cruzada (S2):** estima honestamente el error de prueba para girar las perillas.
- **Regularización (S2–S3):** compra reducción de varianza pagando con sesgo (λ).
- **Ensamblados (S4):** promedian muchos modelos para bajar la varianza (Random Forest) o suman aprendices débiles para bajar el sesgo (*boosting*).
- **Métricas de clasificación (S5):** eligen la pérdida correcta cuando los errores tienen costos asimétricos.
- **ML causal (S6):** usa la buena predicción al servicio de un β creíble.
- **No supervisado (S7):** comprime la dimensión sin necesidad de y .
- **Redes, texto y LLMs (S8–S9):** clases $\mathcal{F}$ ultra flexibles + regularización agresiva + muchos datos.

Recap

- 1 **Predicción $\neq$ inferencia causal:** $\hat{y}$ -problems y β -problems son preguntas distintas con herramientas distintas — y muchos problemas de política son de predicción.
- 2 El objetivo del ML supervisado es minimizar el **riesgo de generalización** $R(f) = \mathbb{E}[L(Y, f(X))]$, no el error en la muestra.
- 3 El **error de entrenamiento es optimista**: evaluar donde se entrenó premia la memorización. Separar entrenamiento y prueba es la regla de oro.
- 4 **Descomposición fundamental:** $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$. La complejidad baja el sesgo y sube la varianza: el óptimo es interior.
- 5 Aceptar **algo de sesgo** para reducir mucha varianza mejora la predicción — la idea que motiva la regularización (próxima sesión).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Mullainathan & Spiess (2017), *Machine Learning: An Applied Econometric Approach*, JEP.

Guía: concéntrense en la distinción $\hat{y}$ vs. $\hat{\beta}$ y en la Tabla 1.

- Varian (2014), *Big Data: New Tricks for Econometrics*, JEP.

Guía: secciones de entrenamiento/prueba y árboles de decisión.

Lecturas recomendadas: Breiman (2001, *Two Cultures*); Kleinberg et al. (2015, *Prediction Policy Problems*).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Mullainathan & Spiess (2017), *Machine Learning: An Applied Econometric Approach*, JEP.

Guía: concéntrense en la distinción $\hat{y}$ vs. $\hat{\beta}$ y en la Tabla 1.

- Varian (2014), *Big Data: New Tricks for Econometrics*, JEP.

Guía: secciones de entrenamiento/prueba y árboles de decisión.

Lecturas recomendadas: Breiman (2001, *Two Cultures*); Kleinberg et al. (2015, *Prediction Policy Problems*).

Nivelación en R: completar los módulos de introducción y `dp1yr` (enlaces en la diapositiva de nivelación) **antes** de la sesión 2.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Mullainathan & Spiess (2017), *Machine Learning: An Applied Econometric Approach*, JEP.

Guía: concéntrense en la distinción $\hat{y}$ vs. $\hat{\beta}$ y en la Tabla 1.

- Varian (2014), *Big Data: New Tricks for Econometrics*, JEP.

Guía: secciones de entrenamiento/prueba y árboles de decisión.

Lecturas recomendadas: Breiman (2001, *Two Cultures*); Kleinberg et al. (2015, *Prediction Policy Problems*).

Nivelación en R: completar los módulos de introducción y `dp1yr` (enlaces en la diapositiva de nivelación) **antes** de la sesión 2.

Próxima sesión: validación cruzada, bootstrap, selección de modelos y regularización (Ridge, Lasso, Elastic Net) — y la primera aplicación guiada en R.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 2. [ISLR]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Caps. 2 y 7. [ESL]
- Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*, 16(3), 199–231.
- Varian, H. (2014). Big Data: New Tricks for Econometrics. *JEP*, 28(2), 3–28.
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *AER P&P*, 105(5), 491–495.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J., & Mullainathan, S. (2018). Human Decisions and Machine Predictions. *QJE*, 133(1), 237–293.
- Ginsberg, J., et al. (2009). Detecting Influenza Epidemics Using Search Engine Query Data. *Nature*, 457, 1012–1014.
- Lazer, D., Kennedy, R., King, G., & Vespignani, A. (2014). The Parable of Google Flu. *Science*, 343(6176), 1203–1205.
- Jean, N., et al. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.