

Big Data y Machine Learning para Economía Aplicada

Week 01: Predecir, no explicar — el marco del aprendizaje estadístico

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 14, 2026

Acerca de este curso

❶ Al finalizar el curso podrás:

- ▶ Predecir y clasificar variables económicas con métodos de ML y evaluar el desempeño *fuera de muestra* con honestidad.
- ▶ Construir el flujo de trabajo completo en R: partición, validación, ajuste, evaluación e interpretación.
- ▶ Abrir un modelo flexible (importancia de variables, dependencia parcial, SHAP) y saber qué dice y qué no dice.
- ▶ Leer críticamente y presentar investigación económica que usa ML.

❷ **Texto guía:** James, Witten, Hastie & Tibshirani, *An Introduction to Statistical Learning* (ISL, 2. ed.). Seguimos su progresión.

❸ **Metodología:** en cada método, el problema que resuelve → intuición → formulación esencial → cómo funciona → aplicación con datos reales → evaluación → interpretación. Las derivaciones largas van al apéndice “Para profundizar” de cada sesión.

❹ **Evaluación:** presentación de artículo (10%) - Problem Set 1 (15%) - Problem Set 2 (15%) - Proyecto final (60%).

El mapa de las 9 sesiones

#	Tema	ISL
1	Predecir, no explicar: el marco del aprendizaje estadístico ← hoy	1–2
2	La regresión lineal como máquina de predecir; evaluar una predicción	3, 7
3	Clasificación: de la logística a las métricas que deciden	4
4	Remuestreo, validación y el <i>pipeline</i> honesto	5
5	Selección de variables y regularización	6
6	Árboles, bosques y <i>boosting</i>	8
7	Abrir la caja negra: importancia, dependencia parcial y SHAP	—
8	Redes neuronales: qué son, cuándo usarlas y una aplicación	10
9	Estructura sin y, la frontera causal + presentaciones finales	12

- **Problem Set 1** cubre las sesiones 1–5; **Problem Set 2** cubre las sesiones 6–9.
- Cada sesión tiene un **artículo aplicado de referencia** (el *paper de la sesión*); lo discutimos en clase y, a lo largo del semestre, cada estudiante presenta uno (10 minutos: qué se predice, con qué datos y método, cómo se evalúa, cómo se interpreta).
- El **proyecto final** corre en paralelo durante todo el semestre.

Los datos que nos acompañan todo el semestre

Tres conjuntos de datos reales, reutilizados de sesión en sesión, para que el esfuerzo se vaya a los métodos y no a entender datos nuevos cada semana:

- 1 **Mesas electorales de Colombia, 2006–2022.** Resultados por mesa (voto por el ganador, participación) enlazados con características censales del entorno (estrato, servicios, edades, composición étnica) y luces nocturnas. *Regresión, clasificación, validación espacial, árboles e interpretación.*
- 2 **Precios de vivienda en Bogotá.** Anuncios con características físicas y de localización. *Regresión, flexibilidad, regularización y árboles.*
- 3 **Imágenes satelitales y luces nocturnas.** *La aplicación de redes neuronales.*

La pregunta que abre el curso

¿Qué tan predecible es una elección a partir de las características *estables* de los lugares? La respondemos por etapas a lo largo del curso: primero con una regresión, después con un bosque (sesión 6) y abriendo el bosque (sesión 7).

Nivelación en R y política de IA

Nivelación en R (obligatoria, autónoma, por fuera del horario de clase):

- Introducción a R: [Disponible \[aquí\]](#)
- Manipulación de datos con `dplyr`: [Disponible \[aquí\]](#)
- Lectura y escritura de datos: [Disponible \[aquí\]](#)
- Gestión y organización de datos: [Disponible \[aquí\]](#)
- Buenas prácticas de modelamiento con `tidymodels`: material en **Intu**.
- Para quienes opten por la vía Python, se ofrece material equivalente de referencia.

Política de IA

Se permite el uso de herramientas de IA en cualquier componente del curso, siempre que se **declare explícitamente** qué se usó y para qué.

- 1 De β a y : dos preguntas para los mismos datos
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 Sesgo y varianza: por qué el error de prueba tiene forma de U
- 5 El mapa de tareas y el flujo de trabajo del curso

Los mismos datos, dos preguntas

Tomen el panel de mesas electorales: voto por el ganador (y) y composición étnica del entorno (x).

Pregunta causal (Econometría)

- ¿Cuánto *cambia* el voto si cambia la composición étnica?
- Objeto: un parámetro β .
- Enemigo: el sesgo (selección, omitidas).
- Se valida con un **diseño** de identificación.

Pregunta predictiva (este curso)

- ¿Qué tan bien podemos *anticipar* el voto de una mesa que no hemos visto, y de qué depende?
- Objeto: la función completa $\hat{f}(x)$ y su error.
- Enemigo: el sobreajuste (varianza).
- Se valida con **datos nuevos**.

La frase que vamos a repetir todo el semestre

Un coeficiente significativo no es una predicción, y la importancia de una variable en un modelo predictivo no es un efecto causal. Son preguntas distintas, con herramientas y criterios de éxito distintos.

¿Y qué es machine learning?

- Una rama de la estadística y la computación que desarrolla **algoritmos para predecir** un resultado y a partir de variables observables x .
- La parte de “aprendizaje”: **no especificamos** de antemano la forma exacta en que la máquina debe predecir y a partir de x ; eso queda como un problema empírico que el algoritmo resuelve con los datos.
- El enfoque es pragmático: nos abstraemos del modelo subyacente.

“Whatever works, works. . .”

- **¿En qué se diferencia de la econometría que ya conocen?**
 - ▶ Econometría clásica: estimar **parámetros** (β) con propiedades deseables e interpretarlos.
 - ▶ ML: producir **predicciones** ($\hat{y}$) que funcionen bien en datos **nuevos**, y luego entender de qué dependen.

La primera gran victoria del ML: Google Flu Trends

Contexto (2008): en EE.UU., la vigilancia de la gripe dependía de los reportes que los centros médicos envían a la CDC.

- La CDC agrega los reportes por región y a nivel nacional.
- Todo el proceso tomaba $\approx$ **10 días** $\rightarrow$ demasiado para una epidemia.

La propuesta de Google (Ginsberg et al., 2009, *Nature*):


- Cruzar los datos oficiales con las **búsquedas** relacionadas con la gripe.
- Evaluaron $\approx$ **50 millones** de términos candidatos y $\approx$ **450 millones** de modelos; el modelo final usaba 45 términos.
- Resultado: predicciones de intensidad de gripe casi en **tiempo real**, para cualquier región.
- A Google le tomaba **1 día** lo que a la CDC **10**.

Sin teoría epidemiológica, sin encuestas, sin modelo estructural.

¿Convencidos?

La figura que convenció al mundo

Ginsberg et al. (2009, *Nature*), Fig. 3: lo que se sabía en cuatro fechas de 2007–08



Región del Atlántico medio de EE.UU. Negro: % de consultas médicas por síndrome gripal (ILI) estimado por el modelo de Google con las búsquedas de esa misma semana. Rojo: el dato oficial de la CDC, que llega con una o dos semanas de rezago. Fuente: Ginsberg et al. (2009), Fig. 3.

Una curva construida con búsquedas en Google sigue a la curva oficial semana a semana, y llega antes. ¿Qué puede salir mal?

... y su primera gran derrota

“The Parable of Google Flu” (Lazer et al., 2014, Science)

- En la temporada 2012–2013, Google Flu Trends predijo **más del doble** de los casos que efectivamente ocurrieron.
- De hecho, sobreestimó la prevalencia en **100 de las 108 semanas** posteriores a agosto de 2011.
- **¿Qué salió mal?**
 - ▶ Con 50 millones de términos, muchos correlacionan con la gripe **por azar** (p. ej., búsquedas estacionales de baloncesto).
 - ▶ El comportamiento de búsqueda **cambia con el tiempo** (y Google cambia su buscador): el modelo se entrenó en un mundo que dejó de existir.
 - ▶ “*Big data hubris*”: la idea implícita de que el tamaño de los datos sustituye a la medición y a la validación cuidadosas.

La lección que organiza este curso

Predecir bien **dentro** de la muestra es fácil; lo difícil es **generalizar** a datos nuevos. Todo el aparato de hoy (riesgo, sobreajuste, sesgo–varianza) existe para atacar ese problema.

¿Paraguas o danza de la lluvia?

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

¿Paraguas o danza de la lluvia?

No toda pregunta de política necesita un efecto causal. Comparen:

- **¿Hago la danza de la lluvia?** Solo importa si la danza *causa* lluvia → problema **causal** (β).
- **¿Llevo paraguas?** Solo importa si va a llover, no por qué llueve → problema de **predicción** ($\hat{y}$).

Ejemplos reales de problemas de predicción en política pública:

- **Avalúo catastral:** el impuesto predial se liquida sobre el valor de cada predio de la ciudad, y casi ninguno se vendió este año. No importa *por qué* vale lo que vale; importa *cuánto* vale, y eso hay que predecirlo.
- **Libertad provisional** (Kleinberg et al., 2018, QJE): jueces deciden con una predicción implícita de fuga o reincidencia. Un modelo de ML podría reducir el crimen $\approx 25\%$ sin más presos, o la población carcelaria $\approx 42\%$ sin más crimen.
- **Focalización:** el Sisbén es, en esencia, un **clasificador** de hogares — predice pobreza estructural a partir de características observables.

¿Mi pregunta es de β o de $\hat{y}$?

Una regla práctica: ¿qué voy a hacer con la respuesta?

- **Problema de β :** la decisión es **cambiar** x ; necesito el efecto sobre y y un diseño que lo identifique.
- **Problema de $\hat{y}$:** la decisión sólo necesita **saber** qué valor tomará y ; necesito un buen predictor y una prueba honesta.

Preguntas de β (la decisión cambia x)

- ¿Sube el precio de una vivienda si construyen una estación de metro al lado?
- ¿La beca mejora el puntaje en el Saber Pro?
- ¿Cambia el voto de una zona si mejora la cobertura de servicios?

Preguntas de $\hat{y}$ (basta saber qué pasará)

- ¿Cuánto vale esta vivienda?
- ¿Qué estudiantes desertarán este semestre?
- ¿En qué mesas ganará el candidato?

Las dos preguntas no son rivales

Un modelo puede predecir muy bien con coeficientes sin sentido, y un β creíble puede predecir mal. Este curso optimiza $\hat{y}$; la sesión 9 muestra cómo un buen $\hat{y}$ ayuda a estimar β .

- 1 De β a y : dos preguntas para los mismos datos
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 Sesgo y varianza: por qué el error de prueba tiene forma de U
- 5 El mapa de tareas y el flujo de trabajo del curso

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio, voto).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio, voto).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

Descomposición fundamental: siempre podemos escribir

$$Y = f(X) + \varepsilon, \quad \text{con } f(x) \equiv \mathbb{E}[Y \mid X = x]$$

- f : la **función de regresión** — la parte sistemática de Y .
- $\varepsilon \equiv Y - f(X)$: lo que X no explica. **Por construcción** $\mathbb{E}[\varepsilon \mid X] = 0$, con $\text{Var}(\varepsilon) = \sigma^2$.

El setup

Datos: observamos n pares (x_i, y_i) , extraídos de forma i.i.d. de una distribución conjunta $P(X, Y)$ **desconocida**.

- Y : variable de respuesta (salario, impago, consumo, precio, voto).
- $X = (X_1, \dots, X_p)$: predictores o *features*.

Descomposición fundamental: siempre podemos escribir

$$Y = f(X) + \varepsilon, \quad \text{con } f(x) \equiv \mathbb{E}[Y \mid X = x]$$

- f : la **función de regresión** — la parte sistemática de Y .
- $\varepsilon \equiv Y - f(X)$: lo que X no explica. **Por construcción** $\mathbb{E}[\varepsilon \mid X] = 0$, con $\text{Var}(\varepsilon) = \sigma^2$.

La meta del aprendizaje supervisado

Usar los datos para construir $\hat{f} \approx f$. En econometría nos importaba un **parámetro dentro** de f ; aquí nos importa la **función completa**, porque con ella predecimos.

¿Qué significa exactamente “aprender”?

Aprender = elegir $\hat{f}$ dentro de una **clase de funciones** $\mathcal{F}$ usando los datos:

- $\mathcal{F}$ puede ser: rectas, polinomios, árboles, redes neuronales. . .
- Cada sesión de este curso es, en el fondo, una clase $\mathcal{F}$ distinta.

¿Qué significa exactamente “aprender”?

Aprender = elegir $\hat{f}$ dentro de una **clase de funciones** $\mathcal{F}$ usando los datos:

- $\mathcal{F}$ puede ser: rectas, polinomios, árboles, redes neuronales. . .
- Cada sesión de este curso es, en el fondo, una clase $\mathcal{F}$ distinta.

¿Y qué es una “buena” $\hat{f}$? Necesitamos una **función de pérdida** $L(y, \hat{f}(x))$ que mida el costo de equivocarse:

- **Cuadrática:** $L = (y - \hat{f}(x))^2$. Castiga fuerte los errores grandes; estándar en regresión.
- **Absoluta:** $L = |y - \hat{f}(x)|$. Más robusta a valores extremos.
- **0–1:** $L = \mathbb{I}\{y \neq \hat{f}(x)\}$. Para clasificación (sesión 3).

La elección de L es una decisión económica

¿Qué error cuesta más? No es lo mismo subestimar la demanda (ventas perdidas) que sobreestimarla (inventario muerto); ni un falso positivo que un falso negativo al focalizar un subsidio.

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

Con pérdida cuadrática, $R(f) = \mathbb{E}[(Y - f(X))^2]$ es el **error cuadrático medio**, **MSE** (*mean squared error*): la métrica que usaremos casi siempre en regresión.

El riesgo de generalización

Definición. El **riesgo** (o error de generalización) de un predictor f es su pérdida esperada sobre un dato **nuevo** extraído de P :

$$R(f) = \mathbb{E}[L(Y, f(X))]$$

Con pérdida cuadrática, $R(f) = \mathbb{E}[(Y - f(X))^2]$ es el **error cuadrático medio**, **MSE** (*mean squared error*): la métrica que usaremos casi siempre en regresión.

¿Cuál es el mejor predictor posible bajo pérdida cuadrática? La media condicional:

$$f^*(x) = \mathbb{E}[Y \mid X = x] = \arg \min_f R(f)$$

- Intuición: en cada x , la constante que minimiza el error cuadrático esperado es el promedio de Y en ese x ; cualquier otra predicción añade el cuadrado de su distancia a ese promedio (la cuenta, de tres líneas, está en el apéndice).

Por qué la regresión es el punto de partida

La regresión aproxima la media condicional. Por eso es el primer método del curso (sesión 2) y el *baseline* contra el que se mide todo lo demás.

Error reducible y error irreducible

Lo que ni el mejor predictor evita: para cualquier $\hat{f}$ y cualquier x , con $Y = f(x) + \varepsilon$,

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\sigma^2}_{\text{irreducible}}$$

Error reducible y error irreducible

Lo que ni el mejor predictor evita: para cualquier $\hat{f}$ y cualquier x , con $Y = f(x) + \varepsilon$,

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\sigma^2}_{\text{irreducible}}$$


- **Reducible:** qué tan lejos está nuestra $\hat{f}$ de la verdadera f . Es lo que un mejor método, más datos o mejores variables pueden mejorar.
- **Irreducible** (σ^2): ni el modelo perfecto ($\hat{f} = f$) lo elimina. Es el techo de lo aprendible con estos predictores. (La cuenta, de dos líneas, en el apéndice.)

Mensaje

Si el desempeño de un modelo parece “malo”, la causa puede ser σ^2 alto: no siempre hay un mejor algoritmo; a veces faltan mejores **datos**. Con sólo el área de un apartamento, el techo para predecir su precio es bajo y ningún algoritmo lo sube: faltan la localización, el estrato, el estado.

Paramétrico o no, flexible o interpretable

Cómo estimar f . **Paramétrico:** fijar la forma ($f = \beta_0 + \beta_1 x + \dots$) y estimar pocos números; estable, pero puede estar *mal especificado*. **No paramétrico:** dejar que los datos dibujen la forma (k -NN, árboles); flexible, pero necesita *muchos* datos.



El precio de la flexibilidad, y por qué existe la sesión 7

Bajar por la diagonal compra precisión y pierde lectura (y arriesga ajustar el ruido). Importancia de variables, dependencia parcial y SHAP recuperan parte de la lectura.

El riesgo empírico y su trampa

1. **El objetivo no se puede calcular.** $R(f) = \mathbb{E}[L(Y, f(X))]$ promedia la pérdida sobre *todos* los datos posibles: exige conocer P .
2. **Lo que sí se puede calcular: el error de entrenamiento.** Reemplazamos la esperanza por el promedio en nuestros n datos, el **riesgo empírico**:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

Y le damos dos usos: **elegir** el modelo, $\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$ (*empirical risk minimization*), y **calificarlo**, reportando $\hat{R}(\hat{f})$.


3. **La trampa: usar los mismos datos para las dos cosas.** $\hat{f}$ se escogió *precisamente* para que $\hat{R}$ fuera pequeño; por eso $\hat{R}(\hat{f})$ es **optimista** como estimación de $R(\hat{f})$: es calificar un examen presentado con las respuestas en la mano. En el extremo, una $\mathcal{F}$ muy flexible **memoriza** los datos ($\hat{R}(\hat{f}) = 0$) sin aprender nada que sirva para un dato nuevo.

Regla de oro #1

El error de entrenamiento **no** estima el error de generalización. Para calificar a $\hat{f}$ hacen falta datos que no participaron en su elección (siguiente diapositiva).

Entrenamiento vs. prueba

La solución más simple: separar los datos **antes** de tocar cualquier modelo.




- El conjunto de **prueba** simula los “datos nuevos”: su error sí estima $R(\hat{f})$ honestamente.
- **Regla de oro #2:** el conjunto de prueba se usa **al final y una sola vez**. Si lo usamos muchas veces para escoger el modelo, se convierte — en la práctica — en un segundo conjunto de entrenamiento.
- Con esto ya podemos trabajar en las sesiones 2 y 3. ¿Y si la muestra es pequeña y partirla “duele”? De eso se encarga la **validación cruzada** (sesión 4).


- 1 De β a y : dos preguntas para los mismos datos
- 2 El marco del aprendizaje estadístico
- 3 **Sobreajuste y complejidad**
- 4 Sesgo y varianza: por qué el error de prueba tiene forma de U
- 5 El mapa de tareas y el flujo de trabajo del curso

Un mismo conjunto de datos, tres modelos


Ajustemos polinomios de grado creciente a los mismos 9 puntos:



Grado 1: **subajuste**




Grado 3: $\approx f$



Grado 15: **sobreajuste**

- **Grado 1:** demasiado rígido — no captura la forma de f (error por **sesgo**).
- **Grado 15:** pasa por *todos* los puntos — ajusta el **ruido** ε , no la señal (error por **varianza**).
- ¿Cuál predice mejor un punto **nuevo**? El del medio. Ni el más simple ni el que “mejor ajusta”.

La curva que resume el curso



- El error de **entrenamiento** cae *monótonamente* con la complejidad: más flexibilidad siempre ajusta mejor la muestra.
- El error de **prueba** tiene forma de **U**: mejora hasta cierto punto y luego el sobreajuste lo destruye.
- **Todo el curso vive en esta figura**: cada método trae una “perilla” de complejidad y una forma de encontrar el mínimo de la curva roja.

¿Qué es exactamente la “complejidad”?

Informalmente: la **capacidad** de la clase $\mathcal{F}$ para ajustar patrones arbitrarios.

- En regresión polinómica: el **grado** del polinomio.
- En regresión múltiple: el **número de predictores** p .
- Más adelante en el curso, cada método tendrá su propia perilla:
 - ▶ k -NN: el número de vecinos k (sesiones 2–3).
 - ▶ Regularización: el parámetro de penalización λ (sesión 5).
 - ▶ Árboles: la profundidad, el tamaño de las hojas y el número de árboles (sesión 6).
 - ▶ Redes neuronales: capas, neuronas, *dropout* (sesión 8).

Idea clave

Elegir el modelo es elegir **dónde pararse** sobre la curva U. Necesitamos: (i) una perilla de complejidad y (ii) un estimador honesto del error de prueba para girarla. Hoy tenemos la partición entrenamiento/prueba; la sesión 4 construye el estimador definitivo.

- 1 De β a y : dos preguntas para los mismos datos
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 Sesgo y varianza: por qué el error de prueba tiene forma de U
- 5 El mapa de tareas y el flujo de trabajo del curso

El experimento mental

Queremos entender *por qué* el error de prueba tiene forma de U. Fijemos un punto x_0 y pensemos qué pasaría si pudiéramos repetir el muestreo:

- La muestra de entrenamiento $\mathcal{D}$ es **aleatoria**: con otros n datos, obtendríamos **otra** $\hat{f}$.
- Por lo tanto, $\hat{f}(x_0)$ es una **variable aleatoria**: cambia de muestra a muestra.
- Dos objetos naturales:
 - ▶ $\mathbb{E}[\hat{f}(x_0)]$: la predicción *promedio* entre muestras posibles.
 - ▶ $\text{Var}(\hat{f}(x_0))$: cuánto *cambia* la predicción de muestra a muestra.
- Definimos el **sesgo** del método en x_0 :

$$\text{Sesgo}(x_0) = \mathbb{E}[\hat{f}(x_0)] - f(x_0)$$

Pregunta

Llega un dato nuevo (x_0, Y_0) con $Y_0 = f(x_0) + \varepsilon_0$. ¿Cuál es el error cuadrático medio de la predicción en x_0 , $\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2]$, promediando sobre muestras $\mathcal{D}$ y sobre ε_0 ?

La descomposición sesgo–varianza

Tres piezas, y solo dos dependen de nosotros

Resultado para el error cuadrático medio en x_0 , $\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2]$ (apéndice):

$$\text{MSE}(x_0) = \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{\sigma^2}_{\text{Irreducible}}$$


- **Sesgo:** error sistemático del método. Un modelo rígido (la recta de grado 1) se equivoca siempre en la misma dirección, con cualquier muestra.
- **Varianza:** sensibilidad a la muestra particular. Un modelo flexible (grado 15) cambia por completo si cambian unos pocos puntos.
- σ^2 : ruido que nadie puede eliminar; el techo de lo aprendible con estos predictores.

Por qué importa

La complejidad **baja el sesgo y sube la varianza**. Como el error total es la suma, el óptimo es interior: esa es la curva U, y toda perilla del curso (grado, k , λ , profundidad, épocas) se mueve sobre ella.


Intuición: las cuatro dianas

Cada punto es la predicción $\hat{f}(x_0)$ obtenida con una muestra de entrenamiento distinta; el centro es el valor verdadero $f(x_0)$:



- **Sesgo:** ¿el *centro* de la nube está sobre el blanco?
- **Varianza:** ¿qué tan *dispersa* es la nube?

El trade-off sesgo–varianza



- Más complejidad: el sesgo² **cae** (menos rigidez) pero la varianza **sube** (más sensibilidad a la muestra).
- El MSE total es la **suma** de las tres piezas: su mínimo es un **punto interior** — ni el modelo más simple ni el más flexible.
- Esta es la explicación formal de la curva U de la sección anterior.

¿Por qué un economista aceptaría un estimador sesgado?

El reflejo de Econometría I: bajo Gauss–Markov, OLS es **MELI** — el de mínima varianza... *entre los insesgados*. La insesgadez se impone como restricción **a priori**.

La lógica de la predicción es distinta: minimizamos el MSE total,

$$\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2,$$

y a nadie le pagan por insesgadez si la varianza explota.

¿Cuándo explota la varianza de OLS? Con muchos predictores respecto a n , con predictores muy correlacionados, con muestras pequeñas o ruidosas. En esos casos, un estimador **levemente sesgado** pero mucho **más estable** predice mejor.

Teaser de la sesión 5

Ridge y Lasso hacen exactamente ese intercambio, con una perilla λ que controla cuánto sesgo compramos a cambio de cuánta varianza. (De hecho, ni siquiera en estimación pura la insesgadez es sagrada: James & Stein, 1961.)

- 1 De β a y : dos preguntas para los mismos datos
- 2 El marco del aprendizaje estadístico
- 3 Sobreajuste y complejidad
- 4 Sesgo y varianza: por qué el error de prueba tiene forma de U
- 5 El mapa de tareas y el flujo de trabajo del curso


Supervisado y no supervisado: el mapa de tareas

Tarea	¿Hay y ?	Pregunta	Ejemplo	Sesión
Regresión	Sí (continua)	¿cuánto?	precio de vivienda	2, 4–8
Clasificación	Sí (discreta)	¿qué clase?	¿ganó en la mesa?	3, 6–8
<i>Clustering</i>	No	¿qué grupos?	segmentar hogares	9
Reducción de dim.	No	¿qué estructura?	índice socioeconómico	5, 9

- **Supervisado:** conocemos la respuesta y en los datos de entrenamiento; el algoritmo aprende el mapa $x \rightarrow y$. La “supervisión” es la y observada.
- **No supervisado:** no hay y ; buscamos estructura en los x (grupos, factores latentes, dimensiones). Sin y tampoco hay error de prueba: validar es otra cosa (sesión 9).
- Las imágenes (sesión 8) combinan ambos mundos: primero se *representan*, luego se predice con ellas.


Las dos culturas del modelamiento (Breiman, 2001)

Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



Las dos culturas del modelamiento (Breiman, 2001)


Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).

Las dos culturas del modelamiento (Breiman, 2001)


Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).
- **Cultura 2 — modelamiento algorítmico:** tratar la caja como **desconocida**; buscar cualquier $f(x)$ que prediga bien y validar con error *out-of-sample*. Entonces el $\approx 2\%$; hoy, la industria entera.

Las dos culturas del modelamiento (Breiman, 2001)

Toda pregunta empírica parte del mismo diagrama: la naturaleza asocia insumos con resultados.



- **Cultura 1 — modelamiento de datos:** asumir un modelo estocástico para la caja (lineal, logit...), estimar sus parámetros y validar con supuestos y bondad de ajuste. En 2001, el $\approx 98\%$ de los estadísticos (y casi toda la econometría).
- **Cultura 2 — modelamiento algorítmico:** tratar la caja como **desconocida**; buscar cualquier $f(x)$ que prediga bien y validar con error *out-of-sample*. Entonces el $\approx 2\%$; hoy, la industria entera.

¿Dónde se para este curso?

En la frontera, que ya se disolvió: la econometría adoptó los algoritmos y el ML aprendió causalidad (sesión 9). Pero adoptamos la **disciplina de validación** de la cultura 2: la prueba de un modelo es predecir datos que no vio.

Aplicación guiada: ver el sesgo y la varianza


Cincuenta avisos simulados, tres polinomios y un aviso nuevo ([applications/week-01](#))

- 1 **Los datos:** 50 avisos simulados de apartamentos: área (m^2) y precio (millones).
- 2 **Tres modelos sobre los mismos 50 puntos:** polinomios del área de grado 1, 3 y 12. Dentro de la muestra el error (raíz del MSE) baja con el grado: 74, 62 y 57. El más flexible “ajusta mejor”.
- 3 **Llega un aviso nuevo** de 185 m^2 a 720 millones. La recta dice 811, la cúbica 750, el grado 12 dice 488. Lo agregamos y reajustamos: la recta y la cúbica se mueven menos de 7; la curva de grado 12 cambia de forma (hasta 755).
- 4 **Llegan diez avisos nuevos:** el error sobre ellos es 69, 56 y 217. El que mejor ajustaba dentro es, por mucho, el que peor predice fuera.
- 5 **Uno a la vez:** reajustamos con cada uno de los diez. Diez rectas iguales, diez cúbicas casi iguales, diez curvas de grado 12 distintas: la varianza, en vivo.

Lo que hay que ver

El modelo rígido se equivoca siempre igual (sesgo); el flexible cambia con cada dato (varianza); el que mejor predice un aviso nuevo está en el medio.

El flujo de trabajo del curso en una diapositiva



Cada sesión cambia una pieza y deja las demás fijas:

- **S2–S3:** qué modelo de referencia usar y cómo medir el error (regresión y clasificación).
- **S4:** cómo validar sin engañarse (CV, *leakage*, estructura espacial y temporal).
- **S5–S6, S8:** clases $\mathcal{F}$ cada vez más flexibles, cada una con su perilla.
- **S7:** cómo abrir la caja; **S9:** qué hacer sin y y cuándo la predicción sirve para estimar β .

Mensaje

Si entienden la sesión de hoy — riesgo, sobreajuste, sesgo–varianza, entrenamiento y prueba — entienden *por qué existe* cada pieza del resto del curso.

Recap

- 1 **Y, no β :** predecir y explicar son preguntas distintas. Un coeficiente significativo no es una predicción, y muchos problemas de política son de predicción.
- 2 El objetivo del ML supervisado es minimizar el **riesgo de generalización** $R(f) = \mathbb{E}[L(Y, f(X))]$, no el error en la muestra; el mejor predictor cuadrático es la media condicional.
- 3 **Regla de oro #1:** el error de entrenamiento es optimista. **Regla de oro #2:** el conjunto de prueba se usa al final y una sola vez.
- 4 **Descomposición fundamental:** $MSE = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$. La complejidad baja el sesgo y sube la varianza: el óptimo es interior (la curva U).
- 5 Bajar por la diagonal flexibilidad–interpretabilidad compra precisión y pierde lectura; las herramientas de la sesión 7 recuperan parte de la lectura.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, caps. 1 y 2.

Guía: la sección 2.2 es la de hoy; las figuras 2.7 y 2.12 son las de clase.

- Mullainathan & Spiess (2017), *Machine Learning: An Applied Econometric Approach*, JEP.

Guía: concéntrense en la distinción $\hat{y}$ vs. $\hat{\beta}$ y en el ejemplo de precios de vivienda.

El paper de la sesión 2 (no es lectura obligatoria; abriremos un espacio en clase para conversarlo): Kim & Zilinsky (2024), *Division Does Not Imply Predictability, Political Behavior*. Guía, si se adelantan: la Figura 2 y la sección “Growing Marginal Effects Do Not Imply Rising Joint Accuracy”.

Nivelación en R: completar los módulos de introducción y `dp1yr` (enlaces en la diapositiva de nivelación) **antes** de la sesión 2.

Próxima sesión: la regresión lineal como máquina de predecir (ISL cap. 3), un poco de flexibilidad (polinomios, *splines*, *k*-NN; ISL cap. 7) y, sobre todo, cómo evaluar una predicción de regresión: RMSE, MAE, R^2 fuera de muestra, predicho vs. observado y dónde se concentra el error. **Aplicación en R:** precios de vivienda en Bogotá.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 1–2. [ISL]
- Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*, 16(3), 199–231.
- Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, 25(3), 289–310.
- Varian, H. (2014). Big Data: New Tricks for Econometrics. *JEP*, 28(2), 3–28.
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *AER P&P*, 105(5), 491–495.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J., & Mullainathan, S. (2018). Human Decisions and Machine Predictions. *QJE*, 133(1), 237–293.
- Kim, S.-y. S., & Zilinsky, J. (2024). Division Does Not Imply Predictability. *Political Behavior*, 46, 67–87.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Documento de trabajo.
- Ginsberg, J., et al. (2009). Detecting Influenza Epidemics Using Search Engine Query Data. *Nature*, 457, 1012–1014.
- Lazer, D., Kennedy, R., King, G., & Vespignani, A. (2014). The Parable of Google Flu. *Science*, 343(6176), 1203–1205.

6 Apéndice: para profundizar

A1. La media condicional minimiza el riesgo cuadrático

Conicionemos en $X = x$ y busquemos la mejor predicción constante c :

1. Expandimos:

$$\mathbb{E}[(Y - c)^2 \mid X = x] = \text{Var}(Y \mid X = x) + (\mathbb{E}[Y \mid X = x] - c)^2$$

2. **Minimizamos en c :** el primer término no depende de c ; el segundo es ≥ 0 y se anula en

$$c^* = \mathbb{E}[Y \mid X = x]$$

3. Conclusión:

$$f^*(x) = \mathbb{E}[Y \mid X = x] = \arg \min_f R(f)$$

Interpretación

La **media condicional** es el objetivo teórico de todo el curso. Por eso la regresión — que la aproxima — es el punto de partida natural del ML.

A2. Error reducible e irreducible: la cuenta

Tomemos cualquier predictor $\hat{f}$ (fijo) y evaluemos en $X = x$ (fijo), con $Y = f(x) + \varepsilon$:

1. Sustituimos y expandimos:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \mathbb{E}[(f(x) - \hat{f}(x) + \varepsilon)^2] = (f(x) - \hat{f}(x))^2 + 2(f(x) - \hat{f}(x)) \mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2]$$

2. Como $\mathbb{E}[\varepsilon] = 0$, el término cruzado desaparece:

$$\mathbb{E}[(Y - \hat{f}(x))^2] = \underbrace{(f(x) - \hat{f}(x))^2}_{\text{reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreducible}}$$

- **Reducible:** qué tan lejos está nuestra $\hat{f}$ de la verdadera f . Es lo que un mejor método puede mejorar.
- **Irreducible** (σ^2): ni el modelo perfecto ($\hat{f} = f$) lo elimina. Es el techo de lo aprendible con estos predictores.

A3. Derivación sesgo–varianza (I): separar el error irreducible

Punto de partida (ε_0 es independiente de $\mathcal{D}$, con $\mathbb{E}[\varepsilon_0] = 0$, $\text{Var}(\varepsilon_0) = \sigma^2$):

$$\text{MSE}(x_0) = \mathbb{E}[(Y_0 - \hat{f}(x_0))^2], \quad Y_0 = f(x_0) + \varepsilon_0$$

1. Sustituimos Y_0 y expandimos el cuadrado:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + 2 \mathbb{E}[(f(x_0) - \hat{f}(x_0)) \varepsilon_0] + \mathbb{E}[\varepsilon_0^2]$$

2. El término cruzado se anula: ε_0 es un ruido *nuevo*, independiente de la muestra con que se construyó $\hat{f}$, y tiene media cero:

$$\mathbb{E}[(f(x_0) - \hat{f}(x_0)) \varepsilon_0] = \mathbb{E}[f(x_0) - \hat{f}(x_0)] \cdot \underbrace{\mathbb{E}[\varepsilon_0]}_{=0} = 0$$

3. Resultado parcial:

$$\text{MSE}(x_0) = \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \sigma^2$$

El primer término es el **error de estimación**; nos falta descomponerlo.

A4. Derivación sesgo–varianza (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\mathbb{E}[(f - \hat{f})^2] = \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2$$

A4. Derivación sesgo–varianza (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

A4. Derivación sesgo–varianza (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

5. **Juntando todo:**

$$\text{MSE}(x_0) = \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{\sigma^2}_{\text{Irreducible}}$$

A4. Derivación sesgo–varianza (II): sesgo al cuadrado más varianza

4. **Sumamos y restamos** $\mathbb{E}[\hat{f}(x_0)]$ dentro del error de estimación:

$$\begin{aligned}\mathbb{E}[(f - \hat{f})^2] &= \mathbb{E}\left[\underbrace{(f - \mathbb{E}[\hat{f}])}_{\text{constante}} + \underbrace{\mathbb{E}[\hat{f}] - \hat{f}}_{\text{aleatorio}}\right]^2 \\ &= (f - \mathbb{E}[\hat{f}])^2 + \mathbb{E}\left[(\hat{f} - \mathbb{E}[\hat{f}])^2\right] + 2(f - \mathbb{E}[\hat{f}]) \underbrace{\mathbb{E}[\mathbb{E}[\hat{f}] - \hat{f}]}_{=0}\end{aligned}$$

5. **Juntando todo:**

$$\text{MSE}(x_0) = \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{\sigma^2}_{\text{Irreducible}}$$

Las tres piezas del error de predicción

Sesgo: error sistemático del método (rigidez). **Varianza:** sensibilidad a la muestra particular. σ^2 : ruido que nadie puede eliminar.