

Big Data y Machine Learning para Economía Aplicada

Week 02: Validación Cruzada, Selección de Modelos y Regularización

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 22, 2026

Previously...

En la sesión pasada construimos el marco conceptual:

- El objetivo del ML supervisado es minimizar el **riesgo de generalización**
 $R(f) = \mathbb{E}[L(Y, f(X))]$ — el error en datos **nuevos**.
- El **error de entrenamiento es optimista**: evaluar donde se entrenó premia la memorización.
- El error de prueba tiene forma de **U** en la complejidad, porque
 $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$.
- Y quedó una promesa: aceptar **algo de sesgo** para reducir mucha varianza mejora la predicción.

Previously...

En la sesión pasada construimos el marco conceptual:

- El objetivo del ML supervisado es minimizar el **riesgo de generalización** $R(f) = \mathbb{E}[L(Y, f(X))]$ — el error en datos **nuevos**.
- El **error de entrenamiento es optimista**: evaluar donde se entrenó premia la memorización.
- El error de prueba tiene forma de **U** en la complejidad, porque $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$.
- Y quedó una promesa: aceptar **algo de sesgo** para reducir mucha varianza mejora la predicción.

Hoy: las dos herramientas que faltan

- 1 **Medir**: ¿cómo estimamos el error de prueba sin desperdiciar datos? (validación cruzada, bootstrap, criterios de información)
- 2 **Girar la perilla**: la primera familia que ejecuta el trade-off sesgo-varianza: la **regularización** (Ridge, Lasso, Elastic Net).

- 1 Estimar el error de generalización
- 2 Selección de modelos y criterios de información
- 3 Regularización: Ridge, Lasso y Elastic Net
- 4 El pipeline honesto

El punto de partida: el conjunto de validación

La receta de la sesión 1: apartar una fracción de los datos y evaluar ahí.



El punto de partida: el conjunto de validación

La receta de la sesión 1: apartar una fracción de los datos y evaluar ahí.



Funciona, pero tiene dos defectos:

- 1 **Alta variabilidad:** la estimación del error depende fuertemente de *cuáles* observaciones cayeron en validación. Con otra partición aleatoria, otra conclusión.
- 2 **Desperdicia datos:** el modelo se entrena con solo una parte de la muestra. Con menos datos se aprende peor $\Rightarrow$ tiende a **sobreestimar** el error que tendría el modelo entrenado con todo.

El punto de partida: el conjunto de validación

La receta de la sesión 1: apartar una fracción de los datos y evaluar ahí.



Funciona, pero tiene dos defectos:

- 1 **Alta variabilidad:** la estimación del error depende fuertemente de *cuáles* observaciones cayeron en validación. Con otra partición aleatoria, otra conclusión.
- 2 **Desperdicia datos:** el modelo se entrena con solo una parte de la muestra. Con menos datos se aprende peor $\Rightarrow$ tiende a **sobreestimar** el error que tendría el modelo entrenado con todo.

La idea de la validación cruzada

Reutilizar **todos** los datos: que cada observación sea validación *alguna* vez y entrenamiento *el resto* de las veces.

Leave-One-Out CV (LOOCV)

El extremo: dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2$$

donde $\hat{y}_{(-i)}$ es la predicción para i del modelo entrenado **sin** i .

Leave-One-Out CV (LOOCV)

El extremo: dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2$$

donde $\hat{y}_{(-i)}$ es la predicción para i del modelo entrenado **sin** i .

Ventajas:

- Cada modelo usa $n - 1$ datos $\Rightarrow$ casi **sin sesgo** respecto al error verdadero.
- No hay aleatoriedad: siempre da el mismo número.

Leave-One-Out CV (LOOCV)

El extremo: dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2$$

donde $\hat{y}_{(-i)}$ es la predicción para i del modelo entrenado **sin** i .

Ventajas:

- Cada modelo usa $n - 1$ datos $\Rightarrow$ casi **sin sesgo** respecto al error verdadero.
- No hay aleatoriedad: siempre da el mismo número.

Desventajas:

- Hay que ajustar el modelo n veces (costoso con n grande).
- **Varianza alta:** los n modelos comparten $n - 2$ observaciones $\Rightarrow$ son casi idénticos $\Rightarrow$ sus errores están muy correlacionados $\Rightarrow$ promediarlos reduce poco la varianza (¡la lección del promedio correlacionado volverá en la sesión 4!).

El atajo de LOOCV en regresión lineal

Para mínimos cuadrados existe una identidad notable: con **un solo ajuste** sobre todos los datos,

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$

donde h_i es el *leverage* de la observación i (el elemento i de la diagonal de la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$).

El atajo de LOOCV en regresión lineal

Para mínimos cuadrados existe una identidad notable: con **un solo ajuste** sobre todos los datos,

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$

donde h_i es el *leverage* de la observación i (el elemento i de la diagonal de la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$).

- **Intuición:** una observación con leverage alto “atrae” la recta hacia sí misma; su residuo dentro de muestra es artificialmente pequeño. Dividir por $(1 - h_i)$ deshace ese favor.
- El costo pasa de n ajustes a **uno**.

El atajo de LOOCV en regresión lineal

Para mínimos cuadrados existe una identidad notable: con **un solo ajuste** sobre todos los datos,

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$

donde h_i es el *leverage* de la observación i (el elemento i de la diagonal de la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$).


- **Intuición:** una observación con leverage alto “atrae” la recta hacia sí misma; su residuo dentro de muestra es artificialmente pequeño. Dividir por $(1 - h_i)$ deshace ese favor.
- El costo pasa de n ajustes a **uno**.

Alcance

La identidad vale para mínimos cuadrados (y suavizadores lineales). Para árboles, redes o *boosting* no hay atajo: por eso en la práctica domina el k -fold.


k -fold: el estándar de la industria

Partir la muestra en k bloques (*folds*) de tamaño similar; cada bloque es validación una vez:



k -fold: el estándar de la industria

Partir la muestra en k bloques (*folds*) de tamaño similar; cada bloque es validación una vez:



$$CV_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{MSE}_j \quad (\text{con folds de igual tamaño})$$

- Cada modelo entrena con fracción $(k-1)/k$ de los datos; se ajusta k veces.
- **Estándar:** $k=5$ o $k=10$.

¿Qué k elegir? El sesgo–varianza... del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

¿Qué k elegir? El sesgo–varianza... del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes

¿Qué k elegir? El sesgo–varianza... del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes

- **Sesgo:** entrenar con menos datos que n hace ver los modelos peores de lo que serán $\Rightarrow$ el CV es algo *pesimista*; el efecto se agrava con folds pequeños (k chico).
- **Varianza:** LOOCV promedia errores de modelos casi clones (muy correlacionados); k -fold usa modelos más distintos entre sí.
- **Veredicto práctico:** $k = 10$ por defecto; $k = 5$ si el ajuste es costoso.

¿Qué k elegir? El sesgo–varianza... del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes


- **Sesgo:** entrenar con menos datos que n hace ver los modelos peores de lo que serán $\Rightarrow$ el CV es algo *pesimista*; el efecto se agrava con folds pequeños (k chico).
- **Varianza:** LOOCV promedia errores de modelos casi clones (muy correlacionados); k -fold usa modelos más distintos entre sí.
- **Veredicto práctico:** $k = 10$ por defecto; $k = 5$ si el ajuste es costoso.

Ojo economistas: datos en el tiempo

Con series de tiempo **no** se barajan folds: se valida “hacia adelante” (entrenar en el pasado, predecir el futuro, ventana rodante). Barajar filtra el futuro hacia el pasado.


CV para elegir hiperparámetros

El uso central del CV en este curso: **girar perillas**. Para una grilla de valores $\lambda_1, \dots, \lambda_m$: calcular $CV(\lambda)$ y elegir.



CV para elegir hiperparámetros

El uso central del CV en este curso: **girar perillas**. Para una grilla de valores $\lambda_1, \dots, \lambda_m$: calcular $CV(\lambda)$ y elegir.



- $\lambda_{\min}$: el mínimo de la curva.
- **Regla de una desviación estándar (1-SE)**: elegir el modelo **más simple** cuyo CV esté a menos de 1 error estándar del mínimo. Razón: el propio CV es ruidoso; ante empate estadístico, parsimonia.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sec. 7.10.2)

Escenario: $n = 50$, $p = 5000$ predictores, y una y generada **al azar** (ninguna relación real).

Procedimiento (¿ven el error?):

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un modelo y estimar su error por 5-fold CV.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sec. 7.10.2)

Escenario: $n = 50$, $p = 5000$ predictores, y una y generada **al azar** (ninguna relación real).

Procedimiento (¿ven el error?):

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un modelo y estimar su error por 5-fold CV.

Resultado: el CV reporta un error bajísimo... en datos donde no hay *nada* que predecir. El paso 1 ya “vio” las respuestas de todos los folds: los predictores fueron elegidos usando también las observaciones que luego fingimos no conocer.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sec. 7.10.2)

Escenario: $n = 50$, $p = 5000$ predictores, y una y generada **al azar** (ninguna relación real).

Procedimiento (¿ven el error?):

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un modelo y estimar su error por 5-fold CV.

Resultado: el CV reporta un error bajísimo... en datos donde no hay *nada* que predecir. El paso 1 ya “vio” las respuestas de todos los folds: los predictores fueron elegidos usando también las observaciones que luego fingimos no conocer.

La regla: todo paso que use y — selección de variables, imputación con y , remuestreo, estandarización con estadísticos de todo el conjunto — debe ocurrir **dentro** de cada fold, solo con sus datos de entrenamiento.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sec. 7.10.2)

Escenario: $n = 50$, $p = 5000$ predictores, y una y generada **al azar** (ninguna relación real).

Procedimiento (¿ven el error?):

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un modelo y estimar su error por 5-fold CV.

Resultado: el CV reporta un error bajísimo... en datos donde no hay *nada* que predecir. El paso 1 ya “vio” las respuestas de todos los folds: los predictores fueron elegidos usando también las observaciones que luego fingimos no conocer.

La regla: todo paso que use y — selección de variables, imputación con y , remuestreo, estandarización con estadísticos de todo el conjunto — debe ocurrir **dentro** de cada fold, solo con sus datos de entrenamiento.

Regla de oro #3

El CV no valida modelos: valida **pipelines completos**.

Bootstrap: la idea general

Pregunta distinta: ¿qué tan **incierto** es un estadístico? (un coeficiente, una mediana, un AUC, un ratio...)

Bootstrap: la idea general

Pregunta distinta: ¿qué tan **incierto** es un estadístico? (un coeficiente, una mediana, un AUC, un ratio...)

El principio plug-in (Efron, 1979):

- No podemos re-muestrear del mundo real; pero la muestra empírica es nuestra mejor estimación del mundo real.
- Entonces: extraer B **remuestras con reemplazo** de tamaño n de la propia muestra; calcular el estadístico en cada una; la dispersión de esas B réplicas estima su error estándar.

$$\widehat{SE}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}$$

Bootstrap: la idea general

Pregunta distinta: ¿qué tan **incierto** es un estadístico? (un coeficiente, una mediana, un AUC, un ratio...)

El principio plug-in (Efron, 1979):

- No podemos re-muestrear del mundo real; pero la muestra empírica es nuestra mejor estimación del mundo real.
- Entonces: extraer B **remuestras con reemplazo** de tamaño n de la propia muestra; calcular el estadístico en cada una; la dispersión de esas B réplicas estima su error estándar.

$$\widehat{SE}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}$$

- Funciona para estadísticos donde **no hay fórmula** de error estándar.
- En este curso lo usaremos dos veces más: *bagging* (sesión 4) nace de remuestras bootstrap, y los intervalos de los *causal forests* (sesión 6) también.

Bootstrap y el error out-of-bag

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra bootstrap?

Bootstrap y el error out-of-bag

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra bootstrap?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632$$

Bootstrap y el error out-of-bag

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra bootstrap?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632$$

- Cada remuestra contiene $\approx 63.2\%$ de las observaciones; el $\approx 36.8\%$ restante queda **afuera** (*out-of-bag*, OOB).
- **Idea:** esas observaciones excluidas son datos de prueba *gratis* para el modelo ajustado en esa remuestra.
- **Error OOB:** predecir cada i usando solo los modelos de las remuestras que **no** la contienen, y promediar.

Bootstrap y el error out-of-bag

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra bootstrap?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632$$

- Cada remuestra contiene $\approx 63.2\%$ de las observaciones; el $\approx 36.8\%$ restante queda **afuera** (*out-of-bag*, OOB).
- **Idea:** esas observaciones excluidas son datos de prueba *gratis* para el modelo ajustado en esa remuestra.
- **Error OOB:** predecir cada i usando solo los modelos de las remuestras que **no** la contienen, y promediar.

Anticipo

Guarden este número (0.632): en la sesión 4, el error OOB nos dará el error de prueba de un Random Forest **sin necesidad de CV**.

- 1 Estimar el error de generalización
- 2 Selección de modelos y criterios de información
- 3 Regularización: Ridge, Lasso y Elastic Net
- 4 El pipeline honesto

El problema de comparar modelos de distinto tamaño

Pregunta previa: ¿por qué no comparar modelos por su R^2 o su RSS?

El problema de comparar modelos de distinto tamaño

Pregunta previa: ¿por qué no comparar modelos por su R^2 o su RSS?

Porque **siempre** mejoran al agregar variables — son medidas de ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada: gana el grande aunque las 27 extra sean ruido.

El problema de comparar modelos de distinto tamaño

Pregunta previa: ¿por qué no comparar modelos por su R^2 o su RSS?

Porque **siempre** mejoran al agregar variables — son medidas de ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada: gana el grande aunque las 27 extra sean ruido.

Los enfoques clásicos de selección:

- **Best subset:** probar los 2^p modelos posibles. Con $p = 20$: un millón; con $p = 40$: 10^{12} . Inviabile rápido.
- **Forward stepwise:** empezar vacío; agregar en cada paso la variable que más mejora. Solo $\approx p^2/2$ ajustes, pero *greedy*: no garantiza el mejor subconjunto.
- **Backward stepwise:** empezar completo e ir quitando (requiere $n > p$).

El problema de comparar modelos de distinto tamaño

Pregunta previa: ¿por qué no comparar modelos por su R^2 o su RSS?

Porque **siempre** mejoran al agregar variables — son medidas de ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada: gana el grande aunque las 27 extra sean ruido.

Los enfoques clásicos de selección:

- **Best subset:** probar los 2^p modelos posibles. Con $p = 20$: un millón; con $p = 40$: 10^{12} . Inviabile rápido.
- **Forward stepwise:** empezar vacío; agregar en cada paso la variable que más mejora. Solo $\approx p^2/2$ ajustes, pero *greedy*: no garantiza el mejor subconjunto.
- **Backward stepwise:** empezar completo e ir quitando (requiere $n > p$).

Y en todos los casos, la pregunta de fondo persiste: entre el mejor modelo de 3 variables y el mejor de 8, **¿cuál gana?** Necesitamos ajustar el optimismo del error de entrenamiento.

Criterios de información: castigar la complejidad

La idea común: error de entrenamiento + castigo por parámetro usado ($d =$ número de parámetros):

Criterios de información: castigar la complejidad

La idea común: error de entrenamiento + castigo por parámetro usado (d = número de parámetros):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2)$$

$$\text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2)$$

donde $\hat{\sigma}^2$ estima la varianza del error. (El AIC es proporcional a C_p en el modelo lineal gaussiano.)

Criterios de información: castigar la complejidad

La idea común: error de entrenamiento + castigo por parámetro usado ($d =$ número de parámetros):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2)$$

$$\text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2)$$

donde $\hat{\sigma}^2$ estima la varianza del error. (El AIC es proporcional a C_p en el modelo lineal gaussiano.)

- C_p/AIC : castigo 2 por parámetro $\Rightarrow$ apunta a **predecir** bien.
- BIC: castigo $\log(n) > 2$ para $n \geq 8 \Rightarrow$ elige modelos **más pequeños**; si existe un “modelo verdadero” esparso, lo recupera con n grande (consistencia).
- R^2 ajustado: el pariente informal; penaliza poco.

Criterios de información: castigar la complejidad

La idea común: error de entrenamiento + castigo por parámetro usado ($d =$ número de parámetros):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2)$$

$$\text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2)$$

donde $\hat{\sigma}^2$ estima la varianza del error. (El AIC es proporcional a C_p en el modelo lineal gaussiano.)

- C_p/AIC : castigo 2 por parámetro $\Rightarrow$ apunta a **predecir** bien.
- BIC: castigo $\log(n) > 2$ para $n \geq 8 \Rightarrow$ elige modelos **más pequeños**; si existe un “modelo verdadero” esparso, lo recupera con n grande (consistencia).
- R^2 ajustado: el pariente informal; penaliza poco.

Intuición del castigo

Cada parámetro extra le “roba” al error de entrenamiento $\approx 2\hat{\sigma}^2/n$ de optimismo. Los criterios se lo devuelven.

¿Criterios o validación cruzada?

	Criterios (C_p , AIC, BIC)	Validación cruzada
Costo	un ajuste	k ajustes
Supuestos	modelo (aprox.) correcto, $\hat{\sigma}^2$	casi ninguno
¿Qué es d ?	claro en modelos lineales	no lo necesita
¿Aplica a RF, boosting, redes?	no (d mal definido)	sí

¿Criterios o validación cruzada?

	Criterios (C_p , AIC, BIC)	Validación cruzada
Costo	un ajuste	k ajustes
Supuestos	modelo (aprox.) correcto, $\hat{\sigma}^2$	casi ninguno
¿Qué es d ?	claro en modelos lineales	no lo necesita
¿Aplica a RF, boosting, redes?	no (d mal definido)	sí

- Los criterios nacieron cuando ajustar un modelo era **caro**. Hoy el cómputo es barato y los métodos son flexibles: ¿cuántos “parámetros” tiene un Random Forest? Nadie sabe.
- **Veredicto del curso:** CV por defecto para todo; criterios como referencia rápida en modelos lineales clásicos.

¿Criterios o validación cruzada?

	Criterios (C_p , AIC, BIC)	Validación cruzada
Costo	un ajuste	k ajustes
Supuestos	modelo (aprox.) correcto, $\hat{\sigma}^2$	casi ninguno
¿Qué es d ?	claro en modelos lineales	no lo necesita
¿Aplica a RF, boosting, redes?	no (d mal definido)	sí

- Los criterios nacieron cuando ajustar un modelo era **caro**. Hoy el cómputo es barato y los métodos son flexibles: ¿cuántos “parámetros” tiene un Random Forest? Nadie sabe.
- **Veredicto del curso:** CV por defecto para todo; criterios como referencia rápida en modelos lineales clásicos.

Hasta aquí, “elegir modelo” significó **elegir variables**: una decisión discreta, de todo o nada, e inestable. La regularización propone algo más elegante.

- 1 Estimar el error de generalización
- 2 Selección de modelos y criterios de información
- 3 Regularización: Ridge, Lasso y Elastic Net
- 4 El pipeline honesto

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar** (subset/stepwise): cada variable está *dentro o fuera*. Decisión discreta $\Rightarrow$ pequeñas perturbaciones de los datos cambian el modelo entero $\Rightarrow$ **varianza alta**.

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar** (subset/stepwise): cada variable está *dentro o fuera*. Decisión discreta $\Rightarrow$ pequeñas perturbaciones de los datos cambian el modelo entero $\Rightarrow$ **varianza alta**.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar** (subset/stepwise): cada variable está *dentro o fuera*. Decisión discreta $\Rightarrow$ pequeñas perturbaciones de los datos cambian el modelo entero $\Rightarrow$ **varianza alta**.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Formulación general:

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\sum_{i=1}^n (y_i - x_i' \beta)^2}_{\text{ajuste}} + \lambda \cdot \underbrace{\mathcal{P}(\beta)}_{\text{penalización}}$$

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar** (subset/stepwise): cada variable está *dentro o fuera*. Decisión discreta $\Rightarrow$ pequeñas perturbaciones de los datos cambian el modelo entero $\Rightarrow$ **varianza alta**.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Formulación general:

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\sum_{i=1}^n (y_i - x_i' \beta)^2}_{\text{ajuste}} + \lambda \cdot \underbrace{\mathcal{P}(\beta)}_{\text{penalización}}$$

- $\lambda \geq 0$: la **perilla continua** de complejidad. $\lambda = 0$: OLS. $\lambda \rightarrow \infty$: todos los coeficientes a 0.
- λ se elige por **validación cruzada** (por eso vimos CV primero).
- Hoy: tres penalizaciones $\mathcal{P}$, tres estimadores.

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

1. Expandimos la función objetivo:

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta$$

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

1. Expandimos la función objetivo:

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta$$

2. Derivamos con respecto a β :

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta$$

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

1. Expandimos la función objetivo:

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta$$

2. Derivamos con respecto a β :

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta$$

3. Igualamos a cero:

$$(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}) \beta = \mathbf{X}'\mathbf{y}$$

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

1. Expandimos la función objetivo:

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta$$

2. Derivamos con respecto a β :

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta$$

3. Igualamos a cero:

$$(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}$$

4. Solución:

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}$$

Ridge: derivación de la solución cerrada

Problema (Hoerl & Kennard, 1970):

$$\hat{\beta}^R = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta$$

1. Expandimos la función objetivo:

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta$$

2. Derivamos con respecto a β :

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta$$

3. Igualamos a cero:

$$(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}$$

4. Solución:

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}$$

Compárenla con OLS

$\hat{\beta}^{OLS} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$. La única diferencia: λ sumado a la diagonal.

La magia de λI : estabilizar la inversa

¿Recuerdan cuándo explota la varianza de OLS? Cuando $\mathbf{X}'\mathbf{X}$ es (casi) singular: $p > n$, colinealidad, autovalores cercanos a cero.

La magia de λ I: estabilizar la inversa

¿Recuerdan cuándo explota la varianza de OLS? Cuando $\mathbf{X}'\mathbf{X}$ es (casi) singular: $p > n$, colinealidad, autovalores cercanos a cero.

- Si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda$: **todos positivos** para cualquier $\lambda > 0$.
- $\Rightarrow$ la inversa **siempre existe** y está bien condicionada — incluso con $p > n$.
- Las direcciones problemáticas (autovalor pequeño = poca información en los datos) son las que más se encogen: Ridge “desconfía” donde los datos informan poco.

La magia de λ I: estabilizar la inversa

¿Recuerdan cuándo explota la varianza de OLS? Cuando $\mathbf{X}'\mathbf{X}$ es (casi) singular: $p > n$, colinealidad, autovalores cercanos a cero.

- Si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda$: **todos positivos** para cualquier $\lambda > 0$.
- $\Rightarrow$ la inversa **siempre existe** y está bien condicionada — incluso con $p > n$.
- Las direcciones problemáticas (autovalor pequeño = poca información en los datos) son las que más se encogen: Ridge “desconfía” donde los datos informan poco.

Caso ortonormal ($\mathbf{X}'\mathbf{X} = \mathbf{I}$): la fórmula se vuelve transparente:

$$\hat{\beta}_j^R = \frac{\hat{\beta}_j^{OLS}}{1 + \lambda}$$

Encogimiento **proporcional**: todos los coeficientes se reducen en el mismo factor, y **ninguno llega exactamente a cero**.

La magia de λ I: estabilizar la inversa

¿Recuerdan cuándo explota la varianza de OLS? Cuando $\mathbf{X}'\mathbf{X}$ es (casi) singular: $p > n$, colinealidad, autovalores cercanos a cero.

- Si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda$: **todos positivos** para cualquier $\lambda > 0$.
- $\Rightarrow$ la inversa **siempre existe** y está bien condicionada — incluso con $p > n$.
- Las direcciones problemáticas (autovalor pequeño = poca información en los datos) son las que más se encogen: Ridge “desconfía” donde los datos informan poco.

Caso ortonormal ($\mathbf{X}'\mathbf{X} = \mathbf{I}$): la fórmula se vuelve transparente:

$$\hat{\beta}_j^R = \frac{\hat{\beta}_j^{OLS}}{1 + \lambda}$$

Encogimiento **proporcional**: todos los coeficientes se reducen en el mismo factor, y **ninguno llega exactamente a cero**.

La promesa de la sesión 1, cumplida

$\hat{\beta}^R$ es **sesgado** hacia cero, pero su varianza es menor que la de OLS. Existe

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años” — pero sus magnitudes no son comparables. Si multiplico ingreso por 1000, su β se divide por 1000 y casi no se penaliza.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años” — pero sus magnitudes no son comparables. Si multiplico ingreso por 1000, su β se divide por 1000 y casi no se penaliza.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar. Así λ trata a todos por igual.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años” — pero sus magnitudes no son comparables. Si multiplico ingreso por 1000, su β se divide por 1000 y casi no se penaliza.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar. Así λ trata a todos por igual.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones hacia cero sin ganar nada.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años” — pero sus magnitudes no son comparables. Si multiplico ingreso por 1000, su β se divide por 1000 y casi no se penaliza.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar. Así λ trata a todos por igual.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones hacia cero sin ganar nada.
- En la práctica, `glmnet` estandariza y excluye el intercepto **por defecto** — pero hay que saber que lo hace, y que los coeficientes reportados vuelven a la escala original.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años” — pero sus magnitudes no son comparables. Si multiplico ingreso por 1000, su β se divide por 1000 y casi no se penaliza.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar. Así λ trata a todos por igual.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones hacia cero sin ganar nada.
- En la práctica, `glmnet` estandariza y excluye el intercepto **por defecto** — pero hay que saber que lo hace, y que los coeficientes reportados vuelven a la escala original.

Y el leakage otra vez

Las medias y desviaciones para estandarizar se calculan **con los datos de entrenamiento de cada fold**, no con toda la muestra (regla de oro #3).

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996):

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996):

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- El único cambio vs. Ridge: $|\beta_j|$ en lugar de β_j^2 .
- La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996):

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- El único cambio vs. Ridge: $|\beta_j|$ en lugar de β_j^2 .
- La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.
- El Lasso hace **dos trabajos a la vez**: encoge (control de varianza) y selecciona variables (interpretabilidad, modelos esparsos).
- No tiene solución cerrada (el valor absoluto no es diferenciable en 0) — los algoritmos, en la sesión 3.

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996):

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$


- El único cambio vs. Ridge: $|\beta_j|$ en lugar de β_j^2 .
- La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.
- El Lasso hace **dos trabajos a la vez**: encoge (control de varianza) y selecciona variables (interpretabilidad, modelos esparsos).
- No tiene solución cerrada (el valor absoluto no es diferenciable en 0) — los algoritmos, en la sesión 3.

¿Por qué el valor absoluto produce ceros exactos?


La respuesta está en la **geometría** de la restricción.

La geometría: por qué el Lasso anula y Ridge no

Forma equivalente (restringida): minimizar RSS sujeto a $\mathcal{P}(\beta) \leq t$.




Lasso: $|\beta_1| + |\beta_2| \leq t$




Ridge: $\beta_1^2 + \beta_2^2 \leq t$

La geometría: por qué el Lasso anula y Ridge no

Forma equivalente (restringida): minimizar RSS sujeto a $\mathcal{P}(\beta) \leq t$.



Lasso: $|\beta_1| + |\beta_2| \leq t$




Ridge: $\beta_1^2 + \beta_2^2 \leq t$


- La solución: donde las curvas de nivel del RSS (elipses) **tocan** la región factible (azul).
- El diamante tiene **esquinas sobre los ejes** ($\beta_j = 0$): las elipses suelen tocar ahí primero $\Rightarrow$ ceros exactos. El círculo **no tiene esquinas**: el contacto casi nunca cae en un eje.

Los tres umbrales, cara a cara


Con $\mathbf{X}$ ortonormal, los tres métodos transforman $\hat{\beta}_j^{OLS}$ así:



Subset (duro)




Ridge ($\times \frac{1}{1+\lambda}$)




Lasso (suave)

Los tres umbrales, cara a cara


Con $\mathbf{X}$ ortonormal, los tres métodos transforman $\hat{\beta}_j^{OLS}$ así:



Subset (duro)



Ridge ($\times \frac{1}{1+\lambda}$)



Lasso (suave)

- **Subset** = umbral **duro**: conserva intactos los grandes, elimina los chicos (salto discontinuo: inestabilidad).
- **Ridge** = encogimiento proporcional: nunca llega a cero.
- **Lasso** = umbral **suave**: $\hat{\beta}_j^L = \text{sign}(\hat{\beta}_j) (|\hat{\beta}_j| - \lambda)_+$ — corre todo hacia cero y corta. Continuo y esparso: lo mejor de los dos mundos.
- La derivación formal de esta fórmula: sesión 3, vía condiciones KKT.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso**
— recorta el ruido a cero y concentra la estimación donde hay señal.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso** — recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge** — anular variables tira señal a la basura; mejor encoger todo un poco.
Ejemplo: predecir precios con cientos de micro-atributos que aportan poquito cada uno.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso** — recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge** — anular variables tira señal a la basura; mejor encoger todo un poco.
Ejemplo: predecir precios con cientos de micro-atributos que aportan poquito cada uno.
- **Predictores muy correlacionados**: el Lasso tiende a elegir **uno** del grupo (casi al azar) y anular los demás $\Rightarrow$ el conjunto seleccionado es **inestable** entre muestras. Cuidado con sobreinterpretar “las variables elegidas”.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso** — recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge** — anular variables tira señal a la basura; mejor encoger todo un poco.
Ejemplo: predecir precios con cientos de micro-atributos que aportan poquito cada uno.
- **Predictores muy correlacionados**: el Lasso tiende a elegir **uno** del grupo (casi al azar) y anular los demás $\Rightarrow$ el conjunto seleccionado es **inestable** entre muestras. Cuidado con sobreinterpretar “las variables elegidas”.

En la práctica

Nadie lo sabe *a priori*: se prueban ambos (y Elastic Net) y **decide el CV**.

Elastic Net: lo mejor de ambos

Problema (Zou & Hastie, 2005), en la parametrización de glmnet:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

Elastic Net: lo mejor de ambos

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ Lasso puro, $\alpha = 0$ Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación.
- **Grouping effect**: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes similares — en vez del sorteo arbitrario del Lasso.

Elastic Net: lo mejor de ambos

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ Lasso puro, $\alpha = 0$ Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación.
- **Grouping effect**: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes similares — en vez del sorteo arbitrario del Lasso.
- Dos hiperparámetros: (λ, α) . En la práctica: CV sobre una grilla de ambos, o fijar $\alpha \in \{0.5, 1\}$ y CV sobre λ .

Elastic Net: lo mejor de ambos

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ Lasso puro, $\alpha = 0$ Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación.
- **Grouping effect**: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes similares — en vez del sorteo arbitrario del Lasso.
- Dos hiperparámetros: (λ, α) . En la práctica: CV sobre una grilla de ambos, o fijar $\alpha \in \{0.5, 1\}$ y CV sobre λ .

Regla mental

Ridge = estabilidad; Lasso = esparsidad; Elastic Net = negociación entre las dos, con α como término del acuerdo.

La lectura bayesiana: penalizar es tener un prior

Los tres estimadores son **modas posteriores** bajo distintos priors sobre β :

$$\hat{\beta}^R : \beta_j \sim N(0, \tau^2)$$


$$\hat{\beta}^L : \beta_j \sim \text{Laplace}(0, b)$$

La lectura bayesiana: penalizar es tener un prior

Los tres estimadores son **modas posteriores** bajo distintos priors sobre β :

$$\hat{\beta}^R : \beta_j \sim N(0, \tau^2)$$

$$\hat{\beta}^L : \beta_j \sim \text{Laplace}(0, b)$$




La lectura bayesiana: penalizar es tener un prior

Los tres estimadores son **modas posteriores** bajo distintos priors sobre β :

$$\hat{\beta}^R : \beta_j \sim N(0, \tau^2)$$


$$\hat{\beta}^L : \beta_j \sim \text{Laplace}(0, b)$$




- El prior de Laplace es **picudo en cero**: apuesta a que muchos coeficientes son exactamente nulos $\Rightarrow$ la moda posterior produce ceros.
- λ traduce la **fuerza de la creencia**: regularizar fuerte = prior concentrado en cero.
- Mensaje: la penalización no es un truco numérico; es **información previa** sobre cómo creemos que es el mundo (“los efectos son pequeños/esparcos”).

- 1 Estimar el error de generalización
- 2 Selección de modelos y criterios de información
- 3 Regularización: Ridge, Lasso y Elastic Net
- 4 El pipeline honesto

Todo junto: el flujo de trabajo completo




Todo junto: el flujo de trabajo completo



- 1 **Separar prueba** al inicio y guardarla bajo llave.
- 2 Dentro del entrenamiento: **CV** (con estandarización y todo preprocesamiento *dentro* de cada fold) para elegir hiperparámetros — mínimo o regla 1-SE.
- 3 **Reajustar** el modelo ganador con todo el entrenamiento.
- 4 **Una sola** evaluación final en prueba: ese número se reporta.

Todo junto: el flujo de trabajo completo




- 1 **Separar prueba** al inicio y guardarla bajo llave.
- 2 Dentro del entrenamiento: **CV** (con estandarización y todo preprocesamiento *dentro* de cada fold) para elegir hiperparámetros — mínimo o regla 1-SE.
- 3 **Reajustar** el modelo ganador con todo el entrenamiento.
- 4 **Una sola** evaluación final en prueba: ese número se reporta.

Este esqueleto no cambia más

Lo que cambia de aquí al final del curso es el **modelo del medio**: hoy `glmnet`; luego bosques, *boosting*, redes. El pipeline es el mismo.


Leer un camino de regularización

La salida típica de `glmnet`: los coeficientes como función de λ .



Leer un camino de regularización

La salida típica de `glmnet`: los coeficientes como función de λ .



- De izquierda (λ grande: todo en cero) a derecha ($\lambda \rightarrow 0$: se acerca a OLS).
- **El orden de entrada informa:** lo que entra primero es lo que más poder predictivo aporta.
- En λ_{1SE} (línea punteada) el modelo final usa **dos** variables: eso es lo que se reporta.

Recap

- 1 La **validación cruzada** estima el error de generalización reutilizando los datos: $k = 5$ o 10 es el estándar; LOOCV tiene atajo solo en regresión lineal; con series de tiempo, folds hacia adelante.
- 2 **Regla de oro #3**: el CV valida *pipelines*, no modelos — todo paso que use y ocurre dentro de cada fold (la historia de los 5000 predictores).
- 3 El **bootstrap** estima incertidumbre remuestreando; deja $\approx 36.8\%$ afuera $\Rightarrow$ error *out-of-bag*.
- 4 Los **criterios** (C_p , AIC, BIC) castigan la complejidad con supuestos; el CV lo hace sin ellos. Hoy: CV por defecto.
- 5 **Ridge** = $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$: estabiliza la inversa, encoge proporcionalmente, nunca anula. **Lasso**: el valor absoluto produce **ceros exactos** (geometría del diamante; umbral suave). **Elastic Net**: mezcla con *grouping effect*.
- 6 Penalizar = tener un **prior**: Normal (Ridge) o Laplace (Lasso).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, caps. 5 (secs. 5.1) y 6 (secs. 6.1–6.2).
Guía: validación cruzada, y la comparación Ridge/Lasso con sus figuras.
- Tibshirani (1996), *Regression Shrinkage and Selection via the Lasso*.
Guía: secciones 1–3; el resto lo cubrimos la próxima semana.

Lecturas recomendadas: ESL caps. 5 y 7 (selectivo); Zou & Hastie (2005, Elastic Net).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, caps. 5 (secs. 5.1) y 6 (secs. 6.1–6.2).
Guía: validación cruzada, y la comparación Ridge/Lasso con sus figuras.
- Tibshirani (1996), *Regression Shrinkage and Selection via the Lasso*.
Guía: secciones 1–3; el resto lo cubrimos la próxima semana.

Lecturas recomendadas: ESL caps. 5 y 7 (selectivo); Zou & Hastie (2005, Elastic Net).

Advertencia amistosa: la próxima es la sesión de **mayor carga matemática** del curso: la teoría del Lasso — condiciones KKT, subgradientes, *coordinate descent*, y cuándo el Lasso recupera las variables verdaderas. Repasen el **Lagrangiano y las condiciones KKT** de sus cursos de optimización/micro.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, caps. 5 (secs. 5.1) y 6 (secs. 6.1–6.2).
Guía: validación cruzada, y la comparación Ridge/Lasso con sus figuras.
- Tibshirani (1996), *Regression Shrinkage and Selection via the Lasso*.
Guía: secciones 1–3; el resto lo cubrimos la próxima semana.

Lecturas recomendadas: ESL caps. 5 y 7 (selectivo); Zou & Hastie (2005, Elastic Net).

Advertencia amistosa: la próxima es la sesión de **mayor carga matemática** del curso: la teoría del Lasso — condiciones KKT, subgradientes, *coordinate descent*, y cuándo el Lasso recupera las variables verdaderas. Repasen el **Lagrangiano y las condiciones KKT** de sus cursos de optimización/micro.

Cierre de la próxima sesión: el puente hacia la inferencia causal — por qué usar el Lasso para *seleccionar controles* requiere cuidado (*post-double-selection*).

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 5–6. [ISLR]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Caps. 3, 5 y 7. [ESL]
- Stone, M. (1974). Cross-Validatory Choice and Assessment of Statistical Predictions. *JRSS-B*, 36(2), 111–147.
- Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *Annals of Statistics*, 7(1), 1–26.
- Hoerl, A., & Kennard, R. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *JRSS-B*, 58(1), 267–288.
- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *JRSS-B*, 67(2), 301–320.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1). [glmnet]