

Big Data y Machine Learning para Economía Aplicada

Week 02: La regresión lineal como máquina de predecir — y cómo
evaluar una predicción

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 18, 2026

Previously...

- Y , **no** β : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción.
- El objetivo es el **riesgo de generalización** (con pérdida cuadrática, el **MSE**); el mejor predictor es la media condicional $\mathbb{E}[Y | X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro**: #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$: la complejidad baja el sesgo y sube la varianza; el óptimo es interior (la curva U).
- **Lo vimos con datos**: 50 avisos, tres polinomios; el grado 12 ajustaba mejor dentro y predecía peor fuera. Hoy empieza el problema del curso.

Hoy

La regresión que ya conocen como **máquina de predecir**: qué se conserva del OLS, qué deja de importar y qué aparece; k -NN como primer contraste; y cómo **evaluar** una predicción: métricas, referencia, gráficos y dónde mirar los errores.

La pregunta de hoy: ¿cuánto del voto de un puesto se puede predecir con su entorno?

El caso del curso: la segunda vuelta presidencial de 2022, Petro vs. Hernández, puesto por puesto

- **La unidad:** el puesto de votación (un colegio, una escuela, una caseta): 12.001 en el país con coordenadas y censo; 1.060 en el Valle; 343 en Cali, Palmira, Yumbo y Jamundí.
- **La y de hoy y de las sesiones 3 y 5:** `voto_petro`, los votos por Petro sobre los votos por los dos candidatos, en puntos. Del 20% (Santander) al 86% (Chocó); en el área metropolitana, del 15% (Pance) al 94% (La Meseta, Jamundí).
- **La y de la sesión 4:** la misma, cortada en 50: ¿ganó Petro el puesto?
- **Las x:** lo que el censo de 2018 dice del **entorno** del puesto. Nada de encuestas ni de campaña: sólo estructura.

Cómo la respondemos hoy, y durante el curso

Una campaña quiere saber qué puestos son “suyos” antes de gastar; un analista, cuánto del voto es *estructura* del territorio. Hoy: la teoría de la regresión como máquina de predecir, con estos puestos como ejemplo, y después el mismo ejercicio en R. Cada semana volvemos al caso con una herramienta más; una **tabla del líder** lleva la cuenta.

Lo que sabemos de cada puesto

Las manzanas del censo asignadas a cada puesto, resumidas en cuatro bloques (y la ubicación)

Bloque	Variables (en % del entorno)	En Cali, Palmira, Yumbo y Jamundí
Socioeconómico	viviendas de estrato bajo (1–2), medio (3–4) y alto (5–6); personas con educación superior	educación superior: del 0 al 58%; estrato alto: del 0 al 92%
Infraestructura y tamaño	servicios por vivienda (agua, alcantarillado, energía, gas, internet: 0 a 5); población; registrados	registrados: de 47 a 21 mil
Demografía	seis grupos de edad; mujeres	mujeres: 48 a 56%
Etnia	afrocolombianos; indígenas	afro: del 0 al 92%
Ubicación	longitud y latitud; cabecera o rural; municipio; departamento	343 puntos en el mapa

- Además, la **referencia vigente**: el voto por Petro en el mismo puesto en 2018, cuando existía.
- Hoy: una variable, luego nueve, luego el mapa. Sesión 3: todo el país con todos los bloques; sesión 7: las 44 columnas crudas del censo. Datos y diccionario en `applications/week-02/input`.

1 La regresión lineal como máquina de predecir

2 Cómo evaluar una predicción de regresión

3 Aplicación guiada

4 Cierre

El capítulo canónico, leído con otros ojos

ISL abre su capítulo 3 con siete preguntas (sobre publicidad y ventas); son las mismas siete sobre el entorno y el voto

- ① ¿Hay relación entre el entorno del puesto y su voto?
- ② ¿Qué tan fuerte es?
- ③ ¿Qué variables del entorno están asociadas con el voto?
- ④ ¿Qué tan grande es la asociación de cada una?
- ⑤ **¿Con qué precisión podemos predecir el voto de un puesto que no hemos visto?**
- ⑥ ¿Es lineal la relación?
- ⑦ ¿Hay interacciones (la educación pesa distinto en la ciudad y en el campo)?

Seis preguntas sobre la relación y sus coeficientes; una sola, la quinta, sobre predecir. Y el capítulo no evalúa fuera de muestra: la primera partición llega en el capítulo 5.

Hoy

El mismo capítulo con la pregunta 5 en el centro: qué se conserva del OLS, qué deja de importar y qué aparece.

OLS con otros ojos

La misma fórmula, otro objetivo

El modelo y el estimador son los de Econometría I:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \arg \min_{\beta} \text{RSS}(\beta)$$

Lo que cambia es **para qué** lo usamos:

	Como econométristas	Como predictores
Nos importa	$\hat{\beta}_j$ y su error estándar	$\hat{y}_0 = x'_0 \hat{\beta}$ en datos nuevos
Elegimos variables	por teoría e identificación	por error de prueba
Variable “no significativa”	se discute	se queda si ayuda a predecir
Insensgamiento	lo que se defiende	negociable por menos varianza
Colinealidad	problema para $\hat{\beta}$	casi irrelevante para $\hat{y}$
La prueba del modelo	supuestos, R^2 , tests	el error en la prueba

Por qué empezar aquí

OLS aproxima la media condicional, es estable, se ajusta en milisegundos y se interpreta sin esfuerzo. Todo método del curso se compara contra él: si un bosque no le gana en la prueba, el bosque sobra.

Las cuatro preguntas de la regresión múltiple, reordenadas


ISL, sección 3.2.2: las mismas preguntas, otras respuestas

La pregunta de ISL	La respuesta clásica	La respuesta del predictor
1. ¿Sirve al menos un predictor?	la prueba F	el error en la prueba contra la referencia (la media)
2. ¿Todos los predictores o un subconjunto?	pruebas t , selección por p -valores	el error de validación (sesión 3); el Lasso lo decide solo
3. ¿Qué tan bien ajusta el modelo?	RSE y R^2 en la muestra	RMSE y R^2 de prueba
4. Dado x_0 , ¿qué predecir y con qué precisión?	$\hat{y}_0$ y dos intervalos	la pregunta del curso (siguiente diapositiva)

- ISL lo dice con todas las letras (p. 80): al añadir una variable el RSS *siempre* baja en el entrenamiento, “no necesariamente en la prueba”; por eso el R^2 en muestra siempre sube.
- Hoy: de una variable a nueve, el R^2 en muestra sube de 0,64 a 0,69 y el RMSE de prueba se queda en 6,8. El estrato alto, junto a la educación superior, queda en $p = 0,09$: recibía el crédito de la variable con la que se correlaciona. Significativo no es predictivo, ni al revés.

Predecir la media o predecir un dato nuevo

Dos intervalos, y sólo uno se cierra con más datos (ISL, pp. 82–83)



Tres errores al predecir $y_0 = f(x_0) + \varepsilon_0$:

- 1 estimar $\hat{\beta}$ con una muestra: reducible, se achica con n ;
- 2 suponer que f es lineal: el sesgo del modelo;
- 3 ε_0 : irreducible, nadie lo predice.

El **intervalo de confianza** cubre la media $f(x_0)$ y sólo carga el primero. El **intervalo de predicción** cubre el voto de *este* puesto y carga además σ^2 : siempre más ancho.

Con los 257 puestos de entrenamiento, en un entorno con 10% de educación superior

Ancho del intervalo de confianza: 1,9 puntos; del de predicción: 29,0. Con sólo 65 puestos: 3,6 y 27,9. La banda azul se cierra con datos; la roja no se mueve. Es el techo de la sesión 1, y el intervalo que le importa a quien usa la predicción.

Predictores cualitativos e interacciones

Cualitativos: una variable con K categorías entra como $K - 1$ *dummies* (zona cabecera/rural, municipio, departamento). La codificación cambia los coeficientes y sus p-valores, **no** las predicciones; lo que importa es no dejar categorías con dos o tres observaciones.

Interacciones: el efecto de una variable depende de otra.

$$\text{voto} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{rural} + \beta_3 (\text{educ} \times \text{rural}) + \varepsilon$$

La educación superior mueve el voto distinto en la cabecera y en el campo (y, veremos, en Cali y en el Pacífico): sin la interacción, la recta se equivoca *sistemáticamente* en ambos.

- Regla jerárquica (ISL): si entra la interacción, entran los dos efectos principales, significativos o no.
- Son **perillas de flexibilidad**: cada una añade parámetros y baja el sesgo a costa de varianza. Con 17 variables y 33 departamentos son cientos de columnas: elegirlas a mano no escala. El Lasso (sesión 3) las filtra; los árboles (sesión 5) las descubren solos.
- **Regla práctica**: añadan las que la economía sugiera (educación $\times$ región, edad $\times$ zona) y dejen que la **prueba** diga si valieron la pena.

Transformaciones: el logaritmo y los polinomios

Log de y : con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el error se reporta en la escala que le importa al usuario (pesos, no logaritmos). Nuestra y es una proporción: la recta puede predecir fuera de 0–100 (lo veremos al extrapolar).

Polinomios: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d + \varepsilon$ sigue siendo **lineal en los parámetros**: es OLS sobre nuevas columnas.

- El grado d es la perilla de complejidad de la sesión 1. Hoy, la cúbica y el grado 12 predicen igual que la recta (RMSE de prueba 6,9 contra 6,8): la relación es lineal y la flexibilidad no compra nada.
- Un polinomio es **global**: para curvar la relación en los entornos de baja educación, cambia también su forma en los de alta. Y fuera del rango de los datos, explota.

Transformaciones: el logaritmo y los polinomios

Log de y : con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el error se reporta en la escala que le importa al usuario (pesos, no logaritmos). Nuestra y es una proporción: la recta puede predecir fuera de 0–100 (lo veremos al extrapolar).

Polinomios: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d + \varepsilon$ sigue siendo **lineal en los parámetros**: es OLS sobre nuevas columnas.


- El grado d es la perilla de complejidad de la sesión 1. Hoy, la cúbica y el grado 12 predicen igual que la recta (RMSE de prueba 6,9 contra 6,8): la relación es lineal y la flexibilidad no compra nada.
- Un polinomio es **global**: para curvar la relación en los entornos de baja educación, cambia también su forma en los de alta. Y fuera del rango de los datos, explota.

Lo que queremos

Flexibilidad **local**: que la forma de la relación en una zona de x no obligue a nada en otra. Eso es lo que dan los escalones y los *splines*.

Más allá de la linealidad, en una diapositiva

Escalones, *splines* y modelos aditivos: la escalera que sigue siendo OLS (ISL, cap. 7)



- **Escalones:** cortar x en tramos y ajustar una constante por tramo (*dummies* de rango). Fácil de leer, feo en los bordes.
- **Spline cúbico:** un polinomio de grado 3 por tramo, obligado a empalmar suavemente en los **nodos**. Sigue siendo OLS sobre una *base* de columnas construidas a partir de x (apéndice A2); la perilla es el número de nodos; los *splines naturales* son lineales en las colas.
- **GAM:** $y = \beta_0 + f_1(x_1) + \dots + f_p(x_p) + \varepsilon$, un *spline* por variable, sumados. Flexible donde importa y legible variable por variable (esa figura vuelve en la sesión 6 como dependencia parcial); su límite es que no descubre interacciones.

Los seis problemas de la regresión, releídos para predecir

ISL, sección 3.3.3: lo que dañan en $\hat{\beta}$ y lo que dañan en $\hat{y}$

Problema	Qué daña en $\hat{\beta}$	¿Y para $\hat{y}$?
No linealidad	todo lo que dicen los co-eficientes	Sí , el único que ISL nombra: variables nuevas o métodos flexibles
Errores correlacionados	errores estándar subestimados	El punto no cambia; se daña la validación : puestos del mismo municipio se parecen (sesión 3)
Varianza no constante	errores estándar y pruebas	Los intervalos de predicción, no el punto
Atípicos	el RSE y todo lo que depende de él	La recta casi no se mueve; dañan las métricas y avisan de un predictor que falta
Alto apalancamiento	un par de puntos mueve el ajuste	Sí : se mueven todas las predicciones (“un dato nuevo cambia la curva”)
Colinealidad	errores estándar enormes, t que se hundan	Casi nada : quitar la variable colineal deja el ajuste intacto (ISL, p. 103); Ridge la convierte en ventaja (sesión 3)


En alta dimensión (ISL, sección 6.4.4)

Nunca se sabe qué variables son “las verdaderas”: otro subconjunto predice igual de bien. El modelo sirve; leerlo como si fuera único, no.

k -NN de regresión: el promedio de los vecinos

El método no paramétrico más simple: para predecir en x_0 , promediar la y de las k observaciones **más cercanas**:

$$\hat{f}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i$$



- **Sin fórmula**: la forma la ponen los datos. La perilla es k : $k = 1$ memoriza (varianza), $k = n$ predice la media (sesgo).
- Necesita una **distancia** (estandarizar las x). Hoy es la del **mapa**: los vecinos son los puestos más cercanos; el modelo no sabe nada de educación. En la sesión 4 vota; hoy promedia.

La maldición de la dimensionalidad

Por qué “los vecinos” dejan de ser vecinos

Con predictores uniformes en $[0, 1]^p$, ¿qué fracción del rango de *cada* variable hay que abarcar para capturar el 10% de los datos como vecinos?

p	1	2	5	10	100
Lado del “vecindario” $(0,1^{1/p})$	0,10	0,32	0,63	0,79	0,98

- Con $p = 10$, el “vecindario” que reúne el 10% de los datos cubre el 79% del rango de cada variable: los vecinos ya no se parecen a x_0 en nada. El promedio local se vuelve un promedio *global* y el sesgo explota.
- Los métodos que dependen de distancias (k -NN, kernels) sufren esto de frente; los lineales, los *splines* aditivos y los árboles lo esquivan porque **imponen estructura**.

Lección

Flexibilidad total sólo es gratis con pocas variables y muchos datos. En alta dimensión, algo de *estructura* (linealidad, aditividad, particiones) es lo que permite aprender. Ese es el argumento de fondo de las sesiones 3 y 5.

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5: la única del capítulo con el error de prueba en los ejes

- Si f es (casi) lineal, **OLS gana**: estima dos números; k -NN gasta los datos en dibujar una forma que no necesitaba. Si f es no lineal y p es pequeño, **k -NN puede ganar**.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado** (ISL, Fig. 3.20: gana k -NN con $p = 1$ o 2, empatan con 3, gana la recta desde 4). Pocas observaciones por predictor favorecen al paramétrico; si empatan, ISL prefiere la recta.
- **Hoy**: la recta con una buena variable, 6,8; los vecinos del mapa, 8,2. Con 257 puestos, la educación vale más que la ubicación (en la sesión 3, con el país, la cuenta cambia).

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5: la única del capítulo con el error de prueba en los ejes

- Si f es (casi) lineal, **OLS gana**: estima dos números; k -NN gasta los datos en dibujar una forma que no necesitaba. Si f es no lineal y p es pequeño, **k -NN puede ganar**.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado** (ISL, Fig. 3.20: gana k -NN con $p = 1$ o 2, empatan con 3, gana la recta desde 4). Pocas observaciones por predictor favorecen al paramétrico; si empatan, ISL prefiere la recta.
- **Hoy**: la recta con una buena variable, 6,8; los vecinos del mapa, 8,2. Con 257 puestos, la educación vale más que la ubicación (en la sesión 3, con el país, la cuenta cambia).

La regla de comparación del curso

Nunca se sabe a priori. Se ajustan los dos en el mismo conjunto de entrenamiento, se evalúan en el *mismo* conjunto de prueba con la *misma* métrica, y gana el que gana. Esa tabla comparativa es el producto central de cada aplicación del curso. El k se elige sin tocar la prueba: sesión 3.

1 La regresión lineal como máquina de predecir

2 Cómo evaluar una predicción de regresión

3 Aplicación guiada

4 Cierre

Las métricas: el error de prueba tiene muchas caras

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t} \sum (y_i - \hat{y}_i)^2$ / $\sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y ; castiga los errores grandes
MAE	$\frac{1}{n_t} \sum y_i - \hat{y}_i $	robusta a extremos; el “error típico”
MAPE	$\frac{100}{n_t} \sum y_i - \hat{y}_i / y_i $	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y}_{\text{train}})^2$	fracción del error de la media que el modelo evita; puede ser negativo

Las métricas: el error de prueba tiene muchas caras

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t} \sum (y_i - \hat{y}_i)^2$ / $\sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y ; castiga los errores grandes
MAE	$\frac{1}{n_t} \sum y_i - \hat{y}_i $	robusta a extremos; el “error típico”
MAPE	$\frac{100}{n_t} \sum y_i - \hat{y}_i / y_i $	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y}_{\text{train}})^2$	fracción del error de la media que el modelo evita; puede ser negativo

- El RMSE en puntos no dice nada solo: se lee **relativo** a y . La recta de hoy: 6,8 puntos sobre un voto que promedia 69 y se dispersa 12; un 10% del voto, poco más de la mitad del error de la media.
- $\text{RMSE} \geq \text{MAE}$ siempre; una brecha grande delata **pocos errores muy grandes**. La recta: 6,8 y 5,4; k -NN con $k = 1$: 8,9 y 6,8, la brecha más ancha de la tabla.
- Reporten siempre **más de una**: cada métrica cuenta una parte de la historia.

R^2 de prueba no es el R^2 de Econometría

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el grado 12 tenía el R^2 más alto de los tres.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra una referencia explícita: predecir $\bar{y}_{\text{train}}$ para todos.

R^2 de prueba no es el R^2 de Econometría

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el grado 12 tenía el R^2 más alto de los tres.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra una referencia explícita: predecir $\bar{y}_{\text{train}}$ para todos.

Cómo leerlo, con los puestos

La recta: R^2 de prueba = 0,62: sobre puestos que nunca vio, su error cuadrático es el 38% del de quien predice el promedio; $k = 1$ evita sólo el 35%. Y puede ser negativo: el grado 12 de la sesión 1 dio $-0,90$ en los avisos nuevos, peor que la media. Es una *reducción de error*, no una “bondad de ajuste”.

Un detalle que separa a los cuidadosos: el denominador usa $\bar{y}$ de **entrenamiento**, y las métricas se calculan **una sola vez** sobre la prueba.

Siempre contra una referencia (*baseline*)


Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

- 1 **La media** (o la mediana): el modelo que no usa x . Si no le ganan, no hay señal aprendible. Hoy: predecir 69% para todos da un RMSE de 11,0; la recta, 6,8.
- 2 **El modelo simple**: OLS con las variables obvias; todo lo demás debe justificar su complejidad frente a él. La recta de hoy es ese modelo.
- 3 **La regla vigente**: el avalúo catastral, el Sisbén, el pronóstico del analista. Para una campaña, *lo que pasó la vez anterior*: el voto de 2018 en el mismo puesto. Tal cual, 14,1 (Petro creció 11 puntos); con una recta que corrige el nivel, 8,4; la recta con la educación en esos 319 puestos, 7,2. Hay que predecir mejor que lo que ya se usa.

Cómo se reporta

Una tabla con una fila por modelo y una columna por métrica, todas calculadas en la *misma* prueba, con la referencia en la primera fila. Sin esa fila, “RMSE 6,8” no se puede leer. La construimos hoy y la heredamos cada semana.

Predicho vs. observado: la figura que nunca falta



- Cada punto es una observación de **prueba**; la diagonal es la predicción perfecta.
- El patrón típico: **pendiente menor que uno**. Se **sobrepredice** en la cola baja y se **subpredice** en la alta: las predicciones se *comprimen* hacia la media.
- Es la primera figura del reporte de cada aplicación: una por modelo, sobre la misma prueba.

Qué buscar en la figura

Curvatura (no linealidad omitida), abanico (varianza que crece con y), grupos desplazados y puntos aislados (errores grandes). El R^2 resume; la figura explica.

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :


$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

- Aun el predictor **perfecto** f es menos disperso que Y : el ruido ε está en y pero no en $\hat{y}$. Las observaciones extremas lo son en parte por ε , que nadie puede predecir.
- Un modelo bien calibrado cumple $\mathbb{E}[Y | \hat{y}] = \hat{y}$: la regresión de y sobre $\hat{y}$ tiene pendiente 1. La compresión aparece al mirar la figura “al revés” ($\hat{y}$ contra y), que es como solemos dibujarla (la cuenta, en el apéndice).
- Un modelo **sobreajustado** rompe la regla: sus $\hat{y}$ son *más* dispersas de lo que la señal justifica, y la pendiente de y sobre $\hat{y}$ cae por debajo de 1.

Consecuencia práctica

Una compresión moderada es normal; la pregunta útil es *cuánto* error queda en las colas y si un modelo más flexible lo reduce. De eso trata la siguiente diapositiva.

Dónde se concentra el error (I): por cuantiles de y



- Calculen el RMSE **por decil** (o quintil) de y en la prueba. La U es la huella de la compresión: el modelo falla más en los extremos.
- Hoy, por quintiles: 9,8 abajo (puestos que votan 54%), 5,0, 4,3 y 4,7 en el centro, 8,3 arriba (84%). Los casi unánimes son *justo* los que una campaña quiere reconocer.
- Los avalúos automáticos reportan el R^2 por cuartil de precio por lo mismo: la métrica agregada esconde las colas.

Dos remedios que veremos

Más flexibilidad donde la relación se curva (sesión 5) y, a veces, otra pérdida: si errar en la cola alta cuesta más, el MSE simétrico no es el objetivo.

Dónde se concentra el error (II): por subgrupos y en el mapa


La misma pregunta, cortando por **quién** y por **dónde**:

- **Por subgrupo:** RMSE por municipio, por zona (cabecera o rural), por estrato del entorno. Un modelo con buen RMSE global que falla sistemáticamente en un grupo es un problema de **equidad** además de precisión (sesiones 4 y 6).
- **En el mapa:** hoy pintamos los residuos de la recta sobre Cali. Manchas de un mismo signo delatan variables omitidas de la localización, y anticipan por qué la validación cruzada aleatoria engaña con datos espaciales (sesión 3).
- **Los residuos como diagnóstico:** si un método flexible logra predecir los residuos de su modelo, el modelo dejó estructura por fuera: tiene sesgo. Es una prueba barata antes de complicar la especificación.

La costumbre que vale la pena adquirir


Después de la tabla de métricas, tres figuras: predicho vs. observado, error por decil de y , y error por el subgrupo (o el mapa) que le importa a la pregunta.

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; *k*-NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola “razonablemente” sólo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar. Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; *k*-NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola “razonablemente” sólo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar. Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Regla

Reporten el **rango** de los predictores en el entrenamiento y marquen las predicciones fuera de él: un modelo entrenado con entornos de 0 a 58% de educación superior no sabe nada de uno con 80% (hoy: la recta dice 20, la cúbica -31 y el grado 12, 640.981).

1 La regresión lineal como máquina de predecir

2 Cómo evaluar una predicción de regresión

3 Aplicación guiada

4 Cierre

Aplicación guiada (I): una recta para Cali y su área metropolitana

343 puestos de Cali, Palmira, Yumbo y Jamundí; 257 para aprender y 86 bajo llave (applications/week-02)

- **La y:** el voto por Petro promedia 69,6% y se dispersa 11,7 puntos: de Pance La Viga (15%) a La Meseta, en Jamundí (94%).
- **La recta:** $\widehat{\text{voto}} = 79,7 - 0,75 \times \text{educación superior}$. $R^2 = 0,64$; RMSE 7,3 dentro y 6,8 en la prueba.
- **Las dos bandas**, en un entorno con 10% de educación superior: confianza 1,9 puntos, predicción 29,0; con 65 puestos, 3,6 y 27,9.
- **Nueve variables** (estratos, edad, mujeres, afro, servicios, tamaño): R^2 0,69, RMSE de prueba 6,8. Con $p < 0,05$ sólo la educación ($-0,44$), la población afro ($+0,11$) y los mayores de 60 ($-0,55$).
- **k-NN en el mapa**, sin censo: $k = 1$ memoriza (dentro 0, fuera 8,9); $k = 5$, 8,2; $k = 25$, 8,6.

Lo que hay que ver

La incertidumbre del coeficiente desaparece con datos; la del voto de *este* puesto no. Y una perilla nueva, k , que hoy giramos a ojo.

Aplicación guiada (II): la tabla canónica con los puestos

Ocho modelos, la misma prueba (86 puestos), tres métricas y una referencia

Modelo	RMSE dentro	RMSE prueba	MAE prueba	R^2 prueba
M0: media del entrenamiento (69,1)	12,2	11,0	8,9	0,00
M1: recta (educación superior)	7,3	6,8	5,4	0,62
M3: cúbica	7,1	6,9	5,5	0,61
M12: grado 12	7,0	6,9	5,5	0,61
M9: nueve variables	6,8	6,8	5,1	0,63
k -NN en el mapa, $k = 1$	0,0	8,9	6,8	0,35
k -NN en el mapa, $k = 5$	6,4	8,2	6,2	0,44
k -NN en el mapa, $k = 25$	9,7	8,6	6,8	0,39

- La primera fila es la referencia: sin ella, “6,8” no dice nada. La recta evita el 62% del error de la media; ocho variables más, la cúbica y el grado 12 no añaden nada en la prueba.
- $k = 1$: el menor error **dentro**, el peor **fuera** (regla de oro #1). Y los vecinos pierden contra la recta: la educación vale más que la ubicación.
- **La regla vigente** (el voto de 2018 en el mismo puesto, corregido con una recta): 8,4. El censo le gana al pasado.
- **Extrapolar** a 80% de educación superior (el entrenamiento llega a 58): la recta dice 20, la cúbica -31, el grado 12, 640.981. Ninguno sabe; sólo uno lo disimula.

Aplicación guiada (III): la recta no viaja

La misma recta, estimada en el área metropolitana, aplicada al resto del Valle del Cauca

Puestos	<i>n</i>	Voto real	Voto predicho	RMSE recta	Desv. de <i>y</i>
Área metropolitana (prueba)	86	69,6	69,5	6,8	11,7
Resto del Valle, cabeceras	169	58,3	71,5	21,2	16,1
Resto del Valle, rural	465	52,4	77,9	33,9	21,8
Buenaventura	83	91,4	75,4	17,6	8,1

- Fuera de las cuatro ciudades la recta predice **peor que la media local**: en el campo dice 78 donde la realidad es 52; en Buenaventura, 75 donde es 91. Las nueve variables mejoran poco (31,8 y 11,1).
- No es ruido: la relación cambia. Baja educación en Cali es un barrio popular que vota Petro; en el norte del Valle, un corregimiento cafetero que no. En el país, la recta con la educación explica el **0,04%** del voto: Santander vota 20% y Chocó 86% con la misma educación.
- **Con la vivienda de Cali**: la misma tabla canónica es la Parte 1 del Problem Set 1.

La limitación que nos lleva a la sesión 3

Necesitamos todo el país y muchas más variables (regiones, interacciones, todos los bloques). Con cientos de columnas, ¿cómo elegimos sin engañarnos, y cómo validamos cuando los puestos vecinos se parecen?

1 La regresión lineal como máquina de predecir

2 Cómo evaluar una predicción de regresión

3 Aplicación guiada

4 Cierre

Recap

- ➊ **OLS como máquina de predecir:** mismas fórmulas, otro criterio. Las cuatro preguntas de ISL cambian de respuesta: la señal se prueba fuera de muestra contra una referencia, las variables se eligen por validación, el ajuste se mide en la prueba. La colinealidad deja de asustar.
- ➋ **Predecir la media no es predecir un dato nuevo:** el intervalo de confianza se cierra con datos, el de predicción carga σ^2 y no. Ese es el techo.
- ➌ **Flexibilidad controlada:** interacciones, polinomios, escalones, *splines* y GAM bajan el sesgo y conservan la lectura; k -NN quita la fórmula y paga con varianza y con la **maldición de la dimensionalidad**. Su k se elige en la sesión 3.
- ➍ **Métricas:** RMSE, MAE, MAPE y R^2 de prueba (que puede ser negativo); siempre más de una, siempre relativas a y , siempre contra una referencia.
- ➎ **El reporte estándar:** tabla en la misma prueba + tres figuras (predicho vs. observado, error por decil, error por subgrupo o mapa), y marcar la extrapolación. La compresión hacia la media es normal; lo que importa es cuánto error queda en las colas.

La tabla del líder

Una fila por modelo, la misma prueba; se hereda y se actualiza cada semana

Semana	Modelo	Predictores	RMSE prueba
2	Media del entrenamiento	ninguno	11,0
2	Regla vigente: el voto de 2018, corregido	el pasado del puesto	8,4
2	k -NN en el mapa ($k = 5$)	la ubicación	8,2
2	Recta	educación superior	6,8
2	Regresión múltiple	nueve variables del entorno	6,8

Hoy la prueba son 86 puestos del área metropolitana de Cali. Desde la sesión 3 la tabla es **nacional**: 12.001 puestos y una partición fija (80/20, estratificada por departamento) que ningún modelo vuelve a mirar hasta anotar su resultado final. La advertencia de hoy queda registrada: fuera de las cuatro ciudades, la recta no viaja.

La sesión 8: un paper por área de la economía. Elijan la suya hoy

3 de noviembre: seis presentaciones de 15 minutos, seis áreas distintas

Área	Opción A	Opción B
Economía política	Kim & Zilinsky (2024, <i>Pol. Behavior</i>): demografía y voto	Bazzi et al. (2022, <i>REStat</i>): predecir el conflicto en Colombia
Crimen y justicia	Kleinberg et al. (2018, <i>QJE</i>): el riesgo de fuga y los jueces	Angelova, Dobbie & Yang (2026, <i>REStud</i>): algoritmo y jueces
Salud	Mullainathan & Obermeyer (2022, <i>QJE</i>): el error del médico	Einav et al. (2018, <i>Science</i>): el gasto al final de la vida
Desarrollo y pobreza	Aiken et al. (2023, <i>JDE</i>): focalizar con datos de celular	Haushofer et al. (2025, <i>AER</i>): focalizar por impacto o privación
Trabajo	Hoffman, Kahn & Li (2018, <i>QJE</i>): pruebas de contratación o discreción	Chalfin et al. (2016, <i>AER P&P</i>): elegir docentes y policías
Finanzas y crédito	Fuster et al. (2022, <i>J. Finance</i>): ML y desigualdad en el crédito	Dobbie et al. (2021, <i>REStud</i>): el sesgo en los préstamos
Macroeconomía	Medeiros et al. (2021, <i>JBES</i>): pronosticar la inflación	Goulet Coulombe et al. (2022, <i>JAE</i>): cuándo ayuda el ML
Organización industrial	Dubé & Misra (2023, <i>JPE</i>): precios personalizados	Bandiera et al. (2020, <i>JPE</i>): qué hacen los CEO

El guion: la pregunta y la decisión; los datos y la unidad; la referencia; la evaluación fuera de muestra y dónde falla; el resultado; qué método del curso es. La biblioteca completa, por áreas, está en [literature/](#).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, sección 5.1 (validación cruzada) y secciones 6.2 y 6.4 (Ridge, Lasso y alta dimensión).

Guía: la figura 5.6 (la curva de CV) y las figuras 6.4 y 6.6 (los caminos de Ridge y Lasso) son las de clase.

Nivelación en R: seguir con los módulos de lectura y escritura de datos y de gestión de datos (enlaces en la sesión 1).

Próxima sesión — validación cruzada y regularización: elegir entre modelos sin gastar la prueba (k -fold, la curva de CV, el *pipeline* sin filtraciones, validar por grupos, en el tiempo y en el espacio) y qué hacer con muchos predictores (Ridge, Lasso y Elastic Net, con λ por CV). **Aplicación en R:** los 12.001 puestos del país, la “ficha larga” de cientos de columnas, un Lasso con λ por validación cruzada, validar por municipio y probar en el tiempo (2018 $\rightarrow$ 2022).

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 2–3 y 7. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Caps. 2–3 y 5. [ESL]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Working paper. [De donde salen los datos del caso.]
- Los dieciséis papers del menú de la sesión 8 están, con su ficha, en [literature/](#) (biblioteca por áreas de la economía).

5 Apéndice: para profundizar

A1. OLS en forma matricial y la media condicional

1. El problema: con $\mathbf{X}$ de $n \times (p + 1)$ (columna de unos incluida),

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

2. Condición de primer orden: $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \Rightarrow \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$, y si $\mathbf{X}'\mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad \hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \equiv \mathbf{H}\mathbf{y}.$$

3. Lectura predictiva: $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio generado por las columnas de $\mathbf{X}$: la mejor aproximación *lineal* a la media condicional. Si $\mathbb{E}[Y | X]$ es lineal, OLS la estima sin sesgo; si no, estima la mejor recta, y el sesgo que queda es el precio de la rigidez.

4. Por qué la colinealidad no asusta al predictor: $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ depende del *espacio* de las columnas, no de cómo se reparten los coeficientes entre columnas parecidas. Dos coeficientes inestables pueden sumar una predicción estable. (La varianza de $\hat{y}_0$ sí crece con p : esa es la varianza de la sesión 1.)

A2. La base de un *spline*: cómo se construyen las columnas

Polinomio cúbico por tramos con un nodo en ξ : dos cúbicas distintas a cada lado de ξ , unidas de modo que la función, su primera y su segunda derivada sean continuas en ξ .

La base de potencias truncadas lo logra con una sola columna extra:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x - \xi)_+^3 + \varepsilon, \quad (x - \xi)_+^3 = \max\{0, (x - \xi)^3\}.$$

Antes de ξ la columna vale cero; después añade una cúbica que arranca en cero con derivadas cero: el empalme es suave por construcción.

- Con K nodos: $K + 4$ columnas, es decir, $K + 4$ grados de libertad. Todo se estima por OLS.
- Un **spline natural** impone linealidad más allá de los nodos extremos y ahorra 4 grados de libertad: menos varianza en las colas, donde hay pocos datos.
- En R, `splines::ns(x, df = 4)` construye la base y se usa dentro de `lm()`. Los *B-splines* son otra base, numéricamente más estable, del mismo espacio.

A3. La cuenta de la compresión:

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2$$

1. Ley de la varianza total: para cualquier Y y X ,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

2. Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon | X] = 0$ **y** $\text{Var}(\varepsilon | X) = \sigma^2$: $\mathbb{E}[Y | X] = f(X)$ y $\text{Var}(Y | X) = \sigma^2$, luego

$$\text{Var}(Y) = \sigma^2 + \text{Var}(f(X)) \geq \text{Var}(f(X)).$$

3. Calibración y pendiente: si $\hat{y}$ está bien calibrado, $\mathbb{E}[Y | \hat{y}] = \hat{y}$, de modo que en la regresión de y sobre $\hat{y}$ la pendiente es 1 y el intercepto 0. La regresión *inversa*, de $\hat{y}$ sobre y , tiene pendiente $\text{Cov}(y, \hat{y})/\text{Var}(y) = \text{Var}(\hat{y})/\text{Var}(y) \leq 1$: esa es la compresión que se ve al dibujar $\hat{y}$ contra y .

Uso

La pendiente de y sobre $\hat{y}$ en la prueba es un test de calibración gratuito: por debajo de 1 hay sobreajuste (predicciones demasiado dispersas); por encima, subajuste. Vuelve en la sesión 4 para probabilidades.