

Big Data y Machine Learning para Economía Aplicada

Week 02: La regresión lineal como máquina de predecir — y cómo
evaluar una predicción

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 9, 2026

Previously...

- **Y, no β** : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).

Previously...

- Y , **no** β : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).
- El objetivo es el **riesgo de generalización**; el mejor predictor cuadrático es la media condicional $f(x) = \mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.

Previously...

- Y , **no** β : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).
- El objetivo es el **riesgo de generalización**; el mejor predictor cuadrático es la media condicional $f(x) = \mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro**: #1 el error de entrenamiento es optimista; #2 el conjunto de prueba se usa al final y una sola vez.

Previously...

- Y , **no** β : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).
- El objetivo es el **riesgo de generalización**; el mejor predictor cuadrático es la media condicional $f(x) = \mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro**: #1 el error de entrenamiento es optimista; #2 el conjunto de prueba se usa al final y una sola vez.
- $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$: la complejidad baja el sesgo y sube la varianza; el óptimo es interior (la curva U).

Previously...

- Y , **no** β : predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).
- El objetivo es el **riesgo de generalización**; el mejor predictor cuadrático es la media condicional $f(x) = \mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro**: #1 el error de entrenamiento es optimista; #2 el conjunto de prueba se usa al final y una sola vez.
- $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$: la complejidad baja el sesgo y sube la varianza; el óptimo es interior (la curva U).
- Dejamos abierta una pregunta: ¿cuánto de una elección anticipa una **recta**, y *dónde* se equivoca?

Previously...

- **Y, no β :** predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción (Kim & Zilinsky).
- El objetivo es el **riesgo de generalización**; el mejor predictor cuadrático es la media condicional $f(x) = \mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 el conjunto de prueba se usa al final y una sola vez.
- $\text{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$: la complejidad baja el sesgo y sube la varianza; el óptimo es interior (la curva U).
- Dejamos abierta una pregunta: ¿cuánto de una elección anticipa una **recta**, y *dónde* se equivoca?

Hoy

Convertimos la regresión que ya conocen en una **máquina de predecir**, le añadimos algo de flexibilidad y, sobre todo, aprendemos a **evaluar** una predicción de regresión: con qué métricas, contra qué baseline, con qué gráficos y dónde mirar los errores.

Presentación estudiantil: Kim & Zilinsky (2024)

Quince minutos, tres preguntas

- 1 **¿Qué se predice y por qué importa?** El voto presidencial y la identificación partidista en EE.UU. (ANES 1952–2020) usando *solo* demografía: la capacidad predictiva como medida del *sorting* social.
- 2 **¿Con qué datos y método, y cómo se evalúa?** *Random forests* y logit por ola, partición 80/20, tuning por validación cruzada; accuracy, AUC y F1 fuera de muestra, con intervalos de confianza y una regresión de la accuracy sobre el año.
- 3 **¿Qué se encuentra y cómo se interpreta?** Cerca del 64% de acierto, estable en 70 años, con efectos marginales crecientes: el argumento de que la asociación y la predictibilidad conjunta son cosas distintas.

Presentación estudiantil: Kim & Zilinsky (2024)

Quince minutos, tres preguntas

- ❶ **¿Qué se predice y por qué importa?** El voto presidencial y la identificación partidista en EE.UU. (ANES 1952–2020) usando *solo* demografía: la capacidad predictiva como medida del *sorting* social.
- ❷ **¿Con qué datos y método, y cómo se evalúa?** *Random forests* y logit por ola, partición 80/20, tuning por validación cruzada; accuracy, AUC y F1 fuera de muestra, con intervalos de confianza y una regresión de la accuracy sobre el año.
- ❸ **¿Qué se encuentra y cómo se interpreta?** Cerca del 64% de acierto, estable en 70 años, con efectos marginales crecientes: el argumento de que la asociación y la predictibilidad conjunta son cosas distintas.

Para el resto de la sala

Mientras escuchan, anoten: ¿qué baseline usan los autores para decir que 64% es “poco”? ¿Por qué la AUC sube y la accuracy no? Volveremos sobre ambas preguntas hoy y en la sesión 3.

- 1 La regresión lineal como máquina de predecir
- 2 Cómo evaluar una predicción de regresión
- 3 Aplicación guiada: precios de vivienda en Bogotá
- 4 Cierre

OLS con otros ojos

La misma fórmula, otro objetivo

El modelo y el estimador son los de Econometría I:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \arg \min_{\beta} \text{RSS}(\beta)$$

OLS con otros ojos

La misma fórmula, otro objetivo

El modelo y el estimador son los de Econometría I:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \arg \min_{\beta} \text{RSS}(\beta)$$

Lo que cambia es **para qué** lo usamos:

	Como econométristas	Como predictores
Nos importa	$\hat{\beta}_j$ y su error estándar	$\hat{y}_0 = x'_0 \hat{\beta}$ en datos nuevos
Elegimos variables	por teoría e identificación	por error de prueba
Variable “no significativa”	se discute	se queda si ayuda a predecir
Colinealidad	problema para $\hat{\beta}$	casi irrelevante para $\hat{y}$
La prueba del modelo	supuestos, R^2 , tests	RMSE en la prueba

OLS con otros ojos

La misma fórmula, otro objetivo

El modelo y el estimador son los de Econometría I:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \arg \min_{\beta} \text{RSS}(\beta)$$

Lo que cambia es **para qué** lo usamos:

	Como econométristas	Como predictores
Nos importa	$\hat{\beta}_j$ y su error estándar	$\hat{y}_0 = x'_0 \hat{\beta}$ en datos nuevos
Elegimos variables	por teoría e identificación	por error de prueba
Variable “no significativa”	se discute	se queda si ayuda a predecir
Colinealidad	problema para $\hat{\beta}$	casi irrelevante para $\hat{y}$
La prueba del modelo	supuestos, R^2 , tests	RMSE en la prueba

Por qué empezar aquí

OLS aproxima la media condicional, es estable, se ajusta en milisegundos y se interpreta sin esfuerzo. Todo método del curso se compara contra él: si un bosque no le gana en la prueba, el bosque sobra.

Predictores cualitativos e interacciones

Cualitativos: una variable con K categorías entra como $K - 1$ *dummies* (estrato, localidad, tipo de inmueble). Para predecir no importa cuál es la base; importa no dejar categorías con dos o tres observaciones.

Predictores cualitativos e interacciones

Cualitativos: una variable con K categorías entra como $K - 1$ *dummies* (estrato, localidad, tipo de inmueble). Para predecir no importa cuál es la base; importa no dejar categorías con dos o tres observaciones. **Interacciones:** el efecto de una variable depende de otra.

$$\text{precio} = \beta_0 + \beta_1 \text{área} + \beta_2 \text{estrato} + \beta_3 (\text{área} \times \text{estrato}) + \varepsilon$$

El metro cuadrado vale distinto en estrato 6 que en estrato 2: sin la interacción, la recta se equivoca *sistemáticamente* en ambos extremos.

Predictores cualitativos e interacciones

Cualitativos: una variable con K categorías entra como $K - 1$ *dummies* (estrato, localidad, tipo de inmueble). Para predecir no importa cuál es la base; importa no dejar categorías con dos o tres observaciones. **Interacciones:** el efecto de una variable depende de otra.

$$\text{precio} = \beta_0 + \beta_1 \text{área} + \beta_2 \text{estrato} + \beta_3 (\text{área} \times \text{estrato}) + \varepsilon$$

El metro cuadrado vale distinto en estrato 6 que en estrato 2: sin la interacción, la recta se equivoca *sistemáticamente* en ambos extremos.

- En un modelo predictivo las interacciones son **perillas de flexibilidad**: cada una añade parámetros y baja el sesgo a costa de varianza.
- Con p variables hay $p(p - 1)/2$ interacciones de segundo orden: elegir las a mano no escala. Los árboles (sesión 6) las descubren solos; el Lasso (sesión 5) las filtra.

Predictores cualitativos e interacciones

Cualitativos: una variable con K categorías entra como $K - 1$ *dummies* (estrato, localidad, tipo de inmueble). Para predecir no importa cuál es la base; importa no dejar categorías con dos o tres observaciones. **Interacciones:** el efecto de una variable depende de otra.

$$\text{precio} = \beta_0 + \beta_1 \text{área} + \beta_2 \text{estrato} + \beta_3 (\text{área} \times \text{estrato}) + \varepsilon$$

El metro cuadrado vale distinto en estrato 6 que en estrato 2: sin la interacción, la recta se equivoca *sistemáticamente* en ambos extremos.

- En un modelo predictivo las interacciones son **perillas de flexibilidad**: cada una añade parámetros y baja el sesgo a costa de varianza.
- Con p variables hay $p(p - 1)/2$ interacciones de segundo orden: elegir las a mano no escala. Los árboles (sesión 6) las descubren solos; el Lasso (sesión 5) las filtra.

Regla práctica

Añadan interacciones cuando la economía las sugiera (precio $\times$ ubicación, edad $\times$ educación) y dejen que la **prueba** diga si valieron la pena.

Transformaciones: el logaritmo y los polinomios

Log de y : con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el RMSE se reporta en la escala que le importa al usuario.

Transformaciones: el logaritmo y los polinomios

Log de y : con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el RMSE se reporta en la escala que le importa al usuario.

Polinomios: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d + \varepsilon$ sigue siendo **lineal en los parámetros**: es OLS sobre nuevas columnas.

- El grado d es la perilla de complejidad de la sesión 1: $d = 1$ subajusta, $d = 15$ memoriza.
- Un polinomio es **global**: para curvar la relación en el rango de precios bajos, cambia también su forma en los precios altos. Y fuera del rango de los datos, explota.

Transformaciones: el logaritmo y los polinomios

Log de y : con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el RMSE se reporta en la escala que le importa al usuario.


Polinomios: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d + \varepsilon$ sigue siendo **lineal en los parámetros**: es OLS sobre nuevas columnas.

- El grado d es la perilla de complejidad de la sesión 1: $d = 1$ subajusta, $d = 15$ memoriza.
- Un polinomio es **global**: para curvar la relación en el rango de precios bajos, cambia también su forma en los precios altos. Y fuera del rango de los datos, explota.


Lo que queremos

Flexibilidad **local**: que la forma de la relación en una zona de x no obligue a nada en otra. Eso es lo que dan los escalones y los *splines*.

Más allá de la linealidad (I): escalones y *splines*




Más allá de la linealidad (I): escalones y *splines*



- **Escalones:** cortar x en tramos y ajustar una constante por tramo (*dummies* de rango). Fácil de leer, feo en los bordes.
- **Spline cúbico:** un polinomio de grado 3 por tramo, obligado a empalmar suavemente en los **nodos**. Sigue siendo OLS sobre una *base* de columnas construidas de x (la construcción, en el apéndice).

Más allá de la linealidad (I): escalones y *splines*



- **Escalones:** cortar x en tramos y ajustar una constante por tramo (*dummies* de rango). Fácil de leer, feo en los bordes.
- **Spline cúbico:** un polinomio de grado 3 por tramo, obligado a empalmar suavemente en los **nodos**. Sigue siendo OLS sobre una *base* de columnas construidas de x (la construcción, en el apéndice).
- La perilla de complejidad es el **número de nodos** (o grados de libertad); ISL recomienda nodos en cuantiles de x y *splines naturales* (lineales en los extremos) para no explotar en las colas.

Más allá de la linealidad (II): modelos aditivos generalizados

Un **GAM** aplica la idea variable por variable y luego suma:

$$y = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_p(x_p) + \varepsilon,$$

con cada f_j un *spline* (o un escalón, o una recta).

Más allá de la linealidad (II): modelos aditivos generalizados

Un **GAM** aplica la idea variable por variable y luego suma:

$$y = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_p(x_p) + \varepsilon,$$

con cada f_j un *spline* (o un escalón, o una recta).

- **Flexible donde importa:** el precio puede subir con el área de forma cóncava y caer con la distancia al centro de forma convexa, sin que ustedes escriban la forma.
- **Interpretable:** cada f_j se grafica; es el “efecto marginal” no lineal de x_j . Esta figura reaparece en la sesión 7 con otro nombre (dependencia parcial).
- **Su límite:** es *aditivo*: no descubre interacciones salvo que se las escriban. Los árboles sí.

Más allá de la linealidad (II): modelos aditivos generalizados

Un **GAM** aplica la idea variable por variable y luego suma:

$$y = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_p(x_p) + \varepsilon,$$

con cada f_j un *spline* (o un escalón, o una recta).

- **Flexible donde importa:** el precio puede subir con el área de forma cóncava y caer con la distancia al centro de forma convexa, sin que ustedes escriban la forma.
- **Interpretable:** cada f_j se grafica; es el “efecto marginal” no lineal de x_j . Esta figura reaparece en la sesión 7 con otro nombre (dependencia parcial).
- **Su límite:** es *aditivo*: no descubre interacciones salvo que se las escriban. Los árboles sí.


Dónde estamos en el mapa flexibilidad–interpretabilidad

OLS $\rightarrow$ polinomios $\rightarrow$ *splines* $\rightarrow$ GAM es la escalera lineal: cada peldaño baja el sesgo y conserva la lectura. En la sesión 6 saltamos a otra escalera.

k -NN de regresión: el promedio de los vecinos

El método no paramétrico más simple: para predecir en x_0 , promediar la y de las k observaciones **más cercanas**:


$$\hat{f}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i$$



k -NN de regresión: el promedio de los vecinos

El método no paramétrico más simple: para predecir en x_0 , promediar la y de las k observaciones **más cercanas**:

$$\hat{f}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i$$



- **Sin fórmula:** la forma la ponen los datos. La perilla es k : $k = 1$ memoriza (varianza), $k = n$ predice la media (sesgo).
- Necesita una **distancia**: hay que estandarizar las x (un metro cuadrado no es un estrato).
- Vive en la sesión 3 como clasificador (votación de vecinos) y aquí como regresor (promedio de vecinos).

La maldición de la dimensionalidad

Por qué “los vecinos” dejan de ser vecinos

Con predictores uniformes en $[0, 1]^p$, ¿qué fracción del rango de *cada* variable hay que abarcar para capturar el 10% de los datos como vecinos?

p	1	2	5	10	100
Lado del “vecindario” $(0, 1^{1/p})$	0,10	0,32	0,63	0,79	0,98

La maldición de la dimensionalidad

Por qué “los vecinos” dejan de ser vecinos

Con predictores uniformes en $[0, 1]^p$, ¿qué fracción del rango de *cada* variable hay que abarcar para capturar el 10% de los datos como vecinos?

p	1	2	5	10	100
Lado del “vecindario” $(0, 1^{1/p})$	0,10	0,32	0,63	0,79	0,98

- Con $p = 10$, el “vecindario” que reúne el 10% de los datos cubre el 79% del rango de cada variable: los vecinos ya no se parecen a x_0 en nada. El promedio local se vuelve un promedio *global* y el sesgo explota.
- Los métodos que dependen de distancias (k -NN, kernels) sufren esto de frente; los lineales, los *splines* aditivos y los árboles lo esquivan porque **imponen estructura**.

La maldición de la dimensionalidad

Por qué “los vecinos” dejan de ser vecinos

Con predictores uniformes en $[0, 1]^p$, ¿qué fracción del rango de *cada* variable hay que abarcar para capturar el 10% de los datos como vecinos?

p	1	2	5	10	100
Lado del “vecindario” $(0,1^{1/p})$	0,10	0,32	0,63	0,79	0,98

- Con $p = 10$, el “vecindario” que reúne el 10% de los datos cubre el 79% del rango de cada variable: los vecinos ya no se parecen a x_0 en nada. El promedio local se vuelve un promedio *global* y el sesgo explota.
- Los métodos que dependen de distancias (k -NN, kernels) sufren esto de frente; los lineales, los *splines* aditivos y los árboles lo esquivan porque **imponen estructura**.

Lección

Flexibilidad total solo es gratis con pocas variables y muchos datos. En alta dimensión, algo de *estructura* (linealidad, aditividad, particiones) es lo que permite aprender. Ese es el argumento de fondo de las sesiones 5 y 6.

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5

- Si la verdadera f es (casi) lineal, **OLS gana**: usa los datos para estimar dos números, k -NN los gasta en dibujar una forma que no necesitaba.

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5

- Si la verdadera f es (casi) lineal, **OLS gana**: usa los datos para estimar dos números, k -NN los gasta en dibujar una forma que no necesitaba.
- Si f es claramente no lineal y p es pequeño, k -**NN puede ganar**: su sesgo es menor y la varianza extra se paga con datos.

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5

- Si la verdadera f es (casi) lineal, **OLS gana**: usa los datos para estimar dos números, k -NN los gasta en dibujar una forma que no necesitaba.
- Si f es claramente no lineal y p es pequeño, **k -NN puede ganar**: su sesgo es menor y la varianza extra se paga con datos.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado**: la maldición de la dimensionalidad castiga más a k -NN de lo que el sesgo castiga a la recta.

Lineal vs. k -NN: ¿cuándo gana cada uno?

ISL, sección 3.5

- Si la verdadera f es (casi) lineal, **OLS gana**: usa los datos para estimar dos números, k -NN los gasta en dibujar una forma que no necesitaba.
- Si f es claramente no lineal y p es pequeño, **k -NN puede ganar**: su sesgo es menor y la varianza extra se paga con datos.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado**: la maldición de la dimensionalidad castiga más a k -NN de lo que el sesgo castiga a la recta.

La regla de comparación del curso

Nunca se sabe a priori. Se ajustan los dos en el mismo conjunto de entrenamiento, se evalúan en el *mismo* conjunto de prueba con la *misma* métrica, y gana el que gana. Esa tabla comparativa es el producto central de cada aplicación del curso.

- 1 La regresión lineal como máquina de predecir
- 2 **Cómo evaluar una predicción de regresión**
- 3 Aplicación guiada: precios de vivienda en Bogotá
- 4 Cierre

El error de prueba tiene muchas caras

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t} \sum (y_i - \hat{y}_i)^2$ / $\sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y ; castiga los errores grandes
MAE	$\frac{1}{n_t} \sum y_i - \hat{y}_i $	robusta a extremos; el “error típico”
MAPE	$\frac{100}{n_t} \sum y_i - \hat{y}_i / y_i $	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y}_{\text{train}})^2$	varianza de prueba explicada; puede ser negativo

El error de prueba tiene muchas caras

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t} \sum (y_i - \hat{y}_i)^2$ / $\sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y ; castiga los errores grandes
MAE	$\frac{1}{n_t} \sum y_i - \hat{y}_i $	robusta a extremos; el “error típico”
MAPE	$\frac{100}{n_t} \sum y_i - \hat{y}_i / y_i $	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y}_{\text{train}})^2$	varianza de prueba explicada; puede ser negativo

- $\text{RMSE} \geq \text{MAE}$ siempre; una brecha grande entre ambos delata **pocos errores muy grandes** (colas).
- El RMSE en pesos no dice nada solo: se reporta **relativo** a la media o a la desviación estándar de y . En Gelvez et al. (2026), el RMSE del *vote share* es de 14,5 a 17,9 puntos, que equivale a entre 20% y 43% del promedio según la elección.

El error de prueba tiene muchas caras

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t} \sum (y_i - \hat{y}_i)^2$ / $\sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y ; castiga los errores grandes
MAE	$\frac{1}{n_t} \sum y_i - \hat{y}_i $	robusta a extremos; el “error típico”
MAPE	$\frac{100}{n_t} \sum y_i - \hat{y}_i / y_i $	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y}_{\text{train}})^2$	varianza de prueba explicada; puede ser negativo

- $\text{RMSE} \geq \text{MAE}$ siempre; una brecha grande entre ambos delata **pocos errores muy grandes** (colas).
- El RMSE en pesos no dice nada solo: se reporta **relativo** a la media o a la desviación estándar de y . En Gelvez et al. (2026), el RMSE del *vote share* es de 14,5 a 17,9 puntos, que equivale a entre 20% y 43% del promedio según la elección.
- Reporten siempre **más de una**: cada métrica cuenta una parte de la historia.

R^2 de prueba no es el R^2 de Econometría

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el polinomio de grado 15 tiene $R^2 = 1$.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra un baseline explícito: predecir $\bar{y}_{\text{train}}$ para todos.

R^2 de prueba no es el R^2 de Econometría

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el polinomio de grado 15 tiene $R^2 = 1$.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra un baseline explícito: predecir $\bar{y}_{\text{train}}$ para todos.

Cómo leerlo

“ R^2 de prueba = 0,66” significa: sobre mesas que el modelo nunca vio, el error cuadrático es un 34% del que cometería quien predijera el promedio para todas. Es una *reducción de error*, no una “bondad de ajuste”.

R^2 de prueba no es el R^2 de Econometría

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el polinomio de grado 15 tiene $R^2 = 1$.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra un baseline explícito: predecir $\bar{y}_{\text{train}}$ para todos.

Cómo leerlo

“ R^2 de prueba = 0,66” significa: sobre mesas que el modelo nunca vio, el error cuadrático es un 34% del que cometería quien predijera el promedio para todas. Es una *reducción de error*, no una “bondad de ajuste”.

Un detalle que separa a los cuidadosos: el denominador usa $\bar{y}$ de **entrenamiento** (lo único que el modelo pudo conocer), y las métricas se calculan **una sola vez** sobre la prueba.

Siempre contra un *baseline*

Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

Siempre contra un *baseline*

Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

- 1 **La media** (o la mediana): el modelo que no usa x . Si no le ganan, no hay señal aprendible con esas variables.

Siempre contra un *baseline*

Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

- 1 **La media** (o la mediana): el modelo que no usa x . Si no le ganan, no hay señal aprendible con esas variables.
- 2 **El modelo simple**: OLS con las variables obvias. Es lo que ya sabían hacer; todo lo demás debe justificar su complejidad frente a él.

Siempre contra un *baseline*

Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

- ❶ **La media** (o la mediana): el modelo que no usa x . Si no le ganan, no hay señal aprendible con esas variables.
- ❷ **El modelo simple**: OLS con las variables obvias. Es lo que ya sabían hacer; todo lo demás debe justificar su complejidad frente a él.
- ❸ **La regla vigente**: el avalúo del tasador, el puntaje del Sisbén, el pronóstico del analista. Muchos papers ganan aquí su interés: McBride & Nichols (2018) mejoran la focalización de pobreza entre 2 y 18 puntos frente a la regresión *stepwise* que usaban los programas.

Siempre contra un *baseline*


Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

- 1 **La media** (o la mediana): el modelo que no usa x . Si no le ganan, no hay señal aprendible con esas variables.
- 2 **El modelo simple**: OLS con las variables obvias. Es lo que ya sabían hacer; todo lo demás debe justificar su complejidad frente a él.
- 3 **La regla vigente**: el avalúo del tasador, el puntaje del Sisbén, el pronóstico del analista. Muchos papers ganan aquí su interés: McBride & Nichols (2018) mejoran la focalización de pobreza entre 2 y 18 puntos frente a la regresión *stepwise* que usaban los programas.

Cómo se ve en un paper


Una tabla con una fila por modelo y una columna por métrica, todas calculadas en la *misma* prueba. Kim & Zilinsky la usan para decir que 64% es poco: con partido político la accuracy sube mucho, y con un baseline de “predecir al ganador” el aporte de la demografía es menor de lo que parece.

Predicho vs. observado: la figura que nunca falta



- Cada punto es una observación de **prueba**; la diagonal es la predicción perfecta.
- El patrón típico: **pendiente menor que uno**. Se **sobrepredice** en la cola baja y se **subpredice** en la alta: las predicciones se *comprimen* hacia la media.
- Gelvez et al. (2026, Fig. 3) muestran esto para el *vote share*: más compresión en 2006 y 2010, menos en 2022.

Predicho vs. observado: la figura que nunca falta



- Cada punto es una observación de **prueba**; la diagonal es la predicción perfecta.
- El patrón típico: **pendiente menor que uno**. Se **sobrepredice** en la cola baja y se **subpredice** en la alta: las predicciones se *comprimen* hacia la media.
- Gelvez et al. (2026, Fig. 3) muestran esto para el *vote share*: más compresión en 2006 y 2010, menos en 2022.

Qué buscar en la figura

Curvatura (no linealidad omitida), abanico (varianza que crece con y), grupos desplazados y puntos aislados (errores grandes). El R^2 resume; la figura explica.

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

- Aun el predictor **perfecto** f es menos disperso que Y : el ruido ε está en y pero no en $\hat{y}$. Las observaciones extremas lo son en parte por ε , que nadie puede predecir.

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

- Aun el predictor **perfecto** f es menos disperso que Y : el ruido ε está en y pero no en $\hat{y}$. Las observaciones extremas lo son en parte por ε , que nadie puede predecir.
- Un modelo bien calibrado cumple $\mathbb{E}[Y \mid \hat{y}] = \hat{y}$: la regresión de y sobre $\hat{y}$ tiene pendiente 1. La compresión aparece al mirar la figura “al revés” ($\hat{y}$ contra y), que es como solemos dibujarla.

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \quad \implies \quad \text{Var}(f(X)) \leq \text{Var}(Y).$$

- Aun el predictor **perfecto** f es menos disperso que Y : el ruido ε está en y pero no en $\hat{y}$. Las observaciones extremas lo son en parte por ε , que nadie puede predecir.
- Un modelo bien calibrado cumple $\mathbb{E}[Y \mid \hat{y}] = \hat{y}$: la regresión de y sobre $\hat{y}$ tiene pendiente 1. La compresión aparece al mirar la figura “al revés” ($\hat{y}$ contra y), que es como solemos dibujarla.
- Un modelo **sobreajustado** rompe la regla: sus $\hat{y}$ son *más* dispersas que lo que la señal justifica, y la pendiente de y sobre $\hat{y}$ cae por debajo de 1.

¿Por qué se comprimen las predicciones?

No es un error del modelo: es lo que una media condicional *debe* hacer

Con $Y = f(X) + \varepsilon$ y ε independiente de X :


$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2 \implies \text{Var}(f(X)) \leq \text{Var}(Y).$$

- Aun el predictor **perfecto** f es menos disperso que Y : el ruido ε está en y pero no en $\hat{y}$. Las observaciones extremas lo son en parte por ε , que nadie puede predecir.
- Un modelo bien calibrado cumple $\mathbb{E}[Y | \hat{y}] = \hat{y}$: la regresión de y sobre $\hat{y}$ tiene pendiente 1. La compresión aparece al mirar la figura “al revés” ($\hat{y}$ contra y), que es como solemos dibujarla.
- Un modelo **sobreajustado** rompe la regla: sus $\hat{y}$ son *más* dispersas que lo que la señal justifica, y la pendiente de y sobre $\hat{y}$ cae por debajo de 1.

Consecuencia práctica


Una compresión moderada es normal; la pregunta útil es *cuánto* error queda en las colas y si un modelo más flexible lo reduce. De eso trata la siguiente diapositiva.

Dónde se concentra el error (I): por cuantiles de y



- Calculen el RMSE **por decil** de y observado en la prueba. La U es la huella de la compresión: el modelo falla más en los extremos.
- En vivienda, las casas muy baratas y muy caras; en elecciones, las mesas casi unánimes: *justo* donde la decisión importa.
- Bogin & Shui (2020) reportan R^2 por cuartil de precio: la métrica agregada escondía las colas.

Dónde se concentra el error (I): por cuantiles de y



- Calculen el RMSE **por decil** de y observado en la prueba. La U es la huella de la compresión: el modelo falla más en los extremos.
- En vivienda, las casas muy baratas y muy caras; en elecciones, las mesas casi unánimes: *justo* donde la decisión importa.
- Bogin & Shui (2020) reportan R^2 por cuartil de precio: la métrica agregada escondía las colas.

Dos remedios que veremos

Más flexibilidad donde la relación se curva (sesiones 5–6) y, a veces, otra pérdida: si errar en la cola alta cuesta más, el MSE simétrico no es el objetivo correcto.

Dónde se concentra el error (II): por subgrupos y en el mapa

La misma pregunta, cortando por **quién** y por **dónde**:

Dónde se concentra el error (II): por subgrupos y en el mapa

La misma pregunta, cortando por **quién** y por **dónde**:

- **Por subgrupo:** RMSE por localidad, por estrato, por tipo de inmueble; por región o por ruralidad en las mesas. Un modelo con buen RMSE global que falla sistemáticamente en un grupo es un problema de **equidad** además de precisión (sesiones 3 y 7).

Dónde se concentra el error (II): por subgrupos y en el mapa

La misma pregunta, cortando por **quién** y por **dónde**:

- **Por subgrupo:** RMSE por localidad, por estrato, por tipo de inmueble; por región o por ruralidad en las mesas. Un modelo con buen RMSE global que falla sistemáticamente en un grupo es un problema de **equidad** además de precisión (sesiones 3 y 7).
- **En el mapa:** con datos georreferenciados, pinten los residuos. Manchas de un mismo signo delatan variables omitidas de la localización, y anticipan por qué la validación cruzada aleatoria engaña con datos espaciales (sesión 4).

Dónde se concentra el error (II): por subgrupos y en el mapa

La misma pregunta, cortando por **quién** y por **dónde**:

- **Por subgrupo:** RMSE por localidad, por estrato, por tipo de inmueble; por región o por ruralidad en las mesas. Un modelo con buen RMSE global que falla sistemáticamente en un grupo es un problema de **equidad** además de precisión (sesiones 3 y 7).
- **En el mapa:** con datos georreferenciados, pinten los residuos. Manchas de un mismo signo delatan variables omitidas de la localización, y anticipan por qué la validación cruzada aleatoria engaña con datos espaciales (sesión 4).
- **Los residuos como diagnóstico:** Pace & Hayunga (2020) ajustan árboles *sobre los residuos* de un hedónico y encuentran estructura que la especificación lineal dejó por fuera. Si un método flexible predice los residuos de su modelo, su modelo tiene sesgo.

Dónde se concentra el error (II): por subgrupos y en el mapa


La misma pregunta, cortando por **quién** y por **dónde**:

- **Por subgrupo:** RMSE por localidad, por estrato, por tipo de inmueble; por región o por ruralidad en las mesas. Un modelo con buen RMSE global que falla sistemáticamente en un grupo es un problema de **equidad** además de precisión (sesiones 3 y 7).
- **En el mapa:** con datos georreferenciados, pinten los residuos. Manchas de un mismo signo delatan variables omitidas de la localización, y anticipan por qué la validación cruzada aleatoria engaña con datos espaciales (sesión 4).
- **Los residuos como diagnóstico:** Pace & Hayunga (2020) ajustan árboles *sobre los residuos* de un hedónico y encuentran estructura que la especificación lineal dejó por fuera. Si un método flexible predice los residuos de su modelo, su modelo tiene sesgo.

La costumbre que vale la pena adquirir


Después de la tabla de métricas, tres figuras: predicho vs. observado, error por decil de y , y error por el subgrupo (o el mapa) que le importa a la pregunta.

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; k -NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola “razonablemente” solo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar.
- Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; *k*-NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola “razonablemente” solo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar.
- Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Regla

Reporten el **rango** de los predictores en el entrenamiento y marquen las predicciones fuera de él: un modelo entrenado con apartamentos de 40 a 200 m² no sabe nada de uno de 600.

Un ejemplo publicado: avalúos rurales

Bogin & Shui (2020), *Journal of Real Estate Finance and Economics*

Con más de 400 mil avalúos de Fannie Mae y Freddie Mac (2012–2016), partición 80/20 y 115 variables, comparan un hedónico lineal con métodos que veremos en la sesión 6:

Modelo	R^2 de prueba	RMSE de prueba
Hedónico (OLS)	0,680	0,319
<i>Random forest</i>	0,722	0,297
<i>Boosting</i>	0,676	0,321

Un ejemplo publicado: avalúos rurales

Bogin & Shui (2020), *Journal of Real Estate Finance and Economics*

Con más de 400 mil avalúos de Fannie Mae y Freddie Mac (2012–2016), partición 80/20 y 115 variables, comparan un hedónico lineal con métodos que veremos en la sesión 6:

Modelo	R^2 de prueba	RMSE de prueba
Hedónico (OLS)	0,680	0,319
<i>Random forest</i>	0,722	0,297
<i>Boosting</i>	0,676	0,321

- La tabla es el formato canónico: misma prueba, mismas métricas, una fila por modelo. Y la lectura no es “el bosque gana”: gana por 4 puntos de R^2 , mientras que el *boosting* mal afinado *pierde* contra la recta. La flexibilidad no es gratis ni automática.

Un ejemplo publicado: avalúos rurales

Bogin & Shui (2020), *Journal of Real Estate Finance and Economics*

Con más de 400 mil avalúos de Fannie Mae y Freddie Mac (2012–2016), partición 80/20 y 115 variables, comparan un hedónico lineal con métodos que veremos en la sesión 6:

Modelo	R^2 de prueba	RMSE de prueba
Hedónico (OLS)	0,680	0,319
<i>Random forest</i>	0,722	0,297
<i>Boosting</i>	0,676	0,321

- La tabla es el formato canónico: misma prueba, mismas métricas, una fila por modelo. Y la lectura no es “el bosque gana”: gana por 4 puntos de R^2 , mientras que el *boosting* mal afinado *pierde* contra la recta. La flexibilidad no es gratis ni automática.
- Luego repiten el R^2 en los cuartiles inferior y superior de precio: allí el hedónico se degrada más. La ventaja del bosque vive en las colas.
- Y discuten el costo computacional: un hedónico se estima en segundos; un bosque con 400 mil filas, no. Ese es también un criterio.

- 1 La regresión lineal como máquina de predecir
- 2 Cómo evaluar una predicción de regresión
- 3 Aplicación guiada: precios de vivienda en Bogotá
- 4 Cierre

Los datos y la pregunta

Datos: anuncios de venta de vivienda en Bogotá con precio, área, habitaciones, baños, estrato, tipo de inmueble, localidad y distancias a puntos de interés (centro, parques, estaciones).

Los datos y la pregunta

Datos: anuncios de venta de vivienda en Bogotá con precio, área, habitaciones, baños, estrato, tipo de inmueble, localidad y distancias a puntos de interés (centro, parques, estaciones). **Pregunta predictiva:** ¿con qué precisión podemos anticipar el precio de un inmueble que no está en la muestra? Es el problema de un evaluador automático (*AVM*), de un banco que valora garantías, o de un hogar que quiere saber si le están cobrando de más.

Los datos y la pregunta

Datos: anuncios de venta de vivienda en Bogotá con precio, área, habitaciones, baños, estrato, tipo de inmueble, localidad y distancias a puntos de interés (centro, parques, estaciones). **Pregunta predictiva:** ¿con qué precisión podemos anticipar el precio de un inmueble que no está en la muestra? Es el problema de un evaluador automático (*AVM*), de un banco que valora garantías, o de un hogar que quiere saber si le están cobrando de más. **Decisiones antes de ajustar nada:**

- 1 $y = \log(\text{precio})$; las métricas se reportan también en pesos.
- 2 Partición 80/20 **estratificada por deciles de y** ; la prueba queda bajo llave.
- 3 Un baseline: la media del entrenamiento. Un modelo de referencia: OLS con área, habitaciones, baños y estrato.

Los datos y la pregunta

Datos: anuncios de venta de vivienda en Bogotá con precio, área, habitaciones, baños, estrato, tipo de inmueble, localidad y distancias a puntos de interés (centro, parques, estaciones). **Pregunta predictiva:** ¿con qué precisión podemos anticipar el precio de un inmueble que no está en la muestra? Es el problema de un evaluador automático (AVM), de un banco que valora garantías, o de un hogar que quiere saber si le están cobrando de más. **Decisiones antes de ajustar nada:**

- 1 $y = \log(\text{precio})$; las métricas se reportan también en pesos.
- 2 Partición 80/20 **estratificada por deciles de y** ; la prueba queda bajo llave.
- 3 Un baseline: la media del entrenamiento. Un modelo de referencia: OLS con área, habitaciones, baños y estrato.

Lo que no haremos hoy

Elegir hiperparámetros con la prueba. Para escoger k o el número de nodos usaremos un pedazo del entrenamiento (validación); la manera correcta de hacerlo llega en la sesión 4.

Cuatro modelos, una misma prueba

	Modelo	RMSE (log)	MAE (pesos)	R^2 prueba
0	Media del entrenamiento	en clase	en clase	0
1	OLS básico: área, habitaciones, baños, estrato	en clase	en clase	en clase
2	OLS + localidad + interacciones + <i>splines</i>	en clase	en clase	en clase
3	k -NN, mismas variables estandarizadas	en clase	en clase	en clase

Cuatro modelos, una misma prueba

Modelo	RMSE (log)	MAE (pesos)	R^2 prueba
0 Media del entrenamiento	en clase	en clase	0
1 OLS básico: área, habitaciones, baños, estrato	en clase	en clase	en clase
2 OLS + localidad + interacciones + <i>splines</i>	en clase	en clase	en clase
3 k -NN, mismas variables estandarizadas	en clase	en clase	en clase

Preguntas que la tabla debe responder:

- ¿Cuánto explican cuatro variables? ¿Cuánto añade la localización? (La distancia entre la fila 1 y la 2 es el valor de la geografía.)
- ¿Le gana k -NN a la recta flexible? Con p moderado y muchos datos, puede; si no, la maldición de la dimensionalidad acaba de aparecer en vivo.

Cuatro modelos, una misma prueba

	Modelo	RMSE (log)	MAE (pesos)	R^2 prueba
0	Media del entrenamiento	en clase	en clase	0
1	OLS básico: área, habitaciones, baños, estrato	en clase	en clase	en clase
2	OLS + localidad + interacciones + <i>splines</i>	en clase	en clase	en clase
3	k -NN, mismas variables estandarizadas	en clase	en clase	en clase

Preguntas que la tabla debe responder:

- ¿Cuánto explican cuatro variables? ¿Cuánto añade la localización? (La distancia entre la fila 1 y la 2 es el valor de la geografía.)
- ¿Le gana k -NN a la recta flexible? Con p moderado y muchos datos, puede; si no, la maldición de la dimensionalidad acaba de aparecer en vivo.
- ¿Qué modelo tiene mayor brecha RMSE–MAE? Ese es el que más sufre en las colas.

Las celdas se completan con el código de la sesión; los números no se conocen hasta correrlo, y esa es la gracia.

Después de la tabla: las tres figuras

- 1 **Predicho vs. observado** para los modelos 1 y 2 (en log). Esperamos compresión en ambos y menos curvatura en el 2. Si el modelo 2 sigue curvado en los precios altos, la relación con el área no es la que asumimos ni con *splines*: pista para la sesión 6.

Después de la tabla: las tres figuras

- 1 **Predicho vs. observado** para los modelos 1 y 2 (en log). Esperamos compresión en ambos y menos curvatura en el 2. Si el modelo 2 sigue curvado en los precios altos, la relación con el área no es la que asumimos ni con *splines*: pista para la sesión 6.
- 2 **Error por decil de precio.** La U dirá cuánto pierde cada modelo en los apartamentos más caros. Es la fila que le importa a un banco: ahí están las garantías grandes.

Después de la tabla: las tres figuras

- 1 **Predicho vs. observado** para los modelos 1 y 2 (en log). Esperamos compresión en ambos y menos curvatura en el 2. Si el modelo 2 sigue curvado en los precios altos, la relación con el área no es la que asumimos ni con *splines*: pista para la sesión 6.
- 2 **Error por decil de precio.** La U dirá cuánto pierde cada modelo en los apartamentos más caros. Es la fila que le importa a un banco: ahí están las garantías grandes.
- 3 **Residuo promedio por localidad**, en tabla y en mapa. Manchas de un mismo signo señalan lo que la localidad y las distancias no capturan (ruido, vías, comercio, vista). Es la motivación de la validación espacial de la sesión 4 y de las variables satelitales de la sesión 8.

Después de la tabla: las tres figuras

- 1 **Predicho vs. observado** para los modelos 1 y 2 (en log). Esperamos compresión en ambos y menos curvatura en el 2. Si el modelo 2 sigue curvado en los precios altos, la relación con el área no es la que asumimos ni con *splines*: pista para la sesión 6.
- 2 **Error por decil de precio**. La U dirá cuánto pierde cada modelo en los apartamentos más caros. Es la fila que le importa a un banco: ahí están las garantías grandes.
- 3 **Residuo promedio por localidad**, en tabla y en mapa. Manchas de un mismo signo señalan lo que la localidad y las distancias no capturan (ruido, vías, comercio, vista). Es la motivación de la validación espacial de la sesión 4 y de las variables satelitales de la sesión 8.

El reporte de una aplicación, de aquí en adelante

Tabla de métricas en la misma prueba + predicho vs. observado + error por decil + error por el subgrupo relevante. Cuatro piezas; una página.

Cómo se ve en R (tidymodels)

```
library(tidymodels); set.seed(2026)
split <- initial_split(vivienda, prop = 0.8, strata = log_precio)
train <- training(split); test <- testing(split) # test bajo llave

rec <- recipe(log_precio ~ area + habitaciones + banos + estrato +
              localidad + dist_centro, data = train) |>
  step_dummy(all_nominal_predictors()) |>
  step_ns(area, dist_centro, deg_free = 4) |>      # splines naturales
  step_normalize(all_numeric_predictors())         # escala para k-NN

m_ols <- linear_reg() |> set_engine("lm")
m_knn <- nearest_neighbor(neighbors = 15) |>
  set_engine("kkn") |> set_mode("regression")

fit_ols <- workflow(rec, m_ols) |> fit(train)
pred    <- augment(fit_ols, test)              # predice en la prueba
metrics(pred, truth = log_precio, estimate = .pred) # rmse, rsq, mae
```

- El preprocesamiento vive **dentro** de la receta: se aprende en el entrenamiento y se aplica a la prueba. Esa disciplina es el *pipeline* de la sesión 4.
- rsq es una correlación al cuadrado; el R^2 de prueba se calcula a mano.

- 1 La regresión lineal como máquina de predecir
- 2 Cómo evaluar una predicción de regresión
- 3 Aplicación guiada: precios de vivienda en Bogotá
- 4 Cierre

Recap

- 1 **OLS como máquina de predecir:** mismas fórmulas, otro criterio. Las variables se eligen por error de prueba; la colinealidad deja de asustar; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- 2 **Flexibilidad controlada:** interacciones, polinomios, escalones, *splines* y GAM bajan el sesgo y conservan la lectura; *k*-NN quita la fórmula y paga con varianza y con la **maldición de la dimensionalidad**.
- 3 **Métricas:** RMSE, MAE, MAPE y R^2 de prueba (que puede ser negativo); siempre más de una, siempre relativas a y , siempre contra un baseline.
- 4 **Predicho vs. observado:** la compresión hacia la media es normal ($\text{Var}(f(X)) \leq \text{Var}(Y)$); lo que importa es cuánto error queda en las colas y en qué subgrupos.
- 5 **El reporte estándar:** tabla en la misma prueba + tres figuras (predicho vs. observado, error por decil, error por subgrupo o mapa). Y marcar la extrapolación.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 3 (secs. 3.1–3.3 y 3.5) y cap. 7 (secs. 7.1–7.4 y 7.7).
Guía: la sección 3.5 (lineal vs. k -NN) y las figuras 7.4 y 7.5 son las de clase.
- Bogin & Shui (2020), *Appraisal Accuracy and Automated Valuation Models in Rural Areas*, JREFE.
Guía: la tabla de comparación y la sección de resultados por cuartil de precio.

Para la presentación estudiantil de la sesión 3: Bogin & Shui (2020) o Pace & Hayunga (2020), *Examining the Information Content of Residuals from Hedonic and Spatial Models Using Trees and Forests*.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 3 (secs. 3.1–3.3 y 3.5) y cap. 7 (secs. 7.1–7.4 y 7.7).
Guía: la sección 3.5 (lineal vs. k -NN) y las figuras 7.4 y 7.5 son las de clase.
- Bogin & Shui (2020), *Appraisal Accuracy and Automated Valuation Models in Rural Areas*, JREFE.
Guía: la tabla de comparación y la sección de resultados por cuartil de precio.

Para la presentación estudiantil de la sesión 3: Bogin & Shui (2020) o Pace & Hayunga (2020), *Examining the Information Content of Residuals from Hedonic and Spatial Models Using Trees and Forests*.

Próxima sesión — clasificación: cuando y es una categoría (¿ganó el candidato en la mesa?, ¿el hogar es pobre?, ¿el crédito se paga?): la regresión logística como modelo de referencia, k -NN y LDA en breve, y la parte que decide todo en la práctica: **matriz de confusión, umbrales con costos, ROC/AUC, calibración y desbalanceo**. Repasen máxima verosimilitud de Econometría II. Lectura previa: ISL cap. 4 (secs. 4.1–4.4).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 3 (secs. 3.1–3.3 y 3.5) y cap. 7 (secs. 7.1–7.4 y 7.7).
Guía: la sección 3.5 (lineal vs. k -NN) y las figuras 7.4 y 7.5 son las de clase.
- Bogin & Shui (2020), *Appraisal Accuracy and Automated Valuation Models in Rural Areas*, JREFE.
Guía: la tabla de comparación y la sección de resultados por cuartil de precio.

Para la presentación estudiantil de la sesión 3: Bogin & Shui (2020) o Pace & Hayunga (2020), *Examining the Information Content of Residuals from Hedonic and Spatial Models Using Trees and Forests*.

Próxima sesión — clasificación: cuando y es una categoría (¿ganó el candidato en la mesa?, ¿el hogar es pobre?, ¿el crédito se paga?): la regresión logística como modelo de referencia, k -NN y LDA en breve, y la parte que decide todo en la práctica: **matriz de confusión, umbrales con costos, ROC/AUC, calibración y desbalanceo**. Repasen máxima verosimilitud de Econometría II. Lectura previa: ISL cap. 4 (secs. 4.1–4.4).

Aplicación de esta semana en R: precios de vivienda en Bogotá con `tidymodels`: los cuatro modelos, la tabla y las tres figuras.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 3 y 7. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Caps. 2–3 y 5. [ESL]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Kim, S.-y. S., & Zilinsky, J. (2024). Division Does Not Imply Predictability. *Political Behavior*, 46, 67–87.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Documento de trabajo.
- Bogin, A. N., & Shui, J. (2020). Appraisal Accuracy and Automated Valuation Models in Rural Areas. *Journal of Real Estate Finance and Economics*, 60, 40–52.
- Pace, R. K., & Hayunga, D. K. (2020). Examining the Information Content of Residuals from Hedonic and Spatial Models Using Trees and Forests. *Journal of Real Estate Finance and Economics*, 60, 170–180.
- McBride, L., & Nichols, A. (2018). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. *World Bank Economic Review*, 32(3), 531–550.
- Kuhn, M., & Silge, J. (2022). *Tidy Modeling with R*. O'Reilly. [\[disponible online\]](#)

5 Apéndice: para profundizar

A1. OLS en forma matricial y la media condicional

1. **El problema:** con $\mathbf{X}$ de $n \times (p + 1)$ (columna de unos incluida),

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

A1. OLS en forma matricial y la media condicional

1. El problema: con $\mathbf{X}$ de $n \times (p + 1)$ (columna de unos incluida),

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

2. Condición de primer orden: $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \Rightarrow \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$, y si $\mathbf{X}'\mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad \hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \equiv \mathbf{H}\mathbf{y}.$$

A1. OLS en forma matricial y la media condicional

1. **El problema:** con $\mathbf{X}$ de $n \times (p + 1)$ (columna de unos incluida),

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

2. **Condición de primer orden:** $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \Rightarrow \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$, y si $\mathbf{X}'\mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad \hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \equiv \mathbf{H}\mathbf{y}.$$

3. **Lectura predictiva:** $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio generado por las columnas de $\mathbf{X}$: la mejor aproximación *lineal* a la media condicional. Si $\mathbb{E}[Y | X]$ es lineal, OLS la estima sin sesgo; si no, estima la mejor recta, y el sesgo que queda es el precio de la rigidez.

A1. OLS en forma matricial y la media condicional

1. El problema: con $\mathbf{X}$ de $n \times (p + 1)$ (columna de unos incluida),

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

2. Condición de primer orden: $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \Rightarrow \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$, y si $\mathbf{X}'\mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad \hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \equiv \mathbf{H}\mathbf{y}.$$

3. Lectura predictiva: $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio generado por las columnas de $\mathbf{X}$: la mejor aproximación *lineal* a la media condicional. Si $\mathbb{E}[Y | X]$ es lineal, OLS la estima sin sesgo; si no, estima la mejor recta, y el sesgo que queda es el precio de la rigidez. **4. Por qué la colinealidad no asusta al**

predictor: $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ depende del *espacio* de las columnas, no de cómo se repartan los coeficientes entre columnas parecidas. Dos coeficientes inestables pueden sumar una predicción estable. (La varianza de $\hat{y}_0$ sí crece con p : esa es la varianza de la sesión 1.)

A2. La base de un *spline*: cómo se construyen las columnas

Polinomio cúbico por tramos con un nodo en ξ : dos cúbicas distintas a cada lado de ξ , unidas de modo que la función, su primera y su segunda derivada sean continuas en ξ .

A2. La base de un *spline*: cómo se construyen las columnas

Polinomio cúbico por tramos con un nodo en ξ : dos cúbicas distintas a cada lado de ξ , unidas de modo que la función, su primera y su segunda derivada sean continuas en ξ . **La base de potencias truncadas** lo logra con una sola columna extra:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x - \xi)_+^3 + \varepsilon, \quad (x - \xi)_+^3 = \max\{0, (x - \xi)^3\}.$$

Antes de ξ la columna vale cero; después añade una cúbica que arranca en cero con derivadas cero: el empalme es suave por construcción.

A2. La base de un *spline*: cómo se construyen las columnas

Polinomio cúbico por tramos con un nodo en ξ : dos cúbicas distintas a cada lado de ξ , unidas de modo que la función, su primera y su segunda derivada sean continuas en ξ . **La base de potencias truncadas** lo logra con una sola columna extra:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 (x - \xi)_+^3 + \varepsilon, \quad (x - \xi)_+^3 = \max\{0, (x - \xi)^3\}.$$

Antes de ξ la columna vale cero; después añade una cúbica que arranca en cero con derivadas cero: el empalme es suave por construcción.

- Con K nodos: $K + 4$ columnas, es decir, $K + 4$ grados de libertad. Todo se estima por OLS.
- Un **spline natural** impone linealidad más allá de los nodos extremos y ahorra 4 grados de libertad: menos varianza en las colas, donde hay pocos datos.
- En R, `splines::ns(x, df = 4)` construye la base; `step_ns()` la mete en la receta. Los *B-splines* son otra base, numéricamente más estable, del mismo espacio.

A3. La cuenta de la compresión:

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2$$

1. **Ley de la varianza total:** para cualquier Y y X ,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

A3. La cuenta de la compresión:

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2$$

1. Ley de la varianza total: para cualquier Y y X ,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

2. Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon | X] = 0$ **y** $\text{Var}(\varepsilon | X) = \sigma^2$: $\mathbb{E}[Y | X] = f(X)$ y $\text{Var}(Y | X) = \sigma^2$, luego

$$\text{Var}(Y) = \sigma^2 + \text{Var}(f(X)) \geq \text{Var}(f(X)).$$

A3. La cuenta de la compresión:

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2$$

1. Ley de la varianza total: para cualquier Y y X ,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

2. Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon | X] = 0$ **y** $\text{Var}(\varepsilon | X) = \sigma^2$: $\mathbb{E}[Y | X] = f(X)$ y $\text{Var}(Y | X) = \sigma^2$, luego

$$\text{Var}(Y) = \sigma^2 + \text{Var}(f(X)) \geq \text{Var}(f(X)).$$

3. Calibración y pendiente: si $\hat{y}$ está bien calibrado, $\mathbb{E}[Y | \hat{y}] = \hat{y}$, de modo que en la regresión de y sobre $\hat{y}$ la pendiente es 1 y el intercepto 0. La regresión *inversa*, de $\hat{y}$ sobre y , tiene pendiente $\text{Cov}(y, \hat{y})/\text{Var}(y) = \text{Var}(\hat{y})/\text{Var}(y) \leq 1$: esa es la compresión que se ve al dibujar $\hat{y}$ contra y .

A3. La cuenta de la compresión:

$$\text{Var}(Y) = \text{Var}(f(X)) + \sigma^2$$

1. Ley de la varianza total: para cualquier Y y X ,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

2. Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon | X] = 0$ **y** $\text{Var}(\varepsilon | X) = \sigma^2$: $\mathbb{E}[Y | X] = f(X)$ y $\text{Var}(Y | X) = \sigma^2$, luego

$$\text{Var}(Y) = \sigma^2 + \text{Var}(f(X)) \geq \text{Var}(f(X)).$$

3. Calibración y pendiente: si $\hat{y}$ está bien calibrado, $\mathbb{E}[Y | \hat{y}] = \hat{y}$, de modo que en la regresión de y sobre $\hat{y}$ la pendiente es 1 y el intercepto 0. La regresión *inversa*, de $\hat{y}$ sobre y , tiene pendiente $\text{Cov}(y, \hat{y})/\text{Var}(y) = \text{Var}(\hat{y})/\text{Var}(y) \leq 1$: esa es la compresión que se ve al dibujar $\hat{y}$ contra y .

Uso

La pendiente de y sobre $\hat{y}$ en la prueba es un test de calibración gratuito: por debajo de 1 hay sobreajuste (predicciones demasiado dispersas); por encima, subajuste. Vuelve en la sesión 3 para probabilidades.