Big Data y Machine Learning para Economía Aplicada

Week 02: La regresión lineal como máquina de predecir — y cómo evaluar una predicción

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

October 8, 2026

Previously...

- **Y, no β:** predecir y explicar son preguntas distintas; un coeficiente significativo no es una predicción.
- El objetivo es el **riesgo de generalización** (con pérdida cuadrática, el **MSE**); el mejor predictor es la media condicional $\mathbb{E}[Y \mid X = x]$, y σ^2 es el techo de lo aprendible.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- $\mathrm{MSE} = \text{Sesgo}^2 + \text{Varianza} + \sigma^2$: la complejidad baja el sesgo y sube la varianza; el óptimo es interior (la curva U).
- **Lo vimos con datos:** 50 avisos, tres polinomios; el grado 12 ajustaba mejor dentro y predecía peor fuera. Hoy empieza el problema del curso.

Hoy

La regresión que ya conocen como **máquina de predecir**: qué se conserva del OLS, qué deja de importar y qué aparece; k-NN como primer contraste; y cómo **evaluar** una predicción: métricas, referencia, gráficos y dónde mirar los errores.

La pregunta de hoy: ¿cuánto del voto de un puesto se puede predecir con su entorno?

El caso del curso: la segunda vuelta presidencial de 2022, Petro vs. Hernández, puesto por puesto

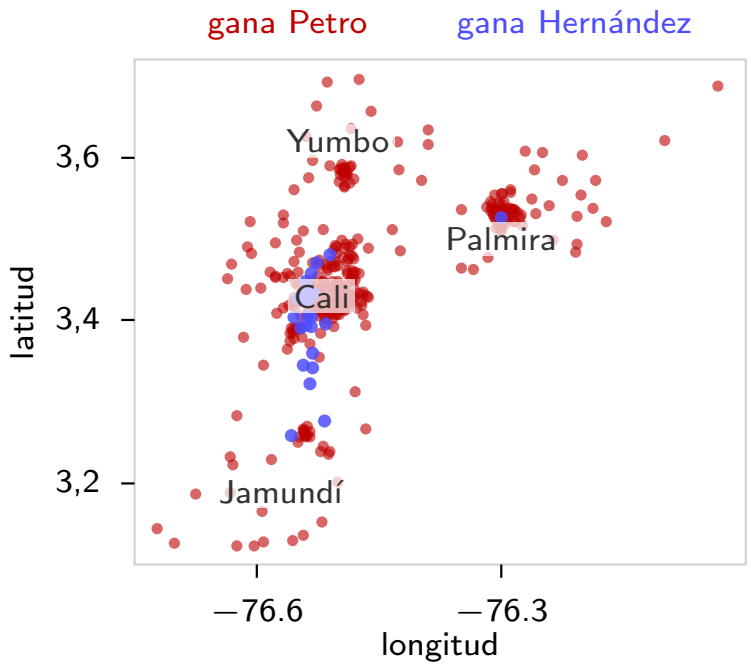
- **La unidad:** el puesto de votación (un colegio, una escuela, una caseta): 12.000 en el país con coordenadas y censo; 1.060 en el Valle; 343 en Cali, Palmira, Yumbo y Jamundí.
- **La y de hoy y de las sesiones 3 y 5:** `voto_petro`, los votos por Petro sobre los votos por los dos candidatos, en puntos. Del 20% (Santander) al 86% (Chocó); en el área metropolitana, del 15% (Pance) al 94% (La Meseta, Jamundí).
- **La y de la sesión 4:** `gana_petro`: ¿sacó Petro más votos que Hernández? Ganar es eso, no pasar del 50%.
- **Las x:** lo que el censo de 2018 dice del **entorno** del puesto. Nada de encuestas ni de campaña: sólo estructura.

Cómo la respondemos hoy, y durante el curso

Una campaña quiere saber qué puestos son "suyos" antes de gastar; un analista, cuánto del voto es *estructura* del territorio. Hoy: la teoría de la regresión como máquina de predecir, con estos puestos como ejemplo, y después el mismo ejercicio en R. Cada semana volvemos al caso con una herramienta más; una **tabla del líder** lleva la cuenta.

La pregunta, en el mapa

Cada punto es un puesto de votación; el color, quién lo ganó (más votos que el rival)



- El voto tiene una geografía clarísima: el oriente de Cali y Jamundí, casi unánimes; el sur de Cali, la otra orilla. Y nada de esto usa encuestas: es sólo el resultado.
- La pregunta de la campaña: ¿cuánto de este dibujo se podía anticipar *sólo con el censo*? Para responderla, primero hay que saber qué sabemos de cada punto.

Lo que sabemos de cada puesto

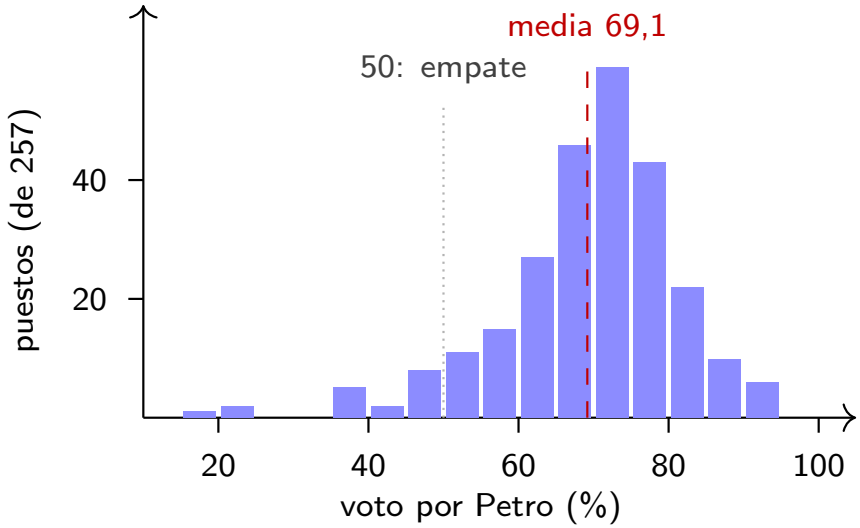
Las manzanas del censo asignadas a cada puesto, resumidas en cuatro bloques (y la ubicación)

Bloque	**Variables (en % del entorno)**	**En Cali, Palmira, Yumbo y Jamundí**
Socioeconómico	viviendas de estrato bajo (1–2), medio (3–4) y alto (5–6); personas con educación superior	educación superior: del 0 al 58%; estrato alto: del 0 al 92%
Infraestructura y tamaño	servicios por vivienda (agua, alcantarillado, energía, gas, internet: 0 a 5); población; registrados	registrados: de 44 a 22 mil
Demografía	seis grupos de edad; mujeres	mujeres: 43 a 57%
Etnia	afrocolombianos; indígenas	afro: del 0 al 92%
Ubicación	longitud y latitud; cabecera o rural; municipio; departamento	343 puntos en el mapa

- Además, la **referencia vigente**: el voto por Petro en el mismo puesto en 2018, cuando existía.
- Antes de tocar las x, lo clásico: describir la y que queremos predecir (siguiente diapositiva). Sesión 3: todo el país; sesión 7: las 44 columnas crudas del censo.

La y, antes de cualquier modelo

Lo clásico: describir el *target* para saber qué significa acertar (sólo el entrenamiento)



- La masa entre 60 y 85 (el 77% de los puestos), media 69,1, desviación 12,2; la cola larga va hacia abajo: Petro pierde en sólo 18 de los 257 (7%).
- Dos lecciones antes de ajustar: predecir "la media para todos" ya deja un error típico de 12 puntos — ésa será la **referencia** — y lo difícil estará en las colas (volveremos con el error por quintil).
- La candidata del censo para empezar a ordenar esta dispersión: la **educación superior**. Parte 1.

1. La regresión simple como máquina de predecir
2. Más flexible que la recta, con una variable
3. La regresión múltiple
4. Después de predecir: entender qué predice el modelo
5. Cierre

El capítulo canónico, leído con otros ojos

ISL abre su capítulo 3 con siete preguntas (sobre publicidad y ventas); son las mismas siete sobre el entorno y el voto

1. ¿Hay relación entre el entorno del puesto y su voto?
2. ¿Qué tan fuerte es?
3. ¿Qué variables del entorno están asociadas con el voto?
4. ¿Qué tan grande es la asociación de cada una?
5. **¿Con qué precisión podemos predecir el voto de un puesto que no hemos visto?**
6. ¿Es lineal la relación?
7. ¿Hay interacciones (la educación pesa distinto en la ciudad y en el campo)?

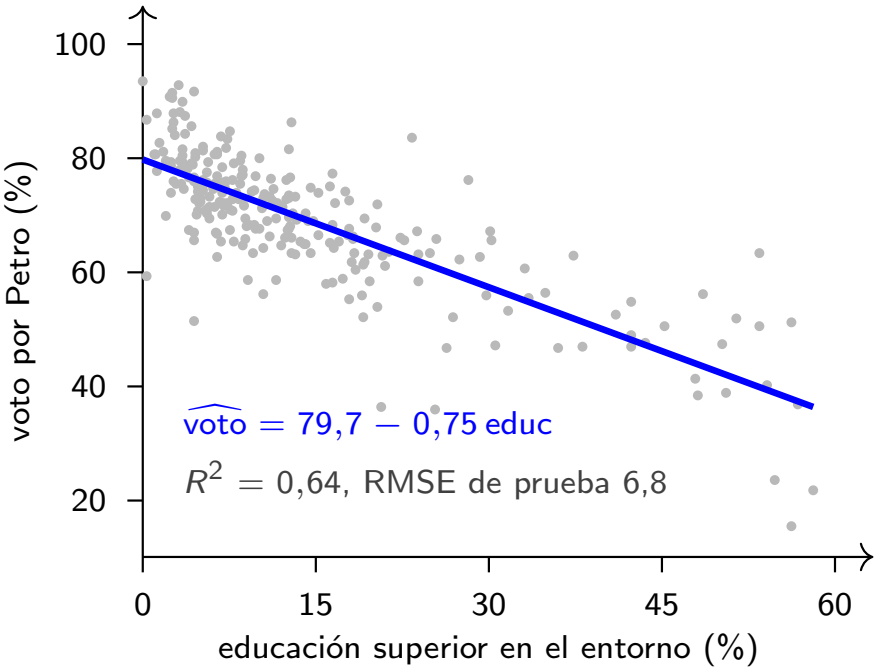
Seis preguntas sobre la relación y sus coeficientes; una sola, la quinta, sobre predecir. Y el capítulo nunca evalúa fuera de muestra.

Hoy: el itinerario

La pregunta 5 al centro: la recta y su mecánica, las métricas, más flexibilidad, más variables, y qué mirar *después* de predecir. Las demás preguntas van cayendo en el camino (las que no, al apéndice).

La primera respuesta: una recta

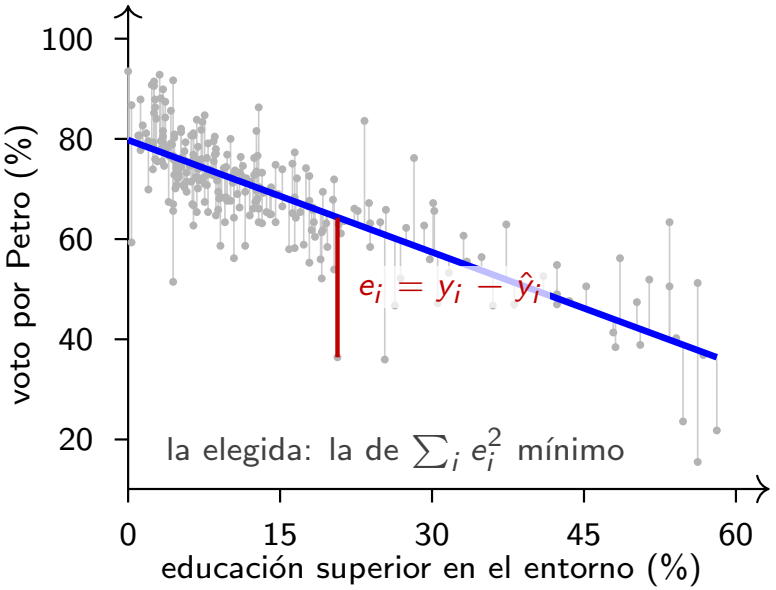
Los 257 puestos del entrenamiento contra la educación superior, la variable del censo que más se mueve con el voto (cor $-0{,}80$)



- Una sola variable del entorno ordena buena parte del mapa: $R^2 = 0{,}64$ en muestra, 6,8 puntos de RMSE en la prueba (qué significan: en tres diapositivas).
- Dibujarla es fácil. La pregunta seria: ¿*cuál* recta es esta? ¿Quién la eligió, con qué criterio? De esa respuesta vive todo lo que sigue.

¿Cuál recta? La que minimiza el RSS

El residuo del puesto i: $e_i = y_i - \hat{y}_i$, lo que la recta no explica de ese puesto



La recta de mínimos cuadrados minimiza

$$\text{RSS} = \sum_{i=1}^{n} e_i^2$$

- Con los 257 puestos: $\text{RSS} = 13.739$; $\text{RSS}/n = 53{,}5$, el **MSE de entrenamiento** (su raíz: 7,3, el "RMSE dentro" de hoy).
- Minimizar el RSS *es* minimizar el error de entrenamiento (el riesgo empírico de la sesión 1).

Por qué el error de entrenamiento adula (regla de oro #1)

La recta fue elegida *para* hacer pequeño ese error: calificarla con él es dejar que el estudiante se ponga la nota.

La solución: $\hat{y}$ es la proyección de y sobre las x

La misma cuenta de Econometría, leída en clave de predicción

1. El problema: con $\mathbf{X}$ de $n \times (p+1)$ (columna de unos incluida),

$$\hat{\beta} = \arg\min_{\beta} \, (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta).$$

2. Condición de primer orden: $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \;\Rightarrow\; \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{y}$, y si $\mathbf{X}'\mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \qquad \hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \equiv \mathbf{H}\mathbf{y}.$$

3. Lectura predictiva: $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio generado por las columnas de $\mathbf{X}$: la mejor aproximación *lineal* a la media condicional. Si $\mathbb{E}[Y \mid X]$ es lineal, OLS la estima sin sesgo; si no, estima la mejor recta, y el sesgo que queda es el precio de la rigidez.

4. Por qué la colinealidad no asusta al predictor: $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ depende del *espacio* de las columnas, no de cómo se repartan los coeficientes entre columnas parecidas. Dos coeficientes inestables pueden sumar una predicción estable. (La varianza de $\hat{y}_0$ sí crece con p: esa es la varianza de la sesión 1.)

Las métricas: el error de prueba tiene muchas caras

Ya sabemos ajustar la recta; falta el número con que se califica, siempre en la prueba

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t}\sum(y_i-\hat{y}_i)^2 \quad / \quad \sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y; castiga los errores grandes
MAE	$\frac{1}{n_t}\sum\lvert y_i-\hat{y}_i\rvert$	robusta a extremos; el "error típico"
MAPE	$\frac{100}{n_t}\sum\lvert y_i-\hat{y}_i\rvert/\lvert y_i\rvert$	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1-\sum(y_i-\hat{y}_i)^2/\sum(y_i-\bar{y}_{\text{train}})^2$	fracción del error de la media que el modelo evita; **puede ser negativo**

Las métricas: el error de prueba tiene muchas caras

Ya sabemos ajustar la recta; falta el número con que se califica, siempre en la prueba

Con n_t observaciones de prueba y predicciones $\hat{y}_i$:

Métrica	Fórmula	Cuándo usarla
MSE / RMSE	$\frac{1}{n_t}\sum(y_i-\hat{y}_i)^2 \quad / \quad \sqrt{\text{MSE}}$	la estándar; RMSE en unidades de y; castiga los errores grandes
MAE	$\frac{1}{n_t}\sum\lvert y_i-\hat{y}_i\rvert$	robusta a extremos; el "error típico"
MAPE	$\frac{100}{n_t}\sum\lvert y_i-\hat{y}_i\rvert/\lvert y_i\rvert$	error relativo; inservible cuando $y \approx 0$
R^2 de prueba	$1-\sum(y_i-\hat{y}_i)^2/\sum(y_i-\bar{y}_{\text{train}})^2$	fracción del error de la media que el modelo evita; **puede ser negativo**

- El RMSE en puntos no dice nada solo: se lee **relativo** a y. La recta de hoy: 6,8 puntos sobre un voto que promedia 69 y se dispersa 12; un 10% del voto, poco más de la mitad del error de la media.
- RMSE $\geq$ MAE siempre; una brecha grande delata **pocos errores muy grandes**. La recta: 6,8 y 5,4, brecha corta: su error es parejo.
- El R^2 de prueba **puede ser negativo**: peor que predecir $\bar{y}$ (apéndice A7). Y reporten siempre **más de una**.

1 La regresión simple como máquina de predecir

2 Más flexible que la recta, con una variable

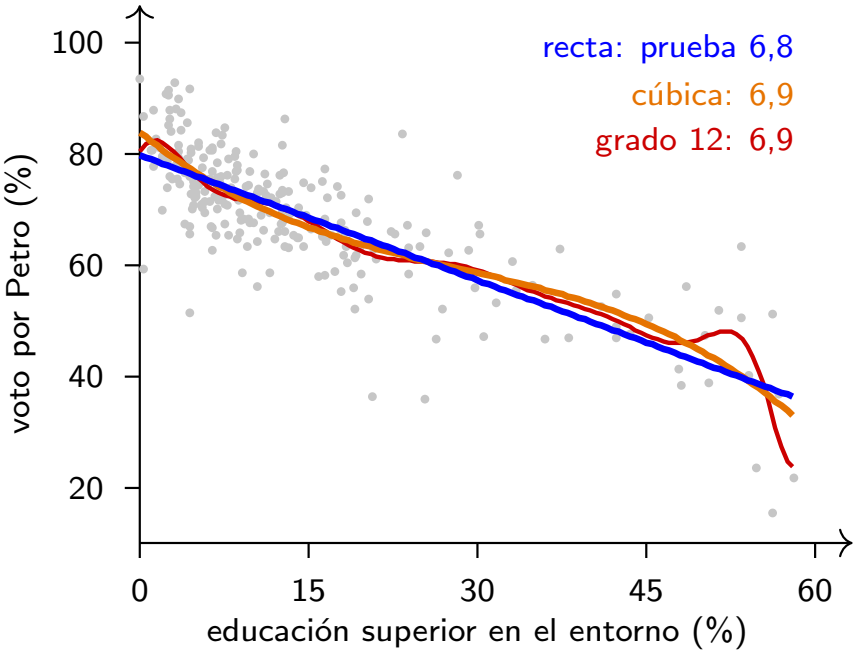
3 La regresión múltiple

4 Después de predecir: entender qué predice el modelo

5 Cierre

Los polinomios, con nuestros puestos: se abrazan

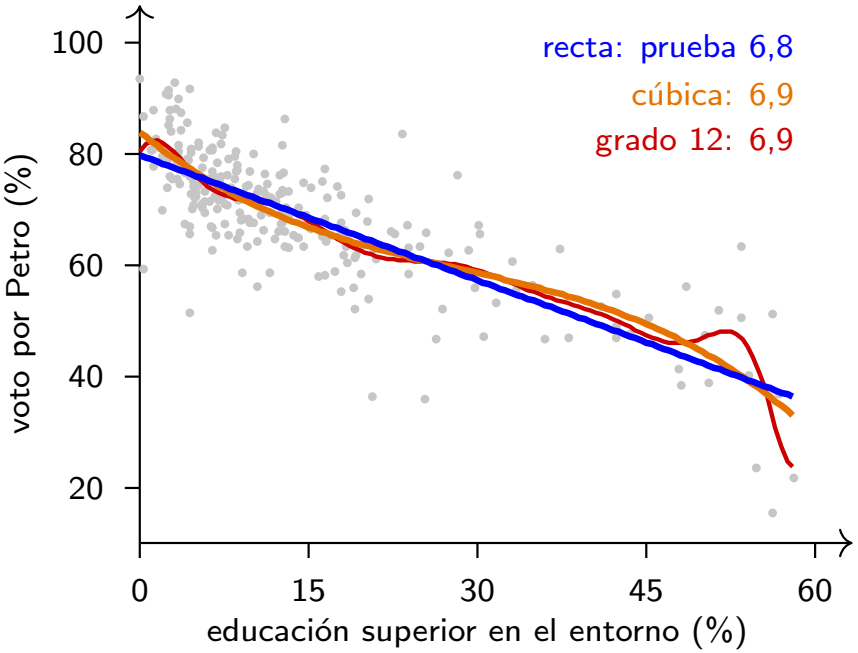
Dentro del rango observado, la recta, la cúbica y el grado 12 son casi la misma función



- Un polinomio de grado d sigue siendo OLS sobre las columnas $x, x^2, \ldots, x^d$; el grado es la perilla. Aquí la relación es casi lineal y la flexibilidad **no compró nada** (prueba: 6,8 / 6,9 / 6,9); en el `Auto` de ISL (Fig. 3.8) la curvatura es real y el cuadrático sí gana.
- El grado 12 ya *ondula* donde los datos ralean: paga varianza sin quitar sesgo. Y fuera del rango las tres se separan de verdad (la extrapolación, al cierre).

Los polinomios, con nuestros puestos: se abrazan

Dentro del rango observado, la recta, la cúbica y el grado 12 son casi la misma función



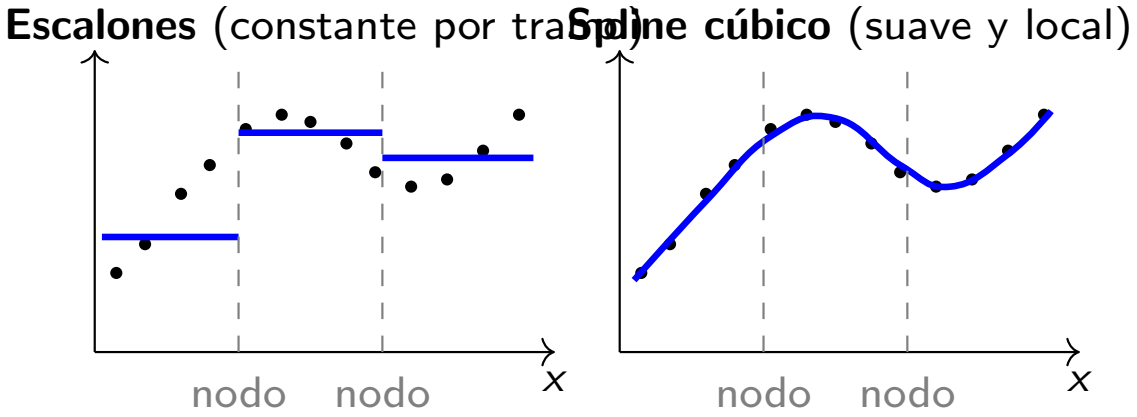
- Un polinomio de grado d sigue siendo OLS sobre las columnas $x, x^2, \ldots, x^d$; el grado es la perilla. Aquí la relación es casi lineal y la flexibilidad **no compró nada** (prueba: 6,8 / 6,9 / 6,9); en el `Auto` de ISL (Fig. 3.8) la curvatura es real y el cuadrático sí gana.
- El grado 12 ya *ondula* donde los datos ralean: paga varianza sin quitar sesgo. Y fuera del rango las tres se separan de verdad (la extrapolación, al cierre).

Lo que queremos

Flexibilidad **local**: que la forma de la relación en una zona de x no obligue a nada en otra. Eso es lo que dan los escalones y los *splines*.

Más allá de la linealidad, en una diapositiva

Escalones, *splines* y modelos aditivos: la escalera que sigue siendo OLS (ISL, cap. 7)



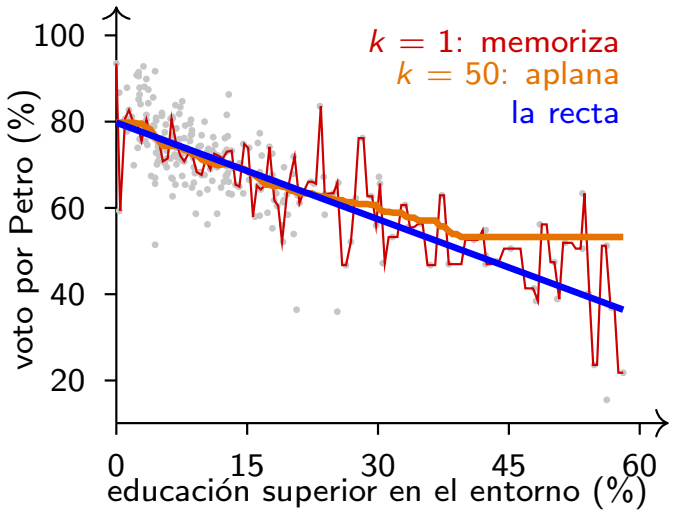
- **Escalones:** cortar x en tramos y ajustar una constante por tramo (*dummies* de rango). Fácil de leer, feo en los bordes.
- **Spline cúbico:** un polinomio de grado 3 por tramo, obligado a empalmar suavemente en los **nodos**. Sigue siendo OLS sobre una *base* de columnas construidas a partir de x (apéndice A5); la perilla es el número de nodos; los *splines naturales* son lineales en las colas.
- **GAM:** $y = \beta_0 + f_1(x_1) + \cdots + f_p(x_p) + \varepsilon$, un *spline* por variable, sumados. Flexible donde importa y legible variable por variable (esa figura vuelve en la sesión 6 como dependencia parcial); su límite es que no descubre interacciones.

¿Y si sobra la fórmula? k-NN, el promedio de los vecinos

Todas las perillas anteriores curvan una fórmula global; el otro extremo es no tener ninguna

Para predecir en x_0: promediar la y de las k observaciones **más cercanas**:

$$\hat{f}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i$$



- **Sin fórmula**: la forma la ponen los datos. La perilla es k: con $k = 1$ la curva pasa por cada punto (varianza) y con k grande se aplana hacia la media (sesgo).
- Necesita una **distancia** (estandarizar las x). En la figura los vecinos se buscan en la *educación*; en la tabla final de hoy probamos también la distancia del **mapa**. En la sesión 4 vota; hoy promedia.

La maldición de la dimensionalidad

Por qué "los vecinos" dejan de ser vecinos

Con predictores uniformes en $[0,1]^p$, ¿qué fracción del rango de *cada* variable hay que abarcar para capturar el 10% de los datos como vecinos?

p	1	2	5	10	100
Lado del "vecindario" $(0{,}1^{1/p})$	0,10	0,32	0,63	0,79	0,98

- Con $p = 10$, el "vecindario" que reúne el 10% de los datos cubre el 79% del rango de cada variable: los vecinos ya no se parecen a x_0 en nada. El promedio local se vuelve un promedio *global* y el sesgo explota.
- Los métodos que dependen de distancias (k-NN, kernels) sufren esto de frente; los lineales, los *splines* aditivos y los árboles lo esquivan porque **imponen estructura**.

Lección

Flexibilidad total sólo es gratis con pocas variables y muchos datos. En alta dimensión, algo de *estructura* (linealidad, aditividad, particiones) es lo que permite aprender. Ese es el argumento de fondo de las sesiones 3 y 5.

1 La regresión simple como máquina de predecir

2 Más flexible que la recta, con una variable

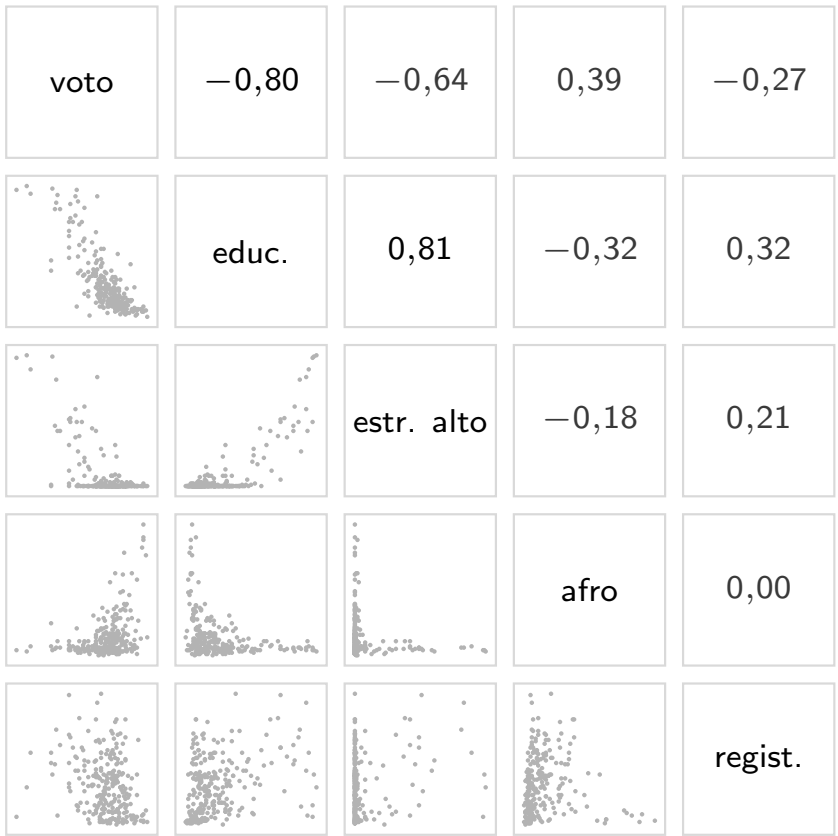
3 La regresión múltiple

4 Después de predecir: entender qué predice el modelo

5 Cierre

Mirar antes de ajustar: todas contra todas

Cinco de las variables, sólo con los 257 puestos de entrenamiento: la exploración también respeta la partición

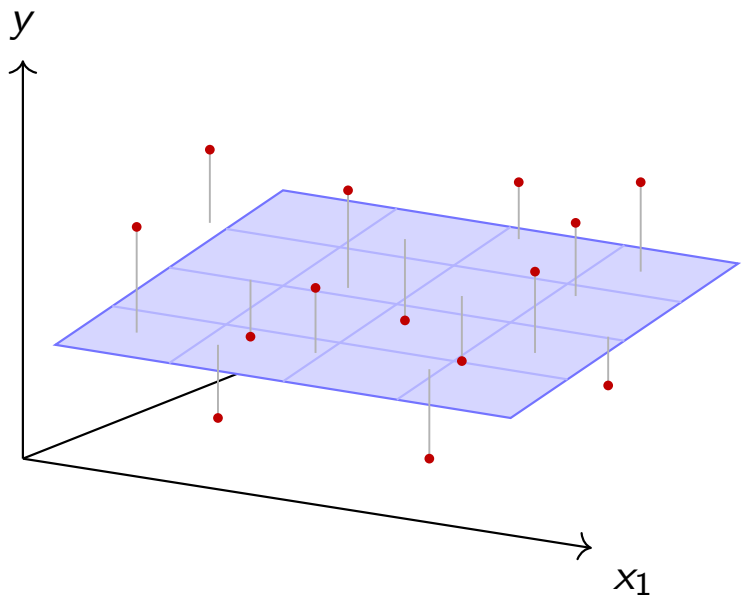


- **La fila del voto** ordena a las candidatas: la educación superior (−0,80) ya está en el modelo; estrato alto, afro y registrados esperan turno.
- **Gemelas a la vista:** educación y estrato alto (0,81) cuentan casi la misma historia. En unas diapositivas: qué pasa si entran juntas.
- **Registrados** es asimétrica (mediana 6.100, máximo 22.000): cuando entre al modelo, entrará en logaritmo.

Con 9 variables aún se puede mirar todo contra todo; con los cientos de la sesión 3, ya no. Y ojo con las **gemelas** (0,81): esa cuenta se cobra en tres diapositivas.

De la recta al plano, y a donde ya no se dibuja

El mismo criterio con dos predictores: minimizar los cuadrados de las distancias verticales al plano



- Con $p = 2$ todavía se dibuja: el RSS suma distancias verticales a un **plano**. Con nuestras nueve variables, el ajuste es un hiperplano en un espacio que nadie puede ver.
- La consecuencia práctica: desde ahí **la evaluación es numérica** y la intuición de "cerca" hay que ganársela (la maldición de la parte anterior). ¿Y el reporte en muestra, se entera de que entraron variables? Siguiente diapositiva.

El reporte en muestra: RSE y R^2

Las dos medidas que ya conocían, releídas; y una advertencia al añadir variables

- **RSE** $= \sqrt{\mathrm{RSS}/(n-2)} = 7{,}34$ puntos: la desviación típica del residuo. Releído para predecir: la **estimación de** σ, el techo de la sesión 1. Guárdenlo: de ahí sale el ancho de la banda de predicción ($\approx 4 \times \mathrm{RSE} \approx 29$ puntos; apéndice A1).
- $R^2 = 1 - \mathrm{RSS}/\mathrm{TSS} = 0{,}64$, **en muestra**: la fracción de la varianza del voto que la recta ordena *en los mismos datos que la eligieron*.
- Al añadir variables, el R^2 en muestra **nunca baja** — aunque la variable sea basura — y el RSE apenas se inmuta. ¿Cómo saber entonces si la variable nueva sobra? Pregunta para la sala, siguiente diapositiva.

La regla

Ajuste en muestra no es capacidad de predecir. Toda cifra "oficial" del curso se reporta sobre la **prueba**; las de esta diapositiva describen el ajuste, no lo califican.

Pregunta para la sala: ¿y si meto una gemela?

Lo prometido en la matriz de pares: el R^2 ni se entera; el daño está en otra parte

Modelo	R^2	R^2 ajust.	ee(educación)	RMSE prueba
Educación sola	0,640	0,638	0,035	6,8
+ estrato alto (cor 0,81)	0,640	0,637	0,060	6,8
+ una gemela de educación (cor 0,999)	0,640	0,637	0,911	6,8
+ 150 columnas de ruido puro	**0,853**	0,642	0,056	**9,9**

- El R^2 en muestra **nunca baja** al añadir una variable: por eso no sirve para elegirlas. Con ruido puro llega a 0,85; el ajustado lo descuenta y la prueba lo cobra (9,9 vs. 6,8).
- Con la gemela el punto predicho casi no cambia, pero el **crédito se reparte al azar**: el $-0{,}75$ de educación se parte en $-0{,}24$ y $-0{,}51$, con error estándar 26 veces mayor. Interpretar coeficientes ahí es leer ruido (por qué la predicción sale ilesa: la proyección de la parte 1).
- Y el riesgo escondido: la cancelación entre gemelas funciona *mientras su correlación se mantenga*; si en datos nuevos se desacoplan, la predicción se rompe ("la recta no viaja").

OLS con otros ojos

La lección de la gemela, en general: $\hat{\beta}$ y $\hat{y}$ responden preguntas distintas

El modelo y el estimador son los de Econometría I:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \qquad \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \;=\; \arg\min_{\beta} \mathrm{RSS}(\beta)$$

Lo que cambia es **para qué** lo usamos:

	Como econometristas	**Como predictores**
Nos importa	$\hat{\beta}_j$ y su error estándar	$\hat{y}_0 = x_0'\hat{\beta}$ en datos nuevos
Elegimos variables	por teoría e identificación	por error de prueba
Variable "no significativa"	se discute	se queda si ayuda a predecir
Insesgamiento	lo que se defiende	negociable por menos varianza
Colinealidad	problema para $\hat{\beta}$	casi irrelevante para $\hat{y}$
La prueba del modelo	supuestos, R^2, tests	el error en la prueba

El papel de OLS en el curso

OLS aproxima la media condicional, es estable, se ajusta en milisegundos y se interpreta sin esfuerzo. Todo método del curso se compara contra él: si un bosque no le gana en la prueba, el bosque sobra.

1 La regresión simple como máquina de predecir

2 Más flexible que la recta, con una variable

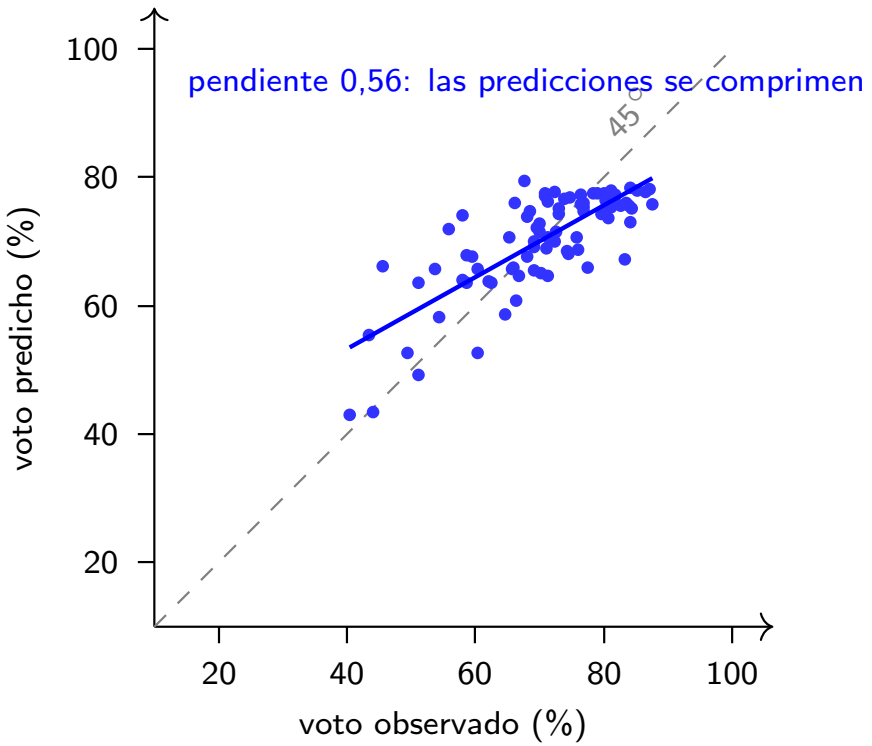
3 La regresión múltiple

4 Después de predecir: entender qué predice el modelo

5 Cierre

Predicho vs. observado: la figura que nunca falta

Qué predice el modelo: la recta, en los 86 puestos de prueba



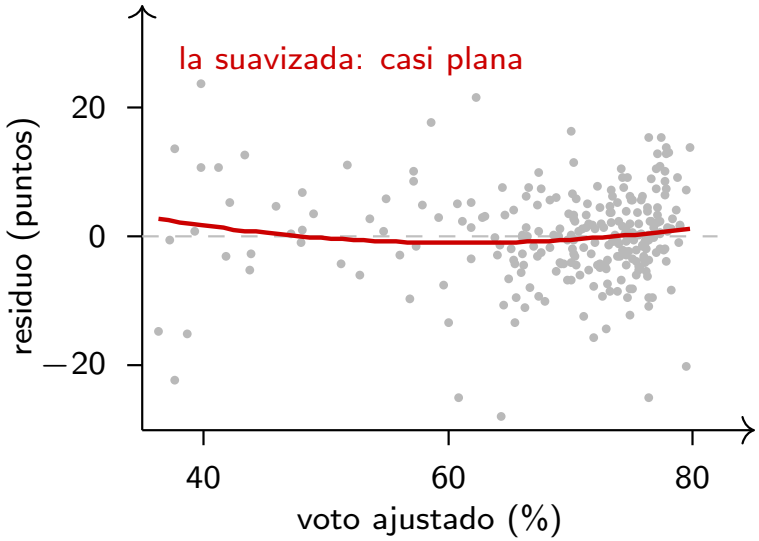
- Cada punto es una observación de **prueba**; la diagonal es la predicción perfecta.
- El patrón típico: **pendiente menor que uno** (aquí, 0,56). Se **sobrepredice** en la cola baja y se **subpredice** en la alta: las predicciones se *comprimen* hacia la media (la cuenta: apéndice A8).
- La primera figura del reporte: una por modelo, sobre la misma prueba.

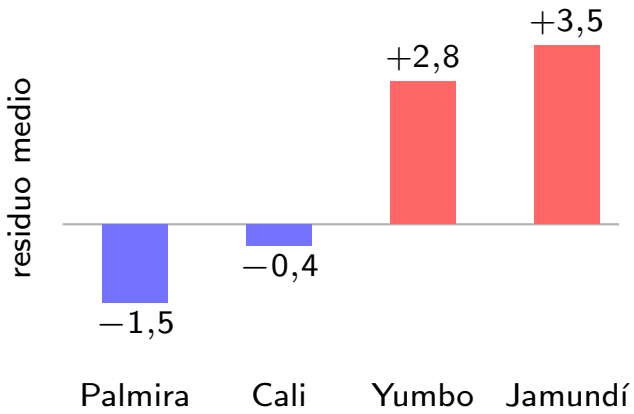
Qué buscar en la figura

Curvatura (no linealidad omitida), abanico (varianza que crece con y), grupos desplazados y puntos aislados (errores grandes). El R^2 resume; la figura explica.

Los residuos como detector

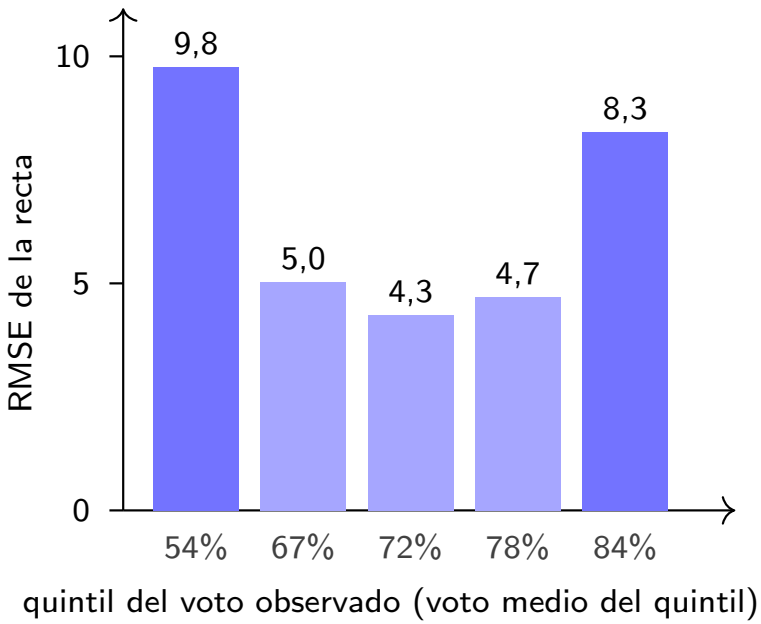
Graficar e_i contra lo que se sospeche: donde haya patrón, quedó estructura sin capturar





- Contra el **ajustado** (izquierda), nada: a esta recta no le falta curvatura — coherente con la cúbica, que no compraba nada. En el `Auto` de ISL este panel muestra una U: allá sí faltaba el cuadrático.
- Contra el **municipio** (derecha), sí: la recta le queda corta a Jamundí y a Yumbo y le sobra en Palmira. A nuestra recta no le falta forma: le falta *lugar*. La versión fina es el mapa (dos diapositivas).
- El detector general: si algo — un grupo, el mapa, el tiempo, otro método — logra *predecir* tus residuos, tu modelo dejó estructura por fuera.

Dónde se concentra el error (I): por cuantiles de y



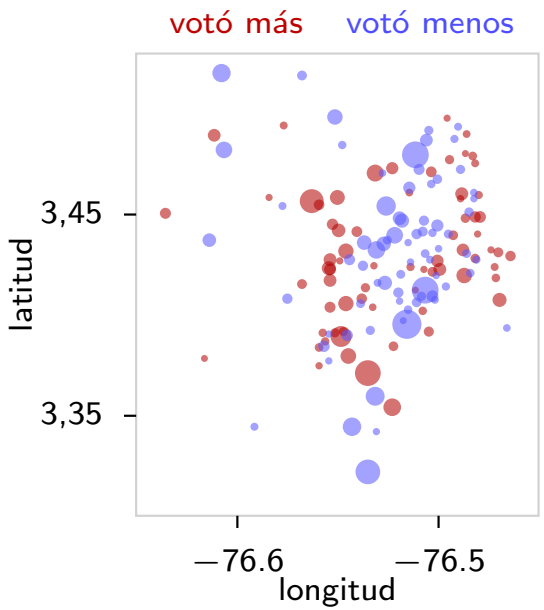
- Calculen el RMSE **por decil** (o quintil) de y en la prueba. La U es la huella de la compresión: el modelo falla más en los extremos.
- Hoy, por quintiles: 9,8 abajo (puestos que votan 54%), 5,0, 4,3 y 4,7 en el centro, 8,3 arriba (84%). Los casi unánimes son *justo* los que una campaña quiere reconocer.
- Los avalúos automáticos reportan el R^2 por cuartil de precio por lo mismo: la métrica agregada esconde las colas.

Dos remedios que veremos

Más flexibilidad donde la relación se curva (sesión 5) y, a veces, otra pérdida: si errar en la cola alta cuesta más, el MSE simétrico no es el objetivo.

Dónde se concentra el error (II): subgrupos y mapa

La misma pregunta, cortando por **quién** y por **dónde**



- **En el mapa:** los residuos de la recta en los 143 puestos de Cali (el tamaño del punto es el error). Las manchas de un mismo signo delatan variables omitidas de la *localización*: por eso la validación con datos espaciales pide cuidado (sesión 3).
- **Por subgrupo:** RMSE por municipio, por zona (cabecera o rural), por estrato. Un buen RMSE global que falla en un grupo es un problema de **equidad** además de precisión (sesiones 4 y 6).

La costumbre que vale la pena adquirir

Después de la tabla de métricas, las figuras: predicho vs. observado, los residuos contra lo que se sospeche, y el error por decil de y y por el subgrupo (o el mapa) que le importa a la pregunta.

Siempre contra una referencia (*baseline*)

Una métrica sola no dice si el modelo es bueno. Tres comparaciones que nunca faltan:

1. **La media** (o la mediana): el modelo que no usa x. Si no le ganan, no hay señal aprendible. Hoy: predecir 69% para todos da un RMSE de 11,0; la recta, 6,8.
2. **El modelo simple**: OLS con las variables obvias; todo lo demás debe justificar su complejidad frente a él. La recta de hoy es ese modelo.
3. **La regla vigente**: el avalúo catastral, el Sisbén, el pronóstico del analista. Para una campaña, *lo que pasó la vez anterior*: el voto de 2018 en el mismo puesto. Tal cual, 14,1 (Petro creció 11 puntos); con una recta que corrige el nivel, 8,4; la recta con la educación en esos 319 puestos, 7,2. Hay que predecir mejor que lo que ya se usa.

Cómo se reporta

Una tabla con una fila por modelo y una columna por métrica, todas calculadas en la *misma* prueba, con la referencia en la primera fila. Sin esa fila, "RMSE 6,8" no se puede leer. La nuestra: siguiente diapositiva. Y se hereda cada semana.

La tabla canónica de hoy

Toda la parte 1 en una tabla: ocho modelos, la misma prueba (86 puestos), tres métricas y la referencia

Modelo	RMSE dentro	RMSE prueba	MAE prueba	R^2 prueba
M0: media del entrenamiento (69,1)	12,2	11,0	8,9	0,00
M1: recta (educación superior)	7,3	6,8	5,4	0,62
M3: cúbica	7,1	6,9	5,5	0,61
M12: grado 12	7,0	6,9	5,5	0,61
M9: nueve variables	6,8	6,8	5,1	0,63
k-NN en el mapa, $k = 1$	0,0	8,9	6,8	0,35
k-NN en el mapa, $k = 5$	6,4	8,2	6,2	0,44
k-NN en el mapa, $k = 25$	9,7	8,6	6,8	0,39

- La primera fila es la referencia: sin ella, "6,8" no dice nada. La recta evita el 62% del error de la media; ocho variables más, la cúbica y el grado 12 no añaden nada en la prueba. **A igual error, la más simple: la campeona de hoy es la recta.**
- $k = 1$: el menor error **dentro**, el peor **fuera** (regla de oro #1). Y los vecinos pierden contra la recta: la educación vale más que la ubicación.
- **La regla vigente** (el voto de 2018 en el mismo puesto, corregido con una recta): 8,4. El censo le gana al pasado.

1 La regresión simple como máquina de predecir

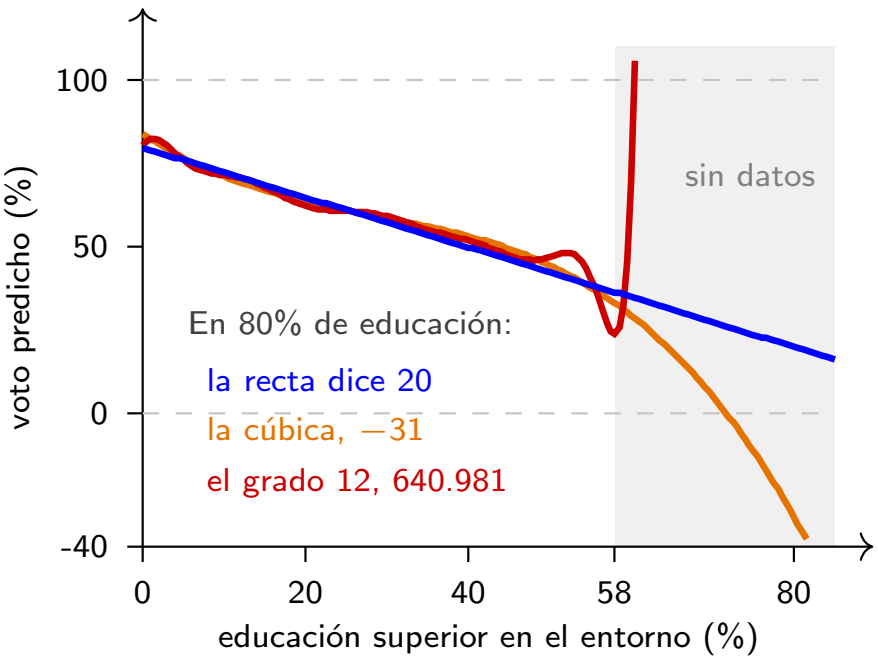
2 Más flexible que la recta, con una variable

3 La regresión múltiple

4 Después de predecir: entender qué predice el modelo

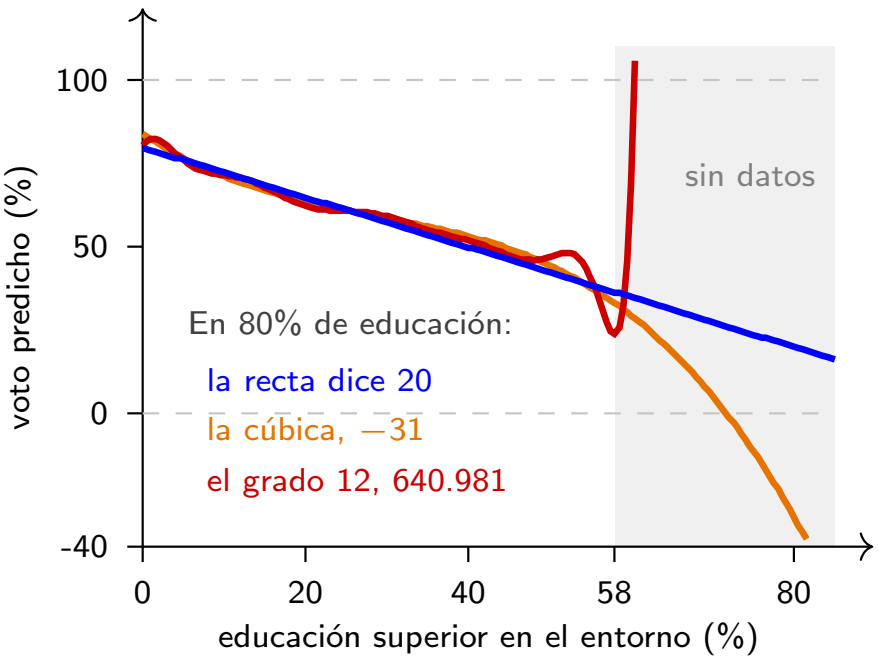
5 Cierre

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; *k*-NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola "razonablemente" sólo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar. Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Extrapolación: predecir donde no hay datos



- Fuera del rango de entrenamiento ningún modelo *sabe*: el polinomio se dispara; k-NN y los árboles se quedan **planos** en el último valor.
- La recta extrapola "razonablemente" sólo si la relación sigue siendo lineal allá afuera, cosa que los datos no pueden confirmar. Los *splines naturales* imponen linealidad en las colas: un compromiso explícito.

Regla

Reporten el **rango** de los predictores en el entrenamiento y marquen las predicciones fuera de él: un modelo entrenado con entornos de 0 a 58% de educación superior no sabe nada de uno con 80% (hoy: la recta dice 20, la cúbica −31 y el grado 12, 640.981).

La prueba de fuego: la recta no viaja

Hasta aquí la recta jugó de local; la misma recta, aplicada al resto del Valle del Cauca:

Puestos	n	Voto real	Voto predicho	RMSE recta	Desv. de y
Área metropolitana (prueba)	86	70,7	70,3	6,8	11,0
Resto del Valle, cabeceras	169	58,3	71,5	21,2	16,1
Resto del Valle, rural	465	52,4	77,9	33,9	21,8
Buenaventura	83	91,4	75,4	17,6	8,1

- Fuera de las cuatro ciudades la recta predice **peor que la media local**: en el campo dice 78 donde la realidad es 52; en Buenaventura, 75 donde es 91. Las nueve variables mejoran poco (31,8 y 11,1).
- Y no es extrapolación (la educación allá cae *dentro* del rango): cambia la *relación*. Baja educación en Cali es un barrio popular que vota Petro; en el norte del Valle, un corregimiento cafetero que no. En el país, la recta con la educación explica el **0,04%** del voto: Santander vota 20% y Chocó 86% con la misma educación.
- **Con la vivienda de Cali:** la misma tabla canónica es la Parte 1 del Problem Set 1.

La limitación que nos lleva a la sesión 3

Necesitamos todo el país y muchas más variables (regiones, interacciones, todos los bloques). Con cientos de columnas, ¿cómo elegimos sin engañarnos, y cómo validamos cuando los puestos vecinos se parecen?

Recap

1. **La recta como máquina:** el RSS que minimiza es el error *de entrenamiento* (por eso adula); $\hat{y}$ es la **proyección** de y sobre las x; la nota se pone en la **prueba**: RMSE, MAE, R^2 de prueba, relativas a y.
2. **Más flexible con una variable:** los polinomios aquí se abrazan; escalones y *splines* dan flexibilidad local; k-NN quita la fórmula y la **maldición** le pasa cuenta: sin estructura no se aprende en alta dimensión.
3. **Más variables:** la matriz muestra candidatas y gemelas; el criterio es el mismo RSS; el R^2 en muestra nunca baja y por eso no elige variables; las gemelas reparten crédito, no predicción (apéndice A9).
4. **Después de predecir:** predicho vs. observado, los residuos como detector, el error por quintil y por subgrupo o mapa, todo contra una **referencia** y resumido en la **tabla canónica**. El mensaje: entender *qué* es lo que predice el modelo.
5. **Las dos advertencias:** extrapolar (predecir donde no hay datos) y viajar (predecir donde la relación cambia); la segunda abre la sesión 3.

La sesión 8: un paper por área de la economía. Elijan la suya hoy

3 de noviembre: seis presentaciones de 15 minutos, seis áreas distintas

Área	**La pregunta típica**
Economía política	¿Cuánto del voto (o del conflicto) se anticipa con datos del territorio?
Crimen y justicia	¿A quién dejar libre antes del juicio: el juez o el algoritmo?
Salud	¿Dónde se equivoca el médico al asignar exámenes y cuidado?
Desarrollo y pobreza	¿Cómo focalizar la ayuda donde no hay censo (celulares, satélites)?
Trabajo	¿Contratar con la prueba estandarizada o con el olfato del reclutador?
Finanzas y crédito	¿Quién gana y quién pierde cuando una máquina decide el crédito?
Macroeconomía	¿Pronostica mejor la inflación una máquina con cientos de predictores?
Organización industrial	¿Cuánto valen los precios personalizados, y a quién le cuestan?

Hoy se elige el área; los dos candidatos de cada una, con su ficha, están en `literature/`, y la asignación se cierra esta semana. **El guion de los 15 minutos:** la pregunta y la decisión; los datos y la unidad; la referencia; la evaluación fuera de muestra y dónde falla; el resultado; qué método del curso es.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, sección 5.1 (validación cruzada) y secciones 6.2 y 6.4 (Ridge, Lasso y alta dimensión).
  Guía: la figura 5.6 (la curva de CV) y las figuras 6.4 y 6.6 (los caminos de Ridge y Lasso) son las de clase.

Nivelación en R: seguir con los módulos de lectura y escritura de datos y de gestión de datos (enlaces en la sesión 1).

Próxima sesión — validación cruzada y regularización: elegir entre modelos sin gastar la prueba (*k*-fold, la curva de CV, el *pipeline* sin filtraciones, validar por grupos, en el tiempo y en el espacio) y qué hacer con muchos predictores (Ridge, Lasso y Elastic Net, con λ por CV). **Aplicación en R:** los 12.000 puestos del país y las 37 variables del censo: la validación cruzada pliegue a pliegue, Ridge y Lasso con λ por CV, y la escala (estandarizar antes de penalizar).

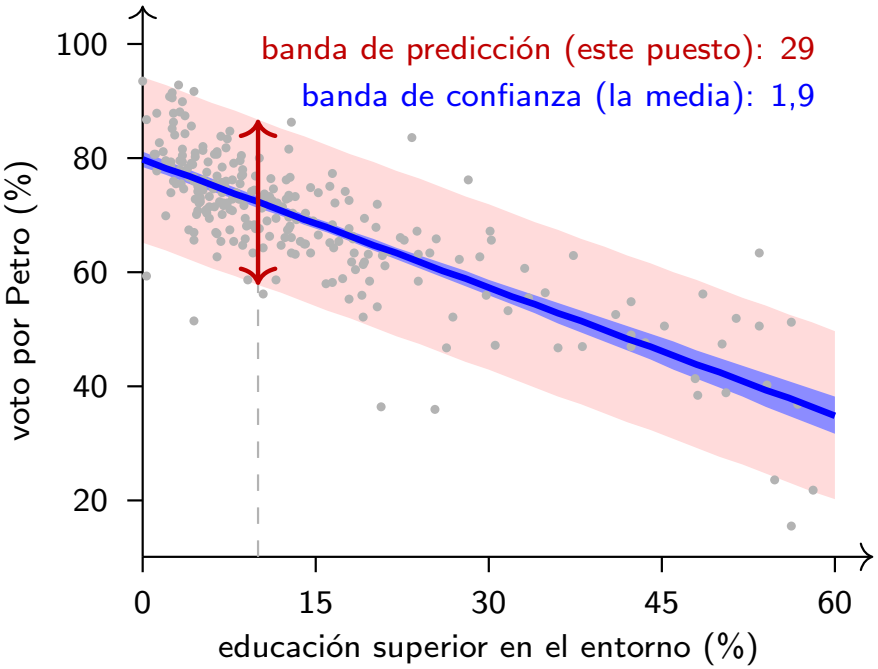
Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 2–3 y 7. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Caps. 2–3 y 5. [ESL]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Working paper. [De donde salen los datos del caso.]
- Los papers candidatos de la sesión 8 están, con su ficha y por área de la economía, en `literature/`.

6 Apéndice: para profundizar

A1. Predecir la media o predecir un dato nuevo

De $\hat{\beta}$ a $\hat{y}_0$: dos intervalos, y sólo uno se cierra con más datos (ISL, pp. 82–83)



Tres errores al predecir $y_0 = f(x_0) + \varepsilon_0$**:**

1. estimar $\hat{\beta}$ con una muestra: reducible, se achica con n;
2. suponer que f es lineal: el sesgo del modelo;
3. ε_0: irreducible, nadie lo predice.

El **intervalo de confianza** cubre la media $f(x_0)$ y sólo carga el primero. El **intervalo de predicción** cubre el voto de *este* puesto y carga además σ^2: siempre más ancho.

Con los 257 puestos de entrenamiento, en un entorno con 10% de educación superior

Ancho del intervalo de confianza: 1,9 puntos; del de predicción: 29,0 ($\approx 4 \times \mathrm{RSE}$). Con sólo 65 puestos: 3,6 y 27,9. La azul se cierra con datos; la roja no: es el techo de la sesión 1, el intervalo que le importa a quien usa la predicción.

A2. Predictores cualitativos

Hasta aquí las x eran números; las categorías entran como columnas de ceros y unos

Una variable con K categorías entra como $K-1$ *dummies*: la zona (cabecera o rural), el municipio, el departamento. Dos lecturas para el predictor:

- La codificación (cuál categoría queda de base) cambia los coeficientes y sus p-valores, **no** las predicciones.
- Lo que sí importa: no dejar categorías con dos o tres observaciones — esos coeficientes son ruido y viajan mal.

En el caso

La recta de hoy no usa la zona ni el municipio a propósito: son justo lo que interrogó el detector de residuos, y lo que la sesión 3 mete al modelo cuando pasemos al país entero.

A3. Interacciones: el efecto depende de dónde

El efecto de una variable puede depender de otra:

$$\text{voto} = \beta_0 + \beta_1\,\text{educ} + \beta_2\,\text{rural} + \beta_3\,(\text{educ} \times \text{rural}) + \varepsilon$$

La educación superior mueve el voto distinto en la cabecera y en el campo (y, veremos, en Cali y en el Pacífico): sin la interacción, la recta se equivoca *sistemáticamente* en ambos.

- Regla jerárquica (ISL): si entra la interacción, entran los dos efectos principales, significativos o no.
- Son **perillas de flexibilidad**: cada una añade parámetros y baja el sesgo a costa de varianza. Con 17 variables y 33 departamentos son cientos de columnas: elegirlas a mano no escala. El Lasso (sesión 3) las filtra; los árboles (sesión 5) las descubren solos.
- **Regla práctica:** añadan las que la economía sugiera (educación $\times$ región, edad $\times$ zona) y dejen que la **prueba** diga si valieron la pena.

A4. Transformaciones: el logaritmo y los polinomios

Log de y: con precios, ingresos o ventas, modelar $\log y$ estabiliza la varianza y convierte efectos multiplicativos en aditivos. Ojo al volver: $\exp(\widehat{\log y})$ predice la *mediana*, no la media; el error se reporta en la escala que le importa al usuario (pesos, no logaritmos). Nuestra y es una proporción: la recta puede predecir fuera de 0–100 (lo veremos al extrapolar).

Polinomios: $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_d x^d + \varepsilon$ sigue siendo **lineal en los parámetros**: es OLS sobre nuevas columnas.

- El grado d es la perilla de complejidad de la sesión 1: más grado, menos sesgo y más varianza.
- Un polinomio es **global**: para curvar la relación en los entornos de baja educación, cambia también su forma en los de alta. Y fuera del rango de los datos, explota.

A5. La base de un *spline*: cómo se construyen las columnas

Polinomio cúbico por tramos con un nodo en ξ: dos cúbicas distintas a cada lado de ξ, unidas de modo que la función, su primera y su segunda derivada sean continuas en ξ.

La base de potencias truncadas lo logra con una sola columna extra:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 \, (x - \xi)_+^3 + \varepsilon, \qquad (x - \xi)_+^3 = \max\{0, (x - \xi)^3\}.$$

Antes de ξ la columna vale cero; después añade una cúbica que arranca en cero con derivadas cero: el empalme es suave por construcción.

- Con K nodos: $K + 4$ columnas, es decir, $K + 4$ grados de libertad. Todo se estima por OLS.
- Un **spline natural** impone linealidad más allá de los nodos extremos y ahorra 4 grados de libertad: menos varianza en las colas, donde hay pocos datos.
- En R, `splines::ns(x, df = 4)` construye la base y se usa dentro de `lm()`. Los *B-splines* son otra base, numéricamente más estable, del mismo espacio.

A6. Lineal vs. k-NN: ¿cuándo gana cada uno?

ISL, sección 3.5: la única del capítulo con el error de prueba en los ejes

- Si f es (casi) lineal, **OLS gana**: estima dos números; k-NN gasta los datos en dibujar una forma que no necesitaba. Si f es no lineal y p es pequeño, k-**NN puede ganar**.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado** (ISL, Fig. 3.20: k-NN gana con $p \leq 2$; la recta, desde 4). Pocas observaciones por predictor favorecen al paramétrico.
- **Hoy:** la recta con una buena variable, 6,8; los vecinos del mapa, 8,2 (la tabla canónica de la parte 4). Con 257 puestos, la educación vale más que la ubicación; en la sesión 3, con el país, la cuenta cambia.

A6. Lineal vs. k-NN: ¿cuándo gana cada uno?

ISL, sección 3.5: la única del capítulo con el error de prueba en los ejes

- Si f es (casi) lineal, **OLS gana**: estima dos números; k-NN gasta los datos en dibujar una forma que no necesitaba. Si f es no lineal y p es pequeño, **k-NN puede ganar**.
- A medida que p crece, **OLS vuelve a ganar aunque esté mal especificado** (ISL, Fig. 3.20: k-NN gana con $p \leq 2$; la recta, desde 4). Pocas observaciones por predictor favorecen al paramétrico.
- **Hoy:** la recta con una buena variable, 6,8; los vecinos del mapa, 8,2 (la tabla canónica de la parte 4). Con 257 puestos, la educación vale más que la ubicación; en la sesión 3, con el país, la cuenta cambia.

La regla de comparación del curso

Nunca se sabe a priori. Se ajustan los dos en el mismo conjunto de entrenamiento, se evalúan en el *mismo* conjunto de prueba con la *misma* métrica, y gana el que gana. Esa tabla comparativa es el producto central de cada aplicación del curso. Moraleja: con 257 puestos y pocas variables, la **estructura es información**. El k se elige sin tocar la prueba: sesión 3.

A7. R^2 de prueba no es el R^2 de Econometría

El R^2 en muestra de la parte 1, reencarnado donde no puede hacer trampa

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el grado 12 tenía el R^2 más alto de los tres.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra una referencia explícita: predecir $\bar{y}_{\text{train}}$ para todos.

A7. R^2 de prueba no es el R^2 de Econometría

El R^2 en muestra de la parte 1, reencarnado donde no puede hacer trampa

El R^2 que conocen (en muestra):

- Nunca baja al añadir variables.
- Está entre 0 y 1 por construcción.
- Mide ajuste, no capacidad de predecir: el grado 12 tenía el R^2 más alto de los tres.

El R^2 de prueba:

- **Puede bajar** al añadir variables: es la curva U.
- **Puede ser negativo**: el modelo predice peor que la media del entrenamiento.
- Compara contra una referencia explícita: predecir $\bar{y}_{\text{train}}$ para todos.

Cómo leerlo, con los puestos

La recta: R^2 de prueba $= 0{,}62$: sobre puestos que nunca vio, su error cuadrático es el 38% del de quien predice el promedio; $k = 1$ evita sólo el 35%. Y puede ser negativo: el grado 12 de la sesión 1 dio $-0{,}90$ en los avisos nuevos, peor que la media. Es una *reducción de error*, no una "bondad de ajuste".

Detalle de cuidadosos: el denominador usa $\bar{y}$ de **entrenamiento**, y las métricas se calculan **una sola vez** sobre la prueba.

A8. La cuenta de la compresión: $\mathrm{Var}(Y) = \mathrm{Var}(f(X)) + \sigma^2$

1. Ley de la varianza total: para cualquier Y y X,

$$\mathrm{Var}(Y) = \mathbb{E}\big[\mathrm{Var}(Y \mid X)\big] + \mathrm{Var}\big(\mathbb{E}[Y \mid X]\big).$$

2. Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon \mid X] = 0$ y $\mathrm{Var}(\varepsilon \mid X) = \sigma^2$: $\mathbb{E}[Y \mid X] = f(X)$ y $\mathrm{Var}(Y \mid X) = \sigma^2$, luego

$$\mathrm{Var}(Y) = \sigma^2 + \mathrm{Var}\big(f(X)\big) \;\geq\; \mathrm{Var}\big(f(X)\big).$$

3. Calibración y pendiente: si $\hat{y}$ está bien calibrado, $\mathbb{E}[Y \mid \hat{y}] = \hat{y}$, de modo que en la regresión de y sobre $\hat{y}$ la pendiente es 1 y el intercepto 0. La regresión *inversa*, de $\hat{y}$ sobre y, tiene pendiente $\mathrm{Cov}(y, \hat{y})/\mathrm{Var}(y) = \mathrm{Var}(\hat{y})/\mathrm{Var}(y) \leq 1$: esa es la compresión que se ve al dibujar $\hat{y}$ contra y.

Uso

La pendiente de y sobre $\hat{y}$ en la prueba es un test de calibración gratuito: por debajo de 1 hay sobreajuste (predicciones demasiado dispersas); por encima, subajuste. Vuelve en la sesión 4 para probabilidades.

A9. Los seis problemas, releídos para predecir

ISL, sección 3.3.3: lo que dañan en $\hat{\beta}$ y lo que dañan en $\hat{y}$

Problema	**Qué daña en $\hat{\beta}$**	**¿Y para $\hat{y}$?**
No linealidad	todo lo que dicen los coeficientes	**Sí**, el único que ISL nombra: variables nuevas o métodos flexibles
Errores correlacionados	errores estándar subestimados	El punto no cambia; se daña la **validación**: puestos del mismo municipio se parecen (sesión 3)
Varianza no constante	errores estándar y pruebas	Los intervalos de predicción, no el punto
Atípicos	el RSE y todo lo que depende de él	La recta casi no se mueve; dañan las **métricas** y avisan de un predictor que falta
Alto apalancamiento	un par de puntos mueve el ajuste	**Sí**: se mueven todas las predicciones ("un dato nuevo cambia la curva")
Colinealidad	errores estándar enormes, t que se hunden	**Casi nada**: quitar la variable colineal deja el ajuste intacto (ISL, p. 103); Ridge la convierte en ventaja (sesión 3)

En alta dimensión (ISL, sección 6.4.4)

Nunca se sabe qué variables son "las verdaderas": otro subconjunto predice igual de bien. El modelo sirve; leerlo como si fuera único, no.