

Big Data y Machine Learning para Economía Aplicada

Week 03: Modelos Lineales de Alta Dimensión — La Teoría del Lasso

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 23, 2026

Previously...

- La **validación cruzada** nos da un estimador honesto del error de generalización — y con ella giramos perillas.
- **Ridge** = $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$: encoge proporcionalmente, estabiliza, nunca anula.
- **Lasso**: el valor absoluto produce **ceros exactos** — lo vimos con la geometría del diamante y el umbral suave $S_\lambda(z) = \text{sign}(z)(|z| - \lambda)_+ \dots$ pero ambas fueron *imágenes*, no demostraciones.

Previously...

- La **validación cruzada** nos da un estimador honesto del error de generalización — y con ella giramos perillas.
- **Ridge** = $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$: encoge proporcionalmente, estabiliza, nunca anula.
- **Lasso**: el valor absoluto produce **ceros exactos** — lo vimos con la geometría del diamante y el umbral suave $S_\lambda(z) = \text{sign}(z)(|z| - \lambda)_+ \dots$ pero ambas fueron *imágenes*, no demostraciones.

Hoy: abrir el capó (la sesión más matemática del curso)

- 1 ¿Por qué exactamente la alta dimensión rompe a OLS?
- 2 ¿De dónde salen *de verdad* los ceros del Lasso? (KKT y subgradientes)
- 3 ¿Cómo se calcula? (*coordinate descent*, LARS)
- 4 ¿Cuándo recupera las variables verdaderas? (sparsity, irrepresentabilidad)
- 5 Y el puente a lo que más nos importa como economistas: usar el Lasso para **inferencia causal** (*post-double-selection*).

- 1 ¿Por qué la alta dimensión rompe a OLS?
- 2 El Lasso como problema de optimización
- 3 Algoritmos: coordinate descent y LARS
- 4 ¿Cuándo el Lasso recupera la verdad?
- 5 Del Lasso a la inferencia causal: post-double-selection

Los tres regímenes de p y n

- 1 **Clásico** (p fijo, $n \rightarrow \infty$): el mundo de Econometría I. OLS es consistente, asintóticamente normal; todo funciona.

Los tres regímenes de p y n

- 1 **Clásico** (p fijo, $n \rightarrow \infty$): el mundo de Econometría I. OLS es consistente, asintóticamente normal; todo funciona.
- 2 p **comparable a** n : OLS “funciona” pero tiembla — varianzas enormes, coeficientes inestables.

Los tres regímenes de p y n

- 1 **Clásico** (p fijo, $n \rightarrow \infty$): el mundo de Econometría I. OLS es consistente, asintóticamente normal; todo funciona.
- 2 p **comparable a** n : OLS “funciona” pero tiembla — varianzas enormes, coeficientes inestables.
- 3 $p \gg n$: OLS ni siquiera está definido de manera única.

Los tres regímenes de p y n

- 1 **Clásico** (p fijo, $n \rightarrow \infty$): el mundo de Econometría I. OLS es consistente, asintóticamente normal; todo funciona.
- 2 p **comparable a** n : OLS “funciona” pero tiembla — varianzas enormes, coeficientes inestables.
- 3 $p \gg n$: OLS ni siquiera está definido de manera única.

¿Y de dónde salen tantos predictores en economía?

- Datos administrativos y *scanner data*: miles de características por unidad.
- Texto e imágenes convertidos en variables (sesiones 8–9).
- **Flexibilidad que nosotros mismos creamos**: polinomios, *dummies* finas e **interacciones**. Con 30 variables base y sus interacciones de a pares:
 $30 + \binom{30}{2} = 465$ regresores. Agreguen cuadrados y triples y p explota.

Los tres regímenes de p y n

- 1 **Clásico** (p fijo, $n \rightarrow \infty$): el mundo de Econometría I. OLS es consistente, asintóticamente normal; todo funciona.
- 2 p **comparable a** n : OLS “funciona” pero tiembla — varianzas enormes, coeficientes inestables.
- 3 $p \gg n$: OLS ni siquiera está definido de manera única.

¿Y de dónde salen tantos predictores en economía?

- Datos administrativos y *scanner data*: miles de características por unidad.
- Texto e imágenes convertidos en variables (sesiones 8–9).
- **Flexibilidad que nosotros mismos creamos**: polinomios, *dummies* finas e **interacciones**. Con 30 variables base y sus interacciones de a pares:
 $30 + \binom{30}{2} = 465$ regresores. Agreguen cuadrados y triples y p explota.

El punto

La alta dimensión no es exótica: aparece apenas uno quiere controlar *flexiblemente* por covariables — exactamente lo que un economista aplicado hace.

Qué falla, exactamente (I): $p > n$

Con $p > n$, la matriz $\mathbf{X}'\mathbf{X}$ ($p \times p$) tiene rango a lo sumo $n < p$:

- $\mathbf{X}'\mathbf{X}$ es **singular**: la inversa no existe, las ecuaciones normales tienen **infinitas soluciones**.

Qué falla, exactamente (I): $p > n$

Con $p > n$, la matriz $\mathbf{X}'\mathbf{X}$ ($p \times p$) tiene rango a lo sumo $n < p$:

- $\mathbf{X}'\mathbf{X}$ es **singular**: la inversa no existe, las ecuaciones normales tienen **infinitas soluciones**.
- Existen (infinitos) β que ajustan los datos **perfectamente**: $\text{RSS} = 0$, $R^2 = 1$... sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura.

Qué falla, exactamente (I): $p > n$

Con $p > n$, la matriz $\mathbf{X}'\mathbf{X}$ ($p \times p$) tiene rango a lo sumo $n < p$:

- $\mathbf{X}'\mathbf{X}$ es **singular**: la inversa no existe, las ecuaciones normales tienen **infinitas soluciones**.
- Existen (infinitos) β que ajustan los datos **perfectamente**: $\text{RSS} = 0$, $R^2 = 1$... sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura.
- Y no hay grados de libertad para estimar σ^2 : la inferencia clásica muere con el ajuste perfecto.

Qué falla, exactamente (I): $p > n$

Con $p > n$, la matriz $\mathbf{X}'\mathbf{X}$ ($p \times p$) tiene rango a lo sumo $n < p$:

- $\mathbf{X}'\mathbf{X}$ es **singular**: la inversa no existe, las ecuaciones normales tienen **infinitas soluciones**.
- Existen (infinitos) β que ajustan los datos **perfectamente**: $\text{RSS} = 0$, $R^2 = 1$... sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura.
- Y no hay grados de libertad para estimar σ^2 : la inferencia clásica muere con el ajuste perfecto.

Pregunta para la sala

Si $p > n$ hace que *cualquier* y sea ajustable a la perfección, ¿qué información puede haber en “ajustar bien”?

Qué falla, exactamente (I): $p > n$

Con $p > n$, la matriz $\mathbf{X}'\mathbf{X}$ ($p \times p$) tiene rango a lo sumo $n < p$:

- $\mathbf{X}'\mathbf{X}$ es **singular**: la inversa no existe, las ecuaciones normales tienen **infinitas soluciones**.
- Existen (infinitos) β que ajustan los datos **perfectamente**: $\text{RSS} = 0$, $R^2 = 1$... sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura.
- Y no hay grados de libertad para estimar σ^2 : la inferencia clásica muere con el ajuste perfecto.

Pregunta para la sala

Si $p > n$ hace que *cualquier* y sea ajustable a la perfección, ¿qué información puede haber en “ajustar bien”?

Ninguna. En alta dimensión, el ajuste dentro de muestra pierde todo su contenido informativo: solo el desempeño *out-of-sample* y la estructura (p. ej. sparsity) pueden discriminar modelos.

Qué falla, exactamente (II): $p \approx n$ y colinealidad

Aun con $p < n$, si hay predictores muy correlacionados, $\mathbf{X}'\mathbf{X}$ está *cerca* de singular. Descompongamos: sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ con autovectores v_j .

Qué falla, exactamente (II): $p \approx n$ y colinealidad

Aun con $p < n$, si hay predictores muy correlacionados, $\mathbf{X}'\mathbf{X}$ está *cerca* de singular. Descompongamos: sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ con autovectores v_j .

La varianza de OLS en la dirección v_j :

$$\text{Var}(v_j' \hat{\beta}) = \sigma^2 v_j' (\mathbf{X}'\mathbf{X})^{-1} v_j = \frac{\sigma^2}{d_j}$$

Qué falla, exactamente (II): $p \approx n$ y colinealidad

Aun con $p < n$, si hay predictores muy correlacionados, $\mathbf{X}'\mathbf{X}$ está *cerca* de singular. Descompongamos: sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ con autovectores v_j .

La varianza de OLS en la dirección v_j :

$$\text{Var}(v_j' \hat{\beta}) = \sigma^2 v_j' (\mathbf{X}'\mathbf{X})^{-1} v_j = \frac{\sigma^2}{d_j}$$

- En direcciones con d_j **pequeño** (combinaciones de predictores casi colineales), la varianza **explota**: $\sigma^2/d_j \rightarrow \infty$.
- Interpretación: los datos casi no varían en esa dirección $\Rightarrow$ casi no informan sobre ella $\Rightarrow$ OLS “adivina” con enorme ruido.

Qué falla, exactamente (II): $p \approx n$ y colinealidad

Aun con $p < n$, si hay predictores muy correlacionados, $\mathbf{X}'\mathbf{X}$ está *cerca* de singular. Descompongamos: sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ con autovectores v_j .

La varianza de OLS en la dirección v_j :

$$\text{Var}(v_j' \hat{\beta}) = \sigma^2 v_j' (\mathbf{X}'\mathbf{X})^{-1} v_j = \frac{\sigma^2}{d_j}$$

- En direcciones con d_j **pequeño** (combinaciones de predictores casi colineales), la varianza **explota**: $\sigma^2/d_j \rightarrow \infty$.
- Interpretación: los datos casi no varían en esa dirección $\Rightarrow$ casi no informan sobre ella $\Rightarrow$ OLS “adivina” con enorme ruido.
- Y recuerden la solución de Ridge: reemplazar d_j por $d_j + \lambda$ — amortiguar exactamente las direcciones enfermas.

Qué falla, exactamente (II): $p \approx n$ y colinealidad

Aun con $p < n$, si hay predictores muy correlacionados, $\mathbf{X}'\mathbf{X}$ está *cerca* de singular. Descompongamos: sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ con autovectores v_j .

La varianza de OLS en la dirección v_j :

$$\text{Var}(v_j' \hat{\beta}) = \sigma^2 v_j' (\mathbf{X}'\mathbf{X})^{-1} v_j = \frac{\sigma^2}{d_j}$$

- En direcciones con d_j **pequeño** (combinaciones de predictores casi colineales), la varianza **explota**: $\sigma^2/d_j \rightarrow \infty$.
- Interpretación: los datos casi no varían en esa dirección $\Rightarrow$ casi no informan sobre ella $\Rightarrow$ OLS “adivina” con enorme ruido.
- Y recuerden la solución de Ridge: reemplazar d_j por $d_j + \lambda$ — amortiguar exactamente las direcciones enfermas.

Moraleja

El enemigo no es p grande *per se*: es la **información por parámetro**. Alta dimensión = muchos parámetros persiguiendo poca variación independiente.

La bendición oculta: sparsity

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones, sin salida.

La bendición oculta: sparsity

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones, sin salida.

El supuesto que salva el día:

β^0 es **esparso**: solo $s \ll n$ de sus p componentes son $\neq 0$

(o aproximadamente esparso: pocos grandes, el resto despreciables).

La bendición oculta: sparsity

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones, sin salida.

El supuesto que salva el día:

β^0 es **esparso**: solo $s \ll n$ de sus p componentes son $\neq 0$

(o aproximadamente esparso: pocos grandes, el resto despreciables).

- Con sparsity, los “verdaderos” grados de libertad son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? Búsqueda exacta = 2^p (imposible); el Lasso la vuelve **convexa**.

La bendición oculta: sparsity

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones, sin salida.

El supuesto que salva el día:

β^0 es **esparso**: solo $s \ll n$ de sus p componentes son $\neq 0$

(o aproximadamente esparso: pocos grandes, el resto despreciables).

- Con sparsity, los “verdaderos” grados de libertad son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? Búsqueda exacta = 2^p (imposible); el Lasso la vuelve **convexa**.
- ¿Es creíble en economía? A menudo sí como aproximación: de cientos de controles posibles, unos pocos capturan lo esencial. Pero es un **supuesto**, no un teorema — y volveremos a él críticamente.

La bendición oculta: sparsity

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones, sin salida.

El supuesto que salva el día:

β^0 es **esparso**: solo $s \ll n$ de sus p componentes son $\neq 0$

(o aproximadamente esparso: pocos grandes, el resto despreciables).

- Con sparsity, los “verdaderos” grados de libertad son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? Búsqueda exacta $= 2^p$ (imposible); el Lasso la vuelve **convexa**.
- ¿Es creíble en economía? A menudo sí como aproximación: de cientos de controles posibles, unos pocos capturan lo esencial. Pero es un **supuesto**, no un teorema — y volveremos a él críticamente.

El programa de hoy

Entender al Lasso como *la relajación convexa* del problema de búsqueda esparsa — y estudiar cuándo esa relajación devuelve la respuesta correcta.

- 1 ¿Por qué la alta dimensión rompe a OLS?
- 2 El Lasso como problema de optimización
- 3 Algoritmos: coordinate descent y LARS
- 4 ¿Cuándo el Lasso recupera la verdad?
- 5 Del Lasso a la inferencia causal: post-double-selection

Dos formas del mismo problema

Forma penalizada (la que usamos hasta ahora; convención con $\frac{1}{2}$ para derivadas limpias):

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1$$

Dos formas del mismo problema

Forma penalizada (la que usamos hasta ahora; convención con $\frac{1}{2}$ para derivadas limpias):

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1$$

Forma restringida:

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeto a} \quad \|\beta\|_1 \leq t$$

Dos formas del mismo problema

Forma penalizada (la que usamos hasta ahora; convención con $\frac{1}{2}$ para derivadas limpias):

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1$$

Forma restringida:

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeto a} \quad \|\beta\|_1 \leq t$$

- Son **equivalentes**: para cada $\lambda > 0$ existe un t (y viceversa) con la misma solución. El puente es el **Lagrangiano**: λ es el multiplicador de la restricción $\|\beta\|_1 \leq t$.
- La forma restringida dio la **geometría** (el diamante); la penalizada es la que se **computa**.

Dos formas del mismo problema

Forma penalizada (la que usamos hasta ahora; convención con $\frac{1}{2}$ para derivadas limpias):

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1$$

Forma restringida:

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeto a} \quad \|\beta\|_1 \leq t$$

- Son **equivalentes**: para cada $\lambda > 0$ existe un t (y viceversa) con la misma solución. El puente es el **Lagrangiano**: λ es el multiplicador de la restricción $\|\beta\|_1 \leq t$.
- La forma restringida dio la **geometría** (el diamante); la penalizada es la que se **computa**.
- Ambas son **convexas**: función objetivo convexa, región factible convexa $\Rightarrow$ todo mínimo local es global, y las condiciones de primer orden **caracterizan** la solución.

Dos formas del mismo problema

Forma penalizada (la que usamos hasta ahora; convención con $\frac{1}{2}$ para derivadas limpias):

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1$$

Forma restringida:

$$\hat{\beta}^L = \arg \min_{\beta} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeto a} \quad \|\beta\|_1 \leq t$$

- Son **equivalentes**: para cada $\lambda > 0$ existe un t (y viceversa) con la misma solución. El puente es el **Lagrangiano**: λ es el multiplicador de la restricción $\|\beta\|_1 \leq t$.
- La forma restringida dio la **geometría** (el diamante); la penalizada es la que se **computa**.
- Ambas son **convexas**: función objetivo convexa, región factible convexa $\Rightarrow$ todo mínimo local es global, y las condiciones de primer orden **caracterizan** la solución.

Por qué esto importa

Repaso exprés: KKT (el Lagrangiano de micro, con desigualdades)

Para un problema convexo $\min_{\beta} f(\beta)$ s.a. $g(\beta) \leq 0$, con $\mathcal{L} = f + \mu g$, la solución $\hat{\beta}$ cumple:

- 1 **Estacionariedad:** $\nabla f(\hat{\beta}) + \mu \nabla g(\hat{\beta}) = 0$.
- 2 **Factibilidad primal:** $g(\hat{\beta}) \leq 0$; **dual:** $\mu \geq 0$.
- 3 **Holgura complementaria:** $\mu \cdot g(\hat{\beta}) = 0$ (o la restricción no ata, o el precio es positivo).

Repaso exprés: KKT (el Lagrangiano de micro, con desigualdades)

Para un problema convexo $\min_{\beta} f(\beta)$ s.a. $g(\beta) \leq 0$, con $\mathcal{L} = f + \mu g$, la solución $\hat{\beta}$ cumple:

- ❶ **Estacionariedad:** $\nabla f(\hat{\beta}) + \mu \nabla g(\hat{\beta}) = 0$.
 - ❷ **Factibilidad primal:** $g(\hat{\beta}) \leq 0$; **dual:** $\mu \geq 0$.
 - ❸ **Holgura complementaria:** $\mu \cdot g(\hat{\beta}) = 0$ (o la restricción no ata, o el precio es positivo).
- Es el mismo aparato de la maximización de utilidad con restricción de presupuesto: $\mu =$ precio sombra de la restricción $\|\beta\|_1 \leq t$; aquí ese precio se llama λ .
 - En problemas convexos, KKT no es solo necesario: es **suficiente** — quien cumple KKT es la solución.

Repaso exprés: KKT (el Lagrangiano de micro, con desigualdades)

Para un problema convexo $\min_{\beta} f(\beta)$ s.a. $g(\beta) \leq 0$, con $\mathcal{L} = f + \mu g$, la solución $\hat{\beta}$ cumple:

- ❶ **Estacionariedad:** $\nabla f(\hat{\beta}) + \mu \nabla g(\hat{\beta}) = 0$.
 - ❷ **Factibilidad primal:** $g(\hat{\beta}) \leq 0$; **dual:** $\mu \geq 0$.
 - ❸ **Holgura complementaria:** $\mu \cdot g(\hat{\beta}) = 0$ (o la restricción no ata, o el precio es positivo).
- Es el mismo aparato de la maximización de utilidad con restricción de presupuesto: $\mu =$ precio sombra de la restricción $\|\beta\|_1 \leq t$; aquí ese precio se llama λ .
 - En problemas convexos, KKT no es solo necesario: es **suficiente** — quien cumple KKT es la solución.

El obstáculo


La estacionariedad pide $\nabla \dots$ pero $\|\beta\|_1 = \sum_j |\beta_j|$ **no es diferenciable** en $\beta_j = 0$ — que es *justo donde ocurre lo interesante*. Necesitamos generalizar la derivada.

El subgradiente: derivadas para funciones con esquinas

Definición. g es un **subgradiente** de una función convexa f en x_0 si

$$f(x) \geq f(x_0) + g(x - x_0) \quad \forall x$$

(la recta con pendiente g por $(x_0, f(x_0))$ queda *debajo* de f). El conjunto de todos: $\partial f(x_0)$.




El subgradiente: derivadas para funciones con esquinas

Definición. g es un **subgradiente** de una función convexa f en x_0 si

$$f(x) \geq f(x_0) + g(x - x_0) \quad \forall x$$

(la recta con pendiente g por $(x_0, f(x_0))$ queda *debajo* de f). El conjunto de todos: $\partial f(x_0)$.



Para el valor absoluto:


$$\partial|\beta_j| = \begin{cases} \{\text{sign}(\beta_j)\} & \text{si } \beta_j \neq 0 \\ [-1, 1] & \text{si } \beta_j = 0 \end{cases}$$

El subgradiente: derivadas para funciones con esquinas

Definición. g es un **subgradiente** de una función convexa f en x_0 si

$$f(x) \geq f(x_0) + g(x - x_0) \quad \forall x$$

(la recta con pendiente g por $(x_0, f(x_0))$ queda *debajo* de f). El conjunto de todos: $\partial f(x_0)$.



Para el valor absoluto:

$$\partial|\beta_j| = \begin{cases} \{\text{sign}(\beta_j)\} & \text{si } \beta_j \neq 0 \\ [-1, 1] & \text{si } \beta_j = 0 \end{cases}$$

Condición de óptimo generalizada: $\hat{\beta}$ minimiza f convexa $\iff 0 \in \partial f(\hat{\beta})$.

Las condiciones de optimalidad del Lasso

Aplicamos $0 \in \partial \left[\frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right]$. El primer término es diferenciable (gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$); el segundo aporta el subgradiente:

Las condiciones de optimalidad del Lasso

Aplicamos $0 \in \partial \left[\frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right]$. El primer término es diferenciable (gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$); el segundo aporta el subgradiente:

$$\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j \in \partial |\hat{\beta}_j| \quad \forall j$$

Las condiciones de optimalidad del Lasso

Aplicamos $0 \in \partial \left[\frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right]$. El primer término es diferenciable (gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$); el segundo aporta el subgradiente:

$$\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j \in \partial |\hat{\beta}_j| \quad \forall j$$

Leyendo por casos:

$\begin{aligned} \hat{\beta}_j \neq 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda \operatorname{sign}(\hat{\beta}_j) \\ \hat{\beta}_j = 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) \leq \lambda \end{aligned}$

Las condiciones de optimalidad del Lasso

Aplicamos $0 \in \partial \left[\frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right]$. El primer término es diferenciable (gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$); el segundo aporta el subgradiente:

$$\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j \in \partial|\hat{\beta}_j| \quad \forall j$$

Leyendo por casos:

$\begin{aligned} \hat{\beta}_j \neq 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda \text{sign}(\hat{\beta}_j) \\ \hat{\beta}_j = 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) \leq \lambda \end{aligned}$

- **Interpretación:** $\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})$ es la covarianza del predictor j con el **residuo**. Los predictores **activos** la tienen exactamente en $\pm\lambda$; los **inactivos**, por debajo en valor absoluto.
- λ es un **umbral de mérito**: entras al modelo solo si tu correlación con lo aún no explicado alcanza λ .

Las condiciones de optimalidad del Lasso

Aplicamos $0 \in \partial \left[\frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right]$. El primer término es diferenciable (gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$); el segundo aporta el subgradiente:

$$\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda s_j, \quad s_j \in \partial|\hat{\beta}_j| \quad \forall j$$

Leyendo por casos:

$\begin{aligned} \hat{\beta}_j \neq 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda \operatorname{sign}(\hat{\beta}_j) \\ \hat{\beta}_j = 0 : \quad & \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) \leq \lambda \end{aligned}$

- **Interpretación:** $\mathbf{X}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})$ es la covarianza del predictor j con el **residuo**. Los predictores **activos** la tienen exactamente en $\pm\lambda$; los **inactivos**, por debajo en valor absoluto.
- λ es un **umbral de mérito**: entras al modelo solo si tu correlación con lo aún no explicado alcanza λ .
- **Consecuencia inmediata:** si $\lambda \geq \lambda_{\max} \equiv \max_j |\mathbf{X}'_j \mathbf{y}|$, entonces $\hat{\beta} = 0$ cumple las condiciones: **nadie entra**. El camino de soluciones arranca en $\lambda_{\max}$ — así construye `glmnet` su grilla.

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

1. Si $\hat{\beta} > 0$: la condición de primer orden es $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$.
Coherente con $\hat{\beta} > 0$ solo si $z > \lambda$.

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

1. Si $\hat{\beta} > 0$: la condición de primer orden es $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$.
Coherente con $\hat{\beta} > 0$ solo si $z > \lambda$.
2. Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$. Requiere $z < -\lambda$.

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

1. Si $\hat{\beta} > 0$: la condición de primer orden es $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$.
Coherente con $\hat{\beta} > 0$ solo si $z > \lambda$.
2. Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$. Requiere $z < -\lambda$.
3. Si $\hat{\beta} = 0$: necesitamos $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir $z \in [-\lambda, \lambda]$.

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

1. Si $\hat{\beta} > 0$: la condición de primer orden es $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$. Coherente con $\hat{\beta} > 0$ solo si $z > \lambda$.
2. Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$. Requiere $z < -\lambda$.
3. Si $\hat{\beta} = 0$: necesitamos $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir $z \in [-\lambda, \lambda]$.

Juntando los tres casos:

$$\hat{\beta} = S_{\lambda}(z) = \text{sign}(z) (|z| - \lambda)_+$$

la fórmula que en la sesión 2 mostramos como dibujo, ahora demostrada.

Derivación del umbral suave (el átomo del Lasso)

Caso univariado (o una coordenada con $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$$

1. **Si $\hat{\beta} > 0$:** la condición de primer orden es $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$. Coherente con $\hat{\beta} > 0$ solo si $z > \lambda$.
2. **Si $\hat{\beta} < 0$:** $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$. Requiere $z < -\lambda$.
3. **Si $\hat{\beta} = 0$:** necesitamos $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir $z \in [-\lambda, \lambda]$.

Juntando los tres casos:

$$\hat{\beta} = S_{\lambda}(z) = \text{sign}(z) (|z| - \lambda)_+$$

la fórmula que en la sesión 2 mostramos como dibujo, ahora demostrada.

Por qué la llamamos “el átomo”

Todos los algoritmos modernos del Lasso consisten en aplicar S_{λ} millones de veces, una coordenada a la vez. Eso es lo siguiente.

- 1 ¿Por qué la alta dimensión rompe a OLS?
- 2 El Lasso como problema de optimización
- 3 Algoritmos: coordinate descent y LARS
- 4 ¿Cuándo el Lasso recupera la verdad?
- 5 Del Lasso a la inferencia causal: post-double-selection

Coordinate descent: el algoritmo de `glmnet`

Idea: optimizar **una coordenada a la vez**, dejando las demás fijas — porque el subproblema de una coordenada es el umbral suave que acabamos de derivar.

Coordinate descent: el algoritmo de glmnet

Idea: optimizar **una coordenada a la vez**, dejando las demás fijas — porque el subproblema de una coordenada es el umbral suave que acabamos de derivar.

Algoritmo (con predictores estandarizados, objetivo $\frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1$):

- ❶ Inicializar $\hat{\beta} = 0$.
- ❷ Repetir hasta converger, para $j = 1, \dots, p$:
 - ▶ Residuo parcial: $r^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{X}_k \hat{\beta}_k$
 - ▶ Actualizar: $\hat{\beta}_j \leftarrow S_\lambda(\frac{1}{n} \mathbf{X}_j' r^{(j)})$

Coordinate descent: el algoritmo de glmnet

Idea: optimizar **una coordenada a la vez**, dejando las demás fijas — porque el subproblema de una coordenada es el umbral suave que acabamos de derivar.

Algoritmo (con predictores estandarizados, objetivo $\frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1$):

- ❶ Inicializar $\hat{\beta} = 0$.
- ❷ Repetir hasta converger, para $j = 1, \dots, p$:
 - ▶ Residuo parcial: $r^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{X}_k \hat{\beta}_k$
 - ▶ Actualizar: $\hat{\beta}_j \leftarrow S_\lambda(\frac{1}{n} \mathbf{X}_j' r^{(j)})$

¿Por qué converge? El objetivo es convexo y la parte no diferenciable ($\|\beta\|_1$) es **separable** por coordenadas — la condición exacta bajo la cual el descenso coordenado alcanza el óptimo global (Tseng, 2001).

Coordinate descent: el algoritmo de glmnet

Idea: optimizar **una coordenada a la vez**, dejando las demás fijas — porque el subproblema de una coordenada es el umbral suave que acabamos de derivar.

Algoritmo (con predictores estandarizados, objetivo $\frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1$):

- ❶ Inicializar $\hat{\beta} = 0$.
- ❷ Repetir hasta converger, para $j = 1, \dots, p$:
 - ▶ Residuo parcial: $r^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{X}_k \hat{\beta}_k$
 - ▶ Actualizar: $\hat{\beta}_j \leftarrow S_\lambda(\frac{1}{n} \mathbf{X}'_j r^{(j)})$

¿Por qué converge? El objetivo es convexo y la parte no diferenciable ($\|\beta\|_1$) es **separable** por coordenadas — la condición exacta bajo la cual el descenso coordenado alcanza el óptimo global (Tseng, 2001).

Los trucos de glmnet (Friedman, Hastie & Tibshirani, 2010):

- *Warm starts*: resolver el camino completo de $\lambda_{\max}$ hacia abajo, usando cada solución como arranque de la siguiente.
- *Active set*: iterar solo sobre las variables activas y chequear el resto de vez en cuando (por KKT, la mayoría permanece en cero).

LARS y la forma del camino


Least Angle Regression (Efron, Hastie, Johnstone & Tibshirani, 2004): la alternativa geométrica.

- Arrancar en $\beta = 0$; avanzar en la dirección del predictor más correlacionado con el residuo.
- Cuando otro predictor **alcanza** esa correlación, avanzar en la dirección **equiangular** entre ambos; y así sucesivamente.
- Con una pequeña modificación, produce **exactamente** el camino del Lasso, al costo de un solo OLS.

LARS y la forma del camino

Least Angle Regression (Efron, Hastie, Johnstone & Tibshirani, 2004): la alternativa geométrica.


- Arrancar en $\beta = 0$; avanzar en la dirección del predictor más correlacionado con el residuo.
- Cuando otro predictor **alcanza** esa correlación, avanzar en la dirección **equiangular** entre ambos; y así sucesivamente.
- Con una pequeña modificación, produce **exactamente** el camino del Lasso, al costo de un solo OLS.



LARS y la forma del camino

Least Angle Regression (Efron, Hastie, Johnstone & Tibshirani, 2004): la alternativa geométrica.

- Arrancar en $\beta = 0$; avanzar en la dirección del predictor más correlacionado con el residuo.
- Cuando otro predictor **alcanza** esa correlación, avanzar en la dirección **equiangular** entre ambos; y así sucesivamente.
- Con una pequeña modificación, produce **exactamente** el camino del Lasso, al costo de un solo OLS.



- 1 ¿Por qué la alta dimensión rompe a OLS?
- 2 El Lasso como problema de optimización
- 3 Algoritmos: coordinate descent y LARS
- 4 ¿Cuándo el Lasso recupera la verdad?
- 5 Del Lasso a la inferencia causal: post-double-selection

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso (soporte S , $|S| = s$).

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso (soporte S , $|S| = s$).

❶ **¿Predice bien?** ¿Es pequeño el error $\frac{1}{n}\|\mathbf{X}(\hat{\beta} - \beta^0)\|_2^2$?

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso (soporte S , $|S| = s$).

- 1 **¿Predice bien?** ¿Es pequeño el error $\frac{1}{n}\|\mathbf{X}(\hat{\beta} - \beta^0)\|_2^2$?
- 2 **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso (soporte S , $|S| = s$).

- ❶ **¿Predice bien?** ¿Es pequeño el error $\frac{1}{n}\|\mathbf{X}(\hat{\beta} - \beta^0)\|_2^2$?
 - ❷ **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?
- La (2) es **mucho** más exigente que la (1): se puede predecir de maravilla con las variables “equivocadas” (proxies correlacionados).
 - Y son relevantes para usos distintos: para **pronosticar**, basta (1); para **interpretar** qué variables importan — o elegir *controles* — quisiéramos (2).

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso (soporte S , $|S| = s$).

- ❶ **¿Predice bien?** ¿Es pequeño el error $\frac{1}{n}\|\mathbf{X}(\hat{\beta} - \beta^0)\|_2^2$?
 - ❷ **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?
- La (2) es **mucho** más exigente que la (1): se puede predecir de maravilla con las variables “equivocadas” (proxies correlacionados).
 - Y son relevantes para usos distintos: para **pronosticar**, basta (1); para **interpretar** qué variables importan — o elegir *controles* — quisiéramos (2).

Lo que sigue

Los dos resultados centrales de la teoría, presentados con su **intuición** (las demostraciones: Wainwright, caps. 7–8, para quien quiera el detalle).

Resultado 1: el precio de la alta dimensión es solo $\log p$

Teorema (informal). Con errores razonables, $\lambda \asymp \sigma \sqrt{\log(p)/n}$, y un diseño no demasiado degenerado en las direcciones esparsas (*restricted eigenvalue*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}$$

Resultado 1: el precio de la alta dimensión es solo $\log p$

Teorema (informal). Con errores razonables, $\lambda \asymp \sigma \sqrt{\log(p)/n}$, y un diseño no demasiado degenerado en las direcciones esparsas (*restricted eigenvalue*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}$$

Cómo leerlo:

- Si conociéramos de antemano las s variables correctas, OLS sobre ellas daría error $\sim \sigma^2 s/n$.

Resultado 1: el precio de la alta dimensión es solo $\log p$

Teorema (informal). Con errores razonables, $\lambda \asymp \sigma \sqrt{\log(p)/n}$, y un diseño no demasiado degenerado en las direcciones esparsas (*restricted eigenvalue*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}$$

Cómo leerlo:

- Si conociéramos de antemano las s variables correctas, OLS sobre ellas daría error $\sim \sigma^2 s/n$.
- El Lasso, **sin saber cuáles son** entre p candidatas, paga solo un factor $\log p$ adicional: el costo de la búsqueda es **logarítmico**.

Resultado 1: el precio de la alta dimensión es solo $\log p$

Teorema (informal). Con errores razonables, $\lambda \asymp \sigma \sqrt{\log(p)/n}$, y un diseño no demasiado degenerado en las direcciones esparsas (*restricted eigenvalue*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}$$

Cómo leerlo:

- Si conociéramos de antemano las s variables correctas, OLS sobre ellas daría error $\sim \sigma^2 s/n$.
- El Lasso, **sin saber cuáles son** entre p candidatas, paga solo un factor $\log p$ adicional: el costo de la búsqueda es **logarítmico**.
- Por eso p puede ser enorme: con $p = 10^6$, $\log p \approx 14$. Lo que de verdad limita es s (cuánta señal hay) y n (cuántos datos).

Resultado 1: el precio de la alta dimensión es solo $\log p$

Teorema (informal). Con errores razonables, $\lambda \asymp \sigma \sqrt{\log(p)/n}$, y un diseño no demasiado degenerado en las direcciones esparsas (*restricted eigenvalue*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}$$

Cómo leerlo:

- Si conociéramos de antemano las s variables correctas, OLS sobre ellas daría error $\sim \sigma^2 s/n$.
- El Lasso, **sin saber cuáles son** entre p candidatas, paga solo un factor $\log p$ adicional: el costo de la búsqueda es **logarítmico**.
- Por eso p puede ser enorme: con $p = 10^6$, $\log p \approx 14$. Lo que de verdad limita es s (cuánta señal hay) y n (cuántos datos).

La condición del diseño, en palabras

Se necesita que la colinealidad no destruya la información *en las direcciones esparsas relevantes*. Es mucho más débil que pedir $\mathbf{X}'\mathbf{X}$ invertible — y por eso el Lasso vive donde OLS muere.

Resultado 2: recuperar el soporte exige mucho más

Para que $\{j : \hat{\beta}_j \neq 0\} = S$ con alta probabilidad se necesita, además:

Resultado 2: recuperar el soporte exige mucho más

Para que $\{j : \hat{\beta}_j \neq 0\} = S$ con alta probabilidad se necesita, además:

- 1 **Señales no minúsculas** (*beta-min*): $\min_{j \in S} |\beta_j^0| \gtrsim \lambda$. Coeficientes verdaderos por debajo del umbral de ruido son indistinguibles de cero — nadie puede encontrarlos.

Resultado 2: recuperar el soporte exige mucho más

Para que $\{j : \hat{\beta}_j \neq 0\} = S$ con alta probabilidad se necesita, además:

- 1 **Señales no minúsculas** (*beta-min*): $\min_{j \in S} |\beta_j^0| \gtrsim \lambda$. Coeficientes verdaderos por debajo del umbral de ruido son indistinguibles de cero — nadie puede encontrarlos.
- 2 **Condición de irrepresentabilidad** (Zhao & Yu, 2006):

$$\|\mathbf{X}'_{S^c} \mathbf{X}_S (\mathbf{X}'_S \mathbf{X}_S)^{-1} \text{sign}(\beta_S^0)\|_{\infty} < 1$$

En palabras: **ningún predictor irrelevante puede ser demasiado bien explicado (regresado) por los relevantes.**

Resultado 2: recuperar el soporte exige mucho más

Para que $\{j : \hat{\beta}_j \neq 0\} = S$ con alta probabilidad se necesita, además:


- 1 **Señales no minúsculas** (*beta-min*): $\min_{j \in S} |\beta_j^0| \gtrsim \lambda$. Coeficientes verdaderos por debajo del umbral de ruido son indistinguibles de cero — nadie puede encontrarlos.
- 2 **Condición de irrepresentabilidad** (Zhao & Yu, 2006):

$$\|\mathbf{X}'_{S^c} \mathbf{X}_S (\mathbf{X}'_S \mathbf{X}_S)^{-1} \text{sign}(\beta_S^0)\|_{\infty} < 1$$

En palabras: **ningún predictor irrelevante puede ser demasiado bien explicado (regresado) por los relevantes.**


- Es una condición **fuerte** y — lo incómodo — **no verificable** (depende del soporte S , que no conocemos).
- Si falla, el Lasso incluye proxies equivocados *sin importar cuántos datos haya*: no es un problema de n , es estructural.

El modo de falla típico: el proxy correlacionado




- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y .
- Para el ojo del Lasso, ambos predicen casi igual: con ruido de por medio, puede quedarse con X_2 (o repartir, o alternar entre muestras).

El modo de falla típico: el proxy correlacionado



- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y .
- Para el ojo del Lasso, ambos predicen casi igual: con ruido de por medio, puede quedarse con X_2 (o repartir, o alternar entre muestras).
- Para **predecir**, da lo mismo; para **interpretar**, es un desastre silencioso: el modelo reporta con confianza la variable equivocada.

El modo de falla típico: el proxy correlacionado



- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y .
- Para el ojo del Lasso, ambos predicen casi igual: con ruido de por medio, puede quedarse con X_2 (o repartir, o alternar entre muestras).
- Para **predecir**, da lo mismo; para **interpretar**, es un desastre silencioso: el modelo reporta con confianza la variable equivocada.

La frase para tatuarse

El Lasso selecciona **predictores**, no **causas**.

¿Y los métodos secuenciales? (forward/backward vs. Lasso)

	Forward/backward stepwise	Lasso
Naturaleza	búsqueda <i>greedy</i> discreta	optimización convexa global
Solución	depende del camino	única (diseño general)
Estabilidad	baja: todo o nada	mayor: encogimiento continuo
Garantías teóricas	débiles	tasas y condiciones claras
Costo	$O(p^2)$ ajustes	camino completo, rápido

¿Y los métodos secuenciales? (forward/backward vs. Lasso)

	Forward/backward stepwise	Lasso
Naturaleza	búsqueda <i>greedy</i> discreta	optimización convexa global
Solución	depende del camino	única (diseño general)
Estabilidad	baja: todo o nada	mayor: encogimiento continuo
Garantías teóricas	débiles	tasas y condiciones claras
Costo	$O(p^2)$ ajustes	camino completo, rápido

- El stepwise *hereda* todos los problemas de selección del Lasso (proxies, inestabilidad) **sin** sus garantías.
- Y ambos comparten el pecado capital para nosotros: **la inferencia clásica después de seleccionar es inválida** — los errores estándar fingen que el modelo estaba decidido antes de ver los datos.

¿Y los métodos secuenciales? (forward/backward vs. Lasso)

	Forward/backward stepwise	Lasso
Naturaleza	búsqueda <i>greedy</i> discreta	optimización convexa global
Solución	depende del camino	única (diseño general)
Estabilidad	baja: todo o nada	mayor: encogimiento continuo
Garantías teóricas	débiles	tasas y condiciones claras
Costo	$O(p^2)$ ajustes	camino completo, rápido

- El stepwise *hereda* todos los problemas de selección del Lasso (proxies, inestabilidad) **sin** sus garantías.
- Y ambos comparten el pecado capital para nosotros: **la inferencia clásica después de seleccionar es inválida** — los errores estándar fingen que el modelo estaba decidido antes de ver los datos.

Ese pecado es exactamente el tema del cierre de hoy.

- 1 ¿Por qué la alta dimensión rompe a OLS?
- 2 El Lasso como problema de optimización
- 3 Algoritmos: coordinate descent y LARS
- 4 ¿Cuándo el Lasso recupera la verdad?
- 5 Del Lasso a la inferencia causal: post-double-selection

El problema que nos importa como economistas

Setup: queremos el efecto de un tratamiento d (no aleatorizado) sobre y , controlando *flexiblemente* por confusores observables:

$$y_i = \alpha d_i + x_i' \beta + \varepsilon_i, \quad p = \dim(x) \text{ grande}$$

- x : cientos de controles candidatos (variables base + polinomios + interacciones).
- El objetivo es α **con un intervalo de confianza válido** — no predecir y .

El problema que nos importa como economistas

Setup: queremos el efecto de un tratamiento d (no aleatorizado) sobre y , controlando *flexiblemente* por confusores observables:

$$y_i = \alpha d_i + x_i' \beta + \varepsilon_i, \quad p = \dim(x) \text{ grande}$$

- x : cientos de controles candidatos (variables base + polinomios + interacciones).
- El objetivo es α **con un intervalo de confianza válido** — no predecir y .

La tentación (single selection):

- 1 Lasso de y sobre (d, x) sin penalizar $d \Rightarrow$ controles seleccionados $\hat{S}$.
- 2 OLS de y sobre d y $x_{\hat{S}}$; reportar el error estándar de siempre.

El problema que nos importa como economistas

Setup: queremos el efecto de un tratamiento d (no aleatorizado) sobre y , controlando *flexiblemente* por confusores observables:

$$y_i = \alpha d_i + x_i' \beta + \varepsilon_i, \quad p = \dim(x) \text{ grande}$$

- x : cientos de controles candidatos (variables base + polinomios + interacciones).
- El objetivo es α **con un intervalo de confianza válido** — no predecir y .

La tentación (single selection):

- 1 Lasso de y sobre (d, x) sin penalizar $d \Rightarrow$ controles seleccionados $\hat{S}$.
- 2 OLS de y sobre d y $x_{\hat{S}}$; reportar el error estándar de siempre.

Pregunta para la sala

¿Dónde está el error?

El problema que nos importa como economistas

Setup: queremos el efecto de un tratamiento d (no aleatorizado) sobre y , controlando *flexiblemente* por confusores observables:

$$y_i = \alpha d_i + x_i' \beta + \varepsilon_i, \quad p = \dim(x) \text{ grande}$$

- x : cientos de controles candidatos (variables base + polinomios + interacciones).
- El objetivo es α **con un intervalo de confianza válido** — no predecir y .

La tentación (single selection):


- 1 Lasso de y sobre (d, x) sin penalizar $d \Rightarrow$ controles seleccionados $\hat{S}$.
- 2 OLS de y sobre d y $x_{\hat{S}}$; reportar el error estándar de siempre.

Pregunta para la sala


¿Dónde está el error?

El Lasso selecciona por **capacidad de predecir** y — pero un confusor peligroso no necesita eso: le basta estar **muy correlacionado con** d . A ese, el Lasso lo bota, y su omisión sesga $\hat{\alpha}$.

El fallo, en el lenguaje de su curso de causalidad




El fallo, en el lenguaje de su curso de causalidad




- x_k : confusor con efecto **débil sobre y** pero **fuertemente correlacionado con d** .
- El Lasso de y sobre (d, x) lo descarta (d ya “absorbe” su poca señal sobre y) $\Rightarrow$ backdoor abierto $\Rightarrow$ **sesgo de variable omitida** en $\hat{\alpha}$: el $\delta \cdot \phi$ de su curso de inferencia causal, resucitado por un algoritmo.

El fallo, en el lenguaje de su curso de causalidad



- x_k : confusor con efecto **débil** sobre y pero **fuertemente correlacionado** con d .
- El Lasso de y sobre (d, x) lo descarta (d ya “absorbe” su poca señal sobre y) $\Rightarrow$ backdoor abierto $\Rightarrow$ **sesgo de variable omitida** en $\hat{\alpha}$: el $\delta \cdot \phi$ de su curso de inferencia causal, resucitado por un algoritmo.
- Y el problema es sistemático: la selección se equivoca *precisamente* en los regresores de coeficiente moderado — los errores de selección son inevitables en muestras finitas.

El fallo, en el lenguaje de su curso de causalidad



- x_k : confusor con efecto **débil sobre y** pero **fuertemente correlacionado con d** .
- El Lasso de y sobre (d, x) lo descarta (d ya “absorbe” su poca señal sobre y) $\Rightarrow$ backdoor abierto $\Rightarrow$ **sesgo de variable omitida** en $\hat{\alpha}$: el $\delta \cdot \phi$ de su curso de inferencia causal, resucitado por un algoritmo.
- Y el problema es sistemático: la selección se equivoca *precisamente* en los regresores de coeficiente moderado — los errores de selección son inevitables en muestras finitas.

Post-double-selection (Belloni, Chernozhukov & Hansen, 2014)

El algoritmo:

- 1 **Lasso de y sobre x :** controles que predicen el *resultado* $\Rightarrow \hat{S}_y$.
- 2 **Lasso de d sobre x :** controles que predicen el *tratamiento* $\Rightarrow \hat{S}_d$.
- 3 **OLS de y sobre d y $x_{\hat{S}_y \cup \hat{S}_d}$:** reportar los errores estándar robustos de siempre.

Post-double-selection (Belloni, Chernozhukov & Hansen, 2014)

El algoritmo:

- 1 **Lasso de y sobre x :** controles que predicen el *resultado* $\Rightarrow \hat{S}_y$.
- 2 **Lasso de d sobre x :** controles que predicen el *tratamiento* $\Rightarrow \hat{S}_d$.
- 3 **OLS de y sobre d y $x_{\hat{S}_y \cup \hat{S}_d}$:** reportar los errores estándar robustos de siempre.

Teorema (informal): bajo sparsity aproximada de ambas ecuaciones, $\hat{\alpha}$ es $\sqrt{n}$ -consistente y asintóticamente normal; los intervalos de confianza usuales son **uniformemente válidos** — incluso aunque la selección cometa errores.

Post-double-selection (Belloni, Chernozhukov & Hansen, 2014)

El algoritmo:

- 1 **Lasso de y sobre x :** controles que predicen el *resultado* $\Rightarrow \hat{S}_y$.
- 2 **Lasso de d sobre x :** controles que predicen el *tratamiento* $\Rightarrow \hat{S}_d$.
- 3 **OLS de y sobre d y $x_{\hat{S}_y \cup \hat{S}_d}$:** reportar los errores estándar robustos de siempre.

Teorema (informal): bajo sparsity aproximada de ambas ecuaciones, $\hat{\alpha}$ es $\sqrt{n}$ -consistente y asintóticamente normal; los intervalos de confianza usuales son **uniformemente válidos** — incluso aunque la selección cometa errores.

Por qué funciona (la intuición que hay que llevarse):

- Para sesgar $\hat{\alpha}$, una variable omitida debe correlacionar con y y con d (el $\delta \cdot \phi$).
- PDS solo omite variables débiles **en ambas** ecuaciones $\Rightarrow$ el sesgo residual es un producto de dos términos pequeños: de **segundo orden**, despreciable frente a $1/\sqrt{n}$.

PDS en la práctica

- **En R:** paquete `hdm` (Chernozhukov, Hansen & Spindler): `rlassoEffect()` implementa PDS con una línea; reporta $\hat{\alpha}$, SE e IC válidos.

PDS en la práctica

- **En R:** paquete `hdm` (Chernozhukov, Hansen & Spindler): `rlassoEffect()` implementa PDS con una línea; reporta $\hat{\alpha}$, SE e IC válidos.
- **Detalle fino:** para inferencia, λ **no** se elige por CV sino con la fórmula *plug-in* teórica ($\lambda \asymp \sigma \sqrt{n \log p}$, con ajustes): el CV optimiza predicción y tiende a dejar entrar demasiadas variables — otro recordatorio de que predicción e inferencia son juegos distintos.

PDS en la práctica

- **En R:** paquete `hdm` (Chernozhukov, Hansen & Spindler): `rlassoEffect()` implementa PDS con una línea; reporta $\hat{\alpha}$, SE e IC válidos.
- **Detalle fino:** para inferencia, λ **no** se elige por CV sino con la fórmula *plug-in* teórica ($\lambda \asymp \sigma \sqrt{n \log p}$, con ajustes): el CV optimiza predicción y tiende a dejar entrar demasiadas variables — otro recordatorio de que predicción e inferencia son juegos distintos.
- **Dónde lo van a ver:** regresiones de crecimiento (¿qué controles entre docenas?), evaluación con muchos confusores administrativos, efectos de políticas con controles flexibles (BCH lo ilustran re-examinando la relación aborto–crimen y leyes de armas).

PDS en la práctica

- **En R:** paquete `hdm` (Chernozhukov, Hansen & Spindler): `rlassoEffect()` implementa PDS con una línea; reporta $\hat{\alpha}$, SE e IC válidos.
- **Detalle fino:** para inferencia, λ **no** se elige por CV sino con la fórmula *plug-in* teórica ($\lambda \asymp \sigma \sqrt{n \log p}$, con ajustes): el CV optimiza predicción y tiende a dejar entrar demasiadas variables — otro recordatorio de que predicción e inferencia son juegos distintos.
- **Dónde lo van a ver:** regresiones de crecimiento (¿qué controles entre docenas?), evaluación con muchos confusores administrativos, efectos de políticas con controles flexibles (BCH lo ilustran re-examinando la relación aborto–crimen y leyes de armas).

Regla práctica para sus proyectos

¿Muchos controles y un α que interpretar? **Nunca** un solo Lasso de y : siempre doble selección (o, en general, un procedimiento ortogonalizado).

Recap

- 1 La alta dimensión rompe a OLS por **información por parámetro**: $\text{Var}(v_j' \hat{\beta}) = \sigma^2/d_j$ explota en direcciones casi colineales; con $p > n$, el ajuste perfecto pierde todo contenido.
- 2 La salida es un supuesto de estructura: **sparsity**. El Lasso es la **relajación convexa** de la búsqueda esparsa.
- 3 **KKT** + **subgradiente** caracterizan la solución: activos en $|\mathbf{X}_j' r| = \lambda$, inactivos por debajo; de ahí el umbral suave S_λ , demostrado por casos.
- 4 *Coordinate descent* = aplicar S_λ coordenada por coordenada; el camino es lineal por tramos (LARS).
- 5 **Predicción** cuesta solo $\log p$; **selección** exige irrepresentabilidad (fuerte, improbable): el Lasso selecciona *predictores*, no *causas*.
- 6 Para inferencia sobre un tratamiento: **post-double-selection** — seleccionar con y y con d , y la validez sobrevive a los errores de selección (ortogonalidad de Neyman).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la sesión de hoy; léanla completa.
- Hastie, Tibshirani & Wainwright (2015), *Statistical Learning with Sparsity*, caps. 1–2.
Guía: formalizan lo visto; el cap. 11 es opcional para los valientes.

Recomendadas: Efron et al. (2004, LARS); Wainwright (2019), caps. 7–8 (nivel doctorado); Zhao & Yu (2006).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la sesión de hoy; léanla completa.
- Hastie, Tibshirani & Wainwright (2015), *Statistical Learning with Sparsity*, caps. 1–2.
Guía: formalizan lo visto; el cap. 11 es opcional para los valientes.

Recomendadas: Efron et al. (2004, LARS); Wainwright (2019), caps. 7–8 (nivel doctorado); Zhao & Yu (2006).

Próxima sesión — cambio total de familia: dejamos los modelos lineales. Árboles de decisión, Random Forest y *boosting*: los métodos que suelen ganar con datos tabulares. Lean ISLR cap. 8 **antes** de clase.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la sesión de hoy; léanla completa.
- Hastie, Tibshirani & Wainwright (2015), *Statistical Learning with Sparsity*, caps. 1–2.
Guía: formalizan lo visto; el cap. 11 es opcional para los valientes.

Recomendadas: Efron et al. (2004, LARS); Wainwright (2019), caps. 7–8 (nivel doctorado); Zhao & Yu (2006).

Próxima sesión — cambio total de familia: dejamos los modelos lineales. Árboles de decisión, Random Forest y *boosting*: los métodos que suelen ganar con datos tabulares. Lean ISLR cap. 8 **antes** de clase.

Aplicación de esta semana en R: precios de vivienda con muchas covariables — Lasso y Elastic Net con `glmnet`, y PDS con `hdm`.

Referencias esenciales

- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *JRSS-B*, 58(1), 267–288.
- Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least Angle Regression. *Annals of Statistics*, 32(2), 407–499.
- Zhao, P., & Yu, B. (2006). On Model Selection Consistency of Lasso. *JMLR*, 7, 2541–2563.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for GLMs via Coordinate Descent. *J. of Statistical Software*, 33(1).
- Hastie, T., Tibshirani, R., & Wainwright, M. (2015). *Statistical Learning with Sparsity*. CRC Press.
- Wainwright, M. (2019). *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge UP. Caps. 7–8.
- Leeb, H., & Pötscher, B. (2005). Model Selection and Inference: Facts and Fiction. *Econometric Theory*, 21(1), 21–59.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). Inference on Treatment Effects after Selection among High-Dimensional Controls. *Review of Economic Studies*, 81(2), 608–650.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *JEP*, 28(2), 29–50.