

Big Data y Machine Learning para Economía Aplicada

Week 03: Validación cruzada y regularización: el *pipeline* honesto

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 24, 2026

Previously...

- **La recta como máquina de predecir:** en Cali y su área metropolitana, la educación superior sola deja el RMSE de prueba en 6,8 puntos (la media, 11,0). Minimizar el RSS es minimizar el error de entrenamiento: por eso adula (regla de oro #1).
- **Después de predecir:** predicho contra observado, los residuos como detector y el error por quintil y por lugar, siempre contra una referencia.
- **En la práctica, el concurso de los 511:** todas las combinaciones de las nueve variables, ordenadas por su RMSE de prueba. Ganó una de cinco variables, con 6,42.
- **La limitación:** la recta no viaja. En el país explica el 0,04% del voto.

Dos cabos sueltos

Elegimos al campeón *mirando la prueba*, y para viajar la recta necesita muchas más columnas. Hoy los atamos: el primero con un **juez**, el segundo con una **perilla**.

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Qué variables y cuánta flexibilidad: toda decisión tomada mirando los datos también se puede sobreajustar

Deuda 1, de la práctica. El campeón de los 511 se eligió con la misma prueba con la que se calificó. ¿Era el mejor modelo o tuvo suerte con los 86 puestos que cayeron en la prueba?

La herramienta: el juez. La **validación cruzada** estima el error fuera de muestra *dentro* del entrenamiento, promediando muchas particiones. Sirve para comparar y elegir sin tocar la prueba.

Deuda 2, de “la recta no viaja”. Para predecir el país, cada variable debe poder pesar distinto en cada departamento: 1.291 columnas. Con tantas, OLS se ajusta a todo y no predice nada.


La herramienta: la perilla. La **regularización** le pone precio al tamaño de los coeficientes: baja la varianza y, con el Lasso, apaga variables. Su intensidad, λ , la fija. . . el juez.

La idea con la que se van

Resuelven problemas distintos y se necesitan: la regularización **regula** la complejidad y la validación cruzada **decide** cuánta. La prueba se abre una sola vez, al final.

El concurso de los 511, con cien particiones distintas

La misma base, los mismos 511 modelos, la misma regla 75/25: sólo cambia qué puestos caen en la prueba



- **El número depende de la partición:** la misma recta marca de 5,3 a 8,6 según qué 86 puestos le toquen.
- **El campeón también:** en cien concursos hubo **72 campeones distintos**, de 2 a 9 variables. El de la clase ganó una sola vez.
- Siempre queda debajo de la recta porque es el *mínimo* de 511 intentos: parte de su ventaja es ruido que se eligió.

Lo que necesitamos

Un juez que no use la prueba para elegir y que no dependa de una sola partición.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 Juez y perilla, en el país

4 Cierre

Tres papeles para los datos: aprender, elegir y reportar

ISL separa dos usos del error fuera de muestra: seleccionar un modelo y evaluarlo (cap. 5)

entrenamiento aprender: estimar $\hat{\beta}$	validación elegir k , variables, λ	prueba reportar una sola vez
---	---	---

- **Elegir** (selección del modelo) es comparar candidatos y quedarse con uno.
Reportar (evaluación) es decir cuánto se equivoca el elegido en datos nuevos.
- Si el mismo conjunto hace las dos cosas, el reporte adula. El mínimo de muchos errores estimados es optimista,


$$\mathbb{E} \left[\min_m \widehat{\text{Error}}_m \right] \leq \min_m \mathbb{E} [\widehat{\text{Error}}_m],$$

y la brecha crece con el número de candidatos: en la práctica fueron 511.

- La solución más simple (ISL 5.1.1): un **conjunto de validación** para elegir y la prueba, intacta, para reportar (regla de oro #2).

Una sola partición de validación es una lotería


¿Cuántos vecinos del mapa usar? La pregunta de la semana 2, con diez particiones de validación distintas



- Cada curva elige otro k (de 2 a 9) y marca otro nivel: en $k = 10$, de 7,6 a 9,9 según la semilla. Es la Fig. 5.2 de ISL con nuestros puestos.
- Dos defectos (ISL 5.1.1): el resultado **cambia** con la partición, y el modelo se ajusta con **menos datos** (193 de 257), así que el error tiende a exagerar.

Validación cruzada con K pliegues: promediar la lotería

Cada puesto se valida una vez, con un modelo que no lo vio (ISL 5.1.3)




$$CV_{(K)} = \frac{1}{K} \sum_{j=1}^K MSE_j$$

$$MSE_j = \frac{1}{n_j} \sum_{i \in F_j} (y_i - \hat{f}^{(-j)}(x_i))^2$$

$\hat{f}^{(-j)}$: el modelo ajustado sin el pliegue

j . Reportamos $RMSE_{CV} = \sqrt{CV_{(K)}}$.

Con 5 pliegues las diez curvas casi se superponen: el k elegido va de 3 a 6 y el error en $k = 10$, de 9,0 a 9,7 (con una sola partición, de 7,6 a 9,9). Es la Fig. 5.4 de ISL.



¿Cuántos pliegues? De dos a n

La recta de la semana 2 con los 257 puestos: para cada K , cincuenta asignaciones distintas de los pliegues

	RMSE de CV	d.e.
$K = 2$	7,45	0,14
$K = 5$	7,42	0,05
$K = 10$	7,40	0,03
$K = n$ (LOOCV)	7,40	—
Dentro de muestra	7,31	

LOOCV (*leave-one-out*) deja fuera un puesto a la vez. Con OLS no hace falta ajustar n veces (ISL, ec. 5.2):

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$


Es el residuo de entrenamiento inflado por $1/(1 - h_i)$, donde h_i mide cuánto pesa y_i en su propio ajuste. La inflación mide cuánto se acomodó la recta a cada puesto: el optimismo de la regla de oro #1, dato por dato.

El sesgo y la varianza del propio juez (ISL 5.1.4)

Con pocos pliegues cada modelo aprende con menos datos (el juez exagera el error) y el resultado baila con la asignación. Con $K = n$ casi no hay sesgo, pero se promedian n modelos casi idénticos y cuesta n ajustes. En la práctica: $K = 5$ o 10 .

La curva del juez: el mínimo y la regla de un error estándar

k -NN en el mapa con 10 pliegues: el error de validación de cada k y su incertidumbre



- El error **dentro** no sirve de juez: siempre elige $k = 1$ (0,0).
- El **mínimo** de la validación cruzada es $k = 4$ (7,92). Pero diez pliegues dan diez errores, y su dispersión da un error estándar, $EE = d.e.(MSE_1, \dots, MSE_K)/\sqrt{K}$.
- **Regla de un error estándar** (ISL 6.1.3): el modelo más simple cuyo error no pasa de $CV_{\min} + EE$. Aquí, $k = 6$ (8,28): más vecinos, menos varianza.
- Sólo entonces se reajusta con los 257 y se abre la prueba, una vez: 8,31 con $k = 4$ o 8,47 con $k = 6$.

El concurso de los 511, con un juez honesto

Los mismos 511 modelos, calificados con 10 pliegues del entrenamiento; la prueba se abre al final

Modelo	Elegido por	Variables	RMSE de CV	RMSE de prueba
Campeón de la clase	la prueba	5	7,19	6,42
Campeón de la CV	la CV	4	7,09	6,83
Regla de un error estándar	CV + parsimonia	1: la recta	7,38	6,83

El concurso de los 511, con un juez honesto

Los mismos 511 modelos, calificados con 10 pliegues del entrenamiento; la prueba se abre al final

Modelo	Elegido por	Variables	RMSE de CV	RMSE de prueba
Campeón de la clase	la prueba	5	7,19	6,42
Campeón de la CV	la CV	4	7,09	6,83
Regla de un error estándar	CV + parsimonia	1: la recta	7,38	6,83

- El 6,42 de la clase era **la partición, no el modelo**: calificado honestamente, ese campeón queda en el puesto 73.
- El juez, con la regla de un error estándar, elige **la recta de la semana 2**; con otras 20 asignaciones de pliegues, la elige 19 veces.
- Aun así, el error de validación del campeón adula un poco (es el mínimo de 511): por eso la cifra que se reporta sale de la prueba, abierta una sola vez.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 Juez y perilla, en el país

4 Cierre

Con muchas variables, las dos salidas de siempre fallan

La ficha completa del censo (educación, edades, etnia, servicios, estratos, hogares, tamaño): 37 variables para los mismos 257 puestos

Salida 1: elegir cuáles entran (el concurso).

- Con 9 variables fueron 511 modelos. Con 37 son 2^{37} , unos 137 mil millones: **269 millones** de concursos como el de la clase. Años de cómputo.
- Y aunque se pudiera: cuanto más grande el espacio de búsqueda, más fácil encontrar modelos que lucen bien en el entrenamiento sin poder predictivo (ISL 6.1.2). Con 511 ya hubo 72 campeones.

Salida 2: usarlas todas con OLS.

	Coef.	Dentro	CV
Recta	1	7,31	7,38
OLS con la ficha	36	5,94	7,17

$R^2 = 0,76$ dentro, con 8 de 36 coeficientes significativos. La brecha entre dentro y CV pasa de 0,07 a 1,23 puntos: es la **varianza**, que crece cuando n no es mucho mayor que p (ISL, cap. 6).

La tercera salida

Usarlas todas, pero **cobrar** por el tamaño de los coeficientes: una perilla continua en lugar de un interruptor por variable.

Cobrar por la complejidad: la función objetivo penalizada

La suma de cuadrados de la semana 2, más un precio por el tamaño de los coeficientes

$$\hat{\beta}(\lambda) = \arg \min_{\beta} \underbrace{\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2}_{\text{RSS}(\beta): \text{ajustar}} + \underbrace{\lambda P(\beta)}_{\text{el precio}}$$

Precio $P(\beta)$	Nombre	Qué cobra
$\sum_j \mathbb{I}\{\beta_j \neq 0\}$	ℓ_0 : el concurso de los 511	cada variable que entra
$\sum_j \beta_j^2$	ℓ_2 : Ridge	el tamaño, al cuadrado
$\sum_j \beta_j $	ℓ_1 : Lasso	el tamaño

- **La perilla** λ : con $\lambda = 0$ es OLS con todas; con $\lambda \rightarrow \infty$ todos los β_j valen cero y se predice $\bar{y}$, **la referencia** de la semana 2. En medio, un continuo de modelos para que el juez elija.
- **Dos detalles que no son detalles**: el intercepto no se castiga, y las x se **estandarizan** (ISL, ec. 6.6): el precio de un coeficiente no puede depender de si una variable está en pesos o en millones.
- Ridge y Lasso son las versiones tratables del concurso: cambian un conteo imposible de optimizar por una suma que sí se puede (ISL, ec. 6.10).

Ridge: encoger todo, no apagar nada

El precio ℓ_2 : $\text{RSS} + \lambda \sum_j \beta_j^2$ (Hoerl y Kennard, 1970; ISL 6.2.1)

La solución tiene fórmula:

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}$$

Sumar $\lambda \mathbf{I}$ vuelve invertible a $\mathbf{X}'\mathbf{X}$ aunque haya gemelas o más columnas que puestos.

El caso que se ve a simple vista:

predictores ortogonales y estandarizados (ISL, ec. 6.14),

$$\hat{\beta}_j^R = \frac{\hat{\beta}_j}{1 + \lambda}.$$

Ridge divide: todos los coeficientes se encogen en la misma proporción y ninguno llega a cero.

Por qué ayuda: dividir baja la varianza de los coeficientes a cambio de un poco de sesgo. Gana cuando OLS es ruidoso: pocas observaciones por variable o predictores muy correlacionados (ISL, Fig. 6.5).

Con la gemela de la semana 2: OLS reparte al azar ($-0,24$ y $-0,51$, con un error estándar 26 veces mayor). Ridge les da a las dos el mismo peso: reparte el crédito en vez de sortearlo. La figura, en tres diapositivas.

Lo que no hace: apagar variables. Con 37 columnas, el modelo sigue teniendo 37.

Lasso: restar en lugar de dividir

El precio ℓ_1 : $\text{RSS} + \lambda \sum_j |\beta_j|$ (Tibshirani, 1996; ISL 6.2.2)


El mismo caso simple (ISL, ec. 6.15):

$$\hat{\beta}_j^L = \text{sign}(\hat{\beta}_j) (|\hat{\beta}_j| - \lambda/2)_+$$

El Lasso resta una cantidad fija, y si no alcanza deja el coeficiente en cero: el “umbral suave”.

Frente a los otros dos precios, en el mismo caso:


- **Ridge divide** por $1 + \lambda$: nunca llega a cero.
- **El Lasso resta** $\lambda/2$: los pequeños quedan en cero y los grandes, encogidos.
- **El concurso corta**: conserva $\hat{\beta}_j$ entero si $|\hat{\beta}_j| > \sqrt{\lambda}$ y si no lo borra. Todo o nada.



Con $\lambda = 1$: Ridge divide entre 2; el Lasso resta 0,5 y anula todo lo que no llegue; el concurso borra lo que no pase de 1 y deja intacto el resto (ISL, Fig. 6.10).

Por qué el cero es exacto: el costo marginal del precio

Leído como economistas: elegir β_j es igualar beneficio marginal y costo marginal (el mismo caso simple)



El beneficio marginal de mover β_j es cuánto baja el RSS: $\text{BMg} = 2(\hat{\beta}_j - \beta_j)$, alto al principio y cero en OLS.


El costo marginal depende del precio:

- Ridge, $\lambda\beta_j^2$: $\text{CMg} = 2\lambda\beta_j$, **cero** al arrancar. Siempre cruza al BMg en un $\beta_j > 0$: encoge pero no apaga (**puntos azules**).
- Lasso, $\lambda|\beta_j|$: $\text{CMg} = \lambda$ **desde el primer peso**: un peaje. Si el BMg en cero no llega a λ , la mejor decisión es la **esquina**: $\hat{\beta}_j = 0$ (**círculo rojo**).

En general (apéndice A3): una variable entra sólo si su correlación con el residuo, su beneficio marginal, cubre el peaje λ .

La geometría: el diamante y el círculo


El mismo problema con presupuesto: mínimo RSS sujeto a $\sum_j |\beta_j| \leq s$ (Lasso) o a $\sum_j \beta_j^2 \leq s^2$ (Ridge)



- La educación superior y el estrato alto (las gemelas de la matriz de pares, correlación 0,81), estandarizadas. Cada elipse un punto con el mismo RSS alrededor de OLS, $(-10,1; 0,4)$. Presupuesto: $s = 8$.
- El **diamante** tiene esquinas sobre los ejes: la primera elipse que lo toca lo hace en una esquina y el estrato alto queda en **cero**. El **círculo** no tiene esquinas: Ridge conserva las dos y le pasa al estrato alto parte del crédito. Con p variables el diamante tiene más esquinas, y hay más ceros (ISL, Fig. 6.7).

Elastic Net: las dos penalizaciones a la vez


$RSS + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$: con $\alpha = 1$ es el Lasso y con $\alpha = 0$, Ridge (Zou y Hastie, 2005)



- **La gemela de la semana 2.** Ridge les da a las dos el mismo peso; el Lasso le da el crédito a una y deja a la otra atrás (un sorteo); Elastic Net las trata como Ridge y, como el Lasso, puede apagar lo que no sirve.
- **Qué aporta:** con **grupos** de variables correlacionadas (el censo está lleno: estratos, educación, servicios, edades) conserva o descarta el grupo entero; y con más columnas que observaciones no se limita a n variables, como el Lasso.
- Su región queda entre el diamante y el círculo: esquinas (ceros) y bordes curvos (agrupa). Dos perillas, λ y α , ambas por CV.

Los caminos: cada λ es un modelo


La ficha de 37 en los 257 puestos: los coeficientes estandarizados mientras sube la penalización (ISL, Figs. 6.4 y 6.6)



- **Ridge:** todos se encogen juntos y sólo llegan a cero en el límite. **Lasso:** entran de a uno. Primero, y por mucho, la educación superior; después la estructura de edades, el estrato 6 y la población afro.
- El camino es la lista de candidatos que se le presenta al juez: en lugar de 2^{37} modelos, uno por cada valor de λ .

¿Cuánto encoger? El juez elige λ

El mismo protocolo del k de los vecinos: 10 pliegues, el mínimo y la regla de un error estándar (ISL 6.2.3)



- **Dentro de muestra** el error sube siempre con λ : el entrenamiento votaría por no encoger nada (la regla de oro #1, otra vez).
- La **validación cruzada** dibuja la U de la sesión 1 entre los dos extremos de la perilla: OLS con las 37 a la izquierda y la media a la derecha.
- $\lambda_{\min}$: 24 variables y un RMSE de CV de 6,89. λ_{1SE} : 7 variables y 7,33.

La ficha de 37 en el área metropolitana: la tabla

Los mismos 10 pliegues para todos; la prueba de 86 puestos, abierta una vez

Modelo	Coef. $\neq 0$	RMSE dentro	RMSE de CV	RMSE de prueba
Recta (educación superior)	1	7,31	7,38	6,83
OLS con la ficha	36	5,94	7,17	6,70
Ridge ($\lambda_{\min}$)	37	6,21	6,82	6,51
Lasso ($\lambda_{\min}$)	24	6,17	6,89	6,42
Lasso (λ_{1SE})	7	7,05	7,33	6,95
Elastic Net, $\alpha = 0,5$ ($\lambda_{\min}$)	24	6,20	6,88	6,44

- Las penalizadas tienen la mejor validación cruzada **sin que nadie les diga qué sobra**: de 7,17 con OLS a 6,82–6,89.
- **¿Ridge o Lasso?** Depende del mundo: si la señal está repartida entre muchas variables correlacionadas gana Ridge; si la llevan pocas, el Lasso (ISL, Figs. 6.8 y 6.9). No se sabe de antemano: lo decide el juez. Aquí, por poco, Ridge.
- Con 86 puestos la prueba no distingue diferencias de medio punto. Hoy importa más la *forma* de decidir que el ganador.

1 El juez: validar sin gastar la prueba


2 La perilla: regularizar

3 Juez y perilla, en el país

4 Cierre

Ahora sí, el país: la y antes de cualquier modelo


Los 9.602 puestos de entrenamiento de la partición fija del curso (2.398 quedan bajo llave)



- En el país la y es casi **plana** de 0 a 100: una desviación de 27,3 frente a 12,2 en el área metropolitana. Petro gana en el 53% de los puestos.
- Predecir la media para todos deja un RMSE de prueba de 26,7; la recta de la semana 2 también deja 26,7: la educación sola explica el 0,04% del voto.

La educación pesa distinto en cada departamento

Una recta por departamento: la pendiente de la educación superior, ± 2 errores estándar



- Donde hay datos las pendientes son precisas y **cambian de signo**: $-0,56$ en Bogotá, $+1,04$ en Boyacá, $+1,02$ en Cundinamarca. La recta del país es plana porque promedia relaciones opuestas.
- Para que la recta viaje, cada variable necesita su pendiente en cada departamento: $37 + 33 + 37 \times 33 = \mathbf{1.291}$ columnas. Pero Vaupés tiene 20 puestos para 38 coeficientes: a la izquierda del embudo, las pendientes son ruido.

1.291 columnas: OLS se desploma; con la perilla, no


Los mismos 10 pliegues para todos; la prueba de 2.398 puestos, abierta una sola vez

Modelo	Coef. $\neq 0$	RMSE dentro	RMSE de CV	RMSE de prueba
Media del entrenamiento	0	27,3	27,3	26,7
Recta (educación superior)	1	27,3	27,3	26,7
La ficha de 37	36	20,2	20,3	19,8
Ficha + departamentos	68	15,6	15,8	15,6
OLS con la ficha larga	1.122	12,3	más de 7.000	69,1
Ridge, ficha larga ($\lambda_{\min}$)	1.278	13,1	17,2	14,7
Lasso, ficha larga ($\lambda_{\min}$)	202	14,5	14,9	14,7
Elastic Net, ficha larga ($\lambda_{\min}$)	230	14,5	14,9	14,7

- **OLS**: el mejor error dentro y el peor fuera; en los departamentos chicos p se acerca a n y el ajuste interpola (ISL 6.4.2).
- **Ridge** acierta en la prueba (14,7), pero el juez ve lo que una prueba sola esconde: sus tres peores pliegues marcan 18,3, 18,6 y 25,9 (los del Lasso no pasan de 15,5). En el peor, 3 puestos de San Andrés hacen el 69% del error: Ridge encoge pero no apaga.
- El juez elige **al Lasso**: 14,9 en CV, estable en todos los pliegues (de 14,3 a 15,5), y 14,7 en la prueba: $-0,9$ frente a la ficha con departamentos (intervalo *bootstrap* del 95%: de $-1,2$ a $-0,7$).

Qué eligió el Lasso


Sobreviven 202 de 1.291 columnas: 15 efectos nacionales, 1 constante y 186 desviaciones



- **Más datos, más libertad.** Es la esquina de la parte 2: una columna entra sólo si su beneficio marginal en cero supera λ , y el de una desviación se suma sobre los puestos de su departamento. Nariño conserva 12 de 37; los chicos, casi ninguna (correlación de 0,64 con el log del tamaño).
- **Lo que cambia por departamento** no es la educación superior (se aparta en 2 de 33): es la zona rural (en 14 departamentos), la población indígena (12) y la población afro (11).

Cambia la lista, no la predicción

El mismo λ en 20 remuestras *bootstrap* (apéndice A7): ¿en cuántas entra cada columna?



- De 583 columnas que entran alguna vez, 119 lo hacen una sola vez y sólo 47 siempre. La educación superior entra en 2 de 20, y no porque no importe: las 15 nacionales que sí entran explican el 82% de su variación. La gemela de la semana 2, a gran escala.
- La predicción casi no se mueve: la de un puesto típico cambia 1,4 puntos entre remuestras (su error: 14,7).

El Lasso selecciona predictores, no causas

Que una columna salga no dice que no importe: otra cuenta lo mismo. Se confía en la predicción, no en la lista (ISL 6.4.4; Mullainathan y Spiess, 2017).

Una columna que ya sabe la respuesta (regla de oro #3)

Añadir a la ficha el voto promedio del municipio: una idea natural, calculada en el lugar equivocado

Ficha + promedio municipal	RMSE
CV, promedio con todo	11,2
CV, promedio en cada pliego	13,1
Prueba	13,0

Una columna que ya sabe la respuesta (regla de oro #3)

Añadir a la ficha el voto promedio del municipio: una idea natural, calculada en el lugar equivocado

Ficha + promedio municipal	RMSE
CV, promedio con todo	11,2
CV, promedio en cada pliegue	13,1
Prueba	13,0

- Un municipio típico tiene 5 puestos: si el promedio se calcula con todos, **cada puesto pesa $1/5$ en su propio predictor**. El juez ve la respuesta y promete 11,2; la prueba cobra 13,0.
- Calculada dentro del pliegue, la columna es legítima y hasta buena: 13,0 en la prueba, mejor que el Lasso (el municipio sabe mucho del voto). El problema no es la variable sino *dónde* se calcula.

Regla de oro #3: la validación cruzada valida la receta completa

Todo lo que aprende de la y —elegir variables, fijar k o λ , promedios por grupo— se hace **dentro** de cada pliegue. ISL ya lo exige para el concurso: la mejor combinación de cada tamaño se busca de nuevo en cada pliegue (sección 6.1.3).

Vecinos que se copian: ¿qué pregunta responde tu validación?

Pliegues al azar o pliegues de municipios enteros: la pregunta de la semana 2, ¿cómo validar cuando los puestos vecinos se parecen?

RMSE de CV	Pliegues al azar	Municipios enteros	Aumento
Media del entrenamiento	27,3	27,4	+0,1
La ficha de 37	20,3	20,8	+0,5
Ficha + departamentos	15,8	16,7	+0,9
Lasso, ficha larga	14,9	16,6	+1,7
<i>k</i> -NN en el mapa ($k = 7$)	12,0	15,0	+3,0

Vecinos que se copian: ¿qué pregunta responde tu validación?

Pliegues al azar o pliegues de municipios enteros: la pregunta de la semana 2, ¿cómo validar cuando los puestos vecinos se parecen?

RMSE de CV	Pliegues al azar	Municipios enteros	Aumento
Media del entrenamiento	27,3	27,4	+0,1
La ficha de 37	20,3	20,8	+0,5
Ficha + departamentos	15,8	16,7	+0,9
Lasso, ficha larga	14,9	16,6	+1,7
k -NN en el mapa ($k = 7$)	12,0	15,0	+3,0

- **Al azar** se responde: ¿qué tan bien completo el mapa de un municipio que ya conozco? **Por municipio**: ¿y en uno nuevo? Son dos usos distintos del mismo modelo.
- Cuanto más se apoya un modelo en los vecinos, más cae: los vecinos del mapa pierden 3,0 puntos, el Lasso 1,7 y la ficha sola, 0,5. El k -NN sigue ganando, pero su ventaja sobre el Lasso se achica.
- El esquema de validación debe imitar el uso (Roberts et al., 2017). Con datos en el tiempo, la versión honesta es validar hacia adelante: entrenar con una elección y probar con la siguiente, nunca al azar.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 Juez y perilla, en el país

4 Cierre

Recap

- 1 **Elegir también es ajustar.** Si la prueba elige, deja de ser prueba: en cien particiones el concurso de los 511 tuvo 72 campeones, y el 6,42 de la clase era la partición.
- 2 **El juez:** la validación cruzada con $K = 5$ o 10 estima el error fuera de muestra sin tocar la prueba; se elige con el mínimo o con la regla de un error estándar, y la prueba se abre una vez. Juzgado así, el concurso elige la recta.
- 3 **La perilla:** la penalización cambia el interruptor por variable por un precio continuo. Ridge divide (encoge y no apaga); el Lasso resta y apaga (esquinas, peaje constante); Elastic Net combina y agrupa. λ lo elige el juez.
- 4 **Juntos, en el país:** con 1.291 columnas OLS se desploma (69,1) y el Lasso deja el error de prueba en 14,7. Lo que selecciona cambia con la muestra y la predicción casi no: predictores, no causas.
- 5 **La receta completa y la pregunta correcta:** todo lo que mira la y va dentro de los pliegues (regla de oro #3), y los pliegues deben imitar el uso: al azar o por municipio no es un detalle técnico.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, secciones 4.1–4.3 (clasificación y regresión logística) y 4.7.6 (el laboratorio de k -NN como clasificador).

Guía: la sección 4.4.2 tiene la matriz de confusión y la curva ROC con el ejemplo *Default*; las secciones 4.4–4.5 (LDA, QDA, Naive Bayes) van al apéndice de la sesión.

Próxima sesión — clasificación: de la logística a las decisiones. La misma elección, otra pregunta: a la campaña no le importa si Petro saca 48 o 52 en un puesto; le importa **si lo gana**. La y pasa a ser una categoría; la logística como referencia y, con las herramientas de hoy, la logística penalizada; y la mitad que decide: por qué la exactitud engaña, la matriz de confusión, el umbral como decisión con costos, ROC y AUC, calibración.

Aplicación en R: los 12.000 puestos del país, la ficha de hoy y una y nueva, `gana_petro`. **Se publica el Problem Set 1** (vivienda en Cali; entrega: martes 20 de octubre, 8:00).

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 5 (5.1) y 6 (6.1, 6.2 y 6.4). [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Secs. 3.4 (Ridge, Lasso y Elastic Net) y 7.10 (la validación cruzada bien y mal hecha). [ESL]
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.
- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society, Series B*, 67(2), 301–320.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1–22. [glmnet]
- Roberts, D. R., et al. (2017). Cross-validation Strategies for Data with Temporal, Spatial, Hierarchical, or Phylogenetic Structure. *Ecography*, 40(8), 913–929.
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87–106.

5 Apéndice: para profundizar

A1. Antes de la validación cruzada: C_p , AIC, BIC y R^2 ajustado

Corregir el error de entrenamiento en vez de estimar el de prueba (ISL 6.1.3)

Con un modelo OLS de d predictores y $\hat{\sigma}^2$ estimado con el modelo completo:

$$C_p = \frac{1}{n}(\text{RSS} + 2d\hat{\sigma}^2), \quad \text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2),$$

$$R_{\text{aj}}^2 = 1 - \frac{\text{RSS}/(n - d - 1)}{\text{TSS}/(n - 1)}$$

- Suman al RSS un precio por cada variable: son, otra vez, un precio ℓ_0 . AIC es proporcional a C_p en el modelo lineal gaussiano; BIC cobra más ($\log n > 2$ desde $n = 8$) y elige modelos más pequeños.
- Sirven para elegir el tamaño en el concurso o en la selección paso a paso (*stepwise*: añadir, o quitar, una variable a la vez; $1 + p(p + 1)/2$ modelos en lugar de 2^p , sin garantía de encontrar el mejor).
- Frente a la validación cruzada: suponen el modelo correcto y un buen $\hat{\sigma}^2$, y fallan cuando p se acerca a n (ISL 6.4.2). La CV estima el error de prueba directamente y hoy su costo casi nunca es un problema.

A2. Ridge por dentro: encoge más donde los datos informan menos

1. **La descomposición:** con $\mathbf{X} = \mathbf{UDV}'$ (valores singulares $d_1 \geq \dots \geq d_p$),

$$\mathbf{x}\hat{\beta}^{OLS} = \sum_j \mathbf{u}_j \mathbf{u}_j' \mathbf{y}, \quad \mathbf{x}\hat{\beta}^R = \sum_j \mathbf{u}_j \frac{d_j^2}{d_j^2 + \lambda} \mathbf{u}_j' \mathbf{y}.$$

2. **La lectura:** Ridge encoge cada dirección de los datos por el factor $d_j^2/(d_j^2 + \lambda)$. Las direcciones con mucha variación (d_j grande) casi no se tocan; las que apenas varían se encogen casi a cero.

3. **La gemela:** educación y su gemela varían juntas (dirección “suma”, d_j grande) y casi nunca por separado (dirección “diferencia”, d_j diminuto). OLS estima la diferencia con puro ruido ($-0,24$ contra $-0,51$); Ridge la aplasta y reparte el efecto por igual.

4. **Grados de libertad efectivos:** $gl(\lambda) = \sum_j d_j^2/(d_j^2 + \lambda)$, de p (con $\lambda = 0$) a 0: la complejidad del modelo como una perilla continua (ESL 3.4.1).

A3. El Lasso por dentro: optimalidad y descenso por coordenadas

1. Las condiciones de optimalidad (el RSS no es derivable en cero por el valor absoluto; se usa el subgradiente): en la solución, para cada j ,

$$\hat{\beta}_j \neq 0 \Rightarrow 2 |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})| = \lambda, \quad \hat{\beta}_j = 0 \Leftrightarrow 2 |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})| \leq \lambda.$$

Es el peaje de la diapositiva del Lasso: una variable entra sólo si su correlación con el residuo, su beneficio marginal, llega a λ .

2. Descenso por coordenadas (lo que hace `glmnet`): se fija todo menos β_j , se calcula el residuo parcial $r^{(j)} = \mathbf{y} - \mathbf{X}_{-j}\hat{\boldsymbol{\beta}}_{-j}$, y con $\mathbf{x}_j$ estandarizada

$$\hat{\beta}_j \leftarrow \text{sign}(z_j) (|z_j| - \lambda/2)_+ / \mathbf{x}'_j \mathbf{x}_j, \quad z_j = \mathbf{x}'_j r^{(j)}.$$

Es el umbral suave de la diapositiva, aplicado variable por variable hasta que nada cambia.

3. El camino completo: se empieza en el λ en que todo vale cero, $\lambda_{\max} = 2 \max_j |\mathbf{x}'_j \mathbf{y}|$, y se baja por una grilla usando cada solución como punto de partida de la siguiente (Friedman, Hastie y Tibshirani, 2010).

A4. La lectura bayesiana: penalizar es tener un *prior*

Con errores normales y un *prior* independiente para cada coeficiente, $p(\beta) = \prod_j g(\beta_j)$, la moda de la posterior es

$$\begin{aligned}\hat{\beta} &= \arg \max_{\beta} \left[\log f(\mathbf{y} \mid \mathbf{X}, \beta) + \sum_j \log g(\beta_j) \right] \\ &= \arg \min_{\beta} \left[\text{RSS}(\beta) - 2\sigma^2 \sum_j \log g(\beta_j) \right].\end{aligned}$$

- g **normal** con media cero: $-\log g(\beta_j) \propto \beta_j^2$, y la moda es **Ridge** (también es la media de la posterior).
- g **de Laplace** (doble exponencial): $-\log g(\beta_j) \propto |\beta_j|$, y la moda es el **Lasso**. Ese *prior* tiene un pico en cero: espera a priori que muchos coeficientes sean exactamente cero (ISL, Fig. 6.11).
- λ es la confianza en el *prior*: cuanto más grande, más se cree que los efectos son pequeños. La validación cruzada la calibra con los datos.

A5. Validación cruzada anidada: el error de la elección

- El error de validación del campeón es el mínimo de muchos: adula un poco (diapositiva de los tres papeles). Si no hay una prueba aparte —pocos datos, o se quiere un intervalo—, la validación anidada estima el error del **procedimiento completo**, elección incluida.
- **Cómo:** un lazo externo de K pliegues para evaluar; dentro de cada pliegue externo, un lazo interno de validación cruzada que elige k o λ sólo con los datos de adentro. Se reporta el promedio de los errores externos.
- **Qué estima:** cuánto se equivoca “elegir λ por CV y ajustar el Lasso”, no un λ en particular. Cuesta $K_{\text{externo}} \times K_{\text{interno}}$ veces más.
- En este curso la partición fija hace ese papel: la prueba de 2.398 puestos no participa en ninguna elección.

A6. En R: lo que conviene saber de glmnet

- **La escala:** glmnet minimiza $\frac{1}{2n} \text{RSS} + \lambda \left[\frac{1-\alpha}{2} \sum_j \beta_j^2 + \alpha \sum_j |\beta_j| \right]$. Los λ que reporta no son comparables con los de ISL, que no divide el RSS por $2n$.
- **Estandariza por dentro** (standardize = TRUE) y devuelve los coeficientes en la escala original de cada variable.
- **Los mismos pliegues para todos:** cv.glmnet(x, y, alpha = 1, foldid = pliegue) permite comparar Ridge, Lasso y Elastic Net con el mismo juez. Después, lambda.min y lambda.1se.
- **Mirar el borde de la grilla:** si $\lambda_{\min}$ es el último valor de la grilla, el mínimo verdadero está afuera. Nos pasó con Ridge en el país; se arregla alargando la grilla (lambda.min.ratio, nlambda).
- **La categoría de referencia:** con una, la penalización encoge hacia ella. En la ficha larga usamos las 33 columnas de departamento, para que cada departamento se encoja hacia lo nacional.
- **Columnas casi vacías:** estandarizar las abarata. En la peor remuestra de la parte 3, la desviación indígena $\times$ Norte de Santander (en la bolsa, el máximo del departamento era 0,7%) quedó con un coeficiente de 16,8, y un puesto fuera de la bolsa con 92% se predijo en 1.629 (votó 98). El Lasso también extrapola: revisar antes las columnas con casi todos sus valores iguales.

A7. El *bootstrap*: fabricar muestras para medir la incertidumbre

ISL 5.2: remuestrear con reemplazo

- 1. La idea:** no tenemos otra muestra del país, pero podemos fabricar muchas parecidas: sacar n observaciones **con reemplazo** de las n que tenemos, recalcular el estadístico en cada remuestra y mirar cuánto varía.
- 2. Cuánto deja por fuera:** la probabilidad de que una observación no salga en n intentos es

$$\left(1 - \frac{1}{n}\right)^n \longrightarrow e^{-1} \approx 0,368.$$

Cada remuestra contiene cerca del 63,2% de las observaciones distintas; con los 9.602 puestos, en promedio queda por fuera el 36,8%. Ese tercio vuelve en la sesión 5: el error *out-of-bag* de los bosques.

- 3. Dos usos de hoy:** la estabilidad de la selección del Lasso (veinte remuestras, el mismo λ : ¿qué columnas sobreviven?) y la incertidumbre de la prueba: con 2.000 remuestras de los 2.398 puestos de prueba, la ventaja del Lasso sobre la ficha con departamentos va de $-1,2$ a $-0,7$ puntos (95%).
- 4. Lo que no hace:** elegir modelos. Las remuestras repiten puestos, así que el modelo ve parte de lo que se evalúa; para elegir, la validación cruzada.