

Big Data y Machine Learning para Economía Aplicada

Week 03: Validación cruzada y regularización: el *pipeline* honesto

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 28, 2026

Previously...

- **La recta como máquina de predecir:** en Cali y su área metropolitana, la educación superior sola deja el RMSE de prueba en 6,8 puntos (la media, 11,0). Minimizar el RSS es minimizar el error de entrenamiento: por eso adula (regla de oro #1).
- **Después de predecir:** predicho contra observado, los residuos como detector y el error por quintil y por lugar, siempre contra una referencia.
- **En la práctica, el concurso de los 511:** todas las combinaciones de las nueve variables, ordenadas por su RMSE de prueba. Ganó una de cinco variables, con 6,42.
- **La limitación:** la recta no viaja. En el país explica el 0,04% del voto.

Dos cabos sueltos

Elegimos al campeón *mirando la prueba*, y para viajar la recta necesita muchas más columnas. Hoy los atamos: el primero con un **juez**, el segundo con una **perilla**.

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Deuda 1, de la práctica. El campeón de los 511 se eligió y se calificó con la misma prueba. ¿Era el mejor modelo, o tuvo suerte con los 86 puestos que le tocaron?

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Deuda 1, de la práctica. El campeón de los 511 se eligió y se calificó con la misma prueba. ¿Era el mejor modelo, o tuvo suerte con los 86 puestos que le tocaron?

La herramienta: el juez. La **validación cruzada** estima el error fuera de muestra sin salir del entrenamiento: lo parte en pedazos, valida en cada uno y promedia. Así se compara y se elige sin tocar la prueba.

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Deuda 1, de la práctica. El campeón de los 511 se eligió y se calificó con la misma prueba. ¿Era el mejor modelo, o tuvo suerte con los 86 puestos que le tocaron?

La herramienta: el juez. La **validación cruzada** estima el error fuera de muestra sin salir del entrenamiento: lo parte en pedazos, valida en cada uno y promedia. Así se compara y se elige sin tocar la prueba.

Deuda 2, de “la recta no viaja”. Para predecir en todo el país, cada variable debe poder pesar distinto en cada departamento: 1.291 columnas. Con tantas, OLS se ajusta hasta al ruido y deja de predecir.

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Deuda 1, de la práctica. El campeón de los 511 se eligió y se calificó con la misma prueba. ¿Era el mejor modelo, o tuvo suerte con los 86 puestos que le tocaron?

La herramienta: el juez. La **validación cruzada** estima el error fuera de muestra sin salir del entrenamiento: lo parte en pedazos, valida en cada uno y promedia. Así se compara y se elige sin tocar la prueba.

Deuda 2, de “la recta no viaja”. Para predecir en todo el país, cada variable debe poder pesar distinto en cada departamento: 1.291 columnas. Con tantas, OLS se ajusta hasta al ruido y deja de predecir.

La herramienta: la perilla. La **regularización** le cobra a cada coeficiente por su tamaño: los encoge, baja la varianza y, con el Lasso, apaga las variables que no alcanzan a pagar. ¿Cuánto cobrar (λ)? Lo decide... el juez.

La pregunta de hoy: ¿cómo elegimos un modelo sin engañarnos?

Deuda 1, de la práctica. El campeón de los 511 se eligió y se calificó con la misma prueba. ¿Era el mejor modelo, o tuvo suerte con los 86 puestos que le tocaron?

La herramienta: el juez. La **validación cruzada** estima el error fuera de muestra sin salir del entrenamiento: lo parte en pedazos, valida en cada uno y promedia. Así se compara y se elige sin tocar la prueba.

Deuda 2, de “la recta no viaja”. Para predecir en todo el país, cada variable debe poder pesar distinto en cada departamento: 1.291 columnas. Con tantas, OLS se ajusta hasta al ruido y deja de predecir.


La herramienta: la perilla. La **regularización** le cobra a cada coeficiente por su tamaño: los encoge, baja la varianza y, con el Lasso, apaga las variables que no alcanzan a pagar. ¿Cuánto cobrar (λ)? Lo decide... el juez.

La idea con la que nos vamos

Resuelven problemas distintos, pero se necesitan: la regularización controla la complejidad y la validación cruzada decide cuánta. La prueba se abre una sola vez, al final.

El concurso de los 511, con cien particiones distintas

La misma base, los mismos 511 modelos, la misma regla 75/25: sólo cambia qué puestos caen en la prueba



- **El número depende de la partición:** la misma recta marca de 5,3 a 8,6 según qué 86 puestos le toquen.
- **El campeón también:** en cien concursos hubo **72 campeones distintos**, de 2 a 9 variables. El de la clase ganó una sola vez.
- El campeón nunca queda peor que la recta: la recta es uno de los 511 candidatos y el campeón es el que menos se equivocó en esa prueba.

Lo que necesitamos

Un juez que no use la prueba para elegir y que no dependa de una sola partición.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 En el país

4 Cierre

Tres papeles para los datos: aprender, elegir y reportar

En la práctica, la prueba hizo dos papeles a la vez: eligió al campeón y lo calificó

En la práctica de la semana 2

entrenamiento (257 puestos) aprender: estimar $\hat{\beta}$	prueba (86) elegir y reportar
---	---

Lo que pide la regla de oro #2


entrenamiento aprender: estimar $\hat{\beta}$	validación elegir	prueba reportar
---	-----------------------------	---------------------------

k , variables, λ una sola vez

- **Elegir** es comparar candidatos y quedarse con uno; **reportar** es decir cuánto se equivocará el elegido en datos nuevos. Son preguntas distintas (ISL, cap. 5).
- **Si la misma prueba hace las dos cosas, el reporte adula.** El 6,42 es el menor de 511 errores, y el menor de muchos errores siempre luce mejor de lo que es: $\mathbb{E}[\min_m \widehat{\text{Error}}_m] \leq \min_m \mathbb{E}[\widehat{\text{Error}}_m]$. Cuantos más candidatos, más suerte se elige.
- **La solución más simple** (ISL 5.1.1): separar los papeles, con un conjunto de validación para elegir y la prueba, intacta, para reportar.

Una sola partición de validación es una lotería


¿Cuántos vecinos del mapa usar? La pregunta de la semana 2, con diez particiones de validación distintas



- Cada curva elige otro k (de 2 a 9) y marca otro nivel: en $k = 10$, de 7,6 a 9,9 según la semilla. Es la Fig. 5.2 de ISL con nuestros puestos.
- Dos defectos (ISL 5.1.1): el resultado **cambia** con la partición, y el modelo se ajusta con **menos datos** (193 de 257), así que el error tiende a exagerar.

Validación cruzada con J pliegues: promediar la lotería

Cada puesto se valida una vez, con un modelo que no lo vio (ISL 5.1.3)




$$CV_{(J)} = \frac{1}{J} \sum_{j=1}^J MSE_j$$

$$MSE_j = \frac{1}{n_j} \sum_{i \in F_j} (y_i - \hat{f}^{(-j)}(x_i))^2$$

$\hat{f}^{(-j)}$: el modelo ajustado **sin** el pliegue j . Se reporta la raíz, $RMSE_{CV}$.

Un regalo del método: los J pliegues dan J errores, así que el promedio viene con su propia incertidumbre, $EE = \text{d.e.}(MSE_1, \dots, MSE_J) / \sqrt{J}$. (ISL la llama *k-fold CV*; escribimos J porque aquí k ya son los vecinos.)



Con 5 pliegues, las diez curvas casi se superponen: el k elegido va de 3 a 6 y el error en $k = 10$, de 9,0 a 9,7 (con una sola partición: de 7,6 a 9,9). Es la Fig. 5.4 de ISL.

¿Cuántos pliegues? De dos a n

La recta de la semana 2 con los 257 puestos: para cada J , cincuenta asignaciones distintas de los pliegues

	RMSE de CV	d.e.
$J = 2$	7,45	0,14
$J = 5$	7,42	0,05
$J = 10$	7,40	0,03
$J = n$ (LOOCV)	7,40	—
Dentro de muestra	7,31	

LOOCV (*leave-one-out*) deja fuera un puesto a la vez. Con OLS no hace falta ajustar n veces (ISL, ec. 5.2):

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$

Es el residuo de entrenamiento inflado por $1/(1 - h_i)$, donde h_i mide cuánto pesa y_i en su propio ajuste. La inflación mide cuánto se acomodó la recta a cada puesto: el optimismo de la regla de oro #1, dato por dato.

El sesgo y la varianza del propio juez (ISL 5.1.4)

Con pocos pliegues cada modelo aprende con menos datos (el juez exagera el error) y el resultado baila con la asignación. Con $J = n$ casi no hay sesgo, pero se promedian n modelos casi idénticos y cuesta n ajustes. En la práctica: $J = 5$ o 10 .

El concurso de los 511, con un juez honesto

Los mismos 511 modelos, calificados por el juez con 10 pliegues, dentro del entrenamiento; la prueba ya no elige: sólo reporta

Modelo	Elegido por	Var.	RMSE de CV	RMSE de prueba
Campeón de la clase	la misma prueba	5	7,19	(6,42)
Campeón del juez	mínimo de la CV	4	7,09	6,83
La recta de la semana 2	regla de un error estándar	1	7,38	6,83

El concurso de los 511, con un juez honesto

Los mismos 511 modelos, calificados por el juez con 10 pliegues, dentro del entrenamiento; la prueba ya no elige: sólo reporta

Modelo	Elegido por	Var.	RMSE de CV	RMSE de prueba
Campeón de la clase	la misma prueba	5	7,19	(6,42)
Campeón del juez	mínimo de la CV	4	7,09	6,83
La recta de la semana 2	regla de un error estándar	1	7,38	6,83

- **El engaño de la primera fila:** el 6,42 va en gris porque no es una calificación: la misma prueba que lo produjo fue la que eligió ese modelo entre los 511. Su nota honesta es la CV, 7,19: el lugar 73 del concurso.
- **El juez elige distinto:** su mínimo es otro modelo (7,09). Y la regla de un error estándar remata: entre los modelos que quedan a menos de un EE del mínimo —empates, a ojos del juez—, el más simple es **la recta de la semana 2**. Con 20 asignaciones distintas de los pliegues, la elige 19 veces.
- **La prueba se abre al final, una sola vez, para reportar:** 6,83. Comparar ese 6,83 con el (6,42) es comparar una calificación con un espejismo: un mismo modelo marca de 5,3 a 8,6 según qué 86 puestos caigan en la prueba (diapositiva 4).

El 7,09 también es un mínimo —el de 511 números de CV— y también adula un poco. Regla de oro #2: la cifra que se reporta sale de la prueba, no del juez.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 En el país

4 Cierre

Con muchas variables, las dos salidas de siempre fallan

Las 37 variables del censo (educación, edades, etnia, servicios, estratos, hogares, tamaño), para los mismos 257 puestos

Salida 1: elegir cuáles entran (el concurso).

- Con 9 variables fueron 511 modelos; con 37 son 2^{37} : **269 millones** de concursos como el de la clase. Años de cómputo.
- Y aunque se pudiera: cuanto más grande el menú, más pesa la suerte. Con 511 candidatos hubo 72 campeones; con 2^{37} , el ganador sería casi puro ruido (ISL 6.1.2).

Salida 2: dejarlas entrar todas, gratis (OLS).

	Coef.	Dentro	CV
Recta	1	7,31	7,38
OLS con las 37	36	5,94	7,17

$R^2 = 0,76$ dentro, con 8 de 36 coeficientes significativos; pero la brecha entre dentro y CV se multiplica por 18 (de 0,07 a 1,23 puntos). Con 36 coeficientes para 257 puestos, el modelo empieza a memorizar: es la **varianza** (ISL, cap. 6).

La tercera salida: cobrar la entrada

En las dos salidas, entrar al modelo es *gratis*: una variable está adentro o afuera. La tercera deja entrar a las 37, pero le pone **precio** al tamaño de cada coeficiente —quien no aporte, que no pese—. La siguiente lámina escribe ese precio en la función objetivo.

Cobrar por la complejidad: la función objetivo penalizada

La suma de cuadrados de la semana 2, más un precio por el tamaño de los coeficientes

$$\hat{\beta}(\lambda) = \arg \min_{\beta} \underbrace{\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2}_{\text{RSS}(\beta): \text{ajustar}} + \underbrace{\lambda P(\beta)}_{\text{el precio}}$$

Precio $P(\beta)$	Nombre	Qué cobra
$\sum_j \mathbb{I}\{\beta_j \neq 0\}$	ℓ_0 : el concurso de los 511	cada variable que entra
$\sum_j \beta_j^2$	ℓ_2 : Ridge	el tamaño, al cuadrado
$\sum_j \beta_j $	ℓ_1 : Lasso	el tamaño

- **La perilla** λ : con $\lambda = 0$ es OLS con todas; con $\lambda \rightarrow \infty$ todos los β_j valen cero y se predice $\bar{y}$, **la referencia** de la semana 2. En medio, un continuo de modelos para que el juez elija.
- **Dos detalles que no son detalles**: el intercepto no se castiga, y las x se **estandarizan** (ISL, ec. 6.6): el precio de un coeficiente no puede depender de si una variable está en pesos o en millones.
- Ridge y Lasso son las versiones tratables del concurso: cambian un conteo imposible de optimizar por una suma que sí se puede (ISL, ec. 6.10).

Ridge: encoger todo, no apagar nada

El precio ℓ_2 : $\text{RSS} + \lambda \sum_j \beta_j^2$ (Hoerl y Kennard, 1970; ISL 6.2.1)

Ridge divide. En el caso simple (predictores ortogonales y estandarizados; ISL, ec. 6.14):

$$\hat{\beta}_j^R = \frac{\hat{\beta}_j}{1 + \lambda}$$

Todos los coeficientes se encogen en la **misma proporción** y ninguno llega a cero exacto.

Y la solución general tiene fórmula:

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$$

Sumar $\lambda\mathbf{I}$ vuelve invertible a $\mathbf{X}'\mathbf{X}$ aunque haya gemelas o más columnas que puestos.

Qué compra: varianza. Dividir estabiliza los coeficientes a cambio de un poco de sesgo. Conviene cuando OLS es ruidoso: pocas observaciones por variable o predictores muy correlacionados (ISL, Fig. 6.5).

Con la gemela de la semana 2: OLS repartió el crédito al azar ($-0,24$ y $-0,51$, con un error estándar 26 veces mayor); Ridge se lo da a las dos por igual. La figura, en dos láminas.

Lo que no hace: apagar. Con 37 columnas, el modelo sigue teniendo 37. Para sacar variables hay que cambiar el precio: **la lámina siguiente.**

Lasso: restar en lugar de dividir

El precio ℓ_1 : $\text{RSS} + \lambda \sum_j |\beta_j|$ (Tibshirani, 1996; ISL 6.2.2)


El Lasso resta. El mismo caso simple (ISL, ec. 6.15):

$$\hat{\beta}_j^L = \text{sign}(\hat{\beta}_j) (|\hat{\beta}_j| - \lambda/2)_+$$

Resta una cantidad fija y, si no alcanza, deja el coeficiente en **cero exacto**: el “umbral suave”. (El porqué, leído como costo marginal: apéndice A8.)

Qué compra: selección. Las variables que no sobreviven a la resta salen del modelo; las fuertes quedan, encogidas. El modelo final es más corto —y con 1.291 columnas por delante, eso es justo lo que necesitamos.


En la figura, los tres precios juntos: **Ridge divide** (la lámina anterior), el **Lasso resta** y el **concurso corta**: todo o nada.



Cada curva: qué queda del coeficiente OLS bajo cada precio, con $\lambda = 1$. Ridge divide entre 2; el Lasso resta 0,5 y anula lo que no llegue; el concurso borra lo que no pase de 1 y deja intacto el resto (ISL, Fig. 6.10; el corte del concurso, ESL, Tab. 3.4).

Elastic Net: las dos penalizaciones a la vez


$RSS + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$: con $\alpha = 1$ es el Lasso y con $\alpha = 0$, Ridge (Zou y Hastie, 2005)



- **La gemela de la semana 2.** Ridge les da a las dos el mismo peso; el Lasso le da el crédito a una y deja a la otra atrás (un sorteo); Elastic Net las trata como Ridge y, como el Lasso, puede apagar lo que no sirve.
- **Qué aporta:** con **grupos** de variables correlacionadas (el censo está lleno: estratos, educación, servicios, edades) conserva o descarta el grupo entero; y con más columnas que observaciones no se limita a n variables, como el Lasso.
- Su región queda entre el diamante del Lasso y el círculo de Ridge (la geometría: apéndice A9): esquinas (ceros) y bordes curvos (agrupa). Dos perillas, λ y α , ambas por CV.

Los caminos: cada λ es un modelo


Las 37 variables del censo en los 257 puestos: los coeficientes estandarizados mientras sube la penalización (ISL, Figs. 6.4 y 6.6)



- **Ridge:** todos se encogen juntos y sólo llegan a cero en el límite. **Lasso:** entran de a uno. Primero, y por mucho, la educación superior; después la estructura de edades, el estrato 6 y la población afro.
- El camino es la lista de candidatos que se le presenta al juez: en lugar de 2^{37} modelos, uno por cada valor de λ .

¿Cuánto encoger? El juez elige λ

10 pliegues, el mínimo y la regla de un error estándar: el protocolo de toda perilla del curso (ISL 6.2.3)



- El eje x es el precio λ . Sin cobrar ($\lambda \approx 0$): **OLS con las 37 variables del censo** (CV 7,17). Precio altísimo ($\lambda \rightarrow \infty$): **la media** de la semana 2.
- Las dos curvas: la gris (dentro) sube siempre: el entrenamiento pediría no cobrar (regla de oro #1). La roja (el juez) dibuja la U de la sesión 1.
- El juez elige: $\lambda_{\min}$ deja 24 variables (CV 6,89); λ_{1SE} sube el precio y deja 7 (7,33). **Arriba:** cuántas variables sobreviven a cada precio.

Las 37 variables del censo en el área metropolitana: la tabla

Los mismos 10 pliegues para todos; la prueba de 86 puestos, abierta una vez

Modelo	Coef. $\neq 0$	RMSE dentro	RMSE de CV	RMSE de prueba
Recta (educación superior)	1	7,31	7,38	6,83
OLS con las 37 del censo	36	5,94	7,17	6,70
Ridge ($\lambda_{\min}$)	37	6,21	6,82	6,51
Lasso ($\lambda_{\min}$)	24	6,17	6,89	6,42
Lasso (λ_{1SE})	7	7,05	7,33	6,95
Elastic Net, $\alpha = 0,5$ ($\lambda_{\min}$)	24	6,20	6,88	6,44

- **Nadie le dijo al modelo qué sobra: el precio lo averiguó solo.** La CV mejora de 7,17 (OLS, entrada gratis) a 6,82–6,89. Lo que el concurso buscaba con 2^{37} modelos, la perilla lo encontró con una grilla de λ .
- **¿Ridge o Lasso? Es una pregunta sobre el mundo, no sobre el método:** si la señal está repartida entre muchas variables correlacionadas, divide mejor Ridge; si la cargan unas pocas, resta mejor el Lasso (ISL, Figs. 6.8 y 6.9). No se sabe de antemano: se le pregunta al juez. Aquí gana Ridge, por poco.
- **Con 86 puestos la prueba no corona:** medio punto de diferencia cabe en el ruido. Hoy importa la *forma* de decidir; el veredicto con dientes llega en el país.

1 El juez: validar sin gastar la prueba


2 La perilla: regularizar

3 En el país

4 Cierre

Ahora sí, el país: la y antes de cualquier modelo


Los 9.602 puestos de entrenamiento de la partición fija del curso (2.398 quedan bajo llave)



- En el país la y es casi **plana** de 0 a 100: una desviación de 27,3 frente a 12,2 en el área metropolitana. Petro gana en el 53% de los puestos.
- Predecir la media para todos deja un RMSE de prueba de 26,7; la recta de la semana 2 también deja 26,7: la educación sola explica el 0,04% del voto.

La educación pesa distinto en cada departamento

Una recta por departamento, sólo con la educación superior: su pendiente ± 2 errores estándar, contra el tamaño del departamento



- **A la derecha, señales firmes y de signos contrarios:** $-0,56$ en Bogotá, $+1,04$ en Boyacá, $+1,02$ en Cundinamarca. La recta nacional es plana porque **promedia relaciones opuestas**: por eso explica el $0,04\%$.
- **La salida:** que cada variable pese distinto en cada departamento. Cuesta: $37 + 33 + 37 \times 33 = 1.291$ columnas, censo $\times$ departamento.
- **El embudo es la advertencia:** a la izquierda los intervalos explotan (Vaupés: 20 puestos para 38 coeficientes). Ahí OLS inventa: **necesitamos el precio**.

1.291 columnas: OLS se desploma; con la perilla, no

Los mismos 10 pliegues para todos; la prueba de 2.398 puestos, abierta una sola vez

Modelo	Coef. $\neq 0$	RMSE dentro	RMSE de CV	RMSE de prueba
Media del entrenamiento	0	27,3	27,3	26,7
Recta (educación superior)	1	27,3	27,3	26,7
Las 37 del censo	36	20,2	20,3	19,8
Censo + dummies de depto.	68	15,6	15,8	15,6
<i>Censo $\times$ departamento (1.291 columnas):</i>				
OLS	1.122	12,3	más de 7.000	69,1
Ridge ($\lambda_{\min}$)	1.278	13,1	17,2	14,7
Lasso ($\lambda_{\min}$)	202	14,5	14,9	14,7
Elastic Net ($\lambda_{\min}$)	230	14,5	14,9	14,7

- **OLS**: el mejor error dentro y el peor fuera; en los departamentos chicos p se acerca a n y el ajuste interpola (ISL 6.4.2).
- **Ridge** acierta en la prueba (14,7), pero el juez ve lo que una prueba sola esconde: sus tres peores pliegues marcan 18,3, 18,6 y 25,9 (los del Lasso no pasan de 15,5). En el peor, 3 puestos de San Andrés hacen el 69% del error: Ridge encoge pero no apaga.
- El juez elige **al Lasso**: 14,9 en CV, estable en todos los pliegues (de 14,3 a 15,5), y 14,7 en la prueba: $-0,9$ frente a censo + dummies (intervalo *bootstrap* del 95%: de $-1,2$ a $-0,7$).

Vecinos que se copian: ¿qué pregunta responde tu validación?

Pliegues al azar o pliegues de municipios enteros: la pregunta de la semana 2, ¿cómo validar cuando los puestos vecinos se parecen?

RMSE de CV	Pliegues al azar	Municipios enteros	Aumento
Media del entrenamiento	27,3	27,4	+0,1
Las 37 del censo	20,3	20,8	+0,5
Censo + dummies de departamento	15,8	16,7	+0,9
Lasso, censo $\times$ departamento	14,9	16,6	+1,7
k -NN en el mapa ($k = 7$)	12,0	15,0	+3,0

Vecinos que se copian: ¿qué pregunta responde tu validación?

Pliegues al azar o pliegues de municipios enteros: la pregunta de la semana 2, ¿cómo validar cuando los puestos vecinos se parecen?

RMSE de CV	Pliegues al azar	Municipios enteros	Aumento
Media del entrenamiento	27,3	27,4	+0,1
Las 37 del censo	20,3	20,8	+0,5
Censo + dummies de departamento	15,8	16,7	+0,9
Lasso, censo $\times$ departamento	14,9	16,6	+1,7
k -NN en el mapa ($k = 7$)	12,0	15,0	+3,0

- **Dos jueces, dos preguntas.** Pliegues al azar: ¿qué tal predigo un puesto nuevo en un municipio que *conozco*? Municipios enteros fuera: ¿y en uno que *nunca* vi? Ninguno es “el” error del modelo: cada uno responde su pregunta.
- **Cuanto más se apoya el modelo en los vecinos, más pierde en la segunda:** el k -NN del mapa pierde 3,0 (su única información es el vecino), el Lasso 1,7 y el censo solo 0,5. El k -NN sigue ganando, pero su ventaja sobre el Lasso se achica.
- **La regla:** el esquema de validación imita el uso (Roberts et al., 2017). Con datos en el tiempo: entrenar en una elección y probar en la siguiente, nunca al azar.

1 El juez: validar sin gastar la prueba

2 La perilla: regularizar

3 En el país

4 Cierre

Recap

- 1 **Elegir también es ajustar.** Si la prueba elige, deja de ser prueba: en cien particiones el concurso de los 511 tuvo 72 campeones, y el 6,42 de la clase era la partición.
- 2 **El juez:** la validación cruzada con $J = 5$ o 10 estima el error fuera de muestra sin tocar la prueba; se elige con el mínimo o con la regla de un error estándar, y la prueba se abre una vez. Juzgado así, el concurso elige la recta.
- 3 **La perilla:** la penalización cambia el interruptor por variable por un precio continuo. Ridge divide (encoge y no apaga); el Lasso resta y apaga (esquinas, peaje constante); Elastic Net combina y agrupa. λ lo elige el juez.
- 4 **Juntos, en el país:** con 1.291 columnas OLS se desploma (69,1) y el Lasso deja el error de prueba en 14,7. Lo que selecciona cambia con la muestra y la predicción casi no: predictores, no causas.
- 5 **La receta completa y la pregunta correcta:** todo lo que mira la y va dentro de los pliegues (regla de oro #3), y los pliegues deben imitar el uso: al azar o por municipio no es un detalle técnico.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, secciones 4.1–4.3 (clasificación y regresión logística) y 4.7.6 (el laboratorio de k -NN como clasificador).
Guía: la sección 4.4.2 tiene la matriz de confusión y la curva ROC con el ejemplo *Default*; las secciones 4.4–4.5 (LDA, QDA, Naive Bayes) van al apéndice de la sesión.

Próxima sesión — clasificación: de la logística a las decisiones. La misma elección, otra pregunta: a la campaña no le importa si Petro saca 48 o 52 en un puesto; le importa **si lo gana**. La y pasa a ser una categoría; la logística como referencia y, con las herramientas de hoy, la logística penalizada; y la mitad que decide: por qué la exactitud engaña, la matriz de confusión, el umbral como decisión con costos, ROC y AUC, calibración.

Aplicación en R: los 12.000 puestos del país, las variables de hoy y una y nueva, `gana_petro`. **Se publica el Problem Set 1** (vivienda en Cali; entrega: martes 20 de octubre, 8:00).

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 5 (5.1) y 6 (6.1, 6.2 y 6.4). [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Secs. 3.4 (Ridge, Lasso y Elastic Net) y 7.10 (la validación cruzada bien y mal hecha). [ESL]
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.
- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society, Series B*, 67(2), 301–320.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1–22. [glmnet]
- Roberts, D. R., et al. (2017). Cross-validation Strategies for Data with Temporal, Spatial, Hierarchical, or Phylogenetic Structure. *Ecography*, 40(8), 913–929.
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87–106.

5 Apéndice: para profundizar

A1. Antes de la validación cruzada: C_p , AIC, BIC y R^2 ajustado

Corregir el error de entrenamiento en vez de estimar el de prueba (ISL 6.1.3)

Con un modelo OLS de d predictores y $\hat{\sigma}^2$ estimado con el modelo completo:

$$C_p = \frac{1}{n}(\text{RSS} + 2d\hat{\sigma}^2), \quad \text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2),$$

$$R_{\text{aj}}^2 = 1 - \frac{\text{RSS}/(n - d - 1)}{\text{TSS}/(n - 1)}$$

- Suman al RSS un precio por cada variable: son, otra vez, un precio ℓ_0 . AIC es proporcional a C_p en el modelo lineal gaussiano; BIC cobra más ($\log n > 2$ desde $n = 8$) y elige modelos más pequeños.
- Sirven para elegir el tamaño en el concurso o en la selección paso a paso (*stepwise*: añadir, o quitar, una variable a la vez; $1 + p(p+1)/2$ modelos en lugar de 2^p , sin garantía de encontrar el mejor).
- Frente a la validación cruzada: suponen el modelo correcto y un buen $\hat{\sigma}^2$, y fallan cuando p se acerca a n (ISL 6.4.2). La CV estima el error de prueba directamente y hoy su costo casi nunca es un problema.

A2. Ridge por dentro: encoge más donde los datos informan menos

1. **La descomposición:** con $\mathbf{X} = \mathbf{UDV}'$ (valores singulares $d_1 \geq \dots \geq d_p$),

$$\mathbf{x}\hat{\beta}^{OLS} = \sum_j \mathbf{u}_j \mathbf{u}_j' \mathbf{y}, \quad \mathbf{x}\hat{\beta}^R = \sum_j \mathbf{u}_j \frac{d_j^2}{d_j^2 + \lambda} \mathbf{u}_j' \mathbf{y}.$$

2. **La lectura:** Ridge encoge cada dirección de los datos por el factor $d_j^2/(d_j^2 + \lambda)$. Las direcciones con mucha variación (d_j grande) casi no se tocan; las que apenas varían se encogen casi a cero.

3. **La gemela:** educación y su gemela varían juntas (dirección “suma”, d_j grande) y casi nunca por separado (dirección “diferencia”, d_j diminuto). OLS estima la diferencia con puro ruido ($-0,24$ contra $-0,51$); Ridge la aplasta y reparte el efecto por igual.

4. **Grados de libertad efectivos:** $gl(\lambda) = \sum_j d_j^2/(d_j^2 + \lambda)$, de p (con $\lambda = 0$) a 0: la complejidad del modelo como una perilla continua (ESL 3.4.1).

A3. El Lasso por dentro: optimalidad y descenso por coordenadas

1. Las condiciones de optimalidad (el RSS no es derivable en cero por el valor absoluto; se usa el subgradiente): en la solución, para cada j ,

$$\hat{\beta}_j \neq 0 \Rightarrow 2 |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})| = \lambda, \quad \hat{\beta}_j = 0 \Leftrightarrow 2 |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})| \leq \lambda.$$

Es el peaje de la diapositiva del Lasso: una variable entra sólo si su correlación con el residuo, su beneficio marginal, llega a λ .

2. Descenso por coordenadas (lo que hace `glmnet`): se fija todo menos β_j , se calcula el residuo parcial $r^{(j)} = \mathbf{y} - \mathbf{X}_{-j}\hat{\beta}_{-j}$, y con $\mathbf{x}_j$ estandarizada

$$\hat{\beta}_j \leftarrow \text{sign}(z_j) (|z_j| - \lambda/2)_+ / \mathbf{x}'_j \mathbf{x}_j, \quad z_j = \mathbf{x}'_j r^{(j)}.$$

Es el umbral suave de la diapositiva, aplicado variable por variable hasta que nada cambia.

3. El camino completo: se empieza en el λ en que todo vale cero, $\lambda_{\max} = 2 \max_j |\mathbf{x}'_j \mathbf{y}|$, y se baja por una grilla usando cada solución como punto de partida de la siguiente (Friedman, Hastie y Tibshirani, 2010).

A4. La lectura bayesiana: penalizar es tener un *prior*

Con errores normales y un *prior* independiente para cada coeficiente, $p(\beta) = \prod_j g(\beta_j)$, la moda de la posterior es

$$\begin{aligned}\hat{\beta} &= \arg \max_{\beta} \left[\log f(\mathbf{y} \mid \mathbf{X}, \beta) + \sum_j \log g(\beta_j) \right] \\ &= \arg \min_{\beta} \left[\text{RSS}(\beta) - 2\sigma^2 \sum_j \log g(\beta_j) \right].\end{aligned}$$

- g **normal** con media cero: $-\log g(\beta_j) \propto \beta_j^2$, y la moda es **Ridge** (también es la media de la posterior).
- g **de Laplace** (doble exponencial): $-\log g(\beta_j) \propto |\beta_j|$, y la moda es el **Lasso**. Ese *prior* tiene un pico en cero: espera a priori que muchos coeficientes sean exactamente cero (ISL, Fig. 6.11).
- λ es la confianza en el *prior*: cuanto más grande, más se cree que los efectos son pequeños. La validación cruzada la calibra con los datos.

A5. Validación cruzada anidada: el error de la elección

- El error de validación del campeón es el mínimo de muchos: adula un poco (diapositiva de los tres papeles). Si no hay una prueba aparte —pocos datos, o se quiere un intervalo—, la validación anidada estima el error del **procedimiento completo**, elección incluida.
- **Cómo:** un lazo externo de J pliegues para evaluar; dentro de cada pliegue externo, un lazo interno de validación cruzada que elige k o λ sólo con los datos de adentro. Se reporta el promedio de los errores externos.
- **Qué estima:** cuánto se equivoca “elegir λ por CV y ajustar el Lasso”, no un λ en particular. Cuesta $J_{\text{externo}} \times J_{\text{interno}}$ veces más.
- En este curso la partición fija hace ese papel: la prueba de 2.398 puestos no participa en ninguna elección.

A6. En R: lo que conviene saber de glmnet

- **La escala:** glmnet minimiza $\frac{1}{2n} \text{RSS} + \lambda \left[\frac{1-\alpha}{2} \sum_j \beta_j^2 + \alpha \sum_j |\beta_j| \right]$. Los λ que reporta no son comparables con los de ISL, que no divide el RSS por $2n$.
- **Estandariza por dentro** (standardize = TRUE) y devuelve los coeficientes en la escala original de cada variable.
- **Los mismos pliegues para todos:** cv.glmnet(x, y, alpha = 1, foldid = pliegue) permite comparar Ridge, Lasso y Elastic Net con el mismo juez. Después, lambda.min y lambda.1se.
- **Mirar el borde de la grilla:** si $\lambda_{\min}$ es el último valor de la grilla, el mínimo verdadero está afuera. Nos pasó con Ridge en el país; se arregla alargando la grilla (lambda.min.ratio, nlambda).
- **La categoría de referencia:** con una, la penalización encoge hacia ella. En la matriz censo $\times$ departamento usamos las 33 columnas de departamento, para que cada departamento se encoja hacia lo nacional.
- **Columnas casi vacías:** estandarizar las abarata. En la peor remuestra de la parte 3, la desviación indígena $\times$ Norte de Santander (en la bolsa, el máximo del departamento era 0,7%) quedó con un coeficiente de 16,8, y un puesto fuera de la bolsa con 92% se predijo en 1.629 (votó 98). El Lasso también extrapola: revisar antes las columnas con casi todos sus valores iguales.

A7. El *bootstrap*: fabricar muestras para medir la incertidumbre

ISL 5.2: remuestrear con reemplazo

1. **La idea:** no tenemos otra muestra del país, pero podemos fabricar muchas parecidas: sacar n observaciones **con reemplazo** de las n que tenemos, recalcular el estadístico en cada remuestra y mirar cuánto varía.
2. **Cuánto deja por fuera:** la probabilidad de que una observación no salga en n intentos es


$$\left(1 - \frac{1}{n}\right)^n \longrightarrow e^{-1} \approx 0,368.$$

Cada remuestra contiene cerca del 63,2% de las observaciones distintas; con los 9.602 puestos, en promedio queda por fuera el 36,8%. Ese tercio vuelve en la sesión 5: el error *out-of-bag* de los bosques.

3. **Dos usos de hoy:** la estabilidad de la selección del Lasso (veinte remuestras, el mismo λ : ¿qué columnas sobreviven?) y la incertidumbre de la prueba: con 2.000 remuestras de los 2.398 puestos de prueba, la ventaja del Lasso sobre censo + dummies va de $-1,2$ a $-0,7$ puntos (95%).
4. **Lo que no hace:** elegir modelos. Las remuestras repiten puestos, así que el modelo ve parte de lo que se evalúa; para elegir, la validación cruzada.

A8. Por qué el cero es exacto: el costo marginal del precio

Leído como economistas: cada variable compra peso mientras su beneficio marginal supere al costo marginal (el caso simple)




- **El beneficio marginal (negro)**: cuánto baja el RSS el siguiente peso de β_j . Alto al arrancar, cero al llegar a OLS.
- **Ridge (azul)** cobra $2\lambda\beta_j$: **el primer peso sale casi gratis** y comprar un poco siempre conviene. Por eso encoge y nunca apaga (puntos azules).
- **El Lasso (rojo)** cobra λ **desde el primer peso**: un peaje plano de entrada. Si el beneficio inicial no lo cubre, lo óptimo es no entrar: $\hat{\beta}_j = 0$ exacto (la **esquina**, círculo rojo).

El cero no es un redondeo: es una decisión de esquina. Una variable entra sólo si su correlación con el residuo paga el peaje λ (apéndice A3).

A9. La geometría: el diamante y el círculo


El mismo problema con presupuesto: mínimo RSS sujeto a $\sum_j |\beta_j| \leq s$ (Lasso) o a $\sum_j \beta_j^2 \leq s^2$ (Ridge)



- La educación superior y el estrato alto (las gemelas de la matriz de pares, correlación 0,81), estandarizadas. Cada elipse un punto con el mismo RSS alrededor de OLS, $(-10, 1; 0, 4)$. Presupuesto: $s = 8$.
- El **diamante** tiene esquinas sobre los ejes: la primera elipse que lo toca lo hace en una esquina y el estrato alto queda en **cero**. El **círculo** no tiene esquinas: Ridge conserva las dos y le pasa al estrato alto parte del crédito. Con p variables el diamante tiene más esquinas, y hay más ceros (ISL, Fig. 6.7).

A10. Qué eligió el Lasso


Sobreviven 202 de 1.291 columnas: 15 efectos nacionales, 1 constante y 186 desviaciones



- **El precio es el mismo para todas las columnas; el beneficio, no.** Una desviación departamental sólo mejora la predicción en los puestos de *su* departamento: cuantos más puestos, más beneficio junta para pagar el peaje λ (apéndice A8). Por eso Nariño conserva 12 de sus 37 y los departamentos chicos, casi ninguna: correlación 0,64 con el tamaño.
- **Qué dejó pesar distinto: el mapa social, no la educación.** La zona rural (en 14 departamentos), la población indígena (12) y la afro (11); la educación superior casi no se aparta de su efecto nacional (2 de 33).

A11. Cambia la lista, no la predicción

El mismo λ en 20 remuestras *bootstrap* (apéndice A7): ¿en cuántas entra cada columna?



- **El experimento:** 20 versiones *bootstrap*, el mismo λ . **La lista baila** (583 columnas entran alguna vez; 119, una sola; 47, siempre), **la predicción no:** un puesto típico se mueve 1,4 puntos (su error: 14,7).
- **La educación superior nacional entra en 2 de 20.** No porque no importe: las 15 nacionales que entran explican el 82 % de su variación (la gemela, a gran escala).

El Lasso selecciona predictores, no causas

Que una columna salga no dice que no importe: otra cuenta lo mismo. Se confía en la predicción, no en la lista (ISL 6.4.4; Mullainathan y Spiess, 2017).

A12. Una columna que ya sabe la respuesta (regla de oro #3)

Añadir a las 37 del censo el voto promedio del municipio: una idea natural, calculada en el lugar equivocado

Censo + promedio municipal	RMSE
CV, promedio con todo	11,2
CV, promedio en cada pliegue	13,1
Prueba	13,0

A12. Una columna que ya sabe la respuesta (regla de oro #3)

Añadir a las 37 del censo el voto promedio del municipio: una idea natural, calculada en el lugar equivocado

Censo + promedio municipal	RMSE
CV, promedio con todo	11,2
CV, promedio en cada pliegue	13,1
Prueba	13,0

- **La idea parece inocente; el error está en dónde se calcula:** con todos los puestos, *antes* de partir en pliegues. Un municipio típico tiene 5: cada puesto pesa $1/5$ en su propio predictor. La respuesta se filtró.
- **El juez, engañado, promete 11,2; la prueba cobra 13,0.** Y la variable no es el problema: calculada *dentro* de cada pliegue es legítima y hasta buena (13,0: el municipio sabe mucho del voto).

Regla de oro #3: la validación cruzada valida la receta completa

Todo lo que aprende de la y —elegir variables, fijar k o λ , promedios por grupo— se hace **dentro** de cada pliegue (ISL 6.1.3 lo exige hasta para el concurso).