

Big Data y Machine Learning para Economía Aplicada

Week 03: Clasificación — de la logística a las métricas que deciden

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 9, 2026

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- **Flexibilidad controlada:** interacciones, *splines*, GAM y *k*-NN bajan el sesgo y pagan con varianza; en alta dimensión los vecinos dejan de ser vecinos.

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- **Flexibilidad controlada:** interacciones, *splines*, GAM y *k*-NN bajan el sesgo y pagan con varianza; en alta dimensión los vecinos dejan de ser vecinos.
- **Evaluar una regresión:** RMSE, MAE y R^2 de prueba, siempre contra un baseline; predicho vs. observado, error por decil y por subgrupo.

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- **Flexibilidad controlada:** interacciones, *splines*, GAM y k -NN bajan el sesgo y pagan con varianza; en alta dimensión los vecinos dejan de ser vecinos.
- **Evaluar una regresión:** RMSE, MAE y R^2 de prueba, siempre contra un baseline; predicho vs. observado, error por decil y por subgrupo.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- **Flexibilidad controlada:** interacciones, *splines*, GAM y *k*-NN bajan el sesgo y pagan con varianza; en alta dimensión los vecinos dejan de ser vecinos.
- **Evaluar una regresión:** RMSE, MAE y R^2 de prueba, siempre contra un baseline; predicho vs. observado, error por decil y por subgrupo.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- Quedó una pregunta anotada en la presentación de Kim & Zilinsky: ¿por qué la AUC sube con las décadas y la *accuracy* no?

Previously...

- **OLS como máquina de predecir:** las variables se eligen por error de prueba; el modelo lineal es el *baseline* contra el que todo lo demás se mide.
- **Flexibilidad controlada:** interacciones, *splines*, GAM y *k*-NN bajan el sesgo y pagan con varianza; en alta dimensión los vecinos dejan de ser vecinos.
- **Evaluar una regresión:** RMSE, MAE y R^2 de prueba, siempre contra un baseline; predicho vs. observado, error por decil y por subgrupo.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- Quedó una pregunta anotada en la presentación de Kim & Zilinsky: ¿por qué la AUC sube con las décadas y la *accuracy* no?

Hoy

y es una **categoría**. Cambian el modelo (logística en vez de OLS), el objeto que se predice (una probabilidad y, con ella, una decisión) y, sobre todo, la evaluación: con clases desbalanceadas y errores de costo distinto, **elegir la métrica y el umbral es la decisión económica**.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre

Qué cambia cuando y es una categoría

Las preguntas del curso, en versión binaria: ¿ganó el eventual presidente en la mesa? ¿El hogar está en pobreza extrema? ¿El crédito se paga? ¿El estudiante deserta? ¿El avalúo supera el precio de venta?

Qué cambia cuando y es una categoría

Las preguntas del curso, en versión binaria: ¿ganó el eventual presidente en la mesa? ¿El hogar está en pobreza extrema? ¿El crédito se paga? ¿El estudiante deserta? ¿El avalúo supera el precio de venta? Ahora $y \in \{0, 1\}$ (o K clases) y queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$: es la media condicional de una variable binaria, así que todo lo de la sesión 1 sigue en pie.
- Una **decisión** $\hat{y}(x) \in \{0, 1\}$, que exige además un **umbral**: predecir 1 si $\hat{p}(x) \geq \tau$.

Qué cambia cuando y es una categoría

Las preguntas del curso, en versión binaria: ¿ganó el eventual presidente en la mesa? ¿El hogar está en pobreza extrema? ¿El crédito se paga? ¿El estudiante deserta? ¿El avalúo supera el precio de venta? Ahora $y \in \{0, 1\}$ (o K clases) y queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$: es la media condicional de una variable binaria, así que todo lo de la sesión 1 sigue en pie.
- Una **decisión** $\hat{y}(x) \in \{0, 1\}$, que exige además un **umbral**: predecir 1 si $\hat{p}(x) \geq \tau$.

La pérdida natural es la 0–1 de la sesión 1, $L = \mathbb{I}\{y \neq \hat{y}\}$, cuyo promedio es la tasa de error. Pero un falso positivo y un falso negativo casi nunca cuestan lo mismo: de ahí sale toda la segunda mitad de la clase.

Qué cambia cuando y es una categoría

Las preguntas del curso, en versión binaria: ¿ganó el eventual presidente en la mesa? ¿El hogar está en pobreza extrema? ¿El crédito se paga? ¿El estudiante deserta? ¿El avalúo supera el precio de venta? Ahora $y \in \{0, 1\}$ (o K clases) y queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$: es la media condicional de una variable binaria, así que todo lo de la sesión 1 sigue en pie.
- Una **decisión** $\hat{y}(x) \in \{0, 1\}$, que exige además un **umbral**: predecir 1 si $\hat{p}(x) \geq \tau$.


La pérdida natural es la 0–1 de la sesión 1, $L = \mathbb{I}\{y \neq \hat{y}\}$, cuyo promedio es la tasa de error. Pero un falso positivo y un falso negativo casi nunca cuestan lo mismo: de ahí sale toda la segunda mitad de la clase.

El plan

Un modelo para $p(x)$ (la logística y sus alternativas) $\rightarrow$ de la probabilidad a la decisión $\rightarrow$ las métricas que deciden $\rightarrow$ la aplicación con las mesas electorales.

Por qué no OLS: el modelo de probabilidad lineal como predictor


ISL, sección 4.2



- Regresar la *dummy* sobre x es el **modelo de probabilidad lineal** (LPM). Estima bien la pendiente promedio. . .
- . . . pero como **predictor** entrega $\hat{p} < 0$ y $\hat{p} > 1$, con las que no se puede decidir con umbrales ni hablar de calibración.
- Con $K > 2$ clases codificadas 1, 2, 3 impone un orden que no existe.

Por qué no OLS: el modelo de probabilidad lineal como predictor

ISL, sección 4.2



- Regresar la *dummy* sobre x es el **modelo de probabilidad lineal** (LPM). Estima bien la pendiente promedio. . .
- . . . pero como **predictor** entrega $\hat{p} < 0$ y $\hat{p} > 1$, con las que no se puede decidir con umbrales ni hablar de calibración.
- Con $K > 2$ clases codificadas 1, 2, 3 impone un orden que no existe.

Y , no β , otra vez

Para estimar un *efecto marginal promedio* el LPM es legítimo, y ustedes lo usan en Inferencia Causal. Hoy el objetivo es otro: **probabilidades calibradas para clasificar y decidir**.

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0,5$); a un lado se predice 1, al otro 0.

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0,5$); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es positivo siempre que las clases se *traslapen*: mesas idénticas en X con ganadores distintos; es el análogo del σ^2 irreducible de la sesión 1, el piso que ningún método perfora.

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0,5$); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es positivo siempre que las clases se *traslapen*: mesas idénticas en X con ganadores distintos; es el análogo del σ^2 irreducible de la sesión 1, el piso que ningún método perfora.
- Nadie conoce $P(y \mid x)$: **cada clasificador es una manera distinta de estimarla** a partir de datos (o de estimar directamente la frontera).

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0,5$); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es positivo siempre que las clases se *traslapen*: mesas idénticas en X con ganadores distintos; es el análogo del σ^2 irreducible de la sesión 1, el piso que ningún método perfora.
- Nadie conoce $P(y \mid x)$: **cada clasificador es una manera distinta de estimarla** a partir de datos (o de estimar directamente la frontera).

Consecuencia para la evaluación

Si el error de Bayes es 15%, pedir 95% de acierto es pedir magia. La pregunta útil no es “¿acierta mucho?” sino “¿cuánto mejor que el baseline, y en qué clase falla?”.


- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre

Regresión logística: el modelo

Una recta para los *log-odds*, una curva en S para la probabilidad

Modelar la probabilidad con una función que **vive en** $[0, 1]$:

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$




Regresión logística: el modelo

Una recta para los *log-odds*, una curva en S para la probabilidad

Modelar la probabilidad con una función que **vive en** $[0, 1]$:

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$



- El índice es lineal $\Rightarrow$ la frontera $p(x) = 0,5 \iff x'\beta = 0$ es un **hiperplano**: la logística separa con una recta, como OLS ajusta con una recta.
- **Parámetros:** β . **Hiperparámetros:** ninguno; la flexibilidad viene de interacciones y *splines* (sesión 2) o de una penalización (sesión 5).

Cómo se ajusta: máxima verosimilitud en una línea

Se eligen los β que hacen **más probable lo observado**: p_i alta para los unos y baja para los ceros ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

Cómo se ajusta: máxima verosimilitud en una línea

Se eligen los β que hacen **más probable lo observado**: p_i alta para los unos y baja para los ceros ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

- No hay solución cerrada: ℓ es cóncava y `glm()` la maximiza por Newton–Raphson en milisegundos. El gradiente, $\sum_i x_i(y_i - p_i)$, está en el apéndice y reaparece en el *boosting* de la sesión 6.

Cómo se ajusta: máxima verosimilitud en una línea

Se eligen los β que hacen **más probable lo observado**: p_i alta para los unos y baja para los ceros ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

- No hay solución cerrada: ℓ es cóncava y `glm()` la maximiza por Newton–Raphson en milisegundos. El gradiente, $\sum_i x_i(y_i - p_i)$, está en el apéndice y reaparece en el *boosting* de la sesión 6.
- $-\ell(\beta)/n$ es la **log-loss**: la pérdida que la logística minimiza es también una métrica que reportaremos.

Cómo se ajusta: máxima verosimilitud en una línea

Se eligen los β que hacen **más probable lo observado**: p_i alta para los unos y baja para los ceros ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

- No hay solución cerrada: ℓ es cóncava y `glm()` la maximiza por Newton–Raphson en milisegundos. El gradiente, $\sum_i x_i(y_i - p_i)$, está en el apéndice y reaparece en el *boosting* de la sesión 6.
- $-\ell(\beta)/n$ es la **log-loss**: la pérdida que la logística minimiza es también una métrica que reportaremos.
- **Separación perfecta**: si una variable separa las clases sin error, $\hat{\beta} \rightarrow \infty$ y `glm()` avisa. Casi siempre es *leakage* (una variable que ya contiene a y) o una señal de que hay que regularizar: la logística **penalizada** de la sesión 5.

Cómo se ajusta: máxima verosimilitud en una línea

Se eligen los β que hacen **más probable lo observado**: p_i alta para los unos y baja para los ceros ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

- No hay solución cerrada: ℓ es cóncava y `glm()` la maximiza por Newton–Raphson en milisegundos. El gradiente, $\sum_i x_i(y_i - p_i)$, está en el apéndice y reaparece en el *boosting* de la sesión 6.
- $-\ell(\beta)/n$ es la **log-loss**: la pérdida que la logística minimiza es también una métrica que reportaremos.
- **Separación perfecta**: si una variable separa las clases sin error, $\hat{\beta} \rightarrow \infty$ y `glm()` avisa. Casi siempre es *leakage* (una variable que ya contiene a y) o una señal de que hay que regularizar: la logística **penalizada** de la sesión 5.

Lo que hay que retener

La logística es el OLS de las probabilidades: lineal en el índice, sin perillas, estable, rápida y razonablemente calibrada. Es el **baseline de clasificación** del curso.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1 - p)$ por una unidad más de x_j . Es lo que ya conocen de Econometría II.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1-p)$ por una unidad más de x_j . Es lo que ya conocen de Econometría II.
- El efecto sobre la **probabilidad** no es constante: $\partial p / \partial x_j = \beta_j p(1-p)$, máximo en $p = 0,5$ y casi nulo en las colas. Una misma variable mueve mucho a las mesas “indecisas” y nada a las seguras.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1-p)$ por una unidad más de x_j . Es lo que ya conocen de Econometría II.
- El efecto sobre la **probabilidad** no es constante: $\partial p / \partial x_j = \beta_j p(1-p)$, máximo en $p = 0,5$ y casi nulo en las colas. Una misma variable mueve mucho a las mesas “indecisas” y nada a las seguras.
- Para **predecir**, lo que importa es $\hat{p}(x)$ completo, no un coeficiente: variables “no significativas” pueden mejorar la AUC en la prueba, y significativas pueden no mover nada.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1-p)$ por una unidad más de x_j . Es lo que ya conocen de Econometría II.
- El efecto sobre la **probabilidad** no es constante: $\partial p / \partial x_j = \beta_j p(1-p)$, máximo en $p = 0,5$ y casi nulo en las colas. Una misma variable mueve mucho a las mesas “indecisas” y nada a las seguras.
- Para **predecir**, lo que importa es $\hat{p}(x)$ completo, no un coeficiente: variables “no significativas” pueden mejorar la AUC en la prueba, y significativas pueden no mover nada.

Significativo no es predictivo, versión clasificación

En Kim & Zilinsky (2024) el logit del voto sobre demografía tiene coeficientes significativos y crecientes, y acierta el 64% fuera de muestra, década tras década. Los coeficientes dicen *qué usa* el modelo; la prueba dice *cuánto sabe*.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1-p)$ por una unidad más de x_j . Es lo que ya conocen de Econometría II.
- El efecto sobre la **probabilidad** no es constante: $\partial p / \partial x_j = \beta_j p(1-p)$, máximo en $p = 0,5$ y casi nulo en las colas. Una misma variable mueve mucho a las mesas “indecisas” y nada a las seguras.
- Para **predecir**, lo que importa es $\hat{p}(x)$ completo, no un coeficiente: variables “no significativas” pueden mejorar la AUC en la prueba, y significativas pueden no mover nada.

Significativo no es predictivo, versión clasificación

En Kim & Zilinsky (2024) el logit del voto sobre demografía tiene coeficientes significativos y crecientes, y acierta el 64% fuera de muestra, década tras década. Los coeficientes dicen *qué usa* el modelo; la prueba dice *cuánto sabe*.

Hoy leemos $\hat{\beta}$ para entender qué hace el modelo, no para estimar efectos causales. Las herramientas para “abrir” modelos que no tienen coeficientes llegan en la sesión 7.

Más de dos clases (y una nota sobre conteos)

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad:

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la función } \textit{softmax}),$$

con una clase de referencia cuyo β se fija en cero; los demás se leen *relativos* a ella. Ejemplo: ¿cuál de los tres candidatos principales gana la mesa?

Más de dos clases (y una nota sobre conteos)

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad:

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la función } \textit{softmax}),$$

con una clase de referencia cuyo β se fija en cero; los demás se leen *relativos* a ella. Ejemplo: ¿cuál de los tres candidatos principales gana la mesa?

- Categorías **ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica y volver a la sesión 2. Las métricas de hoy se extienden clase por clase (“una contra el resto”).

Más de dos clases (y una nota sobre conteos)

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad:

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la función } \textit{softmax}),$$

con una clase de referencia cuyo β se fija en cero; los demás se leen *relativos* a ella. Ejemplo: ¿cuál de los tres candidatos principales gana la mesa?

- Categorías **ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica y volver a la sesión 2. Las métricas de hoy se extienden clase por clase (“una contra el resto”).
- **Conteos** (delitos por cuadrante, siniestros): regresión de Poisson, $\log \mathbb{E}[y \mid x] = x' \beta$, otro GLM (ISL 4.6). Misma lógica: una función de enlace que respeta el soporte de y .

Más de dos clases (y una nota sobre conteos)

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad:

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la función } \textit{softmax}),$$

con una clase de referencia cuyo β se fija en cero; los demás se leen *relativos* a ella. Ejemplo: ¿cuál de los tres candidatos principales gana la mesa?


- Categorías **ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica y volver a la sesión 2. Las métricas de hoy se extienden clase por clase (“una contra el resto”).
- **Conteos** (delitos por cuadrante, siniestros): regresión de Poisson, $\log \mathbb{E}[y \mid x] = x' \beta$, otro GLM (ISL 4.6). Misma lógica: una función de enlace que respeta el soporte de y .

Para hoy

Nos quedamos en el caso binario: es donde viven las decisiones (aprobar, focalizar, alertar) y donde las métricas tienen más que enseñar.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre


Modelos generativos: LDA, QDA y Naive Bayes



La logística modela $P(y | x)$ directamente.
La alternativa *generativa*: modelar cómo se distribuye x en cada clase, $f_k(x)$, y las proporciones π_k , y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x).$$

Modelos generativos: LDA, QDA y Naive Bayes




La logística modela $P(y | x)$ directamente.
La alternativa *generativa*: modelar cómo se distribuye x en cada clase, $f_k(x)$, y las proporciones π_k , y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x).$$

- **LDA:** f_k normal con la **misma covarianza** en todas las clases $\Rightarrow$ frontera lineal, como la logística; gana con n pequeño y clases bien separadas. **QDA:** una covarianza por clase $\Rightarrow$ frontera cuadrática: más flexible, más parámetros.
- **Naive Bayes:** supone las x **independientes dentro de cada clase**, $f_k(x) = \prod_j f_{kj}(x_j)$. Es falso y aun así funciona cuando p es enorme y los datos escasos: el filtro de spam.

Modelos generativos: LDA, QDA y Naive Bayes



La logística modela $P(y | x)$ directamente.
La alternativa *generativa*: modelar cómo se distribuye x en cada clase, $f_k(x)$, y las proporciones π_k , y voltear con Bayes:


$$P(y = k | x) \propto \pi_k f_k(x).$$

- **LDA:** f_k normal con la **misma covarianza** en todas las clases $\Rightarrow$ frontera lineal, como la logística; gana con n pequeño y clases bien separadas. **QDA:** una covarianza por clase $\Rightarrow$ frontera cuadrática: más flexible, más parámetros.
- **Naive Bayes:** supone las x **independientes dentro de cada clase**, $f_k(x) = \prod_j f_{kj}(x_j)$. Es falso y aun así funciona cuando p es enorme y los datos escasos: el filtro de spam.

Mapa mental

Más supuestos = más eficiencia *si* aguantan; con n grande y sin normalidad, la logística es más robusta. Fórmulas en el apéndice.

k -NN como clasificador: votar entre vecinos




Para clasificar x_0 , mirar sus k vecinos más cercanos y **votar**:

$$\hat{p}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i, \quad \hat{y}(x_0) = \mathbb{I}\{\hat{p}(x_0) \geq \tau\}.$$

- Es el k -NN de la sesión 2 con y binaria: la fracción de vecinos con $y = 1$.
- k es la **perilla de complejidad** (la curva U): $k = 1$ memoriza; $k = n$ predice siempre la mayoría.

k -NN como clasificador: votar entre vecinos



Para clasificar x_0 , mirar sus k vecinos más cercanos y **votar**:

$$\hat{p}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i, \quad \hat{y}(x_0) = \mathbb{I}\{\hat{p}(x_0) \geq \tau\}.$$

- Es el k -NN de la sesión 2 con y binaria: la fracción de vecinos con $y = 1$.
- k es la **perilla de complejidad** (la curva U): $k = 1$ memoriza; $k = n$ predice siempre la mayoría.
- Sin fórmula y sin supuestos: la frontera la dibujan los datos, tan rugosa como k lo permita. Requiere **estandarizar** y sufre de frente la **maldición de la dimensionalidad**: con decenas de predictores censales, los “vecinos” de una mesa están lejísimos.
- Su papel hoy: el **contraste natural** con la logística. Hiperplano vs. ninguna forma; cero perillas vs. una; extrapola vs. se queda plano.

¿Cuál usar? La comparación de ISL (sección 4.5)

Método	Frontera	Supuestos	Gana cuando...
Logística	lineal	pocos	n grande; frontera casi lineal
LDA	lineal	normalidad, Σ común	n pequeño; clases separadas
QDA	cuadrática	normalidad, Σ_k	curvatura y n suficiente
Naive Bayes	no lineal	independencia por clase	p enorme, n escaso (texto)
k -NN	cualquiera	ninguno	p pequeño; frontera irregular
Árboles (sesión 6)	cualquiera	ninguno	tabulares con interacciones

¿Cuál usar? La comparación de ISL (sección 4.5)

Método	Frontera	Supuestos	Gana cuando...
Logística	lineal	pocos	n grande; frontera casi lineal
LDA	lineal	normalidad, Σ común	n pequeño; clases separadas
QDA	cuadrática	normalidad, Σ_k	curvatura y n suficiente
Naive Bayes	no lineal	independencia por clase	p enorme, n escaso (texto)
k -NN	cualquiera	ninguno	p pequeño; frontera irregular
Árboles (sesión 6)	cualquiera	ninguno	tabulares con interacciones

- ISL lo muestra con seis escenarios simulados: **ningún método domina**; el ganador depende de la forma de la frontera verdadera y de cuántos datos hay para dibujarla.

¿Cuál usar? La comparación de ISL (sección 4.5)

Método	Frontera	Supuestos	Gana cuando...
Logística	lineal	pocos	n grande; frontera casi lineal
LDA	lineal	normalidad, Σ común	n pequeño; clases separadas
QDA	cuadrática	normalidad, Σ_k	curvatura y n suficiente
Naive Bayes	no lineal	independencia por clase	p enorme, n escaso (texto)
k -NN	cualquiera	ninguno	p pequeño; frontera irregular
Árboles (sesión 6)	cualquiera	ninguno	tabulares con interacciones

- ISL lo muestra con seis escenarios simulados: **ningún método domina**; el ganador depende de la forma de la frontera verdadera y de cuántos datos hay para dibujarla.
- En datos reales la logística suele quedar cerca de los métodos flexibles: en Gelvez et al. (2026) el logit alcanza AUC de 0,83 a 0,91 y el bosque afinado le añade entre 0,01 y 0,04.

¿Cuál usar? La comparación de ISL (sección 4.5)

Método	Frontera	Supuestos	Gana cuando...
Logística	lineal	pocos	n grande; frontera casi lineal
LDA	lineal	normalidad, Σ común	n pequeño; clases separadas
QDA	cuadrática	normalidad, Σ_k	curvatura y n suficiente
Naive Bayes	no lineal	independencia por clase	p enorme, n escaso (texto)
k -NN	cualquiera	ninguno	p pequeño; frontera irregular
Árboles (sesión 6)	cualquiera	ninguno	tabulares con interacciones

- ISL lo muestra con seis escenarios simulados: **ningún método domina**; el ganador depende de la forma de la frontera verdadera y de cuántos datos hay para dibujarla.
- En datos reales la logística suele quedar cerca de los métodos flexibles: en Gelvez et al. (2026) el logit alcanza AUC de 0,83 a 0,91 y el bosque afinado le añade entre 0,01 y 0,04.

La regla del curso

La logística es el *baseline* de clasificación, como OLS lo es de regresión. Las métricas que siguen se aplican igual a cualquier modelo que entregue una probabilidad.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre

La exactitud engaña

Segunda vuelta de 2010: el ganador se llevó el 87,8 % de las mesas de prueba

Un modelo que no mira los datos y dice “el presidente ganó en todas” acierta en el 87,8% de las mesas. El bosque afinado de Gelvez et al. (2026) acierta en el 92,2%.

La exactitud engaña

Segunda vuelta de 2010: el ganador se llevó el 87,8 % de las mesas de prueba

Un modelo que no mira los datos y dice “el presidente ganó en todas” acierta en el 87,8% de las mesas. El bosque afinado de Gelvez et al. (2026) acierta en el 92,2%.

Pregunta para la sala

¿Cuánto mejor es el modelo que la regla trivial? ¿Y qué *no* nos dice el 92,2%?

La exactitud engaña

Segunda vuelta de 2010: el ganador se llevó el 87,8 % de las mesas de prueba

Un modelo que no mira los datos y dice “el presidente ganó en todas” acierta en el 87,8% de las mesas. El bosque afinado de Gelvez et al. (2026) acierta en el 92,2%.

Pregunta para la sala

¿Cuánto mejor es el modelo que la regla trivial? ¿Y qué *no* nos dice el 92,2%?

Baja el error del 12,2% al 7,8%, que no es poco. Pero esconde *en qué* se equivoca: como veremos en la matriz, el modelo encuentra solo la **mitad** de las mesas que ganó la oposición. Con clases desbalanceadas, la exactitud premia ignorar a la clase minoritaria, que casi siempre es *la que importa*: el moroso, el fraude, el hogar pobre, el desertor.

La exactitud engaña

Segunda vuelta de 2010: el ganador se llevó el 87,8 % de las mesas de prueba

Un modelo que no mira los datos y dice “el presidente ganó en todas” acierta en el 87,8% de las mesas. El bosque afinado de Gelse et al. (2026) acierta en el 92,2%.

Pregunta para la sala

¿Cuánto mejor es el modelo que la regla trivial? ¿Y qué *no* nos dice el 92,2%?

Baja el error del 12,2% al 7,8%, que no es poco. Pero esconde *en qué* se equivoca: como veremos en la matriz, el modelo encuentra solo la **mitad** de las mesas que ganó la oposición. Con clases desbalanceadas, la exactitud premia ignorar a la clase minoritaria, que casi siempre es *la que importa*: el moroso, el fraude, el hogar pobre, el desertor.

- El problema no es del modelo sino de la **métrica**: la exactitud pesa cada error igual y su valor depende de la **prevalencia** (la proporción de positivos), que el modelo no controla.
- Necesitamos vocabulario para los *tipos* de error, y después precios para cada uno.

La matriz de confusión, con números reales

Gelvez et al. (2026), Tabla A5: segunda vuelta de 2010, 1.951 mesas de prueba

Real \ Predicho	+	-
	Real +	Real -
Predicho +	VP = 1.678	FN = 34
Predicho -	FP = 119	VN = 120

+: el eventual presidente ganó la mesa (1.712 mesas, el 87,8%). -: la ganó otro candidato (239 mesas).

Métrica	Fórmula	2010-II
Exactitud	$(VP + VN)/n$	0,922
<i>Recall</i> (sensibilidad), R	$VP/(VP + FN)$	0,980
Especificidad	$VN/(VN + FP)$	0,502
Precisión, P	$VP/(VP + FP)$	0,934
F1	$2PR/(P + R)$	0,956
<i>Balanced accuracy</i>	$(R + \text{espec.})/2$	0,741

La matriz de confusión, con números reales

Gelvez et al. (2026), Tabla A5: segunda vuelta de 2010, 1.951 mesas de prueba

Real \ Predicho	+	-
	Predicho +	Predicho -
Real +	VP = 1.678	FN = 34
	FP = 119	VN = 120

Métrica	Fórmula	2010-II
Exactitud	$(VP + VN)/n$	0,922
<i>Recall</i> (sensibilidad), R	$VP/(VP + FN)$	0,980
Especificidad	$VN/(VN + FP)$	0,502
Precisión, P	$VP/(VP + FP)$	0,934
F1	$2PR/(P + R)$	0,956
<i>Balanced accuracy</i>	$(R + \text{espec.})/2$	0,741

+: el eventual presidente ganó la mesa (1.712 mesas, el 87,8%). -: la ganó otro candidato (239 mesas).

- **Recall:** de las mesas que ganó el presidente, ¿qué fracción encontré?
Especificidad: de las que ganó la oposición, ¿cuántas reconocí? Aquí, **la mitad**. **Precisión:** de mis “positivos”, ¿cuántos eran ciertos?
- Exactitud, precisión, *recall* y F1 lucen espléndidos; la especificidad y la *balanced accuracy* cuentan la otra mitad de la historia. Ninguna métrica sola lo hace.

Dos elecciones, dos prevalencias, las mismas métricas

Gelvez et al. (2026), Tabla A5: el mismo bosque, mesas de prueba de cada elección

	2010, 2. ^a vuelta	2022, 1. ^a vuelta
Prevalencia de la clase positiva	0,878	0,545
Exactitud	0,922	0,861
F1	0,956	0,873
<i>Balanced accuracy</i>	0,741	0,859
AUC	0,931	0,931

Dos elecciones, dos prevalencias, las mismas métricas

Gelvez et al. (2026), Tabla A5: el mismo bosque, mesas de prueba de cada elección

	2010, 2. ^a vuelta	2022, 1. ^a vuelta
Prevalencia de la clase positiva	0,878	0,545
Exactitud	0,922	0,861
F1	0,956	0,873
<i>Balanced accuracy</i>	0,741	0,859
AUC	0,931	0,931

- Por exactitud y F1 el modelo de 2010 parece mucho mejor; por *balanced accuracy* es peor, y por AUC son **idénticos**. Exactitud y F1 suben con la **dominancia** del ganador (88% de las mesas en 2010), no solo con la habilidad del modelo; la *balanced accuracy* y la AUC no dependen de la prevalencia.

Dos elecciones, dos prevalencias, las mismas métricas

Gelvez et al. (2026), Tabla A5: el mismo bosque, mesas de prueba de cada elección

	2010, 2. ^a vuelta	2022, 1. ^a vuelta
Prevalencia de la clase positiva	0,878	0,545
Exactitud	0,922	0,861
F1	0,956	0,873
<i>Balanced accuracy</i>	0,741	0,859
AUC	0,931	0,931

- Por exactitud y F1 el modelo de 2010 parece mucho mejor; por *balanced accuracy* es peor, y por AUC son **idénticos**. Exactitud y F1 suben con la **dominancia** del ganador (88% de las mesas en 2010), no solo con la habilidad del modelo; la *balanced accuracy* y la AUC no dependen de la prevalencia.
- Por eso el paper usa la AUC como cabecera (“la prevalencia de la clase positiva varía marcadamente entre elecciones”) y manda el resto a un apéndice con las matrices completas.

Dos elecciones, dos prevalencias, las mismas métricas

Gelvez et al. (2026), Tabla A5: el mismo bosque, mesas de prueba de cada elección

	2010, 2. ^a vuelta	2022, 1. ^a vuelta
Prevalencia de la clase positiva	0,878	0,545
Exactitud	0,922	0,861
F1	0,956	0,873
<i>Balanced accuracy</i>	0,741	0,859
AUC	0,931	0,931

- Por exactitud y F1 el modelo de 2010 parece mucho mejor; por *balanced accuracy* es peor, y por AUC son **idénticos**. Exactitud y F1 suben con la **dominancia** del ganador (88% de las mesas en 2010), no solo con la habilidad del modelo; la *balanced accuracy* y la AUC no dependen de la prevalencia.
- Por eso el paper usa la AUC como cabecera (“la prevalencia de la clase positiva varía marcadamente entre elecciones”) y manda el resto a un apéndice con las matrices completas.
- **Regla de reporte:** junto con la métrica cabecera, **siempre** la prevalencia y la matriz de confusión. Sin ellas, un 92% no significa nada.

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

El modelo entrega $\hat{p}(x)$; decidir exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.

¿Quién fija τ ? **Los costos.** Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de un individuo.

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

El modelo entrega $\hat{p}(x)$; decidir exige un **umbral** τ : predecir $+$ si $\hat{p}(x) \geq \tau$.

¿Quién fija τ ? **Los costos.** Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de un individuo. **1. Costo esperado de predecir $+$:** $(1 - p) c_{FP}$

(me equivoco si era $-$)

2. Costo esperado de predecir $-$: $p c_{FN}$ (me equivoco si era $+$)

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

El modelo entrega $\hat{p}(x)$; decidir exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.

¿Quién fija τ ? **Los costos.** Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de un individuo. **1. Costo esperado de predecir +:** $(1 - p) c_{FP}$

(me equivoco si era -)

2. Costo esperado de predecir -: $p c_{FN}$ (me equivoco si era +)

3. Predecir + cuando $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

El modelo entrega $\hat{p}(x)$; decidir exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.

¿Quién fija τ ? **Los costos**. Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de un individuo. **1. Costo esperado de predecir +:** $(1 - p) c_{FP}$

(me equivoco si era -)

2. Costo esperado de predecir -: $p c_{FN}$ (me equivoco si era +)

3. Predecir + cuando $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Solo importa el **cociente** de costos. Errores igual de caros $\Rightarrow \tau^* = 0,5$ (la regla de Bayes). FN diez veces más caro $\Rightarrow \tau^* = 1/11 \approx 0,09$: alarma temprana.
- El 0,5 por defecto de los paquetes es una decisión económica *implícita*, y casi nunca la correcta. Cuando los errores no tienen costos asimétricos (medir la predictibilidad de una elección), 0,5 es el umbral natural y la métrica cabecera debe ser una que **no dependa del umbral**.

Tres mini-casos para calibrar la intuición

Focalizar una transferencia contra la pobreza extrema. c_{FN} (excluir a un hogar pobre) es alto; c_{FP} (incluir a un no pobre) es una filtración fiscal, real pero menor $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. La filtración se vigila con la *precisión*.

Tres mini-casos para calibrar la intuición

Focalizar una transferencia contra la pobreza extrema. c_{FN} (excluir a un hogar pobre) es alto; c_{FP} (incluir a un no pobre) es una filtración fiscal, real pero menor $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. La filtración se vigila con la *precisión*.

Aprobar un crédito. El “positivo” es el impago. c_{FN} (prestarle a quien impaga) es la pérdida de capital; c_{FP} (negarle a un buen pagador) es margen no ganado $\Rightarrow \tau^*$ bajo también; los bancos lo afinan sobre la **ganancia esperada** de la cartera. Fuster et al. (2022) muestran que pasar del logit a modelos de ML mejora la predicción del impago hipotecario, pero el beneficio se reparte de forma desigual entre grupos raciales.

Tres mini-casos para calibrar la intuición

Focalizar una transferencia contra la pobreza extrema. c_{FN} (excluir a un hogar pobre) es alto; c_{FP} (incluir a un no pobre) es una filtración fiscal, real pero menor $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. La filtración se vigila con la *precisión*.

Aprobar un crédito. El “positivo” es el impago. c_{FN} (prestarle a quien impaga) es la pérdida de capital; c_{FP} (negarle a un buen pagador) es margen no ganado $\Rightarrow \tau^*$ bajo también; los bancos lo afinan sobre la **ganancia esperada** de la cartera. Fuster et al. (2022) muestran que pasar del logit a modelos de ML mejora la predicción del impago hipotecario, pero el beneficio se reparte de forma desigual entre grupos raciales. **Libertad bajo fianza.** Kleinberg et al. (2018) predicen el riesgo de que un acusado no comparezca; el juez decide con un umbral implícito. Ordenando por riesgo predicho, una regla podría reducir el crimen hasta un 24,7% con la misma tasa de detención, o la detención hasta un 41,9% con el mismo crimen. El modelo **ordena**; la sociedad elige el punto de la curva.

Tres mini-casos para calibrar la intuición

Focalizar una transferencia contra la pobreza extrema. c_{FN} (excluir a un hogar pobre) es alto; c_{FP} (incluir a un no pobre) es una filtración fiscal, real pero menor $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. La filtración se vigila con la *precisión*.


Aprobar un crédito. El “positivo” es el impago. c_{FN} (prestarle a quien impaga) es la pérdida de capital; c_{FP} (negarle a un buen pagador) es margen no ganado $\Rightarrow \tau^*$ bajo también; los bancos lo afinan sobre la **ganancia esperada** de la cartera. Fuster et al. (2022) muestran que pasar del logit a modelos de ML mejora la predicción del impago hipotecario, pero el beneficio se reparte de forma desigual entre grupos raciales. **Libertad bajo fianza.** Kleinberg et al. (2018) predicen el riesgo de que un acusado no comparezca; el juez decide con un umbral implícito. Ordenando por riesgo predicho, una regla podría reducir el crimen hasta un 24,7% con la misma tasa de detención, o la detención hasta un 41,9% con el mismo crimen. El modelo **ordena**; la sociedad elige el punto de la curva.

El patrón general

Mismo modelo, distinta economía $\Rightarrow$ distinto umbral. Reportar “exactitud” sin discutir costos es esconder la decisión. Y elegir el punto exige ver *todos* los umbrales a la vez: la curva ROC.

La curva ROC: todos los umbrales a la vez

tasa de VP (*recall*)




Barriendo τ de 1 a 0 y graficando (tasa de FP, tasa de VP) en cada punto:

- Cada punto es un umbral; la curva es el **menú completo** de intercambios entre encontrar positivos y dar falsas alarmas.
- **AUC:** 0,5 es el azar, 1 es perfecto. Lectura exacta: *la probabilidad de que un positivo al azar reciba mayor $\hat{p}$ que un negativo al azar.*

La curva ROC: todos los umbrales a la vez


tasa de VP (*recall*)



Barriando τ de 1 a 0 y graficando (tasa de FP, tasa de VP) en cada punto:


- Cada punto es un umbral; la curva es el **menú completo** de intercambios entre encontrar positivos y dar falsas alarmas.
- **AUC:** 0,5 es el azar, 1 es perfecto. Lectura exacta: *la probabilidad de que un positivo al azar reciba mayor $\hat{p}$ que un negativo al azar*.
- En Gelvez et al. (2026), AUC entre 0,86 y 0,93: si le dan una mesa que ganó el presidente y una que perdió, el modelo ordena bien el par en el 86 a 93% de los casos. Compara modelos y elecciones **sin fijar umbral**.
- **La pregunta de Kim & Zilinsky:** su AUC sube despacio con las décadas (0,002 por año, $p < 0,01$) y la *accuracy* al 50% no se mueve. La AUC mira el orden en *todos* los umbrales; la exactitud, solo cuántos cruzan el 0,5. Ordenar bien y decidir bien son pasos distintos.

Cuando los positivos son raros: precisión–recall



- Con 2% de positivos, la ROC luce optimista: la tasa de FP divide por los negativos, que son *muchísimos*; miles de falsas alarmas apenas la mueven.
- La curva **PR** no usa los VN: muestra cruda la calidad de las alarmas. Su “azar” es la prevalencia, no 0,5.
- El F1 es *un punto* de esta curva (el del umbral elegido); la PR es el menú completo.

Cuando los positivos son raros: precisión–recall




- Con 2% de positivos, la ROC luce optimista: la tasa de FP divide por los negativos, que son *muchísimos*; miles de falsas alarmas apenas la mueven.
- La curva **PR** no usa los VN: muestra cruda la calidad de las alarmas. Su “azar” es la prevalencia, no 0,5.
- El F1 es *un punto* de esta curva (el del umbral elegido); la PR es el menú completo.

Regla práctica (Saito & Rehmsmeier, 2015)

Positivos raros (fraude, impago, deserción, pobreza extrema) $\Rightarrow$ reportar ROC y PR, y decir cuál es la prevalencia. Con clases razonablemente balanceadas, como las mesas de 2022, la ROC basta.

Calibración: ¿ $\hat{p} = 0,8$ significa 80 %?


La pendiente de y sobre $\hat{y}$ de la sesión 2, ahora para probabilidades



- Agrupen la prueba por deciles de $\hat{p}$ y comparen con la frecuencia observada de $y = 1$ en cada grupo. Sobre la diagonal, el modelo **dice la verdad**.
- Descalibrado $\Rightarrow$ el umbral τ^* sobre $\hat{p}$ decide mal aunque la AUC sea alta: ordenar bien no es cuantificar bien.
- La logística suele salir calibrada; k -NN con k pequeño, bosques y *boosting*, no siempre $\Rightarrow$ recalibrar (Platt o isotónica) en validación.

Calibración: ¿ $\hat{p} = 0,8$ significa 80 %?

La pendiente de y sobre $\hat{y}$ de la sesión 2, ahora para probabilidades



- Agrupen la prueba por deciles de $\hat{p}$ y comparen con la frecuencia observada de $y = 1$ en cada grupo. Sobre la diagonal, el modelo **dice la verdad**.
- Descalibrado $\Rightarrow$ el umbral τ^* sobre $\hat{p}$ decide mal aunque la AUC sea alta: ordenar bien no es cuantificar bien.
- La logística suele salir calibrada; k -NN con k pequeño, bosques y *boosting*, no siempre $\Rightarrow$ recalibrar (Platt o isotónica) en validación.
- **Métricas de probabilidad:** la **log-loss** (lo que la logística minimiza) y el **Brier** $= \frac{1}{n_t} \sum_i (\hat{p}_i - y_i)^2$, el MSE de las probabilidades, que se descompone en calibración y resolución (apéndice).
- Una figura barata: $\hat{p}$ por clase observada (Gelvez et al., Figs. 16–17 del apéndice): dos nubes separadas, con medias lejos de 0,5.

Desbalance de clases: los remedios y sus advertencias

Con 2% de impagos, la verosimilitud apenas nota a la clase minoritaria: el modelo optimiza ignorándola. **Los remedios**, del más simple al más elaborado:

- ➊ **Pesos en la pérdida** (*class weights*): encarecer los errores en la clase rara. Sin tocar los datos; disponible en casi todo (glm, ranger, xgboost).
- ➋ **Submuestrear** la clase mayoritaria (rápido, pero tira datos) o **sobremuestrear** la minoritaria (duplica; invita al sobreajuste sobre copias).
- ➌ **SMOTE** (Chawla et al., 2002): crear positivos *sintéticos* interpolando entre vecinos de la clase rara: $x_{new} = x_i + u(x_{nn} - x_i)$, $u \sim U(0, 1)$.

Desbalance de clases: los remedios y sus advertencias

Con 2% de impagos, la verosimilitud apenas nota a la clase minoritaria: el modelo optimiza ignorándola. **Los remedios**, del más simple al más elaborado:

- 1 **Pesos en la pérdida** (*class weights*): encarecer los errores en la clase rara. Sin tocar los datos; disponible en casi todo (glm, ranger, xgboost).
- 2 **Submuestrear** la clase mayoritaria (rápido, pero tira datos) o **sobremuestrear** la minoritaria (duplica; invita al sobreajuste sobre copias).
- 3 **SMOTE** (Chawla et al., 2002): crear positivos *sintéticos* interpolando entre vecinos de la clase rara: $x_{new} = x_i + u(x_{nn} - x_i)$, $u \sim U(0, 1)$.

Dos advertencias no negociables

(i) Todo remuestreo ocurre **solo en el entrenamiento**: remuestrear antes de partir contamina la prueba (la disciplina completa, en la sesión 4). (ii) Remuestrear **distorsiona** $\hat{p}$, que queda inflada: recalibrar antes de usar umbrales de costos.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien (AUC decente) y está calibrado, ¿hacía falta remuestrear?

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien (AUC decente) y está calibrado, ¿hacía falta remuestrear?

- Muchas veces **no**: mover τ^* según los costos logra lo mismo, con probabilidades honestas y sin cirugía sobre los datos.
- Pesos y SMOTE ayudan cuando la clase rara es *tan* rara que el modelo ni aprende su estructura.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien (AUC decente) y está calibrado, ¿hacía falta remuestrear?

- Muchas veces **no**: mover τ^* según los costos logra lo mismo, con probabilidades honestas y sin cirugía sobre los datos.
- Pesos y SMOTE ayudan cuando la clase rara es *tan* rara que el modelo ni aprende su estructura.

El flujo del practicante:

- 1 Partición (y, desde la sesión 4, CV) **estratificadas**.
- 2 Entrenar normal; evaluar con ROC y PR, nunca con la exactitud sola.
- 3 Calibrar; decidir con τ^* de costos.
- 4 ¿Aún mal en *recall* o precisión? Pesos de clase; SMOTE como último recurso.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien (AUC decente) y está calibrado, ¿hacía falta remuestrear?

- Muchas veces **no**: mover τ^* según los costos logra lo mismo, con probabilidades honestas y sin cirugía sobre los datos.
- Pesos y SMOTE ayudan cuando la clase rara es *tan* rara que el modelo ni aprende su estructura.

El flujo del practicante:

- 1 Partición (y, desde la sesión 4, CV) **estratificadas**.
- 2 Entrenar normal; evaluar con ROC y PR, nunca con la exactitud sola.
- 3 Calibrar; decidir con τ^* de costos.
- 4 ¿Aún mal en *recall* o precisión? Pesos de clase; SMOTE como último recurso.

Para la aplicación

Las mesas de 2022 están balanceadas y sin costos asimétricos: el flujo se detiene en el paso 2. Con 2010 (88% de positivos) la exactitud y el F1 se inflan solos.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre

Los datos y la pregunta

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006–2022). Predictores: características demográficas, socioeconómicas, de infraestructura y étnicas del vecindario censal de cada mesa, luminosidad nocturna e indicadores de departamento.

Los datos y la pregunta

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006–2022). Predictores: características demográficas, socioeconómicas, de infraestructura y étnicas del vecindario censal de cada mesa, luminosidad nocturna e indicadores de departamento. **Pregunta predictiva:** ¿el candidato que terminó siendo presidente ganó la mesa? ($y = 1$ si el eventual ganador nacional fue el más votado.) Dos vueltas para contrastar: 2022-I (prevalencia 0,545: competencia pareja) y 2010-II (0,878: dominancia).

Los datos y la pregunta

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006–2022). Predictores: características demográficas, socioeconómicas, de infraestructura y étnicas del vecindario censal de cada mesa, luminosidad nocturna e indicadores de departamento. **Pregunta predictiva:** ¿el candidato que terminó siendo presidente ganó la mesa? ($y = 1$ si el eventual ganador nacional fue el más votado.) Dos vueltas para contrastar: 2022-I (prevalencia 0,545: competencia pareja) y 2010-II (0,878: dominancia). **Decisiones antes de ajustar nada:**

- 1 Partición 80/20 **estratificada por clase**; la prueba queda bajo llave.
- 2 Baseline: “ganó en todas”. Referencia: logística con todos los predictores. Retador: k -NN estandarizado.
- 3 Umbral 0,5 (sin costos asimétricos); cabecera: AUC y *balanced accuracy*.

Los datos y la pregunta

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006–2022). Predictores: características demográficas, socioeconómicas, de infraestructura y étnicas del vecindario censal de cada mesa, luminosidad nocturna e indicadores de departamento. **Pregunta predictiva:** ¿el candidato que terminó siendo presidente ganó la mesa? ($y = 1$ si el eventual ganador nacional fue el más votado.) Dos vueltas para contrastar: 2022-I (prevalencia 0,545: competencia pareja) y 2010-II (0,878: dominancia). **Decisiones antes de ajustar nada:**

- 1 Partición 80/20 **estratificada por clase**; la prueba queda bajo llave.
- 2 Baseline: “ganó en todas”. Referencia: logística con todos los predictores. Retador: k -NN estandarizado.
- 3 Umbral 0,5 (sin costos asimétricos); cabecera: AUC y *balanced accuracy*.

Lo que no haremos hoy: elegir k con la prueba. Se elige con un pedazo del entrenamiento; la forma correcta (CV de 5 pliegues, como en el paper) llega en la sesión 4.

Cuatro modelos, una misma prueba: 2022, primera vuelta

	Modelo	AUC	Exactitud	<i>Bal. acc.</i>	F1
0	"El presidente ganó en todas"	0,500	0,545	0,500	0,705
1	Logística, todos los predictores	0,909	en clase	en clase	en clase
2	<i>k</i> -NN, predictores estandarizados	en clase	en clase	en clase	en clase
3	<i>Random forest</i> afinado (sesión 6)	0,931	0,861	0,859	0,873

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y A5, misma partición 80/20. El baseline se deduce de la prevalencia (precisión = 0,545, *recall* = 1). Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla.

Cuatro modelos, una misma prueba: 2022, primera vuelta

	Modelo	AUC	Exactitud	Bal. acc.	F1
0	“El presidente ganó en todas”	0,500	0,545	0,500	0,705
1	Logística, todos los predictores	0,909	en clase	en clase	en clase
2	k -NN, predictores estandarizados	en clase	en clase	en clase	en clase
3	<i>Random forest</i> afinado (sesión 6)	0,931	0,861	0,859	0,873

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y A5, misma partición 80/20. El baseline se deduce de la prevalencia (precisión = 0,545, *recall* = 1). Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla. **Preguntas que la tabla debe**

responder:

- ¿Cuánto añade una recta al baseline? De 0,5 a 0,91 de AUC: la geografía del ganador es legible incluso con una frontera lineal; es “una propiedad de los datos, no un artefacto de la flexibilidad del modelo” (Gelvez et al.).

Cuatro modelos, una misma prueba: 2022, primera vuelta

	Modelo	AUC	Exactitud	Bal. acc.	F1
0	"El presidente ganó en todas"	0,500	0,545	0,500	0,705
1	Logística, todos los predictores	0,909	en clase	en clase	en clase
2	k -NN, predictores estandarizados	en clase	en clase	en clase	en clase
3	<i>Random forest</i> afinado (sesión 6)	0,931	0,861	0,859	0,873

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y A5, misma partición 80/20. El baseline se deduce de la prevalencia (precisión = 0,545, *recall* = 1). Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla. **Preguntas que la tabla debe**

responder:

- ¿Cuánto añade una recta al baseline? De 0,5 a 0,91 de AUC: la geografía del ganador es legible incluso con una frontera lineal; es "una propiedad de los datos, no un artefacto de la flexibilidad del modelo" (Gelvez et al.).
- ¿Le gana k -NN al hiperplano? Con decenas de predictores, la maldición de la dimensionalidad juega en contra; si gana, la frontera tiene curvatura que la logística no ve.

Cuatro modelos, una misma prueba: 2022, primera vuelta

	Modelo	AUC	Exactitud	Bal. acc.	F1
0	"El presidente ganó en todas"	0,500	0,545	0,500	0,705
1	Logística, todos los predictores	0,909	en clase	en clase	en clase
2	k -NN, predictores estandarizados	en clase	en clase	en clase	en clase
3	<i>Random forest</i> afinado (sesión 6)	0,931	0,861	0,859	0,873

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y A5, misma partición 80/20. El baseline se deduce de la prevalencia (precisión = 0,545, *recall* = 1). Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla. **Preguntas que la tabla debe**

responder:

- ¿Cuánto añade una recta al baseline? De 0,5 a 0,91 de AUC: la geografía del ganador es legible incluso con una frontera lineal; es "una propiedad de los datos, no un artefacto de la flexibilidad del modelo" (Gelvez et al.).
- ¿Le gana k -NN al hiperplano? Con decenas de predictores, la maldición de la dimensionalidad juega en contra; si gana, la frontera tiene curvatura que la logística no ve.
- ¿Qué compra el bosque? Dos centésimas de AUC sobre el logit: el precio y el premio de la flexibilidad, que discutimos en la sesión 6.

Después de la tabla: las tres figuras

- 1 **Las curvas ROC de los modelos, en los mismos ejes.** Si la de k -NN cruza a la de la logística, un modelo gana en los umbrales exigentes y el otro en los generosos: la AUC resume, la curva decide. Marcar el punto $\tau = 0,5$ de cada uno.

Después de la tabla: las tres figuras

- 1 **Las curvas ROC de los modelos, en los mismos ejes.** Si la de k -NN cruza a la de la logística, un modelo gana en los umbrales exigentes y el otro en los generosos: la AUC resume, la curva decide. Marcar el punto $\tau = 0,5$ de cada uno.
- 2 **Calibración:** la curva de confiabilidad por deciles de $\hat{p}$ para la logística y k -NN, y al lado $\hat{p}$ por clase observada. Esperamos a la logística sobre la diagonal y a k -NN con k pequeño, sobreconfiado.

Después de la tabla: las tres figuras

- 1 **Las curvas ROC de los modelos, en los mismos ejes.** Si la de k -NN cruza a la de la logística, un modelo gana en los umbrales exigentes y el otro en los generosos: la AUC resume, la curva decide. Marcar el punto $\tau = 0,5$ de cada uno.
- 2 **Calibración:** la curva de confiabilidad por deciles de $\hat{p}$ para la logística y k -NN, y al lado $\hat{p}$ por clase observada. Esperamos a la logística sobre la diagonal y a k -NN con k pequeño, sobreconfiado.
- 3 **Dónde falla:** la tasa de error por departamento y por ruralidad, y el mapa de aciertos y fallos (Gelvez et al., Figs. 18–26 del apéndice). Manchas de fallos del mismo signo son lo que la validación espacial de la sesión 4 va a castigar.

Después de la tabla: las tres figuras

- ❶ **Las curvas ROC de los modelos, en los mismos ejes.** Si la de k -NN cruza a la de la logística, un modelo gana en los umbrales exigentes y el otro en los generosos: la AUC resume, la curva decide. Marcar el punto $\tau = 0,5$ de cada uno.
- ❷ **Calibración:** la curva de confiabilidad por deciles de $\hat{p}$ para la logística y k -NN, y al lado $\hat{p}$ por clase observada. Esperamos a la logística sobre la diagonal y a k -NN con k pequeño, sobreconfiado.
- ❸ **Dónde falla:** la tasa de error por departamento y por ruralidad, y el mapa de aciertos y fallos (Gelvez et al., Figs. 18–26 del apéndice). Manchas de fallos del mismo signo son lo que la validación espacial de la sesión 4 va a castigar.

El reporte de una clasificación, de aquí en adelante

Tabla con métrica cabecera + prevalencia + matriz de confusión; ROC (y PR si los positivos son raros); calibración; error por el subgrupo que le importa a la pregunta. Después, repetir con 2010 y ver cómo cambian exactitud y F1 sin que cambie la AUC.

Cómo se ve en R (tidymodels)

```
library(tidymodels); set.seed(2026)
mesas22 <- mesas |> filter(eleccion == 2022, vuelta == 1) |>
  mutate(ganador = factor(ganador, levels = c("1", "0")))
split <- initial_split(mesas22, prop = 0.8, strata = ganador)
train <- training(split); test <- testing(split) # bajo llave
rec <- recipe(ganador ~ ., data = train) |>
  step_impute_mean(all_numeric_predictors()) |>
  step_dummy(all_nominal_predictors()) |>
  step_normalize(all_numeric_predictors()) # escala para k-NN
m_log <- logistic_reg() |> set_engine("glm")
m_knn <- nearest_neighbor(neighbors = 25) |>
  set_engine("kknn") |> set_mode("classification")
fit_log <- workflow(rec, m_log) |> fit(train)
pred <- augment(fit_log, test) # .pred_1 y .pred_class
cls <- metric_set(roc_auc, accuracy, bal_accuracy, f_meas)
cls(pred, truth = ganador, estimate = .pred_class, .pred_1)
```

- strata conserva la prevalencia en las dos muestras; la imputación y la escala se aprenden en el entrenamiento y se aplican a la prueba. accuracy, bal_accuracy y f_meas usan el umbral 0,5 de .pred_class; roc_auc, no. Curvas y calibración: roc_curve() con autoplot() y probably::cal_plot_breaks().

Presentación estudiantil: el paper de la sesión 2

Quince minutos, tres preguntas

Bogin & Shui (2020) o Pace & Hayunga (2020), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa?** El precio (o el avalúo) de una vivienda; quién usa esa predicción y qué decisión depende de ella.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Partición, modelos comparados (hedónico vs. flexibles), métricas en la prueba, resultados por cuartil de precio o por subgrupo.
- 3 **¿Qué se encuentra y cómo se interpreta?** Cuánto gana el modelo flexible, dónde (las colas), y qué dice eso de la especificación lineal.

Presentación estudiantil: el paper de la sesión 2

Quince minutos, tres preguntas

Bogin & Shui (2020) o Pace & Hayunga (2020), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa?** El precio (o el avalúo) de una vivienda; quién usa esa predicción y qué decisión depende de ella.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Partición, modelos comparados (hedónico vs. flexibles), métricas en la prueba, resultados por cuartil de precio o por subgrupo.
- 3 **¿Qué se encuentra y cómo se interpreta?** Cuánto gana el modelo flexible, dónde (las colas), y qué dice eso de la especificación lineal.

Para el resto de la sala

Mientras escuchan, anoten: ¿contra qué baseline se mide la ganancia? ¿Se reporta el error donde importa (viviendas caras, zonas rurales)? Y una pregunta de hoy: si el problema fuera binario (¿el avalúo supera el precio de venta?), ¿qué métrica cabecera usarían y por qué?

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Otros clasificadores, en breve
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada: ¿ganó el eventual presidente en la mesa?
- 6 Interpretación y cierre

Qué dice el modelo y qué no dice

Lo que sí dice. Con una AUC de 0,91 para una frontera lineal, la geografía del apoyo al ganador de 2022 es *legible* desde las características de los lugares: mesas parecidas en composición demográfica, estrato, infraestructura y etnicidad votan parecido. Los $\hat{\beta}$ y las *odds ratios* dicen **qué usa** el modelo para ordenar las mesas.

Qué dice el modelo y qué no dice

Lo que sí dice. Con una AUC de 0,91 para una frontera lineal, la geografía del apoyo al ganador de 2022 es *legible* desde las características de los lugares: mesas parecidas en composición demográfica, estrato, infraestructura y etnicidad votan parecido. Los $\hat{\beta}$ y las *odds ratios* dicen **qué usa** el modelo para ordenar las mesas.

Lo que no dice.

- **No es causal:** que la composición étnica “prediga” el voto no significa que lo cause; puede ser un proxy de historia, geografía o presencia del Estado.
- **No es individual:** las unidades son mesas; inferir que *un* votante con tal característica vota de tal forma es inferencia ecológica.
- **No es un pronóstico:** el desempeño fuera de muestra dentro de 2022 no anticipa 2026. Lo que se mide es la *estructura* de una elección, no su futuro.

Qué dice el modelo y qué no dice

Lo que sí dice. Con una AUC de 0,91 para una frontera lineal, la geografía del apoyo al ganador de 2022 es *legible* desde las características de los lugares: mesas parecidas en composición demográfica, estrato, infraestructura y etnicidad votan parecido. Los $\hat{\beta}$ y las *odds ratios* dicen **qué usa** el modelo para ordenar las mesas.

Lo que no dice.

- **No es causal:** que la composición étnica “prediga” el voto no significa que lo cause; puede ser un proxy de historia, geografía o presencia del Estado.
- **No es individual:** las unidades son mesas; inferir que *un* votante con tal característica vota de tal forma es inferencia ecológica.
- **No es un pronóstico:** el desempeño fuera de muestra dentro de 2022 no anticipa 2026. Lo que se mide es la *estructura* de una elección, no su futuro.

La métrica es parte de la interpretación

Un F1 de 0,96 en 2010 habla de *dominancia*: el ganador arrasó y la clase positiva era fácil. Una AUC de 0,93 con clases parejas en 2022 habla de *sorting* territorial: coaliciones alineadas con divisiones sociales persistentes. Leer la métrica junto con la prevalencia es leer la elección.

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Logística	siempre, como baseline; p grande con penalización	separación perfecta; curvaturas que no escribimos
k -NN	p pequeño y frontera irregular	la escala de las x ; alta dimensión; $\hat{p}$ granular
LDA / QDA / NB	n pequeño; p enorme (texto)	normalidad e independencia como supuestos fuertes
Exactitud	clases balanceadas y costos simétricos	prevalencia desigual: reportar <i>balanced accuracy</i>
AUC / ROC	comparar modelos y contextos sin umbral	no elige el umbral; optimista con positivos muy raros
Precisión– <i>recall</i> , F1	positivos raros; alarmas costosas	dependen del umbral y de la prevalencia
Calibración	antes de cualquier umbral por costos	remuestreo y ensambles descalibran

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Logística	siempre, como baseline; p grande con penalización	separación perfecta; curvaturas que no escribimos
k -NN	p pequeño y frontera irregular	la escala de las x ; alta dimensión; $\hat{p}$ granular
LDA / QDA / NB	n pequeño; p enorme (texto)	normalidad e independencia como supuestos fuertes
Exactitud	clases balanceadas y costos simétricos	prevalencia desigual: reportar <i>balanced accuracy</i>
AUC / ROC	comparar modelos y contextos sin umbral	no elige el umbral; optimista con positivos muy raros
Precisión– <i>recall</i> , F1	positivos raros; alarmas costosas	dependen del umbral y de la prevalencia
Calibración	antes de cualquier umbral por costos	remuestreo y ensambles descalibran

Qué leer: ISL cap. 4 (los métodos) y su sección 4.4.2 (matriz de confusión y ROC con el ejemplo *Default*); Fawcett (2006) para la ROC completa; Saito & Rehmsmeier (2015) para la PR; el apéndice de Gelvez et al. (2026) como modelo de reporte.

Recap

- 1 **Clasificar es estimar $P(y | x)$ y luego decidir.** El ideal es el clasificador de Bayes; su error es el σ^2 de la clasificación. La **logística** (índice lineal, verosimilitud, sin perillas) es el baseline; LDA/NB y k -NN son las alternativas, y los árboles llegan en la sesión 6.
- 2 **La exactitud engaña** cuando la prevalencia es desigual. La matriz de confusión da el vocabulario: *recall*, especificidad, precisión, F1, *balanced accuracy*. Siempre con la prevalencia al lado.
- 3 **El umbral es economía:** $\tau^* = c_{FP} / (c_{FP} + c_{FN})$. Sin costos asimétricos, 0,5 y una métrica que no dependa del umbral.
- 4 **ROC y AUC** comparan modelos y contextos sin umbral; la **PR** es más honesta con positivos raros; nada funciona sin **calibración**.
- 5 **Desbalance:** estratificar, ordenar bien y calibrar antes que remuestrear; si se remuestrea, solo en el entrenamiento y recalibrando.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 4 (secs. 4.1–4.5; la 4.6 es opcional).
Guía: la sección 4.4.2 tiene la matriz de confusión y la ROC con el ejemplo *Default*; la 4.5 es la comparación que vimos en clase.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5 y 7; es el manual de la curva ROC.

Para la presentación estudiantil de la sesión 4: Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018), *Human Decisions and Machine Predictions*, QJE, o Fuster, Goldsmith-Pinkham, Ramadorai & Walther (2022), *Predictably Unequal?*, JF.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 4 (secs. 4.1–4.5; la 4.6 es opcional).
Guía: la sección 4.4.2 tiene la matriz de confusión y la ROC con el ejemplo *Default*; la 4.5 es la comparación que vimos en clase.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5 y 7; es el manual de la curva ROC.

Para la presentación estudiantil de la sesión 4: Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018), *Human Decisions and Machine Predictions*, QJE, o Fuster, Goldsmith-Pinkham, Ramadorai & Walther (2022), *Predictably Unequal?*, JF. **Próxima sesión — remuestreo y validación:** cómo estimar el error de generalización sin engañarse: conjunto de validación, LOOCV y k -fold; CV para elegir hiperparámetros (el k de hoy, los nodos de la sesión 2); *leakage* y el preprocesamiento dentro del *pipeline*; CV temporal y espacial con las mesas; *bootstrap* para ponerle intervalos a las métricas. Lectura previa: ISL cap. 5.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 4 (secs. 4.1–4.5; la 4.6 es opcional).
Guía: la sección 4.4.2 tiene la matriz de confusión y la ROC con el ejemplo *Default*; la 4.5 es la comparación que vimos en clase.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5 y 7; es el manual de la curva ROC.

Para la presentación estudiantil de la sesión 4: Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018), *Human Decisions and Machine Predictions*, QJE, o Fuster, Goldsmith-Pinkham, Ramadorai & Walther (2022), *Predictably Unequal?*, JF. **Próxima sesión — remuestreo y validación:** cómo estimar el error de generalización sin engañarse: conjunto de validación, LOOCV y k -fold; CV para elegir hiperparámetros (el k de hoy, los nodos de la sesión 2); *leakage* y el preprocesamiento dentro del *pipeline*; CV temporal y espacial con las mesas; *bootstrap* para ponerle intervalos a las métricas. Lectura previa: ISL cap. 5. **Aplicación de esta semana en R:** mesas de 2022 (primera vuelta) y 2010 (segunda vuelta) con `tidymodels`: baseline, logística y k -NN; la tabla y las tres figuras.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 4. [ISL]
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.
- Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Documento de trabajo.
- Kim, S.-y. S., & Zilinsky, J. (2024). Division Does Not Imply Predictability. *Political Behavior*, 46, 67–87.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J., & Mullainathan, S. (2018). Human Decisions and Machine Predictions. *Quarterly Journal of Economics*, 133(1), 237–293.
- Fuster, A., Goldsmith-Pinkham, P., Ramadorai, T., & Walther, A. (2022). Predictably Unequal? The Effects of Machine Learning on Credit Markets. *Journal of Finance*, 77(1), 5–47.
- Kuhn, M., & Silge, J. (2022). *Tidy Modeling with R*. O'Reilly. [\[disponible online\]](#)

7 Apéndice: para profundizar

A1. La verosimilitud de la logística: gradiente y Newton–Raphson

1. La log-verosimilitud de n observaciones independientes, usando $1 - p_i = 1/(1 + e^{x_i' \beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

A1. La verosimilitud de la logística: gradiente y Newton–Raphson

1. La log-verosimilitud de n observaciones independientes, usando $1 - p_i = 1/(1 + e^{x_i' \beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

2. Gradiente y hessiano (con $\partial \log(1 + e^{x_i' \beta}) / \partial \beta = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta'} = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i' \equiv -\mathbf{X}' \mathbf{W} \mathbf{X}.$$

A1. La verosimilitud de la logística: gradiente y Newton–Raphson

1. La log-verosimilitud de n observaciones independientes, usando $1 - p_i = 1/(1 + e^{x_i' \beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

2. Gradiente y hessiano (con $\partial \log(1 + e^{x_i' \beta}) / \partial \beta = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta'} = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i' \equiv -\mathbf{X}' \mathbf{W} \mathbf{X}.$$

3. Igualar a cero no tiene solución cerrada (p_i depende de β de forma no lineal). Newton–Raphson itera

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' (\mathbf{y} - \mathbf{p}),$$

una regresión ponderada en cada paso (*IRLS*); `glm()` converge en pocas iteraciones.

A1. La verosimilitud de la logística: gradiente y Newton–Raphson

1. La log-verosimilitud de n observaciones independientes, usando $1 - p_i = 1/(1 + e^{x_i'\beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

2. Gradiente y hessiano (con $\partial \log(1 + e^{x_i' \beta}) / \partial \beta = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta'} = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i' \equiv -\mathbf{X}' \mathbf{W} \mathbf{X}.$$

3. Igualar a cero no tiene solución cerrada (p_i depende de β de forma no lineal). Newton–Raphson itera

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' (\mathbf{y} - \mathbf{p}),$$

una regresión ponderada en cada paso (*IRLS*); `glm()` converge en pocas iteraciones. **4. Lectura:** con intercepto, las condiciones de primer orden implican $\sum_i \hat{p}_i = \sum_i y_i$: la logística está calibrada *en promedio*. Y el “residuo por regresor” $x_i(y_i - p_i)$ es lo que el *boosting* logístico ajusta con árboles (sesión 6).

A2. LDA, QDA y Naive Bayes: las fórmulas

1. Bayes: $P(y = k \mid x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$; se clasifica en la clase que maximiza $\pi_k f_k(x)$.

A2. LDA, QDA y Naive Bayes: las fórmulas

1. Bayes: $P(y = k | x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$; se clasifica en la clase que maximiza $\pi_k f_k(x)$. **2. LDA:** $f_k = N(\mu_k, \Sigma)$ con Σ común. Tomando logaritmos y descartando lo que no depende de k :

$$\delta_k(x) = x' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log \pi_k,$$

lineal en x : la frontera entre dos clases, $\delta_k(x) = \delta_l(x)$, es un hiperplano. Se estima con $\hat{\pi}_k = n_k/n$, las medias por clase $\hat{\mu}_k$ y la covarianza agrupada $\hat{\Sigma}$.

A2. LDA, QDA y Naive Bayes: las fórmulas

1. Bayes: $P(y = k | x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$; se clasifica en la clase que maximiza $\pi_k f_k(x)$. **2. LDA:** $f_k = N(\mu_k, \Sigma)$ con Σ común. Tomando logaritmos y descartando lo que no depende de k :

$$\delta_k(x) = x' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log \pi_k,$$

lineal en x : la frontera entre dos clases, $\delta_k(x) = \delta_l(x)$, es un hiperplano. Se estima con $\hat{\pi}_k = n_k/n$, las medias por clase $\hat{\mu}_k$ y la covarianza agrupada $\hat{\Sigma}$. **3.**

QDA: $f_k = N(\mu_k, \Sigma_k)$; sobrevive el término cuadrático $-\frac{1}{2}(x - \mu_k)' \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k|$. Con p predictores hay que estimar $K p(p+1)/2$ parámetros de covarianza: mucha varianza si n es pequeño. Es la curva U entre LDA y QDA.

A2. LDA, QDA y Naive Bayes: las fórmulas

1. Bayes: $P(y = k | x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$; se clasifica en la clase que maximiza $\pi_k f_k(x)$. **2. LDA:** $f_k = N(\mu_k, \Sigma)$ con Σ común. Tomando logaritmos y descartando lo que no depende de k :


$$\delta_k(x) = x' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log \pi_k,$$

lineal en x : la frontera entre dos clases, $\delta_k(x) = \delta_l(x)$, es un hiperplano. Se estima con $\hat{\pi}_k = n_k/n$, las medias por clase $\hat{\mu}_k$ y la covarianza agrupada $\hat{\Sigma}$. **3.**

QDA: $f_k = N(\mu_k, \Sigma_k)$; sobrevive el término cuadrático $-\frac{1}{2}(x - \mu_k)' \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k|$. Con p predictores hay que estimar $K p(p+1)/2$ parámetros de covarianza: mucha varianza si n es pequeño. Es la curva U entre LDA y QDA. **4. Naive Bayes:** $f_k(x) = \prod_{j=1}^p f_{kj}(x_j)$; cada f_{kj} se estima por separado (normal, histograma o, para x_j discreta, frecuencias). Con miles de palabras como predictores y pocos correos, es el único de los tres que se puede estimar.

A3. Máquinas de soporte vectorial: la intuición del margen


Fuera del cuerpo del curso; conservada para quien la necesite (ISL, cap. 9)



- Otra filosofía: buscar el hiperplano que separa las clases con el **margen más ancho**; solo los puntos sobre el margen (los *vectores de soporte*, circulados) determinan la solución.
- **Soft margin** (C): permitir violaciones pagando un costo; es la perilla de regularización, elegida por CV.
- **Kernel trick**: productos internos $\rightarrow K(x, x')$: fronteras no lineales sin construir el espacio.

A3. Máquinas de soporte vectorial: la intuición del margen

Fuera del cuerpo del curso; conservada para quien la necesite (ISL, cap. 9)



- Otra filosofía: buscar el hiperplano que separa las clases con el **margen más ancho**; solo los puntos sobre el margen (los *vectores de soporte*, circulados) determinan la solución.
- **Soft margin** (C): permitir violaciones pagando un costo; es la perilla de regularización, elegida por CV.
- **Kernel trick**: productos internos $\rightarrow K(x, x')$: fronteras no lineales sin construir el espacio.

Por qué no está en el cuerpo

Entrega *scores*, no probabilidades (hay que calibrar con Platt); escala mal con n grande; y en la literatura aplicada en economía casi no aparece frente a la logística penalizada y los ensambles de árboles. Referencia: Cortes & Vapnik (1995), *Machine Learning*, 20(3), 273–297.

A4. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\text{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \frac{1}{2} \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

coincide con el área bajo la ROC empírica; por eso no depende del umbral ni de la prevalencia.

A4. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\text{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \frac{1}{2} \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

coincide con el área bajo la ROC empírica; por eso no depende del umbral ni de la prevalencia. **2. El Brier se descompone** (Murphy, 1973). Con B grupos por $\hat{p}$, de tamaño n_b , predicción media $\bar{p}_b$ y frecuencia observada $\bar{y}_b$:

$$\underbrace{\frac{1}{n} \sum_i (\hat{p}_i - y_i)^2}_{\text{Brier}} \approx \underbrace{\frac{1}{n} \sum_b n_b (\bar{p}_b - \bar{y}_b)^2}_{\text{calibración (menor, mejor)}} - \underbrace{\frac{1}{n} \sum_b n_b (\bar{y}_b - \bar{y})^2}_{\text{resolución (mayor, mejor)}} + \underbrace{\bar{y}(1 - \bar{y})}_{\text{incertidumbre}} .$$

A4. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\text{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \frac{1}{2} \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

coincide con el área bajo la ROC empírica; por eso no depende del umbral ni de la prevalencia. **2. El Brier se descompone** (Murphy, 1973). Con B grupos por $\hat{p}$, de tamaño n_b , predicción media $\bar{p}_b$ y frecuencia observada $\bar{y}_b$:

$$\underbrace{\frac{1}{n} \sum_i (\hat{p}_i - y_i)^2}_{\text{Brier}} \approx \underbrace{\frac{1}{n} \sum_b n_b (\bar{p}_b - \bar{y}_b)^2}_{\text{calibración (menor, mejor)}} - \underbrace{\frac{1}{n} \sum_b n_b (\bar{y}_b - \bar{y})^2}_{\text{resolución (mayor, mejor)}} + \underbrace{\bar{y}(1 - \bar{y})}_{\text{incertidumbre}}.$$

- **Calibración:** distancia a la diagonal de la curva de confiabilidad.
- **Resolución:** cuánto separan las probabilidades a los grupos (lo que la AUC mide de otra forma). **Incetidumbre:** el Brier del predictor constante $\bar{y}$.
- AUC alta y Brier malo es posible: buena resolución, mala calibración (k -NN con k pequeño; cualquier modelo tras remuestrear).