

Big Data y Machine Learning para Economía Aplicada

Week 04: Clasificación: de la probabilidad a la decisión

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 24, 2026

Previously...

- **El juez:** la validación cruzada estima el error fuera de muestra sin tocar la prueba. Juzgado así, el campeón de los 511 cayó al puesto 73 y la regla de un error estándar eligió la recta.
- **La perilla:** la penalización cambia el interruptor por variable por un precio continuo. Ridge divide, el Lasso resta y apaga; λ lo elige el juez.
- **En el país:** con 1.291 columnas OLS se desplomó (69,1) y el Lasso dejó el error de prueba en 14,7. Cambia la lista, no la predicción.
- **Dos trampas del juez:** la columna que ya sabe la respuesta (prometía 11,2, valía 13,0) y validar al azar cuando los vecinos se copian.

Lo que traemos

Un modelo que predice el voto por Petro con un error típico de 14,7 puntos, y una disciplina: elegir con el juez y abrir la prueba una sola vez.

La pregunta de hoy: ¿gana Petro el puesto, y qué tan seguros estamos?

La misma elección, los mismos puestos, la misma ficha; cambia la *y*


- **Lo que tenemos:** un número. El Lasso predice el voto con 14,7 puntos de error típico.
- **Lo que la campaña necesita:** una decisión por puesto. Cuáles da por seguros (y no les manda recursos) y cuáles trabaja. No le importa si Petro saca 48 o 52: le importa **si gana**, y **qué tan seguro** es.
- **La *y* de hoy:** $\text{gana_petro} = 1$ si Petro sacó más votos que Hernández en el puesto (ganar es eso, no pasar del 50 %). Pasó en el 53% de los 9.602 puestos de entrenamiento.

La idea con la que se van

Clasificar es estimar una **probabilidad** y luego **decidir**. El modelo ordena los puestos, la calibración dice si sus probabilidades son creíbles y los costos de cada error fijan el umbral.

El atajo: la regresión de la semana 3 ya clasifica

“Gana si el voto predicho es 50 o más”: los cuatro cuadrantes son la matriz de confusión



- En los 2.398 puestos de prueba acierta el **84,8%**; “Petro gana en todos” acierta el 52,9%. En rojo, los errores: caen cerca de las líneas.
- **La regla vigente**, lo que haría la campaña sin modelo: “gana donde ganó en 2018”. En los 2.014 puestos que ya existían acierta el 84,3%; el atajo, el 85,1%.
- Pero entrega **puntos de voto, no una probabilidad**: un 51 y un 95 son el mismo “gana”.


Lo que falta

Un modelo para $P(\text{gana} \mid x)$: sin probabilidad no hay forma de ponerle precio a los errores.

- 1 La probabilidad: de la recta a la curva
- 2 De la probabilidad a la decisión
- 3 Evaluar un clasificador: ordenar, decidir y cuantificar
- 4 El Problem Set 1
- 5 Cierre

¿Por qué no una recta? La curva está en los datos

El área metropolitana de la semana 2: 257 puestos, un predictor (ISL, sección 4.2)




- Con $y \in \{0, 1\}$, $\mathbb{E}[y | x] = P(y = 1 | x)$: OLS sobre la *dummy* estima una probabilidad lineal (el LPM), $\hat{p} = 1,10 - 0,0121 \times \text{educ}$. Se sale de $[0, 1]$ en 112 de los 257 puestos; en el país, con la ficha y los departamentos, en 371 de los 2.398 de prueba (de $-0,28$ a $1,36$).
- Los triángulos no siguen una recta: una meseta cerca de 1 y después una caída. Para un efecto marginal promedio el LPM sirve; para **decidir con probabilidades**, no.

La logística: una S para la probabilidad

Una recta para las chances; el índice sigue siendo lineal (ISL, sección 4.3.1)

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$




- **Intuición:** las chances $p/(1 - p)$ van de 0 a ∞ y su logaritmo, de $-\infty$ a ∞ : ahí sí cabe una recta. La S devuelve cualquier índice a $[0, 1]$.
- **La frontera** $p = 0,5 \iff x'\beta = 0$ es un hiperplano. En el área metropolitana, $6,09 - 0,136 \times \text{educ} = 0$ en **44,8 %** de educación superior: por debajo, el modelo dice que gana Petro.
- **Parámetros:** β . **Hiperparámetros:** ninguno.

La verosimilitud: el RSS de las probabilidades

Se eligen los β que hacen más probable lo observado (ISL, sección 4.3.2)

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1-y_i) \log(1-p_i) \right], \quad p_i = p(x_i).$$



- **La pérdida:** $-\ell(\beta)/n$ es la **log-loss**. Si Petro ganó y el modelo le daba $\hat{p} = 0,01$, paga $-\log 0,01 = 4,6$; el cuadrado, a lo sumo 1: castiga la **seguridad equivocada**.
- **La condición de primer orden,** $\sum_i x_i (y_i - \hat{p}_i) = 0$, es la de OLS con otra predicción: el residuo queda ortogonal a las x y, con intercepto, $\sum_i \hat{p}_i = \sum_i y_i$. Sin solución cerrada: Newton (apéndice A1).

Lo que hay que retener

La logística es el OLS de las probabilidades, y su pérdida también es una métrica que el juez mide fuera de muestra.


Cómo leer la logística, y qué no leer en ella

- **Odds ratio:** e^{β_j} multiplica las chances por cada unidad de x_j . En el área metropolitana, un punto más de educación superior las multiplica por 0,87; diez puntos, por 0,26.
- **El efecto sobre la probabilidad no es constante:** $\partial p / \partial x_j = \beta_j p (1 - p)$. El mismo punto de educación mueve 3,4 puntos de probabilidad donde $p = 0,5$ y 0,1 donde $p = 0,99$: mueve a los dudosos, no a los seguros.
- **Significativo no es predictivo:** en el país, la logística con las nueve variables de la semana 2 tiene 7 coeficientes con $p < 0,01$ y acierta el 68,7%; “gana donde ganó en 2018”, sin un coeficiente, el 84,3%.
- **Separación:** en Casanare Petro ganó el 3% de los puestos y en Putumayo, el 98%. Con una pendiente por departamento, la verosimilitud empuja algunos β hacia $\pm\infty$: otra vez hace falta una perilla.

Hoy leemos $\hat{\beta}$ para entender qué hace el modelo, no para estimar efectos; abrir modelos sin coeficientes es la sesión 6.

La perilla, otra vez: el Lasso logístico

La ficha larga de la semana 3 (1.291 columnas), los mismos 10 pliegues; sólo cambió la pérdida




$$\hat{\beta}^L = \arg \min_{\beta} -\frac{1}{n} \ell(\beta) + \lambda \sum_j |\beta_j|$$

- El juez mide la misma pérdida que el modelo minimiza, ahora fuera de muestra: la log-loss de validación cruzada.
- Con $\lambda_{\min}$ se queda con 386 columnas (285 con λ_{1SE}). Su log-loss de CV es 0,327, contra 0,69 de la prevalencia sola.
- AUC de 0,935 en CV y **0,937** en la prueba.

Los vecinos votan: k -NN como clasificador

La función de las semanas 2 y 3, con y binaria



$$\hat{p}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i$$

- La fracción de los k puestos más cercanos donde ganó Petro. Sin fórmula y sin supuestos: la frontera la dibuja el mapa.
- **k por CV con la AUC:** los vecinos no tienen verosimilitud y , con k chico, dicen 0 o 1 exactos (la log-loss explota). AUC de 0,857 con $k = 1$, **0,949** con $k = 14$ y 0,926 con $k = 100$.
- En la prueba, **0,945**: los vecinos ordenan mejor que la estructura, sin usar el censo.

- 1 La probabilidad: de la recta a la curva
- 2 De la probabilidad a la decisión
- 3 Evaluar un clasificador: ordenar, decidir y cuantificar
- 4 El Problem Set 1
- 5 Cierre

La regla de Bayes y los dos errores

Si las probabilidades fueran las verdaderas, ¿qué regla se equivoca menos? (ISL, secciones 2.2.3 y 4.4.2)

$$\hat{y}(x) = \mathbb{I}\{p(x) \geq 0,5\} \quad \text{minimiza la tasa de error} \quad \frac{1}{n} \sum_i \mathbb{I}\{y_i \neq \hat{y}_i\}.$$

Lasso logístico, umbral 0,5

	Pred. gana	Pred. pierde
Ganó (1.268)	VP = 1.096	FN = 172
Perdió (1.130)	FP = 158	VN = 972

- **Sensibilidad** = $VP/(VP + FN) = 0,86$: de los que ganó, cuántos encontré.
- **Especificidad** = $VN/(VN + FP)$: de los que perdió, cuántos reconocí.
- **Precisión** = $VP/(VP + FP) = 0,87$: de los que di por ganados, cuántos lo eran.
- **El error de Bayes** es el de esa regla ideal: positivo cuando las clases se traslapan, como dos puestos con la misma ficha que se definieron por un voto. Es el σ^2 de la clasificación.
- Pero la regla cuenta igual los dos errores, y a la campaña no le cuestan lo mismo: **FP** es confiarse y perder; **FN**, trabajar un puesto que igual ganaba.

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de que Petro gane un puesto.

1. **Costo esperado de darlo por seguro:** $(1 - p) c_{FP}$ (si lo pierde)
2. **Costo esperado de trabajarlo:** $p c_{FN}$ (si igual lo ganaba)
3. **Darlo por seguro cuando** $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Sólo importa el **cociente** de costos. Si los dos errores cuestan lo mismo, $\tau^* = 0,5$: la regla de Bayes.
- **La campaña:** confiarse y perder cuesta cinco veces más que trabajar un puesto de más. $c_{FP} = 5$, $c_{FN} = 1 \Rightarrow \tau^* = 5/6 \approx \mathbf{0,83}$: sólo se da por seguro lo *muy* seguro.
- El 0,5 por defecto de los paquetes es una decisión económica implícita, y casi nunca la correcta.

El mismo modelo, dos umbrales

Lasso logístico en los 2.398 puestos de prueba; costo = $5 \times FP + 1 \times FN$

Umbral 0,5

	Pred. gana	Pred. pierde
Ganó	VP = 1.096	FN = 172
Perdió	FP = 158	VN = 972

Costo: **962**

Umbral $\tau^* = 0,83$


	Pred. gana	Pred. pierde
Ganó	VP = 850	FN = 418
Perdió	FP = 45	VN = 1.085

Costo: **643**

- Las mismas probabilidades; sólo cambió el umbral. La precisión pasa de 0,87 a 0,95 y la sensibilidad, de 0,86 a 0,67: se trabajan más puestos que igual se ganaban para no regalar los que se pierden.
- La exactitud empeora**, de 86,2% a 80,7%, y sin embargo es la decisión correcta: la exactitud cuenta errores, no pesa costos.

La curva de costo: el mínimo cae donde dijo la fórmula

El costo total de la campaña en la prueba, para cada umbral




- El mínimo de la curva está en $\tau = 0,83$; la fórmula, sin mirar los datos, decía 0,83.
- Sin modelo, dar todos los puestos por seguros cuesta 5.650 y trabajarlos todos, 1.268.
- **Mejores probabilidades valen plata:** con el mismo τ^* , la logística con ficha y departamentos cuesta 695 y los vecinos del mapa, 628.

Pregunta para la sala: la campaña de Hernández usa las mismas probabilidades para decidir qué puestos dar por perdidos, con los mismos 5 a 1. ¿Qué umbral usa?

La curva de costo: el mínimo cae donde dijo la fórmula

El costo total de la campaña en la prueba, para cada umbral




- El mínimo de la curva está en $\tau = 0,83$; la fórmula, sin mirar los datos, decía 0,83.
- Sin modelo, dar todos los puestos por seguros cuesta 5.650 y trabajarlos todos, 1.268.
- **Mejores probabilidades valen plata:** con el mismo τ^* , la logística con ficha y departamentos cuesta 695 y los vecinos del mapa, 628.

Pregunta para la sala: la campaña de Hernández usa las mismas probabilidades para decidir qué puestos dar por perdidos, con los mismos 5 a 1. ¿Qué umbral usa? Su error caro es el contrario: contar como perdido un puesto que Petro gana. $\tau^* = 1/6 \approx 0,17$ sobre la misma $\hat{p}$. Mismo modelo, distinta economía, distinto umbral.

- 1 La probabilidad: de la recta a la curva
- 2 De la probabilidad a la decisión
- 3 Evaluar un clasificador: ordenar, decidir y cuantificar
- 4 El Problem Set 1
- 5 Cierre

La curva ROC: todos los umbrales a la vez

Barriendo τ de 1 a 0: cada punto es una matriz de confusión (ISL, sección 4.4.2, Fig. 4.8)



- **AUC**, el área bajo la curva: 0,5 es el azar, 1 es perfecto. Su lectura exacta: $AUC = P(\hat{p}_i > \hat{p}_j \mid y_i = 1, y_j = 0)$, la probabilidad de que un puesto que ganó Petro reciba más probabilidad que uno que perdió (apéndice A4). No depende del umbral.
- **Ordenar no es decidir**: el voto de 2018 como puntaje tiene una AUC de 0,95, pero con su corte de 50 acierta el 84,3%: Petro creció, y de los 241 puestos donde en 2018 sacó entre 40 y 50, ganó el 65%.

¿Qué elección es más predecible?

La misma logística (bloques del censo y departamentos) en dos segundas vueltas, cada una con su prueba

	2010 (Santos–Mockus)	2022 (Petro–Hernández)
Prevalencia (gana el primero)	0,882	0,529
Exactitud	0,901	0,832
F1	0,945	0,840
<i>Balanced accuracy</i>	0,655	0,832
AUC	0,878	0,906

Pregunta para la sala: ¿cuál es más predecible?

¿Qué elección es más predecible?

La misma logística (bloques del censo y departamentos) en dos segundas vueltas, cada una con su prueba


	2010 (Santos–Mockus)	2022 (Petro–Hernández)
Prevalencia (gana el primero)	0,882	0,529
Exactitud	0,901	0,832
F1	0,945	0,840
<i>Balanced accuracy</i>	0,655	0,832
AUC	0,878	0,906

Pregunta para la sala: ¿cuál es más predecible? Por exactitud y F1, 2010; por *balanced accuracy* y AUC, 2022. En 2010 Santos ganó el 88,2% de los puestos: “Santos gana en todos” se equivoca en el 11,8% y el modelo en el 9,9%. La exactitud premia la dominancia, no la habilidad: de los puestos de Mockus, el modelo reconoce uno de cada tres (especificidad de 0,33).

- Para comparar elecciones, regiones o años, la métrica cabecera **no puede depender de la prevalencia**: AUC o *balanced accuracy* = (sensibilidad + especificidad)/2. Y siempre al lado, la prevalencia.

Cuando los positivos son raros: precisión y *recall*

2010 otra vez, buscando los puestos de Mockus: el 11,8 % de la prueba




- Con umbral 0,5 el modelo levanta 109 alarmas: encuentra el 33% de los puestos de Mockus y acierta en el 65%.
- Para encontrar el 83% hay que bajar a 0,1: 519 alarmas, y sólo el 34% son ciertas.
- La tasa de falsos positivos apenas pasa de 0,02 a 0,22: divide por los negativos, que son muchísimos, y la ROC casi no se entera. La curva PR no usa los VN.

Regla práctica (Saito y Rehmsmeier, 2015)

Positivos raros (la vivienda VIS del Problem Set 1, un fraude, un impago)
⇒ reportar ROC **y** PR, con la prevalencia al lado. Con clases parejas, como los puestos de 2022, la ROC basta.

Calibración: cuando el modelo dice 0,8, ¿gana el 80 %?


La prueba en deciles de $\hat{p}$: la probabilidad media contra la fracción que ganó Petro



- Sobre la diagonal, el modelo **dice la verdad**. El umbral τ^* usa $\hat{p}$ al pie de la letra: sin calibración, decide mal aunque la AUC sea alta.
- El **Brier** $= \frac{1}{n} \sum_i (\hat{p}_i - y_i)^2$ es el MSE de la semana 2 aplicado a probabilidades: Lasso logístico 0,099, k -NN 0,091, la prevalencia sola 0,249.
- Los vecinos exageran en las puntas: el 47% de sus probabilidades de prueba son 0 o 1 exactos.

Dónde falla: los puestos reñidos

Exactitud del Lasso logístico (umbral 0,5) según por cuántos puntos se definió el puesto



- En los 275 puestos que se definieron por menos de 5 puntos acierta el 57%; por encima de 30, el 97%.
- Es el error de Bayes con datos: donde la ficha no distingue ganar de perder por un voto, ningún modelo lo hará.
- Entre la zona rural (85,6%) y las cabeceras (87,1%) casi no hay diferencia.

La tabla de hoy: ordenar, decidir y cuantificar

Los mismos 2.398 puestos de prueba, abiertos una vez; λ y k los eligió el juez con la CV

Modelo	AUC de CV	AUC de prueba	Exactitud (0,5)	Brier
Logística, educación superior	0,520	0,526	52,9%	0,249
Logística, las nueve variables	0,760	0,765	68,7%	0,196
Logística, la ficha de 37	0,845	0,851	77,6%	0,157
Logística, ficha + departamentos	0,920	0,916	83,8%	0,115
Lasso logístico, ficha larga	0,935	0,937	86,2%	0,099
k -NN en el mapa ($k = 14$)	0,949	0,945	87,8%	0,091

- **Cada escalón de la semana 3 vuelve a pagar:** la ficha, los departamentos y la ficha larga con perilla. La educación superior sola no viaja: la estrella de Cali, en el país, no ordena nada.
- **Ningún método domina** (ISL, sección 4.5): los vecinos ordenan mejor sin usar el censo; la estructura explica *qué* se parece a *qué*.
- Tres preguntas, tres métricas: la AUC ordena, la exactitud con un umbral decide y el Brier cuantifica. Ninguna sola cuenta la historia.

- 1 La probabilidad: de la recta a la curva
- 2 De la probabilidad a la decisión
- 3 Evaluar un clasificador: ordenar, decidir y cuantificar
- 4 El Problem Set 1**
- 5 Cierre

El Problem Set 1 se publica hoy

Otro problema, las mismas herramientas. Entrega: martes 20 de octubre, 8:00

Una sola base: avisos de venta de apartamentos y casas en Cali, con diccionario y partición fija. En los avisos de prueba el precio y la condición de VIS están ocultos.

Parte	Sesión	Pts	Qué hacen
1. Referencia y regresión	2	15	la media y OLS; RMSE, MAE y R^2 ; predicho vs. observado
2. Validación y regularización	3	25	CV al azar vs. por zonas; preprocesar en el pliegue; Ridge, Lasso, EN; k -NN
3. Clasificación	4	15	¿es VIS?: referencia y logística; ROC, AUC y PR; umbral con costos; calibración
4. Modelo final	2–4	15	elegir con la validación, reajustar y predecir la prueba una vez
Ranking del curso		20	RMSE de prueba del precio; primero 20, último 10
Reproducibilidad		10	00_run.R corre de principio a fin

En parejas; las prácticas de las sesiones 2 a 4 son el punto de partida. **Debrief** con el ranking en la sesión 7.

- 1 La probabilidad: de la recta a la curva
- 2 De la probabilidad a la decisión
- 3 Evaluar un clasificador: ordenar, decidir y cuantificar
- 4 El Problem Set 1
- 5 Cierre

Recap

- 1 **Clasificar es estimar una probabilidad y luego decidir.** La regresión de la semana 3 ya clasificaba, pero sin decir qué tan seguro.
- 2 **La logística:** una recta para los log-odds, una S para la probabilidad; se ajusta por verosimilitud, cuya pérdida (la log-loss) castiga la seguridad equivocada. El Lasso logístico y los vecinos son la semana 3 y la semana 2 con otra y .
- 3 **El umbral es economía:** $\tau^* = c_{FP} / (c_{FP} + c_{FN})$. Con 5 a 1, el costo de la campaña bajó de 962 a 643 con el mismo modelo, aunque la exactitud empeoró.
- 4 **Ordenar, decidir, cuantificar:** la AUC ordena sin umbral; la exactitud y la F1 dependen de la prevalencia (2010); con positivos raros, precisión y *recall*; nada de esto sirve sin calibración.
- 5 **Dónde falla:** en los puestos reñidos, el error de Bayes que ningún método perfora.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, cap. 8 (árboles, *bagging*, bosques aleatorios y *boosting*).
Guía: las figuras 8.1 a 8.3 (cómo un árbol parte el espacio) y la 8.8 (bosques vs. *bagging*) son las de clase; la sección 8.2.3 es el *boosting*.

Problem Set 1: publicado hoy; entrega el martes 20 de octubre a las 8:00, antes de la sesión 6.

Próxima sesión — árboles, bosques y boosting: hasta hoy todos los modelos de estructura fueron lineales en el índice, y las interacciones con el departamento las escribimos a mano. Un árbol parte el territorio en grupos de puestos parecidos *solo*, y predice una constante en cada uno; un bosque promedia cientos de árboles sobre remuestras *bootstrap*; el *boosting* ajusta árboles a los residuos. Sirven para las dos preguntas del caso, `voto_petro` y `gana_petro`.

Aplicación en R: los mismos puestos y las dos preguntas del caso: un árbol que se pueda leer, un bosque y un *boosting*, contra los mejores de hoy y de la semana 3, en la misma prueba.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Secs. 2.2.3, 4.1–4.5. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Cap. 4. [ESL]
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1–22. [glmnet]
- Murphy, A. H. (1973). A New Vector Partition of the Probability Score. *Journal of Applied Meteorology*, 12(4), 595–600. [apéndice]
- Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357. [apéndice]
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297. [apéndice]
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

6 Apéndice: para profundizar

A1. La verosimilitud de la logística: gradiente y Newton

1. **La log-verosimilitud**, usando $1 - p_i = 1/(1 + e^{x_i' \beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

2. **Gradiente y hessiano** (con $\partial \log(1 + e^{x_i' \beta}) / \partial \beta = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta'} = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i' \equiv -\mathbf{X}' \mathbf{W} \mathbf{X}.$$

3. **Sin solución cerrada** (p_i depende de β de forma no lineal). Newton–Raphson itera

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' (\mathbf{y} - \mathbf{p}),$$

una regresión ponderada en cada paso (*IRLS*); el hessiano es negativo definido, así que ℓ es cóncava y el máximo es único si existe.

4. **Lectura:** con intercepto, $\sum_i \hat{p}_i = \sum_i y_i$. El “residuo por regresor” $x_i(y_i - p_i)$ es lo que el *boosting* logístico ajusta con árboles (sesión 5).

A2. Modelos generativos: LDA, QDA y Naive Bayes

La otra familia de ISL (sección 4.4): modelar x dentro de cada clase y voltear con Bayes

$$P(y = k | x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)},$$

con $\pi_k = P(y = k)$ y f_k la densidad de x dentro de la clase k .

- **LDA:** $f_k = N(\mu_k, \Sigma)$ con la **misma** covarianza. El discriminante $\delta_k(x) = x' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log \pi_k$ es **lineal en** x : frontera lineal, como la logística (ISL 4.5.1 muestra que los dos tienen log-odds lineales; difieren en cómo estiman).
- **QDA:** una covarianza por clase $\Rightarrow$ frontera cuadrática; $Kp(p+1)/2$ parámetros de covarianza: más flexible, más varianza.
- **Naive Bayes:** x independientes dentro de cada clase, $f_k(x) = \prod_j f_{kj}(x_j)$. Falso y útil cuando p es enorme y los datos escasos (el filtro de *spam*).

Por qué no están en el cuerpo

Con n grande y sin normalidad, la logística es más robusta: no pide suponer cómo se distribuyen las x .

A3. Más de dos clases, y conteos

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad,

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la softmax}),$$

con una clase de referencia cuyo β se fija en cero. Ejemplo: ¿cuál de los tres más votados en la primera vuelta gana el puesto? La misma *softmax* es la última capa de una red neuronal (sesión 7).

- **Categorías ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica. Las métricas de hoy se extienden clase por clase (“una contra el resto”).
- **Conteos** (delitos por cuadrante, siniestros): regresión de Poisson, $\log \mathbb{E}[y \mid x] = x' \beta$ (ISL 4.6). La misma lógica: una función de enlace que respeta el soporte de y .

A4. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\text{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \frac{1}{2} \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

es el área bajo la ROC empírica; no depende del umbral ni de la prevalencia.

2. El Brier se descompone (Murphy, 1973). Con B grupos por $\hat{p}$, de tamaño n_b , predicción media $\bar{p}_b$ y frecuencia observada $\bar{y}_b$:

$$\underbrace{\frac{1}{n} \sum_i (\hat{p}_i - y_i)^2}_{\text{Brier}} \approx \underbrace{\frac{1}{n} \sum_b n_b (\bar{p}_b - \bar{y}_b)^2}_{\text{calibración}} - \underbrace{\frac{1}{n} \sum_b n_b (\bar{y}_b - \bar{y})^2}_{\text{resolución}} + \underbrace{\bar{y}(1 - \bar{y})}_{\text{incertidumbre}} .$$

- **Calibración:** la distancia a la diagonal de la figura de deciles (menor, mejor).
- **Resolución:** cuánto separan las probabilidades a los grupos (mayor, mejor).
- AUC alta y Brier malo es posible: buena resolución, mala calibración.

A5. Desbalance de clases: remuestrear o decidir mejor

Con 2 % de positivos (un fraude, un impago), la verosimilitud apenas nota a la clase rara. **Los remedios**, del más simple al más elaborado:

- ➊ **Mover el umbral** con los costos: casi siempre basta si el modelo ordena bien y está calibrado.
- ➋ **Pesos en la pérdida** (*class weights*): encarecer los errores de la clase rara, sin tocar los datos.
- ➌ **Submuestrear** la clase mayoritaria o **sobremuestrear** la minoritaria; **SMOTE** (Chawla et al., 2002) crea positivos sintéticos entre vecinos, $x_{new} = x_i + u(x_{nn} - x_i)$, $u \sim U(0, 1)$.

Dos advertencias no negociables

(i) Todo remuestreo ocurre **dentro de cada pliegue y sólo en el entrenamiento** (regla de oro #3). (ii) Remuestrear **distorsiona** $\hat{p}$: hay que recalibrar antes de usar un umbral de costos.

A6. Máquinas de soporte vectorial: la intuición del margen

Fuera del cuerpo del curso; para quien la necesite (ISL, cap. 9)

- Otra filosofía: buscar el hiperplano que separa las clases con el **margen más ancho**; sólo los puntos sobre el margen (los *vectores de soporte*) determinan la solución.
- **Margen blando** (C): permitir violaciones pagando un costo; es la perilla, elegida por CV.
- **Kernel**: reemplazar productos internos por $K(x, x')$ da fronteras no lineales sin construir el espacio.

Por qué no está en el cuerpo

Entrega puntajes, no probabilidades (hay que calibrarlos), escala mal con n grande y en la economía aplicada casi no aparece frente a la logística penalizada y los ensambles de árboles. Referencia: Cortes y Vapnik (1995).