Big Data y Machine Learning para Economía Aplicada

Week 04: Clasificación: de la probabilidad a la decisión

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

October 6, 2026

Previously...

- **El juez:** la validación cruzada estima el error fuera de muestra sin tocar la prueba. Juzgado así, el campeón de los 511 cayó al lugar 73 y la regla de un error estándar eligió la recta.
- **La perilla:** la penalización cambia el interruptor por variable por un precio continuo. Ridge divide, el Lasso resta y apaga; λ lo elige el juez.
- **En el país:** con las 1.291 columnas del censo $\times$ departamento OLS se desplomó (69,1) y el juez eligió al Lasso: 14,9 de CV, 14,7 en la prueba.
- **Dos jueces, dos preguntas:** validar al azar responde "¿completo el mapa?"; sacar municipios enteros, "¿predigo un municipio nuevo?". Al k-NN le cuesta 3,0 puntos.

Lo que traemos

Un modelo que predice el voto por Petro con un RMSE de prueba de 14,7 puntos, y una disciplina: elegir con el juez y abrir la prueba una sola vez.

La pregunta de hoy: ¿gana Petro el puesto, y qué tan seguros estamos?

La misma elección, los mismos puestos, el mismo censo; cambia la *y*

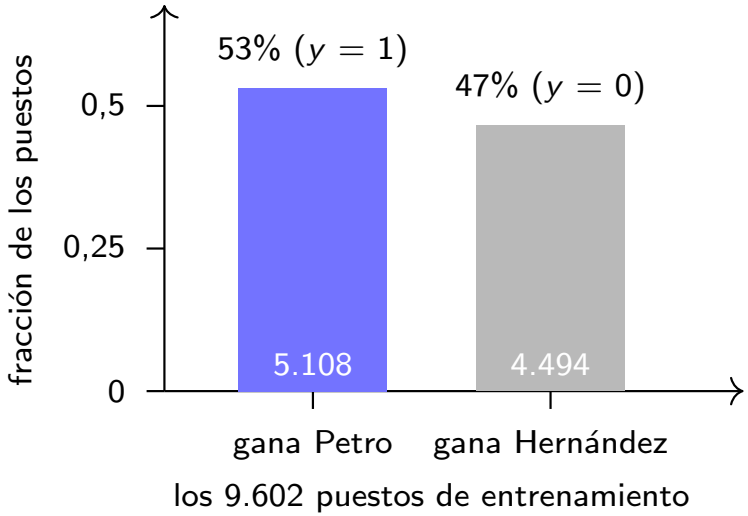
- **Lo que tenemos:** un número. El Lasso predice el voto con un RMSE de prueba de 14,7 puntos.
- **Lo que la campaña necesita:** una decisión por puesto. Cuáles da por seguros (y no les manda recursos) y cuáles trabaja. No le importa si Petro saca 60 o 75: le importa **si gana**, y **qué tan seguro** es.
- **La *y* de hoy:** $\texttt{gana_petro} = 1$ si Petro sacó más votos que Hernández en el puesto (ganar es eso, no pasar del 50 %). Su distribución, antes de cualquier modelo: la siguiente lámina.

La idea con la que se van

Clasificar es estimar una **probabilidad** y luego **decidir**: el modelo ordena los puestos y los costos de cada error fijan el umbral.

La y, antes de cualquier modelo

Como en la semana 2: describir el *target*, y sacar de ahí las primeras referencias



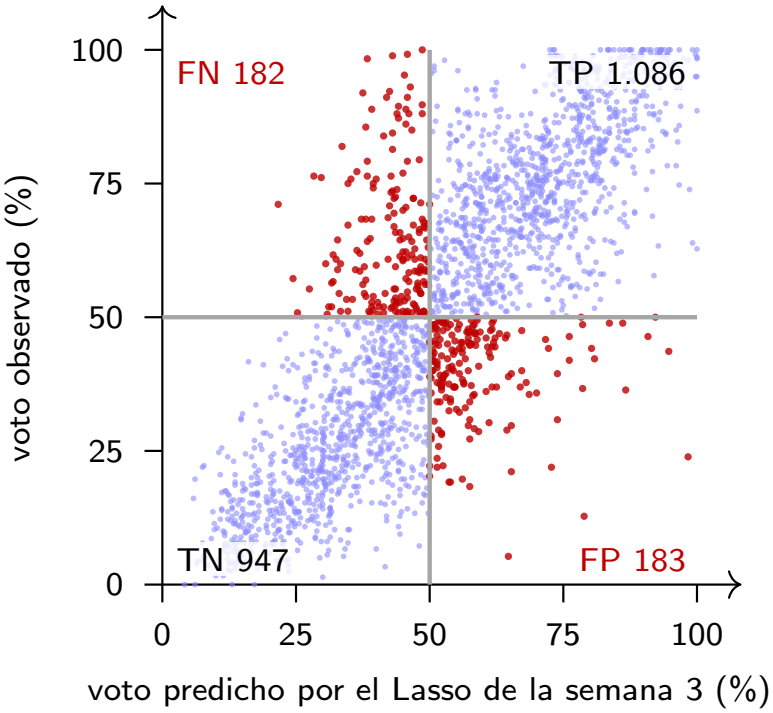
- **La y es un 0 o un 1:** `gana_petro` $= 1$ si Petro sacó más votos que Hernández en el puesto, 0 si no. En el entrenamiento gana en el 53 % (5.108 de 9.602): las clases están casi parejas.
- **Referencia 1, sin un solo dato:** decir "gana en todos". En la prueba acierta el 52,9 %: la **prevalencia**, la fracción de puestos con $y = 1$.
- **Referencia 2, sin modelo:** la regla vigente de la campaña, "gana donde ganó en 2018". Acierta el 84,3 % en los 2.014 puestos con historia.

La vara de hoy

Todo modelo tiene que ganarles a las dos referencias; y cuando una clase domina, la prevalencia infla el *accuracy* (lo veremos con 2010).

El atajo: la regresión de la semana 3 ya clasifica

"Gana donde saca más votos predichos": los cuatro cuadrantes son la matriz de confusión



- **El atajo:** nada nuevo que estimar — el Lasso de la semana 3 predice el voto sobre los dos; "gana" si llega a 50: **más votos que Hernández**.
- Acierta el **84,8%**, por encima de las dos referencias: 52,9% la 1; la 2, 84,3% contra 85,1% del atajo.
- En rojo, los errores frente a `gana_petro`: los reñidos.
- Pero entrega **puntos de voto, no una probabilidad**: un 51 y un 95 son el mismo "gana".

Lo que falta

Un modelo para $P(\text{gana} \mid x)$: con una probabilidad, el corte que abarata los errores lo da una fórmula; con puntos de voto, hay que buscarlo a tientas.

1 La probabilidad: de la recta a la curva

2 La decisión y sus métricas

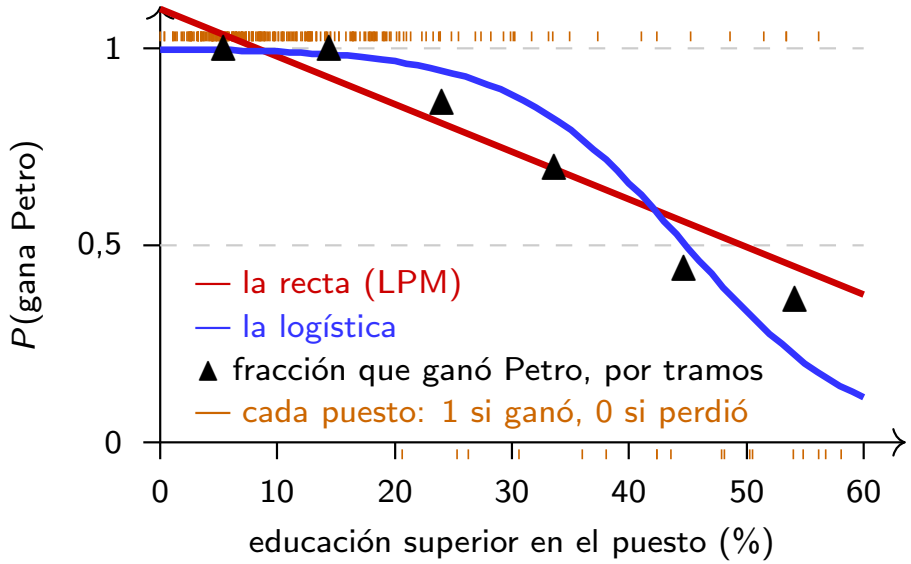
3 Evaluar y comparar: ordenar, decidir y cuantificar

4 El Problem Set 1

5 Cierre

¿Por qué no una recta? La curva está en los datos

El área metropolitana de la semana 2: 257 puestos, un predictor (ISL, sección 4.2)



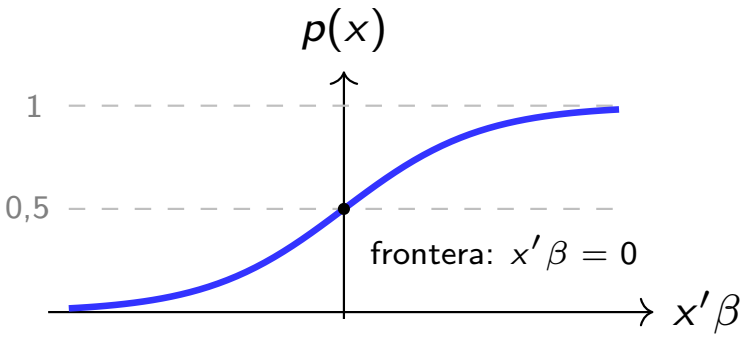
- Con $y \in \{0, 1\}$, $\mathbb{E}[y \mid x] = P(y = 1 \mid x)$: la $P(\text{gana} \mid x)$ que faltaba se puede estimar con OLS sobre la *dummy* — el **modelo de probabilidad lineal** (LPM): $\hat{p} = 1{,}10 - 0{,}0121 \times \text{educ}$. Pero se sale de $[0, 1]$ en 112 de los 257 puestos.
- Los triángulos no siguen una recta: una meseta cerca de 1 y después una caída. Para un efecto marginal promedio el LPM sirve; para **decidir con probabilidades**, no: hay que encerrar la recta en $[0, 1]$ — la S de la siguiente lámina.

En el país pasa igual: con censo + dummies de departamento, el LPM se sale de $[0, 1]$ en 371 de los 2.398 puestos de prueba (de $-0{,}28$ a $1{,}36$).

La logística: una S para la probabilidad

La recta de siempre, convertida en probabilidad (ISL, sección 4.3.1)

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}}$$

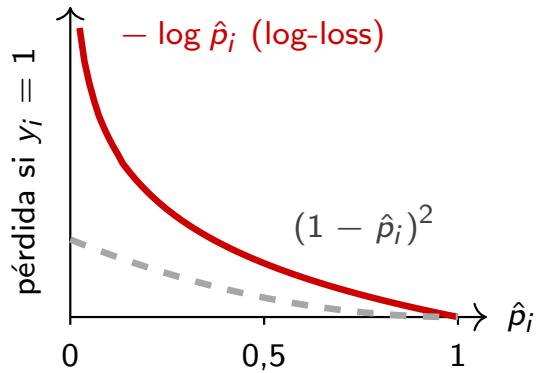


- **La lectura del economista:** una **ventaja latente** de Petro en el puesto, $y^* = x'\beta + \varepsilon$; observamos $y = 1$ si $y^* > 0$. Su media, la **ventaja esperada** $x'\beta$, es la recta de siempre; la S la convierte en probabilidad.
- Con ε logístico sale esta S (el *logit*); con ε normal, el *probit*: gemelos en la práctica.
- **Al revés:** $\log \frac{p}{1-p} = x'\beta$: las *chances* $p/(1-p)$ en logaritmo sí son una recta; así se leerán los β (dos láminas).
- **En los 257 del área metropolitana:** ventaja esperada $= 6{,}09 - 0{,}136 \times$ educ; cruza 0 — la **frontera**, $\hat{p} = 0{,}5$ — en **44,8 %** de educación superior: por debajo, Petro.
- **Parámetros:** β. **Hiperparámetros:** ninguno.

La verosimilitud: el RSS de las probabilidades

Se eligen los β que hacen más probable lo observado (ISL, sección 4.3.2)

$$\hat{\beta} \;=\; \arg\max_{\beta}\; \ell(\beta), \qquad \ell(\beta) = \sum_{i=1}^{n} \Big[\, y_i \log p_i + (1-y_i)\log(1-p_i) \,\Big], \qquad p_i = p(x_i).$$



- **La pérdida:** $-\ell(\beta)/n$ es la **log-loss**. Si Petro ganó y el modelo le daba $\hat{p} = 0{,}01$, paga $-\log 0{,}01 = 4{,}6$; el cuadrado, a lo sumo 1: castiga la **seguridad equivocada**.
- **La condición de primer orden**, $\sum_i x_i(y_i - \hat{p}_i) = 0$, es la de OLS con otra predicción: el residuo queda ortogonal a las x y, con intercepto, $\sum_i \hat{p}_i = \sum_i y_i$. Sin solución cerrada: Newton (apéndice A1).

Lo que hay que retener

La logística es el OLS de las probabilidades, y su pérdida también es una métrica que el juez mide fuera de muestra.

Cómo leer la logística

¿Menos 0,136 *qué*? Gratis sólo se lee el signo; la magnitud hay que convertirla

- **El problema:** en la semana 2, $\hat{\beta}$ eran puntos de voto ($-0{,}75$ por punto de educación). Hoy $\hat{\beta}_{\text{educ}} = -0{,}136$ está en unidades de la **ventaja latente**, y esa escala es convencional: **sólo el signo se lee directo —** más educación, menos Petro.
- **Conversión 1, a chances:** e^{β_j} multiplica las chances $p/(1-p)$: $e^{-0{,}136} = 0{,}87$ por punto de educación; 0,26 por diez puntos (el *odds ratio* de los papers).
- **Conversión 2, a probabilidad:** $\partial p/\partial x_j = \beta_j\, p\,(1-p)$ depende del puesto: $-3{,}4$ puntos de probabilidad en la frontera ($p = 0{,}5$) y $-0{,}1$ en uno seguro ($p = 0{,}99$): **mueve a los dudosos, no a los seguros**.

Qué no leer en la logística

Dos advertencias — y la segunda vuelve a pedir la perilla

- **Significativo no es predictivo:** en el país, la logística con las nueve variables de la semana 2 tiene 7 coeficientes con $p < 0{,}01$ y acierta el 68,7%; "gana donde ganó en 2018", sin un solo coeficiente, el 84,3%.
- **Separación:** en Casanare Petro ganó el 3% de los puestos y en Putumayo, el 98%. Con una pendiente por departamento, la verosimilitud empuja algunos β hacia $\pm\infty$: otra vez hace falta una perilla.

Leemos $\hat{\beta}$ para entender el modelo, no para estimar efectos; abrir modelos sin coeficientes es la sesión 6.

1 La probabilidad: de la recta a la curva

2 La decisión y sus métricas

3 Evaluar y comparar: ordenar, decidir y cuantificar

4 El Problem Set 1

5 Cierre

Del modelo a la decisión: el umbral τ

La logística entrega una probabilidad; la clase la ponemos nosotros

- **El modelo de esta parte:** la logística de la parte 1, ahora con las variables de la semana 3 — las 37 del censo + las *dummies* de departamento —, estimada en los 9.602 puestos de entrenamiento.
- **Lo que entrega** para cada puesto de prueba es $\hat{p} = \widehat{P}(\text{gana} \mid x) \in [0, 1]$: una probabilidad, **no** un "gana/pierde".
- **La clase la pone una regla nuestra:** elegir un umbral τ y declarar "gana" si $\hat{p} \geq \tau$. La primera elección natural: $\tau = 0{,}5$, declarar lo más probable.
- **Tres objetos, no uno:** el 50 del atajo eran **puntos de voto** predichos; $\hat{p}$ es una **probabilidad** de ganar; τ es el **corte** que convierte esa probabilidad en una clase.

La pregunta de esta parte

¿Qué produce $\tau = 0{,}5$? ¿Cómo se ve el modelo en *todos* los umbrales a la vez? ¿Y cuál τ conviene? Esa es la ruta de esta parte.

La matriz de confusión: los cuatro resultados de la regla

La logística censo + dummies con $\tau = 0{,}5$, en los 2.398 de prueba (ISL, sección 4.4.2)

La regla: $\hat{p} \geq \tau = 0{,}5$

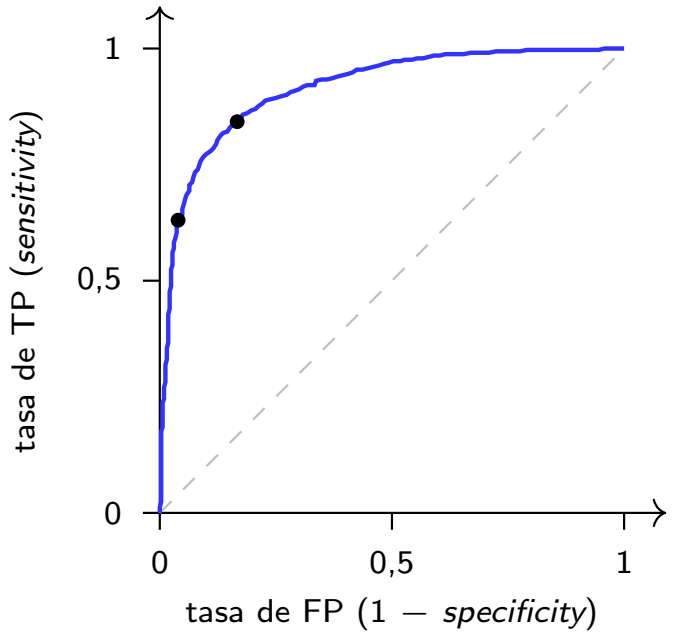
	Pred. gana	Pred. pierde
Ganó (1.268)	TP = 1.067	FN = 201
Perdió (1.130)	FP = 188	TN = 942

- **Accuracy** $= (TP + TN)/n = 0{,}84$: el % de acierto con el que venimos comparando las referencias.
- **Sensitivity** — en los papers, *recall*; **son la misma métrica** — $= TP/(TP + FN) = 0{,}84$: de los que ganó, cuántos encontré.
- **Specificity** $= TN/(TN + FP) = 0{,}83$: de los que perdió, cuántos reconocí.
- **Precision** $= TP/(TP + FP) = 0{,}85$: de los que di por ganados, cuántos lo eran.

Cuatro lecturas de la misma tabla, todas con $\tau = 0{,}5$. ¿Y en los demás umbrales? La siguiente lámina.

La curva ROC: todos los umbrales a la vez

Cada punto de la curva es una matriz de confusión (ISL, sección 4.4.2, Fig. 4.8)



AUC en la prueba

— la logística censo + dummies: 0,916

• dos umbrales: $\tau = 0{,}5$ y $\tau = 0{,}83$

- - - azar: AUC = 0,50

- **Los ejes son las métricas que acabamos de definir:** vertical, la tasa de TP (*sensitivity*); horizontal, la tasa de FP (1− *specificity*). Una regla $\hat{p} \geq \tau$ es **un punto**; barrer τ de 1 a 0 dibuja **la curva**.
- Los dos puntos negros: $\tau = 0{,}5$, la regla de la matriz anterior, y un corte más exigente, $\tau = 0{,}83$, que en unas láminas tendrá nombre propio. ¿Y el "AUC" de la leyenda? La siguiente lámina.

El AUC: qué tan bien ordena el modelo, sin fijar umbral

El área bajo la curva ROC resume todos los umbrales en un solo número

$$\text{AUC} \;=\; P\big(\hat{p}_i > \hat{p}_j \;\big|\; y_i = 1,\; y_j = 0\big)$$

- **La lectura exacta:** la probabilidad de que un puesto que ganó Petro reciba más probabilidad que uno que perdió (apéndice A4). 0,5 es el azar; 1, el orden perfecto. La logística censo + dummies: **0,916**.
- **No depende de τ:** mide el **ordenamiento**, no la decisión. Por eso sirve para comparar modelos antes de comprometerse con un umbral.
- **Ordenar no es decidir:** el voto de 2018 como puntaje tiene una AUC de 0,95, pero con su corte de 50 acierta el 84,3%: Petro creció, y de los 241 puestos donde en 2018 sacó entre 40 y 50, ganó el 65%.

¿Y si movemos τ? Se mueve la matriz entera

Las mismas $\hat{p}$, otro corte: nada se reestima

Umbral 0,5

	Pred. gana	Pred. pierde
Ganó	TP = 1.067	FN = 201
Perdió	FP = 188	TN = 942

Umbral 0,83

	Pred. gana	Pred. pierde
Ganó	TP = 798	FN = 470
Perdió	FP = 45	TN = 1.085

- Subir el corte exige más seguridad para declarar "gana": los FP caen de 188 a 45 y los FN suben de 201 a 470.
- Las métricas se mueven en direcciones opuestas: *precision* 0,85 $\rightarrow$ 0,95; *sensitivity* 0,84 $\rightarrow$ 0,63; *accuracy* 83,8% $\rightarrow$ 78,5%.
- **¿Cuál τ es el bueno?** La mecánica no lo dice, y la AUC tampoco: es una pregunta sobre **costos**. La siguiente lámina.

El umbral es una decisión económica

La estadística estima p; la economía pone los costos

Los dos errores no cuestan lo mismo: **FP** es confiarse y perder el puesto; **FN**, trabajar uno que igual ganaba. Sean c_{FP} y c_{FN} esos costos y p la probabilidad de ganar.

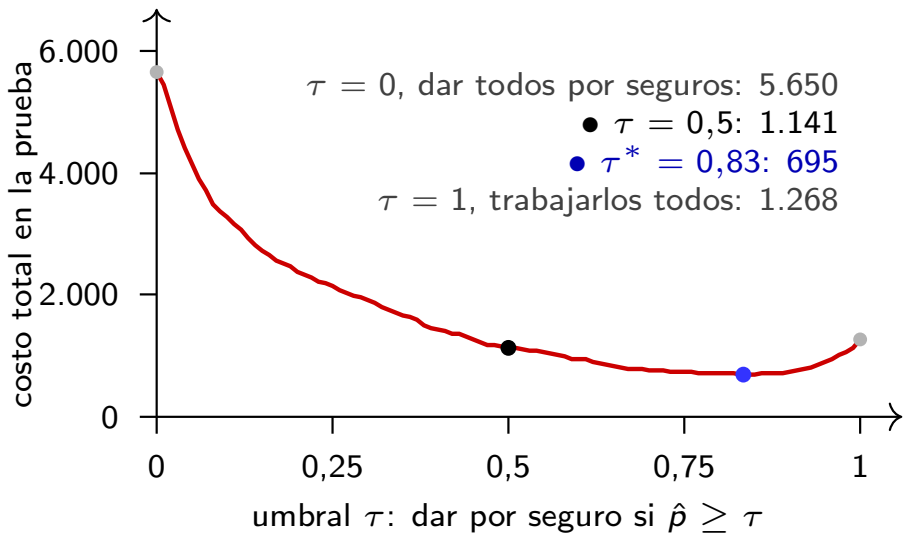
1. **Costo esperado de darlo por seguro:** $(1-p)\,c_{FP}$ (si lo pierde)
2. **Costo esperado de trabajarlo:** $p\,c_{FN}$ (si igual lo ganaba)
3. **Darlo por seguro cuando** $(1-p)\,c_{FP} \leq p\,c_{FN}$, es decir:

$$\boxed{p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}}$$

- Sólo importa el **cociente** de costos. Si los dos errores cuestan lo mismo, $\tau^* = 0{,}5$: la regla de Bayes.
- **La campaña:** confiarse y perder cuesta cinco veces más que trabajar un puesto de más. $c_{FP} = 5$, $c_{FN} = 1 \Rightarrow \tau^* = 5/6 \approx \mathbf{0{,}83}$: sólo se da por seguro lo *muy* seguro.
- El 0,5 por defecto de los paquetes es una decisión económica implícita, y casi nunca la correcta.

La curva de costo: el mínimo cae donde dijo la fórmula

El costo total de la campaña en la prueba, para cada umbral

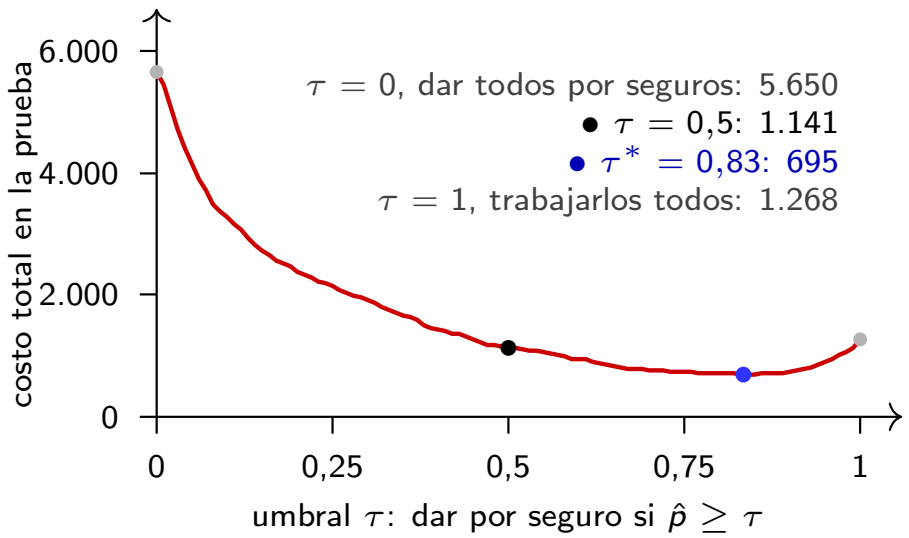


- El mínimo cae en $\tau = 0{,}84$; la fórmula decía 0,83: **el 0,83 de la mecánica era τ^*.**
- Las dos matrices, con su costo: $\tau = 0{,}5$ paga **1.141**; τ^*, **695** — y el *accuracy* empeora (83,8 → 78,5%): **cuenta errores, no pesa costos**.
- Sin modelo: todos seguros cuestan 5.650; todos trabajados, 1.268. **Mejores $\hat{p}$ valdrían más plata**: la parte 3 mide si un competidor las tiene.

Pregunta para la sala: la campaña de Hernández usa las mismas probabilidades para decidir qué puestos dar por perdidos, con los mismos 5 a 1. ¿Qué umbral usa?

La curva de costo: el mínimo cae donde dijo la fórmula

El costo total de la campaña en la prueba, para cada umbral



- El mínimo cae en $\tau = 0{,}84$; la fórmula decía 0,83: **el 0,83 de la mecánica era τ^*.**
- Las dos matrices, con su costo: $\tau = 0{,}5$ paga **1.141**; τ^*, **695** — y el *accuracy* empeora (83,8 → 78,5%): **cuenta errores, no pesa costos**.
- Sin modelo: todos seguros cuestan 5.650; todos trabajados, 1.268. **Mejores $\hat{p}$ valdrían más plata**: la parte 3 mide si un competidor las tiene.

Pregunta para la sala: la campaña de Hernández usa las mismas probabilidades para decidir qué puestos dar por perdidos, con los mismos 5 a 1. ¿Qué umbral usa? Su error caro es el contrario: contar como perdido un puesto que Petro gana. $\tau^* = 1/6 \approx 0{,}17$ sobre la misma $\hat{p}$. Mismo modelo, distinta economía, distinto umbral.

Caso especial: cuando una clase domina

Fuera del hilo, para llevar: 2010, donde Santos ganó el 88 % de los puestos

La y: en 2010, 1 si **Santos** saca más votos que Mockus en el puesto; en 2022, si **Petro** saca más que Hernández. La misma logística (bloques del censo y departamentos), estimada en *su* entrenamiento; la clase, con $\hat{p} \geq \tau = 0{,}5$: de esa matriz, *accuracy* y F1 (la media armónica de *precision* y *recall*). La AUC no usa τ.

	2010 (Santos–Mockus)	2022 (Petro–Hernández)
Prevalencia ($y = 1$)	0,882	0,529
Accuracy	0,901	0,832
F1	0,945	0,840
Balanced accuracy	0,655	0,832
AUC	0,878	0,906

Pregunta para la sala: ¿cuál es más predecible?

Caso especial: cuando una clase domina

Fuera del hilo, para llevar: 2010, donde Santos ganó el 88 % de los puestos

La y: en 2010, 1 si **Santos** saca más votos que Mockus en el puesto; en 2022, si **Petro** saca más que Hernández. La misma logística (bloques del censo y departamentos), estimada en *su* entrenamiento; la clase, con $\hat{p} \geq \tau = 0{,}5$: de esa matriz, *accuracy* y F1 (la media armónica de *precision* y *recall*). La AUC no usa τ.

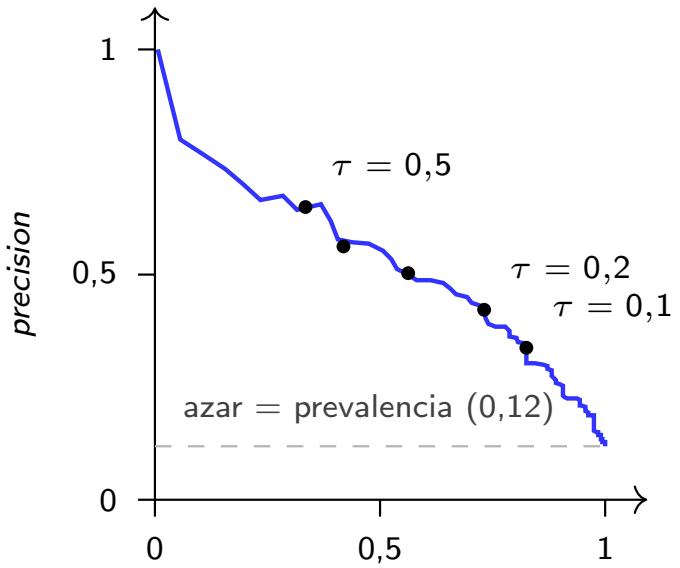
	2010 (Santos–Mockus)	2022 (Petro–Hernández)
Prevalencia ($y = 1$)	0,882	0,529
Accuracy	0,901	0,832
F1	0,945	0,840
Balanced accuracy	0,655	0,832
AUC	0,878	0,906

Pregunta para la sala: ¿cuál es más predecible? Por *accuracy* y F1, 2010; por *balanced accuracy* y AUC, 2022. En 2010 Santos ganó el 88,2%: "Santos gana en todos" se equivoca en el 11,8% y el modelo en el 9,9%. El *accuracy* premia la dominancia, no la habilidad: de los puestos de Mockus, el modelo reconoce uno de cada tres (*specificity* de 0,33).

- Para comparar elecciones, regiones o años, la métrica cabecera **no puede depender de la prevalencia**: AUC o *balanced accuracy* $= (\textit{sensitivity} + \textit{specificity})/2$.

Caso especial (II): positivos raros — *precision* y *recall*

Buscar los puestos de Mockus en 2010: el 11,8 % de la prueba



recall: fracción de puestos de Mockus encontrados

- Con $\tau = 0{,}5$ el modelo **señala** 109 puestos como de Mockus: encuentra el 33% (*recall*) y acierta en el 65% de los señalados (*precision*).
- Para encontrar el 83% hay que bajar τ a 0,1: señala 519, y sólo el 34% son de Mockus de verdad.
- La tasa de falsos positivos apenas pasa de 0,02 a 0,22: divide por los negativos, que son muchísimos, y la ROC casi no se entera. La curva PR no usa los TN.

Regla práctica (Saito y Rehmsmeier, 2015)

Positivos raros (la vivienda VIS del Problem Set 1, un fraude, un impago) $\Rightarrow$ reportar ROC **y** PR, con la prevalencia al lado. Con clases parejas, como los puestos de 2022, la ROC basta.

1 La probabilidad: de la recta a la curva

2 La decisión y sus métricas

3 Evaluar y comparar: ordenar, decidir y cuantificar

4 El Problem Set 1

5 Cierre

El competidor: el LPM con el Lasso de la semana 3

La pérdida cuadrática de la semana 3 sobre la y de 0/1, con el censo $\times$ departamento y los 10 pliegues

$$\hat{\beta}^{\text{LPM-}L} \;=\; \arg\min_{\beta} \; \frac{1}{n}\sum_{i}\left(y_i - x_i'\beta\right)^2 \;+\; \lambda\sum_{j}|\beta_j|, \qquad y_i \in \{0,1\}.$$

- **Es exactamente la perilla de la semana 3; sólo cambió la y.** El juez elige λ_{min} y quedan **179 de las 1.291 columnas** (140 con la regla de un error estándar).
- **Ordena un pelo mejor que la logística:** AUC de 0,925 en la prueba contra 0,916 (y 0,929 contra 0,920 en la validación).
- **Pero sus "probabilidades" no son probabilidades:** en la prueba se sale de $[0,1]$ en 184 puestos (va de $-0{,}24$ a 1,80). Para ordenar sirve; para el umbral de costos, no.

¿Y si le devolvemos la S de la logística a su selección de variables? La siguiente lámina.

La logística con las variables seleccionadas

Las 140 columnas que el LPM-Lasso dejó con la regla 1-EE, ahora dentro de la verosimilitud

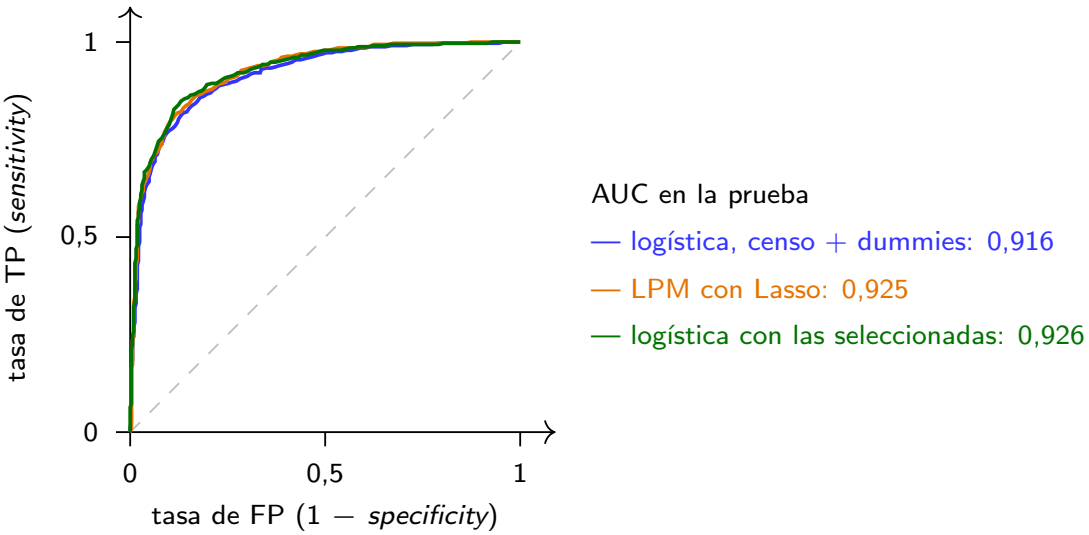
- **La misma lista de variables, otra formulación:** la ventaja esperada $x'\beta$ entra en la S y las $\hat{p}$ vuelven a $[0, 1]$.
- AUC de **0,926** en la prueba (0,933 en la validación); *accuracy* de 85,5 % con $\tau = 0{,}5$.
- La letra pequeña del pipeline honesto (regla de oro #3): la selección se hizo una vez con todo el entrenamiento, así que su cifra de *validación* hereda esa elección; la de **prueba** nunca la vio. El pipeline sin este paso — penalizar la logística directamente — queda en el apéndice A8.

La comparación que importa

Mismas variables, dos formulaciones: el LPM y el Logit ordenan casi igual; la diferencia está en si las $\hat{p}$ se pueden usar como probabilidades para decidir.

Las tres curvas, la misma prueba

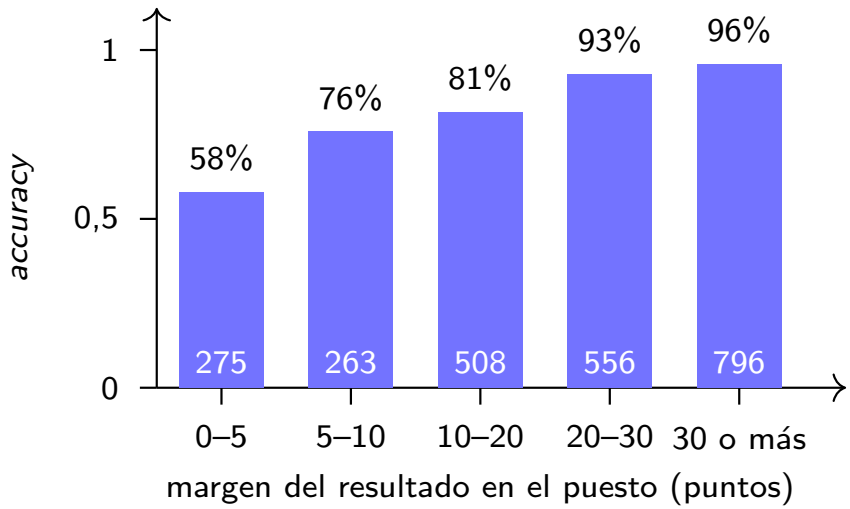
Ordenar: las ROC y sus AUC, en condiciones comparables



- Las tres ordenan muy por encima del azar y casi pegadas: 0,916, 0,925 y **0,926**.
- **Ordenar no es todo:** el LPM con Lasso ordena bien, pero 184 de sus $\hat{p}$ no son probabilidades: no puede usar la regla de costos.
- **El mejor de hoy:** la logística con las seleccionadas — ordena mejor *y* entrega probabilidades de verdad.

Dónde falla: los puestos reñidos

Accuracy del mejor, la logística con las seleccionadas ($\tau = 0{,}5$), según el margen del puesto



- En los 275 puestos que se definieron por menos de 5 puntos acierta el 58%; por encima de 30, el 96%.
- Es el error irreducible de la semana 1, en versión clasificación: donde el censo no distingue ganar de perder por un voto, ningún modelo lo hará.
- En la zona rural acierta un poco menos: 84,7% contra 86,6% en las cabeceras.

La tabla de hoy: las referencias y los tres modelos

Los mismos 2.398 puestos de prueba, abiertos una vez; λ lo eligió el juez, como en la semana 3

Modelo	AUC de CV	AUC de prueba	*Accuracy* (0,5)
Referencia 1: "gana en todos"	—	0,50 (azar)	52,9%
Referencia 2: la regla de 2018†	—	0,95	84,3%
LPM con Lasso, censo × depto.	0,929	0,925	84,8%
Logística, censo + dummies de depto.	0,920	0,916	83,8%
Logística con las seleccionadas‡	0,933	**0,926**	**85,5%**

† En sus 2.014 puestos con historia; su AUC es la del voto de 2018 como puntaje. ‡ Su CV hereda la selección (regla #3); su prueba, no.

- **¿Le ganan a las referencias?** A la 1, de lejos; a la regla de 2018, por poco — el atajo ya lo mostró: 85,1% contra 84,3% en los mismos 2.014.
- **¿Quién ordena mejor?** Las seleccionadas (0,926), con el LPM pisándole los talones — pero sin probabilidades para la regla de costos.
- **¿Y al decidir?** Con $\tau = 0{,}5$ también ganan las seleccionadas; y con costos 5 a 1 el umbral es τ^*, que exige $\hat{p}$ de verdad: la S.

1 La probabilidad: de la recta a la curva

2 La decisión y sus métricas

3 Evaluar y comparar: ordenar, decidir y cuantificar

4 El Problem Set 1

5 Cierre

El Problem Set 1 se publica hoy

Otro problema, las mismas herramientas. Entrega: martes 20 de octubre, 8:00

Una sola base: avisos de venta de apartamentos y casas en Cali, con diccionario y partición fija. En los avisos de prueba el precio y la condición de VIS están ocultos.

Parte	Sesión	Pts	Qué hacen
1. Referencia y regresión	2	15	la media y OLS; RMSE, MAE y R^2; predicho vs. observado
2. Validación y regularización	3	25	CV al azar vs. por zonas; preprocesar en el pliegue; Ridge, Lasso, EN; k-NN
3. Clasificación	4	15	¿es VIS?: referencia y logística; matriz y métricas; ROC y AUC; PR (la clase rara); umbral con costos
4. Modelo final	2–4	15	elegir con la validación, reajustar y predecir la prueba una vez
Ranking del curso		20	RMSE de prueba del precio; primero 20, último 10
Reproducibilidad		10	`00_run.R` corre de principio a fin

En parejas; las prácticas de las sesiones 2 a 4 son el punto de partida. **Debrief** con el ranking en la sesión 7.

1 La probabilidad: de la recta a la curva

2 La decisión y sus métricas

3 Evaluar y comparar: ordenar, decidir y cuantificar

4 El Problem Set 1

5 Cierre

Recap

1. **Primero la y y sus referencias:** la prevalencia y la regla vigente; todo modelo tiene que ganarles.
2. **Clasificar es estimar una probabilidad y luego decidir:** del LPM a la logística (la S, la verosimilitud y la log-loss, que castiga la seguridad equivocada).
3. **La matriz de confusión y sus métricas:** *accuracy*, *precision*, *sensitivity* (= *recall*) y *specificity*; con clases desbalanceadas el *accuracy* engaña (2010), y con positivos raros se mira *precision–recall*.
4. **El umbral es economía:** $\tau^* = c_{FP}/(c_{FP} + c_{FN})$; con 5 a 1, el costo bajó de 1.141 a 695 con el mismo modelo, aunque el *accuracy* empeoró. La AUC ordena sin necesidad de umbral.
5. **Tres modelos, una lección:** ordenan casi igual (0,916, 0,925 y **0,926**); el LPM con Lasso no entrega probabilidades (184 fuera de $[0, 1]$) y la logística sí, que es lo que pide la regla de costos. Y la regla de 2018 sigue siendo una vara seria.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, cap. 8 (árboles, *bagging*, bosques aleatorios y *boosting*).
  Guía: las figuras 8.1 a 8.3 (cómo un árbol parte el espacio) y la 8.8 (bosques vs. *bagging*) son las de clase; la sección 8.2.3 es el *boosting*.

Problem Set 1: publicado hoy; entrega el martes 20 de octubre a las 8:00, antes de la sesión 6.

Próxima sesión — árboles, bosques y boosting: hasta hoy todos los modelos de estructura fueron lineales en $x'\beta$, y las interacciones con el departamento las escribimos a mano. Un árbol parte el territorio en grupos de puestos parecidos *solo*, y predice una constante en cada uno; un bosque promedia cientos de árboles sobre remuestras *bootstrap*; el *boosting* ajusta árboles a los residuos. Sirven para las dos preguntas del caso, `voto_petro` y `gana_petro`.

Aplicación en R: los mismos puestos y las dos preguntas del caso: un árbol que se pueda leer, un bosque y un *boosting*, contra los mejores de hoy y de la semana 3, en la misma prueba.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Secs. 2.2.3, 4.1–4.5. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Cap. 4. [ESL]
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1–22. [`glmnet`]
- Murphy, A. H. (1973). A New Vector Partition of the Probability Score. *Journal of Applied Meteorology*, 12(4), 595–600. [apéndice]
- Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357. [apéndice]
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297. [apéndice]
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

6 Apéndice: para profundizar

A1. La verosimilitud de la logística: gradiente y Newton

1. La log-verosimilitud, usando $1 - p_i = 1/(1 + e^{x_i'\beta})$:

$$\ell(\beta) \;=\; \sum_{i=1}^{n} \Big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big] \;=\; \sum_{i=1}^{n} \Big[y_i \, x_i'\beta - \log\left(1 + e^{x_i'\beta}\right) \Big].$$

2. Gradiente y hessiano (con $\partial \log(1 + e^{x_i'\beta})/\partial\beta = x_i \, p_i$):

$$\frac{\partial \ell}{\partial \beta} \;=\; \sum_{i=1}^{n} x_i \big(y_i - p_i\big), \qquad \frac{\partial^2 \ell}{\partial \beta \, \partial \beta'} \;=\; -\sum_{i=1}^{n} p_i(1 - p_i) \, x_i x_i' \;\equiv\; -\mathbf{X}'\mathbf{W}\mathbf{X}.$$

3. Sin solución cerrada (p_i depende de β de forma no lineal). Newton–Raphson itera

$$\beta^{(t+1)} \;=\; \beta^{(t)} + (\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}\mathbf{X}'(\mathbf{y} - \mathbf{p}),$$

una regresión ponderada en cada paso (*IRLS*); el hessiano es negativo definido, así que ℓ es cóncava y el máximo es único si existe.

4. Lectura: con intercepto, $\sum_i \hat{p}_i = \sum_i y_i$. El "residuo por regresor" $x_i(y_i - p_i)$ es lo que el *boosting* logístico ajusta con árboles (sesión 5).

A2. Modelos generativos: LDA, QDA y Naive Bayes

La otra familia de ISL (sección 4.4): modelar x dentro de cada clase y voltear con Bayes

$$P(y = k \mid x) \;=\; \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)},$$

con $\pi_k = P(y = k)$ y f_k la densidad de x dentro de la clase k.

- **LDA:** $f_k = N(\mu_k, \Sigma)$ con la **misma** covarianza. El discriminante $\delta_k(x) = x'\Sigma^{-1}\mu_k - \frac{1}{2}\mu_k'\Sigma^{-1}\mu_k + \log \pi_k$ es **lineal en** x: frontera lineal, como la logística (ISL 4.5.1 muestra que los dos tienen log-odds lineales; difieren en cómo estiman).
- **QDA:** una covarianza por clase $\Rightarrow$ frontera cuadrática; $Kp(p+1)/2$ parámetros de covarianza: más flexible, más varianza.
- **Naive Bayes:** x independientes dentro de cada clase, $f_k(x) = \prod_j f_{kj}(x_j)$. Falso y útil cuando p es enorme y los datos escasos (el filtro de *spam*).

Por qué no están en el cuerpo

Con n grande y sin normalidad, la logística es más robusta: no pide suponer cómo se distribuyen las x.

A3. Más de dos clases, y conteos

Logística multinomial (ISL 4.3.5): con K clases, un $x'\beta_k$ por clase y una normalización que reparte la probabilidad,

$$P(y = k \mid x) \;=\; \frac{e^{x'\beta_k}}{\sum_{l=1}^{K} e^{x'\beta_l}} \qquad \text{(la } \textit{softmax}\text{)},$$

con una clase de referencia cuyo β se fija en cero. Ejemplo: ¿cuál de los tres más votados en la primera vuelta gana el puesto? La misma *softmax* es la última capa de una red neuronal (sesión 7).

- **Categorías ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica. Las métricas de hoy se extienden clase por clase ("una contra el resto").
- **Conteos** (delitos por cuadrante, siniestros): regresión de Poisson, $\log \mathbb{E}[y \mid x] = x'\beta$ (ISL 4.6). La misma lógica: una función de enlace que respeta el soporte de y.

A4. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\mathrm{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \tfrac{1}{2}\, \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

es el área bajo la ROC empírica; no depende del umbral ni de la prevalencia.

2. El Brier se descompone (Murphy, 1973). Con B grupos por $\hat{p}$, de tamaño n_b, predicción media $\bar{p}_b$ y frecuencia observada $\bar{y}_b$:

$$\underbrace{\tfrac{1}{n}\textstyle\sum_i (\hat{p}_i - y_i)^2}_{\text{Brier}} \approx \underbrace{\tfrac{1}{n}\textstyle\sum_b n_b (\bar{p}_b - \bar{y}_b)^2}_{\text{calibración}} - \underbrace{\tfrac{1}{n}\textstyle\sum_b n_b (\bar{y}_b - \bar{y})^2}_{\text{resolución}} + \underbrace{\bar{y}(1-\bar{y})}_{\text{incertidumbre}} .$$

- **Calibración:** la distancia a la diagonal de la figura de deciles del apéndice A7 (menor, mejor). **Resolución:** cuánto separan las probabilidades a los grupos (mayor, mejor).
- AUC alta y Brier malo es posible: buena resolución, mala calibración.

A5. Desbalance de clases: remuestrear o decidir mejor

Con 2 % de positivos (un fraude, un impago), la verosimilitud apenas nota a la clase rara. **Los remedios**, del más simple al más elaborado:

1. **Mover el umbral** con los costos: casi siempre basta si el modelo ordena bien y está calibrado.
2. **Pesos en la pérdida** (*class weights*): encarecer los errores de la clase rara, sin tocar los datos.
3. **Submuestrear** la clase mayoritaria o **sobremuestrear** la minoritaria; **SMOTE** (Chawla et al., 2002) crea positivos sintéticos entre vecinos, $x_{new} = x_i + u\,(x_{nn} - x_i)$, $u \sim U(0,1)$.

Dos advertencias no negociables

(i) Todo remuestreo ocurre **dentro de cada pliegue y sólo en el entrenamiento** (regla de oro #3). (ii) Remuestrear **distorsiona** $\hat{p}$: hay que recalibrar (apéndice A7) antes de usar un umbral de costos.

A6. Máquinas de soporte vectorial: la intuición del margen

Fuera del cuerpo del curso; para quien la necesite (ISL, cap. 9)

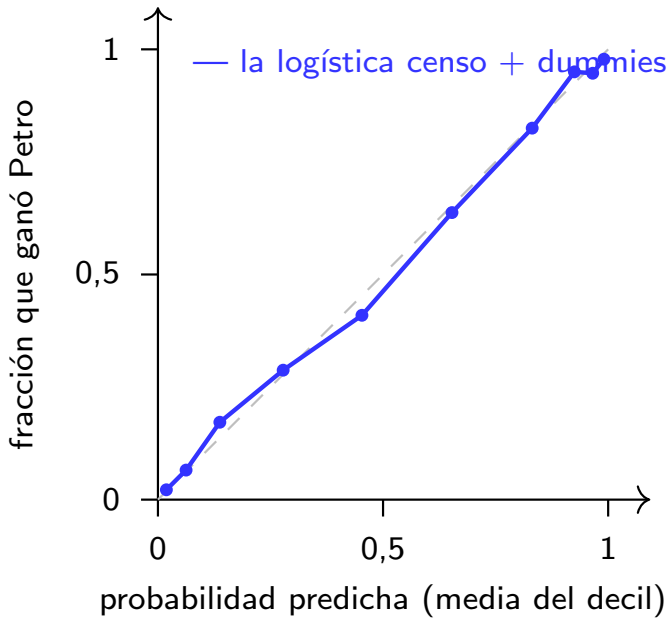
- Otra filosofía: buscar el hiperplano que separa las clases con el **margen más ancho**; sólo los puntos sobre el margen (los *vectores de soporte*) determinan la solución.
- **Margen blando** (C): permitir violaciones pagando un costo; es la perilla, elegida por CV.
- **Kernel:** reemplazar productos internos por $K(x, x')$ da fronteras no lineales sin construir el espacio.

Por qué no está en el cuerpo

Entrega puntajes, no probabilidades (hay que calibrarlos), escala mal con n grande y en la economía aplicada casi no aparece frente a la logística penalizada y los ensambles de árboles. Referencia: Cortes y Vapnik (1995).

A7. Calibración y Brier: ¿las $\hat{p}$ dicen la verdad?

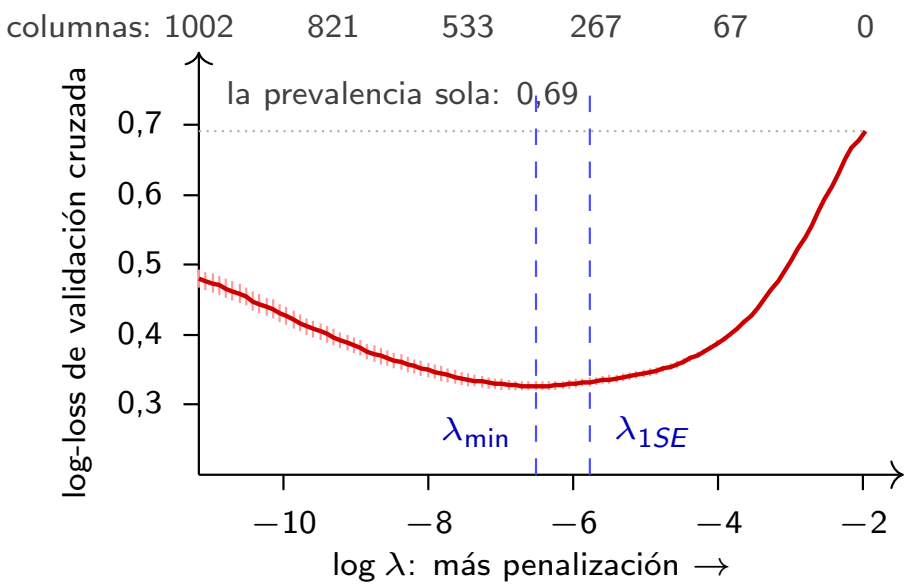
La prueba en deciles de $\hat{p}$: la probabilidad media contra la fracción que ganó Petro



- Sobre la diagonal, el modelo **dice la verdad**. El umbral τ^* usa $\hat{p}$ al pie de la letra: sin calibración, decide mal aunque la AUC sea alta.
- **El Brier** $= \frac{1}{n}\sum_i(\hat{p}_i - y_i)^2$ es el MSE de la semana 2 aplicado a probabilidades: la logística, 0,115; el LPM con Lasso, 0,113; decir la prevalencia en todos, 0,249.
- El LPM con Lasso ni llega entero a esta gráfica: 184 de sus $\hat{p}$ están fuera de $[0, 1]$. Ordenar no le cuesta; ser probabilidad, sí.

A8. El Lasso directamente sobre el Logit

Penalizar la log-verosimilitud, con los mismos 10 pliegues: sin selección en dos pasos



$$\hat{\beta}^{L} = \arg\min_{\beta} \; -\frac{1}{n}\,\ell(\beta) + \lambda \sum_{j} |\beta_j|$$

- **El juez mide la misma pérdida** que el modelo minimiza, ahora fuera de muestra: la log-loss de validación cruzada. El eje de arriba: cuántas columnas sobreviven a cada precio.
- **El protocolo de la semana 3:** $\lambda_{\min}$ para predecir — quedan 386 de las 1.291 columnas, log-loss de CV 0,327 contra 0,69 de la prevalencia sola; la regla de un error estándar deja 285 con casi la misma pérdida.
- AUC de 0,935 en CV y 0,937 en la prueba, sin la herencia de la selección en dos pasos.