

Big Data y Machine Learning para Economía Aplicada

Week 04: Clasificación — de la logística a las decisiones

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 18, 2026

Previously...

- **La prueba se abre una vez.** Modelos e hiperparámetros se eligen dentro del entrenamiento con la curva de CV: así salieron el k de los vecinos y el λ del Lasso.
- **Regla de oro #3:** el CV valida *pipelines*. El voto promedio del municipio, calculado con todos los puestos, prometía un RMSE de 11,3; en la prueba fue 13,0.
- **El k -fold aleatorio miente** cuando los vecinos se copian: los vecinos del mapa valen 12,3 al azar y 15,3 en municipios que el modelo no ha visto.
- **Ridge y Lasso:** con 1.253 columnas OLS explotó (118,3); el Lasso se quedó con 191 y dejó el error del país en 14,7. **El Lasso selecciona predictores, no causas.**

La tabla del líder, al cierre de la semana 3 (el país, 2.398 puestos de prueba)

Media 26,7 · ficha de 37 19,8 · ficha + departamentos 15,6 · **Lasso con la ficha larga 14,7** · k -NN en el mapa 12,1.

La pregunta de hoy: ¿gana Petro el puesto, y con qué probabilidad?

La misma elección, los mismos puestos, la misma ficha; cambia la y

- **Lo que tenemos:** un número. El líder predice el voto por Petro en cada puesto con un error típico de 14,7 puntos.
- **Lo que la campaña necesita:** una decisión. No le importa si saca 48 o 52; le importa **si gana el puesto**, para saber cuáles puede dar por seguros y en cuáles tiene que trabajar. Y un “54 más o menos 15” no le dice qué tan seguro es.
- **La y de hoy:** $\text{gana_petro} = 1$ si Petro sacó más votos que Hernández en el puesto. Pasó en el **53%** de los 12.000 puestos.

Cómo la respondemos

Un modelo que entregue una **probabilidad** (la logística, y dos contrastes con las herramientas de la semana 3) → de la probabilidad a la **decisión**: el umbral y el costo de cada error → las **métricas** que dicen si la decisión es buena → el mismo ejercicio en R, y la tabla del líder de clasificación.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

Qué cambia cuando y es una categoría

Ahora $y \in \{0, 1\}$: Petro gana el puesto o lo pierde. Queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$: es la media condicional de una variable binaria, así que todo lo de la sesión 1 sigue en pie.
- Una **decisión** $\hat{y}(x) \in \{0, 1\}$, que exige además un **umbral**: predecir 1 si $\hat{p}(x) \geq \tau$.

La pérdida natural es la 0–1 de la sesión 1, $L = \mathbb{I}\{y \neq \hat{y}\}$, cuyo promedio es la tasa de error. Pero dar por ganado un puesto que se pierde y trabajar uno que ya estaba ganado no cuestan lo mismo: de ahí sale la segunda mitad de la clase.

Las dos referencias de hoy (2.398 puestos de prueba):

- **La que no mira los datos**: “Petro gana en todos” acierta el 52,9%.
- **La regla vigente**, lo que haría la campaña sin modelo: “gana donde ganó en 2018”. En los 2.014 puestos que ya existían acierta el **84,3%**. Esa es la vara.

La misma estructura sirve para otras preguntas binarias de la economía aplicada: ¿el crédito entra en mora?, ¿el hogar es pobre?, ¿el estudiante deserta?

El atajo: clasificar con la regresión de la semana 3

Si el voto predicho es 50 o más, decir que gana

	Pred. pierde	Pred. gana
Pierde	931	199
Gana	198	1.070

Exactitud: **83,4%**


- La ficha con departamentos (RMSE 15,6) ya **clasifica bien**: acierta el 83,4% de los puestos de prueba, contra el 52,9% de no mirar los datos.
- Pero entrega **puntos de voto, no una probabilidad**. ¿Qué tan seguro es un 54? ¿Y un 70?
- Sin probabilidad no hay forma de ponerle precio a los errores: la campaña no puede decir “doy por seguro lo que pase de 83%”.
- Y tiró información a la inversa: para saber quién gana, un puesto de 51 y uno de 95 son el mismo dato.

Lo que falta

Un modelo para $P(\text{gana} \mid x)$. Hay un camino corto (OLS sobre la *dummy*) y uno correcto (una función que viva entre 0 y 1). Primero, por qué el corto no sirve.

Por qué no una recta: la curva está en los datos

El área metropolitana de la semana 2: 257 puestos, un predictor (ISL, sección 4.2)



- **Los triángulos son datos:** la fracción de puestos que ganó Petro por tramos de educación superior: todos hasta 20%; el 86% de 20 a 30; el 44% de 40 a 50.
- **La recta** (el *modelo de probabilidad lineal*, OLS sobre la *dummy*) es $1,10 - 0,012 \times \text{educación}$: en 112 de los 257 puestos predice una “probabilidad” mayor que 1.
- **La logística** sigue a los triángulos sin salirse de $[0, 1]$.

En el país, con la ficha y los departamentos, el LPM entrega valores fuera de $[0, 1]$ en 371 de los 2.398 puestos de prueba (de $-0,28$ a $1,36$).

Y , no β , otra vez

Para estimar un *efecto marginal promedio* el LPM es legítimo, y ustedes lo usan en Inferencia Causal. Hoy el objetivo es otro: **probabilidades con las que se pueda decidir.**

El clasificador de Bayes: el ideal y su error

Si conociéramos las probabilidades verdaderas, la regla que minimiza la tasa de error es asignar cada x a su clase **más probable**:

$$\hat{y}^{\text{Bayes}}(x) = \arg \max_k P(y = k \mid X = x) \quad (\text{binario: } 1 \text{ si } p(x) \geq 0,5).$$

- **Frontera de Bayes:** donde hay empate ($p(x) = 0,5$); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es positivo si las clases se *traslapan*: dos puestos con la misma ficha, uno que Petro gana con el 51% y otro que pierde con el 49%. Es el σ^2 irreducible de la sesión 1: el piso que ningún método perfora.
- Nadie conoce $P(y \mid x)$: **cada clasificador es una manera distinta de estimarla.**

Consecuencia para la evaluación

275 puestos de prueba se definieron por menos de cinco puntos: ahí nuestro mejor modelo lineal acierta el 58%; con margen de más de 30, el 97%. La pregunta útil no es “¿acierta mucho?” sino “¿cuánto mejor que la referencia, y dónde falla?”.


- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

Regresión logística: el modelo

Una recta para los *log-odds*, una curva en S para la probabilidad

Modelar la probabilidad con una función que **vive en** $[0, 1]$:

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$



- El índice es lineal $\Rightarrow$ la frontera $p(x) = 0,5 \iff x'\beta = 0$ es un **hiperplano**. En el área metropolitana, $6,09 - 0,136 \times \text{educación} = 0$ en **44,8%** de educación superior: por debajo, el modelo dice que gana Petro.
- **Parámetros:** β . **Hiperparámetros:** ninguno; la flexibilidad viene de interacciones y polinomios (sesión 3) o de una penalización (en unos minutos).

Cómo se ajusta: máxima verosimilitud en una línea

Los β que hacen **más probable lo observado**: p_i alta en los puestos que ganó, baja en los que perdió ($p_i \equiv p(x_i)$):

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta), \quad \ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

- No hay solución cerrada: ℓ es cóncava y `glm()` la maximiza por Newton–Raphson. El gradiente, $\sum_i x_i(y_i - p_i)$, reaparece en el *boosting* de la sesión 5 (apéndice A1).
- $-\ell(\beta)/n$ es la **log-loss**: la pérdida que la logística minimiza es también una métrica.
- **Separación perfecta**: una variable que separa las clases sin error manda $\hat{\beta} \rightarrow \infty$, y `glm()` avisa (estuvimos cerca: Petro ganó el 3% de los puestos de Casanare y el 97% de los de Putumayo). Suele ser *leakage* o falta de regularización.

Lo que hay que retener

La logística es el OLS de las probabilidades: lineal en el índice, sin perillas, estable y razonablemente calibrada. Es la **referencia de clasificación** del curso.

Cómo leer la logística (y qué no leer en ella)

- e^{β_j} es el **odds ratio**: cuánto se multiplican las chances $p/(1-p)$ por una unidad más de x_j . En el área metropolitana, cada punto más de educación superior multiplica por 0,87 las chances de que Petro gane; diez puntos, por 0,26.
- El efecto sobre la **probabilidad** no es constante: $\partial p / \partial x_j = \beta_j p(1-p)$. El mismo punto de educación quita 0,1 puntos de probabilidad donde $\hat{p} = 0,99$ y 3,4 donde $\hat{p} = 0,49$: mueve a los dudosos, no a los seguros.
- Para **predecir** importa $\hat{p}(x)$ completo, no un coeficiente: variables “no significativas” pueden mejorar la AUC de prueba, y significativas no mover nada.

Significativo no es predictivo, versión clasificación

En el país, el logit con las nueve variables de la semana 2 tiene ocho coeficientes con $p < 0,01$ y acierta el 68,5% de los puestos; “gana donde ganó en 2018”, sin un solo coeficiente, el 84,3%. Los coeficientes dicen *qué usa* el modelo; la prueba, *cuánto sabe*.

Hoy leemos $\hat{\beta}$ para entender qué hace el modelo, no para estimar efectos; abrir modelos sin coeficientes es la sesión 6. Más de dos clases y conteos: apéndice A4.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

La logística penalizada: la sesión 3 con otra pérdida

`glmnet` con familia binomial (ISL, sección 4.7.6)

La misma idea de Ridge y Lasso, con la log-verosimilitud en el lugar del RSS:

$$\hat{\beta}^L = \arg \min_{\beta} -\frac{1}{n} \ell(\beta) + \lambda \sum_{j=1}^p |\beta_j| \quad (\beta_j^2 \text{ para Ridge; } \alpha \text{ para Elastic Net}).$$

- **Cuándo hace falta:** muchos predictores para pocos eventos (la regla del pulgar pide unos diez casos de la clase menos frecuente por parámetro); la receta con interacciones; separación perfecta.
- **λ por CV, como siempre,** pero la métrica de cada pliegue es de clasificación (AUC o log-loss), con pliegues estratificados; `glmnet` estandariza dentro del pliegue.
- **Con los puestos:** la ficha larga de la semana 3 son 1.253 columnas; en Vaupés hay 20 puestos de entrenamiento para 38 coeficientes, la receta de la separación. El Lasso logístico se queda con **417**: AUC de 0,935 en CV y **0,937** en la prueba, contra 0,916 de la ficha con departamentos.


Lo que hay que ver

La sesión 3 no cambia de sesión: la curva de CV, la regla 1-SE y el camino de coeficientes son idénticos; sólo cambió la pérdida. Y otra vez la penalización deja usar una especificación que sin ella no se podría estimar.

k -NN como clasificador: votar entre vecinos

Para clasificar el puesto x_0 , mirar sus k vecinos más cercanos y **votar**:

$$\hat{p}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i, \quad \hat{y}(x_0) = \mathbb{I}\{\hat{p}(x_0) \geq \tau\}.$$



- Es el k -NN de las semanas 2 y 3 con y binaria: la fracción de vecinos donde ganó Petro (en el script es *la misma función*).
- k : $k = 1$ memoriza; $k = n$ predice la prevalencia. Se elige por CV con la AUC.
- Sin fórmula y sin supuestos: la frontera la dibujan los datos. Con más variables hay que **estandarizar** (dentro del pliegue) y aparece la **maldición de la dimensionalidad**. Su papel hoy: el contraste con la logística (hiperplano vs. ninguna forma).
- **Con los puestos, en el mapa**: la AUC de CV es 0,857 con $k = 1$, **0,947** con $k = 10$ y 0,924 con $k = 100$. En la prueba, 0,945: otra vez los vecinos ganan sin usar el censo.

¿Cuál usar? La comparación de ISL (sección 4.5), con el kit del curso

Método	Frontera	Perillas	Gana cuando...
Logística	lineal	ninguna	n grande; frontera casi lineal
Logística penalizada	lineal	λ (α)	p grande o pocos eventos; con la receta
k -NN	cualquiera	k	p pequeño; frontera irregular
Árboles y bosques (sesión 5)	cualquiera	varias	tabulares con interacciones
Generativos (apéndice)	lineal o no	ninguna	n pequeño; texto con p enorme

- ISL lo muestra con seis escenarios simulados: **ningún método domina**. Con los puestos, la logística con la ficha y los departamentos llega a una AUC de 0,916; penalizar la ficha larga añade 0,02 y los vecinos del mapa, 0,03. La referencia queda cerca de los flexibles.
- Los modelos generativos de ISL 4.4 (LDA, QDA, Naive Bayes) estiman cómo se distribuye x en cada clase y voltean con Bayes; no los usaremos en el caso. Están en el apéndice, con sus fórmulas.

La regla del curso

La logística es la *referencia* de clasificación, como OLS lo es de regresión; las métricas que siguen valen para cualquier modelo que entregue una probabilidad.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

La exactitud engaña

Otra elección, los mismos puestos: en la segunda vuelta de 2010 Santos ganó el 87,6 % de los puestos de prueba

Un modelo que no mira los datos y dice “Santos gana en todos” acierta en el 87,6% de los puestos. Una logística con el censo y los departamentos, en el 89,8%. **Pregunta para la sala:** ¿cuánto mejor es el modelo que la regla trivial? ¿Y qué *no* nos dice el 89,8%?

La exactitud engaña

Otra elección, los mismos puestos: en la segunda vuelta de 2010 Santos ganó el 87,6 % de los puestos de prueba

Un modelo que no mira los datos y dice “Santos gana en todos” acierta en el 87,6% de los puestos. Una logística con el censo y los departamentos, en el 89,8%. **Pregunta para la sala:** ¿cuánto mejor es el modelo que la regla trivial? ¿Y qué *no* nos dice el 89,8%? Baja el error del 12,4% al 10,2%: poco. Y esconde *en qué* se equivoca: como veremos en la matriz, encuentra sólo **uno de cada tres** puestos de Mockus. Con clases desbalanceadas, la exactitud premia ignorar a la minoritaria, que casi siempre es *la que importa*: el puesto que se pierde, el moroso, el hogar pobre.

- **Ya lo vimos hoy sin notarlo:** en el área metropolitana Petro ganó el 93% de los puestos: “gana en todos” acierta el 94% de la prueba y la logística, el 97%.
- El problema es de la **métrica**: pesa cada error igual y depende de la **prevalencia**, que el modelo no controla. En el país en 2022 las clases están parejas (53 y 47); casi nunca hay tanta suerte.
- Necesitamos vocabulario para los *tipos* de error, y luego precios para cada uno.

La matriz de confusión, con números reales

Segunda vuelta de 2010, Santos vs. Mockus: 1.812 puestos de prueba, logística con umbral 0,5

Real	Predicho +	Predicho -
	VP = 1.546	FN = 42
Real	FP = 142	VN = 82

Métrica	Fórmula	2010
Exactitud	$(VP + VN)/n$	0,898
<i>Recall</i> (sensibilidad), R	$VP/(VP + FN)$	0,974
Especificidad	$VN/(VN + FP)$	0,366
Precisión, P	$VP/(VP + FP)$	0,916
F1	$2PR/(P + R)$	0,944
<i>Balanced accuracy</i>	$(R + \text{espec.})/2$	0,670

+: Santos ganó el puesto (1.588 puestos, el 87,6%). -: lo ganó Mockus (224 puestos).

- **Recall:** de los puestos que ganó Santos, ¿qué fracción encontré?
Especificidad: de los que ganó Mockus, ¿cuántos reconocí? Aquí, **uno de cada tres**. **Precisión:** de mis “positivos”, ¿cuántos eran ciertos?
- Exactitud, precisión, *recall* y F1 lucen espléndidos; la especificidad y la *balanced accuracy* cuentan la otra mitad de la historia. Ninguna métrica sola lo hace.

Dos elecciones, dos prevalencias, las mismas métricas

Una logística con el censo y los departamentos en cada elección; puestos de prueba de cada una

	2010 (Santos–Mockus)	2022 (Petro–Hernández)
Prevalencia (clase positiva)	0,876	0,529
Exactitud	0,898	0,838
F1	0,944	0,846
<i>Balanced accuracy</i>	0,670	0,838
AUC	0,882	0,916

- Por exactitud y F1 el modelo de 2010 parece mucho mejor; por *balanced accuracy* y AUC es **peor**. Exactitud y F1 suben con la **dominancia** del ganador (88% de los puestos en 2010), no sólo con la habilidad del modelo; la *balanced accuracy* y la AUC no dependen de la prevalencia.
- Para comparar elecciones, regiones o años, la métrica cabecera **no puede depender de la prevalencia**: la tabla del líder de clasificación llevará la AUC.
- **Regla de reporte**: junto con la métrica cabecera, **siempre** la prevalencia y la matriz de confusión. Sin ellas, un 90% no significa nada.

El umbral es una decisión económica

La estadística estima p ; la economía pone los costos

El modelo entrega $\hat{p}(x)$; decidir exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.

¿Quién fija τ ? **Los costos.** Sean c_{FP} y c_{FN} los costos de cada error y p la probabilidad de un puesto.

1. **Costo esperado de predecir +:** $(1 - p) c_{FP}$ (me equivoco si era -)
2. **Costo esperado de predecir -:** $p c_{FN}$ (me equivoco si era +)
3. **Predecir + cuando** $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Sólo importa el **cociente** de costos. Errores igual de caros $\Rightarrow \tau^* = 0,5$ (la regla de Bayes).
- **La campaña** da por seguro un puesto si el modelo dice que gana, y no le manda recursos. Si confiarse y perder (FP) cuesta cinco veces más que trabajar un puesto que igual ganaba (FN) $\Rightarrow \tau^* = 5/6 \approx 0,83$: sólo se da por seguro lo *muy* seguro.
- El 0,5 por defecto de los paquetes es una decisión económica *implícita*, y casi nunca la correcta.

El mismo modelo, tres usuarios

La campaña de Petro decide qué puestos dar por seguros. Su error caro es el falso positivo (confiarse y perder) $\Rightarrow \tau^*$ **alto**: 0,83. Vigila la *precisión*: de los que dio por seguros, ¿cuántos ganó?

La campaña de Hernández usa las mismas probabilidades para decidir qué puestos dar por perdidos. Su error caro es el contrario: contar con un puesto que termina ganando Petro (para este modelo, un falso negativo) $\Rightarrow \tau^*$ **bajo**: con los mismos 5 a 1, $1/6 \approx 0,17$.

Un analista que sólo quiere medir cuánto del resultado es estructura del territorio no tiene costos asimétricos: 0,5 es su umbral natural y su métrica cabecera debe ser una que **no dependa del umbral**.


El mismo razonamiento fuera de las elecciones: al aprobar un crédito, prestarle a quien no paga cuesta el capital y negarle a quien sí paga, el margen; al focalizar un subsidio, excluir a un hogar pobre cuesta más que incluir a uno que no lo es.

El patrón general

Mismo modelo, distinta economía $\Rightarrow$ distinto umbral. Reportar “exactitud” sin discutir costos es esconder la decisión. Y elegir el punto exige ver *todos* los umbrales a la vez: la curva ROC.

La curva ROC: todos los umbrales a la vez


tasa de VP (recall)



Barriendo τ de 1 a 0 y graficando (tasa de FP, tasa de VP) en cada punto:

- Cada punto es un umbral; la curva es el **menú completo** de intercambios entre encontrar positivos y dar falsas alarmas. Los dos umbrales de hoy son dos puntos de la curva azul.
- **AUC:** 0,5 es el azar, 1 es perfecto. Lectura exacta: *la probabilidad de que un positivo al azar reciba mayor $\hat{p}$ que un negativo al azar.*
- **Con los puestos** (curvas de la prueba): dados un puesto que ganó Petro y uno que perdió, la ficha con departamentos ordena bien el par 92 de cada 100 veces, **sin fijar umbral.**
- **Ordenar no es decidir:** el voto de 2018 como puntaje tiene una AUC de 0,95, mejor que la ficha, pero con su corte natural de 50 puntos acierta el 84%: Petro creció y el corte quedó viejo (con 40 a 50 puntos en 2018 ganó el 64% de esos puestos en 2022).

Cuando los positivos son raros: precisión–recall




- **2010 otra vez, buscando los puestos de Mockus** (12% de la prueba): con umbral 0,5 el modelo levanta 124 alarmas, encuentra el 37% y acierta en el 66%.
- Para encontrar el 83% hay que bajar a 0,1: 542 alarmas, y sólo **una de cada tres** es cierta. La tasa de FP apenas pasó de 0,03 a 0,22: divide por los negativos, que son *muchísimos*, y la ROC casi no se entera.
- La curva **PR** no usa los VN: muestra cruda la calidad de las alarmas. Su “azar” es la prevalencia; el F1 es *un punto* de ella.

Regla práctica (Saito & Rehmsmeier, 2015)

Positivos raros (fraude, impago con 2%, deserción) $\Rightarrow$ reportar ROC y PR, y decir cuál es la prevalencia. Con clases balanceadas, como los puestos de 2022, la ROC basta.

Calibración: ¿ $\hat{p} = 0,8$ significa 80 %?



- Agrupen la prueba por deciles de $\hat{p}$ y comparen con la frecuencia observada de $y = 1$. Sobre la diagonal, el modelo **dice la verdad**. Los puntos son la ficha con departamentos: donde dijo 0,83, Petro ganó el 82,5%.
- Descalibrado $\Rightarrow$ el umbral τ^* sobre $\hat{p}$ decide mal aunque la AUC sea alta: ordenar bien no es cuantificar bien.
- La logística suele salir calibrada; k -NN con k pequeño, bosques y *boosting*, no siempre $\Rightarrow$ recalibrar (Platt o isotónica) en validación.
- **Métricas de probabilidad:** la **log-loss** (lo que la logística minimiza) y el **Brier** $= \frac{1}{n_t} \sum_i (\hat{p}_i - y_i)^2$, el MSE de las probabilidades, que se descompone en calibración y resolución (apéndice).
- Una figura barata: el histograma de $\hat{p}$ por clase observada; dos nubes separadas son un modelo que distingue.

Desbalance de clases: los remedios y sus advertencias

Con el 12% de puestos de Mockus la logística ya los ignoraba; con 2% de positivos (un fraude, un impago) la verosimilitud apenas nota a la clase minoritaria. **Los remedios**, del más simple al más elaborado:

- 1 **Pesos en la pérdida** (*class weights*): encarecer los errores en la clase rara. Sin tocar los datos; disponible en casi todo (glm, glmnet, ranger, xgboost).
- 2 **Submuestrear** la clase mayoritaria (rápido, pero tira datos) o **sobremuestrear** la minoritaria (duplica; invita al sobreajuste sobre copias).
- 3 **SMOTE** (Chawla et al., 2002): crear positivos *sintéticos* interpolando entre vecinos de la clase rara: $x_{new} = x_i + u(x_{nn} - x_i)$, $u \sim U(0, 1)$.

Dos advertencias no negociables

(i) Todo remuestreo ocurre **dentro de cada pliegue y sólo en el entrenamiento** (regla de oro #3): remuestrear antes de partir pone copias del mismo positivo a ambos lados. (ii) Remuestrear **distorsiona** $\hat{p}$, que queda inflada: recalibrar antes de usar umbrales de costos.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien y está calibrado, ¿hacía falta remuestrear?

- Muchas veces **no**: mover τ^* según los costos logra lo mismo, sin cirugía sobre los datos. En 2010, bajar el umbral de “gana Mockus” de 0,5 a 0,2 sube del 37% al 75% los puestos suyos que se encuentran.
- Pesos y SMOTE ayudan cuando la clase rara es *tan* rara que el modelo ni aprende su estructura.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *ordena* bien y está calibrado, ¿hacía falta remuestrear?

- Muchas veces **no**: mover τ^* según los costos logra lo mismo, sin cirugía sobre los datos. En 2010, bajar el umbral de “gana Mockus” de 0,5 a 0,2 sube del 37% al 75% los puestos suyos que se encuentran.
- Pesos y SMOTE ayudan cuando la clase rara es *tan* rara que el modelo ni aprende su estructura.

El flujo del practicante:

- 1 Partición y CV **estratificadas**.
- 2 Entrenar normal; evaluar con ROC y PR.
- 3 Calibrar; decidir con τ^* de costos.
- 4 ¿Aún mal? Pesos de clase; SMOTE como último recurso.

Para la aplicación

Los puestos de 2022 están balanceados (53 y 47): llegamos al paso 3, con los costos de la campaña. Los de 2010 muestran qué les pasa a la exactitud y al F1 cuando una clase domina.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

Aplicación guiada (I): ocho filas, la misma prueba

9.602 puestos para aprender, 2.398 bajo llave, la ficha de la semana 3
(applications/week-04)

Modelo (umbral 0,5)	AUC	Exactitud	Sensibilidad	Especificidad
“Petro gana en todos”	0,500	0,529	1,000	0,000
Logística, educación superior	0,526	0,529	1,000	0,000
Logística, las nueve variables	0,763	0,685	0,715	0,650
Logística, la ficha de 37	0,851	0,776	0,789	0,762
Regresión de la semana 3 ($\widehat{\text{voto}} \geq 50$)	0,912	0,834	0,844	0,824
Logística, ficha + departamentos	0,916	0,838	0,841	0,834
Logística penalizada, ficha larga (417 col.)	0,937	0,863	0,867	0,859
k-NN en el mapa ($k = 10$ por CV)	0,945	0,880	0,897	0,861

- **La educación superior sola no viaja:** la estrella de Cali tiene en el país un coeficiente de 0,003 ($p = 0,14$) y predice “gana” en todos. Es la semana 2, en versión clasificación.
- **Cada escalón de la semana 3 vuelve a pagar:** la ficha, los departamentos y la ficha larga penalizada (λ por CV con la AUC). **Los vecinos del mapa** lideran otra vez sin usar el censo: siguen las dos ligas.
- **La vara**, en los 2.014 puestos con historia: “gana donde ganó en 2018” acierta el 84,3%; la ficha con departamentos, 84,1%; la penalizada, 86,5%; los vecinos, 89,0%.

Aplicación guiada (II): el umbral con costos

Dar por seguro un puesto que se pierde cuesta 5; trabajar uno que igual se ganaba, 1:

$$\tau^* = 5/6 = 0,83$$

Umbral 0,5

	Pred. gana	Pred. pierde
Gana (1.268)	VP = 1.067	FN = 201
Pierde (1.130)	FP = 188	VN = 942

$$\text{Costo: } 188 \times 5 + 201 \times 1 = \mathbf{1.141}$$

Umbral $\tau^* = 0,83$

	Pred. gana	Pred. pierde
Gana (1.268)	VP = 798	FN = 470
Pierde (1.130)	FP = 45	VN = 1.085

$$\text{Costo: } 45 \times 5 + 470 \times 1 = \mathbf{695}$$

- **La misma logística (ficha + departamentos), las mismas probabilidades.** Sólo cambió el umbral: la precisión pasa de 0,85 a 0,95 y la sensibilidad de 0,84 a 0,63. Se trabajan 269 puestos más que igual se ganaban para no regalar 143.
- **Sin modelo**, trabajar todos los puestos cuesta 1.268 y darlos todos por seguros, 5.650. Con 0,5 el modelo casi no ayuda (1.141); con τ^* , 695: casi la mitad. El mínimo de la curva de costo (en el script) cae donde dijo la fórmula.

Aplicación guiada (II): el umbral con costos

Dar por seguro un puesto que se pierde cuesta 5; trabajar uno que igual se ganaba, 1:

$$\tau^* = 5/6 = 0,83$$

Umbral 0,5

	Pred. gana	Pred. pierde
Gana (1.268)	VP = 1.067	FN = 201
Pierde (1.130)	FP = 188	VN = 942

$$\text{Costo: } 188 \times 5 + 201 \times 1 = \mathbf{1.141}$$

Umbral $\tau^* = 0,83$

	Pred. gana	Pred. pierde
Gana (1.268)	VP = 798	FN = 470
Pierde (1.130)	FP = 45	VN = 1.085

$$\text{Costo: } 45 \times 5 + 470 \times 1 = \mathbf{695}$$

- **La misma logística (ficha + departamentos), las mismas probabilidades.** Sólo cambió el umbral: la precisión pasa de 0,85 a 0,95 y la sensibilidad de 0,84 a 0,63. Se trabajan 269 puestos más que igual se ganaban para no regalar 143.
- **Sin modelo**, trabajar todos los puestos cuesta 1.268 y darlos todos por seguros, 5.650. Con 0,5 el modelo casi no ayuda (1.141); con τ^* , 695: casi la mitad. El mínimo de la curva de costo (en el script) cae donde dijo la fórmula.

Lo que hay que ver

La exactitud con τ^* es 78,5%, peor que con 0,5 (83,8%), y sin embargo es la decisión correcta. Y mejores probabilidades valen plata: con el mismo τ^* , la penalizada cuesta 645 y los vecinos, 585.

Aplicación guiada (III): calibración, y dónde falla

Decil de $\hat{p}$	1	2	3	4	5	6	7	8	9	10
Logística: $\hat{p}$ media	0,02	0,06	0,14	0,28	0,45	0,65	0,83	0,93	0,96	0,99
Logística: frecuencia observada	0,02	0,07	0,17	0,29	0,41	0,64	0,83	0,95	0,95	0,98
k -NN: $\hat{p}$ media	0,00	0,00	0,07	0,22	0,44	0,70	0,88	1,00	1,00	1,00
k -NN: frecuencia observada	0,01	0,02	0,08	0,23	0,45	0,70	0,87	0,97	0,99	0,97

- **La logística dice la verdad:** predichas y observadas van juntas de 0,02 a 0,98; por eso el umbral de costos funcionó. La penalizada, igual.
- **k -NN exagera en las puntas:** cuando los diez vecinos coinciden dice 0 o 1 exactos, y se equivoca entre el 1 y el 3% de las veces. Para la exactitud no importa; para la log-loss, un solo error con $\hat{p} = 0$ vale infinito (el script recorta las probabilidades antes de calcularla).
- **Dónde falla** (penalizada, umbral 0,5): acierta el 58% de los 275 puestos que se definieron por menos de 5 puntos, el 75% entre 5 y 10, el 84% entre 10 y 20 y el 97% por encima de 30. El error vive en los puestos reñidos: es el error de Bayes de hace una hora. Entre cabeceras (87,0%) y zona rural (85,8%) casi no hay diferencia.

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1**
- 7 Cierre

El Problem Set 1 se publica hoy

Otro problema, las mismas herramientas: el precio de la vivienda en Cali. Entrega: martes 20 de octubre, 8:00

Una sola base: avisos de venta de apartamentos y casas en Cali, con diccionario y partición fija. El precio de los avisos de prueba está oculto.

Parte	Sesión	Pts	Qué hacen
1. Referencia y regresión	2	15	la media y OLS con los atributos del aviso; RMSE, MAE y R^2 ; predicho vs. observado
2. Validación y regularización	3	25	CV al azar vs. por zonas del mapa; variables construidas en el pliegue; Ridge, Lasso y EN; quién sobrevive
3. Clasificación	4	15	¿es vivienda de interés social?: referencia, logística y penalizada; AUC; umbral con costos; calibración
4. Modelo final	2-4	15	menor RMSE de validación → reajuste → predicciones para la prueba, una sola vez
Ranking del curso		20	por el RMSE de prueba del modelo final; primero 20, último 10
Reproducibilidad		10	00_run.R corre de principio a fin

En clase hicimos las tres partes con los puestos; los scripts de las sesiones 2 a 4 son el punto de partida. **Debrief** con el ranking en la sesión 7 (27 de octubre).

- 1 Cuando y es una categoría
- 2 La regresión logística
- 3 Dos contrastes con las herramientas de la sesión 3
- 4 De la probabilidad a la decisión: las métricas que deciden
- 5 Aplicación guiada en R: ¿qué puestos da por seguros la campaña?
- 6 El Problem Set 1
- 7 Cierre

Qué dice el modelo y qué no dice

Lo que sí dice. Con una AUC de 0,92 a 0,94, el censo del entorno y el departamento *ordenan* los puestos: entre uno que ganó Petro y uno que perdió, ponen más probabilidad en el primero 92 de cada 100 veces. Los $\hat{\beta}$ dicen **qué usa** el modelo: más jóvenes, más mujeres y más población afro, a favor; más mayores de 60, más estrato alto y puestos más grandes, en contra.

Lo que no dice.

- **No es causal, ni habla de personas:** son puestos, no votantes. Que Petro gane los puestos con más población afro no dice cómo votó cada persona (la falacia ecológica), ni que cambiar un barrio cambie su voto.
- **No es una decisión:** la probabilidad es la mitad; sin los costos, el 0,5 de los paquetes decide por ustedes.
- **No es un pronóstico:** aprendimos con puestos de la *misma* elección. Sirve para completar el mapa, no para anticipar la siguiente: el corte de 2018 ya era viejo en 2022.

Qué dice el modelo y qué no dice

Lo que sí dice. Con una AUC de 0,92 a 0,94, el censo del entorno y el departamento *ordenan* los puestos: entre uno que ganó Petro y uno que perdió, ponen más probabilidad en el primero 92 de cada 100 veces. Los $\hat{\beta}$ dicen **qué usa** el modelo: más jóvenes, más mujeres y más población afro, a favor; más mayores de 60, más estrato alto y puestos más grandes, en contra.

Lo que no dice.

- **No es causal, ni habla de personas:** son puestos, no votantes. Que Petro gane los puestos con más población afro no dice cómo votó cada persona (la falacia ecológica), ni que cambiar un barrio cambie su voto.
- **No es una decisión:** la probabilidad es la mitad; sin los costos, el 0,5 de los paquetes decide por ustedes.
- **No es un pronóstico:** aprendimos con puestos de la *misma* elección. Sirve para completar el mapa, no para anticipar la siguiente: el corte de 2018 ya era viejo en 2022.

La métrica es parte de la interpretación

Un F1 de 0,94 en 2010 habla de la *dominancia* de Santos; una AUC de 0,92 con clases parejas en 2022, de un territorio que se deja ordenar; y una exactitud del 94% en Cali no habla de nada: es la prevalencia.

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Logística	siempre, como referencia	separación perfecta; curvaturas que no escribimos
Logística penalizada	p grande, pocos eventos, la receta con interacciones	λ por CV con métrica de clasificación; coeficientes encogidos
k -NN	p pequeño y frontera irregular	la escala de las x ; alta dimensión; $\hat{p}$ de 0 y 1 exactos
Exactitud	clases balanceadas y costos simétricos	prevalencia desigual: reportar <i>balanced accuracy</i>
AUC / ROC	comparar modelos y contextos sin umbral	no elige el umbral; optimista con positivos muy raros
Precisión– <i>recall</i> , F1	positivos raros; alarmas costosas	dependen del umbral y de la prevalencia
Umbral de costos	siempre que los errores cuesten distinto	exige probabilidades calibradas
Calibración	antes de cualquier umbral por costos	remuestreo, k -NN y ensambles descalibran

Qué leer: ISL cap. 4 (secs. 4.1–4.3 y 4.4.2, con el ejemplo *Default*); Fawcett (2006) para la ROC; Saito & Rehmsmeier (2015) para la curva de precisión–*recall*.

Recap

- 1 **Clasificar es estimar $P(y | x)$ y luego decidir.** El ideal es el clasificador de Bayes; su error (los puestos reñidos) es el σ^2 de la clasificación. La **logística** (índice lineal, verosimilitud, sin perillas) es la referencia; la **penalizada** y **k-NN** son la sesión 3 y la sesión 2 con otra y .
- 2 **La exactitud engaña** cuando la prevalencia es desigual: 88% en 2010 y 94% en Cali eran no hacer nada. La matriz de confusión da el vocabulario: *recall*, especificidad, precisión, F1, *balanced accuracy*. Siempre con la prevalencia al lado.
- 3 **El umbral es economía:** $\tau^* = c_{FP} / (c_{FP} + c_{FN})$. Con $c_{FP} = 5 c_{FN}$, el 0,83 bajó el costo de la campaña de 1.141 a 695 con el mismo modelo. Sin costos asimétricos, 0,5 y una métrica que no dependa del umbral.
- 4 **ROC y AUC** comparan modelos y contextos sin umbral (y ordenar no es decidir: la regla de 2018); la **PR** es más honesta con positivos raros; nada funciona sin **calibración**.
- 5 **Desbalance:** estratificar, ordenar bien y calibrar antes que remuestrear; si se remuestrea, dentro del pliegue y recalibrando.

La tabla del líder: clasificación

gana_petro, los mismos 2.398 puestos de prueba de la semana 3

Sem.	Modelo	Ubicación	AUC	Exactitud
4	"Petro gana en todos"	no	0,500	52,9%
4	Logística, las nueve variables	no	0,763	68,5%
4	Logística, la ficha de 37	no	0,851	77,6%
4	Regresión de la semana 3 (50 o más)	departamento	0,912	83,4%
4	Logística, ficha + departamentos	departamento	0,916	83,8%
4	Logística penalizada, ficha larga	departamento	0,937	86,3%
4	k -NN en el mapa ($k = 10$)	sólo la ubicación	0,945	88,0%

- Las mismas dos ligas: en la de la **estructura** lidera la logística penalizada; en la de la **ubicación**, los vecinos. Y una vara que no es un modelo: la historia electoral (AUC de 0,95 donde existe).
- **La limitación que nos lleva a la sesión 5:** todos los modelos de estructura de hoy son lineales en el índice. Para que la educación pesara distinto en el Pacífico y en Santander escribimos 1.253 columnas a mano, y decidimos *nosotros* que la interacción era con el departamento. ¿Y si las particiones que importan son otras? La semana 5 trae un método que las busca solo; se lleva de equipaje los dos líderes: 14,7 y 0,937.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, cap. 8 (árboles, *bagging*, bosques aleatorios y *boosting*).
Guía: las figuras 8.1 a 8.3 (cómo un árbol parte el espacio) y la 8.8 (bosques vs. *bagging*) son las de clase; la sección 8.2.3 es el *boosting*.

Problem Set 1: publicado hoy; entrega el martes 20 de octubre a las 8:00, antes de la sesión 6. Los scripts de las sesiones 2 a 4 son el punto de partida.

Próxima sesión — árboles, bosques y boosting: dejamos los modelos lineales. Un árbol parte el territorio en grupos de puestos parecidos y predice una constante en cada uno (cómo elige cada corte, y la poda por CV); un bosque promedia cientos de árboles sobre remuestras *bootstrap* (el 63% de la sesión 3, el error *out-of-bag*, el *mtry*); el *boosting* ajusta árboles a los residuos, con parada temprana. Son los métodos que suelen ganar con datos tabulares.

Aplicación en R: los mismos puestos y las dos preguntas del caso, `voto_petro` y `gana_petro`: un árbol que se pueda leer, un bosque y un *boosting*, contra los dos líderes de hoy, en la misma prueba.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 4. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Cap. 4. [ESL]
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.
- Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1). [glmnet]
- Murphy, A. H. (1973). A New Vector Partition of the Probability Score. *Journal of Applied Meteorology*, 12(4), 595–600. [apéndice]
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297. [apéndice]
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

8 Apéndice: para profundizar

A1. La verosimilitud de la logística: gradiente y Newton–Raphson

1. La log-verosimilitud de n observaciones independientes, usando $1 - p_i = 1/(1 + e^{x_i'\beta})$:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right].$$

2. Gradiente y hessiano (con $\partial \log(1 + e^{x_i' \beta}) / \partial \beta = x_i p_i$):


$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i), \quad \frac{\partial^2 \ell}{\partial \beta \partial \beta'} = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i' \equiv -\mathbf{X}' \mathbf{W} \mathbf{X}.$$

3. Igualar a cero no tiene solución cerrada (p_i depende de β de forma no lineal). Newton–Raphson itera

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' (\mathbf{y} - \mathbf{p}),$$

una regresión ponderada en cada paso (*IRLS*; `glm()` converge en pocas iteraciones). **4. Lectura:** con intercepto, las condiciones de primer orden implican $\sum_i \hat{p}_i = \sum_i y_i$: la logística está calibrada *en promedio*. Y el “residuo por regresor” $x_i(y_i - p_i)$ es lo que el *boosting* logístico ajusta con árboles (sesión 5).

A2. Modelos generativos: LDA, QDA y Naive Bayes



La logística modela $P(y | x)$ directamente.
La alternativa *generativa*: modelar cómo se distribuye x en cada clase, $f_k(x)$, y las proporciones π_k , y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x).$$

- **LDA:** f_k normal con la **misma covarianza** en todas las clases $\Rightarrow$ frontera lineal, como la logística; gana con n pequeño y clases bien separadas. **QDA:** una covarianza por clase $\Rightarrow$ frontera cuadrática: más flexible, más parámetros.
- **Naive Bayes:** supone las x **independientes dentro de cada clase**, $f_k(x) = \prod_j f_{kj}(x_j)$. Es falso y aun así funciona cuando p es enorme y los datos escasos: el filtro de spam.

Mapa mental

Más supuestos = más eficiencia *si* aguantan; con n grande y sin normalidad, la logística es más robusta. Fórmulas en la siguiente diapositiva.

A3. LDA, QDA y Naive Bayes: las fórmulas

1. **Bayes:** $P(y = k | x) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}$; se clasifica en la clase que maximiza $\pi_k f_k(x)$.

2. **LDA:** $f_k = N(\mu_k, \Sigma)$ con Σ común. Tomando logaritmos y descartando lo que no depende de k :

$$\delta_k(x) = x' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log \pi_k,$$

lineal en x : la frontera entre dos clases, $\delta_k(x) = \delta_l(x)$, es un hiperplano. Se estima con $\hat{\pi}_k = n_k/n$, las medias por clase $\hat{\mu}_k$ y la covarianza agrupada $\hat{\Sigma}$.

3. **QDA:** $f_k = N(\mu_k, \Sigma_k)$; sobrevive el término cuadrático $-\frac{1}{2}(x - \mu_k)' \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k|$. Con p predictores hay que estimar $K p(p+1)/2$ parámetros de covarianza: mucha varianza si n es pequeño. Es la curva U entre LDA y QDA.

4. **Naive Bayes:** $f_k(x) = \prod_{j=1}^p f_{kj}(x_j)$; cada f_{kj} se estima por separado (normal, histograma o, para x_j discreta, frecuencias). Con miles de palabras como predictores y pocos correos, es el único de los tres que se puede estimar.

A4. Más de dos clases (y una nota sobre conteos)

Logística multinomial (ISL 4.3.5): con K clases, un índice lineal por clase y una normalización que reparte la probabilidad:

$$P(y = k \mid x) = \frac{e^{x' \beta_k}}{\sum_{l=1}^K e^{x' \beta_l}} \quad (\text{la función } \textit{softmax}),$$

con una clase de referencia cuyo β se fija en cero; los demás se leen *relativos* a ella. Ejemplo: ¿cuál de los tres candidatos más votados de la primera vuelta gana el puesto? La misma *softmax* es la última capa de una red neuronal (sesión 7).


- Categorías **ordenadas** (estrato, nivel educativo): logit ordenado, o tratar la escala como numérica y volver a la sesión 2. Las métricas de la sesión se extienden clase por clase (“una contra el resto”).
- **Conteos** (delitos por cuadrante, siniestros): regresión de Poisson, $\log \mathbb{E}[y \mid x] = x' \beta$, otro GLM (ISL 4.6). Misma lógica: una función de enlace que respeta el soporte de y .

Por qué el cuerpo se queda en el caso binario

Es donde viven las decisiones (aprobar, focalizar, alertar) y donde las métricas tienen más que enseñar.

A5. Máquinas de soporte vectorial: la intuición del margen

Fuera del cuerpo del curso; conservada para quien la necesite (ISL, cap. 9)



- Otra filosofía: buscar el hiperplano que separa las clases con el **margen más ancho**; sólo los puntos sobre el margen (los *vectores de soporte*, circulados) determinan la solución.
- **Soft margin** (C): permitir violaciones pagando un costo; es la perilla de regularización, elegida por CV.
- **Kernel trick**: productos internos $\rightarrow K(x, x')$: fronteras no lineales sin construir el espacio.

Por qué no está en el cuerpo

Entrega *scores*, no probabilidades (hay que calibrar con Platt); escala mal con n grande; y en la literatura aplicada en economía casi no aparece frente a la logística penalizada y los ensambles de árboles. Referencia: Cortes & Vapnik (1995).

A6. La AUC como probabilidad y la descomposición del Brier

1. AUC = probabilidad de ordenar bien un par. Con n_+ positivos y n_- negativos, el estadístico de Mann–Whitney

$$\widehat{\text{AUC}} = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} \left[\mathbb{I}\{\hat{p}_i > \hat{p}_j\} + \frac{1}{2} \mathbb{I}\{\hat{p}_i = \hat{p}_j\} \right]$$

coincide con el área bajo la ROC empírica (la función `auc()` del script); no depende del umbral ni de la prevalencia.

2. El Brier se descompone (Murphy, 1973). Con B grupos por $\hat{p}$, de tamaño n_b , predicción media $\bar{p}_b$ y frecuencia observada $\bar{y}_b$:

$$\underbrace{\frac{1}{n} \sum_i (\hat{p}_i - y_i)^2}_{\text{Brier}} \approx \underbrace{\frac{1}{n} \sum_b n_b (\bar{p}_b - \bar{y}_b)^2}_{\text{calibración (menor, mejor)}} - \underbrace{\frac{1}{n} \sum_b n_b (\bar{y}_b - \bar{y})^2}_{\text{resolución (mayor, mejor)}} + \underbrace{\bar{y}(1 - \bar{y})}_{\text{incertidumbre}}.$$

- **Calibración:** distancia a la diagonal de la curva de confiabilidad.
Resolución: cuánto separan las probabilidades a los grupos.
Incetidumbre: el Brier del predictor constante $\bar{y}$.
- AUC alta y Brier malo es posible: buena resolución, mala calibración.