

Big Data y Machine Learning para Economía Aplicada

Week 04: Remuestreo, validación y el *pipeline* honesto

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 9, 2026

Previously...

- **Clasificar es estimar $P(y \mid x)$ y luego decidir.** La logística es el baseline; k -NN, LDA y Naive Bayes son las alternativas.

Previously...

- **Clasificar es estimar $P(y | x)$ y luego decidir.** La logística es el baseline; k -NN, LDA y Naive Bayes son las alternativas.
- **La exactitud engaña** con prevalencia desigual: matriz de confusión, *balanced accuracy*, AUC como cabecera; el umbral es una decisión con costos; nada funciona sin calibración.

Previously...

- **Clasificar es estimar $P(y | x)$ y luego decidir.** La logística es el baseline; k -NN, LDA y Naive Bayes son las alternativas.
- **La exactitud engaña** con prevalencia desigual: matriz de confusión, *balanced accuracy*, AUC como cabecera; el umbral es una decisión con costos; nada funciona sin calibración.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.

Previously...

- **Clasificar es estimar $P(y | x)$ y luego decidir.** La logística es el baseline; k -NN, LDA y Naive Bayes son las alternativas.
- **La exactitud engaña** con prevalencia desigual: matriz de confusión, *balanced accuracy*, AUC como cabecera; el umbral es una decisión con costos; nada funciona sin calibración.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- Dos veces dijimos “el k se elige con un pedazo del entrenamiento; la forma correcta llega en la sesión 4”. Llegó.

Previously...

- **Clasificar es estimar $P(y | x)$ y luego decidir.** La logística es el baseline; k -NN, LDA y Naive Bayes son las alternativas.
- **La exactitud engaña** con prevalencia desigual: matriz de confusión, *balanced accuracy*, AUC como cabecera; el umbral es una decisión con costos; nada funciona sin calibración.
- **Reglas de oro:** #1 el error de entrenamiento es optimista; #2 la prueba se usa al final y una sola vez.
- Dos veces dijimos “el k se elige con un pedazo del entrenamiento; la forma correcta llega en la sesión 4”. Llegó.

Hoy

Cómo estimar el error de generalización **sin gastar la prueba**: validación cruzada y *bootstrap*. Con eso se eligen los hiperparámetros, se ponen intervalos a las métricas y se comparan modelos. Y la disciplina que hace todo eso honesto: el **pipeline**, que se reutiliza de aquí al final del curso.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

Dos preguntas, un solo conjunto de prueba


Necesitamos el error fuera de muestra para dos cosas distintas:

- 1 **Elegir:** ¿qué k en k -NN? ¿cuántos nodos en el *spline*? ¿qué λ (sesión 5)? ¿qué profundidad (sesión 6)? Muchas comparaciones.
- 2 **Reportar:** cuánto se equivoca el modelo final en datos nuevos. Una sola cifra.

Dos preguntas, un solo conjunto de prueba

Necesitamos el error fuera de muestra para dos cosas distintas:


- 1 **Elegir:** ¿qué k en k -NN? ¿cuántos nodos en el *spline*? ¿qué λ (sesión 5)? ¿qué profundidad (sesión 6)? Muchas comparaciones.
- 2 **Reportar:** cuánto se equivoca el modelo final en datos nuevos. Una sola cifra.



Dos preguntas, un solo conjunto de prueba

Necesitamos el error fuera de muestra para dos cosas distintas:

- 1 **Elegir:** ¿qué k en k -NN? ¿cuántos nodos en el *spline*? ¿qué λ (sesión 5)? ¿qué profundidad (sesión 6)? Muchas comparaciones.
- 2 **Reportar:** cuánto se equivoca el modelo final en datos nuevos. Una sola cifra.



- La prueba solo puede responder la pregunta 2, y una sola vez (regla #2). Si la usáramos para elegir entre veinte configuraciones, dejaría de ser prueba: sería un segundo entrenamiento.
- La pregunta 1 se responde **dentro del entrenamiento**, remuestreándolo. De eso trata la primera mitad de hoy.

El punto de partida: el conjunto de validación

La receta de las sesiones 2 y 3: apartar una fracción del entrenamiento y evaluar ahí.



El punto de partida: el conjunto de validación

La receta de las sesiones 2 y 3: apartar una fracción del entrenamiento y evaluar ahí.



Funciona, pero tiene dos defectos (ISL, Fig. 5.2):

- 1 **Alta variabilidad:** el error estimado depende de *cuáles* observaciones cayeron en validación. Con otra partición aleatoria, otra curva y a veces otro ganador.
- 2 **Desperdicia datos:** el modelo se entrena con una parte de la muestra; con menos datos aprende peor $\Rightarrow$ tiende a **sobreestimar** el error del modelo entrenado con todo.

El punto de partida: el conjunto de validación

La receta de las sesiones 2 y 3: apartar una fracción del entrenamiento y evaluar ahí.



Funciona, pero tiene dos defectos (ISL, Fig. 5.2):

- 1 **Alta variabilidad:** el error estimado depende de *cuáles* observaciones cayeron en validación. Con otra partición aleatoria, otra curva y a veces otro ganador.
- 2 **Desperdicia datos:** el modelo se entrena con una parte de la muestra; con menos datos aprende peor $\Rightarrow$ tiende a **sobreestimar** el error del modelo entrenado con todo.

La idea de la validación cruzada

Reutilizar **todos** los datos del entrenamiento: que cada observación sea validación *alguna vez* y entrenamiento *el resto* de las veces.

Leave-one-out: el extremo

Dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2, \quad \hat{y}_{(-i)} : \text{predicción de } i \text{ sin usar } i.$$

Leave-one-out: el extremo

Dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2, \quad \hat{y}_{(-i)} : \text{predicción de } i \text{ sin usar } i.$$

- **A favor:** cada modelo usa $n - 1$ datos, así que casi no hay sesgo; y no hay azar: siempre da el mismo número.
- **En contra:** n ajustes (para OLS hay un atajo, en el apéndice; para bosques y redes, no). Y **varianza alta:** los n modelos comparten $n - 2$ observaciones, son casi idénticos, y promediar errores muy correlacionados reduce poco la varianza.

Leave-one-out: el extremo

Dejar **una sola** observación afuera, entrenar con las otras $n - 1$, predecirla; repetir para cada i :

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{(-i)})^2, \quad \hat{y}_{(-i)} : \text{predicción de } i \text{ sin usar } i.$$


- **A favor:** cada modelo usa $n - 1$ datos, así que casi no hay sesgo; y no hay azar: siempre da el mismo número.
- **En contra:** n ajustes (para OLS hay un atajo, en el apéndice; para bosques y redes, no). Y **varianza alta:** los n modelos comparten $n - 2$ observaciones, son casi idénticos, y promediar errores muy correlacionados reduce poco la varianza.

La lección del promedio correlacionado

Promediar n cosas solo ayuda si son *distintas* entre sí. Vuelve en la sesión 6 con los bosques aleatorios.


k-fold: el estándar

Partir el entrenamiento en k bloques de tamaño similar; cada bloque es validación una vez:



k-fold: el estándar

Partir el entrenamiento en k bloques de tamaño similar; cada bloque es validación una vez:



$$CV_{(k)} = \frac{1}{k} \sum_{j=1}^k \text{error}_j, \quad \widehat{EE} = \frac{\text{desv. est.}(\text{error}_1, \dots, \text{error}_k)}{\sqrt{k}}$$

- Cada modelo entrena con la fracción $(k-1)/k$ de los datos; se ajusta k veces. **Estándar:** $k = 5$ o 10 .
- Los k errores dan, además del promedio, una **medida de incertidumbre**. Es lo que las barras de la curva de CV van a mostrar.

¿Qué k ? El sesgo–varianza del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes

¿Qué k ? El sesgo–varianza del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes

- **Sesgo:** entrenar con menos de n datos hace ver los modelos peores de lo que serán: el CV es algo *pesimista*, más con k pequeño.
- **Varianza:** LOOCV promedia errores de modelos casi clones; k -fold usa modelos más distintos entre sí. **Veredicto:** $k = 10$ por defecto, $k = 5$ si el ajuste es costoso; repetir el CV con varias particiones si n es pequeño.

¿Qué k ? El sesgo–varianza del propio CV

El estimador CV es, él mismo, una variable aleatoria: tiene sesgo y varianza.

	Sesgo	Varianza	Costo
Conjunto de validación	alto (pesimista)	alta	1 ajuste
LOOCV	≈ 0	alta	n ajustes
k -fold ($k = 5, 10$)	bajo	moderada	k ajustes

- **Sesgo:** entrenar con menos de n datos hace ver los modelos peores de lo que serán: el CV es algo *pesimista*, más con k pequeño.
- **Varianza:** LOOCV promedia errores de modelos casi clones; k -fold usa modelos más distintos entre sí. **Veredicto:** $k = 10$ por defecto, $k = 5$ si el ajuste es costoso; repetir el CV con varias particiones si n es pequeño.


En clasificación

Pliegues **estratificados**: cada uno conserva la prevalencia (con 2% de positivos, un pliegue sin positivos no mide nada). La métrica se calcula **por pliegue** y luego se promedia: una AUC por pliegue, no una AUC sobre las predicciones concatenadas.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre


La curva de CV: girar la perilla y mirar

Para cada valor del hiperparámetro (aquí λ ; puede ser k , los nodos, la profundidad), calcular CV y su error estándar:




La curva de CV: girar la perilla y mirar

Para cada valor del hiperparámetro (aquí λ ; puede ser k , los nodos, la profundidad), calcular CV y su error estándar:




- $\lambda_{\min}$: el mínimo de la curva. Es la curva U de la sesión 1, ahora **estimada** con datos.
- **Regla de una desviación estándar (1-SE)**: el modelo **más simple** cuyo CV está a menos de un error estándar del mínimo. El propio CV es ruidoso: ante un empate estadístico, parsimonia. Con k -NN, “más simple” es k más grande.

Cómo recorrer el espacio de hiperparámetros



- **Grilla:** 3 hiperparámetros $\times$ 10 valores = 1.000 configuraciones, cada una con k ajustes. No escala.
- **Aleatoria** (Bergstra & Bengio, 2012): con el mismo presupuesto explora **más valores** de cada hiperparámetro; gana cuando solo uno o dos importan.
- **Bayesiana** (Snoek et al., 2012): modela el CV como función de los hiperparámetros y prueba donde es más probable mejorar (apéndice).

Cómo recorrer el espacio de hiperparámetros




- **Grilla:** 3 hiperparámetros $\times$ 10 valores = 1.000 configuraciones, cada una con k ajustes. No escala.
- **Aleatoria** (Bergstra & Bengio, 2012): con el mismo presupuesto explora **más valores** de cada hiperparámetro; gana cuando solo uno o dos importan.
- **Bayesiana** (Snoek et al., 2012): modela el CV como función de los hiperparámetros y prueba donde es más probable mejorar (apéndice).

Cómo se ve en un paper: Gelvez et al. (2026)


Bosque afinado con CV de 5 pliegues y búsqueda bayesiana de 100 configuraciones sobre cinco hiperparámetros; se elige la de mejor F1 medio de CV y se reajusta con todo el entrenamiento.

El CV anidado: cuando el número que reportas también se eligió



- Si probamos 100 configuraciones y reportamos el mejor CV, ese número es **optimista**: es el máximo de 100 variables ruidosas (la maldición del ganador).
- **CV anidado**: un lazo externo evalúa; dentro de cada pliegue de entrenamiento, un lazo interno afina. Lo que se reporta nunca se usó para elegir.

El CV anidado: cuando el número que reportas también se eligió



- Si probamos 100 configuraciones y reportamos el mejor CV, ese número es **optimista**: es el máximo de 100 variables ruidosas (la maldición del ganador).
- **CV anidado**: un lazo externo evalúa; dentro de cada pliegue de entrenamiento, un lazo interno afina. Lo que se reporta nunca se usó para elegir.
- En este curso usamos la versión sencilla del mismo principio: **afinar con CV dentro del entrenamiento, reportar en la prueba**. La prueba es el lazo externo con un solo pliegue.
- El CV anidado hace falta cuando **no hay** prueba aparte (muestras pequeñas) o cuando se quiere el error del *procedimiento* completo, con su afinación incluida.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sección 7.10.2)

Escenario: $n = 50$, $p = 5.000$ predictores, y una y generada **al azar**: ninguna relación real. **Procedimiento (¿ven el error?):**

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un clasificador y estimar su error por CV de 5 pliegues.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sección 7.10.2)

Escenario: $n = 50$, $p = 5.000$ predictores, y una y generada **al azar**: ninguna relación real. **Procedimiento (¿ven el error?):**

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un clasificador y estimar su error por CV de 5 pliegues.

Resultado: el CV reporta un error cercano al 3%, en datos donde el error verdadero es del 50%. El paso 1 ya “vio” las respuestas de todos los pliegues: los predictores se eligieron usando también las observaciones que luego fingimos no conocer.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sección 7.10.2)

Escenario: $n = 50$, $p = 5.000$ predictores, y una y generada **al azar**: ninguna relación real. **Procedimiento (¿ven el error?):**

- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un clasificador y estimar su error por CV de 5 pliegues.

Resultado: el CV reporta un error cercano al 3%, en datos donde el error verdadero es del 50%. El paso 1 ya “vio” las respuestas de todos los pliegues: los predictores se eligieron usando también las observaciones que luego fingimos no conocer. **La regla:** todo paso que use y , o que aprenda algo de los datos (selección de variables, imputación, estandarización, remuestreo por desbalance, PCA), ocurre **dentro** de cada pliegue, solo con sus datos de entrenamiento.

La trampa del *leakage*: el CV mal hecho

La forma incorrecta y la correcta de hacer CV (ESL, sección 7.10.2)

Escenario: $n = 50$, $p = 5.000$ predictores, y una y generada **al azar**: ninguna relación real. **Procedimiento (¿ven el error?):**


- 1 Con **todos** los datos, filtrar los 100 predictores más correlacionados con y .
- 2 Con esos 100, ajustar un clasificador y estimar su error por CV de 5 pliegues.

Resultado: el CV reporta un error cercano al 3%, en datos donde el error verdadero es del 50%. El paso 1 ya “vio” las respuestas de todos los pliegues: los predictores se eligieron usando también las observaciones que luego fingimos no conocer. **La regla:** todo paso que use y , o que aprenda algo de los datos (selección de variables, imputación, estandarización, remuestreo por desbalance, PCA), ocurre **dentro** de cada pliegue, solo con sus datos de entrenamiento.


Regla de oro #3

El CV no valida modelos: valida **pipelines completos**.

Anatomía de un *pipeline*




Anatomía de un *pipeline*




- La **receta** es todo lo que transforma las x antes del modelo. Se *aprende* (las medias para imputar, las desviaciones para escalar, los cuantiles de los nodos) en el entrenamiento del pliegue y se *aplica* tal cual a la validación. Es lo que hace *recipes*.

Anatomía de un *pipeline*




- La **receta** es todo lo que transforma las x antes del modelo. Se *aprende* (las medias para imputar, las desviaciones para escalar, los cuantiles de los nodos) en el entrenamiento del pliegue y se *aplica* tal cual a la validación. Es lo que hace *recipes*.
- Lo mismo vale para el conjunto de prueba al final: la receta aprendida con todo el entrenamiento se aplica a la prueba. Nunca al revés.

Anatomía de un *pipeline*



- La **receta** es todo lo que transforma las x antes del modelo. Se *aprende* (las medias para imputar, las desviaciones para escalar, los cuantiles de los nodos) en el entrenamiento del pliegue y se *aplica* tal cual a la validación. Es lo que hace *recipes*.
- Lo mismo vale para el conjunto de prueba al final: la receta aprendida con todo el entrenamiento se aplica a la prueba. Nunca al revés.
- Gelvez et al. (2026) lo dicen explícitamente: los faltantes se imputan con medias del entrenamiento “dentro del *pipeline*, de modo que ninguna información de validación entra en la selección del modelo”.

Anatomía de un *pipeline*



- La **receta** es todo lo que transforma las x antes del modelo. Se *aprende* (las medias para imputar, las desviaciones para escalar, los cuantiles de los nodos) en el entrenamiento del pliegue y se *aplica* tal cual a la validación. Es lo que hace recetas.
- Lo mismo vale para el conjunto de prueba al final: la receta aprendida con todo el entrenamiento se aplica a la prueba. Nunca al revés.
- Gelvez et al. (2026) lo dicen explícitamente: los faltantes se imputan con medias del entrenamiento “dentro del *pipeline*, de modo que ninguna información de validación entra en la selección del modelo”.

Lo que cambia de aquí al final del curso

Solo la caja “ajustar el modelo”: hoy k -NN y logística; luego `glmnet`, bosques, *boosting*, redes. La receta y el remuestreo son los mismos.

Otras formas de filtración

Cuatro filtraciones menos visibles que la de ESL, frecuentes en datos económicos:

- 1 **Variables que contienen a y:** los votos del ganador al predecir si ganó la mesa; la fecha de castigo al predecir el impago; el precio por metro cuadrado al predecir el precio. Se delatan por métricas demasiado buenas.

Otras formas de filtración

Cuatro filtraciones menos visibles que la de ESL, frecuentes en datos económicos:

- 1 **Variables que contienen a y:** los votos del ganador al predecir si ganó la mesa; la fecha de castigo al predecir el impago; el precio por metro cuadrado al predecir el precio. Se delatan por métricas demasiado buenas.
- 2 **Información del futuro:** usar el desempleo de diciembre para “predecir” el de octubre. Toda variable debe existir en el momento de decidir.

Otras formas de filtración

Cuatro filtraciones menos visibles que la de ESL, frecuentes en datos económicos:

- 1 **Variables que contienen a y:** los votos del ganador al predecir si ganó la mesa; la fecha de castigo al predecir el impago; el precio por metro cuadrado al predecir el precio. Se delatan por métricas demasiado buenas.
- 2 **Información del futuro:** usar el desempleo de diciembre para “predecir” el de octubre. Toda variable debe existir en el momento de decidir.
- 3 **Duplicados y grupos:** el mismo inmueble publicado dos veces cae en entrenamiento y en prueba; varias mesas del mismo puesto se reparten entre pliegues. El modelo recuerda, no generaliza.

Otras formas de filtración

Cuatro filtraciones menos visibles que la de ESL, frecuentes en datos económicos:

- 1 **Variables que contienen a y:** los votos del ganador al predecir si ganó la mesa; la fecha de castigo al predecir el impago; el precio por metro cuadrado al predecir el precio. Se delatan por métricas demasiado buenas.
- 2 **Información del futuro:** usar el desempleo de diciembre para “predecir” el de octubre. Toda variable debe existir en el momento de decidir.
- 3 **Duplicados y grupos:** el mismo inmueble publicado dos veces cae en entrenamiento y en prueba; varias mesas del mismo puesto se reparten entre pliegues. El modelo recuerda, no generaliza.
- 4 **Afinar con la prueba:** elegir el modelo mirándola y luego reportarla.

Otras formas de filtración

Cuatro filtraciones menos visibles que la de ESL, frecuentes en datos económicos:


- 1 **Variables que contienen a y:** los votos del ganador al predecir si ganó la mesa; la fecha de castigo al predecir el impago; el precio por metro cuadrado al predecir el precio. Se delatan por métricas demasiado buenas.
- 2 **Información del futuro:** usar el desempleo de diciembre para “predecir” el de octubre. Toda variable debe existir en el momento de decidir.
- 3 **Duplicados y grupos:** el mismo inmueble publicado dos veces cae en entrenamiento y en prueba; varias mesas del mismo puesto se reparten entre pliegues. El modelo recuerda, no generaliza.
- 4 **Afinar con la prueba:** elegir el modelo mirándola y luego reportarla.

Cómo se ve en un paper: Neunhoeffter & Sternberg (2019)


Reexaminan un artículo donde un bosque aleatorio parecía predecir guerras civiles mucho mejor que la logística: parte de la ventaja venía de un CV que dejó filtrar información de la evaluación hacia el ajuste. Corregido el protocolo, la ventaja se reduce sustancialmente. **El protocolo es parte del resultado.**

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

Datos en el tiempo: validar hacia adelante




Datos en el tiempo: validar hacia adelante




- Con series de tiempo **no se barajan** los pliegues: barajar deja que el futuro entrene al pasado, y el modelo aprende tendencias y ciclos que en producción no conocerá.
- **Origen rodante** (o ventana móvil): entrenar hasta t , predecir $t + h$; avanzar el origen; promediar. El error resultante es el *pseudo-fuera-de-muestra* de la literatura de pronóstico.

Datos en el tiempo: validar hacia adelante




- Con series de tiempo **no se barajan** los pliegues: barajar deja que el futuro entrene al pasado, y el modelo aprende tendencias y ciclos que en producción no conocerá.
- **Origen rodante** (o ventana móvil): entrenar hasta t , predecir $t + h$; avanzar el origen; promediar. El error resultante es el *pseudo-fuera-de-muestra* de la literatura de pronóstico.
- Un matiz de Goulet Coulombe et al. (2022): para **afinar** hiperparámetros en pronóstico macro, el k -fold resultó tan bueno como las alternativas; para **evaluar** el pronóstico, no hay sustituto para el esquema hacia adelante.

Datos en el espacio: vecinos que se copian




k-fold aleatorio




bloques espaciales

- Mesas vecinas (o inmuebles de la misma cuadra) comparten lo que el modelo no observa. Si una cae en entrenamiento y la otra en validación, el modelo *interpola* entre vecinas y el CV luce mejor de lo que el modelo es.
- **CV por bloques** (Roberts et al., 2017): los pliegues son regiones contiguas; cada pliegue es un “lugar nuevo”.

Datos en el espacio: vecinos que se copian



k-fold aleatorio



bloques espaciales

- Mesas vecinas (o inmuebles de la misma cuadra) comparten lo que el modelo no observa. Si una cae en entrenamiento y la otra en validación, el modelo *interpola* entre vecinas y el CV luce mejor de lo que el modelo es.
- **CV por bloques** (Roberts et al., 2017): los pliegues son regiones contiguas; cada pliegue es un “lugar nuevo”.
- Deppner & Cajias (2024) lo muestran con modelos hedónicos de árboles: los errores del remuestreo no espacial son “excesivamente optimistas”, y el CV espacial da estimaciones más confiables y modelos que generalizan mejor.
- El mismo principio aplica a cualquier **grupo**: hogares en panel, estudiantes en colegios, mesas en puestos. Se deja fuera el grupo entero.

¿Qué pregunta responde cada esquema?

Esquema	Pregunta que responde	Cuándo es la correcta
k -fold aleatorio	¿qué tan bien predigo mesas nuevas en lugares y años ya vistos?	interpolación en la misma población
Bloques espaciales	¿qué tan bien predigo en un departamento que el modelo nunca vio?	extrapolación a lugares nuevos
Hacia adelante	¿qué tan bien predigo el próximo período?	pronosticar
Por grupos	¿qué tan bien predigo para una unidad nueva (hogar, colegio)?	datos jerárquicos o de panel

¿Qué pregunta responde cada esquema?

Esquema	Pregunta que responde	Cuándo es la correcta
k -fold aleatorio	¿qué tan bien predigo mesas nuevas en lugares y años ya vistos?	interpolación en la misma población
Bloques espaciales	¿qué tan bien predigo en un departamento que el modelo nunca vio?	extrapolación a lugares nuevos
Hacia adelante	¿qué tan bien predigo el próximo período?	pronosticar
Por grupos	¿qué tan bien predigo para una unidad nueva (hogar, colegio)?	datos jerárquicos o de panel

- Roberts et al. advierten el reverso: bloquear puede obligar a *extrapolar* en el espacio de los predictores; el error es honesto para esa tarea y pesimista para la otra. Gelvez et al. (2026) usan CV aleatorio estratificado y lo dicen: miden recuperabilidad *dentro* de la elección, no pronóstico. Hoy calculamos también la versión por departamentos.

¿Qué pregunta responde cada esquema?

Esquema	Pregunta que responde	Cuándo es la correcta
k -fold aleatorio	¿qué tan bien predigo mesas nuevas en lugares y años ya vistos?	interpolación en la misma población
Bloques espaciales	¿qué tan bien predigo en un departamento que el modelo nunca vio?	extrapolación a lugares nuevos
Hacia adelante	¿qué tan bien predigo el próximo período?	pronosticar
Por grupos	¿qué tan bien predigo para una unidad nueva (hogar, colegio)?	datos jerárquicos o de panel

- Roberts et al. advierten el reverso: bloquear puede obligar a *extrapolar* en el espacio de los predictores; el error es honesto para esa tarea y pesimista para la otra. Gelvez et al. (2026) usan CV aleatorio estratificado y lo dicen: miden recuperabilidad *dentro* de la elección, no pronóstico. Hoy calculamos también la versión por departamentos.

Regla

Eliján el esquema de validación según la **predicción que van a hacer**, y digan cuál eligieron.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

Bootstrap: la idea

Pregunta distinta: ¿qué tan **incierto** es un estadístico para el que no hay fórmula de error estándar? Una AUC, un R^2 de prueba, la diferencia de RMSE entre dos modelos.

Bootstrap: la idea

Pregunta distinta: ¿qué tan **incierto** es un estadístico para el que no hay fórmula de error estándar? Una AUC, un R^2 de prueba, la diferencia de RMSE entre dos modelos. **El principio plug-in** (Efron, 1979): no podemos remuestrear del mundo, pero la muestra es nuestra mejor estimación del mundo. Entonces:

- 1 Extraer B **remuestras con reemplazo** de tamaño n de la propia muestra.
- 2 Calcular el estadístico $\hat{\theta}^{*b}$ en cada una.
- 3 La dispersión de las B réplicas estima la incertidumbre:

$$\widehat{\text{EE}}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}, \quad \text{IC}_{95\%} = [\hat{\theta}_{(0,025)}^*, \hat{\theta}_{(0,975)}^*].$$

Bootstrap: la idea

Pregunta distinta: ¿qué tan **incierto** es un estadístico para el que no hay fórmula de error estándar? Una AUC, un R^2 de prueba, la diferencia de RMSE entre dos modelos. **El principio plug-in** (Efron, 1979): no podemos remuestrear del mundo, pero la muestra es nuestra mejor estimación del mundo. Entonces:

- 1 Extraer B **remuestras con reemplazo** de tamaño n de la propia muestra.
- 2 Calcular el estadístico $\hat{\theta}^{*b}$ en cada una.
- 3 La dispersión de las B réplicas estima la incertidumbre:

$$\widehat{\text{EE}}(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}, \quad \text{IC}_{95\%} = [\hat{\theta}_{(0,025)}^*, \hat{\theta}_{(0,975)}^*].$$

- El intervalo por **percentiles** no necesita normalidad ni fórmulas: $B = 1.000$ suele bastar.
- Lo usaremos tres veces: hoy para las métricas; en la sesión 6, las remuestras *son* el *bagging*; en la sesión 9, para los intervalos de los bosques causales.

Intervalos para las métricas y comparación de modelos

Sobre la prueba: remuestrear las n_t observaciones de prueba, recalculando la métrica en cada remuestra y tomar los percentiles. Vale para cualquier métrica.

Intervalos para las métricas y comparación de modelos

Sobre la prueba: remuestrear las n_t observaciones de prueba, recalcular la métrica en cada remuestra y tomar los percentiles. Vale para cualquier métrica.

- “AUC = 0,91” sin intervalo es un número sin escala: con 2.400 mesas de prueba el intervalo es angosto; con 200 hogares, no. Las tablas de Gelvez et al. (2026) traen estimaciones puntuales; hoy les ponemos el intervalo.

Intervalos para las métricas y comparación de modelos

Sobre la prueba: remuestrear las n_t observaciones de prueba, recalculando la métrica en cada remuestra y tomar los percentiles. Vale para cualquier métrica.

- “AUC = 0,91” sin intervalo es un número sin escala: con 2.400 mesas de prueba el intervalo es angosto; con 200 hogares, no. Las tablas de Gelvez et al. (2026) traen estimaciones puntuales; hoy les ponemos el intervalo.
- **Comparar dos modelos:** sus métricas se calcularon sobre las *mismas* observaciones. Se remuestrea la **diferencia**; si su intervalo excluye el cero, la ventaja es real.

Intervalos para las métricas y comparación de modelos

Sobre la prueba: remuestrear las n_t observaciones de prueba, recalcular la métrica en cada remuestra y tomar los percentiles. Vale para cualquier métrica.

- “AUC = 0,91” sin intervalo es un número sin escala: con 2.400 mesas de prueba el intervalo es angosto; con 200 hogares, no. Las tablas de Gelvez et al. (2026) traen estimaciones puntuales; hoy les ponemos el intervalo.
- **Comparar dos modelos:** sus métricas se calcularon sobre las *mismas* observaciones. Se remuestrea la **diferencia**; si su intervalo excluye el cero, la ventaja es real.
- **Sobre el CV:** los k errores también dan un error estándar, pero los pliegues comparten datos y ese EE es optimista (Bengio & Grandvalet, 2004): sirve para la regla 1-SE, no para un test.

Intervalos para las métricas y comparación de modelos

Sobre la prueba: remuestrear las n_t observaciones de prueba, recalcular la métrica en cada remuestra y tomar los percentiles. Vale para cualquier métrica.

- “AUC = 0,91” sin intervalo es un número sin escala: con 2.400 mesas de prueba el intervalo es angosto; con 200 hogares, no. Las tablas de Gelvez et al. (2026) traen estimaciones puntuales; hoy les ponemos el intervalo.
- **Comparar dos modelos:** sus métricas se calcularon sobre las *mismas* observaciones. Se remuestra la **diferencia**; si su intervalo excluye el cero, la ventaja es real.
- **Sobre el CV:** los k errores también dan un error estándar, pero los pliegues comparten datos y ese EE es optimista (Bengio & Grandvalet, 2004): sirve para la regla 1-SE, no para un test.

Con muchos modelos

Elegir entre veinte configuraciones la que gana por dos milésimas es azar disfrazado: para eso existen la regla 1-SE y la parsimonia. Es el problema de las pruebas múltiples (ISL, cap. 13) en versión predictiva.

Bootstrap y el error *out-of-bag*

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0,632.$$

Bootstrap y el error *out-of-bag*

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0,632.$$

- Cada remuestra contiene cerca del 63% de las observaciones (la cuenta, en el apéndice); el 37% restante queda **afuera** (*out-of-bag*, OOB).
- Esas observaciones son datos de validación *gratis* para el modelo ajustado en esa remuestra: predecir cada i solo con los modelos de las remuestras que **no** la contienen, y promediar.

Bootstrap y el error *out-of-bag*

Dato clave: ¿qué fracción de las observaciones originales aparece en una remuestra?

$$P(i \in \text{remuestra}) = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0,632.$$

- Cada remuestra contiene cerca del 63% de las observaciones (la cuenta, en el apéndice); el 37% restante queda **afuera** (*out-of-bag*, OOB).
- Esas observaciones son datos de validación *gratis* para el modelo ajustado en esa remuestra: predecir cada i solo con los modelos de las remuestras que **no** la contienen, y promediar.

Anticipo de la sesión 6

Un bosque aleatorio es un promedio de modelos ajustados sobre remuestras *bootstrap*. Su error OOB es un estimador del error de prueba **sin CV adicional**, y por eso se afina tan rápido.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

Los datos y las preguntas

Datos: los dos de las sesiones anteriores. Vivienda en Bogotá (OLS básico, OLS flexible con *splines* e interacciones, *k*-NN) y mesas de 2022, primera vuelta (logística, *k*-NN).

Los datos y las preguntas

Datos: los dos de las sesiones anteriores. Vivienda en Bogotá (OLS básico, OLS flexible con *splines* e interacciones, *k*-NN) y mesas de 2022, primera vuelta (logística, *k*-NN). **Tres preguntas:**

- 1 ¿Qué modelo gana por CV **dentro del entrenamiento**, y con qué *k* o cuántos nodos? Con intervalos, no solo con promedios.
- 2 ¿Coincide el CV con la prueba? Si el CV dice 0,90 y la prueba 0,80, algo se filtró.
- 3 Para las mesas: ¿cuánto cae la AUC cuando los pliegues son **departamentos enteros** en vez de mesas al azar?

Los datos y las preguntas

Datos: los dos de las sesiones anteriores. Vivienda en Bogotá (OLS básico, OLS flexible con *splines* e interacciones, *k*-NN) y mesas de 2022, primera vuelta (logística, *k*-NN). **Tres preguntas:**

- 1 ¿Qué modelo gana por CV **dentro del entrenamiento**, y con qué *k* o cuántos nodos? Con intervalos, no solo con promedios.
- 2 ¿Coincide el CV con la prueba? Si el CV dice 0,90 y la prueba 0,80, algo se filtró.
- 3 Para las mesas: ¿cuánto cae la AUC cuando los pliegues son **departamentos enteros** en vez de mesas al azar?

Decisiones antes de ajustar nada:

- CV de 5 pliegues, estratificado (por deciles del precio; por clase en las mesas), repetido 3 veces para *k*-NN.
- Grilla de $k \in \{5, 15, 25, 51, 101\}$; regla 1-SE hacia el *k* más grande. Nodos de los *splines*: $\{3, 4, 6, 8\}$.
- La receta (imputación, escala, *dummies*, *splines*) vive dentro del *pipeline*. La prueba sigue bajo llave y se abre una vez.

La tabla: CV contra prueba, con intervalos

Datos	Modelo	CV (media $\pm$ EE)	Prueba	IC 95%
Vivienda, RMSE	OLS básico	en clase	en clase	en clase
	OLS flexible (nodos por CV)	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase
Mesas, AUC	Logística	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase

La tabla: CV contra prueba, con intervalos

Datos	Modelo	CV (media $\pm$ EE)	Prueba	IC 95%
Vivienda, RMSE	OLS básico	en clase	en clase	en clase
	OLS flexible (nodos por CV)	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase
Mesas, AUC	Logística	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase

Un ancla publicada. Gelvez et al. (2026, Tabla A5) reportan, para el bosque, el F1 medio del CV de 5 pliegues con el que se afinó y el F1 en la prueba:

	2014-I	2018-I	2022-I
F1 en CV (afinación)	0,781	0,829	0,868
F1 en la prueba	0,769	0,831	0,873

La tabla: CV contra prueba, con intervalos

Datos	Modelo	CV (media $\pm$ EE)	Prueba	IC 95%
Vivienda, RMSE	OLS básico	en clase	en clase	en clase
	OLS flexible (nodos por CV)	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase
Mesas, AUC	Logística	en clase	en clase	en clase
	k -NN (k por CV, 1-SE)	en clase	en clase	en clase

Un ancla publicada. Gelvez et al. (2026, Tabla A5) reportan, para el bosque, el F1 medio del CV de 5 pliegues con el que se afinó y el F1 en la prueba:

	2014-I	2018-I	2022-I
F1 en CV (afinación)	0,781	0,829	0,868
F1 en la prueba	0,769	0,831	0,873

- Diferencias de una centésima en ambas direcciones: el CV estimó bien lo que la prueba confirmó. Eso es lo que esperamos ver en nuestra tabla; una brecha grande sería la señal de una filtración.

CV espacial con las mesas: ¿qué tan lejos generaliza el modelo?

Diseño: los mismos modelos, pero los cinco pliegues son **grupos de departamentos**: cada pliegue deja fuera regiones enteras.

CV espacial con las mesas: ¿qué tan lejos generaliza el modelo?

Diseño: los mismos modelos, pero los cinco pliegues son **grupos de departamentos**: cada pliegue deja fuera regiones enteras.

AUC en CV, mesas 2022-I	aleatorio	por departamento
Logística con indicadores de dpto.	en clase	no aplica
Logística sin indicadores de dpto.	en clase	en clase
k -NN	en clase	en clase

CV espacial con las mesas: ¿qué tan lejos generaliza el modelo?

Diseño: los mismos modelos, pero los cinco pliegues son **grupos de departamentos**: cada pliegue deja fuera regiones enteras.

AUC en CV, mesas 2022-I	aleatorio	por departamento
Logística con indicadores de dpto.	en clase	no aplica
Logística sin indicadores de dpto.	en clase	en clase
k -NN	en clase	en clase

- **Un detalle que enseña:** con pliegues por departamento, los indicadores de departamento no sirven (el de validación nunca se vio): hay que quitarlos, y la comparación justa es entre las filas sin indicadores.

CV espacial con las mesas: ¿qué tan lejos generaliza el modelo?

Diseño: los mismos modelos, pero los cinco pliegues son **grupos de departamentos**: cada pliegue deja fuera regiones enteras.

AUC en CV, mesas 2022-I	aleatorio	por departamento
Logística con indicadores de dpto.	en clase	no aplica
Logística sin indicadores de dpto.	en clase	en clase
k -NN	en clase	en clase

- **Un detalle que enseña:** con pliegues por departamento, los indicadores de departamento no sirven (el de validación nunca se vio): hay que quitarlos, y la comparación justa es entre las filas sin indicadores.
- **Lo que esperamos:** una caída de la AUC. Su tamaño mide cuánto del desempeño es estructura *regional* y cuánto viaja de un departamento a otro con las características censales.

CV espacial con las mesas: ¿qué tan lejos generaliza el modelo?

Diseño: los mismos modelos, pero los cinco pliegues son **grupos de departamentos**: cada pliegue deja fuera regiones enteras.

AUC en CV, mesas 2022-I	aleatorio	por departamento
Logística con indicadores de dpto.	en clase	no aplica
Logística sin indicadores de dpto.	en clase	en clase
<i>k</i> -NN	en clase	en clase

- **Un detalle que enseña:** con pliegues por departamento, los indicadores de departamento no sirven (el de validación nunca se vio): hay que quitarlos, y la comparación justa es entre las filas sin indicadores.
- **Lo que esperamos:** una caída de la AUC. Su tamaño mide cuánto del desempeño es estructura *regional* y cuánto viaja de un departamento a otro con las características censales.
- **Cómo leerlo:** ninguna AUC es “la verdadera”. La aleatoria responde a Gelvez et al.; la espacial responde “¿y en un departamento nuevo?”. Reportar las dos es reportar el alcance del modelo.

Cómo se ve en R (tidymodels)

```
library(tidymodels); set.seed(2026)
folds <- vfold_cv(train, v = 5, strata = ganador)
knn_spec <- nearest_neighbor(neighbors = tune()) |>
  set_engine("kknn") |> set_mode("classification")
wf <- workflow(rec, knn_spec) # la receta de la sesión 3
res <- tune_grid(wf, resamples = folds,
  grid = tibble(neighbors = c(5, 15, 25, 51, 101)),
  metrics = metric_set(roc_auc))
collect_metrics(res) # media y error estándar
best <- select_by_one_std_err(res, desc(neighbors),
  metric = "roc_auc")
final <- finalize_workflow(wf, best) |> last_fit(split) # una vez
pred <- collect_predictions(final)
boot <- bootstraps(pred, times = 1000) |>
  mutate(auc = map_dbl(splits, \(s)
    roc_auc(analysis(s), ganador, .pred_1)$estimate))
quantile(boot$auc, c(.025, .975)) # IC 95 % bootstrap
# CV espacial: group_vfold_cv(train, group = departamento, v = 5)
```

- `tune_grid` ajusta la receta y el modelo **dentro de cada pliegue**; `last_fit` reajusta con todo el entrenamiento y evalúa en la prueba una sola vez.
`group_vfold_cv` deja fuera grupos enteros.

Presentación estudiantil: el paper de la sesión 3

Quince minutos, tres preguntas

Kleinberg et al. (2018) o Fuster et al. (2022), a elección de quien presenta.

- 1 **¿Qué se predice y qué decisión depende de ello?** El riesgo de no comparecer y la decisión de liberar; la probabilidad de impago y la decisión de prestar (y a qué tasa).
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué modelo, qué partición, qué métrica, y sobre todo: ¿qué observaciones *faltan*? (solo se observa el resultado de los liberados; solo el de los créditos aprobados).
- 3 **¿Qué se encuentra y cómo se interpreta?** La ganancia frente al juez o frente al logit, y para quién: ¿se reparte igual entre grupos?

Presentación estudiantil: el paper de la sesión 3

Quince minutos, tres preguntas

Kleinberg et al. (2018) o Fuster et al. (2022), a elección de quien presenta.

- 1 **¿Qué se predice y qué decisión depende de ello?** El riesgo de no comparecer y la decisión de liberar; la probabilidad de impago y la decisión de prestar (y a qué tasa).
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué modelo, qué partición, qué métrica, y sobre todo: ¿qué observaciones *faltan*? (solo se observa el resultado de los liberados; solo el de los créditos aprobados).
- 3 **¿Qué se encuentra y cómo se interpreta?** La ganancia frente al juez o frente al logit, y para quién: ¿se reparte igual entre grupos?

Para el resto de la sala

Mientras escuchan, busquen la filtración posible: ¿qué variable no estaría disponible en el momento de decidir? ¿Qué pasaría con la evaluación si el conjunto de prueba solo contiene a quienes el sistema actual ya aprobó? Es la sesión de hoy aplicada a un paper.

- 1 Estimar el error sin gastar la prueba
- 2 Validación cruzada para elegir hiperparámetros
- 3 El *pipeline* honesto: preprocesar dentro de cada pliegue
- 4 Cuando el k -fold aleatorio miente: tiempo y espacio
- 5 *Bootstrap*: intervalos para las métricas
- 6 Aplicación guiada: los modelos de las sesiones 2 y 3, validados
- 7 Interpretación y cierre

Qué dice un número de CV y qué no dice

- **Estima el error de un procedimiento**, no de un modelo concreto: el error promedio de “ajustar esta receta y este modelo a muestras de tamaño $(k - 1)n/k$ ”. Por eso es algo pesimista y por eso se reajusta con todo el entrenamiento al final.

Qué dice un número de CV y qué no dice

- **Estima el error de un procedimiento**, no de un modelo concreto: el error promedio de “ajustar esta receta y este modelo a muestras de tamaño $(k - 1)n/k$ ”. Por eso es algo pesimista y por eso se reajusta con todo el entrenamiento al final.
- **El CV con el que se eligió es optimista para el elegido**. El número que se reporta sale de la prueba, o de un lazo externo.

Qué dice un número de CV y qué no dice

- **Estima el error de un procedimiento**, no de un modelo concreto: el error promedio de “ajustar esta receta y este modelo a muestras de tamaño $(k - 1)n/k$ ”. Por eso es algo pesimista y por eso se reajusta con todo el entrenamiento al final.
- **El CV con el que se eligió es optimista para el elegido**. El número que se reporta sale de la prueba, o de un lazo externo.
- **Responde la pregunta de su esquema**: aleatorio, por bloques, hacia adelante. Un modelo con AUC de 0,93 en CV aleatorio puede tener 0,80 en un departamento nuevo, y las dos cifras son verdad.

Qué dice un número de CV y qué no dice

- **Estima el error de un procedimiento**, no de un modelo concreto: el error promedio de “ajustar esta receta y este modelo a muestras de tamaño $(k - 1)n/k$ ”. Por eso es algo pesimista y por eso se reajusta con todo el entrenamiento al final.
- **El CV con el que se eligió es optimista para el elegido**. El número que se reporta sale de la prueba, o de un lazo externo.
- **Responde la pregunta de su esquema**: aleatorio, por bloques, hacia adelante. Un modelo con AUC de 0,93 en CV aleatorio puede tener 0,80 en un departamento nuevo, y las dos cifras son verdad.
- **Los hiperparámetros elegidos son parte del resultado**. El k o los nodos que ganaron dicen cuánta flexibilidad soportan los datos: $k = 101$ en las mesas cuenta una historia distinta de $k = 5$.

Qué dice un número de CV y qué no dice

- **Estima el error de un procedimiento**, no de un modelo concreto: el error promedio de “ajustar esta receta y este modelo a muestras de tamaño $(k - 1)n/k$ ”. Por eso es algo pesimista y por eso se reajusta con todo el entrenamiento al final.
- **El CV con el que se eligió es optimista para el elegido**. El número que se reporta sale de la prueba, o de un lazo externo.
- **Responde la pregunta de su esquema**: aleatorio, por bloques, hacia adelante. Un modelo con AUC de 0,93 en CV aleatorio puede tener 0,80 en un departamento nuevo, y las dos cifras son verdad.
- **Los hiperparámetros elegidos son parte del resultado**. El k o los nodos que ganaron dicen cuánta flexibilidad soportan los datos: $k = 101$ en las mesas cuenta una historia distinta de $k = 5$.

Y , no β , versión validación

En Inferencia Causal la especificación se defiende con teoría e identificación. Aquí se defiende con el *pipeline*: cómo se partió, cómo se afinó, dónde se midió. Un resultado predictivo sin ese protocolo no es reproducible ni comparable.

Cuándo usar qué, y qué leer

Situación	Esquema
Datos tabulares sin estructura	k -fold estratificado, $k = 5$ o 10 ; repetido si n es pequeño
Series de tiempo	origen rodante o ventana móvil; nunca barajar
Datos espaciales o en grupos	bloques o <i>leave-group-out</i> ; quitar las variables que identifican el grupo
Elegir hiperparámetros	CV interno con grilla pequeña o búsqueda aleatoria/bayesiana; regla 1-SE
Comparar modelos	mismos pliegues para todos; diferencia con intervalo <i>bootstrap</i>
Reportar	prueba una sola vez, con intervalo <i>bootstrap</i> ; decir qué esquema de CV afinó
n muy pequeño, sin prueba aparte	CV anidado o LOOCV; reportar la incertidumbre con honestidad

Cuándo usar qué, y qué leer

Situación	Esquema
Datos tabulares sin estructura	k -fold estratificado, $k = 5$ o 10 ; repetido si n es pequeño
Series de tiempo	origen rodante o ventana móvil; nunca barajar
Datos espaciales o en grupos	bloques o <i>leave-group-out</i> ; quitar las variables que identifican el grupo
Elegir hiperparámetros	CV interno con grilla pequeña o búsqueda aleatoria/bayesiana; regla 1-SE
Comparar modelos	misimos pliegues para todos; diferencia con intervalo <i>bootstrap</i>
Reportar	prueba una sola vez, con intervalo <i>bootstrap</i> ; decir qué esquema de CV afinó
n muy pequeño, sin prueba aparte	CV anidado o LOOCV; reportar la incertidumbre con honestidad

Qué leer: ISL cap. 5 (CV y *bootstrap* con las figuras de clase); Roberts et al. (2017) para el CV por bloques; Neunhoffer & Sternberg (2019) como advertencia de tres páginas; Kuhn & Silge (2022), caps. 10–13, para el *pipeline* en *tidymodels*.

Recap

- 1 **La prueba responde una pregunta y una sola vez.** Elegir modelos e hiperparámetros se hace **dentro del entrenamiento**, remuestreándolo.
- 2 **Validación cruzada:** k -fold estratificado ($k = 5$ o 10); la curva de CV con sus barras; el mínimo o la regla 1-SE; grilla, aleatoria o bayesiana para buscar; anidado cuando el número reportado también se eligió.
- 3 **Regla de oro #3:** el CV valida *pipelines*. Todo lo que aprende de los datos (imputar, escalar, seleccionar, remuestrear) ocurre dentro de cada pliegue. La historia de los 5.000 predictores.
- 4 **El k -fold aleatorio miente** con tiempo, espacio y grupos: validar hacia adelante, por bloques, por grupos. Cada esquema responde una pregunta distinta; hay que decir cuál.
- 5 **Bootstrap:** intervalos para cualquier métrica y para la diferencia entre modelos; el 63% y el error *out-of-bag*, que reaparece con los bosques.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 5 (secs. 5.1–5.2).
Guía: las figuras 5.2 a 5.6 son las de clase; la sección 5.2 es el *bootstrap*.
- Roberts et al. (2017), *Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure*, *Ecography*.
Guía: secciones 1–3 y las recomendaciones finales; sáltense las simulaciones.
- Neunhoeffter & Sternberg (2019), *How Cross-Validation Can Go Wrong and What to Do About It*, *Political Analysis*.
Guía: tres páginas; léanla completa.

Para la presentación estudiantil de la sesión 5: Deppner & Cajias (2024), JREFE, o Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022), *Journal of Applied Econometrics*.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 5 (secs. 5.1–5.2).
Guía: las figuras 5.2 a 5.6 son las de clase; la sección 5.2 es el *bootstrap*.
- Roberts et al. (2017), *Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure*, *Ecography*.
Guía: secciones 1–3 y las recomendaciones finales; sáltense las simulaciones.
- Neunhoeffter & Sternberg (2019), *How Cross-Validation Can Go Wrong and What to Do About It*, *Political Analysis*.
Guía: tres páginas; léanla completa.

Para la presentación estudiantil de la sesión 5: Deppner & Cajias (2024), JREFE, o Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022), *Journal of Applied Econometrics*. **Próxima sesión — selección de variables y**

regularización: muchos predictores, sobreajuste y colinealidad; Ridge (encoger) y Lasso (ceros exactos); λ por CV con la curva de hoy; PCR y la intuición de PCA; y por qué “el Lasso selecciona predictores, no causas”. Lectura previa: ISL cap. 6 (secs. 6.1–6.2).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 5 (secs. 5.1–5.2).
Guía: las figuras 5.2 a 5.6 son las de clase; la sección 5.2 es el *bootstrap*.
- Roberts et al. (2017), *Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure*, *Ecography*.
Guía: secciones 1–3 y las recomendaciones finales; sáltense las simulaciones.
- Neunhoeffter & Sternberg (2019), *How Cross-Validation Can Go Wrong and What to Do About It*, *Political Analysis*.
Guía: tres páginas; léanla completa.

Para la presentación estudiantil de la sesión 5: Deppner & Cajias (2024), JREFE, o Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022), *Journal of Applied Econometrics*. **Próxima sesión — selección de variables y**

regularización: muchos predictores, sobreajuste y colinealidad; Ridge (encoger) y Lasso (ceros exactos); λ por CV con la curva de hoy; PCR y la intuición de PCA; y por qué “el Lasso selecciona predictores, no causas”. Lectura previa: ISL cap. 6 (secs. 6.1–6.2). **Aplicación de esta semana en R:** la tabla CV contra prueba con intervalos para vivienda y mesas, y el CV espacial por departamentos.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 5. [ISL]
- Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *Annals of Statistics*, 7(1), 1–26.
- Bergstra, J., & Bengio, Y. (2012). Random Search for Hyper-Parameter Optimization. *JMLR*, 13, 281–305.
- Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian Optimization of Machine Learning Algorithms. *NeurIPS* 25.
- Bengio, Y., & Grandvalet, Y. (2004). No Unbiased Estimator of the Variance of K-Fold Cross-Validation. *JMLR*, 5, 1089–1105.
- Roberts, D. R., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929.
- Neunhoffer, M., & Sternberg, S. (2019). How Cross-Validation Can Go Wrong and What to Do About It. *Political Analysis*, 27(1), 101–106.
- Deppner, J., & Cajias, M. (2024). Accounting for Spatial Autocorrelation in Algorithm-Driven Hedonic Models: A Spatial Cross-Validation Approach. *Journal of Real Estate Finance and Economics*.
- Goulet Coulombe, P., Leroux, M., Stevanovic, D., & Surprenant, S. (2022). How Is Machine Learning Useful for Macroeconomic Forecasting? *Journal of Applied Econometrics*, 37(5), 920–964.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Documento de trabajo.

8 Apéndice: para profundizar

A1. El atajo de LOOCV en regresión lineal

Para mínimos cuadrados (y cualquier suavizador lineal) existe una identidad: con **un solo ajuste** sobre todos los datos,

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2,$$

donde h_i es el *leverage* de la observación i : el elemento i de la diagonal de $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

A1. El atajo de LOOCV en regresión lineal

Para mínimos cuadrados (y cualquier suavizador lineal) existe una identidad: con **un solo ajuste** sobre todos los datos,

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2,$$

donde h_i es el *leverage* de la observación i : el elemento i de la diagonal de $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

- **Intuición:** una observación con *leverage* alto “atrae” la recta hacia sí misma y su residuo dentro de muestra es artificialmente pequeño. Dividir por $(1 - h_i)$ deshace ese favor.
- El costo pasa de n ajustes a **uno**. Con $\sum_i h_i = p + 1$, el *leverage* promedio es $(p + 1)/n$: la corrección crece con la complejidad del modelo, como los criterios de información de la sesión 5.

A1. El atajo de LOOCV en regresión lineal

Para mínimos cuadrados (y cualquier suavizador lineal) existe una identidad: con **un solo ajuste** sobre todos los datos,

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2,$$

donde h_i es el *leverage* de la observación i : el elemento i de la diagonal de $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

- **Intuición:** una observación con *leverage* alto “atrae” la recta hacia sí misma y su residuo dentro de muestra es artificialmente pequeño. Dividir por $(1 - h_i)$ deshace ese favor.
- El costo pasa de n ajustes a **uno**. Con $\sum_i h_i = p + 1$, el *leverage* promedio es $(p + 1)/n$: la corrección crece con la complejidad del modelo, como los criterios de información de la sesión 5.

Alcance

Vale para OLS, *splines* y otros suavizadores lineales. Para árboles, *boosting* o redes no hay atajo: por eso en la práctica domina el k -fold.

A2. La cuenta del 0,632 y el estimador *out-of-bag*

1. Una observación fija i . En cada extracción con reemplazo, $P(\text{no sale } i) = 1 - 1/n$. Las n extracciones son independientes:

$$P(i \notin \text{remuestra}) = \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368,$$

así que $P(i \in \text{remuestra}) \rightarrow 0,632$. Con $n = 100$ ya da 0,634: el límite es una excelente aproximación.

A2. La cuenta del 0,632 y el estimador *out-of-bag*

1. Una observación fija i . En cada extracción con reemplazo, $P(\text{no sale } i) = 1 - 1/n$. Las n extracciones son independientes:

$$P(i \notin \text{remuestra}) = \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368,$$

así que $P(i \in \text{remuestra}) \rightarrow 0,632$. Con $n = 100$ ya da 0,634: el límite es una excelente aproximación. **2. El estimador OOB.** Con B remuestras y un modelo $\hat{f}^{*b}$ por remuestra, para cada i se promedian solo los modelos que no la vieron:

$$\widehat{\text{Err}}_{\text{OOB}} = \frac{1}{n} \sum_{i=1}^n \frac{1}{|B_{-i}|} \sum_{b \in B_{-i}} L(y_i, \hat{f}^{*b}(x_i)),$$

con B_{-i} el conjunto de remuestras que no contienen a i .

A2. La cuenta del 0,632 y el estimador *out-of-bag*

1. Una observación fija i . En cada extracción con reemplazo, $P(\text{no sale } i) = 1 - 1/n$. Las n extracciones son independientes:

$$P(i \notin \text{remuestra}) = \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368,$$

así que $P(i \in \text{remuestra}) \rightarrow 0,632$. Con $n = 100$ ya da 0,634: el límite es una excelente aproximación. **2. El estimador OOB.** Con B remuestras y un modelo $\hat{f}^{*b}$ por remuestra, para cada i se promedian solo los modelos que no la vieron:

$$\widehat{\text{Err}}_{\text{OOB}} = \frac{1}{n} \sum_{i=1}^n \frac{1}{|B_{-i}|} \sum_{b \in B_{-i}} L(y_i, \hat{f}^{*b}(x_i)),$$

con B_{-i} el conjunto de remuestras que no contienen a i .

- Cada $\hat{f}^{*b}$ se entrenó con cerca del 63% de las observaciones distintas: el OOB es algo pesimista, como un CV con $k \approx 3$. Para un bosque grande la diferencia con el CV de 10 pliegues es pequeña y el costo, nulo.
- ESL (sec. 7.11) propone el estimador “0,632”, que mezcla el error OOB con el de entrenamiento para corregir ese pesimismo.

A3. Búsqueda bayesiana de hiperparámetros: la idea

El problema: cada evaluación de $CV(\theta)$ para una configuración θ es cara (cinco ajustes de un bosque). Queremos encontrar el mínimo con pocas evaluaciones.

A3. Búsqueda bayesiana de hiperparámetros: la idea

El problema: cada evaluación de $CV(\theta)$ para una configuración θ es cara (cinco ajustes de un bosque). Queremos encontrar el mínimo con pocas evaluaciones. **El algoritmo** (Snoek, Larochelle & Adams, 2012):

- 1 Evaluar unas pocas configuraciones iniciales (al azar).
- 2 Ajustar un **modelo sustituto** de $CV(\theta)$ sobre lo evaluado: típicamente un proceso gaussiano, que da una media y una incertidumbre para cada θ no probado.
- 3 Elegir la siguiente θ maximizando una **función de adquisición**, por ejemplo la mejora esperada: alta donde la media predicha es baja o donde la incertidumbre es grande (explotar vs. explorar).
- 4 Evaluar, actualizar el sustituto, repetir hasta agotar el presupuesto.

A3. Búsqueda bayesiana de hiperparámetros: la idea

El problema: cada evaluación de $CV(\theta)$ para una configuración θ es cara (cinco ajustes de un bosque). Queremos encontrar el mínimo con pocas evaluaciones. **El algoritmo** (Snoek, Larochelle & Adams, 2012):

- 1 Evaluar unas pocas configuraciones iniciales (al azar).
 - 2 Ajustar un **modelo sustituto** de $CV(\theta)$ sobre lo evaluado: típicamente un proceso gaussiano, que da una media y una incertidumbre para cada θ no probado.
 - 3 Elegir la siguiente θ maximizando una **función de adquisición**, por ejemplo la mejora esperada: alta donde la media predicha es baja o donde la incertidumbre es grande (explotar vs. explorar).
 - 4 Evaluar, actualizar el sustituto, repetir hasta agotar el presupuesto.
- Es la misma lógica de este curso aplicada al propio afinamiento: un modelo que predice el desempeño y una decisión bajo incertidumbre.
 - En R: `tune::tune_bayes()`; en Python, `optuna` o `scikit-optimize`. Gelvez et al. (2026) usan 100 iteraciones sobre cinco hiperparámetros del bosque.