

Big Data y Machine Learning para Economía Aplicada

Week 05: Clasificación y Métricas de Desempeño

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 23, 2026

Previously...

- Cerramos el arco de la **regresión**: modelos lineales regularizados (S2–S3) y ensambles de árboles (S4), todos evaluados con validación cruzada sobre el mismo esqueleto de pipeline.
- Quedó una semilla sembrada: el *gradient boosting* con pérdida logística ajusta árboles a $y_i - \hat{p}_i$... hoy sabremos de dónde sale ese residuo.

Previously...

- Cerramos el arco de la **regresión**: modelos lineales regularizados (S2–S3) y ensambles de árboles (S4), todos evaluados con validación cruzada sobre el mismo esqueleto de pipeline.
- Quedó una semilla sembrada: el *gradient boosting* con pérdida logística ajusta árboles a $y_i - \hat{p}_i$... hoy sabremos de dónde sale ese residuo.

Hoy: y es una categoría

¿Impaga o no? ¿Pobre o no pobre? ¿Compra o no compra? Cambian tres cosas:

- 1 La **pérdida** (el MSE ya no es la métrica natural).
- 2 Los **métodos** (logística, k -NN, LDA/NB, SVM — y los árboles de la semana pasada, que ya clasificaban).
- 3 Y sobre todo la **evaluación**: con clases desbalanceadas y errores de costo asimétrico, elegir la métrica y el umbral es la decisión económica.

1 El problema de clasificación

2 Los clasificadores

3 Métricas: decidir con costos

4 Desbalanceo de clases

Setup, y por qué no usar OLS

Ahora $y \in \{0, 1\}$ (o K clases). Queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$.
- Una **regla de decisión** $\hat{y}(x) \in \{0, 1\}$ (que veremos, requiere además un *umbral*).

Setup, y por qué no usar OLS

Ahora $y \in \{0, 1\}$ (o K clases). Queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$.
- Una **regla de decisión** $\hat{y}(x) \in \{0, 1\}$ (que veremos, requiere además un *umbral*).

¿Y si le tiramos OLS a la dummy? (el “modelo de probabilidad lineal”)

- Predicciones fuera de $[0, 1]$: probabilidades de -0.2 o 1.3 no sirven para **decidir** con umbrales.
- Con $K > 2$ clases codificadas 1, 2, 3: impone un orden y distancias que no existen.

Setup, y por qué no usar OLS

Ahora $y \in \{0, 1\}$ (o K clases). Queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$.
- Una **regla de decisión** $\hat{y}(x) \in \{0, 1\}$ (que veremos, requiere además un *umbral*).

¿Y si le tiramos OLS a la dummy? (el “modelo de probabilidad lineal”)

- Predicciones fuera de $[0, 1]$: probabilidades de -0.2 o 1.3 no sirven para **decidir** con umbrales.
- Con $K > 2$ clases codificadas 1, 2, 3: impone un orden y distancias que no existen.
- **Nota de honestidad econométrica:** para estimar *efectos marginales promedio*, el LPM es legítimo y ustedes lo usan. Pero nuestro objetivo hoy es otro: **probabilidades bien calibradas para clasificar y decidir**. Objetivos distintos, herramientas distintas.

Setup, y por qué no usar OLS

Ahora $y \in \{0, 1\}$ (o K clases). Queremos dos objetos, relacionados pero distintos:

- La **probabilidad** $p(x) = P(y = 1 \mid X = x)$.
- Una **regla de decisión** $\hat{y}(x) \in \{0, 1\}$ (que veremos, requiere además un *umbral*).

¿Y si le tiramos OLS a la dummy? (el “modelo de probabilidad lineal”)

- Predicciones fuera de $[0, 1]$: probabilidades de -0.2 o 1.3 no sirven para **decidir** con umbrales.
- Con $K > 2$ clases codificadas 1, 2, 3: impone un orden y distancias que no existen.
- **Nota de honestidad econométrica:** para estimar *efectos marginales promedio*, el LPM es legítimo y ustedes lo usan. Pero nuestro objetivo hoy es otro: **probabilidades bien calibradas para clasificar y decidir**.
Objetivos distintos, herramientas distintas.

El plan

Primero el clasificador ideal (Bayes), luego los métodos que lo aproximan, y

El clasificador de Bayes: el ideal inalcanzable

Si conociéramos las probabilidades verdaderas, la regla óptima (minimiza la tasa de error) es obvia:

$$\hat{y}^{Bayes}(x) = \arg \max_k P(y = k \mid X = x)$$

asignar cada x a su clase **más probable**.

El clasificador de Bayes: el ideal inalcanzable

Si conociéramos las probabilidades verdaderas, la regla óptima (minimiza la tasa de error) es obvia:

$$\hat{y}^{Bayes}(x) = \arg \max_k P(y = k \mid X = x)$$

asignar cada x a su clase **más probable**.

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0.5$ en el caso binario); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es > 0 siempre que las clases se *traslapen*: individuos idénticos en X con resultados distintos.

El clasificador de Bayes: el ideal inalcanzable

Si conociéramos las probabilidades verdaderas, la regla óptima (minimiza la tasa de error) es obvia:

$$\hat{y}^{Bayes}(x) = \arg \max_k P(y = k \mid X = x)$$

asignar cada x a su clase **más probable**.

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0.5$ en el caso binario); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es > 0 siempre que las clases se *traslapen*: individuos idénticos en X con resultados distintos.
- ¿Les suena? Es el **análogo exacto del σ^2 irreducible** de la sesión 1: el piso que ningún método puede perforar. Si el error de Bayes es 20%, exigirle 95% de acierto a un modelo es pedirle magia.

El clasificador de Bayes: el ideal inalcanzable

Si conociéramos las probabilidades verdaderas, la regla óptima (minimiza la tasa de error) es obvia:

$$\hat{y}^{Bayes}(x) = \arg \max_k P(y = k \mid X = x)$$

asignar cada x a su clase **más probable**.

- **Frontera de Bayes:** el conjunto donde hay empate ($p(x) = 0.5$ en el caso binario); a un lado se predice 1, al otro 0.
- **Error de Bayes:** el error de esta regla ideal. Es > 0 siempre que las clases se *traslapen*: individuos idénticos en X con resultados distintos.
- ¿Les suena? Es el **análogo exacto del σ^2 irreducible** de la sesión 1: el piso que ningún método puede perforar. Si el error de Bayes es 20%, exigirle 95% de acierto a un modelo es pedirle magia.

Todo lo que sigue, en una frase

Cada clasificador es una manera distinta de **estimar** $P(y \mid X)$ — o directamente la frontera — a partir de datos.

1 El problema de clasificación

2 Los clasificadores


3 Métricas: decidir con costos

4 Desbalanceo de clases

Regresión logística: el modelo

Modelar la probabilidad con una función que **viva en** $[0, 1]$:


$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$



Regresión logística: el modelo

Modelar la probabilidad con una función que **viva en** $[0, 1]$:

$$p(x) = \frac{e^{x'\beta}}{1 + e^{x'\beta}} \iff \underbrace{\log \frac{p(x)}{1 - p(x)}}_{\text{log-odds}} = x'\beta$$



- El índice $x'\beta$ es **lineal** (los log-odds son lineales) $\Rightarrow$ la frontera de decisión $p(x) = 0.5 \iff x'\beta = 0$ es un **hiperplano**.
- e^{β_j} : el *odds ratio* de una unidad extra de x_j — la interpretación que ya conocen de Econometría II.

Estimación: máxima verosimilitud y su gradiente

1. **La verosimilitud** de n observaciones independientes ($p_i \equiv p(x_i)$):

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right]$$

Estimación: máxima verosimilitud y su gradiente

1. **La verosimilitud** de n observaciones independientes ($p_i \equiv p(x_i)$):

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right]$$

2. **Derivamos** (usando $\frac{\partial}{\partial \beta} \log(1 + e^{x_i' \beta}) = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i)$$

Estimación: máxima verosimilitud y su gradiente

1. **La verosimilitud** de n observaciones independientes ($p_i \equiv p(x_i)$):

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right]$$

2. **Derivamos** (usando $\frac{\partial}{\partial \beta} \log(1 + e^{x_i' \beta}) = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i)$$

3. **Igualar a cero no tiene solución cerrada** (los p_i dependen de β no linealmente) $\Rightarrow$ se resuelve por Newton–Raphson (IRLS): iterar hasta converger.

Estimación: máxima verosimilitud y su gradiente

1. La **verosimilitud** de n observaciones independientes ($p_i \equiv p(x_i)$):

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] = \sum_{i=1}^n \left[y_i x_i' \beta - \log(1 + e^{x_i' \beta}) \right]$$

2. **Derivamos** (usando $\frac{\partial}{\partial \beta} \log(1 + e^{x_i' \beta}) = x_i p_i$):

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n x_i (y_i - p_i)$$

3. **Igualar a cero no tiene solución cerrada** (los p_i dependen de β no linealmente) $\Rightarrow$ se resuelve por Newton–Raphson (IRLS): iterar hasta converger.

- **Miren el gradiente:** “residuo” $y_i - p_i$ por regresor — la misma cantidad que el *boosting logístico* de la semana pasada ajustaba con árboles. No era coincidencia: era el gradiente.
- Y todo lo de las sesiones 2–3 aplica intacto: **logística penalizada L1/L2** con `glmnet` (familia binomial) para p grande.

k -NN: el clasificador sin modelo

La regla más simple posible: para clasificar x , mirar sus k vecinos más cercanos en los datos y **votar**:

$$\hat{p}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i$$

k -NN: el clasificador sin modelo

La regla más simple posible: para clasificar x , mirar sus k vecinos más cercanos en los datos y **votar**:

$$\hat{p}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i$$

- k es la **perilla de complejidad** (¡otra vez la curva U!): $k = 1$ memoriza (frontera rugosísima, varianza máxima); $k = n$ predice la clase mayoritaria siempre (sesgo máximo). Se elige por CV.
- Requiere **estandarizar** (distancias mezclan escalas) y es caro en predicción (buscar vecinos).

k -NN: el clasificador sin modelo

La regla más simple posible: para clasificar x , mirar sus k vecinos más cercanos en los datos y **votar**:

$$\hat{p}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i$$

- k es la **perilla de complejidad** (¡otra vez la curva U!): $k = 1$ memoriza (frontera rugosísima, varianza máxima); $k = n$ predice la clase mayoritaria siempre (sesgo máximo). Se elige por CV.
- Requiere **estandarizar** (distancias mezclan escalas) y es caro en predicción (buscar vecinos).

Su talón de Aquiles: la maldición de la dimensionalidad. En dimensión p , para capturar el 10% de los datos uniformes en un cubo se necesita un sub-cubo de lado

$$0.1^{1/p} : \quad p = 1 \rightarrow 0.10; \quad p = 10 \rightarrow 0.79; \quad p = 100 \rightarrow 0.98$$

k -NN: el clasificador sin modelo

La regla más simple posible: para clasificar x , mirar sus k vecinos más cercanos en los datos y **votar**:

$$\hat{p}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i$$

- k es la **perilla de complejidad** (¡otra vez la curva U!): $k = 1$ memoriza (frontera rugosísima, varianza máxima); $k = n$ predice la clase mayoritaria siempre (sesgo máximo). Se elige por CV.
- Requiere **estandarizar** (distancias mezclan escalas) y es caro en predicción (buscar vecinos).

Su talón de Aquiles: la maldición de la dimensionalidad. En dimensión p , para capturar el 10% de los datos uniformes en un cubo se necesita un sub-cubo de lado

$$0.1^{1/p} : \quad p = 1 \rightarrow 0.10; \quad p = 10 \rightarrow 0.79; \quad p = 100 \rightarrow 0.98$$

Con p moderadamente grande, los “vecinos más cercanos” **están lejísimos**: la localidad — el alma del método — muere. Moraleja: k -NN brilla con pocas dimensiones informativas; en alta dimensión, volver a los métodos con estructura (lineales regularizados, árboles).

LDA y Naive Bayes, en una diapositiva

El enfoque generativo: en vez de modelar $P(y \mid x)$ directamente (logística: *discriminativo*), modelar cómo se *generan* los datos de cada clase y voltear con Bayes:

$$P(y = k \mid x) \propto \pi_k f_k(x)$$

LDA y Naive Bayes, en una diapositiva

El enfoque generativo: en vez de modelar $P(y | x)$ directamente (logística: *discriminativo*), modelar cómo se *generan* los datos de cada clase y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x)$$

- **LDA** (análisis discriminante lineal): f_k = normal multivariada con **misma covarianza** por clase $\Rightarrow$ frontera lineal, como la logística. Gana cuando n es chico y la normalidad es razonable (usa más estructura); pierde robustez si no.

LDA y Naive Bayes, en una diapositiva

El enfoque generativo: en vez de modelar $P(y | x)$ directamente (logística: *discriminativo*), modelar cómo se *generan* los datos de cada clase y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x)$$

- **LDA** (análisis discriminante lineal): f_k = normal multivariada con **misma covarianza** por clase $\Rightarrow$ frontera lineal, como la logística. Gana cuando n es chico y la normalidad es razonable (usa más estructura); pierde robustez si no.
- **Naive Bayes**: supone los predictores **independientes dentro de cada clase**: $f_k(x) = \prod_j f_{kj}(x_j)$. El supuesto es heroico y falso... y aún así funciona sorprendentemente bien cuando p es enorme y los datos escasos.

LDA y Naive Bayes, en una diapositiva

El enfoque generativo: en vez de modelar $P(y | x)$ directamente (logística: *discriminativo*), modelar cómo se *generan* los datos de cada clase y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x)$$

- **LDA** (análisis discriminante lineal): f_k = normal multivariada con **misma covarianza** por clase $\Rightarrow$ frontera lineal, como la logística. Gana cuando n es chico y la normalidad es razonable (usa más estructura); pierde robustez si no.
- **Naive Bayes:** supone los predictores **independientes dentro de cada clase**: $f_k(x) = \prod_j f_{kj}(x_j)$. El supuesto es heroico y falso... y aún así funciona sorprendentemente bien cuando p es enorme y los datos escasos.
- ¿Dónde brilla NB? **Texto:** miles de palabras como predictores (el clásico filtro de spam). Guarden la idea para la sesión 9.

LDA y Naive Bayes, en una diapositiva

El enfoque generativo: en vez de modelar $P(y | x)$ directamente (logística: *discriminativo*), modelar cómo se *generan* los datos de cada clase y voltear con Bayes:

$$P(y = k | x) \propto \pi_k f_k(x)$$


- **LDA** (análisis discriminante lineal): f_k = normal multivariada con **misma covarianza** por clase $\Rightarrow$ frontera lineal, como la logística. Gana cuando n es chico y la normalidad es razonable (usa más estructura); pierde robustez si no.
- **Naive Bayes**: supone los predictores **independientes dentro de cada clase**: $f_k(x) = \prod_j f_{kj}(x_j)$. El supuesto es heroico y falso... y aún así funciona sorprendentemente bien cuando p es enorme y los datos escasos.
- ¿Dónde brilla NB? **Texto**: miles de palabras como predictores (el clásico filtro de spam). Guarden la idea para la sesión 9.

Mapa mental

Logística = discriminativo, pocos supuestos. LDA/NB = generativos, más supuestos = más eficiencia *si* los supuestos aguantan.


SVM: la intuición del margen máximo

Otra filosofía: no modelar probabilidades — buscar directamente el hiperplano que separa las clases con el **margen más ancho** posible.



SVM: la intuición del margen máximo


Otra filosofía: no modelar probabilidades — buscar directamente el hiperplano que separa las clases con el **margen más ancho** posible.



- Solo los puntos **sobre el margen** (los *vectores de soporte*, circulados) determinan la solución.
- **Soft margin** (C): permitir violaciones pagando un costo — la perilla de regularización, por CV.
- **Kernel trick**: reemplazar productos internos por $K(x, x')$ = separar en un espacio de dimensión altísima *sin construirlo* $\Rightarrow$ fronteras no lineales.

SVM: la intuición del margen máximo

Otra filosofía: no modelar probabilidades — buscar directamente el hiperplano que separa las clases con el **margen más ancho** posible.



- Solo los puntos **sobre el margen** (los *vectores de soporte*, circulados) determinan la solución.
- **Soft margin** (C): permitir violaciones pagando un costo — la perilla de regularización, por CV.
- **Kernel trick**: reemplazar productos internos por $K(x, x')$ = separar en un espacio de dimensión altísima *sin construirlo* $\Rightarrow$ fronteras no lineales.
- **Letra menuda**: el SVM entrega *scores*, no probabilidades calibradas.

1 El problema de clasificación

2 Los clasificadores

3 Métricas: decidir con costos

4 Desbalanceo de clases

Por qué la exactitud engaña

Escenario realista: en una encuesta de hogares, el 5% está en pobreza extrema. Entrenamos un clasificador para focalizar una transferencia.

Por qué la exactitud engaña

Escenario realista: en una encuesta de hogares, el 5% está en pobreza extrema. Entrenamos un clasificador para focalizar una transferencia.

Pregunta para la sala

El modelo “*nadie* es pobre extremo” tiene una exactitud del 95%. ¿Es un buen modelo?

Por qué la exactitud engaña

Escenario realista: en una encuesta de hogares, el 5% está en pobreza extrema. Entrenamos un clasificador para focalizar una transferencia.

Pregunta para la sala

El modelo “*nadie* es pobre extremo” tiene una exactitud del 95%. ¿Es un buen modelo?

Es **inútil**: no encuentra a una sola de las personas que el programa busca. Con clases desbalanceadas, la exactitud premia ignorar a la clase minoritaria — que casi siempre es *la que importa* (el moroso, el fraude, el hogar pobre, el desertor).

Por qué la exactitud engaña

Escenario realista: en una encuesta de hogares, el 5% está en pobreza extrema. Entrenamos un clasificador para focalizar una transferencia.

Pregunta para la sala

El modelo “*nadie* es pobre extremo” tiene una exactitud del 95%. ¿Es un buen modelo?

Es **inútil**: no encuentra a una sola de las personas que el programa busca. Con clases desbalanceadas, la exactitud premia ignorar a la clase minoritaria — que casi siempre es *la que importa* (el moroso, el fraude, el hogar pobre, el desertor).

- El problema no es del modelo sino de la **métrica**: la exactitud pesa cada error igual, y nuestros errores **no cuestan igual**.
- Necesitamos vocabulario para los *tipos* de error — y luego, precios para cada uno.

La matriz de confusión y su vocabulario

		Predicho +	Predicho -
Real	+	VP (verdadero positivo)	FN (falso negativo)
	-	FP (falso positivo)	VN (verdadero negativo)

La matriz de confusión y su vocabulario

		Predicho +	Predicho -
Real	+	VP (verdadero positivo)	FN (falso negativo)
	-	FP (falso positivo)	VN (verdadero negativo)

- **Sensibilidad / recall** = $\frac{VP}{VP+FN}$: de los positivos reales, ¿qué fracción encontré? (¿A cuántos pobres llegó el programa?)
- **Especificidad** = $\frac{VN}{VN+FP}$: de los negativos reales, ¿a cuántos dejé en paz?
- **Precisión** = $\frac{VP}{VP+FP}$: de mis alarmas, ¿cuántas eran ciertas? (¿Qué fracción del gasto llegó bien?)
- **F1** = $2 \frac{\text{prec} \cdot \text{recall}}{\text{prec} + \text{recall}}$: media armónica — castiga estar mal en cualquiera de las dos.

El umbral es una decisión económica (derivémoslo)

El modelo entrega $\hat{p}(x)$; la decisión exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.
¿Quién fija τ ? **Los costos.**

El umbral es una decisión económica (derivémoslo)

El modelo entrega $\hat{p}(x)$; la decisión exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.
¿Quién fija τ ? **Los costos.**

Sean c_{FP} y c_{FN} los costos de cada error. Para un individuo con probabilidad p :

1. **Costo esperado de predecir +:** $(1 - p) c_{FP}$ (me equivoco si era -)
2. **Costo esperado de predecir -:** $p c_{FN}$ (me equivoco si era +)

El umbral es una decisión económica (derivémoslo)

El modelo entrega $\hat{p}(x)$; la decisión exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.
¿Quién fija τ ? **Los costos.**

Sean c_{FP} y c_{FN} los costos de cada error. Para un individuo con probabilidad p :

1. **Costo esperado de predecir +:** $(1 - p) c_{FP}$ (me equivoco si era $-$)
2. **Costo esperado de predecir $-$:** $p c_{FN}$ (me equivoco si era $+$)
3. **Predecir + cuando** $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

El umbral es una decisión económica (derivémoslo)

El modelo entrega $\hat{p}(x)$; la decisión exige un **umbral** τ : predecir + si $\hat{p}(x) \geq \tau$.
¿Quién fija τ ? **Los costos.**

Sean c_{FP} y c_{FN} los costos de cada error. Para un individuo con probabilidad p :

1. **Costo esperado de predecir +:** $(1 - p) c_{FP}$ (me equivoco si era $-$)
2. **Costo esperado de predecir $-$:** $p c_{FN}$ (me equivoco si era $+$)
3. **Predecir + cuando** $(1 - p) c_{FP} \leq p c_{FN}$, es decir:

$$p \geq \tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Solo importa el **cociente** de costos. Errores igual de caros $\Rightarrow \tau^* = 0.5$ (la regla de Bayes). FN diez veces más caro $\Rightarrow \tau^* = 1/11 \approx 0.09$: alarma temprana.
- **La estadística estima p ; la economía pone c_{FP} y c_{FN} .** El umbral 0.5 por defecto de los paquetes es una decisión económica *implícita* — y casi nunca la correcta.

Dos mini-casos para calibrar la intuición

Caso 1 — Focalizar una transferencia contra la pobreza extrema:

- c_{FN} : excluir a un hogar pobre = costo humano y de misión del programa: **alto**.
- c_{FP} : incluir a un no-pobre = filtración fiscal: real, pero menor.
- $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. (Y medir la filtración con la *precisión*.)

Dos mini-casos para calibrar la intuición

Caso 1 — Focalizar una transferencia contra la pobreza extrema:

- c_{FN} : excluir a un hogar pobre = costo humano y de misión del programa: **alto**.
- c_{FP} : incluir a un no-pobre = filtración fiscal: real, pero menor.
- $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. (Y medir la filtración con la *precisión*.)

Caso 2 — Aprobar un crédito:

- Aquí el “positivo” es *impago*. c_{FN} : prestarle a quien impaga = pérdida de capital: **alta**.
- c_{FP} : negarle a un buen pagador = margen no ganado: menor.
- $\Rightarrow \tau^*$ **bajo también** — aunque los bancos lo calibran sobre la **ganancia esperada** de la cartera completa.

Dos mini-casos para calibrar la intuición

Caso 1 — Focalizar una transferencia contra la pobreza extrema:

- c_{FN} : excluir a un hogar pobre = costo humano y de misión del programa: **alto**.
- c_{FP} : incluir a un no-pobre = filtración fiscal: real, pero menor.
- $\Rightarrow \tau^*$ **bajo**: ante la duda, incluir. (Y medir la filtración con la *precisión*.)

Caso 2 — Aprobar un crédito:


- Aquí el “positivo” es *impago*. c_{FN} : prestarle a quien impaga = pérdida de capital: **alta**.
- c_{FP} : negarle a un buen pagador = margen no ganado: menor.
- $\Rightarrow \tau^*$ **bajo también** — aunque los bancos lo calibran sobre la **ganancia esperada** de la cartera completa.

El patrón general

Mismo modelo, distinta economía $\Rightarrow$ distinto umbral. Reportar “exactitud” sin discutir costos es esconder la decisión.


La curva ROC: todos los umbrales a la vez

Barriendo τ de 1 a 0 y graficando (tasa de FP, tasa de VP) en cada punto:



La curva ROC: todos los umbrales a la vez

Barriendo τ de 1 a 0 y graficando (tasa de FP, tasa de VP) en cada punto:



- La ROC muestra el **menú completo** de intercambios FP–VP; cada punto es un umbral.
- **AUC** (área bajo la curva): 0.5 = azar, 1 = perfecto. Interpretación exacta: *la probabilidad de que un positivo aleatorio reciba mayor score que un negativo aleatorio.*
- Por eso el AUC compara **modelos** sin fijar umbral — y por eso **no** sustituye

Dos letras menudas que salvan análisis

1. Con desbalance fuerte, la ROC luce optimista.


- La tasa de FP divide por los negativos, que son *muchísimos*: miles de falsas alarmas apenas la mueven.
- Alternativa: la curva **precisión–recall** (PR), que no usa los VN: muestra cruda la calidad de las alarmas con positivos raros. Desbalance fuerte $\Rightarrow$ reportar ambas.

Dos letras menudas que salvan análisis

1. Con desbalance fuerte, la ROC luce optimista.

- La tasa de FP divide por los negativos, que son *muchísimos*: miles de falsas alarmas apenas la mueven.
- Alternativa: la curva **precisión–recall** (PR), que no usa los VN: muestra cruda la calidad de las alarmas con positivos raros. Desbalance fuerte $\Rightarrow$ reportar ambas.

2. ¿ $\hat{p} = 0.8$ significa 80%? Eso es la calibración.




Dos letras menudas que salvan análisis

1. Con desbalance fuerte, la ROC luce optimista.

- La tasa de FP divide por los negativos, que son *muchísimos*: miles de falsas alarmas apenas la mueven.
- Alternativa: la curva **precisión–recall** (PR), que no usa los VN: muestra cruda la calidad de las alarmas con positivos raros. Desbalance fuerte $\Rightarrow$ reportar ambas.

2. ¿ $\hat{p} = 0.8$ significa 80%? Eso es la calibración.



- Descalibrado $\Rightarrow$ el umbral de costos τ^* sobre $\hat{p}$ decide mal. La logística suele salir calibrada; boosting y SVM, no $\Rightarrow$ recalibrar (Platt/isotónica) en validación.

- 1 El problema de clasificación
- 2 Los clasificadores
- 3 Métricas: decidir con costos
- 4 Desbalanceo de clases

El problema, y el arsenal de remedios

El problema: con 2% de impagos, la pérdida agregada apenas nota a la clase minoritaria: el modelo optimiza ignorándola.

El problema, y el arsenal de remedios

El problema: con 2% de impagos, la pérdida agregada apenas nota a la clase minoritaria: el modelo optimiza ignorándola.

Los remedios, del más simple al más elaborado:

- ➊ **Pesos en la pérdida** (*class weights*): multiplicar el costo de los errores en la clase rara. Sin tocar los datos; disponible en casi todo (`glmnet`, `ranger`, `xgboost`).

El problema, y el arsenal de remedios

El problema: con 2% de impagos, la pérdida agregada apenas nota a la clase minoritaria: el modelo optimiza ignorándola.

Los remedios, del más simple al más elaborado:

- ➊ **Pesos en la pérdida** (*class weights*): multiplicar el costo de los errores en la clase rara. Sin tocar los datos; disponible en casi todo (`glmnet`, `ranger`, `xgboost`).
- ➋ **Submuestrear** la clase mayoritaria: rápido, pero tira datos.
- ➌ **Sobremuestrear** la minoritaria (duplicar): no inventa nada, pero invita al sobreajuste sobre copias.

El problema, y el arsenal de remedios

El problema: con 2% de impagos, la pérdida agregada apenas nota a la clase minoritaria: el modelo optimiza ignorándola.

Los remedios, del más simple al más elaborado:

- ➊ **Pesos en la pérdida** (*class weights*): multiplicar el costo de los errores en la clase rara. Sin tocar los datos; disponible en casi todo (glmnet, ranger, xgboost).
- ➋ **Submuestrear** la clase mayoritaria: rápido, pero tira datos.
- ➌ **Sobremuestrear** la minoritaria (duplicar): no inventa nada, pero invita al sobreajuste sobre copias.
- ➍ **SMOTE** (Chawla et al., 2002): crear ejemplos *sintéticos* de la clase rara interpolando entre vecinos: $x_{new} = x_i + u \cdot (x_{nn} - x_i)$, $u \sim U(0, 1)$.

El problema, y el arsenal de remedios

El problema: con 2% de impagos, la pérdida agregada apenas nota a la clase minoritaria: el modelo optimiza ignorándola.

Los remedios, del más simple al más elaborado:

- ➊ **Pesos en la pérdida** (*class weights*): multiplicar el costo de los errores en la clase rara. Sin tocar los datos; disponible en casi todo (glmnet, ranger, xgboost).
- ➋ **Submuestrear** la clase mayoritaria: rápido, pero tira datos.
- ➌ **Sobremuestrear** la minoritaria (duplicar): no inventa nada, pero invita al sobreajuste sobre copias.
- ➍ **SMOTE** (Chawla et al., 2002): crear ejemplos *sintéticos* de la clase rara interpolando entre vecinos: $x_{new} = x_i + u \cdot (x_{nn} - x_i)$, $u \sim U(0, 1)$.

Las dos advertencias no negociables

(i) Todo remuestreo ocurre **solo en el entrenamiento, dentro de cada fold** — remuestrear antes de partir es *leakage* de manual (regla de oro #3). (ii) Remuestrear **distorsiona las probabilidades** ($\hat{p}$ queda inflada): recalibrar antes de usar umbrales de costos.

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *rankea* bien (AUC decente) y está calibrado, ¿necesitábamos remuestrear?

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *rankea* bien (AUC decente) y está calibrado, ¿necesitábamos remuestrear?

- Muchas veces **no**: mover el umbral τ^* según costos logra lo mismo que el remuestreo — con probabilidades honestas y sin cirugía sobre los datos.
- El remuestreo/pesos ayuda de verdad cuando la clase rara es *tan* rara que el modelo ni aprende su estructura (el algoritmo nunca ve suficientes positivos en cada corte/paso).

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *rankea* bien (AUC decente) y está calibrado, ¿necesitábamos remuestrear?

- Muchas veces **no**: mover el umbral τ^* según costos logra lo mismo que el remuestreo — con probabilidades honestas y sin cirugía sobre los datos.
- El remuestreo/pesos ayuda de verdad cuando la clase rara es *tan* rara que el modelo ni aprende su estructura (el algoritmo nunca ve suficientes positivos en cada corte/paso).

El flujo del practicante:

- 1 Entrenar normal + evaluar con ROC y PR (nunca exactitud sola).
- 2 Calibrar; decidir con τ^* de costos.
- 3 ¿Aún mal en recall/precisión? Probar pesos de clase; SMOTE de último recurso.
- 4 Y siempre: CV **estratificado** (cada fold conserva la proporción de clases).

¿Remuestrear... o simplemente decidir mejor?

La pregunta incómoda: si el modelo *rankea* bien (AUC decente) y está calibrado, ¿necesitábamos remuestrear?

- Muchas veces **no**: mover el umbral τ^* según costos logra lo mismo que el remuestreo — con probabilidades honestas y sin cirugía sobre los datos.
- El remuestreo/pesos ayuda de verdad cuando la clase rara es *tan* rara que el modelo ni aprende su estructura (el algoritmo nunca ve suficientes positivos en cada corte/paso).

El flujo del practicante:

- 1 Entrenar normal + evaluar con ROC y PR (nunca exactitud sola).
- 2 Calibrar; decidir con τ^* de costos.
- 3 ¿Aún mal en recall/precisión? Probar pesos de clase; SMOTE de último recurso.
- 4 Y siempre: CV **estratificado** (cada fold conserva la proporción de clases).

Para la aplicación de esta semana

Focalización de pobreza extrema: logística vs. k -NN vs. SVM, comparados por

Recap

- 1 El ideal es el **clasificador de Bayes**; su error es el σ^2 de la clasificación. Todo método estima $P(y | x)$ o su frontera.
- 2 **Logística**: log-odds lineales, MV sin forma cerrada, gradiente $\sum x_i(y_i - p_i)$; se regulariza con todo lo de las sesiones 2–3. **k-NN**: local y sin modelo, muere en alta dimensión. **LDA/NB**: generativos, eficientes bajo supuestos. **SVM**: margen máximo + kernels, scores sin calibrar.
- 3 La **exactitud engaña** con desbalance; el vocabulario correcto es la matriz de confusión (recall, precisión, F1).
- 4 **El umbral es economía**: $\tau^* = c_{FP} / (c_{FP} + c_{FN})$. La ROC/AUC compara modelos sin umbral; la PR es más honesta con clases raras; nada funciona sin **calibración**.
- 5 **Desbalanceo**: pesos $\rightarrow$ remuestreo $\rightarrow$ SMOTE, siempre dentro del fold y recalibrando; a menudo basta decidir mejor con el umbral.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 4 (secs. 4.1–4.4) y cap. 9 (secs. 9.1–9.3).
Guía: logística y LDA en el 4; la intuición del margen en el 9.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5; es el manual de la curva ROC.

Recomendadas: Chawla et al. (2002, SMOTE); ESL cap. 4.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 4 (secs. 4.1–4.4) y cap. 9 (secs. 9.1–9.3).
Guía: logística y LDA en el 4; la intuición del margen en el 9.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5; es el manual de la curva ROC.

Recomendadas: Chawla et al. (2002, SMOTE); ESL cap. 4.

Próxima sesión — el cierre del puente: *machine learning para inferencia causal*. Double/debiased ML y *causal forests*: la predicción al servicio de un β creíble. Lectura previa: Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About* (skim generoso). Con eso, la mitad de la sesión ya estará ganada.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 4 (secs. 4.1–4.4) y cap. 9 (secs. 9.1–9.3).
Guía: logística y LDA en el 4; la intuición del margen en el 9.
- Fawcett (2006), *An Introduction to ROC Analysis*.
Guía: secciones 1–5; es el manual de la curva ROC.

Recomendadas: Chawla et al. (2002, SMOTE); ESL cap. 4.

Próxima sesión — el cierre del puente: *machine learning para inferencia causal*. Double/debiased ML y *causal forests*: la predicción al servicio de un β creíble. Lectura previa: Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About* (skim generoso). Con eso, la mitad de la sesión ya estará ganada.

Aplicación de esta semana en R: clasificar hogares en pobreza extrema (encuesta de hogares): logística, k -NN y SVM por AUC, umbral por costos y curvas PR — `tidymodels`.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 4 y 9. [ISLR]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Cap. 4. [ESL]
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297.
- Platt, J. (1999). Probabilistic Outputs for Support Vector Machines. En *Advances in Large Margin Classifiers*.
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot on Imbalanced Datasets. *PLOS ONE*, 10(3).