

Big Data y Machine Learning para Economía Aplicada

Week 05: Árboles, bosques y *boosting*: partir, promediar y corregir

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 25, 2026

Previously...

- **Semana 3, el juez y la perilla:** la validación cruzada elige sin tocar la prueba; la penalización encoge y apaga. Para que la relación cambiara de un departamento a otro escribimos a mano 1.291 columnas (cada variable de la ficha, departamento por departamento); el Lasso se quedó con 202 y dejó el error de prueba en 14,7 puntos.
- **Semana 4, la probabilidad y la decisión:** con esas mismas columnas, el Lasso logístico ordena los puestos con AUC 0,937. Con los costos de la campaña (5 a 1), el umbral es 0,83 y el costo, 643.
- **El mapa, en las dos:** sin mirar el censo, los 7 vecinos más cercanos predicen el voto con 12,0 puntos de error, y los 14 más cercanos ordenan con AUC 0,945.

Lo que traemos

Dos ligas que no se tocan: la **estructura** (cómo es el puesto: el censo, con las interacciones que escribimos nosotros) y el **lugar** (dónde queda: sus vecinos). El lugar gana en las dos preguntas.

La pregunta de hoy: ¿puede el modelo encontrar solo dónde cambia la relación?

Los mismos puestos, las mismas dos preguntas; cambia quién escribe la flexibilidad

- **Lo que hicimos a mano:** en la semana 3 elegimos nosotros *con qué* cruzar cada variable (el departamento) y *cómo* (una pendiente propia). ¿Y si la educación pesa distinto en lo rural? Con 37 variables hay 666 cruces de a dos y 7.770 de a tres: nadie los escribe.
- **La idea de hoy:** partir los puestos en grupos parecidos y predecir con el promedio de cada grupo. Un corte dentro de otro es una interacción que nadie escribió.
- **Una familia, tres métodos:** el **árbol** parte, el **bosque** promedia cientos de árboles y el *boosting* suma árboles pequeños que corrigen al anterior. Sirven para las dos preguntas.

La idea con la que se van

Partir, promediar y corregir. Un árbol encuentra solo las interacciones, pero es inestable; promediarlo (bosques) o corregirlo de a poco (*boosting*) lo vuelve el mejor modelo del curso.

- 1 El árbol: partir y promediar
- 2 El bosque: promediar para bajar la varianza
- 3 El *boosting*: aprender despacio
- 4 La carrera: ¿encontró la máquina las interacciones?
- 5 Cierre

Volvamos a Cali: ¿y si en vez de una recta, partimos?

Diez puestos de entrenamiento del área metropolitana, al azar, ordenados por educación superior

Puesto	Municipio	Educ. sup. (%)	Voto (%)	RSS si se corta debajo
La Dolores	Palmira	6,3	67,0	638
Ayacucho La Buitrera	Palmira	7,5	67,4	624
Escuela Bartolomé Loboguerrero	Cali	7,8	72,8	547
La Castilla	Cali	9,4	74,1	401
Liceo Técnico Comercial Litecom	Jamundí	10,5	64,2	411
Esc. Nuestra Señora de los Remedios	Cali	11,6	58,7	501
IE Mater Dei	Palmira	14,5	63,4	495
IE José Celestino Mutis	Cali	16,7	72,0	237
Pance La Vorágine	Cali	29,8	55,9	316
Inst. Univ. Antonio José Camacho	Cali	42,4	47,0	

Sin cortar, la mejor constante es la media y lo que falta por explicar es su RSS: 646. **Un corte** parte los puestos en dos y cada lado usa su propia media. Con diez puestos hay nueve cortes posibles.

Pregunta para la sala: ¿dónde cortarían?

Volvamos a Cali: ¿y si en vez de una recta, partimos?

Diez puestos de entrenamiento del área metropolitana, al azar, ordenados por educación superior

Puesto	Municipio	Educ. sup. (%)	Voto (%)	RSS si se corta debajo
La Dolores	Palmira	6,3	67,0	638
Ayacucho La Buitrera	Palmira	7,5	67,4	624
Escuela Bartolomé Loboguerrero	Cali	7,8	72,8	547
La Castilla	Cali	9,4	74,1	401
Liceo Técnico Comercial Litecom	Jamundí	10,5	64,2	411
Esc. Nuestra Señora de los Remedios	Cali	11,6	58,7	501
IE Mater Dei	Palmira	14,5	63,4	495
IE José Celestino Mutis	Cali	16,7	72,0	237
Pance La Vorágine	Cali	29,8	55,9	316
Inst. Univ. Antonio José Camacho	Cali	42,4	47,0	



Sin cortar, la mejor constante es la media y lo que falta por explicar es su RSS: 646. **Un corte** parte los puestos en dos y cada lado usa su propia media. Con diez puestos hay nueve cortes posibles.

Pregunta para la sala: ¿dónde cortarían?

En 23,3 %: los 8 de menos educación (media 67,4) y los 2 de más (51,5); el RSS baja de 646 a 237. El RSS tiene dos valles: el otro, en 9,9 % (401).

El mismo corte con los 257 puestos


La máquina hace la misma cuenta en todos los cortes posibles y se queda con el que más baja el RSS



- El mejor corte cae en 17,9 % de educación superior: 192 puestos a la izquierda, con voto medio de 73,9, y 65 a la derecha, con 55,0. El RSS baja 45 %, de 38,1 mil a 20,8 mil.
- La recta de la semana 2 deja 13,7 mil: con una sola variable y una relación casi recta, un corte no alcanza. ¿Y si cortamos otra vez?

Cortar otra vez: una escalera

Cada mitad se vuelve a partir con la misma regla. En rojo, el árbol; punteada, la recta



- Con 2, 8 y 17 hojas, el error dentro de muestra baja (9,0, 6,6 y 6,2); el de prueba baja y vuelve a subir (8,4, 7,1 y 7,5), sin llegar al de la recta (6,8). En Cali la relación es casi recta, y la escalera la imita con peldaños que se estiman con pocos puestos cada uno.
- En la semana 2 los escalones los pusimos a mano; el árbol los pone solo, donde más baja el RSS. El juez (10 pliegues) elige 6 hojas: 7,4 en la prueba.

El modelo: una constante por región

Partir el espacio de las x en rectángulos y predecir con el promedio de cada uno (ISL, sección 8.1.1)

$$\hat{f}(x) = \sum_{m=1}^M c_m \mathbb{I}\{x \in R_m\} \quad \text{con } R_1, \dots, R_M \text{ que minimicen el RSS}$$



- Dentro de cada región la mejor constante es la media, $\hat{c}_m = \bar{y}_{R_m}$: la cuenta de la semana 2, repetida en cada pedazo.
- **El problema:** las particiones posibles no se pueden enumerar. **La salida:** un corte a la vez. Para cada variable j y cada umbral s , las dos mitades $R_1 = \{x : x_j < s\}$ y $R_2 = \{x : x_j \geq s\}$, y el corte que minimiza

$$\min_{j, s} \sum_{i: x_i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2} (y_i - \bar{y}_{R_2})^2$$

- Se parte por el mejor (j, s) y se repite dentro de cada mitad, hasta que las hojas quedan pequeñas. En la raíz del país hay 208.236 cortes candidatos (37 variables con sus umbrales): se prueban todos.
- **Codicioso:** el mejor corte *ahora*, no el mejor árbol. Es el paso a paso de la semana 3, con cortes en vez de variables.

Partir el mapa: el árbol y sus rectángulos


Un árbol sobre la longitud y la latitud del país: el mismo modelo en dos dibujos (ISL, figura 8.3)



- Cinco rectángulos, cinco promedios; la franja del Pacífico y Nariño sale sola (86,0). Error de prueba: 19,2, menos que la recta con las 37 variables del censo (19,8).
- El k -NN promedia los vecinos de cada puesto (un círculo que se mueve con él); el árbol, rectángulos fijos que eligen los datos. Podado por el juez: 427 hojas y 13,7; el k -NN, 12,0.

Un corte dentro de otro: así aparecen las interacciones

El árbol del país con la ficha de 37, en seis hojas: nadie le dijo dónde está el Pacífico



- **El primer corte** es la población afro: los 2.094 puestos con 4,6 % o más votaron en promedio 71,2 por Petro; los otros 7.508, 47,3.
- **Un corte dentro de otro es una interacción:** el estrato 2 y el gas sólo aparecen en la rama con poca población afro y casi nada de indígena; ahí separan puestos de voto muy distinto, y en las otras ramas no se usan. Nadie escribió ese cruce.
- **Cortar dos veces la misma variable es una no linealidad:** la población indígena corta dos veces ($\text{indígena} < 0,05 \%$ y $\text{indígena} < 17,2 \%$).

Para gana_petro: la hoja da una probabilidad

Árboles de clasificación: el mismo corte, con otra medida de lo que falta (ISL, sección 8.1.2)


- En cada hoja, la fracción de puestos que ganó Petro, $\hat{p}$, es la probabilidad de la semana 4; con los costos, se decide con τ^* .
- El corte se elige por la **impureza** de las dos mitades, ponderada por su tamaño:

$$\text{error: } E = 1 - \max(\hat{p}, 1 - \hat{p})$$

$$\text{Gini: } G = 2 \hat{p} (1 - \hat{p})$$

$$\text{entropía: } D = -\hat{p} \log \hat{p} - (1 - \hat{p}) \log(1 - \hat{p})$$

- En la raíz, $\hat{p} = 0,53$ y $G = 0,498$. El primer corte (afro en 1,4 %) deja 0,41 por debajo y 0,75 por encima: el Gini ponderado baja a 0,444; el error, de 0,468 a 0,353.




Por qué Gini o entropía para crecer: son curvas y premian las hojas más puras aunque la clase mayoritaria no cambie; el error es recto a trozos y no ve esos cortes. Para podar, si lo que importa es acertar, el error (ISL).

¿Hasta dónde crecer? El árbol también se sobreajusta

La poda por costo-complejidad: un precio por hoja, que elige el juez (ISL, algoritmo 8.1)

$$\min_{T \subseteq T_0} \sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \bar{y}_{R_m})^2 + \alpha |T|$$



- Crecido hasta hojas de 7 puestos, el árbol de la ficha tiene 819 hojas: 11,9 de error dentro de muestra y 20,0 en la prueba (regla de oro #1).
- α es el precio de cada hoja, como el λ del Lasso: con $\alpha = 0$, el árbol completo; con α grande, la raíz. Se poda el eslabón más débil.
- El juez (los 10 pliegues de la semana 3) elige 105 hojas: 19,1 en la prueba; con un error estándar, 63 (19,4).

Árboles contra rectas

Cuál gana depende de la forma de la relación (ISL, sección 8.1.3)

RMSE de prueba	La recta (OLS)	Un árbol podado
Cali y su área, educación superior	6,8	7,4 (6 hojas)
El país, la ficha de 37	19,8	19,1 (105 hojas)
El país, ficha + departamento	15,6	15,7 (98 hojas)

- **Si la relación es casi lineal** (Cali), gana la recta: la escalera la imita con peldaños caros. **Si hay umbrales y cruces** (el país), el árbol empata o gana por poco, sin que le escribamos nada.
- **A favor** (ISL, sección 8.1.4): se explica mejor que una regresión y se dibuja. Usa las cualitativas enteras: con ficha y departamento, el primer corte junta a los 33 departamentos en dos bloques (16 con voto medio de 32,7 y 17 con 68,3), sin *dummies* (apéndice A4).
- **En contra**: no predice mejor que un buen modelo lineal, y es **inestable**: un cambio pequeño en los datos cambia el árbol.

Un árbol solo casi nunca gana. Su fuerza es ser la pieza de algo más grande.

El problema del árbol: su varianza

Veinte remuestras *bootstrap* del entrenamiento, con el precio por hoja que eligió el juez

- **El primer corte es estable:** la población afro en 20 de los 20 árboles. **Lo de abajo cambia:** ya en el segundo nivel hay 2 combinaciones distintas de variables.
- **La predicción se mueve:** la de un puesto cambia 9,2 puntos de un árbol a otro (la mediana de su desviación estándar). La del Lasso de la semana 3, en el mismo ejercicio, se movía 1,4.
- **Cada árbol, solo,** tiene entre 20,1 y 20,9 de error de prueba. **El promedio de los veinte:** 17,3.

La salida

Si cada árbol es ruidoso y los ruidos no son idénticos, promediarlos cancela parte del ruido. Es la idea del bosque.

- 1 El árbol: partir y promediar
- 2 El bosque: promediar para bajar la varianza
- 3 El *boosting*: aprender despacio
- 4 La carrera: ¿encontró la máquina las interacciones?
- 5 Cierre

Bagging: promediar árboles hechos sobre remuestras

Bootstrap aggregation (Breiman, 1996; ISL, sección 8.2.1)

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$


- Cada $\hat{f}^{*b}$ es un árbol **hondo** (hojas de 5 puestos, sin podar) ajustado sobre una remuestra *bootstrap*: poco sesgo, mucha varianza. Promediar no toca el sesgo y baja la varianza.
- Si los B árboles fueran independientes, con varianza σ^2 cada uno, el promedio tendría σ^2/B . No lo son: salen de los mismos datos. Con correlación ρ entre dos árboles,

$$\text{Var}\left(\frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)\right) = \rho \sigma^2 + \frac{1-\rho}{B} \sigma^2 \quad (\text{apéndice A1})$$

- El segundo término se va con más árboles; el primero no: **el piso lo pone qué tan parecidos son los árboles**.
- Para `gana_petro`, cada árbol vota y la probabilidad es la fracción de votos.

Árboles malos, promedio bueno

El error contra el número de árboles promediados, con las mismas 37 columnas (ISL, figura 8.8)



- Un árbol hondo solo: 23,1 en la prueba, peor que el podado (19,1). El promedio de 10: 16,7. El de 300: 15,8. Las mismas columnas en una recta: 19,8.
- B no sobreajusta: más árboles nunca empeoran el promedio; se ponen los suficientes para que la curva se aplane.

El bosque aleatorio: prohibir variables para descorrelacionar

En cada corte, sólo m de las p variables pueden competir (Breiman, 2001; ISL, sección 8.2.2)

- Con *bagging*, la variable fuerte corta arriba en casi todos los árboles (la población afro fue la raíz en 20 de 20 remuestras): los árboles se parecen y ρ es alto.
- El bosque sortea m variables en cada corte ($m \approx p/3$ en regresión, $\sqrt{p}$ en clasificación). A veces la fuerte no está, y otras tienen su oportunidad.
- **La correlación entre dos árboles** (entre sus predicciones en la prueba) baja de 0,58 con *bagging* ($m = 37$) a 0,54 con $m = 12$. Cada árbol empeora (de 23,4 a 23,8) y el promedio mejora (de 15,8 a 15,6).

Pregunta para la sala

¿Cómo puede mejorar el promedio si cada árbol empeora?

El bosque aleatorio: prohibir variables para descorrelacionar

En cada corte, sólo m de las p variables pueden competir (Breiman, 2001; ISL, sección 8.2.2)

- Con *bagging*, la variable fuerte corta arriba en casi todos los árboles (la población afro fue la raíz en 20 de 20 remuestras): los árboles se parecen y ρ es alto.
- El bosque sortea m variables en cada corte ($m \approx p/3$ en regresión, $\sqrt{p}$ en clasificación). A veces la fuerte no está, y otras tienen su oportunidad.
- **La correlación entre dos árboles** (entre sus predicciones en la prueba) baja de 0,58 con *bagging* ($m = 37$) a 0,54 con $m = 12$. Cada árbol empeora (de 23,4 a 23,8) y el promedio mejora (de 15,8 a 15,6).

Pregunta para la sala

¿Cómo puede mejorar el promedio si cada árbol empeora?

Porque el piso del promedio es $\rho \sigma^2$: se sacrifica un poco de cada árbol a cambio de árboles menos parecidos. Aquí la ganancia es pequeña; con muchas variables correlacionadas entre sí, es grande.

El juez gratis: el error fuera de la bolsa

Cada remuestra deja por fuera a cerca de un tercio de los puestos (ISL, sección 8.2.1)


- Una remuestra *bootstrap* deja por fuera, en promedio, al 36,8 % de los puestos: la cuenta de la semana 3, $(1 - 1/n)^n \rightarrow e^{-1}$. Con 300 árboles, cada puesto queda fuera de la bolsa en unos 110.
- **La predicción fuera de la bolsa** de un puesto promedia sólo los árboles que no lo vieron: es honesta, como la de un pliegue.
- Con $m = 12$: 15,9 fuera de la bolsa y 15,6 en la prueba. Sin pliegues ni reajustes, el bosque trae su propio juez; con B grande, se parece al LOOCV.

Regla de oro #3, otra vez

El error fuera de la bolsa valida el bosque, no lo que se hizo *antes* de él: si las variables se eligieron mirando todos los datos, también miente.

La perilla del bosque: cuántas variables por corte


m se elige con el error fuera de la bolsa; el bosque es poco sensible a ella



- $m = 1$, cada corte con una variable al azar: los árboles casi no se parecen (correlación 0,36) pero son muy malos (25,6 cada uno); el bosque, 18,4.
- $m = 37$, el *bagging*: los mejores árboles y los más parecidos. En el medio hay una meseta (el mejor fuera de la bolsa, $m = 25$): por eso el bosque funciona casi sin afinar. Las otras perillas: el tamaño mínimo de la hoja y B .

Lo que el bosque no hace: salirse de los datos

La extrapolación de la semana 2, otra vez: un bosque con la educación superior del área metropolitana



- La predicción de un bosque es un promedio de votos de entrenamiento: nunca sale de $[15,4; 93,5]$. Más allá del puesto más educado (58,1 %) es plana: en 80 %, 26,6. La recta sigue su tendencia (19,9) y la cúbica se desploma ($-31,2$). Nadie sabe qué pasa en 80 %; el bosque, al menos, no inventa.
- Tampoco dibuja curvas suaves (las aproxima con escalones) y pierde el diagrama: 300 árboles no se leen. La semana 6 abre esa caja.

- 1 El árbol: partir y promediar
- 2 El bosque: promediar para bajar la varianza
- 3 El *boosting*: aprender despacio
- 4 La carrera: ¿encontró la máquina las interacciones?
- 5 Cierre


Otra idea: que cada árbol corrija al anterior

Boosting para regresión (ISL, algoritmo 8.2)

- ➊ Arrancar en la media: $\hat{f}(x) = \bar{y}$ y $r_i = y_i - \bar{y}$ para todo i (ISL arranca en 0; da lo mismo).
 - ➋ Para $b = 1, 2, \dots, B$:
 - ➊ ajustar un árbol pequeño $\hat{f}^b$, de d cortes, a los **residuos** (x_i, r_i) ;
 - ➋ sumarlo encogido: $\hat{f}(x) \leftarrow \hat{f}(x) + \lambda \hat{f}^b(x)$;
 - ➌ actualizar los residuos: $r_i \leftarrow r_i - \lambda \hat{f}^b(x_i)$.
 - ➌ El modelo final: $\hat{f}(x) = \bar{y} + \sum_{b=1}^B \lambda \hat{f}^b(x)$.
- **Bosque y boosting, al revés:** el bosque promedia árboles hondos, cada uno por su lado (baja la varianza); el *boosting* suma árboles pequeños, en fila, y cada uno mira lo que los anteriores no explicaron (baja el sesgo, de a poco).
 - λ , la tasa de aprendizaje (η en xgboost), encoge cada árbol: aprender despacio deja que muchos árboles distintos ataquen el residuo.

Aprender despacio, en Cali

El algoritmo 8.2 a mano: tocones (un solo corte) sobre la educación superior, con $\lambda = 0,1$



- Con un tocón, casi la media; con 10, un escalón tímido; con 50, la forma; con 500, una escalera fina que persigue los puntos.
- El error dentro de muestra sólo baja (de 11,6 a 6,4). El de prueba toca fondo en 7,1 (ronda 48) y en la 500 va en 7,3: **a diferencia del bosque, B sí sobreajusta.**
- Con tocones, cada árbol usa una sola variable: el modelo es **aditivo**, una curva por variable y ningún cruce.

El residuo es un gradiente

Por qué el mismo algoritmo sirve para `voto_petro` y para `gana_petro`

- **Pérdida cuadrática**, $L_i = \frac{1}{2}(y_i - f(x_i))^2$: su derivada, con el signo cambiado, es el residuo,

$$-\frac{\partial L_i}{\partial f(x_i)} = y_i - f(x_i) = r_i.$$

Ajustar un árbol al residuo es dar un paso de **descenso por gradiente**, no en los parámetros sino en la función; λ es el tamaño del paso.

- **La log-loss de la semana 4**, con f en la escala de los log-odds y $\hat{p}_i = e^{f(x_i)} / (1 + e^{f(x_i)})$:


$$-\frac{\partial L_i}{\partial f(x_i)} = y_i - \hat{p}_i.$$

Es el término de la condición de primer orden de la logística, $\sum_i x_i (y_i - \hat{p}_i) = 0$: el *boosting* para `gana_petro` ajusta árboles a lo que la probabilidad todavía no explica.

- Cualquier pérdida derivable sirve (Friedman, 2001; apéndice A2). `xgboost` usa además la segunda derivada y un precio por hoja (apéndice A3).

Las perillas del *boosting*: cuántas rondas y qué tan rápido

La ficha de 37 con $d = 6$: el juez (izquierda) contra el error dentro de muestra (derecha)



- **B , las rondas:** dentro de muestra el error siempre baja; el juez tiene un mínimo y ahí se para (*parada temprana*). Con $\eta = 0,3$ el mínimo llega en la ronda 58 (17,1) y después sube: 17,3 en la 2.000.
- **η , la tasa:** con 0,05 el mínimo llega más tarde (ronda 1.167) y más abajo (15,8). Más lento es mejor, como el encogimiento de Ridge; el precio es tiempo.
- **d , la profundidad:** cuántas variables puede cruzar cada árbol. La parte 4 mide cuánto vale.

Tres modelos, sus perillas y su juez

Lo que hay que decidir en cada uno, y quién lo decide


	Árbol	Bosque	Boosting
Qué hace	parte y promedia en cada hoja	promedia árboles hondos sobre remuestras	suma árboles pequeños sobre el residuo
Qué baja	—	la varianza	el sesgo, de a poco
Perillas	α , el precio por hoja	m ; el tamaño de la hoja; B , que no sobreajusta	B , que sí sobreajusta; η ; d ; el submuestreo
El juez	la CV	el error fuera de la bolsa	la CV, con parada temprana
Hoy	α por CV	$m \approx p/3$; hojas de 5	$\eta = 0,05$; $d = 6$; 80 % de filas y de columnas por árbol
En R	rpart	randomForest	xgboost

Todos ven las mismas particiones: los 10 pliegues de la semana 3 y la prueba de siempre, abierta una vez (apéndice A6).

- 1 El árbol: partir y promediar
- 2 El bosque: promediar para bajar la varianza
- 3 El *boosting*: aprender despacio
- 4 La carrera: ¿encontró la máquina las interacciones?
- 5 Cierre

¿Cuánto valen las interacciones?

El mismo *boosting* con los ingredientes de la semana 3 (ficha + departamento); sólo cambia d



- $d = 1$, un corte por árbol: un modelo aditivo, con curvas y sin cruces. Deja 15,5, casi lo de la recta con departamentos (15,8): las curvas solas valen poco.
- $d = 2$ ya cruza pares: 13,9; $d = 6$, 13,2. Los cruces que encontró la máquina valen 2,3 puntos; los que escribimos a mano en la semana 3, 0,9.
- **La respuesta a la pregunta de hoy es sí:** con los mismos ingredientes, la máquina encuentra más interacciones de las que supimos escribir, y valen más.

La carrera con los ingredientes de la semana 3

RMSE de CV (fuera de la bolsa en los bosques) y de prueba, en los 2.398 puestos abiertos una vez

Ingredientes	Modelo	CV	Prueba
—	la media (la referencia)	27,3	26,7
La ficha de 37	OLS	20,3	19,8
	un árbol podado (105 hojas)	19,5	19,1
	bosque ($m = 12$)	15,9	15,6
	<i>boosting</i> ($d = 6$)	15,8	15,7
Ficha + departamento	OLS	15,8	15,6
	Lasso, 1.291 columnas escritas a mano (semana 3)	14,9	14,7
	un árbol podado (98 hojas)	15,7	15,7
	bosque ($m = 12$)	13,3	12,9
	<i>boosting</i> ($d = 6$)	13,2	12,8

- **Sólo con el censo**, bosque y *boosting* bajan el error de 19,8 a 15,6 y 15,7: empatan con la recta que sí conoce el departamento (15,6). Sus cruces compensan lo que el censo no sabe del lugar.
- **Con los mismos ingredientes que el Lasso**, el *boosting* le gana por 1,9 puntos, y el bosque casi lo mismo. Un árbol solo, no: queda como la recta.

El mapa entra a la carrera

Las coordenadas, como dos variables más; y el juez de la semana 3 que valida por municipios enteros

Modelo	CV		
	al azar	por municipio	Prueba
<i>k</i> -NN en el mapa ($k = 7$, semana 3)	12,0	15,0	12,0
un árbol sobre longitud y latitud (427 hojas)	13,6		13,7
<i>boosting</i> , ficha + departamento	13,2	15,7	12,8
bosque, ficha + departamento + coordenadas	12,3		12,1
<i>boosting</i> , ficha + departamento + coordenadas	12,2	14,4	12,1

- **Con las coordenadas**, bosque y *boosting* alcanzan al mapa, pero no lo pasan: los rectángulos de un árbol copian al vecino peor que el círculo del *k*-NN.
- **Por municipios enteros**, todos pierden: el mapa 3,0 puntos (su única información es el vecino), el *boosting* sin coordenadas 2,5 y con coordenadas 2,3. En municipios que nunca vio, el *boosting* con coordenadas (14,4) ya le gana al mapa (15,0).

Promediar modelos distintos: las dos ligas, juntas

El *boosting* sin mapa y el *k*-NN en el mapa se equivocan distinto

$$\hat{f}_{\text{promedio}}(x) = \frac{1}{2} \hat{f}_{\text{boosting}}(x) + \frac{1}{2} \hat{f}_{k\text{-NN}}(x)$$

- La correlación de sus errores en la prueba es 0,69: alta, pero lejos de 1. Es la fórmula del bosque con dos “árboles” muy distintos: el piso es $\rho \sigma^2$.
- **El promedio:** 11,6 de CV y **11,4 en la prueba**, el mejor del curso hasta hoy. Validando por municipios, 14,0: también el mejor.
- Los pesos, $\frac{1}{2}$ y $\frac{1}{2}$, no se estimaron: fijarlos a ciegas quita una oportunidad de sobreajustar. Estimarlos con las predicciones fuera del pliegue es el *stacking* (Wolpert, 1992).

Dos ligas, un modelo

La estructura (qué tipo de puesto es) y el lugar (quiénes son sus vecinos) llevan información distinta: juntas predicen mejor que cualquiera de las dos sola.

La otra pregunta: ¿gana Petro?

Los mismos modelos con `gana_petro`; el *boosting* usa la log-loss. Costo con los precios de la semana 4 (umbral 0,83)

Modelo	AUC de CV	AUC de prueba	Brier	Costo
Lasso logístico, ficha larga (semana 4)	0,935	0,937	0,099	643
k -NN en el mapa ($k = 14$, semana 4)	0,949	0,945	0,091	628
un árbol podado, ficha + departamento	—	0,896	0,122	819
bosque, ficha + departamento	0,942	0,943	0,096	617
<i>boosting</i> , ficha + departamento	0,944	0,941	0,096	609
bosque, + coordenadas	0,949	0,950	0,090	589
<i>boosting</i> , + coordenadas	0,953	0,950	0,087	625
promedio: <i>boosting</i> sin mapa y k -NN	0,957	0,954	0,084	567

- **Con los ingredientes del Lasso logístico**, bosque y *boosting* ordenan un poco mejor (AUC 0,943 y 0,941 contra 0,937) y la campaña gasta menos (617 y 609 contra 643).
- **Ordenar no es decidir** (semana 4): con coordenadas, el *boosting* tiene mejor Brier que el bosque (0,087 contra 0,090), pero con el umbral de 0,83 le cuesta más a la campaña (625 contra 589).
- **El promedio de las dos ligas gana en las tres métricas**: AUC 0,954, Brier 0,084 y el costo más bajo, 567.

Cuándo usar qué

- **Una recta o un Lasso:** si la relación es casi lineal, hay pocos datos por variable, o se necesita leer coeficientes o salir con cuidado del rango de los datos. En Cali ganó la recta.
- **Un árbol:** para explicar una regla sencilla (un semáforo de riesgo), más que para predecir.
- **Un bosque:** el mejor modelo “de caja”: pocas perillas, poco sensibles, y su juez gratis. El primer candidato con datos tabulares.
- **Un boosting:** casi siempre el más preciso con datos tabulares, si se afina con el juez (η , d y B). En 45 bases tabulares de tamaño mediano, los ensambles de árboles todavía le ganan a las redes (Grinsztajn, Oyallon y Varoquaux, 2022).
- **El mapa y los promedios:** k -NN cuando el lugar es información y los vecinos se copian, con cuidado al validar; promediar cuando dos modelos buenos se equivocan distinto.

- 1 El árbol: partir y promediar
- 2 El bosque: promediar para bajar la varianza
- 3 El *boosting*: aprender despacio
- 4 La carrera: ¿encontró la máquina las interacciones?
- 5 Cierre

Qué dice y qué no dice

Lo que aprendió la máquina es predictivo, no causal

- **Dice:** el voto cambia con combinaciones de variables que una recta no ve, y esas combinaciones, encontradas por los datos, predicen mejor que las que escribimos (12,8 contra 14,7).
- **No dice por qué.** Que el primer corte sea la población afro no quiere decir que la etnia cause el voto: es la variable que mejor separa al Pacífico del resto, con todo lo que el Pacífico trae consigo. Otra parecida la reemplazaría: la varianza del árbol.
- **No dice cuáles cruces:** 300 árboles o 738 rondas no se leen. La semana 6 abre la caja: importancia de variables, dependencia parcial y SHAP.
- Significativo no es predictivo (semana 2), y predictivo no es causal.

Recap

- 1 **Un árbol parte y promedia:** cortes codiciosos que minimizan el RSS (o el Gini); un corte dentro de otro es una interacción que nadie escribió. Se poda con un precio por hoja que elige el juez.
- 2 **Un árbol solo es inestable:** la predicción de un puesto se mueve 9,2 puntos entre remuestras. En Cali pierde con la recta, y en el país apenas empata.
- 3 **El bosque promedia** árboles hondos sobre remuestras, con m variables por corte para que se parezcan menos: $\rho \sigma^2 + (1 - \rho) \sigma^2 / B$. Trae su juez, el error fuera de la bolsa, y no extrapola.
- 4 **El boosting corrige** con árboles pequeños sobre el residuo, que es un gradiente; con η pequeño y B por parada temprana. La profundidad mide el valor de las interacciones: 2,3 puntos.
- 5 **La carrera:** con los ingredientes de la semana 3, 12,8 contra 14,7; con el mapa, el promedio de las dos ligas deja 11,4.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- Molnar (2025), *Interpretable Machine Learning*: los capítulos de importancia por permutación, dependencia parcial y SHAP. Libro abierto en línea.
Guía: cada capítulo trae ventajas, desventajas y código; lean las desventajas dos veces.

Problem Set 1: se entrega el martes 20 de octubre a las 8:00, al empezar la sesión 6.

Próxima sesión — abrir la caja negra: hoy ganó un modelo que no se lee: cientos de árboles y miles de cortes. ¿Qué variables usa, cómo se mueve la predicción cuando cambia una, y por qué predice lo que predice en un puesto? Importancia por permutación, dependencia parcial y SHAP, con sus advertencias.

Aplicación en R: los mismos puestos y las dos preguntas: un árbol que se pueda leer, un bosque y un *boosting*, contra los mejores de las semanas 3 y 4, en la misma prueba.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 8. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Secs. 9.2, 10 y 15. [ESL]
- Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Breiman, L. (1996). Bagging Predictors. *Machine Learning*, 24(2), 123–140.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Friedman, J. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- Wolpert, D. (1992). Stacked Generalization. *Neural Networks*, 5(2), 241–259.
- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.).
<https://christophm.github.io/interpretable-ml-book/> [próxima sesión]
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

6 Apéndice: para profundizar

A1. El promedio de árboles correlacionados

Sean $T_1, \dots, T_B$ las predicciones de B árboles en un punto x , con la misma distribución, $\text{Var}(T_b) = \sigma^2$ y correlación ρ entre dos cualesquiera:

$$\begin{aligned}\text{Var}\left(\frac{1}{B} \sum_b T_b\right) &= \frac{1}{B^2} \left[\sum_b \text{Var}(T_b) + \sum_{b \neq b'} \text{Cov}(T_b, T_{b'}) \right] \\ &= \frac{B\sigma^2 + B(B-1)\rho\sigma^2}{B^2} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2\end{aligned}$$

- Con $B \rightarrow \infty$ queda $\rho\sigma^2$: más árboles no bajan la varianza por debajo de ese piso.
- El bosque baja ρ con $m < p$, a cambio de subir un poco la varianza y el sesgo de cada árbol. El m que conviene equilibra las dos cosas (ESL, sección 15.4).
- El sesgo del promedio es el de cada árbol: por eso se promedian árboles hondos, de poco sesgo, y no árboles podados.
- La misma cuenta explica por qué promediar el *boosting* y el k -NN ayuda: dos predicciones con errores de correlación $\rho < 1$.

A2. Gradient boosting con cualquier pérdida

El algoritmo general (Friedman, 2001; ESL, algoritmo 10.3):

- 1 $f_0(x) = \arg \min_{\gamma} \sum_i L(y_i, \gamma)$: la media con pérdida cuadrática; el log-odds de la prevalencia con la log-loss.
- 2 Para $b = 1, \dots, B$: (a) los pseudo-residuos $r_{ib} = -[\partial L(y_i, f(x_i))/\partial f(x_i)]_{f=f_{b-1}}$; (b) un árbol con hojas R_{jb} ajustado a los r_{ib} ; (c) en cada hoja, el mejor paso $\gamma_{jb} = \arg \min_{\gamma} \sum_{x_i \in R_{jb}} L(y_i, f_{b-1}(x_i) + \gamma)$; (d) $f_b(x) = f_{b-1}(x) + \lambda \sum_j \gamma_{jb} \mathbb{I}\{x \in R_{jb}\}$.

Pérdida	$L(y, f)$	$-\partial L/\partial f$
Cuadrática	$\frac{1}{2}(y - f)^2$	$y - f$
Absoluta	$ y - f $	$\text{signo}(y - f)$
Log-loss (f en log-odds)	$-yf + \log(1 + e^f)$	$y - \hat{p}$

- Con pérdida cuadrática, (c) es la media de los residuos en cada hoja: el algoritmo 8.2 de ISL.
- **Submuestreo** (Friedman, 2002): cada árbol ve una fracción de las filas; como en el bosque, baja la correlación entre pasos. Hoy, el 80 %.

A3. xgboost: la segunda derivada y un precio por hoja

En la ronda b , con $g_i = \partial L / \partial \hat{y}_i$ y $h_i = \partial^2 L / \partial \hat{y}_i^2$ evaluadas en la predicción anterior (Chen y Guestrin, 2016):

$$\sum_i \left[g_i f_b(x_i) + \frac{1}{2} h_i f_b(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

donde T es el número de hojas y w_j el valor de la hoja j . Con $G_j = \sum_{i \in j} g_i$ y $H_j = \sum_{i \in j} h_i$, el mejor valor de cada hoja y la ganancia de un corte son

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

- **Pérdida cuadrática:** $g_i = \hat{y}_i - y_i$ y $h_i = 1$, así que $w_j^* = \sum_{i \in j} r_i / (n_j + \lambda)$: la media de los residuos de la hoja, encogida hacia cero. Ridge en cada hoja.
- **Log-loss:** $g_i = \hat{p}_i - y_i$ y $h_i = \hat{p}_i(1 - \hat{p}_i)$: el hessiano de la logística de la semana 4. Cada ronda es un paso de Newton.
- γ es un precio por hoja, como el α de la poda: un corte entra sólo si gana más de γ .

A4. Variables cualitativas y datos faltantes en un árbol

- Una variable con q categorías se puede partir en dos de $2^{q-1} - 1$ maneras. Con los 33 departamentos, 4.294.967.295.
- **El atajo:** en regresión (y en clasificación con dos clases), ordenar las categorías por la media de y y probar sólo los $q - 1$ cortes en ese orden; el mejor corte está entre ellos (Breiman et al., 1984; ESL, sección 9.2.4). Es lo que hizo el árbol con los departamentos.
- **El riesgo:** una variable con muchas categorías tiene muchas oportunidades de cortar bien por azar, y tiende a elegirse de más. Vuelve en la semana 6, con la importancia de variables.
- **Datos faltantes:** `rpart` usa cortes sustitutos (otra variable que imita el corte); `xgboost` aprende, en cada corte, hacia qué lado mandar los faltantes.

A5. Otros ensambles de árboles

- **Extra-trees** (Geurts, Ernst y Wehenkel, 2006): también el umbral de cada corte se sortea. Árboles todavía menos parecidos, a cambio de más sesgo.
- **BART** (Chipman, George y McCulloch, 2010; ISL, sección 8.2.4): una suma de K árboles pequeños; en cada iteración se perturba cada árbol (un corte más, uno menos, otros valores en las hojas) hacia su residuo parcial. Es un MCMC: después de un período de calentamiento se promedia, y los percentiles dan la incertidumbre. Funciona bien casi sin afinar.
- **Bosques de cuantiles** (Meinshausen, 2006): cada hoja guarda sus y , no sólo su media; se predicen cuantiles y , con ellos, intervalos.
- **Bosques honestos y causales** (Wager y Athey, 2018): una mitad de la muestra elige los cortes y la otra estima el valor de las hojas; con ellos se estiman efectos heterogéneos. Es el puente con la inferencia causal de la sesión 8.

A6. Las perillas en R

Paquete	Perilla	Qué controla	Hoy
rpart	cp	el precio por hoja, α dividido por el RSS de la raíz	0, y se poda
	minsplit, minbucket	tamaño mínimo para cortar y de cada hoja	20 y 7
	xval	los pliegues del juez	los de la semana 3
randomForest	ntree	B	300 o 500
	mtry	m	$p/3$
	nodesize	tamaño mínimo de la hoja	5 (1 en clasificación)
xgboost	nrounds,	B , y cuántas rondas sin mejorar esperar	hasta 10.000; 50
	early_stopping_rounds		
	eta	η , la tasa	0,05
	max_depth	d , la profundidad	6
	subsample,	fracción de filas y de	0,8 y 0,8
	colsample_bytree	columnas por árbol	
	lambda, gamma	el Ridge de las hojas y el precio por hoja (A3)	1 y 0

Referencias del apéndice

- Friedman, J. (2002). Stochastic Gradient Boosting. *Computational Statistics & Data Analysis*, 38(4), 367–378. [A2]
- Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely Randomized Trees. *Machine Learning*, 63(1), 3–42. [A5]
- Meinshausen, N. (2006). Quantile Regression Forests. *Journal of Machine Learning Research*, 7, 983–999. [A5]
- Chipman, H., George, E., & McCulloch, R. (2010). BART: Bayesian Additive Regression Trees. *Annals of Applied Statistics*, 4(1), 266–298. [A5]
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228–1242. [A5]