

Big Data y Machine Learning para Economía Aplicada

Week 05: Árboles, bosques y *boosting*

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 18, 2026

Previously...

- **Clasificación:** el modelo entrega una probabilidad; la decisión necesita un umbral, y el umbral sale de los costos, $\tau^* = c_{FP} / (c_{FP} + c_{FN})$. Con los de la campaña, 0,83 en vez de 0,5 bajó el costo de 1.141 a 695.
- **La exactitud engaña** con clases desbalanceadas (Santos ganaba el 88% de los puestos en 2010): la AUC dice si el modelo ordena bien y la calibración, si su probabilidad es creíble.
- Hasta hoy todo fue **lineal en el índice**: las curvas y los cruces había que *escribirlos*. La ficha larga (cada predictor $\times$ departamento) son 1.253 columnas escritas a mano, y la interacción la elegimos *nosotros*.
- Y una promesa de la sesión 1: medir cuánto recorre una recta y cuánto exige flexibilidad.

La tabla del líder, al cierre de la semana 4 (2.398 puestos de prueba)

Voto: Lasso con la ficha larga 14,7 · k -NN en el mapa 12,1. **¿Gana?:**
penalizada 0,937 · k -NN 0,945.

La pregunta de hoy: ¿puede la máquina encontrar sola las particiones que importan?

El mismo caso, las dos preguntas de siempre; cambia quién escribe la flexibilidad

- **La limitación que nos trajo aquí:** para que la educación pesara distinto en Cali y en el Pacífico escribimos 1.253 columnas, y decidimos nosotros que la interacción era con el departamento. ¿Y si lo que importa es “rural del Pacífico sin energía eléctrica”, que no está en ninguna columna?
- **La idea de hoy:** dejar que el algoritmo **parta el territorio** en grupos de puestos parecidos y prediga una constante en cada grupo. Un corte anidado dentro de otro es una interacción que nadie escribió.
- **Tres métodos, una familia:** un **árbol** (se puede leer, predice mal), un **bosque** de árboles sobre remuestras *bootstrap* y el **boosting**, que suma árboles pequeños corrigiendo residuos.

Cómo la respondemos

La teoría de las particiones con los puestos como ejemplo (un corte a mano en Cali, el primer corte del país) → crecer, podar, promediar, sumar → la carrera en R con las dos preguntas del caso y los líderes como vara.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 *Afinar, comparar y combinar*
- 5 *Aplicación guiada en R: la carrera de los árboles*
- 6 *Cierre*

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para curvar el voto en la educación escribimos un polinomio; para que la educación pesara distinto en lo rural habría que escribir `educacion:rural`.
- **Sesión 3:** la ficha larga: $37 \text{ predictores} \times 33 \text{ departamentos} = 1.253$ columnas. El Lasso pudo 1.062, pero las 1.253 candidatas las propusimos *nosotros*, y sólo cruces con el departamento.
- **Los puestos:** ¿la educación predice el voto igual donde hay gas domiciliario y donde no? ¿El estrato importa en el Pacífico? ¿Cuál de *todas* las interacciones posibles importa? Nadie lo sabe de antemano.

Pregunta para la sala

¿Cómo dejar que los datos decidan *dónde* curvar y *qué* cruzar con qué, sin escribir la fórmula?

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para curvar el voto en la educación escribimos un polinomio; para que la educación pesara distinto en lo rural habría que escribir `educacion:rural`.
- **Sesión 3:** la ficha larga: $37 \text{ predictores} \times 33 \text{ departamentos} = 1.253$ columnas. El Lasso pudo 1.062, pero las 1.253 candidatas las propusimos *nosotros*, y sólo cruces con el departamento.
- **Los puestos:** ¿la educación predice el voto igual donde hay gas domiciliario y donde no? ¿El estrato importa en el Pacífico? ¿Cuál de *todas* las interacciones posibles importa? Nadie lo sabe de antemano.


Pregunta para la sala

¿Cómo dejar que los datos decidan *dónde* curvar y *qué* cruzar con qué, sin escribir la fórmula?

Partiendo el espacio de los predictores en pedazos y prediciendo una constante en cada pedazo. Un corte anidado dentro de otro es una interacción; varios cortes sobre la misma variable son una no linealidad. Eso es un árbol.

La idea: partir el espacio en rectángulos

ISL 8.1.1: los dos paneles son el mismo modelo



- Cortes binarios sucesivos, siempre paralelos a un eje. En cada hoja (rectángulo) se predice una **constante**: la media del voto de sus puestos.
- Con los puestos: R_1 es “poca población afro”, R_4 “bastante afro y mucha educación”. El árbol *descubre* la interacción afro $\times$ educación sin que nadie la escriba. Y si X_1, X_2 son lon y lat, las hojas son literalmente **pedazos del mapa**.
- El árbol se lee de arriba hacia abajo: es el único modelo flexible del curso que se le puede mostrar tal cual a quien toma la decisión.

Un corte a mano: diez puestos de Cali

Cinco con la menor educación superior de la ciudad, cinco con la mayor; la cuenta completa

Puesto	Educ.	Voto	Corte	$\bar{y}$ izq.	$\bar{y}$ der.	RSS
Navarro	1,2	77,8	—	55,7		7.636
Colegio Potrerogrande	1,3	87,8	1,2	77,8	53,3	7.102
IE Llano Verde	1,5	82,6	1,4	82,8	49,0	5.812
IE Elías Salazar García	2,4	79,3	2,0	82,7	44,1	4.514
Col. San Francisco Javier	2,5	81,1	2,5	81,9	38,3	3.077
Colegio Benett	54,8	23,6	28,7	81,7	29,7	878
Hormiguero B. Bochalema	56,2	51,2	55,5	72,0	31,2	3.647
Pance La Viga	56,2	15,4	56,2	69,1	24,6	3.488
Universidad Icesi	56,8	36,7	56,5	62,3	29,2	5.885
U. de San Buenaventura	58,1	21,7	57,4	59,5	21,7	6.354

- **Paso 1:** sin cortar, la predicción es la media (55,7) y quedan 7.636 de suma de cuadrados. **Paso 2:** probar cada corte posible (el punto medio entre puestos consecutivos), predecir la media a cada lado y sumar lo que queda. **Paso 3:** quedarse con el mejor: **28,7% de educación**, que deja 878: dos Calis, una que vota 81,7 y otra que vota 29,7.
- Eso es *todo* el algoritmo. Con 9.602 puestos y 37 variables la máquina hace esta misma cuenta, para todas las variables a la vez, y repite dentro de cada mitad.

El modelo: una constante por región

Un árbol con M hojas es una **partición** $R_1, \dots, R_M$ del espacio de las x (las regiones no se solapan y entre todas lo cubren) y una constante por región:

$$f(x) = \sum_{m=1}^M c_m \mathbb{I}\{x \in R_m\}.$$

- **Dada la partición, las constantes son triviales.** Con pérdida cuadrática, la mejor constante de cada región es la media de sus observaciones, $\hat{c}_m = \bar{y}_{R_m}$: en Cali, 81,7 y 29,7. En clasificación, la proporción de unos de la hoja.
- **Todo el problema es elegir la partición** que minimiza $\sum_m \sum_{i: x_i \in R_m} (y_i - \bar{y}_{R_m})^2$.
- Recorrer todas las particiones en rectángulos es **computacionalmente imposible** (ISL 8.1.1). La salida es una búsqueda **de arriba hacia abajo y voraz**: la partición binaria recursiva que acabamos de hacer a mano.

Parámetros: los cortes (variable y umbral) y las constantes de las hojas.

Hiperparámetro: el tamaño del árbol, M ; con $M = n$ el árbol memoriza, como en la sesión 1.

El primer corte del país: la máquina hace la misma cuenta

9.602 puestos, 37 variables: el mejor corte de cada una, y el mejor de todos

En cada paso, buscar el par (variable j , umbral s) que más reduce la suma de cuadrados:


$$\min_{j, s} \sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2.$$

Candidato	Mejor corte	RSS que queda (mill.)	Medias (izq. / der.)
Sin cortar	—	7,16	52,5
Educación superior	35,4%	7,14	
Edad 60–74	7,3%	6,72	
Población afro	4,5%	6,23	47,3 / 71,2

- **El primer corte del país no es la educación** (la estrella de Cali casi no reduce nada a escala nacional): es la población afro. Luego se repite *dentro* de cada mitad: donde hay menos de 4,5% de población afro, el siguiente corte es la indígena.
- La búsqueda es **exhaustiva pero barata** (ordenar y probar umbrales consecutivos) y **voraz**: el mejor corte *ahora*, sin mirar adelante. Sólo importa el *orden* de cada variable: **sin estandarizar y sin logaritmos** en las x .

Clasificación: pureza en vez de suma de cuadrados

Con y categórica (gana_petro), “reducir la RSS” se reemplaza por “dejar los nodos más **puros**”. Para un nodo con proporción $\hat{p}$ de la clase 1:



- **Error de clasificación:** $1 - \max(\hat{p}, 1 - \hat{p})$. **Gini:** $2\hat{p}(1 - \hat{p})$. **Entropía:** $-\hat{p} \log \hat{p} - (1 - \hat{p}) \log(1 - \hat{p})$.
- **Con los puestos:** en la raíz, $\hat{p} = 0,53$ y $\text{Gini} = 0,498$, casi el máximo. El primer corte vuelve a ser la población afro (1,4%): deja una mitad con $\hat{p} = 0,41$ y otra con $\hat{p} = 0,75$ (Gini 0,484 y 0,371).
- Para **crecer** el árbol se usan Gini o entropía: son estrictamente cóncavas y premian avances hacia nodos puros que el error, plano por tramos, ni nota. La hoja entrega una probabilidad, $\hat{p}_m$, y con ella vuelve todo lo de la sesión 4: umbral por costos, ROC, calibración.

¿Cuándo parar? Crecer grande y podar

Con los puestos: de 476 hojas a 103

El dilema: un árbol que corta hasta dejar una observación por hoja tiene error de entrenamiento cero. Parar temprano con una regla local (“no cortar si la ganancia es pequeña”) es miope: un corte mediocre puede habilitar uno excelente después.

La solución de CART (Breiman et al., 1984; ISL, algoritmo 8.1): crecer un árbol grande T_0 y luego **podarlo** resolviendo


$$\min_{T \subseteq T_0} \sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \bar{y}_{R_m})^2 + \alpha |T|,$$

donde $|T|$ es el número de hojas.


- ¿Les suena? **Ajuste + castigo por complejidad:** la sesión 3, con α en el papel de λ y “hojas” en el de “coeficientes”. Al variar α sale una **secuencia anidada** de subárboles; α se elige con la curva de CV (mínimo o regla 1-SE). En R, `rpart` llama a α `cp`.
- **Con los puestos** (ficha + departamento): el árbol grande tiene **476 hojas**; la curva de CV elige **103** (la regla 1-SE, 37). En la prueba: 16,0 el grande, **15,7** el podado, 15,9 el de 37 hojas. Podar recorta el sobreajuste, no hace milagros.

Árboles contra rectas: depende de la forma de f

ISL 8.1.3: ninguna familia domina; lo decide la prueba



frontera real **lineal**:
el **árbol** la escalona



frontera real **rectangular**:
la **recta** no puede

- Si la verdad es (casi) lineal, la logística o el OLS ganan con menos datos: los escalones aproximan mal una pendiente. Si la verdad tiene bloques, umbrales e interacciones, el árbol gana sin ayuda.
- **Con los puestos ya lo vimos:** el árbol legible de 10 hojas queda en 21,4, peor que la ficha de 37 en OLS (19,8). Mucha señal del censo es suave y lineal; la ventaja del árbol tendrá que venir de otra parte.
- **Lo bueno del árbol:** legible, mezcla tipos de variables, tolera faltantes con cortes sustitutos. **Lo malo:** predice peor que casi todo y es **inestable**: pocas observaciones distintas cambian el primer corte y todo lo que sigue.

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* de los mismos 9.602 puestos suelen dar dos árboles que no se parecen.

Pregunta para la sala

Tenemos un método flexible, barato, de bajo sesgo... y varianza enorme. Con lo visto en el curso, ¿qué harían para bajar la varianza sin sacrificar la flexibilidad?

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* de los mismos 9.602 puestos suelen dar dos árboles que no se parecen.

Pregunta para la sala

Tenemos un método flexible, barato, de bajo sesgo... y varianza enorme. Con lo visto en el curso, ¿qué harían para bajar la varianza sin sacrificar la flexibilidad?

Promediar. Si tuviéramos muchas muestras, entrenaríamos un árbol en cada una y promediaríamos sus predicciones: la varianza de un promedio de B cosas independientes es σ^2/B . No tenemos muchas muestras, pero la sesión 3 nos enseñó a fabricarlas: el **bootstrap**.

- Es la segunda palanca del curso contra la varianza. La primera fue **encoger** (sesión 3); la de hoy es **promediar**. Las dos aceptan algo de sesgo a cambio de mucha varianza.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar, comparar y combinar
- 5 Aplicación guiada en R: la carrera de los árboles
- 6 Cierre

Bagging: promediar baja la varianza

Bootstrap aggregating (Breiman, 1996; ISL 8.2.1):

- 1 Extraer B remuestras *bootstrap* del entrenamiento.
- 2 Ajustar un árbol **grande, sin podar** en cada una: sesgo bajo; la varianza la mata el promedio.
- 3 Promediar (regresión) o votar (clasificación): $\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$.

El problema: los B árboles no son independientes; salieron de los mismos datos. Con varianza σ^2 y correlación ρ entre pares (apéndice A1),

$$\text{Var}(\hat{f}_{\text{bag}}(x)) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2$$

- Cuando $B \rightarrow \infty$ el segundo término muere, pero queda $\rho \sigma^2$: un **piso** que ningún número de árboles rompe. Aumentar B **nunca sobreajusta**, sólo satura.
- **Con los puestos se ve la fórmula:** un árbol solo, 18,3 de error; con 5 árboles, 16,3; con 25, 13,1; con 100, 12,5; de 200 a 400, clavado en **12,3**. El cuello de botella ya no es B : es ρ . Para ganar más hay que **descorrelacionar** los árboles.

Random forest = bagging + descorrelación

La idea de Breiman (2001): en cada corte de cada árbol, sortear un subconjunto de sólo m predictores y elegir el mejor corte *entre esos*. ISL sugiere $m \approx \sqrt{p}$; en regresión es común $p/3$. **¿Por qué funciona?**

- Con *bagging* puro, si hay un predictor dominante casi todos los árboles lo usan en el primer corte: árboles clones, ρ alto, piso alto. Aquí lo hay: casi todos abrirían con la población afro o el departamento.
- Al sortear candidatos, muchos árboles *ni ven* al dominante: exploran estructuras distintas, ρ baja y el piso baja. Cada árbol empeora un poco; el promedio mejora (ISL, Fig. 8.10).
- **Con los puestos** ($p = 40$): $m = 2$ da 14,2 (árboles demasiado ciegos); $m = 13 = p/3$, **12,3**; $m = 40$ (bagging puro), 12,4. La perilla importa, pero perdona.

Los hiperparámetros del bosque

B : grande y sin miedo (500 a 1.000; satura). m (`mtry`): la perilla que importa; por CV o por OOB. Tamaño mínimo de hoja o profundidad: cuánto crece cada árbol.

Out-of-bag: la prueba gratis, con letra pequeña

Cada remuestra *bootstrap* deja fuera cerca del 37% de las observaciones (el 63% de la sesión 3): para cada puesto, un tercio de los árboles **no lo vieron**.

- **Predicción OOB de i :** promediar (o votar) sólo con esos árboles. **Error OOB:** el de esas predicciones sobre el entrenamiento, sin apartar datos ni correr CV; con B grande se parece a un LOOCV. Sirve para ver cuándo satura B y afinar m gratis.
- **Con los puestos funcionó:** OOB 12,32; la prueba, que el bosque nunca vio, **12,10**.

La letra pequeña

- El OOB evalúa **el bosque, no el pipeline**: si la imputación o la codificación aprendieron con todo el entrenamiento, el OOB hereda la filtración (regla de oro #3).
- Es un remuestreo **aleatorio**: con tiempo, espacio o grupos miente igual que el k -fold aleatorio. Nuestro 12,3 responde “completar el mapa”, no “municipios nuevos”.
- No reemplaza la prueba: el número que se reporta sigue siendo el de la prueba, una vez.

Importancia nativa: el primer vistazo dentro de la caja

La sesión 6 la abre del todo

El bosque pierde la legibilidad del árbol; el sustituto estándar es la **importancia de variables**: por **impureza** (sumar la reducción de RSS o Gini que aportó cada variable en todos los cortes) o por **permutación** (barajar la variable j en las observaciones OOB y medir cuánto empeora la predicción).

Con los puestos (permutación, las diez primeras): departamento, latitud, longitud, población indígena, edad 75+, edad 60–74, edad 20–29, energía eléctrica, educación técnica, educación superior. **La geografía manda**, y la educación, sola en Cali, aquí es una entre diez.


Tres trampas, en titulares:

- La de impureza favorece a las variables continuas o con muchas categorías: más umbrales donde lucirse (Strobl et al., 2007).
- Con predictores **correlacionados** el crédito se **reparte** entre gemelas (educación y estrato, otra vez): una variable crucial puede lucir mediocre.
- Importancia predictiva $\neq$ efecto: el proxy de la sesión 3.

Uso correcto hoy

Ordenar variables por utilidad predictiva *dado el resto*. Sesgos, estabilidad, dependencia parcial y SHAP: la próxima sesión.

Lo que un bosque no hace



- **No extrapola:** predice promedios de hojas, así que fuera del rango observado devuelve una constante. Fatal para series con tendencia; recuerden la extrapolación de la sesión 2.
- **Comprime hacia la media:** promediar hojas acerca las predicciones a niveles intermedios; los puestos extremos se predicen menos extremos de lo que son. El gráfico de predicho contra observado es parte del reporte.
- **Señales suaves y lineales:** un modelo lineal regularizado puede ganarle con menos datos (sesión 3). Y cuesta memoria: B árboles grandes con n grande.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 ***Boosting***
- 4 Afinar, comparar y combinar
- 5 Aplicación guiada en R: la carrera de los árboles
- 6 Cierre

Boosting: la filosofía opuesta

	<i>Random forest</i>	<i>Boosting</i>
Árboles	grandes, sin podar	pequeños (<i>weak learners</i>)
Entrenamiento	en paralelo, independientes	en secuencia , corrigiendo al anterior
Agregación	promedio	suma con paso pequeño
Ataca	la varianza	el sesgo (parte rígido)

La forma del modelo final:

$$\hat{f}(x) = \sum_{b=1}^B \nu \hat{f}^b(x),$$


una suma de B árboles pequeños (a menudo de uno a tres cortes), cada uno multiplicado por una **tasa de aprendizaje** ν (ISL la llama λ ; aquí λ ya está ocupada).

- Cada árbol aporta un ajuste *modesto* donde el ensamble acumulado todavía se equivoca.
- El lema: **aprender despacio**. Muchos pasos chicos generalizan mejor que pocos pasos grandes. Hoy: 624 pasos de tamaño 0,05.

El algoritmo: ajustar árboles a los residuos

ISL, algoritmo 8.2, con pérdida cuadrática


- 1 Inicializar $\hat{f}(x) = 0$ y residuos $r_i = y_i$.
- 2 Para $b = 1, \dots, B$: ajustar un árbol pequeño $\hat{f}^b$ con d cortes a (x_i, r_i) ; actualizar $\hat{f}(x) \leftarrow \hat{f}(x) + \nu \hat{f}^b(x)$ y $r_i \leftarrow r_i - \nu \hat{f}^b(x_i)$.
- 3 Devolver $\hat{f}(x) = \sum_b \nu \hat{f}^b(x)$.



- Cada árbol ve **lo que falta por explicar**, no los datos originales: el primero aprende “el Pacífico vota alto”; el número doscientos corrige puestos concretos donde el ensamble todavía falla.
- ¿Por qué *gradient* boosting? Porque el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción. Con otra pérdida se ajusta el árbol a su gradiente (apéndice A2): con la logística, a $y_i - \hat{p}_i$, el residuo de la sesión 4. Un solo algoritmo para regresión, clasificación y cuantiles.

Las tres perillas, y la que decide: cuándo parar

Con los puestos: el error dentro baja sin parar; el CV se aplana en 12,4



- 1 **B , número de árboles.** Aquí B grande **sí sobreajusta**: el ensamble sigue ajustando residuos hasta memorizar el ruido. Se elige por **parada temprana**: parar cuando el error de validación deja de bajar (50 rondas sin mejora).
- 2 **ν , tasa de aprendizaje** (0,01 a 0,1). Con $\nu = 0,3$ el CV toca su mínimo (12,9) en la ronda 114 y a la ronda 300 ya va de subida (13,0) mientras el error dentro cae a 2,7: **la curva U, en vivo**. Con $\nu = 0,05$: mínimo 12,4 en la ronda 624. Más pequeño el paso, mejor y más lento.
- 3 **d , cortes por árbol:** el **orden de interacción**. $d = 1$ es aditivo; hoy $d = 5$; rara vez conviene $d > 6$.

XGBoost y LightGBM, en la práctica

XGBoost (Chen & Guestrin, 2016): *gradient boosting* + ingeniería + una idea estadística: cada árbol se elige minimizando

$$\sum_i L(y_i, \hat{f}(x_i)) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

con T hojas de valores w_j : **poda y Ridge dentro del boosting** (apéndice A3). Además: submuestreo de filas y columnas (la idea del bosque), faltantes nativos, histogramas para n grande.

- **LightGBM**: crecimiento por hoja e histogramas agresivos; más veloz con millones de filas. **CatBoost**: categóricas de alta cardinalidad sin *dummies*.
- **Hoy**, con 9.602 puestos y 65 columnas, xgboost corre las 624 rondas con CV de 5 pliegues en unos 15 segundos: el costo no es excusa.

La disciplina del *boosting*

El método más poderoso de la sesión **y** el más fácil de arruinar: exige la validación de la sesión 3. El bosque perdona; el *boosting* no.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 **Afinar, comparar y combinar**
- 5 Aplicación guiada en R: la carrera de los árboles
- 6 Cierre

Los hiperparámetros, en una tabla

Método	Perilla (en R)	Qué controla	Rango típico	Se elige por
Árbol	α (cp)	tamaño tras la poda	10^{-4} a 10^{-1}	curva de CV
	profundidad, hoja mín.	cuánto crece T_0	5 a 30; 5 a 20	fijo o CV
Bosque	B (ntree)	saturación	500 a 1.000	OOB que se aplana
	m (mtry)	descorrelación	$\sqrt{p}$, $p/3$, fracción	OOB o CV
	hoja mín. (nodesize)	tamaño de cada árbol	1 a 20	CV
<i>Boosting</i>	B (nrounds)	cuándo parar	100 a 5.000	parada temprana
	ν (eta)	tamaño del paso	0,01 a 0,1	CV, atado a B
	d (max_depth)	orden de interacción	1 a 6	CV
	submuestreo	varianza, velocidad	0,5 a 1	CV
	λ , γ	Ridge y poda internas	0 a 10	CV o <i>defaults</i>

Lo que afinamos hoy, y cómo

El árbol: cp con la curva de CV de rpart. El bosque: m mirando el OOB (2, 13, 40) y $B = 400$ porque el OOB ya no se movía. El *boosting*: $\nu = 0,05$, $d = 5$, submuestreo 0,8 y las rondas por parada temprana con CV de 5 pliegues. Todo dentro del entrenamiento; la prueba, al final y una vez.

La carrera con nuestros puestos, y su diagnóstico

Las dos preguntas del caso, la misma partición de siempre, la prueba una sola vez

	Voto por Petro (RMSE)		¿Gana Petro? (AUC)	
	CV u OOB	Prueba	CV u OOB	Prueba
El líder lineal de las semanas 3 y 4	14,9	14,7	0,935	0,937
k -NN en el mapa ($k = 10$)	12,3	12,1	0,947	0,945
Árbol podado por CV	15,9 [†]	15,7		
Bosque (ficha + dpto. + coordenadas)	12,3	12,1	*	0,951
<i>Boosting</i> (mismas columnas)	12,4	12,2	0,952	0,950

- **La carrera está bien hecha:** mismos predictores disponibles, misma partición, misma prueba. La diferencia es del método, no de los datos. ([†]La curva de CV de la poda; *el OOB del bosque clasificador reporta tasa de error, 11,9%, no AUC.)
- **El diagnóstico:** CV u OOB y prueba difieren en décimas, en ambas direcciones: no hubo filtración ni sobreafinación. Si el OOB quedara muy por debajo de la prueba, algo se filtró o los datos tienen una estructura (espacio, grupos) que el remuestreo aleatorio ignora.
- **El bosque y el boosting empatan con los vecinos** usando censo + geografía, y la lectura viene en un momento: ¿de dónde salió la mejora?

¿De dónde viene la ganancia? Las interacciones que nadie escribió

La comparación que responde la pregunta de hoy

Modelo	Quién escribió la flexibilidad	RMSE prueba
Ficha + departamentos (OLS)	nadie: efectos aditivos	15,6
Lasso, ficha larga	nosotros : 1.253 columnas a mano	14,7
Bosque, ficha + departamento	la máquina : cortes anidados	12,9
Bosque + coordenadas	la máquina, con el mapa	12,1

- **Con las mismas variables de la ficha larga** (censo y departamento, sin mapa), el bosque baja de 14,7 a **12,9**: casi dos puntos que estaban en interacciones y umbrales que no escribimos. Esa diferencia *mide* cuánta información vivía en la forma, no en las variables.
- **Las coordenadas** le dan al bosque lo que le faltaba (12,1): corta el mapa en rectángulos y replica a los vecinos de la semana 2, pero combinándolos con el censo.
- La respuesta a la pregunta de hoy es **sí**: la máquina encontró sola las particiones. El costo: ya no hay coeficientes que leer. Ese es el precio que la sesión 6 intenta rebajar.

Cara a cara, y la regla práctica

	<i>Random forest</i>	<i>Boosting</i> (XGBoost)
Estrategia	bajar varianza promediando	bajar sesgo sumando en secuencia
B grande	inofensivo (satura)	sobreajusta (parada temprana)
Afinado	mínimo (m)	delicado (ν , d , B , submuestreo)
Error sin CV	OOB gratis	no: validación aparte
Desempeño típico	excelente, robusto	el mejor , si se afina bien

La regla práctica para sus proyectos:

- 1 Empezar con una **regresión regularizada** (sesión 3): la referencia legible.
- 2 **Random forest** casi sin afinar: el salto no lineal con mínimo esfuerzo; su OOB dice si la flexibilidad valió la pena.
- 3 **Boosting** afinado con CV cuando el objetivo es exprimir la última gota. Hoy no la exprimió: 12,2 contra 12,1 del bosque; también eso se reporta.
- 4 Y reportar los tres en la misma tabla, evaluados en la **misma** prueba.

¿Cuándo ganan los árboles?

- **Datos tabulares de tamaño mediano.** Grinsztajn, Oyallon & Varoquaux (2022) comparan ensambles de árboles y redes en 45 conjuntos tabulares: ganan los árboles. Aproximan bien funciones irregulares, ignoran las variables irrelevantes y no dependen de la escala.
- **Con los puestos, hoy:** el ensamble le ganó al mejor lineal por dos puntos y medio (12,1 contra 14,7), y el árbol solo *perdió* hasta con la ficha en OLS (15,7 contra su 15,6, y 21,4 el de diez hojas): flexible no es automático; el premio lo trae el ensamble.
- **Cuándo no.** Señal lineal o suave con pocos datos (gana la sesión 3); cuando hay que extrapolar (tendencias, rangos nuevos); imágenes y texto, donde la estructura está en la *representación* (sesión 7).

La lección de método

“Ganar” es una afirmación sobre una prueba y una métrica. Se demuestra con la tabla, no con la fama del algoritmo.

Promediar modelos distintos

Si promediar árboles ayuda, ¿por qué no promediar familias? **Stacking** o *super learner* (van der Laan et al., 2007): combinar las predicciones de K modelos,

$$\hat{y}(x) = \sum_{k=1}^K w_k \hat{f}_k(x), \quad w_k \geq 0, \quad \sum_k w_k = 1.$$

- **Por qué funciona:** la cuenta del *bagging*. El Lasso, el bosque y los vecinos del mapa se equivocan en puestos distintos; mientras menos correlacionados sus errores, más gana el promedio.
- **Los pesos se aprenden con CV:** con las predicciones de cada modelo en los pliegues que no vio. Elegirlos dentro de muestra premiaría al que más memoriza.
- **El promedio simple** ($w_k = 1/K$) es difícil de vencer.

El precio

Se gana poco (la última décima del ranking) y se pierde lectura: ahora hay K cajas. El combinado es un *pipeline* más: se valida entero y la prueba se abre una vez.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar, comparar y combinar
- 5 Aplicación guiada en R: la carrera de los árboles
- 6 Cierre

Aplicación guiada (I): el árbol, del corte a mano a la poda

applications/week-05; tarda unos cinco minutos: los bosques no son gratis

- **El corte a mano:** los diez puestos de Cali, los nueve cortes candidatos y el RSS de cada uno: el mejor, educación = 28,7 (878 de 7.636). La función `mejor_corte` repite la cuenta para cualquier variable del país.
- **El árbol que se puede leer** (`rpart`, `cp` = 0,01, sólo la ficha): 10 hojas. Se imprime y se recorre: afro < 4,6 → indígena < 0,05 → estrato 2 $\geq$ 2,5 → gas < 62 → “vota 24”. Prueba: **21,4**.
- **Crecer y podar** (ficha + departamento): el árbol de `cp` = 10^{-4} tiene 476 hojas; `plotcp` dibuja la curva de CV; el mínimo la poda a **103 hojas** y la regla 1-SE a 37. Prueba: 16,0 / **15,7** / 15,9.

Lo que hay que ver

La curva de CV del `cp` es la misma curva U de las semanas 1 y 3, con “hojas” en el eje de la complejidad. Y el árbol podado honesto se queda *por encima* del mejor lineal: la flexibilidad de un solo árbol no alcanza.

Aplicación guiada (II): el bosque y el *boosting*

- **El bosque** (randomForest, 400 árboles, ficha + departamento + coordenadas): la curva OOB por número de árboles ($18,3 \rightarrow 12,3$: satura), $mtry \in \{2, 13, 40\}$ por OOB (14,2 / **12,3** / 12,4), la importancia por permutación (la geografía manda) y el veredicto: OOB 12,32, prueba **12,10**.
- **El bosque sin coordenadas**: 12,9. La resta contra el Lasso (14,7) es la medida de las interacciones que nadie escribió; la resta contra 12,1, lo que vale el mapa.
- **El boosting** (xgboost, $\nu = 0,05$, $d = 5$): xgb.cv con parada temprana elige **624 rondas**; la curva muestra el error dentro bajando a 6,4 mientras el CV se aplana en 12,4. Prueba: **12,2**. Con $\nu = 0,3$, el CV hace la U: mínimo en la ronda 114 y de subida después.

Lo que hay que ver

Tres estimaciones honestas del mismo error (OOB, CV, prueba) que difieren en décimas. Y la asimetría de las perillas: al bosque le da casi igual; al *boosting* hay que decirle cuándo parar.

Aplicación guiada (III): la otra pregunta, y la campaña otra vez

- **gana_petro con los mismos tres métodos:** el árbol de clasificación (7 hojas, Gini; AUC **0,76**: ordena poco con tan pocas hojas), el bosque (**0,951**) y el *boosting* (0,950), contra 0,937 de la penalizada y 0,945 de los vecinos.
- **La hoja es una probabilidad**, así que la sesión 4 aplica entera: con los costos de la campaña ($\tau^* = 0,83$), el bosque baja el costo de 695 (logística) a **582**.
- **El guion del script:** datos $\rightarrow$ corte a mano $\rightarrow$ árbol legible $\rightarrow$ poda $\rightarrow$ bosque (OOB, mtry, importancia) $\rightarrow$ *boosting* (parada temprana, curvas) $\rightarrow$ clasificación $\rightarrow$ tabla del líder. Es la plantilla de la Parte 1 del Problem Set 2.

Las preguntas que responde la aplicación

¿Cuánto añade el bosque al mejor lineal? (2,5 puntos.) ¿Y el *boosting* al bosque? (Hoy, nada.) ¿Qué valía el mapa? (0,8.) ¿Y el árbol solo? (Se lee, pero pierde.)

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar, comparar y combinar
- 5 Aplicación guiada en R: la carrera de los árboles
- 6 Cierre

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre y vive en no linealidades e interacciones que el lineal no ve. Con los puestos: 1,8 puntos de RMSE con las mismas variables ($14,7 \rightarrow 12,9$), y 0,8 más con el mapa. Es un resultado sobre el territorio, no sobre el algoritmo.
- **La importancia ordena, no explica:** dice qué variables usa el modelo *dado el resto*. Que el departamento encabece la lista no dice por qué; con proxies correlacionados (educación y estrato) el orden es frágil.
- **Las predicciones están comprimidas y no extrapolan:** los puestos extremos se predicen menos extremos; fuera del rango, el bosque devuelve una constante. El gráfico de predicho contra observado es parte del reporte, no una nota al pie.
- **OOB, CV y prueba** son tres estimaciones del mismo error con tres usos distintos; sólo la prueba se publica.

Y , no β , versión árboles

Un bosque con AUC de 0,95 no dice por qué votan así los puestos; dice cuánta información sobre el resultado hay en la estructura del territorio. Abrir la caja (sesión 6) es lo que le da sentido económico; para hablar de efectos hace falta un diseño, y ese es otro curso.

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Árbol solo	hay que <i>mostrar</i> las reglas; exploración	predice mal; inestable
<i>Bagging</i> <i>Random forest</i>	pocas variables dominantes el primer modelo flexible	los árboles clones (ρ alto) no extrapola; comprime; memoria
<i>Boosting</i>	se busca el máximo desempeño tabular	sobreajusta con B ; exige afinado
Promedio de modelos	la última décima del ranking	K cajas; los pesos van dentro del CV
Lineal regularizado	señal suave o lineal; pocos datos	sólo ve lo que se escribe

Qué leer: ISL cap. 8 (8.1 el árbol; 8.2 los ensambles); Breiman (2001), secciones 1 y 2; Chen & Guestrin (2016) por XGBoost por dentro; Grinsztajn et al. (2022) por la evidencia tabular.

Recap

- 1 **Un árbol** es una partición en rectángulos con una constante por hoja; cada corte se elige con la cuenta que hicimos a mano en Cali, y el tamaño se poda con α por CV ($476 \rightarrow 103$ hojas). Encuentra solo no linealidades e interacciones. Legible, flexible, de varianza altísima.
- 2 **Bagging**: promediar árboles sobre remuestras *bootstrap*.
 $\text{Var} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$: B nunca sobreajusta ($18,3 \rightarrow 12,3$ y se aplana); el piso lo pone ρ .
- 3 **Random forest**: descorrelacionar sorteando m candidatos por corte; OOB como prueba gratis del bosque, no del *pipeline* ($12,32$ contra $12,10$ de la prueba); no extrapola y comprime.
- 4 **Boosting**: árboles pequeños en secuencia sobre residuos, con paso ν ; B por parada temprana (624 rondas; con ν grande, la curva U en vivo), d como orden de interacción.
- 5 **La tabla decide**: mismos predictores, misma partición, misma prueba. El ensamble le ganó 2,5 puntos al mejor lineal; el bosque y el *boosting* empataron; el árbol solo perdió.

La tabla del líder

Las dos preguntas del caso, los mismos 2.398 puestos de prueba

Sem.	Modelo	Voto (RMSE)	¿Gana? (AUC)
3-4	mejor lineal (Lasso / penalizada, ficha larga)	14,7	0,937
3-4	k -NN en el mapa ($k = 10$)	12,1	0,945
5	árbol podado por CV	15,7	0,763 [†]
5	bosque, ficha + departamento	12,9	
5	bosque + coordenadas	12,1	0,951
5	<i>boosting</i> + coordenadas	12,2	0,950

- **Las dos ligas se juntaron:** el bosque con coordenadas usa estructura y ubicación, y empatas con los vecinos en el voto mientras les gana en la clasificación. En la liga de estructura pura, el bosque sin mapa (12,9) destronó al Lasso (14,7). ([†]El árbol de clasificación tiene 7 hojas: se lee, pero ordena poco.)
- **La limitación que nos lleva a la sesión 6:** el nuevo líder no tiene coeficientes. ¿Qué aprendió? ¿La educación sigue importando cuando el bosque ya sabe dónde queda el puesto? ¿Dónde se equivoca más? Abrir la caja es la próxima sesión.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- Molnar (2025), *Interpretable Machine Learning*: los capítulos de importancia por permutación, dependencia parcial (PDP) y SHAP. Libro abierto en línea. Guía: cada capítulo trae ventajas, desventajas y código; lean las desventajas dos veces.

Problem Set 1: se entrega el **martes 20 de octubre a las 8:00**, antes de la sesión 6. Ese día se publica el Problem Set 2, cuya Parte 1 es la aplicación de hoy con la vivienda de Cali.

Próxima sesión — abrir la caja negra: el bosque es el nuevo líder y no tiene coeficientes. ¿Qué aprendió del territorio? Importancia por permutación (y por qué la de impureza engaña), dependencia parcial y curvas individuales, valores de Shapley y SHAP, la contribución de cada bloque del censo, y dónde se equivoca el líder: el error por subgrupos. Con nuestros puestos, de principio a fin.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 8. [ISL]
- Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Breiman, L. (1996). Bagging Predictors. *Machine Learning*, 24(2), 123–140.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Friedman, J. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in Random Forest Variable Importance Measures. *BMC Bioinformatics*, 8, 25.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- van der Laan, M., Polley, E., & Hubbard, A. (2007). Super Learner. *Statistical Applications in Genetics and Molecular Biology*, 6(1), art. 25.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

7 Apéndice: para profundizar

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par.

1. Expandimos la varianza del promedio:

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[\sum_{b=1}^B \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'}) \right].$$

2. Sustituimos (B varianzas; $B(B-1)$ covarianzas iguales a $\rho\sigma^2$):

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[B\sigma^2 + B(B-1)\rho\sigma^2 \right].$$

3. Reorganizamos:

$$\text{Var}(\bar{Z}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

- Con $\rho = 0$ recuperamos σ^2/B ; con $\rho = 1$, promediar no sirve de nada. El sorteo de m candidatos por corte baja ρ a cambio de subir un poco σ^2 (cada árbol es peor); empíricamente, el intercambio favorece bajar ρ (ESL, sec. 15.2).

A2. *Boosting* como descenso de gradiente en el espacio de funciones

Observación de Friedman (2001): el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción:

$$-\frac{\partial}{\partial f(x_i)} \frac{1}{2}(y_i - f(x_i))^2 = y_i - f(x_i) = r_i.$$

Ajustar árboles a los residuos es dar pasos de descenso de gradiente donde el “parámetro” es la función f entera y ν es el tamaño del paso.

La generalización: para cualquier pérdida diferenciable L , ajustar cada árbol al **pseudo-residuo**

$$r_{ib} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f=\hat{f}_{b-1}}.$$

- Pérdida absoluta: $r_{ib} = \text{sign}(y_i - \hat{f}(x_i))$, robusta a atípicos; pérdida de cuantil: *boosting* para percentiles; pérdida logística: $r_{ib} = y_i - \hat{p}(x_i)$, la sesión 4. AdaBoost es el caso de la pérdida exponencial.
- Un solo algoritmo, cualquier pérdida diferenciable: el mismo motor que entrenará las redes de la sesión 7, allí en el espacio de los pesos.

A3. El objetivo de XGBoost y el peso óptimo de cada hoja

Para el árbol b , con $\hat{f}_{b-1}$ fijo, XGBoost minimiza la aproximación de **segundo orden** de la pérdida más la regularización:

$$\sum_i \left[g_i f^b(x_i) + \frac{1}{2} h_i f^b(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2, \quad g_i = \frac{\partial L}{\partial \hat{f}}, \quad h_i = \frac{\partial^2 L}{\partial \hat{f}^2}.$$

1. Fijada la estructura (qué observaciones caen en cada hoja j), con $G_j = \sum_{i \in j} g_i$ y $H_j = \sum_{i \in j} h_i$, el objetivo es una cuadrática separable en los w_j :

$$\sum_j \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T \implies \boxed{w_j^* = -\frac{G_j}{H_j + \lambda}}$$

un paso de **Newton** por hoja, encogido por λ (Ridge).

2. La ganancia de un corte que divide una hoja en L y R :

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma.$$

Si es negativa, el corte no se hace: la poda ocurre *mientras* se construye. Con L cuadrática, $h_i = 1$ y todo se reduce a medias de residuos encogidas.

A4. Otros ensambles de árboles que verán en los papers

- **Árboles extremadamente aleatorios** (*extra-trees*; Geurts, Ernst & Wehenkel, 2006): como el bosque, pero además el *umbral* de cada corte se sorteas en lugar de optimizarse, y cada árbol suele usar toda la muestra. Más aleatoriedad, menos correlación entre árboles, algo más de sesgo; en varias comparaciones aplicadas le gana al bosque clásico.
- **BART** (ISL 8.2.4; Chipman, George & McCulloch, 2010): una suma de árboles con distribuciones *a priori* que los mantienen pequeños, muestreada por MCMC. Casi sin afinar y con **intervalos** para las predicciones; más lento y menos difundido.
- **Bosques de cuantiles y bosques honestos**: el mismo bosque usado para estimar cuantiles condicionales (intervalos de predicción), o con una muestra para elegir los cortes y otra para las medias de las hojas. Los segundos son la base de los *causal forests* (Wager & Athey, 2018): cuándo un bosque ayuda a estimar efectos heterogéneos es tema del curso de Inferencia Causal.