Big Data y Machine Learning para Economía Aplicada

Week 05: Árboles, bosques y *boosting*: partir, promediar y corregir

Eduard F. Martinez Gonzalez

Departamento de Economía, Universidad Icesi

October 13, 2026

Previously...

- **Semana 3, el juez y la perilla:** la validación cruzada elige sin tocar la prueba; la penalización encoge y apaga, y paga cuando las columnas compiten con las filas. En el país ganó lo simple —censo + dummies de departamento, error de prueba de 15,6— y quedó la deuda: la relación cambia por departamento y las pendientes no las escribimos.
- **Semana 4, la probabilidad y la decisión:** la logística estima $P(\text{gana} \mid x)$; los costos fijan el umbral ($\tau^* = 0{,}83$ con los 5 a 1 de la campaña: el costo baja de 1.141 a 695) y la AUC mide el ordenamiento sin fijarlo (la logística censo + dummies: 0,916).

Lo que traemos

Dos marcas a vencer con los mismos datos: en la regresión, 15,6 de error de prueba; en la clasificación, una AUC de 0,916. Y una deuda: la relación cambia de un departamento a otro, y esas pendientes nadie las escribió.

La pregunta de hoy: ¿puede el modelo encontrar solo dónde cambia la relación?

Los mismos puestos, las mismas dos preguntas; cambia quién escribe la flexibilidad

- **Lo que no escribimos a mano:** en la semana 3 la relación cambiaba por departamento y pagamos lo barato: la dummy mueve el nivel, no la pendiente. ¿Y si la educación pesa distinto en lo rural? Con 37 variables hay 666 cruces de a dos y 7.770 de a tres: nadie los escribe.
- **La idea de hoy:** partir los puestos en grupos parecidos y predecir con el promedio de cada grupo. Un corte dentro de otro es una interacción que nadie escribió.
- **Una familia, tres métodos:** el **árbol** parte, el **bosque** promedia cientos de árboles y el *boosting* suma árboles pequeños que corrigen al anterior. Sirven para las dos preguntas.

La idea con la que se van

Partir, promediar y corregir. Un árbol encuentra solo las interacciones, pero es inestable; promediarlo (bosques) o corregirlo de a poco (*boosting*) lo vuelve el mejor modelo del curso.

1. El árbol: partir y promediar
2. El bosque: promediar para bajar la varianza
3. El *boosting*: aprender despacio
4. La carrera: ¿encontró la máquina las interacciones?
5. ¿Y si la pregunta es de clasificación?
6. Cierre

Volvamos a Cali: ¿y si en vez de una recta, partimos?

Diez puestos de entrenamiento del área metropolitana, al azar, ordenados por educación superior

Puesto	Municipio	Educ. sup. (%)	Voto (%)	RSS si se corta debajo
La Dolores	Palmira	6,3	67,0	638
Ayacucho La Buitrera	Palmira	7,5	67,4	624
Escuela Bartolomé Loboguerrero	Cali	7,8	72,8	547
La Castilla	Cali	9,4	74,1	401
Liceo Técnico Comercial Litecom	Jamundí	10,5	64,2	411
Esc. Nuestra Señora de los Remedios	Cali	11,6	58,7	501
IE Mater Dei	Palmira	14,5	63,4	495
IE José Celestino Mutis	Cali	16,7	72,0	**237**
Pance La Vorágine	Cali	29,8	55,9	316
Inst. Univ. Antonio José Camacho	Cali	42,4	47,0	

Sin cortar, la mejor constante es la media y lo que falta por explicar es su RSS: 646. **Un corte** parte los puestos en dos y cada lado usa su propia media. Con diez puestos hay nueve cortes posibles.

Pregunta para la sala: ¿dónde cortarían?

Volvamos a Cali: ¿y si en vez de una recta, partimos?

Diez puestos de entrenamiento del área metropolitana, al azar, ordenados por educación superior

Puesto	Municipio	Educ. sup. (%)	Voto (%)	RSS si se corta debajo
La Dolores	Palmira	6,3	67,0	638
Ayacucho La Buitrera	Palmira	7,5	67,4	624
Escuela Bartolomé Loboguerrero	Cali	7,8	72,8	547
La Castilla	Cali	9,4	74,1	401
Liceo Técnico Comercial Litecom	Jamundí	10,5	64,2	411
Esc. Nuestra Señora de los Remedios	Cali	11,6	58,7	501
IE Mater Dei	Palmira	14,5	63,4	495
IE José Celestino Mutis	Cali	16,7	72,0	**237**
Pance La Vorágine	Cali	29,8	55,9	316
Inst. Univ. Antonio José Camacho	Cali	42,4	47,0	

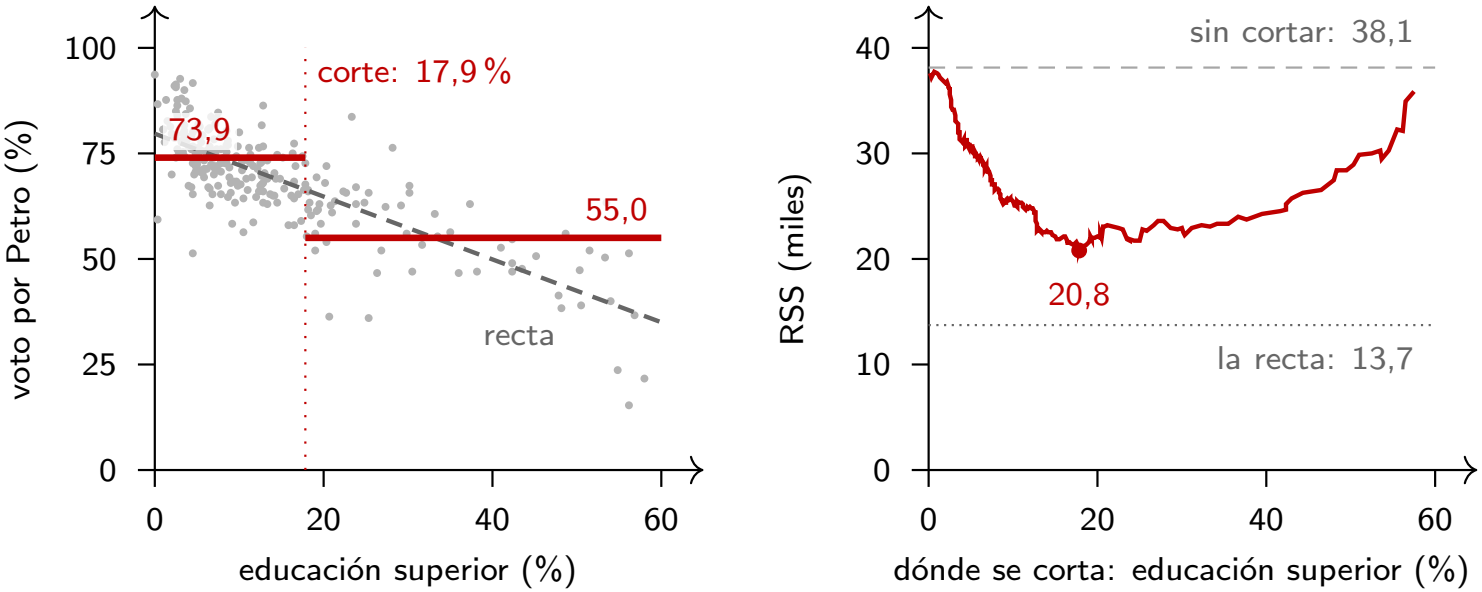
Sin cortar, la mejor constante es la media y lo que falta por explicar es su RSS: 646. **Un corte** parte los puestos en dos y cada lado usa su propia media. Con diez puestos hay nueve cortes posibles.

Pregunta para la sala: ¿dónde cortarían?

En 23,3 %: los 8 de menos educación (media 67,4) y los 2 de más (51,5); el RSS baja de 646 a 237. El RSS tiene dos valles: el otro, en 9,9 % (401).

El mismo corte con los 257 puestos

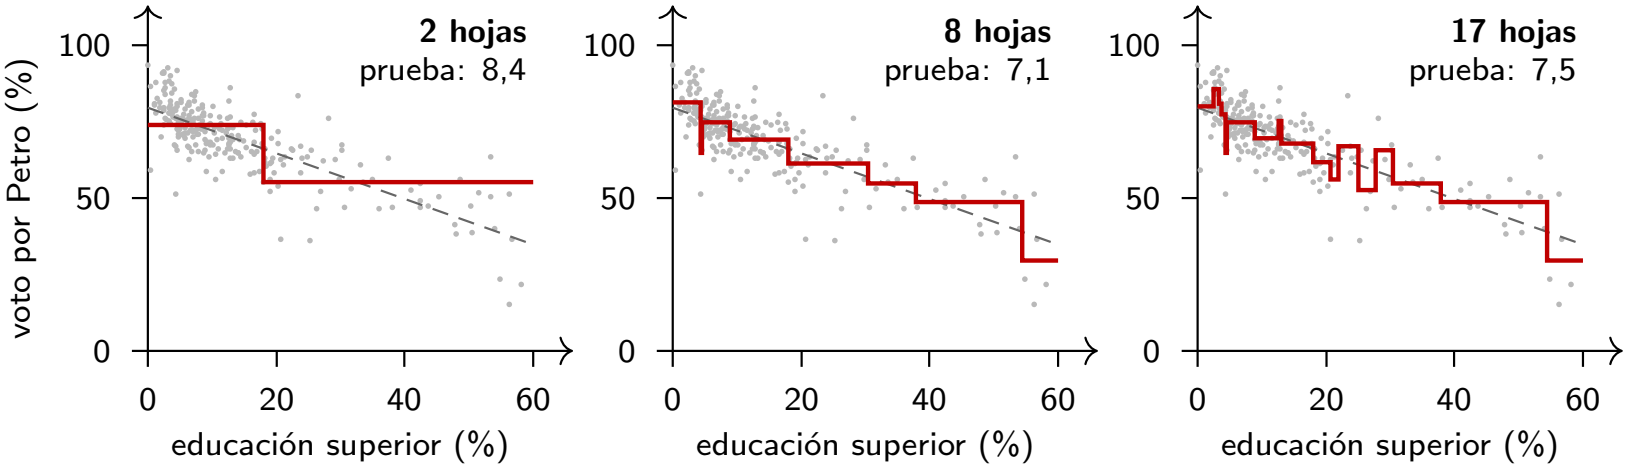
La máquina hace la misma cuenta en todos los cortes posibles y se queda con el que más baja el RSS



- El mejor corte cae en 17,9 % de educación superior: 192 puestos a la izquierda, con voto medio de 73,9, y 65 a la derecha, con 55,0. El RSS baja 45 %, de 38,1 mil a 20,8 mil.
- La recta de la semana 2 deja 13,7 mil: con una sola variable y una relación casi recta, un corte no alcanza. ¿Y si cortamos otra vez?

Cortar otra vez: una escalera

Cada mitad se vuelve a partir con la misma regla. En rojo, el árbol; punteada, la recta



- Cada peldaño es una **hoja**: un grupo de puestos que se predice con su promedio.
- **En el entrenamiento** el error siempre baja con más hojas: 9,0 con 2 hojas, 6,6 con 8 y 6,2 con 17. **En la prueba** baja de 8,4 a 7,1 y vuelve a subir a 7,5.
- Ninguna le gana a la recta de la semana 2, que deja 6,8 en la prueba: en Cali la relación es casi una recta. ¿Cuántas hojas conviene? Al final de esta parte.

El modelo: una constante por región

Partir los puestos en grupos y predecir con el promedio de cada grupo (ISL, sección 8.1.1)

$$\hat{f}(x) = \sum_{h=1}^{H} c_h \, \mathbb{I}\{x \in R_h\} \qquad \text{con } R_1, \ldots, R_H \text{ que minimicen el RSS}$$

- Cada región R_h es un grupo de puestos (una hoja), y su predicción es la mejor constante: el promedio de sus puestos, $\hat{c}_h = \bar{y}_{R_h}$.
- **El problema:** hay demasiadas maneras de armar los grupos; no se pueden probar todas. **La solución:** un corte a la vez. Una variable j y un valor de corte s dejan dos grupos, $R_1 = \{x : x_j < s\}$ y $R_2 = \{x : x_j \geq s\}$, y se busca la pareja que minimiza

$$\min_{j,\, s} \sum_{i:\, x_i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{i:\, x_i \in R_2} (y_i - \bar{y}_{R_2})^2$$

- Hecho ese corte, se repite lo mismo dentro de cada grupo, y así sucesivamente.
- **Es un método codicioso** (*greedy*): en cada paso toma el mejor corte de ese momento, sin mirar si otro, peor hoy, dejaría un árbol mejor después.

El algoritmo, paso a paso

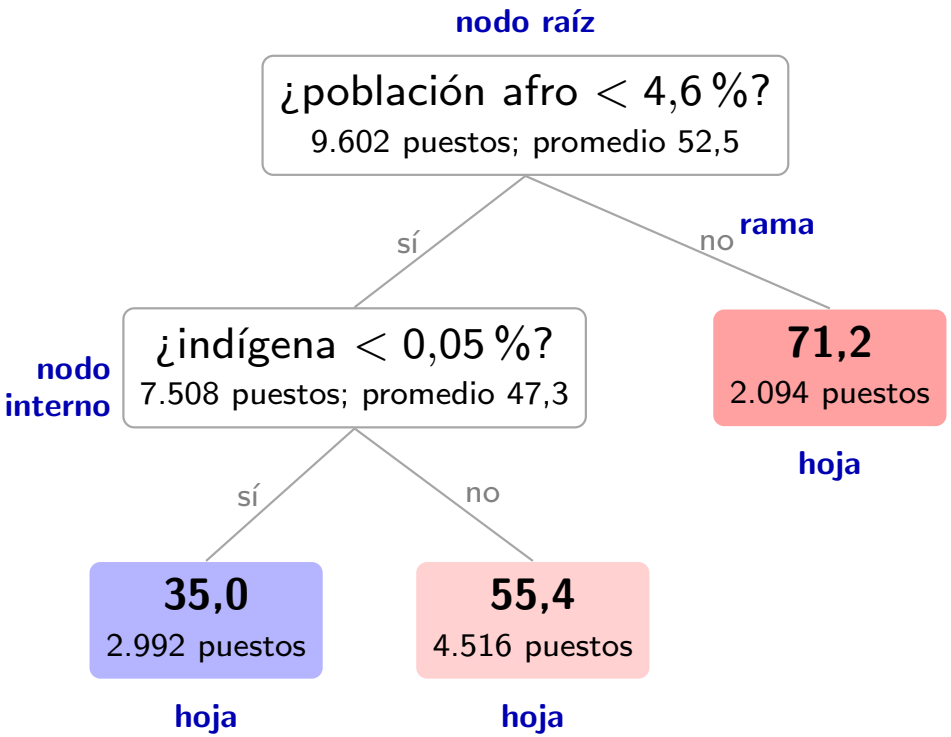
Los cortes candidatos salen de los datos y se prueban todos: nada se sortea

1. **Se arranca con todos los puestos en un solo grupo.** La predicción es el promedio (en el país, 52,5) y su RSS es el punto de partida. No hay semilla: con los mismos datos, el árbol siempre sale igual.
2. **Los cortes candidatos salen de los datos.** Se ordenan los valores de una variable; cada punto medio entre dos valores seguidos es un candidato. Con los diez puestos de Cali había nueve. No hay que decidir cuánto moverse hacia arriba o hacia abajo: se prueban **todos**.
3. **Cada candidato se califica con su RSS:** un promedio a cada lado y la suma de los errores al cuadrado. Y se hace con **cada variable**: en el país, 37 variables y 208.236 candidatos en total.
4. **Gana el corte con el menor RSS.** Variable y valor salen juntos: no se escoge "primero la variable". En el país ganó la población afro, en 4,6 %.
5. **Se repite dentro de cada grupo, por separado.** No se escoge cuál grupo sigue: todos se siguen partiendo, hasta que un grupo tiene menos de 20 puestos o ningún corte mejora.

Para repasarlo, el video Regresión con árboles de decisión (Codificando Bits, 12 minutos).

Las partes de un árbol: raíz, nodos y hojas

El árbol del país con sus dos primeros cortes: el vocabulario, antes de seguir

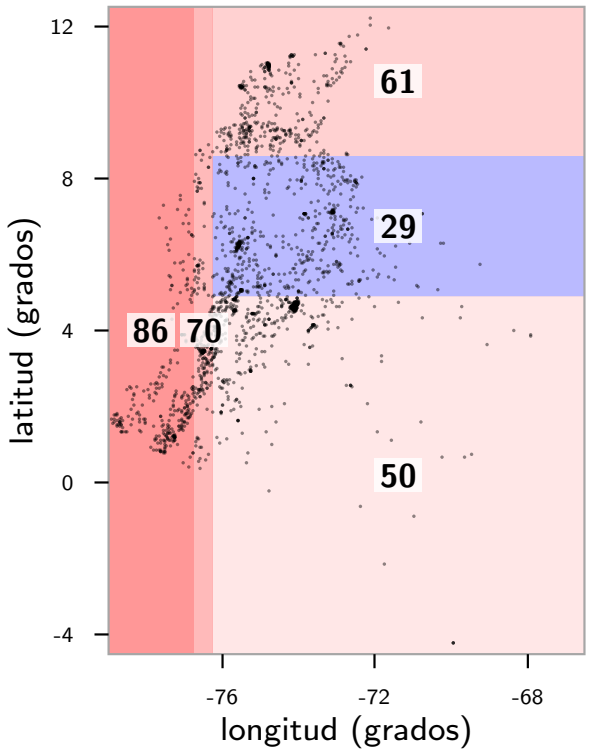


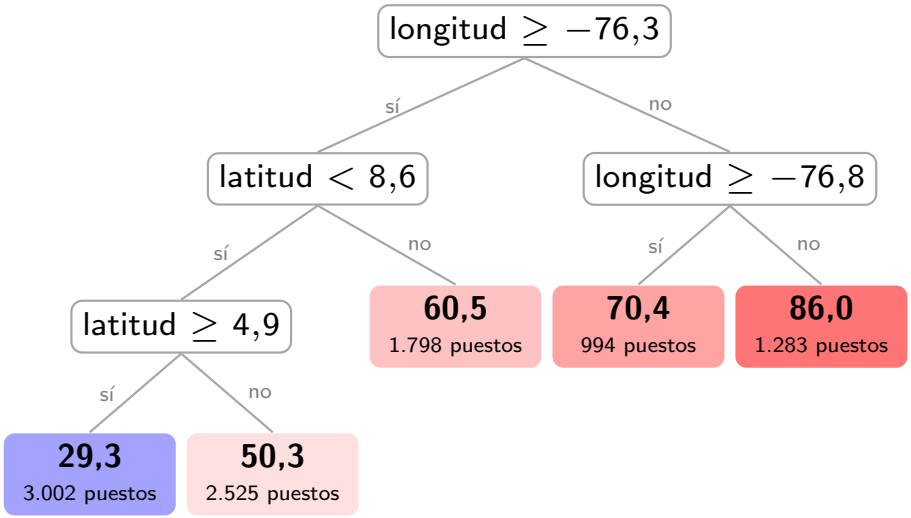
- **Nodo:** cada caja; es un grupo de puestos.
- **Nodo raíz:** el primero. Tiene todos los puestos y hace la primera pregunta.
- **Nodos internos:** los que hacen otra pregunta y se parten en dos **ramas** (sí y no).
- **Hojas** (nodos terminales): los que ya no se parten. Su promedio es la predicción.
- **Tamaño:** el número de hojas (aquí, 3). **Profundidad:** las preguntas de la raíz a la hoja más lejana (aquí, 2).

Para predecir un puesto nuevo se responden las preguntas desde la raíz hasta caer en una hoja: un puesto con 1 % de población afro y 3 % de indígena cae en la de 55,4. Ese es su voto predicho.

Partir el mapa: el árbol y sus rectángulos

Un árbol sobre la longitud y la latitud del país: el mismo modelo en dos dibujos (ISL, figura 8.3)



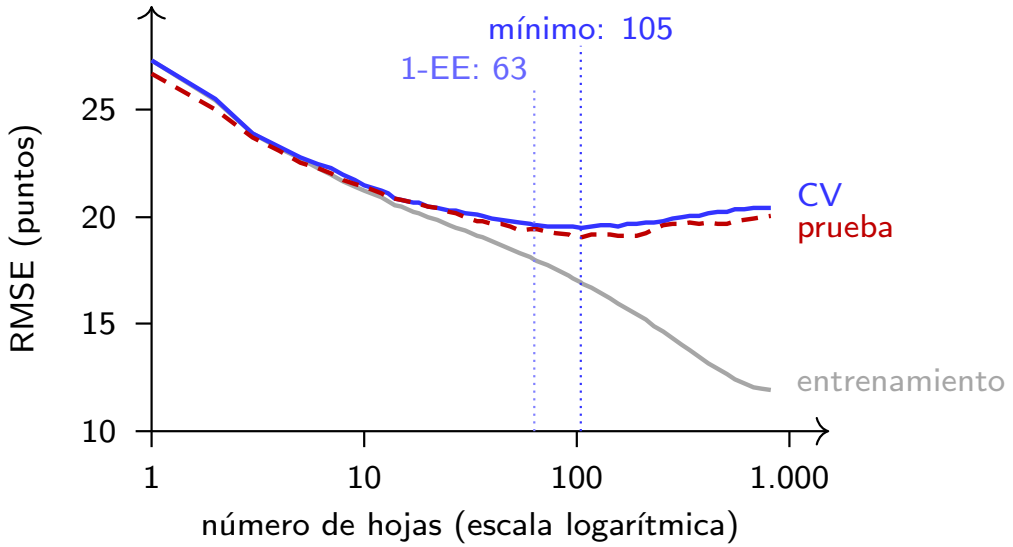


- **El mismo árbol en dos dibujos:** cada hoja del diagrama (derecha) es un rectángulo del mapa (izquierda); el número es el voto promedio de sus puestos.
- **Cinco hojas, cinco rectángulos:** la franja del Pacífico y Nariño queda sola, con 86,0. Error de prueba: 19,2; la regresión lineal con las 37 del censo, 19,8.

¿Hasta dónde crecer? El árbol también se sobreajusta

La poda por costo–complejidad: un precio por hoja, elegido por CV (ISL, algoritmo 8.1)

$$\min_{T \subseteq T_0} \sum_{h=1}^{|T|} \sum_{i:\, x_i \in R_h} (y_i - \bar{y}_{R_h})^2 \;+\; \alpha\, |T|$$



- Crecido hasta hojas de 7 puestos, el árbol de las 37 del censo tiene 819 hojas: 11,9 de error al entrenar y 20,0 en la prueba (regla de oro #1).
- α es el precio de cada hoja, como el λ del Lasso: con $\alpha = 0$, el árbol completo; con α grande, la raíz. Se poda el eslabón más débil.
- La validación cruzada (CV) de la semana 3 elige 105 hojas: 19,1 en la prueba; con un error estándar, 63 (19,4).

El problema del árbol: memoriza y es inestable

El árbol del país con las 37 variables del censo, cada vez más grande

	Error (RMSE)	
Hojas	entrenamiento	prueba
2	25,5	25,0
8	21,6	21,7
63	18,0	19,4
105	16,9	**19,1**
819	11,9	20,0

- **Pequeño, se queda corto:** con 2 u 8 hojas el error es alto en las dos columnas.
- **Grande, memoriza:** con 819 hojas el error de entrenamiento baja a 11,9 y el de prueba sube a 20,0.
- **Podado, no alcanza:** el mejor (105 hojas) deja 19,1; la regresión lineal con las mismas variables, 19,8.

Y es inestable. Repetimos el árbol veinte veces, cada vez con una muestra distinta del mismo entrenamiento (los puestos se sortean de nuevo: unos se repiten y otros quedan por fuera). El primer corte no cambia (la población afro, 20 de 20), pero los de abajo sí: la predicción de un mismo puesto se mueve 9,2 puntos de un árbol a otro. La de la mejor regresión lineal de la semana 3, 1,1.

¿Cómo predecir mejor sin sobreajustar?

Ninguno de los veinte árboles, solo, baja de 20,1 en la prueba. **El promedio de los veinte: 17,3.** No hay que escoger el mejor árbol: hay que promediar muchos. Eso es un bosque.

1 El árbol: partir y promediar

2 El bosque: promediar para bajar la varianza

3 El *boosting*: aprender despacio

4 La carrera: ¿encontró la máquina las interacciones?

5 ¿Y si la pregunta es de clasificación?

6 Cierre

Bagging: promediar muchos árboles

Breiman (1996); ISL, sección 8.2.1

La receta: (1) armar una muestra nueva sorteando n puestos del entrenamiento **con reemplazo** (unos salen repetidos y otros quedan por fuera); (2) ajustar con ella un árbol **grande**, sin podar; (3) repetir B veces y promediar las B predicciones:

$$\hat{f}_{\text{bag}}(x) \;=\; \frac{1}{B}\sum_{b=1}^{B} \hat{f}^{*b}(x)$$

- **Por qué árboles grandes:** cada uno se equivoca mucho, pero no hacia un lado fijo (poco sesgo, mucha varianza): al promediar, sus errores se compensan.
- **Hasta dónde ayuda promediar:** si los B árboles fueran independientes, con varianza σ^2 cada uno, el promedio tendría σ^2/B. Pero salen de los mismos datos y se parecen: con correlación ρ entre dos árboles,

$$\operatorname{Var}\Big(\frac{1}{B}\sum_{b=1}^{B} \hat{f}^{*b}(x)\Big) \;=\; \rho\,\sigma^2 \;+\; \frac{1-\rho}{B}\,\sigma^2 \qquad \text{(apéndice A1)}$$

- Con más árboles el segundo término desaparece; el primero, no: **el límite lo pone qué tan parecidos son los árboles**.

ISL llama *bootstrap* al sorteo con reemplazo; de ahí el nombre, *bootstrap aggregation*.

El bosque aleatorio: que los árboles no se parezcan

En cada corte sólo compiten m variables sorteadas (Breiman, 2001; ISL, sección 8.2.2)

- **El problema del bagging:** todos los árboles ven casi los mismos datos y hacen casi los mismos cortes: la población afro fue el primero en 20 de 20.
- **La solución:** en cada corte se sortean m de las p variables y sólo esas compiten. A veces la más fuerte no entra al sorteo: cada árbol termina usando una **combinación distinta de variables**.
- **Dos letras, dos cosas:** B es cuántos árboles se promedian; m, cuántas variables compiten en cada corte. Con $m = 37$ (todas) es *bagging*; lo usual es $m \approx p/3$ (aquí, 12).
- **El resultado** con $m = 12$: cada árbol es un poco peor (23,8 contra 23,4), pero se parecen menos (correlación de 0,54 contra 0,58) y el promedio mejora (de 15,8 a 15,6).

Pregunta para la sala

¿Cómo puede mejorar el promedio si cada árbol empeora?

El bosque aleatorio: que los árboles no se parezcan

En cada corte sólo compiten m variables sorteadas (Breiman, 2001; ISL, sección 8.2.2)

- **El problema del bagging:** todos los árboles ven casi los mismos datos y hacen casi los mismos cortes: la población afro fue el primero en 20 de 20.
- **La solución:** en cada corte se sortean m de las p variables y sólo esas compiten. A veces la más fuerte no entra al sorteo: cada árbol termina usando una **combinación distinta de variables**.
- **Dos letras, dos cosas:** B es cuántos árboles se promedian; m, cuántas variables compiten en cada corte. Con $m = 37$ (todas) es *bagging*; lo usual es $m \approx p/3$ (aquí, 12).
- **El resultado** con $m = 12$: cada árbol es un poco peor (23,8 contra 23,4), pero se parecen menos (correlación de 0,54 contra 0,58) y el promedio mejora (de 15,8 a 15,6).

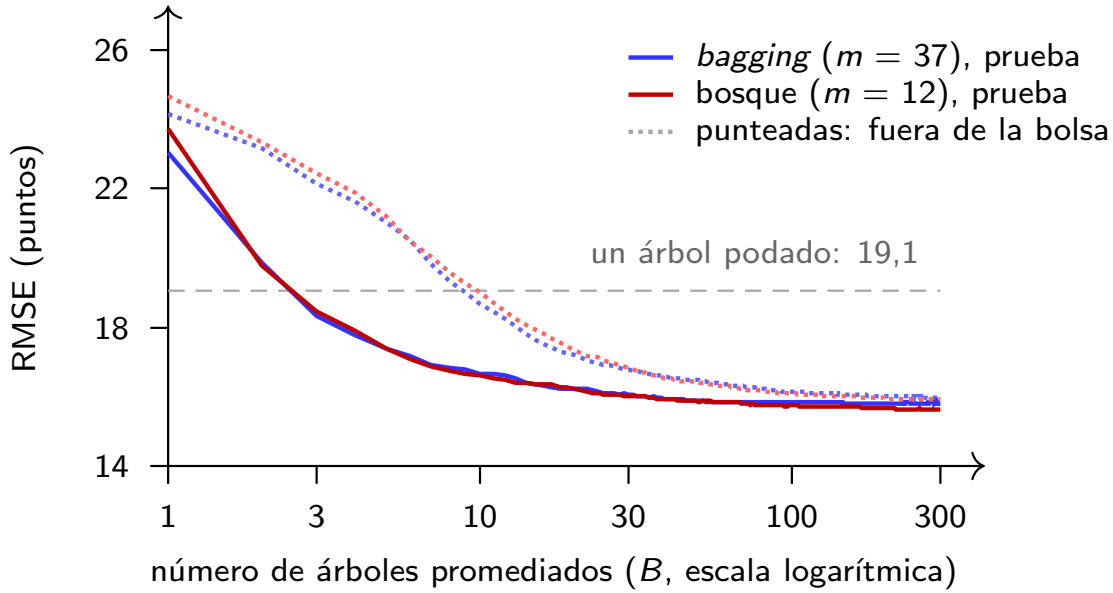
Pregunta para la sala

¿Cómo puede mejorar el promedio si cada árbol empeora?

Porque al promedio le sirve más que los árboles se equivoquen distinto. Es el teorema del jurado de Condorcet (1785): si cada jurado acierta el 60 % de las veces, la mayoría de tres acierta el 65 % y la de once, el 75 %, siempre que no se equivoquen todos en lo mismo. Para verlo moverse: mlu-explain.github.io/random-forest.

Árboles malos, promedio bueno

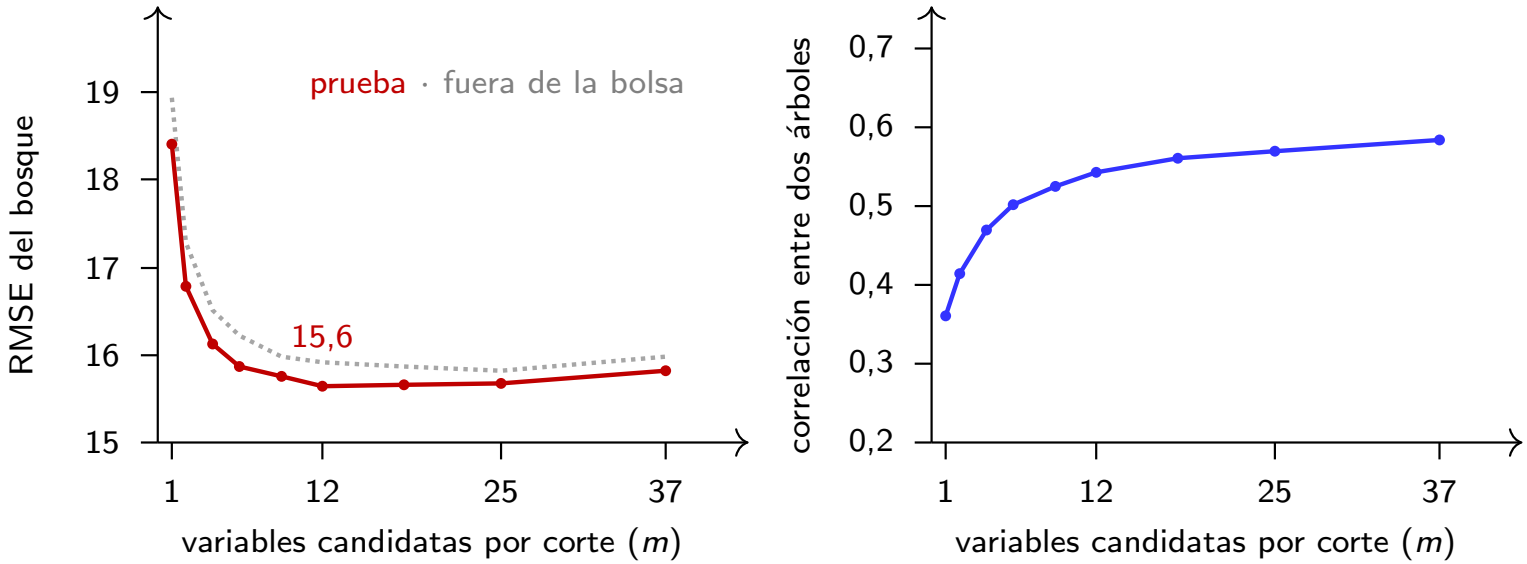
El error según el número de árboles promediados, con las 37 del censo (ISL, figura 8.8)



- **Cómo leerla:** azul, *bagging* (las 37 variables compiten en cada corte); rojo, el bosque aleatorio (sólo 12 sorteadas). Continuas: el error en la prueba; punteadas: "fuera de la bolsa", en los puestos que cada árbol no usó (apéndice A7).
- Un árbol grande solo: 23,1 en la prueba, peor que el podado (19,1). El promedio de 10: 16,7. El de 300: 15,8. La regresión lineal con las mismas variables: 19,8.
- **Más árboles nunca empeoran el promedio:** B no hay que afinarlo; se ponen los suficientes para que la curva se aplane.

¿Cuántas variables por corte? Elegir m

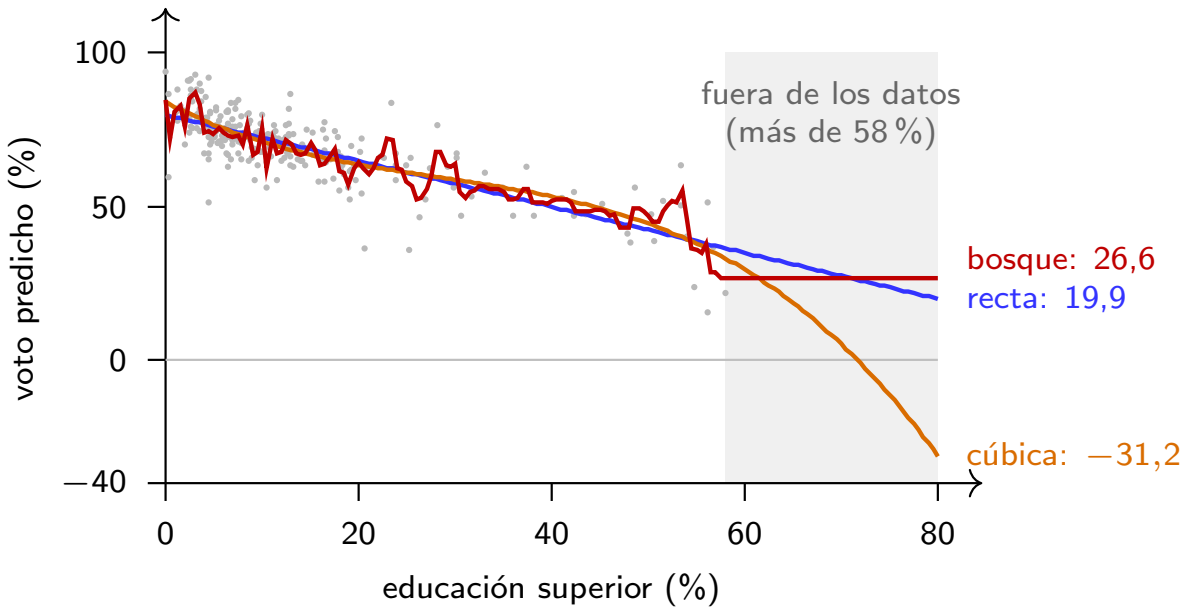
El bosque cambia poco con m: por eso funciona casi sin afinar



- **Cómo leerla:** en los dos ejes horizontales, m. Izquierda: el error del bosque, en rojo en la prueba y en gris en los puestos que cada árbol no usó (fuera de la bolsa). Derecha: qué tan parecidos son dos árboles del mismo bosque (su correlación).
- $m = 1$**,** una variable al azar en cada corte: los árboles casi no se parecen (correlación de 0,36), pero cada uno es muy malo (25,6); el bosque queda en 18,4.
- $m = 37$ es el *bagging*: los mejores árboles y los más parecidos. **En el medio** la curva es casi plana (15,6 con $m = 12$; el mejor fuera de la bolsa es $m = 25$): con $m \approx p/3$ casi nunca hay que afinar.

Lo que el bosque no hace: salirse de los datos

La extrapolación de la semana 2, otra vez: tres modelos con la educación superior del área metropolitana



- **Cómo leerla:** los puntos son los puestos del área metropolitana; en la franja gris (más de 58 % de educación superior) no hay ninguno. A la derecha, lo que cada modelo predice en 80 %.
- **El bosque promedia votos que ya vio:** fuera de los datos se queda plano (26,6). La recta sigue su pendiente (19,9) y la cúbica cae a −31,2, un voto imposible. El bosque, al menos, no inventa.

1 El árbol: partir y promediar

2 El bosque: promediar para bajar la varianza

3 El *boosting*: aprender despacio

4 La carrera: ¿encontró la máquina las interacciones?

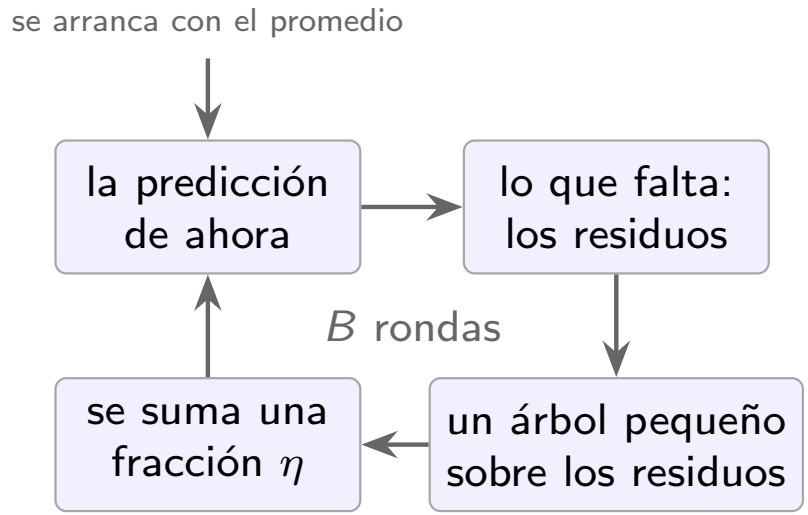
5 ¿Y si la pregunta es de clasificación?

6 Cierre

El *boosting*: árboles pequeños que corrigen lo que falta

El algoritmo para regresión (ISL, algoritmo 8.2)

1. **Arrancar con el promedio:** todos los puestos con la misma predicción, $\hat{f}(x) = \bar{y}$.
2. **Medir lo que falta:** el residuo de cada puesto, $r_i = y_i - \hat{f}(x_i)$.
3. **Ajustar un árbol pequeño a los residuos,** no al voto: encuentra los grupos de puestos donde el modelo más se equivoca.
4. **Sumar sólo una fracción η de ese árbol** (por ejemplo, el 10 %; ISL la llama λ): $\hat{f}(x) \leftarrow \hat{f}(x) + \eta\, \hat{f}^b(x)$.
5. **Volver al paso 2** con la predicción nueva; así, B rondas.

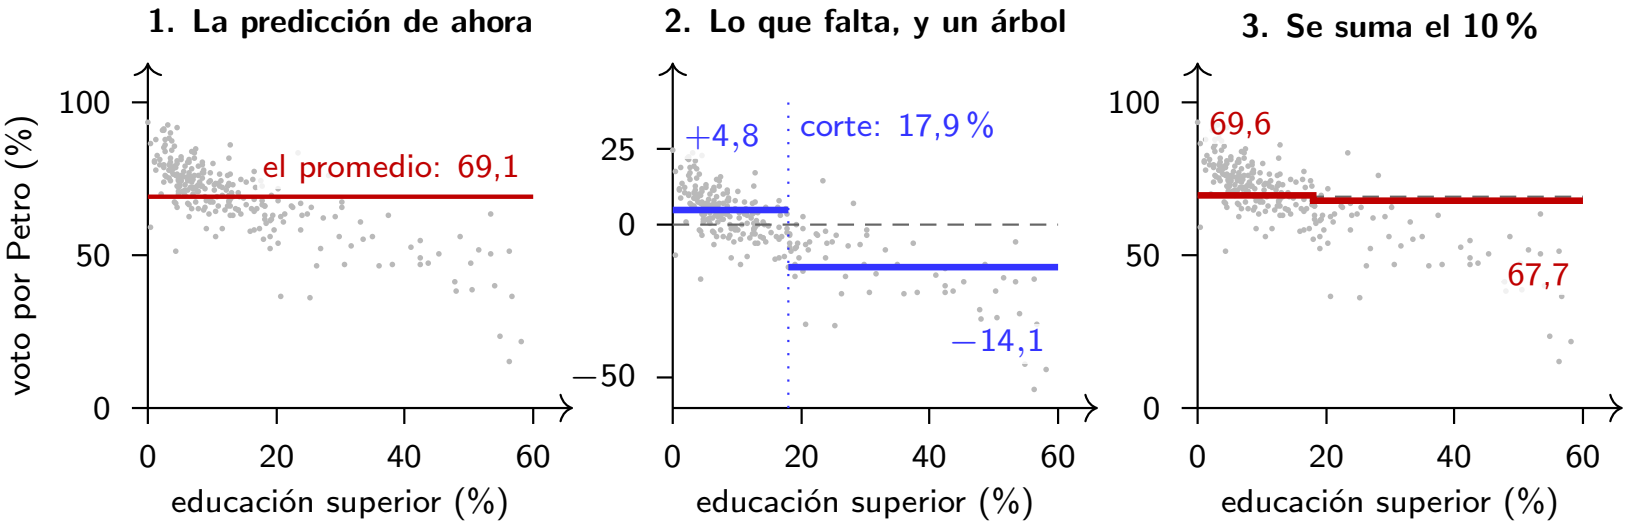


$$\hat{f}(x) \;=\; \bar{y} \;+\; \eta\, \hat{f}^1(x) \;+\; \eta\, \hat{f}^2(x) \;+\; \ldots \;+\; \eta\, \hat{f}^B(x)$$

El bosque promedia árboles grandes, cada uno por su lado; **el boosting** suma árboles pequeños, en fila: cada uno corrige lo que dejaron los anteriores.

Una ronda, a mano, en Cali

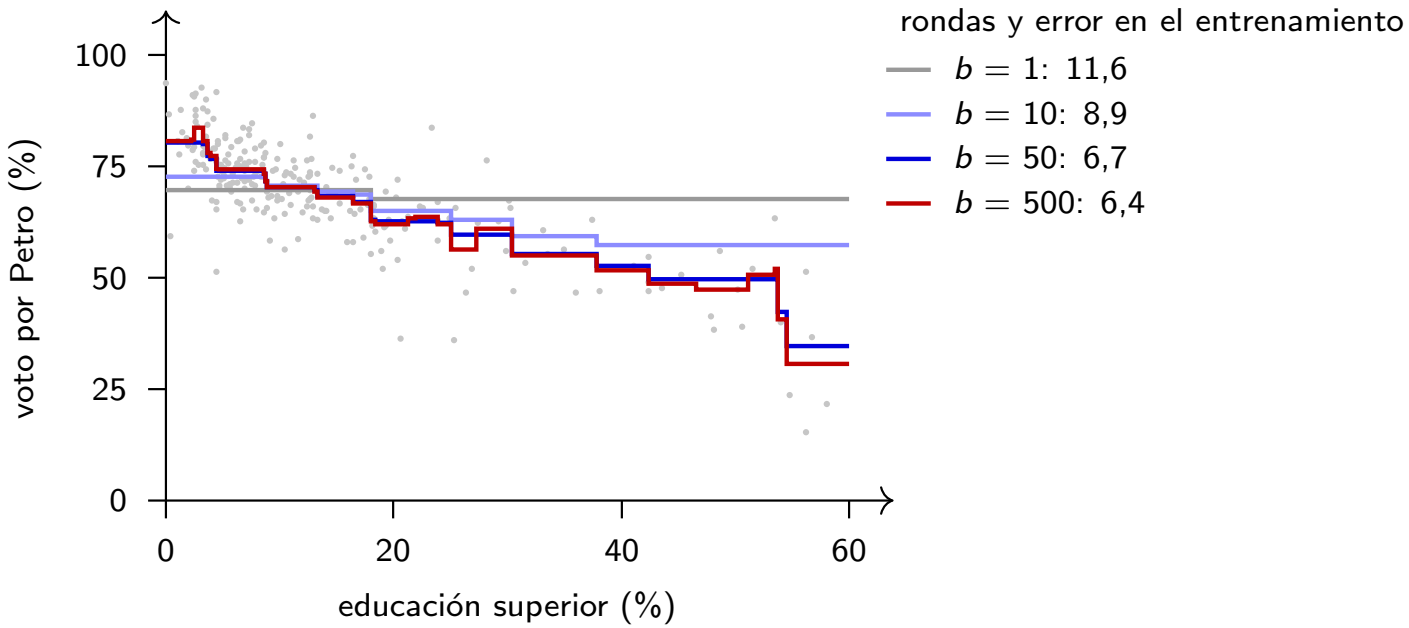
Los 257 puestos del área metropolitana, árboles de un solo corte y $\eta = 0{,}1$



- **1.** Se arranca con el promedio, 69,1 para todos (línea roja). Error en el entrenamiento: 12,2.
- **2.** Lo que falta en cada puesto: su voto menos 69,1. Un árbol de un corte (azul) parte esos residuos en 17,9 %: a la izquierda faltan 4,8 puntos en promedio; a la derecha sobran 14,1.
- **3.** Se suma el 10 %: $69{,}1 + 0{,}5 = 69{,}6$ a la izquierda y $69{,}1 - 1{,}4 = 67{,}7$ a la derecha. El error baja a 11,6.
- **Las rondas 2 y 3** repiten la cuenta con los residuos nuevos (la 2 corta en 25,1 %): el error baja a 11,2 y a 10,8. Cada ronda mueve poco: por eso hacen falta muchas.

Aprender despacio, en Cali

La misma cuenta, repetida hasta 500 rondas: árboles de un solo corte sobre la educación superior, con $\eta = 0{,}1$



- **Cómo leerla:** cada línea es el modelo después de b rondas; a la derecha, su error en el entrenamiento.
- Con una ronda, casi el promedio; con 10, un escalón tímido; con 50, la forma; con 500, una escalera fina que persigue los puntos.
- El error de entrenamiento sólo baja (de 11,6 a 6,4). El de prueba toca fondo en 7,1 (ronda 48) y en la 500 va en 7,3: **a diferencia del bosque, aquí más rondas sí sobreajustan**.

¿Por qué ajustarse a los residuos?

El residuo le dice al modelo hacia dónde corregir, y cuánto, en cada puesto

- **El residuo es una instrucción.** Si el modelo predice 69,1 y el puesto votó 80, el residuo es $+10{,}9$: ahí hay que subir. Si votó 50, es $-19{,}1$: ahí hay que bajar.
- **El árbol pequeño la convierte en una regla:** no corrige puesto por puesto (eso sería memorizar); busca grupos de puestos con residuos parecidos y corrige al grupo entero.
- **La fracción η es el tamaño del paso:** se corrige un poco, se vuelve a medir lo que falta y se corrige otra vez.
- **De ahí el nombre, gradient boosting.** Con el error cuadrático, $L_i = \frac{1}{2}\big(y_i - f(x_i)\big)^2$, el residuo es su derivada con el signo cambiado:

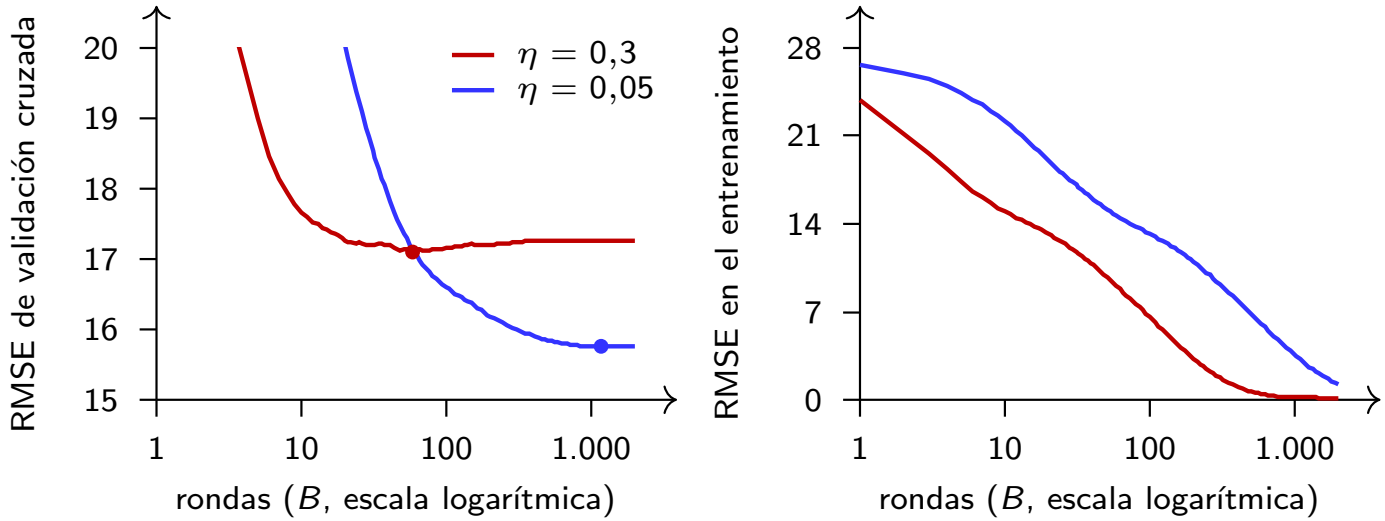
$$-\frac{\partial L_i}{\partial f(x_i)} \;=\; y_i - f(x_i) \;=\; r_i.$$

  Moverse en la dirección del residuo es bajar el error por el camino más corto: un descenso por gradiente, con pasos de tamaño η.

Con otra medida de error sólo cambia el "residuo": para `gana_petro`, $y_i - \hat{p}_i$ (apéndice A2).

¿Cuántas rondas y qué tan rápido? Elegir B y η

El país con las 37 variables del censo: el error de validación cruzada (izquierda) y el de entrenamiento (derecha)



- **Cómo leerla:** en los dos ejes horizontales, las rondas B. Rojo: de cada árbol se suma el 30 % ($\eta = 0{,}3$). Azul: el 5 % ($\eta = 0{,}05$).
- **B, las rondas:** en el entrenamiento (derecha) el error siempre baja. En validación cruzada (izquierda) baja, toca un mínimo y vuelve a subir: desde ahí las rondas nuevas sólo memorizan. Se para en el mínimo (*parada temprana*).
- **η, la tasa:** con 0,3 el mínimo llega en la ronda 58 (17,1); con 0,05 llega en la 1.167 y más abajo (15,8). Más despacio es mejor; el precio es tiempo de cómputo.

Árbol, bosque y *boosting*, lado a lado

Qué hace cada uno, qué hay que elegir y cómo se elige

	Un árbol	**Bosque aleatorio**	**Boosting**
Cuántos árboles	uno	cientos, cada uno por su lado	cientos o miles, en fila
De qué tamaño	mediano: se poda	grandes, sin podar	pequeños
Cómo se combinan	—	se promedian	se suman: cada uno corrige a los anteriores
Qué se elige	el número de hojas	casi nada: $m \approx p/3$	las rondas B, la tasa η y el tamaño d
Cómo se elige	validación cruzada	el error fuera de la bolsa	validación cruzada, con parada temprana
Más árboles	—	nunca sobreajustan	sí sobreajustan
¿Se puede leer?	sí	no	no
En R	`rpart`	`randomForest`	`xgboost`

Hoy: bosques con $m = 12$ y hojas de 5 puestos; *boosting* con $\eta = 0{,}05$ y $d = 6$. Todos se comparan en la misma prueba, abierta una sola vez (apéndice A6).

1 El árbol: partir y promediar

2 El bosque: promediar para bajar la varianza

3 El *boosting*: aprender despacio

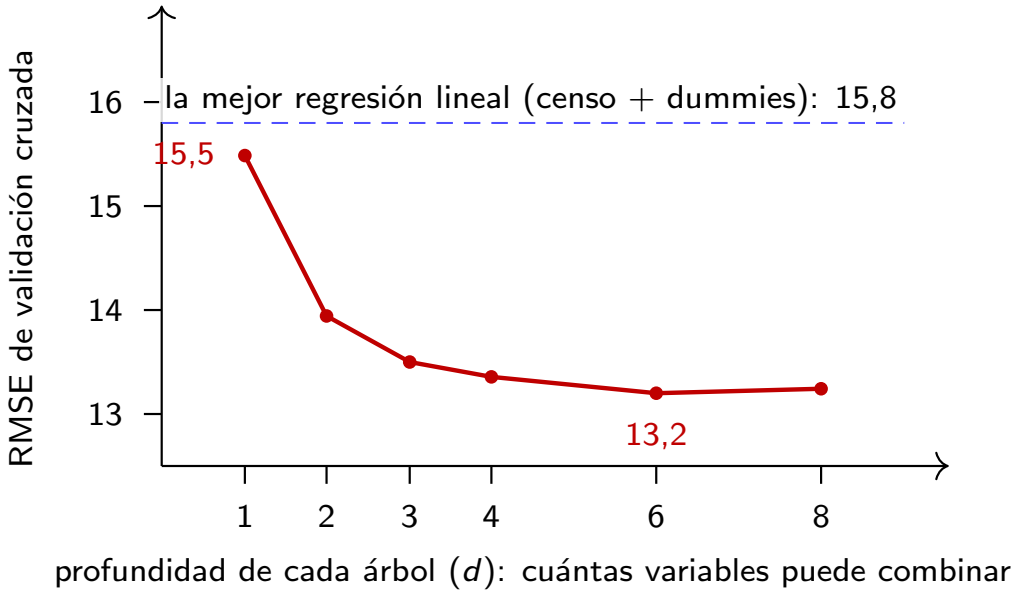
4 La carrera: ¿encontró la máquina las interacciones?

5 ¿Y si la pregunta es de clasificación?

6 Cierre

¿Cuánto valen las interacciones?

El mismo *boosting* con censo + departamento; sólo cambia d, el tamaño de cada árbol



- **Qué es d:** cuántos cortes encadena cada árbol pequeño, es decir, cuántas variables puede combinar. La línea punteada es la mejor regresión lineal de la semana 3.
- $d = 1$**:** un corte por árbol, una sola variable: el modelo no puede combinar variables. Deja 15,5, casi lo mismo que la regresión lineal (15,8).
- $d = 2$ ya combina de a dos: 13,9. $d = 6$**:** 13,2. Entre $d = 1$ y $d = 6$ hay 2,3 puntos: eso valen las interacciones, que el modelo encontró solo. **La respuesta a la pregunta de hoy es sí.**

La carrera: todos los modelos, la misma prueba

RMSE de validación cruzada (CV) y de prueba (2.398 puestos, abiertos una sola vez)

Variables	Modelo	CV	Prueba
—	el promedio (la referencia)	27,3	26,7
Censo (37)	regresión lineal	20,3	19,8
	un árbol podado (105 hojas)	19,5	19,1
	bosque	15,9	15,6
	boosting	15,8	15,7
Censo + departamento	regresión lineal (la mejor de la semana 3)	15,8	15,6
	un árbol podado (98 hojas)	15,7	15,7
	bosque	13,3	12,9
	boosting	13,2	**12,8**
+ coordenadas	bosque	12,3	12,1
	boosting	12,2	**12,1**

En los bosques, la columna CV es el error fuera de la bolsa (apéndice A7).

- **Un árbol solo no le gana a la regresión lineal** (15,7 contra 15,6). Cientos de árboles, sí.
- **Con las mismas variables,** bosque y *boosting* le ganan a la mejor regresión lineal por casi 3 puntos (12,9 y 12,8 contra 15,6). **Sin conocer el departamento** llegan a 15,6 y 15,7: lo mismo que la regresión lineal que sí lo conoce.
- **Con las coordenadas** (longitud y latitud, como dos variables más) llegan a 12,1: dónde queda el puesto dice algo que el censo y el departamento no dicen.

1 El árbol: partir y promediar

2 El bosque: promediar para bajar la varianza

3 El *boosting*: aprender despacio

4 La carrera: ¿encontró la máquina las interacciones?

5 ¿Y si la pregunta es de clasificación?

6 Cierre

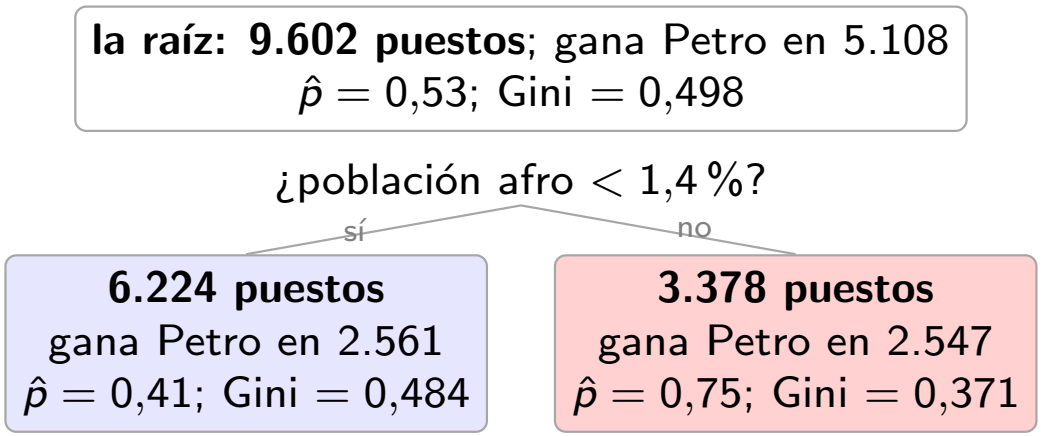
Clasificar con un árbol: el mismo algoritmo, otra medida

La y ahora es `gana_petro`: 1 si Petro sacó más votos que Hernández (ISL, sección 8.1.2)

Cambian sólo dos cosas: (1) **la hoja predice** la fracción de sus puestos donde ganó Petro, $\hat{p}$, una probabilidad; (2) **un corte se califica** por qué tan **mezclados** quedan los dos grupos, no por el RSS.

El índice de Gini de un grupo, $G = 2\,\hat{p}\,(1-\hat{p})$, mide la mezcla: vale 0 si en todos sus puestos ganó el mismo (un grupo puro) y 0,5 si están mitad y mitad.

Lo demás es igual: se prueban todos los cortes candidatos y gana el de menor Gini promedio en sus dos grupos.



El primer corte del país: el Gini promedio de los dos grupos, ponderado por su tamaño, es $\frac{6.224}{9.602} \times 0{,}484 + \frac{3.378}{9.602} \times 0{,}371 = 0{,}444$, menos que el 0,498 de la raíz. Ningún otro corte lo baja más.

Video: Clasificación con árboles de decisión (Codificando Bits, 15 minutos). Para mover el corte con el ratón: mlu-explain.github.io/decision-tree.

¿Gana Petro? Los mismos modelos, la otra pregunta

El costo usa los precios de la campaña de la semana 4 (umbral 0,83)

Modelo	AUC de CV	AUC de prueba	Brier	Costo
Logística, censo + dummies (semana 4)	0,920	0,916	0,115	695
un árbol podado, censo + departamento	–	0,896	0,122	819
bosque, censo + departamento	0,942	0,943	0,096	617
boosting, censo + departamento	0,944	0,941	0,096	609
bosque, + coordenadas	0,949	0,950	0,090	589
boosting, + coordenadas	0,953	0,950	0,087	625

El *Brier*, $\frac{1}{n}\sum_i(\hat{p}_i - y_i)^2$, es el MSE de las probabilidades (apéndice A7 de la semana 4).

- **Cómo dan una probabilidad:** en el bosque cada árbol vota y $\hat{p}$ es la fracción de árboles que dice "gana Petro"; el *boosting* suma árboles pequeños sobre $y - \hat{p}$ (apéndice A2).
- **Un árbol solo ordena peor que la logística** (0,896 contra 0,916). Bosque y *boosting*, mejor (0,943 y 0,941), y la campaña gasta menos (617 y 609 contra 695).
- **Ordenar no es decidir** (semana 4): con coordenadas, el *boosting* tiene mejor Brier que el bosque (0,087 contra 0,090), pero con el umbral de 0,83 le cuesta más (625 contra 589).

1 El árbol: partir y promediar

2 El bosque: promediar para bajar la varianza

3 El *boosting*: aprender despacio

4 La carrera: ¿encontró la máquina las interacciones?

5 ¿Y si la pregunta es de clasificación?

6 Cierre

Cuándo usar qué

- **Una regresión lineal:** si la relación es casi lineal, hay pocos datos por variable, o se necesita leer coeficientes o salir con cuidado del rango de los datos. En Cali ganó la recta.
- **Un árbol:** para explicar una regla sencilla (un semáforo de riesgo), más que para predecir.
- **Un bosque:** el mejor modelo "de caja": casi nada que afinar y poco sensible a lo que se elija. El primer candidato con datos tabulares.
- **Un boosting:** casi siempre el más preciso con datos tabulares, si se eligen η, d y B con validación cruzada. En 45 bases tabulares de tamaño mediano, los ensambles de árboles todavía le ganan a las redes (Grinsztajn, Oyallon y Varoquaux, 2022).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- Molnar (2025), *Interpretable Machine Learning*: los capítulos de importancia por permutación, dependencia parcial y SHAP. Libro abierto en línea.
  Guía: cada capítulo trae ventajas, desventajas y código; lean las desventajas dos veces.

Problem Set 1: se entrega el martes 20 de octubre a las 8:00, al empezar la sesión 6.

Próxima sesión — abrir la caja negra: hoy ganó un modelo que no se lee: cientos de árboles y miles de cortes. ¿Qué variables usa, cómo se mueve la predicción cuando cambia una, y por qué predice lo que predice en un puesto? Importancia por permutación, dependencia parcial y SHAP, con sus advertencias.

Aplicación en R: los mismos puestos y las dos preguntas: un árbol que se pueda leer, un bosque y un *boosting*, contra los mejores de las semanas 3 y 4, en la misma prueba.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 8. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Secs. 9.2, 10 y 15. [ESL]
- Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Breiman, L. (1996). Bagging Predictors. *Machine Learning*, 24(2), 123–140.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Friedman, J. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- Para repasar: Codificando Bits, Regresión con árboles de decisión y Clasificación con árboles de decisión (videos); MLU-Explain, Decision Trees y Random Forest (visualizaciones interactivas).
- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.). https://christophm.github.io/interpretable-ml-book/ [próxima sesión]
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

7 Apéndice: para profundizar

A1. El promedio de árboles correlacionados

Sean $T_1, \ldots, T_B$ las predicciones de B árboles en un punto x, con la misma distribución, $\mathrm{Var}(T_b) = \sigma^2$ y correlación ρ entre dos cualesquiera:

$$\mathrm{Var}\Big(\frac{1}{B}\sum_b T_b\Big) \;=\; \frac{1}{B^2}\Big[\sum_b \mathrm{Var}(T_b) + \sum_{b\neq b'} \mathrm{Cov}(T_b, T_{b'})\Big]$$

$$= \;\frac{B\sigma^2 + B(B-1)\,\rho\,\sigma^2}{B^2} \;=\; \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2$$

- Con $B \to \infty$ queda $\rho\,\sigma^2$: más árboles no bajan la varianza por debajo de ese piso.
- El bosque baja ρ con $m < p$, a cambio de subir un poco la varianza y el sesgo de cada árbol. El m que conviene equilibra las dos cosas (ESL, sección 15.4).
- El sesgo del promedio es el de cada árbol: por eso se promedian árboles grandes, de poco sesgo, y no árboles podados.

A2. *Gradient boosting* con cualquier pérdida

El algoritmo general (Friedman, 2001; ESL, algoritmo 10.3):

1. $f_0(x) = \arg\min_\gamma \sum_i L(y_i, \gamma)$: la media con pérdida cuadrática; el log-odds de la prevalencia con la log-loss.
2. Para $b = 1, \ldots, B$: (a) los pseudo-residuos $r_{ib} = -\left[\partial L(y_i, f(x_i))/\partial f(x_i)\right]_{f=f_{b-1}}$; (b) un árbol con hojas R_{jb} ajustado a los r_{ib}; (c) en cada hoja, el mejor paso $\gamma_{jb} = \arg\min_\gamma \sum_{x_i \in R_{jb}} L(y_i, f_{b-1}(x_i) + \gamma)$; (d) $f_b(x) = f_{b-1}(x) + \eta \sum_j \gamma_{jb} \mathbb{I}\{x \in R_{jb}\}$.

Pérdida	$L(y, f)$	$-\partial L/\partial f$
Cuadrática	$\frac{1}{2}(y - f)^2$	$y - f$
Absoluta	$\lvert y - f \rvert$	signo$(y - f)$
Log-loss (f en log-odds)	$-yf + \log(1 + e^f)$	$y - \hat{p}$

- Con pérdida cuadrática, (c) es la media de los residuos en cada hoja: el algoritmo 8.2 de ISL.
- **Submuestreo** (Friedman, 2002): cada árbol ve una fracción de las filas; como en el bosque, baja la correlación entre pasos. Hoy, el 80 %.

A3. xgboost: la segunda derivada y un precio por hoja

En la ronda b, con $g_i = \partial L/\partial \hat{y}_i$ y $h_i = \partial^2 L/\partial \hat{y}_i^2$ evaluadas en la predicción anterior (Chen y Guestrin, 2016):

$$\sum_i \left[g_i\, f_b(x_i) + \tfrac{1}{2}\, h_i\, f_b(x_i)^2 \right] \;+\; \gamma\, T \;+\; \tfrac{1}{2}\,\lambda \sum_{j=1}^{T} w_j^2$$

donde T es el número de hojas y w_j el valor de la hoja j. Con $G_j = \sum_{i \in j} g_i$ y $H_j = \sum_{i \in j} h_i$, el mejor valor de cada hoja y la ganancia de un corte son

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \qquad \frac{1}{2}\left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

- **Pérdida cuadrática:** $g_i = \hat{y}_i - y_i$ y $h_i = 1$, así que $w_j^* = \sum_{i \in j} r_i/(n_j + \lambda)$: la media de los residuos de la hoja, encogida hacia cero. Ridge en cada hoja.
- **Log-loss:** $g_i = \hat{p}_i - y_i$ y $h_i = \hat{p}_i(1 - \hat{p}_i)$: el hessiano de la logística de la semana 4. Cada ronda es un paso de Newton.
- γ es un precio por hoja, como el α de la poda: un corte entra sólo si gana más de γ.

A4. Variables cualitativas y datos faltantes en un árbol

- Una variable con q categorías se puede partir en dos de $2^{q-1} - 1$ maneras. Con los 33 departamentos, 4.294.967.295.
- **El atajo:** en regresión (y en clasificación con dos clases), ordenar las categorías por la media de y y probar sólo los $q - 1$ cortes en ese orden; el mejor corte está entre ellos (Breiman et al., 1984; ESL, sección 9.2.4). Es lo que hizo el árbol con los departamentos.
- **El riesgo:** una variable con muchas categorías tiene muchas oportunidades de cortar bien por azar, y tiende a elegirse de más. Vuelve en la semana 6, con la importancia de variables.
- **Datos faltantes:** `rpart` usa cortes sustitutos (otra variable que imita el corte); `xgboost` aprende, en cada corte, hacia qué lado mandar los faltantes.

A5. Otros ensambles de árboles

- **Extra-trees** (Geurts, Ernst y Wehenkel, 2006): también el umbral de cada corte se sortea. Árboles todavía menos parecidos, a cambio de más sesgo.
- **BART** (Chipman, George y McCulloch, 2010; ISL, sección 8.2.4): una suma de K árboles pequeños; en cada iteración se perturba cada árbol (un corte más, uno menos, otros valores en las hojas) hacia su residuo parcial. Es un MCMC: después de un período de calentamiento se promedia, y los percentiles dan la incertidumbre. Funciona bien casi sin afinar.
- **Bosques de cuantiles** (Meinshausen, 2006): cada hoja guarda sus y, no sólo su media; se predicen cuantiles y, con ellos, intervalos.
- **Bosques honestos y causales** (Wager y Athey, 2018): una mitad de la muestra elige los cortes y la otra estima el valor de las hojas; con ellos se estiman efectos heterogéneos. Es el puente con la inferencia causal de la sesión 8.

A6. Las perillas en R

Paquete	Perilla	Qué controla	Hoy
`rpart`	`cp`	el precio por hoja, α dividido por el RSS de la raíz	0, y se poda
	`minsplit`, `minbucket`	tamaño mínimo para cortar y de cada hoja	20 y 7
	`xval`	los pliegues de la validación cruzada	los de la semana 3
`randomForest`	`ntree`	B	300 o 500
	`mtry`	m	$p/3$
	`nodesize`	tamaño mínimo de la hoja	5 (1 en clasificación)
`xgboost`	`nrounds`, `early_stopping_rounds`	B, y cuántas rondas sin mejorar esperar	hasta 10.000; 50
	`eta`	η, la tasa	0,05
	`max_depth`	d, la profundidad	6
	`subsample`, `colsample_bytree`	fracción de filas y de columnas por árbol	0,8 y 0,8
	`lambda`, `gamma`	el Ridge de las hojas y el precio por hoja (A3)	1 y 0

A7. El error fuera de la bolsa: una prueba que sale gratis

Cada árbol del bosque deja por fuera a cerca de un tercio de los puestos (ISL, sección 8.2.1)

- La muestra de cada árbol se sortea con reemplazo y deja por fuera, en promedio, al 36,8 % de los puestos: $(1 - 1/n)^n \to e^{-1}$. Con 300 árboles, cada puesto queda por fuera ("fuera de la bolsa", *out-of-bag*, OOB) en unos 110.
- **La predicción fuera de la bolsa** de un puesto promedia sólo los árboles que no lo vieron: es honesta, como la de un pliegue de la validación cruzada.
- Con $m = 12$: 15,9 fuera de la bolsa y 15,6 en la prueba. Sin pliegues ni reajustes, el bosque trae su propia validación; con B grande, se parece al LOOCV.

Regla de oro #3, otra vez

El error fuera de la bolsa valida el bosque, no lo que se hizo *antes* de él: si las variables se eligieron mirando todos los datos, también miente.

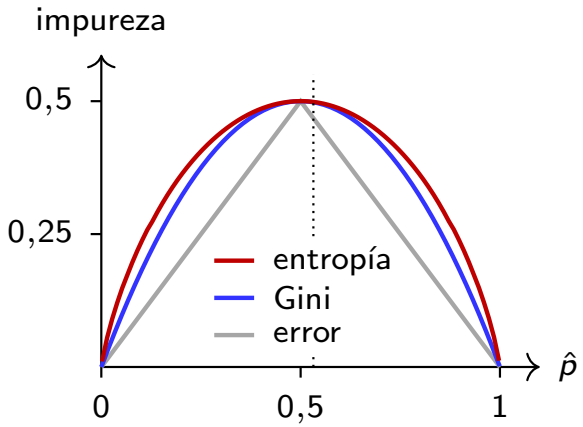
A8. Tres medidas de impureza: error, Gini y entropía

Árboles de clasificación: tres maneras de medir qué tan mezclado queda un grupo (ISL, sección 8.1.2)

- En cada hoja, la fracción de puestos que ganó Petro, $\hat{p}$, es la probabilidad de la semana 4; con los costos, se decide con τ^*.
- Un corte se califica con la **impureza** de las dos mitades, ponderada por su tamaño:

$$\text{error: } E = 1 - \max(\hat{p}, 1-\hat{p})$$
$$\text{Gini: } G = 2\,\hat{p}\,(1-\hat{p})$$
$$\text{entropía: } D = -\hat{p}\log\hat{p} - (1-\hat{p})\log(1-\hat{p})$$

- En la raíz, $\hat{p} = 0{,}53$ y $G = 0{,}498$. El primer corte (afro en 1,4 %) deja 0,41 por debajo y 0,75 por encima: el Gini ponderado baja a 0,444; el error, de 0,468 a 0,353.



(la entropía, reescalada para que su máximo sea 0,5)

Por qué Gini o entropía para crecer: son curvas y premian las hojas más puras aunque la clase mayoritaria no cambie; el error es recto a trozos y no ve esos cortes. Para podar, si lo que importa es acertar, el error (ISL).

Referencias del apéndice

- Friedman, J. (2002). Stochastic Gradient Boosting. *Computational Statistics & Data Analysis*, 38(4), 367–378. [A2]
- Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely Randomized Trees. *Machine Learning*, 63(1), 3–42. [A5]
- Meinshausen, N. (2006). Quantile Regression Forests. *Journal of Machine Learning Research*, 7, 983–999. [A5]
- Chipman, H., George, E., & McCulloch, R. (2010). BART: Bayesian Additive Regression Trees. *Annals of Applied Statistics*, 4(1), 266–298. [A5]
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228–1242. [A5]