

Big Data y Machine Learning para Economía Aplicada

Week 05: Selección de variables y regularización

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 9, 2026

Previously...

- **La prueba responde una pregunta y una sola vez;** elegir modelos e hiperparámetros se hace dentro del entrenamiento con validación cruzada: la curva de CV con sus barras, el mínimo o la regla 1-SE.

Previously...

- **La prueba responde una pregunta y una sola vez;** elegir modelos e hiperparámetros se hace dentro del entrenamiento con validación cruzada: la curva de CV con sus barras, el mínimo o la regla 1-SE.
- **Regla de oro #3:** el CV valida *pipelines*: todo lo que aprende de los datos ocurre dentro de cada pliegue.

Previously...

- **La prueba responde una pregunta y una sola vez;** elegir modelos e hiperparámetros se hace dentro del entrenamiento con validación cruzada: la curva de CV con sus barras, el mínimo o la regla 1-SE.
- **Regla de oro #3:** el CV valida *pipelines*: todo lo que aprende de los datos ocurre dentro de cada pliegue.
- El *k*-fold aleatorio miente con tiempo, espacio y grupos; el *bootstrap* pone intervalos a cualquier métrica.

Previously...

- **La prueba responde una pregunta y una sola vez;** elegir modelos e hiperparámetros se hace dentro del entrenamiento con validación cruzada: la curva de CV con sus barras, el mínimo o la regla 1-SE.
- **Regla de oro #3:** el CV valida *pipelines*: todo lo que aprende de los datos ocurre dentro de cada pliegue.
- El *k*-fold aleatorio miente con tiempo, espacio y grupos; el *bootstrap* pone intervalos a cualquier métrica.
- Y desde la sesión 2 arrastramos una promesa: con muchos predictores, OLS sobreajusta y “algo de sesgo a cambio de mucha varianza” mejora la predicción. Hoy se cumple.

Previously...

- **La prueba responde una pregunta y una sola vez;** elegir modelos e hiperparámetros se hace dentro del entrenamiento con validación cruzada: la curva de CV con sus barras, el mínimo o la regla 1-SE.
- **Regla de oro #3:** el CV valida *pipelines*: todo lo que aprende de los datos ocurre dentro de cada pliegue.
- El *k*-fold aleatorio miente con tiempo, espacio y grupos; el *bootstrap* pone intervalos a cualquier métrica.
- Y desde la sesión 2 arrastramos una promesa: con muchos predictores, OLS sobreajusta y “algo de sesgo a cambio de mucha varianza” mejora la predicción. Hoy se cumple.

Hoy

Predecir con **muchos predictores** sin sobreajustar: seleccionar (subconjuntos, criterios), **encoger** (Ridge, Lasso, Elastic Net) y **comprimir** (PCR, PLS). El hiperparámetro λ se elige con la curva de CV de la semana pasada. Y una lección que vale por toda la sesión: lo que sobrevive a la penalización son *predictores*, no *causas*.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre

De dónde salen tantos predictores

- **Datos administrativos y transaccionales:** cientos de características por unidad.

De dónde salen tantos predictores

- **Datos administrativos y transaccionales:** cientos de características por unidad.
- **Texto e imágenes convertidos en variables:** miles de columnas (sesión 8).

De dónde salen tantos predictores

- **Datos administrativos y transaccionales:** cientos de características por unidad.
- **Texto e imágenes convertidos en variables:** miles de columnas (sesión 8).
- **Flexibilidad que nosotros mismos creamos:** *dummies* finas, polinomios, *splines* e interacciones. Con 30 variables base y sus interacciones de a pares, $30 + \binom{30}{2} = 465$ regresores; con cuadrados y triples, miles.

De dónde salen tantos predictores

- **Datos administrativos y transaccionales:** cientos de características por unidad.
- **Texto e imágenes convertidos en variables:** miles de columnas (sesión 8).
- **Flexibilidad que nosotros mismos creamos:** *dummies* finas, polinomios, *splines* e interacciones. Con 30 variables base y sus interacciones de a pares, $30 + \binom{30}{2} = 465$ regresores; con cuadrados y triples, miles.

Tres regímenes:

- 1 p fijo y $n \rightarrow \infty$: Econometría I; OLS funciona.
- 2 p comparable a n : OLS “funciona” pero tiembla: varianzas enormes, coeficientes inestables.
- 3 $p > n$: OLS ni siquiera está definido de manera única.

De dónde salen tantos predictores

- **Datos administrativos y transaccionales:** cientos de características por unidad.
- **Texto e imágenes convertidos en variables:** miles de columnas (sesión 8).
- **Flexibilidad que nosotros mismos creamos:** *dummies* finas, polinomios, *splines* e interacciones. Con 30 variables base y sus interacciones de a pares, $30 + \binom{30}{2} = 465$ regresores; con cuadrados y triples, miles.

Tres regímenes:

- 1 p fijo y $n \rightarrow \infty$: Econometría I; OLS funciona.
- 2 p comparable a n : OLS “funciona” pero tiembla: varianzas enormes, coeficientes inestables.
- 3 $p > n$: OLS ni siquiera está definido de manera única.

El punto

La alta dimensión aparece apenas uno controla *flexiblemente* por covariables: lo que hicimos con la vivienda en la sesión 2.

Qué falla, exactamente: información por parámetro

Con $p > n$: $\mathbf{X}'\mathbf{X}$ es singular; existen infinitos β que ajustan los datos **perfectamente** ($\text{RSS} = 0$, $R^2 = 1$) sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura: el ajuste dentro de muestra pierde todo contenido informativo.

Qué falla, exactamente: información por parámetro

Con $p > n$: $\mathbf{X}'\mathbf{X}$ es singular; existen infinitos β que ajustan los datos **perfectamente** ($\text{RSS} = 0$, $R^2 = 1$) sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura: el ajuste dentro de muestra pierde todo contenido informativo. **Con $p < n$ pero predictores muy correlacionados:** sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ y v_j sus autovectores. La varianza de OLS en la dirección v_j es

$$\text{Var}(v_j' \hat{\beta}) = \frac{\sigma^2}{d_j}.$$

En las direcciones con d_j pequeño (combinaciones casi colineales) la varianza **explota**: los datos casi no varían ahí, casi no informan, y OLS adivina con enorme ruido.

Qué falla, exactamente: información por parámetro

Con $p > n$: $\mathbf{X}'\mathbf{X}$ es singular; existen infinitos β que ajustan los datos **perfectamente** ($\text{RSS} = 0$, $R^2 = 1$) sin que haya ninguna relación real. Es la memorización de la sesión 1 en su forma más pura: el ajuste dentro de muestra pierde todo contenido informativo. **Con $p < n$ pero predictores muy correlacionados:** sean $d_1 \geq \dots \geq d_p > 0$ los autovalores de $\mathbf{X}'\mathbf{X}$ y v_j sus autovectores. La varianza de OLS en la dirección v_j es

$$\text{Var}(v_j' \hat{\beta}) = \frac{\sigma^2}{d_j}.$$

En las direcciones con d_j pequeño (combinaciones casi colineales) la varianza **explota**: los datos casi no varían ahí, casi no informan, y OLS adivina con enorme ruido.

Moraleja

El enemigo no es p grande *per se*: es la **información por parámetro**. Alta dimensión = muchos parámetros persiguiendo poca variación independiente. Las tres salidas de hoy (seleccionar, encoger, comprimir) reducen el número efectivo de parámetros.

Seleccionar variables: subconjuntos y *stepwise*

Pregunta previa: ¿por qué no comparar modelos por su R^2 ?

Seleccionar variables: subconjuntos y *stepwise*

Pregunta previa: ¿por qué no comparar modelos por su R^2 ? Porque *siempre* mejora al agregar variables: es ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada.

Seleccionar variables: subconjuntos y *stepwise*

Pregunta previa: ¿por qué no comparar modelos por su R^2 ? Porque *siempre* mejora al agregar variables: es ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada. **Los enfoques clásicos** (ISL 6.1):

- **Mejor subconjunto:** probar los 2^p modelos. Con $p = 20$, un millón; con $p = 40$, 10^{12} . Inviabile rápido.
- **Forward stepwise:** empezar vacío y agregar en cada paso la variable que más mejora el ajuste ($\approx p^2/2$ ajustes). **Backward:** empezar completo e ir quitando (requiere $n > p$). Ambos son *greedy*: no garantizan el mejor subconjunto.

Seleccionar variables: subconjuntos y *stepwise*

Pregunta previa: ¿por qué no comparar modelos por su R^2 ? Porque *siempre* mejora al agregar variables: es ajuste *dentro* de muestra. Comparar un modelo de 3 variables con uno de 30 por R^2 es una carrera arreglada. **Los enfoques clásicos** (ISL 6.1):

- **Mejor subconjunto:** probar los 2^p modelos. Con $p = 20$, un millón; con $p = 40$, 10^{12} . Inviabile rápido.
- **Forward stepwise:** empezar vacío y agregar en cada paso la variable que más mejora el ajuste ($\approx p^2/2$ ajustes). **Backward:** empezar completo e ir quitando (requiere $n > p$). Ambos son *greedy*: no garantizan el mejor subconjunto.
- En todos los casos queda la pregunta de fondo: entre el mejor modelo de 3 variables y el mejor de 8, **¿cuál gana?** Hay que corregir el optimismo del error de entrenamiento: con un criterio o con CV.
- Y una decisión *discreta* (dentro o fuera) es **inestable**: pequeñas perturbaciones de los datos cambian el modelo entero. Guarden esta objeción.

Criterios de información frente a la validación cruzada

La idea común: error de entrenamiento + un castigo por parámetro usado (d parámetros, $\hat{\sigma}^2$ estima la varianza del error):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2), \quad \text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2).$$

El AIC es proporcional a C_p en el modelo lineal gaussiano; el BIC castiga más ($\log n > 2$ para $n \geq 8$) y elige modelos más pequeños.

Criterios de información frente a la validación cruzada

La idea común: error de entrenamiento + un castigo por parámetro usado (d parámetros, $\hat{\sigma}^2$ estima la varianza del error):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2), \quad \text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2).$$

El AIC es proporcional a C_p en el modelo lineal gaussiano; el BIC castiga más ($\log n > 2$ para $n \geq 8$) y elige modelos más pequeños.

	Criterios (C_p , AIC, BIC)	Validación cruzada
Costo	un ajuste	k ajustes
Supuestos	modelo casi correcto, $\hat{\sigma}^2$	casi ninguno
¿Qué es d ?	claro en modelos lineales	no lo necesita
¿Bosques, <i>boosting</i> , redes?	no (d mal definido)	sí

Criterios de información frente a la validación cruzada

La idea común: error de entrenamiento + un castigo por parámetro usado (d parámetros, $\hat{\sigma}^2$ estima la varianza del error):

$$C_p = \frac{1}{n}(\text{RSS} + 2 d \hat{\sigma}^2), \quad \text{BIC} = \frac{1}{n}(\text{RSS} + \log(n) d \hat{\sigma}^2).$$

El AIC es proporcional a C_p en el modelo lineal gaussiano; el BIC castiga más ($\log n > 2$ para $n \geq 8$) y elige modelos más pequeños.

	Criterios (C_p , AIC, BIC)	Validación cruzada
Costo	un ajuste	k ajustes
Supuestos	modelo casi correcto, $\hat{\sigma}^2$	casi ninguno
¿Qué es d ?	claro en modelos lineales	no lo necesita
¿Bosques, <i>boosting</i> , redes?	no (d mal definido)	sí

- Los criterios nacieron cuando ajustar un modelo era **caro**. Hoy el cómputo es barato y los métodos son flexibles: ¿cuántos parámetros tiene un bosque? Nadie sabe.
- **Veredicto del curso:** CV por defecto para todo; criterios como referencia rápida en modelos lineales clásicos.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar:** cada variable está dentro o fuera. Decisión discreta $\Rightarrow$ varianza alta.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar:** cada variable está dentro o fuera. Decisión discreta $\Rightarrow$ varianza alta.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Formulación general:

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\sum_{i=1}^n (y_i - x_i' \beta)^2}_{\text{ajuste}} + \lambda \cdot \underbrace{\mathcal{P}(\beta)}_{\text{penalización}}$$

Cambio de filosofía: de seleccionar a encoger

- **Seleccionar:** cada variable está dentro o fuera. Decisión discreta $\Rightarrow$ varianza alta.
- **Encoger** (*shrinkage*): mantener todas las variables pero **empujar los coeficientes hacia cero** de forma continua y controlada.

Formulación general:

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\sum_{i=1}^n (y_i - x_i' \beta)^2}_{\text{ajuste}} + \lambda \cdot \underbrace{\mathcal{P}(\beta)}_{\text{penalización}}$$

- $\lambda \geq 0$ es la **perilla continua** de complejidad: $\lambda = 0$ es OLS; $\lambda \rightarrow \infty$ manda todos los coeficientes a cero. Se elige por **CV** (la curva de la sesión 4).
- **Parámetros:** β . **Hiperparámetros:** λ (y α en Elastic Net). Hoy: tres penalizaciones $\mathcal{P}$, tres estimadores. Y la promesa de la sesión 1 en una frase: un poco de sesgo (encoger) compra mucha varianza cuando hay poca información por parámetro.

Ridge: encoger todo un poco

Problema (Hoerl & Kennard, 1970): $\mathcal{P}(\beta) = \sum_j \beta_j^2$.

$$\hat{\beta}^R = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \Rightarrow \quad \hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

Ridge: encoger todo un poco

Problema (Hoerl & Kennard, 1970): $\mathcal{P}(\beta) = \sum_j \beta_j^2$.

$$\hat{\beta}^R = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \implies \quad \hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

- La única diferencia con OLS es λ sumado a la diagonal (la derivación, en el apéndice). Los autovalores de $\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}$ son $d_j + \lambda > 0$: la inversa **siempre existe**, incluso con $p > n$, y las direcciones enfermas (d_j pequeño) son las que más se encogen. Ridge desconfía donde los datos informan poco.

Ridge: encoger todo un poco

Problema (Hoerl & Kennard, 1970): $\mathcal{P}(\beta) = \sum_j \beta_j^2$.

$$\hat{\beta}^R = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \implies \quad \hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

- La única diferencia con OLS es λ sumado a la diagonal (la derivación, en el apéndice). Los autovalores de $\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}$ son $d_j + \lambda > 0$: la inversa **siempre existe**, incluso con $p > n$, y las direcciones enfermas (d_j pequeño) son las que más se encogen. Ridge desconfía donde los datos informan poco.
- Con $\mathbf{X}$ ortonormal, $\hat{\beta}_j^R = \hat{\beta}_j^{OLS} / (1 + \lambda)$: encogimiento **proporcional**; ningún coeficiente llega exactamente a cero.

Ridge: encoger todo un poco

Problema (Hoerl & Kennard, 1970): $\mathcal{P}(\beta) = \sum_j \beta_j^2$.

$$\hat{\beta}^R = \arg \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}'_i \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \implies \quad \hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

- La única diferencia con OLS es λ sumado a la diagonal (la derivación, en el apéndice). Los autovalores de $\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}$ son $d_j + \lambda > 0$: la inversa **siempre existe**, incluso con $p > n$, y las direcciones enfermas (d_j pequeño) son las que más se encogen. Ridge desconfía donde los datos informan poco.
- Con $\mathbf{X}$ ortonormal, $\hat{\beta}_j^R = \hat{\beta}_j^{OLS} / (1 + \lambda)$: encogimiento **proporcional**; ningún coeficiente llega exactamente a cero.
- **Sesgo–varianza** (ISL, Fig. 6.5): al subir λ , la varianza cae rápido y el sesgo sube despacio; siempre existe un $\lambda > 0$ con menor MSE de prueba que OLS. Dónde está, lo dice el CV.

Ridge: encoger todo un poco

Problema (Hoerl & Kennard, 1970): $\mathcal{P}(\beta) = \sum_j \beta_j^2$.

$$\hat{\beta}^R = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \implies \quad \hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

- La única diferencia con OLS es λ sumado a la diagonal (la derivación, en el apéndice). Los autovalores de $\mathbf{X}'\mathbf{X} + \lambda \mathbf{I}$ son $d_j + \lambda > 0$: la inversa **siempre existe**, incluso con $p > n$, y las direcciones enfermas (d_j pequeño) son las que más se encogen. Ridge desconfía donde los datos informan poco.
- Con $\mathbf{X}$ ortonormal, $\hat{\beta}_j^R = \hat{\beta}_j^{OLS} / (1 + \lambda)$: encogimiento **proporcional**; ningún coeficiente llega exactamente a cero.
- **Sesgo–varianza** (ISL, Fig. 6.5): al subir λ , la varianza cae rápido y el sesgo sube despacio; siempre existe un $\lambda > 0$ con menor MSE de prueba que OLS. Dónde está, lo dice el CV.

Cuándo brilla

Muchos predictores con efectos pequeños y repartidos, o muy correlacionados entre sí: encoger todo un poco es mejor que apostar por unos cuantos.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años”, pero sus magnitudes no son comparables. Si mido el ingreso en miles, su β se multiplica por mil y se penaliza de otra forma.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años”, pero sus magnitudes no son comparables. Si mido el ingreso en miles, su β se multiplica por mil y se penaliza de otra forma.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar; así λ trata a todos por igual. Los coeficientes se reportan de vuelta en la escala original.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años”, pero sus magnitudes no son comparables. Si mido el ingreso en miles, su β se multiplica por mil y se penaliza de otra forma.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar; así λ trata a todos por igual. Los coeficientes se reportan de vuelta en la escala original.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones sin ganar nada.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años”, pero sus magnitudes no son comparables. Si mido el ingreso en miles, su β se multiplica por mil y se penaliza de otra forma.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar; así λ trata a todos por igual. Los coeficientes se reportan de vuelta en la escala original.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones sin ganar nada.
- `glmnet` estandariza y excluye el intercepto **por defecto**; hay que saber que lo hace.

Detalles que no son detalles: escala e intercepto

- **La penalización no es invariante a la escala:** $\sum_j \beta_j^2$ castiga igual al coeficiente de “ingreso en pesos” que al de “edad en años”, pero sus magnitudes no son comparables. Si mido el ingreso en miles, su β se multiplica por mil y se penaliza de otra forma.
- **Solución: estandarizar** los predictores (media 0, desviación 1) antes de regularizar; así λ trata a todos por igual. Los coeficientes se reportan de vuelta en la escala original.
- **El intercepto no se penaliza:** β_0 mide el nivel promedio de y , no la complejidad del modelo. Encogerlo sesgaría todas las predicciones sin ganar nada.
- `glmnet` estandariza y excluye el intercepto **por defecto**; hay que saber que lo hace.

Regla de oro #3, otra vez

Las medias y desviaciones para estandarizar se calculan con los datos de entrenamiento **de cada pliegue**, no con toda la muestra: `step_normalize()` dentro de la receta, como en la sesión 4.

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996): $\mathcal{P}(\beta) = \sum_j |\beta_j|$.

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996): $\mathcal{P}(\beta) = \sum_j |\beta_j|$.

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- El único cambio frente a Ridge: $|\beta_j|$ en lugar de β_j^2 . La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996): $\mathcal{P}(\beta) = \sum_j |\beta_j|$.

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- El único cambio frente a Ridge: $|\beta_j|$ en lugar de β_j^2 . La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.
- El Lasso hace **dos trabajos a la vez**: encoge (control de varianza) y selecciona variables (modelos esparsos, más fáciles de leer).

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996): $\mathcal{P}(\beta) = \sum_j |\beta_j|$.

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- El único cambio frente a Ridge: $|\beta_j|$ en lugar de β_j^2 . La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.
- El Lasso hace **dos trabajos a la vez**: encoge (control de varianza) y selecciona variables (modelos esparsos, más fáciles de leer).
- No tiene solución cerrada (el valor absoluto no es diferenciable en cero). `glmnet` lo resuelve coordenada por coordenada en milisegundos; el algoritmo, la condición de optimalidad y el $\lambda_{\max}$ a partir del cual nadie entra, en el apéndice.

Lasso: un valor absoluto que cambia todo

Problema (Tibshirani, 1996): $\mathcal{P}(\beta) = \sum_j |\beta_j|$.

$$\hat{\beta}^L = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j|$$



- El único cambio frente a Ridge: $|\beta_j|$ en lugar de β_j^2 . La consecuencia es enorme: para λ suficientemente grande, algunos coeficientes son **exactamente cero**.
- El Lasso hace **dos trabajos a la vez**: encoge (control de varianza) y selecciona variables (modelos esparsos, más fáciles de leer).
- No tiene solución cerrada (el valor absoluto no es diferenciable en cero). `glmnet` lo resuelve coordenada por coordenada en milisegundos; el algoritmo, la condición de optimalidad y el $\lambda_{\max}$ a partir del cual nadie entra, en el apéndice.

¿Por qué el valor absoluto produce ceros exactos?

La respuesta está en la **geometría** de la restricción.


La geometría: por qué el Lasso anula y Ridge no

Forma equivalente (restringida): minimizar RSS sujeto a $\mathcal{P}(\beta) \leq t$.



La geometría: por qué el Lasso anula y Ridge no




Forma equivalente (restringida): minimizar RSS sujeto a $\mathcal{P}(\beta) \leq t$.



- La solución está donde las curvas de nivel del RSS (elipses) **tocan** la región factible (azul).
- El diamante tiene **esquinas sobre los ejes** ($\beta_j = 0$): las elipses suelen tocar ahí primero $\Rightarrow$ ceros exactos. El círculo no tiene esquinas: el contacto casi nunca cae sobre un eje.


Los tres umbrales, cara a cara

Con $\mathbf{X}$ ortonormal, cada método transforma $\hat{\beta}_j^{OLS}$ así:




Los tres umbrales, cara a cara

Con $\mathbf{X}$ ortonormal, cada método transforma $\hat{\beta}_j^{OLS}$ así:




- **Subconjunto** = umbral **duro**: conserva intactos los grandes y elimina los chicos, con un salto: la inestabilidad de la selección.
- **Ridge** = encogimiento proporcional: nunca llega a cero.
- **Lasso** = umbral **suave**: $\hat{\beta}_j^L = \text{sign}(\hat{\beta}_j) (|\hat{\beta}_j| - \lambda)_+$; corre todo hacia cero y corta. Continuo y esparso: lo mejor de los dos mundos (la derivación, en el apéndice).

Elegir λ por CV: la curva de la sesión 4, con λ en el eje




Elegir λ por CV: la curva de la sesión 4, con λ en el eje



- `glmnet` ajusta el **camino completo** desde $\lambda_{\max}$ hacia abajo (unos 100 valores en escala logarítmica), usando cada solución como arranque de la siguiente. Es barato: la curva entera cuesta poco más que un OLS.
- Con k pliegues, cada punto trae su barra. $\lambda_{\min}$ minimiza; λ_{1SE} es el modelo más simple estadísticamente indistinguible del mejor. Para reportar un modelo esparso, la regla 1-SE es la costumbre.
- A la izquierda, con $\lambda \rightarrow 0$, la curva sube: es OLS sobreajustando. A la derecha, todo en cero: el modelo predice la media.


Leer un camino de regularización

La otra salida de `glmnet`: los coeficientes como función de λ .



Leer un camino de regularización

La otra salida de `glmnet`: los coeficientes como función de λ .



- De izquierda (λ grande: todo en cero) a derecha ($\lambda \rightarrow 0$: OLS). Cada línea es un coeficiente; el punto donde se despegas del cero es su **entrada**.
- **El orden de entrada informa:** lo que entra primero es lo que más poder predictivo aporta *dado lo que ya está*. En λ_{1SE} el modelo usa dos variables: eso es lo que se reporta. (El camino de Ridge es parecido, pero nadie toca el cero.)

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso**, que recorta el ruido a cero y concentra la estimación donde hay señal.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso**, que recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge**; anular variables tira señal a la basura.
Ejemplo: predecir precios con cientos de microatributos que aportan poquito cada uno.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso**, que recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge**; anular variables tira señal a la basura.
Ejemplo: predecir precios con cientos de microatributos que aportan poquito cada uno.
- **Predictores muy correlacionados**: el Lasso tiende a elegir **uno** del grupo, casi al azar, y anular los demás $\Rightarrow$ el conjunto seleccionado es **inestable** entre muestras. Localidad, distancia al centro y estrato se pisan entre sí: cuál sobrevive depende de la muestra.

¿Ridge o Lasso? Depende de cómo sea el mundo

- **Mundo esparso** (pocos coeficientes grandes, el resto ≈ 0): gana el **Lasso**, que recorta el ruido a cero y concentra la estimación donde hay señal.
- **Mundo denso** (muchos efectos pequeños repartidos): gana **Ridge**; anular variables tira señal a la basura.
Ejemplo: predecir precios con cientos de microatributos que aportan poquito cada uno.
- **Predictores muy correlacionados**: el Lasso tiende a elegir **uno** del grupo, casi al azar, y anular los demás $\Rightarrow$ el conjunto seleccionado es **inestable** entre muestras. Localidad, distancia al centro y estrato se pisan entre sí: cuál sobrevive depende de la muestra.

En la práctica

Nadie lo sabe *a priori*: se prueban ambos (y Elastic Net) sobre los **mismos pliegues**, y decide el CV. Y si el Lasso gana, cuidado con sobreinterpretar “las variables elegidas”: esa es la segunda mitad de la sesión.

Elastic Net: la negociación

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

Elastic Net: la negociación

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ es Lasso puro; $\alpha = 0$, Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes parecidos (*grouping effect*), en vez del sorteo del Lasso.

Elastic Net: la negociación

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ es Lasso puro; $\alpha = 0$, Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes parecidos (*grouping effect*), en vez del sorteo del Lasso.
- Dos hiperparámetros, (λ, α) : CV sobre una grilla de ambos, o fijar $\alpha \in \{0, 0.5, 1\}$ y CV sobre λ . Y todo esto vale igual para la logística: `glmnet` con familia `binomial` es la logística penalizada de la sesión 3.

Elastic Net: la negociación

Problema (Zou & Hastie, 2005), en la parametrización de `glmnet`:

$$\hat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$


- $\alpha \in [0, 1]$ interpola: $\alpha = 1$ es Lasso puro; $\alpha = 0$, Ridge puro.
- Hereda del L1 la **selección** (ceros exactos) y del L2 la **estabilidad** con correlación: predictores muy correlacionados tienden a entrar o salir **juntos**, con coeficientes parecidos (*grouping effect*), en vez del sorteo del Lasso.
- Dos hiperparámetros, (λ, α) : CV sobre una grilla de ambos, o fijar $\alpha \in \{0, 0.5, 1\}$ y CV sobre λ . Y todo esto vale igual para la logística: `glmnet` con familia `binomial` es la logística penalizada de la sesión 3.

Regla mental

Ridge = estabilidad; Lasso = esparsidad; Elastic Net = negociación entre las dos, con α como término del acuerdo.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre


PCA en una diapositiva: las direcciones que concentran la varianza



Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:

- **PC1**: la dirección w ($\|w\| = 1$) que maximiza $\text{Var}(w'x)$; **PC2**: la de máxima varianza *ortogonal* a PC1; etc.
- Cada componente explica una fracción de la varianza; las primeras $M \ll p$ suelen explicar casi toda.

PCA en una diapositiva: las direcciones que concentran la varianza



Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:

- **PC1:** la dirección w ($\|w\| = 1$) que maximiza $\text{Var}(w'x)$; **PC2:** la de máxima varianza *ortogonal* a PC1; etc.
- Cada componente explica una fracción de la varianza; las primeras $M \ll p$ suelen explicar casi toda.
- **Aseo:** centrar siempre; estandarizar casi siempre (si no, la variable de mayor varianza se roba el PC1). Los componentes son autovectores de la covarianza (apéndice); en R, `prcomp()` o `step_pca()`.
- **Leer un componente:** sus *cargas* dicen qué variables lo forman. El PC1 de los activos de un hogar es el índice de riqueza de Filmer & Pritchett (2001); vuelve en la sesión 9.

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

- Es prima hermana de Ridge: ambas encogen las direcciones de poca varianza de $\mathbf{X}$; PCR las *corta*, Ridge las *amortigua*.

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

- Es prima hermana de Ridge: ambas encogen las direcciones de poca varianza de $\mathbf{X}$; PCR las *corta*, Ridge las *amortigua*.
- **Su límite:** elige las direcciones **sin mirar** y . Si la dirección que predice y tiene poca varianza en $\mathbf{X}$, PCR la descarta.

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

- Es prima hermana de Ridge: ambas encogen las direcciones de poca varianza de $\mathbf{X}$; PCR las *corta*, Ridge las *amortigua*.
- **Su límite:** elige las direcciones **sin mirar** y . Si la dirección que predice y tiene poca varianza en $\mathbf{X}$, PCR la descarta.
- **PLS** construye los componentes *usando* y (pondera los predictores por su covarianza con y); en la práctica rara vez gana mucho a PCR o a Ridge (ISL 6.3.2).

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

- Es prima hermana de Ridge: ambas encogen las direcciones de poca varianza de $\mathbf{X}$; PCR las *corta*, Ridge las *amortigua*.
- **Su límite:** elige las direcciones **sin mirar** y . Si la dirección que predice y tiene poca varianza en $\mathbf{X}$, PCR la descarta.
- **PLS** construye los componentes *usando* y (pondera los predictores por su covarianza con y); en la práctica rara vez gana mucho a PCR o a Ridge (ISL 6.3.2).
- Ninguna de las dos **selecciona** variables: cada componente mezcla las p originales. Se pierde la lectura por variable; se gana estabilidad con predictores muy correlacionados.

PCR y PLS: comprimir antes de predecir (ISL, sección 6.3)

Regresión sobre componentes principales (PCR): calcular los M primeros componentes de $\mathbf{X}$ y hacer OLS de y sobre ellos. M es la perilla; se elige por CV.

- Es prima hermana de Ridge: ambas encogen las direcciones de poca varianza de $\mathbf{X}$; PCR las *corta*, Ridge las *amortigua*.
- **Su límite:** elige las direcciones **sin mirar** y . Si la dirección que predice y tiene poca varianza en $\mathbf{X}$, PCR la descarta.
- **PLS** construye los componentes *usando* y (pondera los predictores por su covarianza con y); en la práctica rara vez gana mucho a PCR o a Ridge (ISL 6.3.2).
- Ninguna de las dos **selecciona** variables: cada componente mezcla las p originales. Se pierde la lectura por variable; se gana estabilidad con predictores muy correlacionados.

Cuándo comprimir

Cientos de variables muy correlacionadas (píxeles, bandas satelitales, ítems de encuesta, indicadores macro): comprimir antes de predecir es más estable que seleccionar.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no**
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre

Sparsity: el supuesto que salva el día

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones.

Sparsity: el supuesto que salva el día

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones. **El supuesto:** β^0 es **esparso**: solo $s \ll n$ de sus p componentes son distintos de cero (o aproximadamente: pocos grandes, el resto despreciables).

Sparsity: el supuesto que salva el día

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones. **El supuesto:** β^0 es **esparso**: solo $s \ll n$ de sus p componentes son distintos de cero (o aproximadamente: pocos grandes, el resto despreciables).

- Con *sparsity*, los grados de libertad “verdaderos” son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? La búsqueda exacta cuesta 2^p ; el Lasso la vuelve convexa y la resuelve en segundos.

Sparsity: el supuesto que salva el día

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones. **El supuesto:** β^0 es **esparso**: solo $s \ll n$ de sus p componentes son distintos de cero (o aproximadamente: pocos grandes, el resto despreciables).

- Con *sparsity*, los grados de libertad “verdaderos” son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? La búsqueda exacta cuesta 2^p ; el Lasso la vuelve convexa y la resuelve en segundos.
- **¿Es creíble en economía?** A menudo sí como aproximación; pero es un supuesto, y hay mundos densos (los precios de activos de Gu, Kelly & Xiu, 2020) donde encoger gana a seleccionar.

Sparsity: el supuesto que salva el día

Si **todos** los p coeficientes importaran, con $p > n$ el problema sería imposible: más incógnitas que ecuaciones. **El supuesto:** β^0 es **esparso**: solo $s \ll n$ de sus p componentes son distintos de cero (o aproximadamente: pocos grandes, el resto despreciables).

- Con *sparsity*, los grados de libertad “verdaderos” son $\sim s$, no p : hay esperanza si $n \gg s$, **aunque** $p \gg n$.
- El problema se vuelve de **búsqueda**: ¿cuáles son las s variables? La búsqueda exacta cuesta 2^p ; el Lasso la vuelve convexa y la resuelve en segundos.
- **¿Es creíble en economía?** A menudo sí como aproximación; pero es un supuesto, y hay mundos densos (los precios de activos de Gu, Kelly & Xiu, 2020) donde encoger gana a seleccionar.

Lo que la teoría garantiza (informal; el enunciado, en el apéndice)

Con λ del orden de $\sigma \sqrt{\log(p)/n}$, el error de **predicción** del Lasso es como el de OLS sobre las s variables correctas, pagando solo un factor $\log p$ por no saber cuáles son. Con $p = 10^6$, $\log p \approx 14$.

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso, de soporte S .

- 1 **¿Predice bien?** ¿Es pequeño el error fuera de muestra de $\mathbf{X}\hat{\beta}$?

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso, de soporte S .

- 1 **¿Predice bien?** ¿Es pequeño el error fuera de muestra de $\mathbf{X}\hat{\beta}$?
- 2 **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso, de soporte S .

- ① **¿Predice bien?** ¿Es pequeño el error fuera de muestra de $\mathbf{X}\hat{\beta}$?
 - ② **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?
- La (2) es **mucho** más exigente que la (1): se puede predecir de maravilla con las variables “equivocadas” (proxies correlacionados).
 - Para (1) basta *sparsity* y un diseño no degenerado. Para (2) hacen falta, además, señales no minúsculas ($|\beta_j^0|$ por encima del ruido para todo $j \in S$) y la **condición de irrepresentabilidad**: que ningún predictor irrelevante sea demasiado bien explicado por los relevantes. Es fuerte y, lo incómodo, **no verificable**: depende del soporte que no conocemos.

Dos preguntas que suenan igual y no lo son

Supongamos que el mundo es $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso, de soporte S .

- ❶ **¿Predice bien?** ¿Es pequeño el error fuera de muestra de $\mathbf{X}\hat{\beta}$?
 - ❷ **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?
- La (2) es **mucho** más exigente que la (1): se puede predecir de maravilla con las variables “equivocadas” (proxies correlacionados).
 - Para (1) basta *sparsity* y un diseño no degenerado. Para (2) hacen falta, además, señales no minúsculas ($|\beta_j^0|$ por encima del ruido para todo $j \in S$) y la **condición de irrepresentabilidad**: que ningún predictor irrelevante sea demasiado bien explicado por los relevantes. Es fuerte y, lo incómodo, **no verificable**: depende del soporte que no conocemos.
 - Si falla, el Lasso incluye proxies equivocados *sin importar cuántos datos haya*. No es un problema de n ; es estructural.

Dos preguntas que suenan igual y no lo son


Supongamos que el mundo es $y = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso, de soporte S .

- ❶ **¿Predice bien?** ¿Es pequeño el error fuera de muestra de $\mathbf{X}\hat{\beta}$?
 - ❷ **¿Selecciona bien?** ¿Recupera el soporte: $\{j : \hat{\beta}_j \neq 0\} = S$?
- La (2) es **mucho** más exigente que la (1): se puede predecir de maravilla con las variables “equivocadas” (proxies correlacionados).
 - Para (1) basta *sparsity* y un diseño no degenerado. Para (2) hacen falta, además, señales no minúsculas ($|\beta_j^0|$ por encima del ruido para todo $j \in S$) y la **condición de irrepresentabilidad**: que ningún predictor irrelevante sea demasiado bien explicado por los relevantes. Es fuerte y, lo incómodo, **no verificable**: depende del soporte que no conocemos.
 - Si falla, el Lasso incluye proxies equivocados *sin importar cuántos datos haya*. No es un problema de n ; es estructural.

Y son relevantes para usos distintos


Para **predecir**, basta (1). Para **interpretar** qué variables importan, o para elegir *controles*, quisiéramos (2), y casi nunca la tenemos.

El modo de falla típico: el proxy correlacionado




- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y . Para el Lasso ambos predicen casi igual: con ruido de por medio puede quedarse con X_2 , repartir, o alternar entre muestras.

El modo de falla típico: el proxy correlacionado



- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y . Para el Lasso ambos predicen casi igual: con ruido de por medio puede quedarse con X_2 , repartir, o alternar entre muestras.
- Para **predecir**, da lo mismo. Para **interpretar**, es un desastre silencioso: el modelo reporta con confianza la variable equivocada. En la vivienda: ¿sobrevive la distancia al centro o la *dummy* de localidad? Depende de la muestra.

El modo de falla típico: el proxy correlacionado




- X_1 es la variable verdadera; X_2 es un proxy muy correlacionado que **no** afecta a Y . Para el Lasso ambos predicen casi igual: con ruido de por medio puede quedarse con X_2 , repartir, o alternar entre muestras.
- Para **predecir**, da lo mismo. Para **interpretar**, es un desastre silencioso: el modelo reporta con confianza la variable equivocada. En la vivienda: ¿sobrevive la distancia al centro o la *dummy* de localidad? Depende de la muestra.

La frase para tatuarse


El Lasso selecciona **predictores**, no **causas**. Y el *stepwise* hereda el mismo problema sin ninguna de las garantías.

Anticipo de la sesión 9: si lo que quieren es un β , seleccionen dos veces



Setup: el efecto α de un tratamiento d sobre y , controlando flexiblemente por cientos de x . **La tentación:** Lasso de y sobre (d, x) para elegir controles, y OLS con los elegidos.


Anticipo de la sesión 9: si lo que quieren es un β , seleccionen dos veces



Setup: el efecto α de un tratamiento d sobre y , controlando flexiblemente por cientos de x . **La tentación:** Lasso de y sobre (d, x) para elegir controles, y OLS con los elegidos.

- **El fallo:** el Lasso elige por capacidad de predecir y . Un confusor con efecto *débil* sobre y pero *fuerte* sobre d es descartado, y su omisión sesga $\hat{\alpha}$: el sesgo de variable omitida, resucitado por un algoritmo.

Anticipo de la sesión 9: si lo que quieren es un β , seleccionen dos veces



Setup: el efecto α de un tratamiento d sobre y , controlando flexiblemente por cientos de x . **La tentación:** Lasso de y sobre (d, x) para elegir controles, y OLS con los elegidos.

- **El fallo:** el Lasso elige por capacidad de predecir y . Un confusor con efecto *débil* sobre y pero *fuerte* sobre d es descartado, y su omisión sesga $\hat{\alpha}$: el sesgo de variable omitida, resucitado por un algoritmo.

Post-double-selection (Belloni, Chernozhukov & Hansen, 2014)

Lasso de y sobre x y Lasso de d sobre x ; OLS de y sobre d y la **unión** de los controles seleccionados. Para sesgar $\hat{\alpha}$ una variable omitida debe correlacionar con y y con d ; la doble selección solo omite las débiles en ambas, y el sesgo residual es de segundo orden. Los intervalos usuales vuelven a ser válidos. Los detalles y el *double machine learning*, en la sesión 9.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre

Los datos y la pregunta

Datos: los anuncios de vivienda de Bogotá de la sesión 2, pero ahora con **todo** lo que podemos construir: las variables base, *dummies* de localidad y tipo, interacciones de a pares, polinomios y *splines* de área y distancias. Unos cientos de columnas para unos miles de anuncios.

Los datos y la pregunta

Datos: los anuncios de vivienda de Bogotá de la sesión 2, pero ahora con **todo** lo que podemos construir: las variables base, *dummies* de localidad y tipo, interacciones de a pares, polinomios y *splines* de área y distancias. Unos cientos de columnas para unos miles de anuncios. **Preguntas:**

- 1 ¿Cuánto mejora (o empeora) OLS con todas las columnas frente al OLS flexible “a mano” de la sesión 2?
- 2 ¿Ridge, Lasso o Elastic Net? ¿Con qué λ ? ¿Le ganan al OLS flexible en la prueba?
- 3 ¿Qué variables sobreviven al Lasso, y qué tan estables son entre remuestras?

Los datos y la pregunta

Datos: los anuncios de vivienda de Bogotá de la sesión 2, pero ahora con **todo** lo que podemos construir: las variables base, *dummies* de localidad y tipo, interacciones de a pares, polinomios y *splines* de área y distancias. Unos cientos de columnas para unos miles de anuncios. **Preguntas:**

- 1 ¿Cuánto mejora (o empeora) OLS con todas las columnas frente al OLS flexible “a mano” de la sesión 2?
- 2 ¿Ridge, Lasso o Elastic Net? ¿Con qué λ ? ¿Le ganan al OLS flexible en la prueba?
- 3 ¿Qué variables sobreviven al Lasso, y qué tan estables son entre remuestras?

Decisiones antes de ajustar nada:

- $y = \log(\text{precio})$; la misma partición 80/20 de la sesión 2.
- CV de 10 pliegues sobre los **mismos pliegues** para todos; grilla de 100 valores de λ y $\alpha \in \{0, 0.5, 1\}$; regla 1-SE.
- La receta (*dummies*, interacciones, *splines*, estandarización) vive dentro del *pipeline*.

Cinco modelos, una misma prueba

	Modelo	Coef. $\neq 0$	RMSE (log)	MAE (pesos)	R^2 prueba
1	OLS flexible de la sesión 2	en clase	en clase	en clase	en clase
2	OLS con todas las columnas	p	en clase	en clase	en clase
3	Ridge, λ_{1SE}	p	en clase	en clase	en clase
4	Lasso, λ_{1SE}	en clase	en clase	en clase	en clase
5	Elastic Net, $\alpha = 0,5$	en clase	en clase	en clase	en clase

Cinco modelos, una misma prueba

	Modelo	Coef. $\neq 0$	RMSE (log)	MAE (pesos)	R^2 prueba
1	OLS flexible de la sesión 2	en clase	en clase	en clase	en clase
2	OLS con todas las columnas	p	en clase	en clase	en clase
3	Ridge, λ_{1SE}	p	en clase	en clase	en clase
4	Lasso, λ_{1SE}	en clase	en clase	en clase	en clase
5	Elastic Net, $\alpha = 0,5$	en clase	en clase	en clase	en clase

Un ancla publicada. Mullainathan & Spiess (2017, Tabla 1): precios de vivienda de la *American Housing Survey*, 10.000 unidades de entrenamiento y 150 variables. R^2 en la prueba: OLS 41,7%; Lasso 46,0%; bosque aleatorio 45,5%; ensamble 45,7%. Y la ganancia varía a lo largo de la distribución de precios.

Cinco modelos, una misma prueba

	Modelo	Coef. $\neq 0$	RMSE (log)	MAE (pesos)	R^2 prueba
1	OLS flexible de la sesión 2	en clase	en clase	en clase	en clase
2	OLS con todas las columnas	p	en clase	en clase	en clase
3	Ridge, λ_{1SE}	p	en clase	en clase	en clase
4	Lasso, λ_{1SE}	en clase	en clase	en clase	en clase
5	Elastic Net, $\alpha = 0,5$	en clase	en clase	en clase	en clase

Un ancla publicada. Mullainathan & Spiess (2017, Tabla 1): precios de vivienda de la *American Housing Survey*, 10.000 unidades de entrenamiento y 150 variables. R^2 en la prueba: OLS 41,7%; Lasso 46,0%; bosque aleatorio 45,5%; ensamble 45,7%. Y la ganancia varía a lo largo de la distribución de precios.

Preguntas que la tabla debe responder:

- ¿La fila 2 pierde contra la 1? Si sí, están viendo la varianza de OLS con muchos parámetros en vivo.
- ¿Cuánto recupera la penalización (filas 3–5 contra la 2)? ¿Y le gana a la especificación a mano (fila 1)? Cuatro puntos de R^2 , como en Mullainathan & Spiess, es una ganancia típica.
- ¿Con cuántas variables lo logra el Lasso? Ese número es el precio de la interpretabilidad.

Las figuras: la curva, el camino y quién sobrevive

- 1 **La curva de CV de λ para $\alpha \in \{0, 0.5, 1\}$** , en los mismos ejes. Marcar $\lambda_{\min}$ y λ_{1SE} ; anotar cuántos coeficientes quedan en cada uno. Si la curva es plana en un rango amplio, el dato es que *muchas* especificaciones predicen igual.

Las figuras: la curva, el camino y quién sobrevive

- 1 **La curva de CV de λ** para $\alpha \in \{0, 0.5, 1\}$, en los mismos ejes. Marcar $\lambda_{\min}$ y λ_{1SE} ; anotar cuántos coeficientes quedan en cada uno. Si la curva es plana en un rango amplio, el dato es que *muchas* especificaciones predicen igual.
- 2 **El camino de coeficientes** del Lasso con las diez primeras entradas etiquetadas. Esperamos área y estrato temprano; después, localidades y distancias, que se pisan entre sí.

Las figuras: la curva, el camino y quién sobrevive

- 1 **La curva de CV de λ** para $\alpha \in \{0, 0.5, 1\}$, en los mismos ejes. Marcar $\lambda_{\min}$ y λ_{1SE} ; anotar cuántos coeficientes quedan en cada uno. Si la curva es plana en un rango amplio, el dato es que *muchas* especificaciones predicen igual.
- 2 **El camino de coeficientes** del Lasso con las diez primeras entradas etiquetadas. Esperamos área y estrato temprano; después, localidades y distancias, que se pisan entre sí.
- 3 **Estabilidad de la selección:** repetir el Lasso en 100 remuestras *bootstrap* del entrenamiento y contar en qué fracción sobrevive cada variable. Las que sobreviven en el 95% son señal; las que entran en el 40% son el sorteo del proxy correlacionado.

Las figuras: la curva, el camino y quién sobrevive

- 1 **La curva de CV de λ** para $\alpha \in \{0, 0.5, 1\}$, en los mismos ejes. Marcar $\lambda_{\min}$ y λ_{1SE} ; anotar cuántos coeficientes quedan en cada uno. Si la curva es plana en un rango amplio, el dato es que *muchas* especificaciones predicen igual.
- 2 **El camino de coeficientes** del Lasso con las diez primeras entradas etiquetadas. Esperamos área y estrato temprano; después, localidades y distancias, que se pisan entre sí.
- 3 **Estabilidad de la selección:** repetir el Lasso en 100 remuestras *bootstrap* del entrenamiento y contar en qué fracción sobrevive cada variable. Las que sobreviven en el 95% son señal; las que entran en el 40% son el sorteo del proxy correlacionado.
- 4 Y, como siempre, **predicho vs. observado** y **error por decil** del mejor modelo, contra el OLS flexible de la sesión 2.

Las figuras: la curva, el camino y quién sobrevive

- 1 **La curva de CV de λ** para $\alpha \in \{0, 0.5, 1\}$, en los mismos ejes. Marcar $\lambda_{\min}$ y λ_{1SE} ; anotar cuántos coeficientes quedan en cada uno. Si la curva es plana en un rango amplio, el dato es que *muchas* especificaciones predicen igual.
- 2 **El camino de coeficientes** del Lasso con las diez primeras entradas etiquetadas. Esperamos área y estrato temprano; después, localidades y distancias, que se pisan entre sí.
- 3 **Estabilidad de la selección:** repetir el Lasso en 100 remuestras *bootstrap* del entrenamiento y contar en qué fracción sobrevive cada variable. Las que sobreviven en el 95% son señal; las que entran en el 40% son el sorteo del proxy correlacionado.
- 4 Y, como siempre, **predicho vs. observado** y **error por decil** del mejor modelo, contra el OLS flexible de la sesión 2.

El reporte

La tabla en la misma prueba + la curva de CV + el camino + la tabla de estabilidad. Quien lea “el Lasso eligió la distancia al centro” sin la tabla de estabilidad está leyendo ruido con nombre propio.

Cómo se ve en R (glmnet dentro de tidymodels)

```
library(tidymodels); set.seed(2026)
rec <- recipe(log_precio ~ ., data = train) |>
  step_dummy(all_nominal_predictors()) |>
  step_interact(~ area:starts_with("estrato")) |>
  step_ns(area, dist_centro, deg_free = 4) |>
  step_normalize(all_numeric_predictors()) # dentro del pliegue
enet <- linear_reg(penalty = tune(), mixture = tune()) |>
  set_engine("glmnet") # mixture: 0 Ridge, 1 Lasso
wf <- workflow(rec, enet)
folds <- vfold_cv(train, v = 10, strata = log_precio)
grid <- grid_regular(penalty(range = c(-4, 0)),
  mixture(values = c(0, 0.5, 1)), levels = c(50, 3))
res <- tune_grid(wf, folds, grid = grid, metrics = metric_set(rmse))
autoplot(res) # curvas de CV
best <- select_by_one_std_err(res, desc(penalty),
  metric = "rmse")
final <- finalize_workflow(wf, best) |> last_fit(split) # una vez
tidy(extract_fit_parsnip(final)) |> filter(estimate != 0)
```

- `penalty` es λ y `mixture` es α ; `glmnet` ajusta el camino completo por cada α y `tune_grid` lo evalúa en los pliegues. La última línea lista los coeficientes que sobreviven, en la escala original.

Presentación estudiantil: el paper de la sesión 4

Quince minutos, tres preguntas

Deppner & Cajias (2024) o Goulet Coulombe et al. (2022), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa el protocolo?** Precios o rentas de vivienda con dependencia espacial; variables macro con dependencia temporal.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué esquema de validación usan, contra cuál lo comparan, y qué métrica reportan.
- 3 **¿Qué se encuentra y cómo se interpreta?** Cuánto cambia el error estimado (o el modelo elegido) al cambiar el esquema; qué recomiendan.

Presentación estudiantil: el paper de la sesión 4

Quince minutos, tres preguntas

Deppner & Cajias (2024) o Goulet Coulombe et al. (2022), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa el protocolo?** Precios o rentas de vivienda con dependencia espacial; variables macro con dependencia temporal.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué esquema de validación usan, contra cuál lo comparan, y qué métrica reportan.
- 3 **¿Qué se encuentra y cómo se interpreta?** Cuánto cambia el error estimado (o el modelo elegido) al cambiar el esquema; qué recomiendan.

Para el resto de la sala

Mientras escuchan, anoten: ¿el CV que reportan responde la pregunta que el paper quiere responder? ¿Qué pasaría con sus conclusiones si el remuestreo hubiera sido aleatorio? Es la sesión pasada aplicada a un paper, y la de hoy: en Goulet Coulombe et al., la regularización es uno de los cuatro ingredientes que comparan.

- 1 Muchos predictores: qué falla y por qué
- 2 Encoger: Ridge, Lasso y Elastic Net
- 3 Comprimir: PCR, PLS y la intuición de PCA
- 4 Alta dimensión: lo que la selección dice y lo que no
- 5 Aplicación guiada: vivienda con muchas covariables
- 6 Interpretación y cierre

Qué dice el modelo y qué no dice

- **Los coeficientes están encogidos:** un $\hat{\beta}_j^L$ no es un efecto marginal; está sesgado hacia cero a propósito. Si se quiere la magnitud, se reajusta OLS sobre las variables que sobrevivieron (*post-Lasso*), sabiendo que el error estándar de ese OLS **finge** que el modelo estaba decidido antes de ver los datos.

Qué dice el modelo y qué no dice

- **Los coeficientes están encogidos:** un $\hat{\beta}_j^L$ no es un efecto marginal; está sesgado hacia cero a propósito. Si se quiere la magnitud, se reajusta OLS sobre las variables que sobrevivieron (*post-Lasso*), sabiendo que el error estándar de ese OLS **finge** que el modelo estaba decidido antes de ver los datos.
- **Sobrevivir no es importar:** lo que sobrevive es lo que predice *dado lo demás*. Con proxies correlacionados el sorteo cambia entre remuestras; la tabla de estabilidad es el mínimo honesto.

Qué dice el modelo y qué no dice

- **Los coeficientes están encogidos:** un $\hat{\beta}_j^L$ no es un efecto marginal; está sesgado hacia cero a propósito. Si se quiere la magnitud, se reajusta OLS sobre las variables que sobrevivieron (*post-Lasso*), sabiendo que el error estándar de ese OLS **finge** que el modelo estaba decidido antes de ver los datos.
- **Sobrevivir no es importar:** lo que sobrevive es lo que predice *dado lo demás*. Con proxies correlacionados el sorteo cambia entre remuestras; la tabla de estabilidad es el mínimo honesto.
- **Lo que sí se puede decir:** cuánta capacidad predictiva hay en la información (R^2 de prueba), cuántas variables hacen falta para capturarla, y qué *bloques* de información aportan: la jerarquía de Gelvez et al. (2026), que veremos en la sesión 7.

Qué dice el modelo y qué no dice

- **Los coeficientes están encogidos:** un $\hat{\beta}_j^L$ no es un efecto marginal; está sesgado hacia cero a propósito. Si se quiere la magnitud, se reajusta OLS sobre las variables que sobrevivieron (*post-Lasso*), sabiendo que el error estándar de ese OLS **finje** que el modelo estaba decidido antes de ver los datos.
- **Sobrevivir no es importar:** lo que sobrevive es lo que predice *dado lo demás*. Con proxies correlacionados el sorteo cambia entre remuestras; la tabla de estabilidad es el mínimo honesto.
- **Lo que sí se puede decir:** cuánta capacidad predictiva hay en la información (R^2 de prueba), cuántas variables hacen falta para capturarla, y qué *bloques* de información aportan: la jerarquía de Gelvez et al. (2026), que veremos en la sesión 7.

Y , no β , versión regularización

La penalización es información previa sobre el mundo (efectos pequeños, o pocos; la lectura bayesiana, en el apéndice) y sirve para predecir mejor. Para decir que una variable *causa* algo hace falta un diseño de identificación (sesión 9).

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
OLS	$p \ll n$ y especificación defendible	con p cerca de n , la varianza
Ridge	mundo denso; predictores correlacionados	no selecciona; hay que estandarizar
Lasso	mundo esparso; se quiere un modelo legible	selección inestable con correlación; coeficientes sesgados
Elastic Net	grupos de predictores correlacionados	dos hiperparámetros por CV
PCR / PLS	cientos de variables muy correlacionadas	se pierde la lectura por variable
<i>Stepwise</i>	casi nunca	<i>greedy</i> , inestable, sin garantías
Criterios (AIC, BIC)	referencia rápida en modelos lineales	d no existe para bosques y redes

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
OLS	$p \ll n$ y especificación defendible	con p cerca de n , la varianza
Ridge	mundo denso; predictores correlacionados	no selecciona; hay que estandarizar
Lasso	mundo esparso; se quiere un modelo legible	selección inestable con correlación; coeficientes sesgados
Elastic Net	grupos de predictores correlacionados	dos hiperparámetros por CV
PCR / PLS	cientos de variables muy correlacionadas	se pierde la lectura por variable
<i>Stepwise</i>	casi nunca	<i>greedy</i> , inestable, sin garantías
Criterios (AIC, BIC)	referencia rápida en modelos lineales	d no existe para bosques y redes

Qué leer: ISL cap. 6 (secs. 6.1–6.4, con las figuras de clase); Mullainathan & Spiess (2017) por la tabla de vivienda y la discusión de qué variables “elige” cada remuestra; Belloni, Chernozhukov & Hansen (2014, JEP) como puente amable hacia la sesión 9; Friedman, Hastie & Tibshirani (2010) si quieren saber qué hace `glmnet` por dentro.

Recap

- 1 **Muchos predictores** = poca información por parámetro: la varianza de OLS explota en las direcciones colineales y con $p > n$ el ajuste perfecto no informa nada. Tres salidas: seleccionar, encoger, comprimir.
- 2 **Ridge** = $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$: estabiliza, encoge proporcionalmente, nunca anula. **Lasso**: el valor absoluto produce **ceros exactos** (el diamante, el umbral suave). **Elastic Net**: la negociación. Todo con predictores estandarizados dentro del pliegue.
- 3 λ **se elige por CV**: la curva con sus barras, el mínimo o la regla 1-SE; el camino de coeficientes dice quién entra y cuándo.
- 4 **PCR y PLS** comprimen antes de predecir: estables con variables muy correlacionadas, pero sin lectura por variable. PCA vuelve en la sesión 9.
- 5 **Predecir bien es fácil; seleccionar bien es casi imposible**: el Lasso selecciona *predictores*, no *causas*. Si lo que quieren es un β , doble selección (sesión 9).

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 6 (secs. 6.1–6.4).
Guía: la 6.2 es la de clase (figuras 6.4 a 6.10); la 6.4 es la discusión de alta dimensión.
- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la doble selección; secciones 1–3 bastan por ahora.

Para la presentación estudiantil de la sesión 6: Gu, Kelly & Xiu (2020), *Empirical Asset Pricing via Machine Learning*, RFS, o Blumenstock, Cadamuro & On (2015), *Predicting Poverty and Wealth from Mobile Phone Metadata*, *Science*.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 6 (secs. 6.1–6.4).
Guía: la 6.2 es la de clase (figuras 6.4 a 6.10); la 6.4 es la discusión de alta dimensión.
- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la doble selección; secciones 1–3 bastan por ahora.

Para la presentación estudiantil de la sesión 6: Gu, Kelly & Xiu (2020), *Empirical Asset Pricing via Machine Learning*, RFS, o Blumenstock, Cadamuro & On (2015), *Predicting Poverty and Wealth from Mobile Phone Metadata*, *Science*.
Próxima sesión — árboles, bosques y boosting: dejamos los modelos lineales.

Un árbol parte el espacio de las x en rectángulos; un bosque promedia cientos de árboles sobre remuestras *bootstrap* (el 63% de la sesión 4) y el *boosting* ajusta árboles a los residuos. Son los métodos que suelen ganar con datos tabulares, y con ellos replicamos el núcleo de Gelvez et al. (2026). Lectura previa: ISL cap. 8.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 6 (secs. 6.1–6.4).
Guía: la 6.2 es la de clase (figuras 6.4 a 6.10); la 6.4 es la discusión de alta dimensión.
- Belloni, Chernozhukov & Hansen (2014), *High-Dimensional Methods and Inference on Structural and Treatment Effects*, JEP.
Guía: la versión amable de la doble selección; secciones 1–3 bastan por ahora.

Para la presentación estudiantil de la sesión 6: Gu, Kelly & Xiu (2020), *Empirical Asset Pricing via Machine Learning*, RFS, o Blumenstock, Cadamuro & On (2015), *Predicting Poverty and Wealth from Mobile Phone Metadata*, *Science*.
Próxima sesión — árboles, bosques y boosting: dejamos los modelos lineales.

Un árbol parte el espacio de las x en rectángulos; un bosque promedia cientos de árboles sobre remuestras *bootstrap* (el 63% de la sesión 4) y el *boosting* ajusta árboles a los residuos. Son los métodos que suelen ganar con datos tabulares, y con ellos replicamos el núcleo de Gelvez et al. (2026). Lectura previa: ISL cap. 8.

Aplicación de esta semana en R: vivienda con muchas covariables en `glmnet`: la tabla de cinco modelos, la curva de CV, el camino y la tabla de estabilidad.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 6. [ISL]
- Hoerl, A., & Kennard, R. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55–67.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *JRSS-B*, 58(1), 267–288.
- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *JRSS-B*, 67(2), 301–320.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1). [glmnet]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *Journal of Economic Perspectives*, 28(2), 29–50.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073–1076.
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data — or Tears. *Demography*, 38(1), 115–132.
- Hastie, T., Tibshirani, R., & Wainwright, M. (2015). *Statistical Learning with Sparsity*. CRC Press. [para profundizar]

7 Apéndice: para profundizar

A1. Ridge: la solución cerrada y la magia de λ

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta.$$

A1. Ridge: la solución cerrada y la magia de $\lambda \mathbf{I}$

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta. \quad 2.$$

Derivamos e igualamos a cero:

$$-2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta = 0 \Rightarrow (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}.$$

A1. Ridge: la solución cerrada y la magia de $\lambda \mathbf{I}$

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta. \quad 2.$$

Derivamos e igualamos a cero:

$$-2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta = 0 \Rightarrow (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}. \quad 3. \text{ Solución:}$$

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

A1. Ridge: la solución cerrada y la magia de $\lambda \mathbf{I}$

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta. \quad 2.$$

Derivamos e igualamos a cero:

$$-2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta = 0 \Rightarrow (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}. \quad 3. \text{ Solución:}$$

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

4. Por qué la inversa siempre existe: si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda > 0$ para todo $\lambda > 0$, incluso con $p > n$. En la base de autovectores, Ridge multiplica la coordenada j de OLS por $d_j/(d_j + \lambda)$: casi 1 donde hay mucha varianza, casi 0 en las direcciones enfermas.

A1. Ridge: la solución cerrada y la magia de $\lambda \mathbf{I}$

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta. \quad 2.$$

Derivamos e igualamos a cero:

$$-2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta = 0 \Rightarrow (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}. \quad 3. \text{ Solución:}$$

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

4. Por qué la inversa siempre existe: si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda > 0$ para todo $\lambda > 0$, incluso con $p > n$. En la base de autovectores, Ridge multiplica la coordenada j de OLS por $d_j/(d_j + \lambda)$: casi 1 donde hay mucha varianza, casi 0 en las direcciones enfermas. **5. Caso ortonormal ($\mathbf{X}'\mathbf{X} = \mathbf{I}$):** $\hat{\beta}_j^R = \hat{\beta}_j^{OLS}/(1 + \lambda)$, encogimiento proporcional.

A1. Ridge: la solución cerrada y la magia de $\lambda \mathbf{I}$

1. La función objetivo:

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \beta' \beta = \mathbf{y}'\mathbf{y} - 2\beta' \mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta + \lambda \beta' \beta. \quad 2.$$

Derivamos e igualamos a cero:

$$-2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta + 2\lambda\beta = 0 \Rightarrow (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}'\mathbf{y}. \quad 3. \text{ Solución:}$$

$$\hat{\beta}^R = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}.$$

4. Por qué la inversa siempre existe: si $d_1 \geq \dots \geq d_p \geq 0$ son los autovalores de $\mathbf{X}'\mathbf{X}$, los de $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ son $d_j + \lambda > 0$ para todo $\lambda > 0$, incluso con $p > n$. En la base de autovectores, Ridge multiplica la coordenada j de OLS por $d_j/(d_j + \lambda)$: casi 1 donde hay mucha varianza, casi 0 en las direcciones enfermas. **5. Caso ortonormal ($\mathbf{X}'\mathbf{X} = \mathbf{I}$):** $\hat{\beta}_j^R = \hat{\beta}_j^{OLS}/(1 + \lambda)$, encogimiento proporcional.

Sesgo y varianza

$\mathbb{E}[\hat{\beta}^R] = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{X} \beta \neq \beta$: sesgado hacia cero.

$\text{Var}(\hat{\beta}^R) = \sigma^2 (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1} \mathbf{X}'\mathbf{X} (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}$, menor que la de OLS en cada dirección. Existe $\lambda > 0$ que reduce el MSE (Hoerl & Kennard, 1970).

A2. Las condiciones de optimalidad del Lasso

1. El obstáculo: $|\beta_j|$ no es diferenciable en cero, que es justo donde ocurre lo interesante. Se generaliza la derivada: g es un **subgradiente** de una función convexa f en x_0 si $f(x) \geq f(x_0) + g(x - x_0)$ para todo x . Para el valor absoluto,

$$\partial|\beta_j| = \begin{cases} \{\text{sign}(\beta_j)\} & \beta_j \neq 0 \\ [-1, 1] & \beta_j = 0 \end{cases}, \quad \text{y } \hat{\beta} \text{ minimiza } f \text{ convexa} \iff 0 \in \partial f(\hat{\beta}).$$

A2. Las condiciones de optimalidad del Lasso

1. El obstáculo: $|\beta_j|$ no es diferenciable en cero, que es justo donde ocurre lo interesante. Se generaliza la derivada: g es un **subgradiente** de una función convexa f en x_0 si $f(x) \geq f(x_0) + g(x - x_0)$ para todo x . Para el valor absoluto,

$$\partial|\beta_j| = \begin{cases} \{\text{sign}(\beta_j)\} & \beta_j \neq 0 \\ [-1, 1] & \beta_j = 0 \end{cases}, \quad \text{y } \hat{\beta} \text{ minimiza } f \text{ convexa} \iff 0 \in \partial f(\hat{\beta}).$$

2. Aplicado a $\frac{1}{2}\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda\|\beta\|_1$: el primer término tiene gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$; el segundo aporta el subgradiente. Componente a componente:

$$\hat{\beta}_j \neq 0 : \mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda \text{sign}(\hat{\beta}_j); \quad \hat{\beta}_j = 0 : |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})| \leq \lambda.$$

A2. Las condiciones de optimalidad del Lasso

1. El obstáculo: $|\beta_j|$ no es diferenciable en cero, que es justo donde ocurre lo interesante. Se generaliza la derivada: g es un **subgradiente** de una función convexa f en x_0 si $f(x) \geq f(x_0) + g(x - x_0)$ para todo x . Para el valor absoluto,

$$\partial|\beta_j| = \begin{cases} \{\text{sign}(\beta_j)\} & \beta_j \neq 0 \\ [-1, 1] & \beta_j = 0 \end{cases}, \quad \text{y } \hat{\beta} \text{ minimiza } f \text{ convexa} \iff 0 \in \partial f(\hat{\beta}).$$

2. Aplicado a $\frac{1}{2}\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda\|\beta\|_1$: el primer término tiene gradiente $-\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta)$; el segundo aporta el subgradiente. Componente a componente:

$$\hat{\beta}_j \neq 0 : \mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta}) = \lambda \text{sign}(\hat{\beta}_j); \quad \hat{\beta}_j = 0 : |\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})| \leq \lambda.$$

- $\mathbf{x}'_j(\mathbf{y} - \mathbf{X}\hat{\beta})$ es la covarianza del predictor j con el **residuo**. Los activos la tienen exactamente en $\pm\lambda$; los inactivos, por debajo. λ es un **umbral de mérito**: entras solo si tu correlación con lo aún no explicado alcanza λ .
- Si $\lambda \geq \max_j |\mathbf{x}'_j \mathbf{y}|$, $\hat{\beta} = 0$ cumple las condiciones: nadie entra. De ahí sale $\lambda_{\max}$.

A3. El umbral suave y el descenso por coordenadas

Caso univariado (una coordenada, $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos $\min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$.

- ❶ Si $\hat{\beta} > 0$: $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$, coherente solo si $z > \lambda$.
- ❷ Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$, coherente solo si $z < -\lambda$.
- ❸ Si $\hat{\beta} = 0$: se necesita $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir, $z \in [-\lambda, \lambda]$.

$$\hat{\beta} = S_{\lambda}(z) = \text{sign}(z) (|z| - \lambda)_+$$

A3. El umbral suave y el descenso por coordenadas

Caso univariado (una coordenada, $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos $\min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$.

- ❶ Si $\hat{\beta} > 0$: $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$, coherente solo si $z > \lambda$.
- ❷ Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$, coherente solo si $z < -\lambda$.
- ❸ Si $\hat{\beta} = 0$: se necesita $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir, $z \in [-\lambda, \lambda]$.

$$\hat{\beta} = S_{\lambda}(z) = \text{sign}(z) (|z| - \lambda)_+$$

Descenso por coordenadas (Friedman, Hastie & Tibshirani, 2010), el algoritmo de `glmnet`: con el objetivo $\frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1$ y predictores estandarizados, inicializar $\hat{\beta} = 0$ y repetir, para $j = 1, \dots, p$, hasta converger:

$$r^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \hat{\beta}_k, \quad \hat{\beta}_j \leftarrow S_{\lambda}\left(\frac{1}{n} \mathbf{x}_j' r^{(j)}\right).$$

A3. El umbral suave y el descenso por coordenadas

Caso univariado (una coordenada, $\mathbf{X}$ estandarizada): sea z el estimador sin penalizar; resolvemos $\min_{\beta} \frac{1}{2}(z - \beta)^2 + \lambda|\beta|$.

- ❶ Si $\hat{\beta} > 0$: $\beta - z + \lambda = 0 \Rightarrow \hat{\beta} = z - \lambda$, coherente solo si $z > \lambda$.
- ❷ Si $\hat{\beta} < 0$: $\beta - z - \lambda = 0 \Rightarrow \hat{\beta} = z + \lambda$, coherente solo si $z < -\lambda$.
- ❸ Si $\hat{\beta} = 0$: se necesita $0 \in \{-z + \lambda s : s \in [-1, 1]\}$, es decir, $z \in [-\lambda, \lambda]$.

$$\hat{\beta} = S_{\lambda}(z) = \text{sign}(z) (|z| - \lambda)_+$$

Descenso por coordenadas (Friedman, Hastie & Tibshirani, 2010), el algoritmo de `glmnet`: con el objetivo $\frac{1}{2n} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1$ y predictores estandarizados, inicializar $\hat{\beta} = 0$ y repetir, para $j = 1, \dots, p$, hasta converger:

$$r^{(j)} = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k \hat{\beta}_k, \quad \hat{\beta}_j \leftarrow S_{\lambda}\left(\frac{1}{n} \mathbf{x}_j' r^{(j)}\right).$$


- Converge al óptimo global porque el objetivo es convexo y la parte no diferenciable es separable por coordenadas. Los trucos: *warm starts* a lo largo del camino de λ y *active sets* (iterar solo sobre los activos). Por eso el camino completo cuesta poco más que un OLS.

A4. La lectura bayesiana: penalizar es tener un *prior*

Ridge y Lasso son **modas posteriores** bajo distintos *priors* independientes sobre los β_j :

$$\text{Ridge: } \beta_j \sim N(0, \tau^2)$$

$$\text{Lasso: } \beta_j \sim \text{Laplace}(0, b)$$




A4. La lectura bayesiana: penalizar es tener un *prior*

Ridge y Lasso son **modas posteriores** bajo distintos *priors* independientes sobre los β_j :

$$\text{Ridge: } \beta_j \sim N(0, \tau^2)$$

$$\text{Lasso: } \beta_j \sim \text{Laplace}(0, b)$$



- Con $\varepsilon \sim N(0, \sigma^2)$, maximizar la posterior es minimizar $\text{RSS} + \lambda \mathcal{P}(\beta)$ con $\lambda = \sigma^2 / \tau^2$ (Ridge) o $\lambda = 2\sigma^2 / b$ (Lasso).
- El *prior* de Laplace es **picudo en cero**: apuesta a que muchos coeficientes son exactamente nulos, y la moda posterior produce ceros. λ traduce la fuerza de la creencia.
- Mensaje: la penalización no es un truco numérico; es **información previa** sobre el mundo (“los efectos son pequeños” o “son pocos”). Por eso el CV, que la elige con datos, es lo que la hace honesta.

A5. PCA como problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos la dirección w que maximiza la varianza de la proyección (sin la restricción, alargar w la inflaría sin límite):

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1.$$

A5. PCA como problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos la dirección w que maximiza la varianza de la proyección (sin la restricción, alargar w la inflaría sin límite):

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1.$$

1. Lagrangiano: $\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$.

A5. PCA como problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos la dirección w que maximiza la varianza de la proyección (sin la restricción, alargar w la inflaría sin límite):

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1.$$

1. Lagrangiano: $\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$. **2. Condición de primer orden:** $2 \Sigma w - 2 \lambda w = 0 \implies \boxed{\Sigma w = \lambda w}$: w es un **autovector** de Σ con autovalor λ .

A5. PCA como problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos la dirección w que maximiza la varianza de la proyección (sin la restricción, alargar w la inflaría sin límite):

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1.$$

1. Lagrangiano: $\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$. **2. Condición de primer orden:** $2 \Sigma w - 2 \lambda w = 0 \implies \boxed{\Sigma w = \lambda w}$: w es un **autovector** de Σ con autovalor λ . **3. ¿Cuál autovector?** Evaluando el objetivo, $w' \Sigma w = \lambda w' w = \lambda$: la varianza de la proyección **es** el autovalor. PC1 es el autovector del mayor autovalor λ_1 ; PC2, el del segundo (ortogonal automáticamente, porque Σ es simétrica); y así sucesivamente.

A5. PCA como problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos la dirección w que maximiza la varianza de la proyección (sin la restricción, alargar w la inflaría sin límite):

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1.$$

1. Lagrangiano: $\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$. **2. Condición de primer orden:** $2 \Sigma w - 2 \lambda w = 0 \implies \boxed{\Sigma w = \lambda w}$: w es un **autovector** de Σ con autovalor λ . **3. ¿Cuál autovector?** Evaluando el objetivo, $w' \Sigma w = \lambda w' w = \lambda$: la varianza de la proyección **es** el autovalor. PC1 es el autovector del mayor autovalor λ_1 ; PC2, el del segundo (ortogonal automáticamente, porque Σ es simétrica); y así sucesivamente.

- **Varianza explicada:** el componente j explica $\lambda_j / \sum_k \lambda_k$ de la varianza total; el *scree plot* grafica esa fracción y su codo sugiere M . Para PCR, M se elige por CV, que sí tiene árbitro.
- **Conexión con Ridge:** en la base de autovectores de $\mathbf{X}'\mathbf{X}$, PCR conserva las M primeras coordenadas y descarta el resto; Ridge las multiplica por $d_j / (d_j + \lambda)$. Cortar o amortiguar: la misma idea.

A6. Lo que la teoría del Lasso garantiza (y lo que exige)

Sea $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso de soporte S , $|S| = s$.

A6. Lo que la teoría del Lasso garantiza (y lo que exige)

Sea $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso de soporte S , $|S| = s$. **Resultado 1**

(predicción). Con $\lambda \asymp \sigma \sqrt{\log(p)/n}$ y un diseño no degenerado en las direcciones esparsas (condición de *autovalor restringido*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}.$$

Si conociéramos las s variables correctas, OLS sobre ellas daría $\sigma^2 s/n$: el costo de la búsqueda es solo $\log p$. La condición es mucho más débil que pedir $\mathbf{X}'\mathbf{X}$ invertible; por eso el Lasso vive donde OLS muere.

A6. Lo que la teoría del Lasso garantiza (y lo que exige)

Sea $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso de soporte S , $|S| = s$. **Resultado 1**

(predicción). Con $\lambda \asymp \sigma \sqrt{\log(p)/n}$ y un diseño no degenerado en las direcciones esparsas (condición de *autovalor restringido*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}.$$

Si conociéramos las s variables correctas, OLS sobre ellas daría $\sigma^2 s/n$: el costo de la búsqueda es solo $\log p$. La condición es mucho más débil que pedir $\mathbf{X}'\mathbf{X}$ invertible; por eso el Lasso vive donde OLS muere. **Resultado 2 (selección).**

Para recuperar el soporte con alta probabilidad hacen falta, además, (i) $\min_{j \in S} |\beta_j^0| \gtrsim \lambda$ (señales no minúsculas) y (ii) la **condición de irrepresentabilidad** (Zhao & Yu, 2006):

$$\|\mathbf{X}'_{S^c} \mathbf{X}_S (\mathbf{X}'_S \mathbf{X}_S)^{-1} \text{sign}(\beta_S^0)\|_\infty < 1,$$

es decir, ningún predictor irrelevante puede ser demasiado bien explicado por los relevantes. Es fuerte, no verificable, y si falla el Lasso incluye proxies sin importar n .

A6. Lo que la teoría del Lasso garantiza (y lo que exige)

Sea $\mathbf{y} = \mathbf{X}\beta^0 + \varepsilon$ con β^0 esparso de soporte S , $|S| = s$. **Resultado 1**

(predicción). Con $\lambda \asymp \sigma \sqrt{\log(p)/n}$ y un diseño no degenerado en las direcciones esparsas (condición de *autovalor restringido*),

$$\frac{1}{n} \|\mathbf{X}(\hat{\beta}^L - \beta^0)\|_2^2 \lesssim \sigma^2 \frac{s \log p}{n}.$$

Si conociéramos las s variables correctas, OLS sobre ellas daría $\sigma^2 s/n$: el costo de la búsqueda es solo $\log p$. La condición es mucho más débil que pedir $\mathbf{X}'\mathbf{X}$ invertible; por eso el Lasso vive donde OLS muere. **Resultado 2 (selección).**

Para recuperar el soporte con alta probabilidad hacen falta, además, (i) $\min_{j \in S} |\beta_j^0| \gtrsim \lambda$ (señales no minúsculas) y (ii) la **condición de irrepresentabilidad** (Zhao & Yu, 2006):

$$\|\mathbf{X}'_{S^c} \mathbf{X}_S (\mathbf{X}'_S \mathbf{X}_S)^{-1} \text{sign}(\beta_S^0)\|_\infty < 1,$$

es decir, ningún predictor irrelevante puede ser demasiado bien explicado por los relevantes. Es fuerte, no verificable, y si falla el Lasso incluye proxies sin importar n . Referencias: Hastie, Tibshirani & Wainwright (2015), caps. 2 y 11; Wainwright (2019), *High-Dimensional Statistics*, caps. 7–8.