

Big Data y Machine Learning para Economía Aplicada

Week 06: Machine Learning para Inferencia Causal

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 23, 2026

Previously...

Tres semillas sembradas en el curso, que hoy germinan juntas:

- **S1:** predicción ($\hat{y}$) e inferencia causal ($\hat{\beta}$) son preguntas distintas... pero prometimos que no eran rivales.
- **S3:** el Lasso selecciona *predictores*, no *causas*; para un α creíble, **post-double-selection** — y un nombre misterioso: *ortogonalidad de Neyman*.
- **S4–S5:** bosques y *boosting* predicen de maravilla — “serán los motores dentro de un procedimiento causal”.

Previously...

Tres semillas sembradas en el curso, que hoy germinan juntas:

- **S1:** predicción ($\hat{y}$) e inferencia causal ($\hat{\beta}$) son preguntas distintas... pero prometimos que no eran rivales.
- **S3:** el Lasso selecciona *predictores*, no *causas*; para un α creíble, **post-double-selection** — y un nombre misterioso: *ortogonalidad de Neyman*.
- **S4–S5:** bosques y *boosting* predicen de maravilla — “serán los motores dentro de un procedimiento causal”.

Hoy: la predicción al servicio de β

- 1 **Double/debiased ML (DML):** efectos promedio con controles flexibles estimados por *cualquier* método de ML.
- 2 **Causal forests:** efectos **heterogéneos** $\tau(x)$ con intervalos de confianza — ¿a quién beneficia más el programa?

La sesión que justifica el curso dentro de una maestría en economía.

- 1 El problema y el marco
- 2 Double/debiased machine learning (DML)
- 3 Efectos heterogéneos: causal forests
- 4 El mapa del economista aumentado

¿Dónde entra el ML en una pregunta causal?

La identificación no cambia: seguimos necesitando un diseño — aquí, *selección en observables* (unconfoundedness): condicional en x , el tratamiento es como aleatorio.

¿Dónde entra el ML en una pregunta causal?

La identificación no cambia: seguimos necesitando un diseño — aquí, *selección en observables* (unconfoundedness): condicional en x , el tratamiento es como aleatorio.

Lo que sí cambia: las tareas *internas* del análisis son problemas de **predicción**:

- ¿Cómo controlar **flexiblemente** por x ? (¿lineal? ¿cuadrático? ¿interacciones? — es estimar $\mathbb{E}[y \mid x]$: predicción.)
- ¿Cómo modelar la **propensión** al tratamiento $\mathbb{E}[d \mid x]$? (predicción.)
- ¿**Quién** responde más al tratamiento? (predicción de efectos.)

¿Dónde entra el ML en una pregunta causal?

La identificación no cambia: seguimos necesitando un diseño — aquí, *selección en observables* (unconfoundedness): condicional en x , el tratamiento es como aleatorio.

Lo que sí cambia: las tareas *internas* del análisis son problemas de **predicción**:

- ¿Cómo controlar **flexiblemente** por x ? (¿lineal? ¿cuadrático? ¿interacciones? — es estimar $\mathbb{E}[y \mid x]$: predicción.)
- ¿Cómo modelar la **propensión** al tratamiento $\mathbb{E}[d \mid x]$? (predicción.)
- ¿**Quién** responde más al tratamiento? (predicción de efectos.)

La división del trabajo

El diseño identifica; el ML estima. El ML no compra supuestos de identificación — compra *formas funcionales* que no hay que asumir.

¿Dónde entra el ML en una pregunta causal?

La identificación no cambia: seguimos necesitando un diseño — aquí, *selección en observables* (unconfoundedness): condicional en x , el tratamiento es como aleatorio.

Lo que sí cambia: las tareas *internas* del análisis son problemas de **predicción**:

- ¿Cómo controlar **flexiblemente** por x ? (¿lineal? ¿cuadrático? ¿interacciones? — es estimar $\mathbb{E}[y \mid x]$: predicción.)
- ¿Cómo modelar la **propensión** al tratamiento $\mathbb{E}[d \mid x]$? (predicción.)
- ¿**Quién** responde más al tratamiento? (predicción de efectos.)

La división del trabajo

El diseño identifica; el ML estima. El ML no compra supuestos de identificación — compra *formas funcionales* que no hay que asumir.

El vehículo de toda la primera parte: el **modelo parcialmente lineal** (Robinson, 1988):

$$y = \alpha d + g(x) + \varepsilon, \quad d = m(x) + v, \quad \mathbb{E}[\varepsilon \mid x, d] = 0, \quad \mathbb{E}[v \mid x] = 0$$

α : el efecto que queremos. g, m : funciones *molestas* (*nuisance*) — desconocidas.

- 1 El problema y el marco
- 2 Double/debiased machine learning (DML)
- 3 Efectos heterogéneos: causal forests
- 4 El mapa del economista aumentado

El intento ingenuo y sus dos pecados

Tentación: estimar $\hat{g}$ con un bosque (¡predice buenísimo!), y luego $\hat{\alpha}$ de la regresión de $y - \hat{g}(x)$ sobre d .

El intento ingenuo y sus dos pecados

Tentación: estimar $\hat{g}$ con un bosque (¡predice buenísimo!), y luego $\hat{\alpha}$ de la regresión de $y - \hat{g}(x)$ sobre d .

Pecado 1 — sesgo de regularización. Todo ML *bueno* está regularizado: encoge, poda, suaviza (¡es la lección del curso!). Ese sesgo deliberado en $\hat{g}$ se transmite a $\hat{\alpha}$ **a primer orden**: el error $\hat{g} - g$ está correlacionado con d (porque d depende de x), y $\hat{\alpha}$ lo absorbe. La convergencia de $\hat{g}$ es más lenta que $\sqrt{n} \Rightarrow \hat{\alpha}$ hereda esa lentitud: adiós inferencia estándar.

El intento ingenuo y sus dos pecados

Tentación: estimar $\hat{g}$ con un bosque (¡predice buenísimo!), y luego $\hat{\alpha}$ de la regresión de $y - \hat{g}(x)$ sobre d .

Pecado 1 — sesgo de regularización. Todo ML *bueno* está regularizado: encoge, poda, suaviza (¡es la lección del curso!). Ese sesgo deliberado en $\hat{g}$ se transmite a $\hat{\alpha}$ **a primer orden**: el error $\hat{g} - g$ está correlacionado con d (porque d depende de x), y $\hat{\alpha}$ lo absorbe. La convergencia de $\hat{g}$ es más lenta que $\sqrt{n} \Rightarrow \hat{\alpha}$ hereda esa lentitud: adiós inferencia estándar.

Pecado 2 — sobreajuste propio. Si $\hat{g}$ se estima con *los mismos datos* donde luego se estima α , $\hat{g}$ absorbe parte del ruido $\varepsilon \Rightarrow$ correlación mecánica entre $\hat{g}$ y los errores $\Rightarrow$ otro sesgo.

El intento ingenuo y sus dos pecados

Tentación: estimar $\hat{g}$ con un bosque (¡predice buenísimo!), y luego $\hat{\alpha}$ de la regresión de $y - \hat{g}(x)$ sobre d .

Pecado 1 — sesgo de regularización. Todo ML *bueno* está regularizado: encoge, poda, suaviza (¡es la lección del curso!). Ese sesgo deliberado en $\hat{g}$ se transmite a $\hat{\alpha}$ **a primer orden**: el error $\hat{g} - g$ está correlacionado con d (porque d depende de x), y $\hat{\alpha}$ lo absorbe. La convergencia de $\hat{g}$ es más lenta que $\sqrt{n} \Rightarrow \hat{\alpha}$ hereda esa lentitud: adiós inferencia estándar.

Pecado 2 — sobreajuste propio. Si $\hat{g}$ se estima con *los mismos datos* donde luego se estima α , $\hat{g}$ absorbe parte del ruido $\varepsilon \Rightarrow$ correlación mecánica entre $\hat{g}$ y los errores $\Rightarrow$ otro sesgo.

Las dos curas (una por pecado)

- ❶ Contra el sesgo de regularización: **ortogonalidad de Neyman** (construir bien el momento).
- ❷ Contra el sobreajuste: **cross-fitting** (nunca estimar nuisance y efecto con los mismos datos).

DML = exactamente estas dos ideas, formalizadas por Chernozhukov et al. (2018)

Cura 1: ortogonalidad de Neyman (vía un viejo amigo)

¿**Recuerdan Frisch–Waugh–Lovell?** En regresión lineal, $\hat{\alpha}$ se obtiene regresando *residuos sobre residuos*. La versión DML hace lo mismo con ML:

Cura 1: ortogonalidad de Neyman (vía un viejo amigo)

¿**Recuerdan Frisch–Waugh–Lovell?** En regresión lineal, $\hat{\alpha}$ se obtiene regresando *residuos sobre residuos*. La versión DML hace lo mismo con ML:

- 1 Predecir y desde x : $\hat{\ell}(x) \approx \mathbb{E}[y \mid x]$. Residuo: $\tilde{y} = y - \hat{\ell}(x)$.
- 2 Predecir d desde x : $\hat{m}(x) \approx \mathbb{E}[d \mid x]$. Residuo: $\tilde{d} = d - \hat{m}(x)$.
- 3 Regresar $\tilde{y}$ sobre $\tilde{d}$ por OLS $\Rightarrow \hat{\alpha}$.

Cura 1: ortogonalidad de Neyman (vía un viejo amigo)

¿**Recuerdan Frisch–Waugh–Lovell?** En regresión lineal, $\hat{\alpha}$ se obtiene regresando *residuos sobre residuos*. La versión DML hace lo mismo con ML:

- 1 Predecir y desde x : $\hat{\ell}(x) \approx \mathbb{E}[y \mid x]$. Residuo: $\tilde{y} = y - \hat{\ell}(x)$.
- 2 Predecir d desde x : $\hat{m}(x) \approx \mathbb{E}[d \mid x]$. Residuo: $\tilde{d} = d - \hat{m}(x)$.
- 3 Regresar $\tilde{y}$ sobre $\tilde{d}$ por OLS $\Rightarrow \hat{\alpha}$.

¿**Por qué esto es “ortogonal”?** El momento $\mathbb{E}[(\tilde{y} - \alpha\tilde{d})\tilde{d}] = 0$ tiene una propiedad mágica: su **derivada respecto a los nuisances** (ℓ, m) , **evaluada en los verdaderos, es cero**.

- Errores de *primer orden* en $\hat{\ell}$ y $\hat{m}$ **no mueven** el momento; solo entran *productos* de errores (segundo orden).
- Es la “inmunización” del PDS de la sesión 3 — ahora con cualquier ML en los pasos 1–2, no solo Lasso.

Cura 1: ortogonalidad de Neyman (vía un viejo amigo)

¿**Recuerdan Frisch–Waugh–Lovell?** En regresión lineal, $\hat{\alpha}$ se obtiene regresando *residuos sobre residuos*. La versión DML hace lo mismo con ML:

- 1 Predecir y desde x : $\hat{\ell}(x) \approx \mathbb{E}[y \mid x]$. Residuo: $\tilde{y} = y - \hat{\ell}(x)$.
- 2 Predecir d desde x : $\hat{m}(x) \approx \mathbb{E}[d \mid x]$. Residuo: $\tilde{d} = d - \hat{m}(x)$.
- 3 Regresar $\tilde{y}$ sobre $\tilde{d}$ por OLS $\Rightarrow \hat{\alpha}$.

¿**Por qué esto es “ortogonal”?** El momento $\mathbb{E}[(\tilde{y} - \alpha\tilde{d})\tilde{d}] = 0$ tiene una propiedad mágica: su **derivada respecto a los nuisances** (ℓ, m), **evaluada en los verdaderos, es cero**.


- Errores de *primer orden* en $\hat{\ell}$ y $\hat{m}$ **no mueven** el momento; solo entran *productos* de errores (segundo orden).
- Es la “inmunización” del PDS de la sesión 3 — ahora con cualquier ML en los pasos 1–2, no solo Lasso.

Contraste con el ingenuo

El ingenuo usa el momento equivocado (solo residualiza y): su derivada respecto a g **no** es cero, y el sesgo de regularización entra directo. **Residualizar también el tratamiento** es lo que inmuniza — “double”.


Cura 2: cross-fitting

Falta el pecado 2: no usar las mismas observaciones para aprender los nuisances y para estimar α .



Cura 2: cross-fitting


Falta el pecado 2: no usar las mismas observaciones para aprender los nuisances y para estimar α .



- 1 Partir la muestra en K folds (como en CV — la sesión 2, reciclada para inferencia).
- 2 Para cada fold k : estimar $\hat{\ell}, \hat{m}$ con los **otros** $K - 1$ folds; calcular los residuos $\tilde{y}, \tilde{d}$ **en el fold** k .
- 3 Con todos los residuos (cada uno “out-of-fold”), correr la regresión final y los SE de siempre.

Cura 2: cross-fitting

Falta el pecado 2: no usar las mismas observaciones para aprender los nuisances y para estimar α .



- 1 Partir la muestra en K folds (como en CV — la sesión 2, reciclada para inferencia).
- 2 Para cada fold k : estimar $\hat{\ell}, \hat{m}$ con los **otros** $K - 1$ folds; calcular los residuos $\tilde{y}, \tilde{d}$ **en el fold** k .
- 3 Con todos los residuos (cada uno “out-of-fold”), correr la regresión final y los SE de siempre.
- Cada observación es evaluada por modelos que **nunca la vieron** $\Rightarrow$ muere la correlación mecánica del sobreajuste, sin sacrificar datos.

El resultado central del DML

Teorema (informal; Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey & Robins, 2018). Con (i) momento ortogonal, (ii) cross-fitting, y (iii) nuisances estimados con error que se encoge más rápido que $n^{-1/4}$:

$$\sqrt{n}(\hat{\alpha} - \alpha) \longrightarrow N(0, \sigma_{\alpha}^2)$$

y los intervalos de confianza usuales son válidos.

El resultado central del DML

Teorema (informal; Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey & Robins, 2018). Con (i) momento ortogonal, (ii) cross-fitting, y (iii) nuisances estimados con error que se encoge más rápido que $n^{-1/4}$:

$$\sqrt{n}(\hat{\alpha} - \alpha) \rightarrow N(0, \sigma_{\alpha}^2)$$

y los intervalos de confianza usuales son válidos.

Por qué es un resultado hermoso:

- $n^{-1/4}$ es una vara **baja**: Lasso, bosques, *boosting* y redes la alcanzan bajo condiciones razonables (sparsity aproximada, suavidad. . .).
- Es decir: **predictores mediocres bastan para inferencia de primera** — la ortogonalidad convierte errores de tamaño $n^{-1/4}$ en sesgos de tamaño $n^{-1/2}$ (productos), justo lo tolerable.

El resultado central del DML

Teorema (informal; Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey & Robins, 2018). Con (i) momento ortogonal, (ii) cross-fitting, y (iii) nuisances estimados con error que se encoge más rápido que $n^{-1/4}$:

$$\sqrt{n}(\hat{\alpha} - \alpha) \rightarrow N(0, \sigma_{\alpha}^2)$$

y los intervalos de confianza usuales son válidos.

Por qué es un resultado hermoso:

- $n^{-1/4}$ es una vara **baja**: Lasso, bosques, *boosting* y redes la alcanzan bajo condiciones razonables (sparsity aproximada, suavidad. . .).
- Es decir: **predictores mediocres bastan para inferencia de primera** — la ortogonalidad convierte errores de tamaño $n^{-1/4}$ en sesgos de tamaño $n^{-1/2}$ (productos), justo lo tolerable.
- Y es **agnóstico**: el “mejor ML para los nuisances” se elige por CV como siempre; la teoría no exige uno en particular. La receta general admite también ATE con propensity (AIPW), IV parcialmente lineal, y más.

El resultado central del DML

Teorema (informal; Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey & Robins, 2018). Con (i) momento ortogonal, (ii) cross-fitting, y (iii) nuisances estimados con error que se encoge más rápido que $n^{-1/4}$:

$$\sqrt{n}(\hat{\alpha} - \alpha) \rightarrow N(0, \sigma_{\alpha}^2)$$

y los intervalos de confianza usuales son válidos.

Por qué es un resultado hermoso:

- $n^{-1/4}$ es una vara **baja**: Lasso, bosques, *boosting* y redes la alcanzan bajo condiciones razonables (sparsity aproximada, suavidad. . .).
- Es decir: **predictores mediocres bastan para inferencia de primera** — la ortogonalidad convierte errores de tamaño $n^{-1/4}$ en sesgos de tamaño $n^{-1/2}$ (productos), justo lo tolerable.
- Y es **agnóstico**: el “mejor ML para los nuisances” se elige por CV como siempre; la teoría no exige uno en particular. La receta general admite también ATE con propensity (AIPW), IV parcialmente lineal, y más.

En R

DoubleML (Bach et al.) sobre `mlr3`, o `hdm` para las versiones Lasso. La aplicación

Lo que el DML no hace

- **No compra identificación.** Todo lo anterior asume *unconfoundedness*: los confusores relevantes están **en** x . Si hay selección en no observables, el DML estima con elegancia asintótica... un parámetro sesgado. El diseño (¡su curso de causal!) va primero.

Lo que el DML no hace

- **No compra identificación.** Todo lo anterior asume *unconfoundedness*: los confusores relevantes están **en** x . Si hay selección en no observables, el DML estima con elegancia asintótica... un parámetro sesgado. El diseño (¡su curso de causal!) va primero.
- **No sustituye el sentido común sobre x .** Meter *malos controles* (mediadores, colliders — ¡semana 1 de ECO-60116!) sigue siendo un error: el ML los usará con entusiasmo.

Lo que el DML no hace

- **No compra identificación.** Todo lo anterior asume *unconfoundedness*: los confusores relevantes están **en** x . Si hay selección en no observables, el DML estima con elegancia asintótica... un parámetro sesgado. El diseño (¡su curso de causal!) va primero.
- **No sustituye el sentido común sobre x .** Meter *malos controles* (mediadores, colliders — ¡semana 1 de ECO-60116!) sigue siendo un error: el ML los usará con entusiasmo.
- **No es magia de muestras chicas.** Es un resultado asintótico; con n pequeño y señal débil, los IC son honestos pero anchos.

Lo que el DML no hace

- **No compra identificación.** Todo lo anterior asume *unconfoundedness*: los confusores relevantes están **en** x . Si hay selección en no observables, el DML estima con elegancia asintótica... un parámetro sesgado. El diseño (¡su curso de causal!) va primero.
- **No sustituye el sentido común sobre x .** Meter *malos controles* (mediadores, colliders — ¡semana 1 de ECO-60116!) sigue siendo un error: el ML los usará con entusiasmo.
- **No es magia de muestras chicas.** Es un resultado asintótico; con n pequeño y señal débil, los IC son honestos pero anchos.

El mantra de la sesión

El ML resuelve la **forma funcional**; el economista resuelve la **identificación**. En ese orden de importancia.

- 1 El problema y el marco
- 2 Double/debiased machine learning (DML)
- 3 Efectos heterogéneos: causal forests
- 4 El mapa del economista aumentado

De α promedio a $\tau(x)$: la pregunta de focalización

El DML entrega un **promedio**. Pero la política pública casi siempre pregunta más:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

el efecto **condicional** (CATE): ¿para quién funciona el programa?

De α promedio a $\tau(x)$: la pregunta de focalización

El DML entrega un **promedio**. Pero la política pública casi siempre pregunta más:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

el efecto **condicional** (CATE): ¿para quién funciona el programa?

- ¿La transferencia sube más la asistencia escolar en hogares rurales? ¿El subsidio al empleo sirve solo a los jóvenes? $\Rightarrow$ **focalizar** con presupuesto limitado.

De α promedio a $\tau(x)$: la pregunta de focalización

El DML entrega un **promedio**. Pero la política pública casi siempre pregunta más:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

el efecto **condicional** (CATE): ¿para quién funciona el programa?

- ¿La transferencia sube más la asistencia escolar en hogares rurales? ¿El subsidio al empleo sirve solo a los jóvenes? $\Rightarrow$ **focalizar** con presupuesto limitado.

¿Y por qué no interacciones a mano ($d \times$ mujer, $d \times$ rural, ...)?

- Con muchas x , las interacciones candidatas explotan (¡alta dimensión, sesión 3!).
- Probar docenas y reportar la significativa = *data snooping*: garantía de falsos positivos.
- Y la heterogeneidad real puede ser no lineal o de combinaciones (rural $\times$ joven $\times$ sin acceso a crédito).

De α promedio a $\tau(x)$: la pregunta de focalización

El DML entrega un **promedio**. Pero la política pública casi siempre pregunta más:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

el efecto **condicional** (CATE): ¿para quién funciona el programa?

- ¿La transferencia sube más la asistencia escolar en hogares rurales? ¿El subsidio al empleo sirve solo a los jóvenes? $\Rightarrow$ **focalizar** con presupuesto limitado.

¿**Y por qué no interacciones a mano** ($d \times$ mujer, $d \times$ rural, ...)?

- Con muchas x , las interacciones candidatas explotan (¡alta dimensión, sesión 3!).
- Probar docenas y reportar la significativa = *data snooping*: garantía de falsos positivos.
- Y la heterogeneidad real puede ser no lineal o de combinaciones (rural $\times$ joven $\times$ sin acceso a crédito).

La idea

Dejar que un **método flexible** busque la heterogeneidad — pero con las protecciones estadísticas que la búsqueda exige. Ese método será un **buscador**.

Por qué un árbol “normal” falla para $\tau(x)$

Dos obstáculos, uno conceptual y uno estadístico:

Por qué un árbol “normal” falla para $\tau(x)$

Dos obstáculos, uno conceptual y uno estadístico:

- 1 **El objetivo equivocado.** CART parte el espacio para predecir y . Pero heterogeneidad en *niveles* de $y \neq$ heterogeneidad en *efectos*: un grupo puede tener y altísimo y efecto cero. Hay que partir buscando donde **cambia** τ , no donde cambia y .

Por qué un árbol “normal” falla para $\tau(x)$

Dos obstáculos, uno conceptual y uno estadístico:

- 1 **El objetivo equivocado.** CART parte el espacio para predecir y . Pero heterogeneidad en *niveles* de $y \neq$ heterogeneidad en *efectos*: un grupo puede tener y altísimo y efecto cero. Hay que partir buscando donde **cambia** τ , no donde cambia y .
- 2 **Sobreajuste adaptativo.** Si las *mismas* observaciones eligen los cortes **y** estiman el efecto en cada hoja, los cortes “persiguen” fluctuaciones del ruido y los efectos por hoja quedan **sesgados** hacia la heterogeneidad espuria encontrada. Es el pecado 2 del DML en versión árbol.

Por qué un árbol “normal” falla para $\tau(x)$

Dos obstáculos, uno conceptual y uno estadístico:

- 1 **El objetivo equivocado.** CART parte el espacio para predecir y . Pero heterogeneidad en *niveles* de $y \neq$ heterogeneidad en *efectos*: un grupo puede tener y altísimo y efecto cero. Hay que partir buscando donde **cambia** τ , no donde cambia y .
- 2 **Sobreajuste adaptativo.** Si las *mismas* observaciones eligen los cortes **y** estiman el efecto en cada hoja, los cortes “persiguen” fluctuaciones del ruido y los efectos por hoja quedan **sesgados** hacia la heterogeneidad espuria encontrada. Es el pecado 2 del DML en versión árbol.

La cura: honestidad (Athey & Imbens, 2016)

Partir la muestra del árbol en dos mitades: una elige los **cortes**, la otra — que los cortes nunca vieron — estima los **efectos** en las hojas. Predicción y estimación, divorciadas dentro de cada árbol. (¿Les suena? Es cross-fitting en miniatura.)

Causal forest (Wager & Athey, 2018; Athey, Tibshirani & Wager, 2019)

La receta completa:

- 1 **Ortogonalizar primero** (¡el DML por dentro!): residualizar y y d contra x con bosques auxiliares y cross-fitting.
- 2 Crear muchos **árboles causales honestos** sobre los residuos, con cortes que maximizan la heterogeneidad de τ entre hijos (y las dosis de aleatoriedad del RF: bootstrap + m candidatos).
- 3 $\hat{\tau}(x)$: agregación de los árboles — formalmente, un **promedio ponderado por vecindad adaptativa**: los árboles definen quiénes son “vecinos relevantes” de x para el efecto.

Causal forest (Wager & Athey, 2018; Athey, Tibshirani & Wager, 2019)

La receta completa:

- 1 **Ortogonalizar primero** (¡el DML por dentro!): residualizar y y d contra x con bosques auxiliares y cross-fitting.
- 2 Crear muchos **árboles causales honestos** sobre los residuos, con cortes que maximizan la heterogeneidad de τ entre hijos (y las dosis de aleatoriedad del RF: bootstrap + m candidatos).
- 3 $\hat{\tau}(x)$: agregación de los árboles — formalmente, un **promedio ponderado por vecindad adaptativa**: los árboles definen quiénes son “vecinos relevantes” de x para el efecto.

Lo que se gana con toda esta disciplina:

- $\hat{\tau}(x)$ es **consistente y asintóticamente normal**, con errores estándar estimables $\Rightarrow$ **intervalos de confianza para el efecto de cada quien**.
- Un objeto que ningún método del curso había dado: inferencia *puntual* sobre una función de efectos.

Causal forest (Wager & Athey, 2018; Athey, Tibshirani & Wager, 2019)

La receta completa:

- 1 **Ortogonalizar primero** (¡el DML por dentro!): residualizar y y d contra x con bosques auxiliares y cross-fitting.
- 2 Crear muchos **árboles causales honestos** sobre los residuos, con cortes que maximizan la heterogeneidad de τ entre hijos (y las dosis de aleatoriedad del RF: bootstrap + m candidatos).
- 3 $\hat{\tau}(x)$: agregación de los árboles — formalmente, un **promedio ponderado por vecindad adaptativa**: los árboles definen quiénes son “vecinos relevantes” de x para el efecto.

Lo que se gana con toda esta disciplina:

- $\hat{\tau}(x)$ es **consistente y asintóticamente normal**, con errores estándar estimables $\Rightarrow$ **intervalos de confianza para el efecto de cada quien**.
- Un objeto que ningún método del curso había dado: inferencia *puntual* sobre una función de efectos.

Supuestos. siempre los supuestos

Cómo se lee (y cómo no) un causal forest

El flujo de análisis con grf en R:

- ❶ `cf <- causal_forest(X, Y, W)` ($W = \text{tratamiento}$); $\hat{\tau}(x)$ e IC con `predict(cf, estimate.variance = TRUE)`.
- ❷ **ATE primero:** `average_treatment_effect(cf)` — el promedio, con la maquinaria DML.
- ❸ **¿Hay heterogeneidad de verdad?** `test_calibration(cf)`: un test global antes de emocionarse con el histograma de $\hat{\tau}$.
- ❹ **¿Quién?** Efectos promedio por cuartiles de $\hat{\tau}$, *best linear projection* sobre covariables interpretables.

Cómo se lee (y cómo no) un causal forest

El flujo de análisis con grf en R:

- ❶ `cf <- causal_forest(X, Y, W)` (W = tratamiento); $\hat{\tau}(x)$ e IC con `predict(cf, estimate.variance = TRUE)`.
- ❷ **ATE primero:** `average_treatment_effect(cf)` — el promedio, con la maquinaria DML.
- ❸ **¿Hay heterogeneidad de verdad?** `test_calibration(cf)`: un test global antes de emocionarse con el histograma de $\hat{\tau}$.
- ❹ **¿Quién?** Efectos promedio por cuartiles de $\hat{\tau}$, *best linear projection* sobre covariables interpretables.

Las trampas de lectura:

- La dispersión del histograma de $\hat{\tau}(x)$ **no** es evidencia de heterogeneidad (mezcla señal y ruido): por eso el test primero.
- Las variables que “explican” τ son **descriptivas** (¡proxies, sesión 3!): útiles para focalizar, no para mecanismos.
- Con señal débil, IC individuales anchos: honestidad $\neq$ precisión gratis.
- Modelo a imitar en sus proyectos: Davis & Heller (2017. AER P&P) —

- 1 El problema y el marco
- 2 Double/debiased machine learning (DML)
- 3 Efectos heterogéneos: causal forests
- 4 El mapa del economista aumentado**

Qué herramienta para qué pregunta

Pregunta	Herramienta	Sesión
¿Qué valor tomará y ? (predicción pura)	regularización, RF, boosting	2–5
Efecto promedio, pocos controles	OLS / su curso de causal	—
Efecto promedio, muchos controles	PDS / DML	3, 6
¿ Para quién funciona? (CATE, focalización)	causal forest	6
¿A quién tratar con presupuesto fijo?	<i>policy learning</i> sobre $\hat{\tau}$	(lectura)

Qué herramienta para qué pregunta

Pregunta	Herramienta	Sesión
¿Qué valor tomará y ? (predicción pura)	regularización, RF, boosting	2–5
Efecto promedio, pocos controles	OLS / su curso de causal	—
Efecto promedio, muchos controles	PDS / DML	3, 6
¿ Para quién funciona? (CATE, focalización)	causal forest	6
¿A quién tratar con presupuesto fijo?	<i>policy learning</i> sobre $\hat{\tau}$	(lectura)

Las tres reglas que ordenan todo:

- 1 **Identificación antes que estimación:** el diseño no se delega al algoritmo.
- 2 **Ortogonalizar y separar muestras** siempre que un objeto estimado entre en otra estimación (Neyman + cross-fitting/honestidad).
- 3 **La heterogeneidad se testea antes de interpretarse.**

Qué herramienta para qué pregunta

Pregunta	Herramienta	Sesión
¿Qué valor tomará y ? (predicción pura)	regularización, RF, boosting	2–5
Efecto promedio, pocos controles	OLS / su curso de causal	—
Efecto promedio, muchos controles	PDS / DML	3, 6
¿ Para quién funciona? (CATE, focalización)	causal forest	6
¿A quién tratar con presupuesto fijo?	<i>policy learning</i> sobre $\hat{\tau}$	(lectura)

Las tres reglas que ordenan todo:

- 1 **Identificación antes que estimación:** el diseño no se delega al algoritmo.
- 2 **Ortogonalizar y separar muestras** siempre que un objeto estimado entre en otra estimación (Neyman + cross-fitting/honestidad).
- 3 **La heterogeneidad se testea antes de interpretarse.**

Con esto cierra el bloque supervisado-causal del curso: lo que sigue (S7–S9) explora datos **sin** etiqueta y datos **no estructurados**.

Recap

- 1 En una pregunta causal, el ML estima las piezas **predictivas** ($\mathbb{E}[y|x]$, $\mathbb{E}[d|x]$, $\tau(x)$); la **identificación** sigue siendo del economista.
- 2 El plug-in ingenuo peca dos veces: **sesgo de regularización** y **sobreajuste**. Las curas: momento **ortogonal** (residuos sobre residuos, FWL generalizado) y **cross-fitting**.
- 3 **DML**: con nuisances a tasa $n^{-1/4}$, $\hat{\alpha}$ es $\sqrt{n}$ -normal e IC válidos — predictores mediocres bastan para inferencia de primera.
- 4 **Causal forests**: árboles que parten donde cambia τ , **honestos** (cortes y efectos con mitades distintas), ortogonalizados por dentro $\Rightarrow \hat{\tau}(x)$ con intervalos de confianza.
- 5 Leer con disciplina: test global de heterogeneidad primero; los drivers de τ son proxies para **focalizar**, no mecanismos.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About*, Annual Review of Economics.
Guía: ahora sí, lectura completa — es el mapa de la sesión de hoy.
- Chernozhukov et al. (2018), *Double/Debiased Machine Learning*, secciones 1–2.
Guía: no se pierdan en la notación; busquen ortogonalidad y cross-fitting.

Recomendadas: Wager & Athey (2018); Davis & Heller (2017); Belloni et al. (2014, JEP) para repasar.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About*, Annual Review of Economics.
Guía: ahora sí, lectura completa — es el mapa de la sesión de hoy.
- Chernozhukov et al. (2018), *Double/Debiased Machine Learning*, secciones 1–2.
Guía: no se pierdan en la notación; busquen ortogonalidad y cross-fitting.

Recomendadas: Wager & Athey (2018); Davis & Heller (2017); Belloni et al. (2014, JEP) para repasar.

Próxima sesión — soltamos la y: aprendizaje **no supervisado**. Clustering (k -means, jerárquico) y reducción de dimensión (PCA y amigos): segmentar consumidores y construir índices socioeconómicos sin variable de respuesta.
Lectura previa: ISLR cap. 12 (secs. 12.1–12.2 y 12.4).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About*, Annual Review of Economics.
Guía: ahora sí, lectura completa — es el mapa de la sesión de hoy.
- Chernozhukov et al. (2018), *Double/Debiased Machine Learning*, secciones 1–2.
Guía: no se pierdan en la notación; busquen ortogonalidad y cross-fitting.

Recomendadas: Wager & Athey (2018); Davis & Heller (2017); Belloni et al. (2014, JEP) para repasar.

Próxima sesión — soltamos la y: aprendizaje **no supervisado**. Clustering (*k*-means, jerárquico) y reducción de dimensión (PCA y amigos): segmentar consumidores y construir índices socioeconómicos sin variable de respuesta.
Lectura previa: ISLR cap. 12 (secs. 12.1–12.2 y 12.4).

Aplicación de esta semana en R: heterogeneidad del efecto de un programa social con `grf`: del ATE al CATE, test de calibración y efectos por cuartiles.

Referencias esenciales

- Robinson, P. (1988). Root-N-Consistent Semiparametric Regression. *Econometrica*, 56(4), 931–954.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *JEP*, 28(2), 29–50.
- Athey, S., & Imbens, G. (2016). Recursive Partitioning for Heterogeneous Causal Effects. *PNAS*, 113(27), 7353–7360.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects using Random Forests. *JASA*, 113(523), 1228–1242.
- Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized Random Forests. *Annals of Statistics*, 47(2), 1148–1178.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Davis, J., & Heller, S. (2017). Using Causal Forests to Predict Treatment Heterogeneity: An Application to Summer Jobs. *AER P&P*, 107(5), 546–550.
- Bach, P., Chernozhukov, V., Kurz, M., & Spindler, M. (2022). DoubleML: An Object-Oriented Implementation of Double Machine Learning in R. *JMLR* / CRAN.