

Big Data y Machine Learning para Economía Aplicada

Week 06: Árboles, bosques y *boosting*

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 9, 2026

Previously...

- **Muchos predictores** = poca información por parámetro. Tres salidas: seleccionar, encoger (λ por la curva de CV) y comprimir. Lo que sobrevive a la penalización son *predictores*, no *causas*.

Previously...

- **Muchos predictores** = poca información por parámetro. Tres salidas: seleccionar, encoger (λ por la curva de CV) y comprimir. Lo que sobrevive a la penalización son *predictores*, no *causas*.
- Pero todo seguía siendo **lineal en los parámetros**: las curvas y los cruces había que *escribirlos*: *splines* e interacciones en la sesión 2, 465 regresores de a pares en la sesión 5.

Previously...

- **Muchos predictores** = poca información por parámetro. Tres salidas: seleccionar, encoger (λ por la curva de CV) y comprimir. Lo que sobrevive a la penalización son *predictores*, no *causas*.
- Pero todo seguía siendo **lineal en los parámetros**: las curvas y los cruces había que *escribirlos*: *splines* e interacciones en la sesión 2, 465 regresores de a pares en la sesión 5.
- Y una promesa de la sesión 1: cuánto recorre una recta y cuánto exige flexibilidad. En Gelvez et al. (2026), la recta explica el 58 % de la participación del ganador en 2022 y el bosque el 66 %.

Previously...

- **Muchos predictores** = poca información por parámetro. Tres salidas: seleccionar, encoger (λ por la curva de CV) y comprimir. Lo que sobrevive a la penalización son *predictores*, no *causas*.
- Pero todo seguía siendo **lineal en los parámetros**: las curvas y los cruces había que *escribirlos*: *splines* e interacciones en la sesión 2, 465 regresores de a pares en la sesión 5.
- Y una promesa de la sesión 1: cuánto recorre una recta y cuánto exige flexibilidad. En Gelvez et al. (2026), la recta explica el 58 % de la participación del ganador en 2022 y el bosque el 66 %.

Hoy

Los **árboles**: la máquina que encuentra sola las no linealidades y las interacciones. Un árbol solo predice mal y tiembla; **promediar** cientos de ellos (bosque) o **sumarlos** en secuencia (*boosting*) lo arregla. Con ellos replicamos el núcleo de Gelvez et al. y los comparamos, en la misma prueba, con todo lo anterior. Al final, la presentación estudiantil del paper de la sesión 5.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 *Afinar y comparar*
- 5 *Aplicación guiada: ¿cuánto votó el ganador en la mesa?*
- 6 *Interpretación y cierre*

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para que el precio dependiera del área de forma distinta según el estrato escribimos `area:estrato`; para curvar, *splines* con nodos elegidos por CV.

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para que el precio dependiera del área de forma distinta según el estrato escribimos `area:estrato`; para curvar, *splines* con nodos elegidos por CV.
- **Sesión 5:** con 30 variables base, 465 regresores de a pares; con cubos y triples, miles. El Lasso los podaba, pero *nosotros* los propusimos.

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para que el precio dependiera del área de forma distinta según el estrato escribimos `area:estrato`; para curvar, *splines* con nodos elegidos por CV.
- **Sesión 5:** con 30 variables base, 465 regresores de a pares; con cubos y triples, miles. El Lasso los podaba, pero *nosotros* los propusimos.
- **Las mesas:** Gelvez et al. (2026) sospechan que la relación entre educación y apoyo electoral cambia entre lo urbano y lo rural y según la composición socioeconómica del territorio. ¿Cuál de las 2^k interacciones posibles importa? Nadie lo sabe de antemano.

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para que el precio dependiera del área de forma distinta según el estrato escribimos `area:estrato`; para curvar, *splines* con nodos elegidos por CV.
- **Sesión 5:** con 30 variables base, 465 regresores de a pares; con cubos y triples, miles. El Lasso los podaba, pero *nosotros* los propusimos.
- **Las mesas:** Gelvez et al. (2026) sospechan que la relación entre educación y apoyo electoral cambia entre lo urbano y lo rural y según la composición socioeconómica del territorio. ¿Cuál de las 2^k interacciones posibles importa? Nadie lo sabe de antemano.

Pregunta para la sala

¿Cómo dejar que los datos decidan *dónde* curvar y *qué* cruzar con qué, sin escribir la fórmula?

El problema: las no linealidades que nadie escribió

Hasta hoy, la flexibilidad la poníamos nosotros a mano

- **Sesión 2:** para que el precio dependiera del área de forma distinta según el estrato escribimos `area:estrato`; para curvar, *splines* con nodos elegidos por CV.
- **Sesión 5:** con 30 variables base, 465 regresores de a pares; con cubos y triples, miles. El Lasso los podaba, pero *nosotros* los propusimos.
- **Las mesas:** Gelvez et al. (2026) sospechan que la relación entre educación y apoyo electoral cambia entre lo urbano y lo rural y según la composición socioeconómica del territorio. ¿Cuál de las 2^k interacciones posibles importa? Nadie lo sabe de antemano.


Pregunta para la sala

¿Cómo dejar que los datos decidan *dónde* curvar y *qué* cruzar con qué, sin escribir la fórmula?

Partiendo el espacio de los predictores en pedazos y prediciendo una constante en cada pedazo. Cada corte anidado dentro de otro es una interacción; cada secuencia de cortes sobre la misma variable es una no linealidad. Eso es un árbol.


La idea: partir el espacio en rectángulos

ISL 8.1.1: los dos paneles son el mismo modelo



La idea: partir el espacio en rectángulos

ISL 8.1.1: los dos paneles son el mismo modelo



- Cortes binarios sucesivos; en cada hoja (rectángulo) se predice una **constante**: $\hat{y} = \bar{y}_{R_m}$ en regresión, la clase mayoritaria en clasificación.
- Con la vivienda: R_4 es “grande y lejos del centro”, R_2 “grande y cerca”. El árbol *descubrió* la interacción área $\times$ distancia sin que nadie la escribiera.
- Parámetros: los cortes (j, t) y las constantes de las hojas. Hiperparámetro: el tamaño del árbol.

¿Cómo se elige cada corte?

En regresión: en cada paso, buscar el par (variable j , umbral s) que más reduce la suma de cuadrados:

$$\min_{j, s} \sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2,$$

con $R_1(j, s) = \{x : x_j < s\}$ y $R_2(j, s) = \{x : x_j \geq s\}$.

¿Cómo se elige cada corte?

En regresión: en cada paso, buscar el par (variable j , umbral s) que más reduce la suma de cuadrados:

$$\min_{j, s} \sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2,$$

con $R_1(j, s) = \{x : x_j < s\}$ y $R_2(j, s) = \{x : x_j \geq s\}$.

- La búsqueda es **exhaustiva** pero barata: para cada variable basta probar los umbrales entre observaciones consecutivas.
- El procedimiento es **voraz y recursivo**: el mejor corte *ahora*, sin mirar adelante; luego repetir dentro de cada mitad. Nada garantiza el árbol globalmente óptimo.

¿Cómo se elige cada corte?

En regresión: en cada paso, buscar el par (variable j , umbral s) que más reduce la suma de cuadrados:

$$\min_{j, s} \sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2,$$

con $R_1(j, s) = \{x : x_j < s\}$ y $R_2(j, s) = \{x : x_j \geq s\}$.

- La búsqueda es **exhaustiva** pero barata: para cada variable basta probar los umbrales entre observaciones consecutivas.
- El procedimiento es **voraz y recursivo**: el mejor corte *ahora*, sin mirar adelante; luego repetir dentro de cada mitad. Nada garantiza el árbol globalmente óptimo.
- Solo importa el *orden* de cada variable: el árbol es invariante a transformaciones monótonas. **Sin estandarizar y sin logaritmos.**

¿Cómo se elige cada corte?

En regresión: en cada paso, buscar el par (variable j , umbral s) que más reduce la suma de cuadrados:

$$\min_{j, s} \sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2,$$

con $R_1(j, s) = \{x : x_j < s\}$ y $R_2(j, s) = \{x : x_j \geq s\}$.


- La búsqueda es **exhaustiva** pero barata: para cada variable basta probar los umbrales entre observaciones consecutivas.
- El procedimiento es **voraz y recursivo**: el mejor corte *ahora*, sin mirar adelante; luego repetir dentro de cada mitad. Nada garantiza el árbol globalmente óptimo.
- Solo importa el *orden* de cada variable: el árbol es invariante a transformaciones monótonas. **Sin estandarizar y sin logaritmos.**

Lo que el árbol hace gratis

Funciones escalón e **interacciones** (cortes anidados que se condicionan), sin que nadie las especifique. Compárenlo con agregar términos a mano en la sesión 2.


Clasificación: pureza en vez de suma de cuadrados

Con y categórica, “reducir la RSS” se reemplaza por “dejar los nodos más **puros**”. Para un nodo con proporción $\hat{p}$ de la clase 1:



Clasificación: pureza en vez de suma de cuadrados

Con y categórica, “reducir la RSS” se reemplaza por “dejar los nodos más **puros**”. Para un nodo con proporción $\hat{p}$ de la clase 1:



- **Error de clasificación:** $1 - \max(\hat{p}, 1 - \hat{p})$. **Gini:** $2\hat{p}(1 - \hat{p})$. **Entropía:** $-\hat{p} \log \hat{p} - (1 - \hat{p}) \log(1 - \hat{p})$.
- Para **crecer** el árbol se usan Gini o entropía: son estrictamente cóncavas y premian avances hacia nodos puros que el error, plano por tramos, ni nota. Para **podar** vale el error.
- La hoja entrega una probabilidad, $\hat{p}_m$, y con ella vuelve todo lo de la sesión 3: umbral por costos, ROC, calibración.

¿Cuándo parar? Crecer grande y podar

El dilema: un árbol que corta hasta dejar una observación por hoja tiene error de entrenamiento cero: la memorización de la sesión 1. Parar temprano con reglas locales es miope: un corte mediocre puede habilitar uno excelente después.

¿Cuándo parar? Crecer grande y podar

El dilema: un árbol que corta hasta dejar una observación por hoja tiene error de entrenamiento cero: la memorización de la sesión 1. Parar temprano con reglas locales es miope: un corte mediocre puede habilitar uno excelente después. **La solución de CART** (Breiman et al., 1984; ISL, algoritmo 8.1): crecer un árbol grande T_0 y luego **podar** resolviendo

$$\min_{T \subseteq T_0} \sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \bar{y}_{R_m})^2 + \alpha |T|,$$

donde $|T|$ es el número de hojas.

¿Cuándo parar? Crecer grande y podar

El dilema: un árbol que corta hasta dejar una observación por hoja tiene error de entrenamiento cero: la memorización de la sesión 1. Parar temprano con reglas locales es miope: un corte mediocre puede habilitar uno excelente después. **La solución de CART** (Breiman et al., 1984; ISL, algoritmo 8.1): crecer un árbol grande T_0 y luego **podar** resolviendo


$$\min_{T \subseteq T_0} \sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \bar{y}_{R_m})^2 + \alpha |T|,$$

donde $|T|$ es el número de hojas.


- ¿Les suena? **Ajuste + castigo por complejidad:** la lógica de la sesión 5, con α en el papel de λ y “hojas” en el de “coeficientes”.
- Al variar α sale una **secuencia anidada** de subárboles; α se elige con la curva de CV de la sesión 4 (mínimo o regla 1-SE). En R: `rpart` llama a α `cp`.

Árboles contra rectas: depende de la forma de f

ISL 8.1.3: ninguna familia domina; lo decide la prueba




frontera real **lineal**:
el **árbol** la escalona




frontera real **rectangular**:
la **recta** no puede

Árboles contra rectas: depende de la forma de f

ISL 8.1.3: ninguna familia domina; lo decide la prueba



frontera real **lineal**:
el **árbol** la escalona



frontera real **rectangular**:
la **recta** no puede

- Si la verdad es (casi) lineal, la logística o el OLS ganan con menos datos: los escalones aproximan mal una pendiente. Si la verdad tiene bloques, umbrales e interacciones, el árbol gana sin ayuda.
- **Lo bueno del árbol**: legible (se le puede mostrar a un hacedor de política), mezcla variables continuas y categóricas, tolera faltantes con cortes sustitutos.
- **Lo malo**: predice peor que casi todo y es **inestable**: pocas observaciones distintas cambian el primer corte y todo lo que sigue.

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* del mismo entrenamiento suelen dar dos árboles que no se parecen.

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* del mismo entrenamiento suelen dar dos árboles que no se parecen.

Pregunta para la sala

Tenemos un método flexible, barato, de bajo sesgo... y varianza enorme. Con lo visto en el curso, ¿qué harían para bajar la varianza sin sacrificar la flexibilidad?

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* del mismo entrenamiento suelen dar dos árboles que no se parecen.

Pregunta para la sala

Tenemos un método flexible, barato, de bajo sesgo... y varianza enorme. Con lo visto en el curso, ¿qué harían para bajar la varianza sin sacrificar la flexibilidad?

Promediar. Si tuviéramos muchas muestras, entrenaríamos muchos árboles y promediaríamos sus predicciones: la varianza de un promedio de B cosas independientes es σ^2/B . No tenemos muchas muestras, pero la sesión 4 nos enseñó a fabricarlas: **bootstrap**.

El veredicto sobre el árbol solitario

Sesgo bajo, varianza altísima. Un árbol grande puede reproducir casi cualquier superficie por tramos, pero cada corte se decide con una fracción de los datos y hereda el azar del corte anterior. Dos remuestras *bootstrap* del mismo entrenamiento suelen dar dos árboles que no se parecen.

Pregunta para la sala

Tenemos un método flexible, barato, de bajo sesgo... y varianza enorme. Con lo visto en el curso, ¿qué harían para bajar la varianza sin sacrificar la flexibilidad?

Promediar. Si tuviéramos muchas muestras, entrenaríamos muchos árboles y promediaríamos sus predicciones: la varianza de un promedio de B cosas independientes es σ^2/B . No tenemos muchas muestras, pero la sesión 4 nos enseñó a fabricarlas: **bootstrap**.

- Es la segunda palanca contra la varianza del curso. La primera fue **encoger** (sesión 5); la de hoy es **promediar**. Las dos aceptan algo de sesgo a cambio de mucha varianza.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar y comparar
- 5 Aplicación guiada: ¿cuánto votó el ganador en la mesa?
- 6 Interpretación y cierre

Bagging: promediar baja la varianza

Bootstrap aggregating (Breiman, 1996; ISL 8.2.1):

- 1 Extraer B remuestras *bootstrap* del entrenamiento.
- 2 Ajustar un árbol **grande, sin podar** en cada una: sesgo bajo; la varianza la mata el promedio.
- 3 Promediar (regresión) o votar (clasificación): $\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$.

Bagging: promediar baja la varianza

Bootstrap aggregating (Breiman, 1996; ISL 8.2.1):

- 1 Extraer B remuestras *bootstrap* del entrenamiento.
- 2 Ajustar un árbol **grande, sin podar** en cada una: sesgo bajo; la varianza la mata el promedio.
- 3 Promediar (regresión) o votar (clasificación): $\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$.

El problema: los B árboles no son independientes; salieron de los mismos datos. Con varianza σ^2 y correlación ρ entre pares (apéndice A1),

$$\text{Var}(\hat{f}_{\text{bag}}(x)) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2$$

Bagging: promediar baja la varianza

Bootstrap aggregating (Breiman, 1996; ISL 8.2.1):

- 1 Extraer B remuestras *bootstrap* del entrenamiento.
- 2 Ajustar un árbol **grande, sin podar** en cada una: sesgo bajo; la varianza la mata el promedio.
- 3 Promediar (regresión) o votar (clasificación): $\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$.

El problema: los B árboles no son independientes; salieron de los mismos datos. Con varianza σ^2 y correlación ρ entre pares (apéndice A1),

$$\text{Var}(\hat{f}_{\text{bag}}(x)) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2$$

- Cuando $B \rightarrow \infty$ el segundo término muere, pero queda $\rho \sigma^2$: un **piso** que ningún número de árboles rompe.
- Aumentar B **nunca sobreajusta**, solo satura. El cuello de botella es ρ : para ganar más hay que **descorrelacionar** los árboles.

Random forest = bagging + descorrelación

La idea de Breiman (2001): en cada corte de cada árbol, sortear un subconjunto de solo m predictores y elegir el mejor corte *entre esos*. ISL sugiere $m \approx \sqrt{p}$ en clasificación y $m \approx p/3$ en regresión; es un hiperparámetro.

Random forest = bagging + descorrelación

La idea de Breiman (2001): en cada corte de cada árbol, sortear un subconjunto de solo m predictores y elegir el mejor corte *entre esos*. ISL sugiere $m \approx \sqrt{p}$ en clasificación y $m \approx p/3$ en regresión; es un hiperparámetro. **¿Por qué funciona?**

- Con *bagging* puro, si hay un predictor dominante casi todos los árboles lo usan en el primer corte: árboles clones, ρ alto, piso alto.
- Al sortear candidatos, muchos árboles *ni ven* al dominante en sus primeros cortes: exploran estructuras distintas, ρ baja y el piso baja. Cada árbol empeora un poco; el promedio mejora (ISL, Fig. 8.10: $m = \sqrt{p}$ le gana a $m = p$).

Random forest = bagging + descorrelación

La idea de Breiman (2001): en cada corte de cada árbol, sortear un subconjunto de solo m predictores y elegir el mejor corte *entre esos*. ISL sugiere $m \approx \sqrt{p}$ en clasificación y $m \approx p/3$ en regresión; es un hiperparámetro. **¿Por qué funciona?**

- Con *bagging* puro, si hay un predictor dominante casi todos los árboles lo usan en el primer corte: árboles clones, ρ alto, piso alto.
- Al sortear candidatos, muchos árboles *ni ven* al dominante en sus primeros cortes: exploran estructuras distintas, ρ baja y el piso baja. Cada árbol empeora un poco; el promedio mejora (ISL, Fig. 8.10: $m = \sqrt{p}$ le gana a $m = p$).

Los hiperparámetros del bosque

B : grande y sin miedo (500 a 1.000; satura). m (`mtry`): la perilla que importa; por CV o por OOB. Tamaño mínimo de hoja o profundidad: controla cuánto crece cada árbol. En R: `ranger`. Gelvez et al. (2026) afinan m como *fracción* de los predictores, entre 0,30 y 0,70.

Out-of-bag: la prueba gratis, con letra pequeña

Cada remuestra *bootstrap* deja fuera $\approx 36,8\%$ de las observaciones (el 0,632 de la sesión 4). Para cada observación i , alrededor de un tercio de los árboles **no la vieron**.

- **Predicción OOB de i :** promediar (o votar) usando solo esos árboles.
- **Error OOB:** el error de esas predicciones sobre todo el entrenamiento, sin apartar datos ni correr CV. Con B grande equivale, en esencia, a LOOCV.

Out-of-bag: la prueba gratis, con letra pequeña

Cada remuestra *bootstrap* deja fuera $\approx 36,8\%$ de las observaciones (el 0,632 de la sesión 4). Para cada observación i , alrededor de un tercio de los árboles **no la vieron**.

- **Predicción OOB de i :** promediar (o votar) usando solo esos árboles.
- **Error OOB:** el error de esas predicciones sobre todo el entrenamiento, sin apartar datos ni correr CV. Con B grande equivale, en esencia, a LOOCV.
- **Usos:** ver cuándo el error se aplana al crecer B ; afinar m sin CV.

Out-of-bag: la prueba gratis, con letra pequeña

Cada remuestra *bootstrap* deja fuera $\approx 36,8\%$ de las observaciones (el 0,632 de la sesión 4). Para cada observación i , alrededor de un tercio de los árboles **no la vieron**.

- **Predicción OOB de i :** promediar (o votar) usando solo esos árboles.
- **Error OOB:** el error de esas predicciones sobre todo el entrenamiento, sin apartar datos ni correr CV. Con B grande equivale, en esencia, a LOOCV.
- **Usos:** ver cuándo el error se aplana al crecer B ; afinar m sin CV.

La letra pequeña

- El OOB evalúa **el bosque, no el pipeline**: si la imputación o la codificación aprendieron con todo el entrenamiento, el OOB hereda la filtración (regla de oro #3).
- Es un remuestreo **aleatorio**: con tiempo, espacio o grupos miente igual que el k -fold aleatorio de la sesión 4.
- No reemplaza la prueba. El número que se reporta sigue siendo el de la prueba, una vez.

Importancia nativa: el primer vistazo dentro de la caja

[La sesión 7 la abre del todo](#)

El bosque pierde la legibilidad del árbol; el sustituto estándar es la **importancia de variables**:

- 1 **Por impureza:** sumar, sobre todos los cortes de todos los árboles, la reducción de RSS o Gini que aportó cada variable.
- 2 **Por permutación:** barajar la variable j en las observaciones OOB y medir cuánto empeora la predicción.

Importancia nativa: el primer vistazo dentro de la caja

La sesión 7 la abre del todo

El bosque pierde la legibilidad del árbol; el sustituto estándar es la **importancia de variables**:

- 1 **Por impureza:** sumar, sobre todos los cortes de todos los árboles, la reducción de RSS o Gini que aportó cada variable.
- 2 **Por permutación:** barajar la variable j en las observaciones OOB y medir cuánto empeora la predicción.

Tres trampas, en titulares:

- La de impureza favorece a las variables continuas o con muchas categorías: más umbrales donde lucirse (Strobl et al., 2007).
- Con predictores **correlacionados** el crédito se **reparte** entre gemelas: una variable crucial puede lucir mediocre.
- Importancia predictiva $\neq$ efecto: el proxy de la sesión 5, elevado al cuadrado.

Importancia nativa: el primer vistazo dentro de la caja

La sesión 7 la abre del todo

El bosque pierde la legibilidad del árbol; el sustituto estándar es la **importancia de variables**:

- 1 **Por impureza**: sumar, sobre todos los cortes de todos los árboles, la reducción de RSS o Gini que aportó cada variable.
- 2 **Por permutación**: barajar la variable j en las observaciones OOB y medir cuánto empeora la predicción.


Tres trampas, en titulares:

- La de impureza favorece a las variables continuas o con muchas categorías: más umbrales donde lucirse (Strobl et al., 2007).
- Con predictores **correlacionados** el crédito se **reparte** entre gemelas: una variable crucial puede lucir mediocre.
- Importancia predictiva $\neq$ efecto: el proxy de la sesión 5, elevado al cuadrado.


Uso correcto hoy

Ordenar variables por utilidad predictiva *dado el resto* y decidir qué mirar primero. Sesgos, estabilidad, dependencia parcial y SHAP: la próxima sesión.

Lo que un bosque no hace




Lo que un bosque no hace




- **No extrapola:** predice promedios de hojas, así que fuera del rango observado devuelve una constante. Fatal para tendencias (series con crecimiento) y para el apartamento más grande que el más grande del entrenamiento (sesión 2).

Lo que un bosque no hace



- **No extrapola:** predice promedios de hojas, así que fuera del rango observado devuelve una constante. Fatal para tendencias (series con crecimiento) y para el apartamento más grande que el más grande del entrenamiento (sesión 2).
- **Comprime hacia la media:** promediar hojas acerca las predicciones a niveles intermedios. En Gelvez et al. (2026, Fig. 3) las mesas de apoyo bajo se sobrepredicen y las de apoyo alto se subpredicen.

Lo que un bosque no hace



- **No extrapola:** predice promedios de hojas, así que fuera del rango observado devuelve una constante. Fatal para tendencias (series con crecimiento) y para el apartamento más grande que el más grande del entrenamiento (sesión 2).
- **Comprime hacia la media:** promediar hojas acerca las predicciones a niveles intermedios. En Gelvez et al. (2026, Fig. 3) las mesas de apoyo bajo se sobrepredicen y las de apoyo alto se subpredicen.
- **Señales suaves y lineales:** un modelo lineal regularizado puede ganarle con menos datos (sesión 5). Y cuesta memoria: B árboles grandes con n grande.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar y comparar
- 5 Aplicación guiada: ¿cuánto votó el ganador en la mesa?
- 6 Interpretación y cierre

Boosting: la filosofía opuesta

	<i>Random forest</i>	<i>Boosting</i>
Árboles	grandes, sin podar	pequeños (<i>weak learners</i>)
Entrenamiento	en paralelo, independientes	en secuencia , corrigiendo al anterior
Agregación	promedio	suma con paso pequeño
Ataca	la varianza	el sesgo (parte rígido)

Boosting: la filosofía opuesta

	<i>Random forest</i>	<i>Boosting</i>
Árboles	grandes, sin podar	pequeños (<i>weak learners</i>)
Entrenamiento	en paralelo, independientes	en secuencia , corrigiendo al anterior
Agregación	promedio	suma con paso pequeño
Ataca	la varianza	el sesgo (parte rígido)

La forma del modelo final:

$$\hat{f}(x) = \sum_{b=1}^B \nu \hat{f}^b(x),$$

una suma de B árboles pequeños (a menudo de uno a tres cortes), cada uno multiplicado por una **tasa de aprendizaje** ν (ISL la llama λ ; aquí λ ya está ocupada).

Boosting: la filosofía opuesta

	<i>Random forest</i>	<i>Boosting</i>
Árboles	grandes, sin podar	pequeños (<i>weak learners</i>)
Entrenamiento	en paralelo, independientes	en secuencia , corrigiendo al anterior
Agregación	promedio	suma con paso pequeño
Ataca	la varianza	el sesgo (parte rígido)

La forma del modelo final:

$$\hat{f}(x) = \sum_{b=1}^B \nu \hat{f}^b(x),$$


una suma de B árboles pequeños (a menudo de uno a tres cortes), cada uno multiplicado por una **tasa de aprendizaje** ν (ISL la llama λ ; aquí λ ya está ocupada).

- Cada árbol aporta un ajuste *modesto* donde el ensamble acumulado todavía se equivoca.
- El lema: **aprender despacio**. Muchos pasos chicos generalizan mejor que pocos pasos grandes.

El algoritmo: ajustar árboles a los residuos

ISL, algoritmo 8.2, con pérdida cuadrática


- 1 Inicializar $\hat{f}(x) = 0$ y residuos $r_i = y_i$.
- 2 Para $b = 1, \dots, B$: ajustar un árbol pequeño $\hat{f}^b$ con d cortes a (x_i, r_i) ; actualizar $\hat{f}(x) \leftarrow \hat{f}(x) + \nu \hat{f}^b(x)$ y $r_i \leftarrow r_i - \nu \hat{f}^b(x_i)$.
- 3 Devolver $\hat{f}(x) = \sum_b \nu \hat{f}^b(x)$.



El algoritmo: ajustar árboles a los residuos

ISL, algoritmo 8.2, con pérdida cuadrática


- 1 Inicializar $\hat{f}(x) = 0$ y residuos $r_i = y_i$.
- 2 Para $b = 1, \dots, B$: ajustar un árbol pequeño $\hat{f}^b$ con d cortes a (x_i, r_i) ; actualizar $\hat{f}(x) \leftarrow \hat{f}(x) + \nu \hat{f}^b(x)$ y $r_i \leftarrow r_i - \nu \hat{f}^b(x_i)$.
- 3 Devolver $\hat{f}(x) = \sum_b \nu \hat{f}^b(x)$.



- Cada árbol ve **lo que falta por explicar**, no los datos originales.
- ¿Por qué se llama *gradient* boosting? Porque el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción. Con otra pérdida se ajusta el árbol a su gradiente (apéndice A2): con la logística, a $y_i - \hat{p}_i$, el residuo de la sesión 3. Un solo algoritmo para regresión, clasificación y cuantiles.

Las tres perillas, y la que decide: cuándo parar

error de prueba




bosque: B satura B




boosting: B sobreajusta B

Las tres perillas, y la que decide: cuándo parar




- 1 B , **número de árboles**. Aquí B grande **sí sobreajusta**: el ensamble sigue ajustando residuos hasta memorizar el ruido. Se elige por CV o por *early stopping*: parar cuando el error de validación deja de bajar. La curva U, en vivo.

Las tres perillas, y la que decide: cuándo parar



- 1 **B , número de árboles.** Aquí B grande **sí sobreajusta**: el ensamble sigue ajustando residuos hasta memorizar el ruido. Se elige por CV o por *early stopping*: parar cuando el error de validación deja de bajar. La curva U, en vivo.
- 2 **ν , tasa de aprendizaje** (0,01 a 0,1). Más pequeña, mejor generalización, a cambio de más árboles: bajar ν diez veces pide unas diez veces más B .

Las tres perillas, y la que decide: cuándo parar



- 1 **B , número de árboles.** Aquí B grande **sí sobreajusta**: el ensamble sigue ajustando residuos hasta memorizar el ruido. Se elige por CV o por *early stopping*: parar cuando el error de validación deja de bajar. La curva U, en vivo.
- 2 **ν , tasa de aprendizaje** (0,01 a 0,1). Más pequeña, mejor generalización, a cambio de más árboles: bajar ν diez veces pide unas diez veces más B .
- 3 **d , cortes por árbol: el orden de interacción.** $d = 1$ (*stumps*) es aditivo; $d = 2$ permite pares; rara vez conviene $d > 6$.

XGBoost, LightGBM y BART, en la práctica

XGBoost (Chen & Guestrin, 2016): *gradient boosting* + ingeniería + una idea estadística: cada árbol se elige minimizando

$$\sum_i L(y_i, \hat{f}(x_i)) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

con T hojas de valores w_j : **poda y Ridge dentro del boosting** (apéndice A3).
Además: submuestreo de filas y columnas, faltantes nativos, histogramas para n grande.

XGBoost, LightGBM y BART, en la práctica

XGBoost (Chen & Guestrin, 2016): *gradient boosting* + ingeniería + una idea estadística: cada árbol se elige minimizando

$$\sum_i L(y_i, \hat{f}(x_i)) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

con T hojas de valores w_j : **poda y Ridge dentro del boosting** (apéndice A3). Además: submuestreo de filas y columnas, faltantes nativos, histogramas para n grande.

- **LightGBM**: crecimiento por hoja e histogramas agresivos; más veloz con millones de filas. **CatBoost**: categóricas de alta cardinalidad sin *dummies*.
- **BART** (ISL 8.2.4): suma de árboles con *priors* que los mantienen pequeños, muestreada por MCMC; casi sin afinar y con **intervalos posteriores** gratis (R: `dbarts`). Vuelve en la sesión 9 como pariente de los *causal forests*.

XGBoost, LightGBM y BART, en la práctica

XGBoost (Chen & Guestrin, 2016): *gradient boosting* + ingeniería + una idea estadística: cada árbol se elige minimizando

$$\sum_i L(y_i, \hat{f}(x_i)) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

con T hojas de valores w_j : **poda y Ridge dentro del boosting** (apéndice A3). Además: submuestreo de filas y columnas, faltantes nativos, histogramas para n grande.

- **LightGBM**: crecimiento por hoja e histogramas agresivos; más veloz con millones de filas. **CatBoost**: categóricas de alta cardinalidad sin *dummies*.
- **BART** (ISL 8.2.4): suma de árboles con *priors* que los mantienen pequeños, muestreada por MCMC; casi sin afinar y con **intervalos posteriores** gratis (R: `dbarts`). Vuelve en la sesión 9 como pariente de los *causal forests*.

La disciplina del *boosting*

El método más poderoso de la sesión y el más fácil de arruinar: exige la validación de la sesión 4. El bosque perdona; el *boosting* no.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 **Afinar y comparar**
- 5 Aplicación guiada: ¿cuánto votó el ganador en la mesa?
- 6 Interpretación y cierre

Los hiperparámetros, en una tabla

Método	Perilla	Qué controla	Rango típico	Se elige por
Árbol	α (cp)	tamaño tras la poda	10^{-4} a 10^{-1}	curva de CV
	profundidad, hoja mín.	cuánto crece T_0	5 a 30; 5 a 20	fijo o CV
Bosque	B (trees)	saturación	500 a 1.000	OOB que se aplanan
	m (mtry)	descorrelación	$\sqrt{p}$, $p/3$, fracción	OOB o CV
	hoja mín. (min_n)	tamaño de cada árbol	1 a 20	CV
Boosting	B (trees)	cuándo parar	100 a 5.000	<i>early stopping</i>
	ν (learn_rate)	tamaño del paso	0,01 a 0,1	CV, atado a B
	d (tree_depth)	orden de interacción	1 a 6	CV
	submuestreo	varianza, velocidad	0,5 a 1	CV
	λ, γ	Ridge y poda internas	0 a 10	CV o <i>defaults</i>

Los hiperparámetros, en una tabla

Método	Perilla	Qué controla	Rango típico	Se elige por
Árbol	α (cp)	tamaño tras la poda	10^{-4} a 10^{-1}	curva de CV
	profundidad, hoja mín.	cuánto crece T_0	5 a 30; 5 a 20	fijo o CV
Bosque	B (trees)	saturación	500 a 1.000	OOB que se aplana
	m (mtry)	descorrelación	$\sqrt{p}$, $p/3$, fracción	OOB o CV
	hoja mín. (min_n)	tamaño de cada árbol	1 a 20	CV
Boosting	B (trees)	cuándo parar	100 a 5.000	<i>early stopping</i>
	ν (learn_rate)	tamaño del paso	0,01 a 0,1	CV, atado a B
	d (tree_depth)	orden de interacción	1 a 6	CV
	submuestreo	varianza, velocidad	0,5 a 1	CV
	λ , γ	Ridge y poda internas	0 a 10	CV o <i>defaults</i>

Cómo se ve en un paper: Gelvez et al. (2026)

Cien configuraciones por búsqueda bayesiana con CV de 5 pliegues sobre cinco perillas del bosque: árboles 150 a 500, profundidad 3 a 12, mínimo para partir 5 a 30, mínimo por hoja 3 a 15 y fracción de predictores por corte 0,30 a 0,70. Se maximiza el F1 medio (ganador local) o se minimiza el RMSE medio (participación); la imputación va *dentro* del *pipeline*.

Cara a cara, y la regla práctica

	<i>Random forest</i>	<i>Boosting</i> (XGBoost)
Estrategia	bajar varianza promediando	bajar sesgo sumando en secuencia
B grande	inofensivo (satura)	sobreajusta (<i>early stopping</i>)
Afinado	mínimo (m)	delicado (ν , d , B , submuestreo)
Error sin CV	OOB gratis	no: validación aparte
Paralelización	trivial	parcial (dentro de cada árbol)
Desempeño típico	excelente, robusto	el mejor , si se afina bien

Cara a cara, y la regla práctica

	<i>Random forest</i>	<i>Boosting</i> (XGBoost)
Estrategia	bajar varianza promediando	bajar sesgo sumando en secuencia
B grande	inofensivo (satura)	sobreajusta (<i>early stopping</i>)
Afinado	mínimo (m)	delicado (ν , d , B , submuestreo)
Error sin CV	OOB gratis	no: validación aparte
Paralelización	trivial	parcial (dentro de cada árbol)
Desempeño típico	excelente, robusto	el mejor , si se afina bien

La regla práctica para sus proyectos:

- 1 Empezar con una **regresión regularizada** (sesión 5): la línea base legible.
- 2 **Random forest** con los defaults: el salto no lineal con mínimo esfuerzo; su OOB dice si la flexibilidad valió la pena.
- 3 **XGBoost** afinado con CV cuando el objetivo es exprimir la última gota.
- 4 Y reportar los tres en la misma tabla, evaluados en el **mismo** conjunto de prueba, con intervalos.

¿Cuándo ganan los árboles?

- **Datos tabulares de tamaño mediano.** Grinsztajn, Oyallon & Varoquaux (2022) comparan ensambles de árboles y redes en 45 conjuntos tabulares: ganan los árboles. Razones: aproximan bien funciones irregulares, ignoran las variables irrelevantes y no dependen de la escala.

¿Cuándo ganan los árboles?

- **Datos tabulares de tamaño mediano.** Grinsztajn, Oyallon & Varoquaux (2022) comparan ensambles de árboles y redes en 45 conjuntos tabulares: ganan los árboles. Razones: aproximan bien funciones irregulares, ignoran las variables irrelevantes y no dependen de la escala.
- **En economía.** Medeiros et al. (2021): el bosque domina el pronóstico de inflación en EE. UU. con más de cien predictores. Gu, Kelly & Xiu (2020): árboles y redes ganan en retornos, y la ganancia viene de las *interacciones*. Gelvez et al. (2026): el bosque añade 0,01 a 0,04 de AUC y 7 a 16 pp de R^2 sobre los modelos lineales.

¿Cuándo ganan los árboles?

- **Datos tabulares de tamaño mediano.** Grinsztajn, Oyallon & Varoquaux (2022) comparan ensambles de árboles y redes en 45 conjuntos tabulares: ganan los árboles. Razones: aproximan bien funciones irregulares, ignoran las variables irrelevantes y no dependen de la escala.
- **En economía.** Medeiros et al. (2021): el bosque domina el pronóstico de inflación en EE. UU. con más de cien predictores. Gu, Kelly & Xiu (2020): árboles y redes ganan en retornos, y la ganancia viene de las *interacciones*. Gelvez et al. (2026): el bosque añade 0,01 a 0,04 de AUC y 7 a 16 pp de R^2 sobre los modelos lineales.
- **Cuándo no.** Señal lineal o suave con pocos datos (la sesión 5 gana); hay que extrapolar (series con tendencia, rangos nuevos); imágenes, texto y secuencias, donde la estructura está en la *representación* (sesión 8).

¿Cuándo ganan los árboles?

- **Datos tabulares de tamaño mediano.** Grinsztajn, Oyallon & Varoquaux (2022) comparan ensambles de árboles y redes en 45 conjuntos tabulares: ganan los árboles. Razones: aproximan bien funciones irregulares, ignoran las variables irrelevantes y no dependen de la escala.
- **En economía.** Medeiros et al. (2021): el bosque domina el pronóstico de inflación en EE. UU. con más de cien predictores. Gu, Kelly & Xiu (2020): árboles y redes ganan en retornos, y la ganancia viene de las *interacciones*. Gelvez et al. (2026): el bosque añade 0,01 a 0,04 de AUC y 7 a 16 pp de R^2 sobre los modelos lineales.
- **Cuándo no.** Señal lineal o suave con pocos datos (la sesión 5 gana); hay que extrapolar (series con tendencia, rangos nuevos); imágenes, texto y secuencias, donde la estructura está en la *representación* (sesión 8).

La lección de método

“Ganar” es una afirmación sobre una prueba y una métrica. Se demuestra con la tabla, no con la fama del algoritmo.

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar y comparar
- 5 Aplicación guiada: ¿cuánto votó el ganador en la mesa?
- 6 Interpretación y cierre

Datos y preguntas

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006 a 2022). Predictores en cuatro bloques: estrato y educación; infraestructura, urbanidad y escala poblacional; composición etaria y de género; composición étnica. Más indicadores de departamento.

Datos y preguntas

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006 a 2022). Predictores en cuatro bloques: estrato y educación; infraestructura, urbanidad y escala poblacional; composición etaria y de género; composición étnica. Más indicadores de departamento. **Dos resultados, la misma partición:**

- **Participación del ganador** (continua, en puntos porcentuales): la sesión 2 en versión no lineal. Métricas: RMSE, MAE y R^2 de prueba contra un *baseline* de media.
- **Ganador local** (binaria): la sesión 3. Métrica: AUC.

Datos y preguntas

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006 a 2022). Predictores en cuatro bloques: estrato y educación; infraestructura, urbanidad y escala poblacional; composición etaria y de género; composición étnica. Más indicadores de departamento. **Dos resultados, la misma partición:**

- **Participación del ganador** (continua, en puntos porcentuales): la sesión 2 en versión no lineal. Métricas: RMSE, MAE y R^2 de prueba contra un *baseline* de media.
- **Ganador local** (binaria): la sesión 3. Métrica: AUC.

Protocolo (el de la sesión 4 y el del paper): partición 80/20 estratificada por deciles del resultado; búsqueda bayesiana con CV de 5 pliegues dentro del entrenamiento; imputación de medias dentro del *pipeline*; la prueba se usa una vez; intervalos por *bootstrap*.

Datos y preguntas

Datos: el panel de mesas de Gelvez et al. (2026): 94.671 observaciones mesa–vuelta en nueve vueltas presidenciales (2006 a 2022). Predictores en cuatro bloques: estrato y educación; infraestructura, urbanidad y escala poblacional; composición etaria y de género; composición étnica. Más indicadores de departamento. **Dos resultados, la misma partición:**

- **Participación del ganador** (continua, en puntos porcentuales): la sesión 2 en versión no lineal. Métricas: RMSE, MAE y R^2 de prueba contra un *baseline* de media.
- **Ganador local** (binaria): la sesión 3. Métrica: AUC.

Protocolo (el de la sesión 4 y el del paper): partición 80/20 estratificada por deciles del resultado; búsqueda bayesiana con CV de 5 pliegues dentro del entrenamiento; imputación de medias dentro del *pipeline*; la prueba se usa una vez; intervalos por *bootstrap*.

Las preguntas de hoy

¿Cuánto añade un bosque a la recta y a qué precio? ¿Y el *boosting* al bosque?
¿Coinciden OOB, CV y prueba? ¿Dónde falla el modelo?

La tabla: seis modelos, una misma prueba

Participación del ganador, 2022, primera vuelta: mesas de prueba

Modelo	RMSE (pp)	MAE (pp)	R^2 de prueba
<i>Baseline</i> : media del entrenamiento	$\approx 25,3$ (ded.)	en clase	0,000
OLS, todas las características	$\approx 16,4$ (ded.)	en clase	0,578
Lasso (λ por 1-SE)	en clase	en clase	en clase
Árbol podado (α por CV)	en clase	en clase	en clase
<i>Random forest</i> afinado	14,69	10,90	0,662
XGBoost afinado	en clase	en clase	en clase

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y 6, misma partición 80/20. Las marcadas “ded.” se deducen de $R^2 = 1 - \text{MSE}/\text{Var}(y)$ usando la varianza de prueba implícita en la fila del bosque. Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla.

La tabla: seis modelos, una misma prueba

Participación del ganador, 2022, primera vuelta: mesas de prueba

Modelo	RMSE (pp)	MAE (pp)	R^2 de prueba
<i>Baseline</i> : media del entrenamiento	$\approx 25,3$ (ded.)	en clase	0,000
OLS, todas las características	$\approx 16,4$ (ded.)	en clase	0,578
Lasso (λ por 1-SE)	en clase	en clase	en clase
Árbol podado (α por CV)	en clase	en clase	en clase
<i>Random forest</i> afinado	14,69	10,90	0,662
XGBoost afinado	en clase	en clase	en clase

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y 6, misma partición 80/20. Las marcadas “ded.” se deducen de $R^2 = 1 - \text{MSE}/\text{Var}(y)$ usando la varianza de prueba implícita en la fila del bosque. Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla.

- La recta ya recorre 0,58: la geografía del apoyo es legible con una frontera lineal. El bosque añade 0,08 (entre 7 y 16 pp según la elección): eso valen las no linealidades y las interacciones que nadie escribió.

La tabla: seis modelos, una misma prueba

Participación del ganador, 2022, primera vuelta: mesas de prueba

Modelo	RMSE (pp)	MAE (pp)	R^2 de prueba
<i>Baseline</i> : media del entrenamiento	$\approx 25,3$ (ded.)	en clase	0,000
OLS, todas las características	$\approx 16,4$ (ded.)	en clase	0,578
Lasso (λ por 1-SE)	en clase	en clase	en clase
Árbol podado (α por CV)	en clase	en clase	en clase
<i>Random forest</i> afinado	14,69	10,90	0,662
XGBoost afinado	en clase	en clase	en clase

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y 6, misma partición 80/20. Las marcadas “ded.” se deducen de $R^2 = 1 - \text{MSE}/\text{Var}(y)$ usando la varianza de prueba implícita en la fila del bosque. Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla.

- La recta ya recorre 0,58: la geografía del apoyo es legible con una frontera lineal. El bosque añade 0,08 (entre 7 y 16 pp según la elección): eso valen las no linealidades y las interacciones que nadie escribió.
- Un RMSE de 14,7 pp con media de 42,4 es un 35 % de error relativo: el modelo recupera gradientes territoriales, no la cifra de cada mesa.

La tabla: seis modelos, una misma prueba

Participación del ganador, 2022, primera vuelta: mesas de prueba

Modelo	RMSE (pp)	MAE (pp)	R^2 de prueba
<i>Baseline</i> : media del entrenamiento	$\approx 25,3$ (ded.)	en clase	0,000
OLS, todas las características	$\approx 16,4$ (ded.)	en clase	0,578
Lasso (λ por 1-SE)	en clase	en clase	en clase
Árbol podado (α por CV)	en clase	en clase	en clase
<i>Random forest</i> afinado	14,69	10,90	0,662
XGBoost afinado	en clase	en clase	en clase

Cifras publicadas: Gelvez et al. (2026), Tablas 1 y 6, misma partición 80/20. Las marcadas “ded.” se deducen de $R^2 = 1 - \text{MSE}/\text{Var}(y)$ usando la varianza de prueba implícita en la fila del bosque. Las celdas en gris se calculan con el código de la sesión y pueden diferir por la semilla.

- La recta ya recorre 0,58: la geografía del apoyo es legible con una frontera lineal. El bosque añade 0,08 (entre 7 y 16 pp según la elección): eso valen las no linealidades y las interacciones que nadie escribió.
- Un RMSE de 14,7 pp con media de 42,4 es un 35 % de error relativo: el modelo recupera gradientes territoriales, no la cifra de cada mesa.

Y para el ganador local (AUC, misma vuelta): logística 0,909, bosque 0,931 (Tabla 1); árbol y XGBoost, en clase.

OOB, CV y prueba: tres números que deberían parecerse

Un ancla publicada. Gelvez et al. (2026, Tabla 6) reportan, para el bosque de la participación del ganador, el RMSE medio del CV con el que se afinó y el RMSE en la prueba:

Elección	RMSE en CV (afinación)	RMSE en la prueba	Diferencia	OOB
2006	18,00	17,85	−0,15	en clase
2010-II	15,07	14,46	−0,61	en clase
2014-I	16,18	15,77	−0,41	en clase
2018-I	14,81	14,86	+0,05	en clase
2022-I	14,24	14,69	+0,45	en clase

OOB, CV y prueba: tres números que deberían parecerse

Un ancla publicada. Gelvez et al. (2026, Tabla 6) reportan, para el bosque de la participación del ganador, el RMSE medio del CV con el que se afinó y el RMSE en la prueba:

Elección	RMSE en CV (afinación)	RMSE en la prueba	Diferencia	OOB
2006	18,00	17,85	−0,15	en clase
2010-II	15,07	14,46	−0,61	en clase
2014-I	16,18	15,77	−0,41	en clase
2018-I	14,81	14,86	+0,05	en clase
2022-I	14,24	14,69	+0,45	en clase

- Diferencias de medio punto en ambas direcciones: el CV estimó bien lo que la prueba confirmó. Con 5 pliegues el CV usa el 80 % de las mesas; el modelo final, el 100 %.

OOB, CV y prueba: tres números que deberían parecerse

Un ancla publicada. Gelvez et al. (2026, Tabla 6) reportan, para el bosque de la participación del ganador, el RMSE medio del CV con el que se afinó y el RMSE en la prueba:

Elección	RMSE en CV (afinación)	RMSE en la prueba	Diferencia	OOB
2006	18,00	17,85	-0,15	en clase
2010-II	15,07	14,46	-0,61	en clase
2014-I	16,18	15,77	-0,41	en clase
2018-I	14,81	14,86	+0,05	en clase
2022-I	14,24	14,69	+0,45	en clase

- Diferencias de medio punto en ambas direcciones: el CV estimó bien lo que la prueba confirmó. Con 5 pliegues el CV usa el 80 % de las mesas; el modelo final, el 100 %.
- El OOB debería caer cerca del CV. Si queda muy por debajo, algo se filtró (la imputación fuera del *pipeline*) o la estructura espacial infla el remuestreo aleatorio (sesión 4): hoy lo comprobamos también con pliegues por departamento.

OOB, CV y prueba: tres números que deberían parecerse

Un ancla publicada. Gelvez et al. (2026, Tabla 6) reportan, para el bosque de la participación del ganador, el RMSE medio del CV con el que se afinó y el RMSE en la prueba:

Elección	RMSE en CV (afinación)	RMSE en la prueba	Diferencia	OOB
2006	18,00	17,85	-0,15	en clase
2010-II	15,07	14,46	-0,61	en clase
2014-I	16,18	15,77	-0,41	en clase
2018-I	14,81	14,86	+0,05	en clase
2022-I	14,24	14,69	+0,45	en clase

- Diferencias de medio punto en ambas direcciones: el CV estimó bien lo que la prueba confirmó. Con 5 pliegues el CV usa el 80 % de las mesas; el modelo final, el 100 %.
- El OOB debería caer cerca del CV. Si queda muy por debajo, algo se filtró (la imputación fuera del *pipeline*) o la estructura espacial infla el remuestreo aleatorio (sesión 4): hoy lo comprobamos también con pliegues por departamento.
- Se reporta **la prueba**; el CV y el OOB son diagnósticos del proceso.

Tres figuras (y una cuarta, barata)

- 1 **Predicho vs. observado** en la prueba, con la diagonal (la Fig. 3 de Gelvez et al.). Qué buscar: la **compresión hacia niveles intermedios**: mesas de apoyo bajo sobrepredichas, de apoyo alto subpredichas, más en 2006 y 2010; 2022 sigue la diagonal más de cerca. Un panel por modelo: la recta comprime más que el bosque.

Tres figuras (y una cuarta, barata)

- 1 **Predicho vs. observado** en la prueba, con la diagonal (la Fig. 3 de Gelvez et al.). Qué buscar: la **compresión hacia niveles intermedios**: mesas de apoyo bajo sobrepredichas, de apoyo alto subpredichas, más en 2006 y 2010; 2022 sigue la diagonal más de cerca. Un panel por modelo: la recta comprime más que el bosque.
- 2 **Error contra B** : para el bosque, el OOB que se aplanas; para XGBoost, el error de validación que baja y vuelve a subir, con la línea del *early stopping*. Es la figura de las perillas, con datos.

Tres figuras (y una cuarta, barata)

- 1 **Predicho vs. observado** en la prueba, con la diagonal (la Fig. 3 de Gelvez et al.). Qué buscar: la **compresión hacia niveles intermedios**: mesas de apoyo bajo sobrepredichas, de apoyo alto subpredichas, más en 2006 y 2010; 2022 sigue la diagonal más de cerca. Un panel por modelo: la recta comprime más que el bosque.
- 2 **Error contra B** : para el bosque, el OOB que se aplanas; para XGBoost, el error de validación que baja y vuelve a subir, con la línea del *early stopping*. Es la figura de las perillas, con datos.
- 3 **Importancia por permutación** del bosque (OOB), con barras de *bootstrap*. Qué buscar: qué bloques mandan y cuán apretado es el orden. Es el anticipo de la sesión 7, donde le pondremos signo, dependencia parcial y valores SHAP.

Tres figuras (y una cuarta, barata)

- 1 **Predicho vs. observado** en la prueba, con la diagonal (la Fig. 3 de Gelvez et al.). Qué buscar: la **compresión hacia niveles intermedios**: mesas de apoyo bajo sobrepredichas, de apoyo alto subpredichas, más en 2006 y 2010; 2022 sigue la diagonal más de cerca. Un panel por modelo: la recta comprime más que el bosque.
- 2 **Error contra B** : para el bosque, el OOB que se aplanan; para XGBoost, el error de validación que baja y vuelve a subir, con la línea del *early stopping*. Es la figura de las perillas, con datos.
- 3 **Importancia por permutación** del bosque (OOB), con barras de *bootstrap*. Qué buscar: qué bloques mandan y cuán apretado es el orden. Es el anticipo de la sesión 7, donde le pondremos signo, dependencia parcial y valores SHAP.
- 4 **Error por decil de la participación** (sesión 2), por modelo: el árbol y el bosque deberían fallar menos en los extremos que la recta, pero no cero.

Cómo se ve en R (ranger y xgboost dentro de tidymodels)

```
library(tidymodels); set.seed(2026)
share22 <- mesas |> filter(eleccion == 2022, vuelta == 1)
split <- initial_split(share22, prop = 0.8, strata = share)
train <- training(split); test <- testing(split) # bajo llave
rec <- recipe(share ~ ., data = train) |>
  step_impute_mean(all_numeric_predictors()) |>
  step_dummy(all_nominal_predictors()) # sin normalizar
rf <- rand_forest(mtry = tune(), min_n = tune(), trees = 500) |>
  set_engine("ranger", importance = "permutation") |>
  set_mode("regression")
folds <- vfold_cv(train, v = 5, strata = share)
wf_rf <- workflow(rec, rf)
prm <- extract_parameter_set_dials(wf_rf) |> finalize(train)
res <- tune_bayes(wf_rf, folds, param_info = prm, iter = 40,
  initial = 10, metrics = metric_set(rmse))
best <- select_best(res, metric = "rmse")
final <- finalize_workflow(wf_rf, best) |> last_fit(split) # 1 vez
```

- `tune_bayes` es la búsqueda de la sesión 4; `finalize` fija el rango de `mtry`; `collect_metrics(final)` da la prueba. Para XGBoost: `boost_tree()` con `set_engine("xgboost")` y el *early stopping* en el motor.

Presentación estudiantil: el paper de la sesión 5

Quince minutos, tres preguntas

Gu, Kelly & Xiu (2020) o Blumenstock, Cadamuro & On (2015), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa?** Retornos mensuales de acciones a partir de cientos de características; o la riqueza de personas y regiones a partir de metadatos de telefonía.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué familias comparan, cómo parten tiempo o espacio, contra qué *baseline* miden el R^2 fuera de muestra y cómo ponen incertidumbre.
- 3 **¿Qué se encuentra y cómo se interpreta?** De dónde viene la ganancia de los métodos flexibles; qué variables coinciden entre modelos; qué se reconstruye a escala nacional.

Presentación estudiantil: el paper de la sesión 5

Quince minutos, tres preguntas

Gu, Kelly & Xiu (2020) o Blumenstock, Cadamuro & On (2015), a elección de quien presenta.

- 1 **¿Qué se predice y por qué importa?** Retornos mensuales de acciones a partir de cientos de características; o la riqueza de personas y regiones a partir de metadatos de telefonía.
- 2 **¿Con qué datos y método, y cómo se evalúa?** Qué familias comparan, cómo parten tiempo o espacio, contra qué *baseline* miden el R^2 fuera de muestra y cómo ponen incertidumbre.
- 3 **¿Qué se encuentra y cómo se interpreta?** De dónde viene la ganancia de los métodos flexibles; qué variables coinciden entre modelos; qué se reconstruye a escala nacional.

Para el resto de la sala

¿Qué papel juega la regularización de la sesión 5? ¿Contra qué *baseline* se mide el R^2 fuera de muestra? ¿Los árboles ganan, empatan o pierden, y con qué evidencia?

- 1 Un árbol de decisión
- 2 *Bagging y random forest*
- 3 *Boosting*
- 4 Afinar y comparar
- 5 Aplicación guiada: ¿cuánto votó el ganador en la mesa?
- 6 Interpretación y cierre

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre el resultado vive en no linealidades e interacciones que la recta no ve. En Gelvez et al. (2026) son 7 a 16 pp de R^2 ; y la conclusión comparativa (2022 es la elección más predecible) no depende del modelo.

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre el resultado vive en no linealidades e interacciones que la recta no ve. En Gelvez et al. (2026) son 7 a 16 pp de R^2 ; y la conclusión comparativa (2022 es la elección más predecible) no depende del modelo.
- **La importancia ordena, no explica:** dice qué variables usa el modelo *dado el resto*. No es un efecto marginal ni una causa; con proxies correlacionados el orden es frágil.

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre el resultado vive en no linealidades e interacciones que la recta no ve. En Gelvez et al. (2026) son 7 a 16 pp de R^2 ; y la conclusión comparativa (2022 es la elección más predecible) no depende del modelo.
- **La importancia ordena, no explica:** dice qué variables usa el modelo *dado el resto*. No es un efecto marginal ni una causa; con proxies correlacionados el orden es frágil.
- **Las predicciones están comprimidas y no extrapolan:** el RMSE de 15 pp y la Fig. 3 son parte del reporte, no una nota al pie.

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre el resultado vive en no linealidades e interacciones que la recta no ve. En Gelvez et al. (2026) son 7 a 16 pp de R^2 ; y la conclusión comparativa (2022 es la elección más predecible) no depende del modelo.
- **La importancia ordena, no explica:** dice qué variables usa el modelo *dado el resto*. No es un efecto marginal ni una causa; con proxies correlacionados el orden es frágil.
- **Las predicciones están comprimidas y no extrapolan:** el RMSE de 15 pp y la Fig. 3 son parte del reporte, no una nota al pie.
- **OOB, CV y prueba** son tres estimaciones del mismo error con tres usos distintos; solo la prueba se publica.

Qué dice el modelo y qué no dice

- **El premio del bosque es una medida:** cuánta información sobre el resultado vive en no linealidades e interacciones que la recta no ve. En Gelvez et al. (2026) son 7 a 16 pp de R^2 ; y la conclusión comparativa (2022 es la elección más predecible) no depende del modelo.
- **La importancia ordena, no explica:** dice qué variables usa el modelo *dado el resto*. No es un efecto marginal ni una causa; con proxies correlacionados el orden es frágil.
- **Las predicciones están comprimidas y no extrapolan:** el RMSE de 15 pp y la Fig. 3 son parte del reporte, no una nota al pie.
- **OOB, CV y prueba** son tres estimaciones del mismo error con tres usos distintos; solo la prueba se publica.

Y, no β , versión árboles

Un bosque con AUC de 0,93 no dice por qué votan las mesas; dice cuánta información sobre el resultado hay en la estructura del territorio. Abrir la caja (sesión 7) es lo que le da sentido económico; para hablar de efectos hace falta un diseño (sesión 9).

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Árbol solo	hay que <i>mostrar</i> las reglas; exploración	predice mal; inestable
<i>Bagging</i>	pocas variables dominantes	los árboles clones (ρ alto)
<i>Random forest</i>	el primer modelo flexible	no extrapola; comprime; memoria
<i>Boosting</i>	se busca el máximo desempeño tabular	sobreajusta con B ; exige afinado
BART	se quieren intervalos con poco afinado	lento; menos difundido
Lineal regularizado	señal suave o lineal; pocos datos	solo ve lo que se escribe

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Árbol solo	hay que <i>mostrar</i> las reglas; exploración	predice mal; inestable
<i>Bagging</i>	pocas variables dominantes	los árboles clones (ρ alto)
<i>Random forest</i>	el primer modelo flexible	no extrapola; comprime; memoria
<i>Boosting</i>	se busca el máximo desempeño tabular	sobreajusta con B ; exige afinado
BART	se quieren intervalos con poco afinado	lento; menos difundido
Lineal regularizado	señal suave o lineal; pocos datos	solo ve lo que se escribe

Qué leer: ISL cap. 8 (8.1 el árbol; 8.2 los ensambles); Breiman (2001), secciones 1 y 2; Chen & Guestrin (2016) por XGBoost por dentro; Grinsztajn et al. (2022) por la evidencia tabular.

Recap

- 1 **Un árbol** parte el espacio en rectángulos con cortes voraces y predice constantes: encuentra solo no linealidades e interacciones; se poda con α por CV. Legible, flexible, de varianza altísima.
- 2 **Bagging**: promediar árboles sobre remuestras *bootstrap*.
 $\text{Var} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$: B nunca sobreajusta; el piso lo pone ρ .
- 3 **Random forest**: descorrelacionar sorteando m candidatos por corte; OOB como prueba gratis del bosque, no del *pipeline*; importancia nativa con trampas; no extrapola y comprime.
- 4 **Boosting**: árboles pequeños en secuencia sobre residuos, con paso ν ; B por *early stopping*, d como orden de interacción. XGBoost le pone Ridge y poda por dentro; BART, *priors* e intervalos.
- 5 **La tabla**: la recta explica 0,58 y el bosque 0,66 de la participación del ganador en 2022; CV y prueba coinciden en medio punto. Se reporta la prueba, una vez.
- 6 **Cuándo ganan los árboles**: tabular mediano, funciones irregulares, interacciones; no al extrapolar ni cuando la estructura está en la representación.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 8.

Guía: 8.1 es el árbol (figuras 8.1 a 8.5); 8.2 son los ensambles; 8.2.5 es la tabla de hoy en prosa.

- Breiman (2001), *Random Forests*.

Guía: secciones 1 y 2; el resto, para quien quiera las cotas.

Para la presentación estudiantil de la sesión 7: Medeiros et al. (2021), *Forecasting Inflation in a Data-Rich Environment*, JBES, o Bertrand & Kamenica (2023), *Coming Apart?*, AEJ: Applied.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 8.

Guía: 8.1 es el árbol (figuras 8.1 a 8.5); 8.2 son los ensambles; 8.2.5 es la tabla de hoy en prosa.

- Breiman (2001), *Random Forests*.

Guía: secciones 1 y 2; el resto, para quien quiera las cotas.

Para la presentación estudiantil de la sesión 7: Medeiros et al. (2021), *Forecasting Inflation in a Data-Rich Environment*, JBES, o Bertrand & Kamenica (2023), *Coming Apart?*, AEJ: Applied. **Próxima sesión: abrir la caja negra.** Importancia por permutación y sus sesgos, dependencia parcial, ICE y ALE, valores SHAP, jerarquía de bloques y error por subgrupos; reproducimos las figuras 3, 5 y 6 de Gelvez et al. (2026). Lectura previa: Molnar (2025), capítulos de importancia por permutación, PDP y SHAP.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISL, cap. 8.

Guía: 8.1 es el árbol (figuras 8.1 a 8.5); 8.2 son los ensambles; 8.2.5 es la tabla de hoy en prosa.

- Breiman (2001), *Random Forests*.

Guía: secciones 1 y 2; el resto, para quien quiera las cotas.

Para la presentación estudiantil de la sesión 7: Medeiros et al. (2021), *Forecasting Inflation in a Data-Rich Environment*, JBES, o Bertrand & Kamenica (2023), *Coming Apart?*, AEJ: Applied. **Próxima sesión: abrir la caja negra.** Importancia por permutación y sus sesgos, dependencia parcial, ICE y ALE, valores SHAP, jerarquía de bloques y error por subgrupos; reproducimos las figuras 3, 5 y 6 de Gelvez et al. (2026). Lectura previa: Molnar (2025), capítulos de importancia por permutación, PDP y SHAP. **Aplicación de esta semana en R:** árbol, bosque y XGBoost para la participación del ganador y el ganador local; la tabla; OOB contra CV contra prueba; las figuras.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 8. [ISL]
- Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Breiman, L. (1996). Bagging Predictors. *Machine Learning*, 24(2), 123–140.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Friedman, J. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- Medeiros, M., Vasconcelos, G., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment. *Journal of Business & Economic Statistics*, 39(1), 98–119.
- Bertrand, M., & Kamenica, E. (2023). Coming Apart? Cultural Distances in the United States over Time. *AEJ: Applied Economics*, 15(4), 1–45.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073–1076.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Documento de trabajo.

7 Apéndice: para profundizar

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par (los árboles se parecen porque salieron de los mismos datos).

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par (los árboles se parecen porque salieron de los mismos datos). **1. Expandimos la varianza del promedio:**

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[\sum_{b=1}^B \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'}) \right].$$

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par (los árboles se parecen porque salieron de los mismos datos). **1. Expandimos la varianza del promedio:**

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[\sum_{b=1}^B \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'}) \right].$$

2. Sustituimos (B varianzas; $B(B-1)$ covarianzas iguales a $\rho\sigma^2$):

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[B\sigma^2 + B(B-1)\rho\sigma^2 \right].$$

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par (los árboles se parecen porque salieron de los mismos datos). **1. Expandimos la varianza del promedio:**

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[\sum_{b=1}^B \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'}) \right].$$

2. Sustituimos (B varianzas; $B(B-1)$ covarianzas iguales a $\rho\sigma^2$):

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[B\sigma^2 + B(B-1)\rho\sigma^2 \right].$$

3. Reorganizamos:

$$\text{Var}(\bar{Z}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

A1. Promediar bajo correlación

Sean $Z_1, \dots, Z_B$ las predicciones de B árboles en un punto x , con varianza σ^2 y correlación $\rho > 0$ entre cada par (los árboles se parecen porque salieron de los mismos datos). **1. Expandimos la varianza del promedio:**

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[\sum_{b=1}^B \text{Var}(Z_b) + \sum_{b \neq b'} \text{Cov}(Z_b, Z_{b'}) \right].$$

2. Sustituimos (B varianzas; $B(B-1)$ covarianzas iguales a $\rho\sigma^2$):

$$\text{Var}(\bar{Z}) = \frac{1}{B^2} \left[B\sigma^2 + B(B-1)\rho\sigma^2 \right].$$

3. Reorganizamos:

$$\text{Var}(\bar{Z}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

- Con $\rho = 0$ recuperamos σ^2/B ; con $\rho = 1$, promediar no sirve de nada. El sorteo de m candidatos por corte del *random forest* baja ρ a cambio de subir un poco σ^2 (cada árbol es peor); empíricamente, el intercambio favorece bajar ρ (ESL, sec. 15.2).

A2. *Boosting* como descenso de gradiente en el espacio de funciones

Observación de Friedman (2001): el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción:

$$-\frac{\partial}{\partial f(x_i)} \frac{1}{2}(y_i - f(x_i))^2 = y_i - f(x_i) = r_i.$$

Ajustar árboles a los residuos es dar pasos de descenso de gradiente donde el “parámetro” es la función f entera y ν es el tamaño del paso.

A2. *Boosting* como descenso de gradiente en el espacio de funciones

Observación de Friedman (2001): el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción:

$$-\frac{\partial}{\partial f(x_i)} \frac{1}{2}(y_i - f(x_i))^2 = y_i - f(x_i) = r_i.$$

Ajustar árboles a los residuos es dar pasos de descenso de gradiente donde el “parámetro” es la función f entera y ν es el tamaño del paso. **La generalización:** para cualquier pérdida diferenciable L , ajustar cada árbol al **pseudo-residuo**

$$r_{ib} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f=\hat{f}_{b-1}}.$$

A2. *Boosting* como descenso de gradiente en el espacio de funciones

Observación de Friedman (2001): el residuo es el gradiente negativo de la pérdida cuadrática respecto a la predicción:

$$-\frac{\partial}{\partial f(x_i)} \frac{1}{2}(y_i - f(x_i))^2 = y_i - f(x_i) = r_i.$$

Ajustar árboles a los residuos es dar pasos de descenso de gradiente donde el “parámetro” es la función f entera y ν es el tamaño del paso. **La generalización:** para cualquier pérdida diferenciable L , ajustar cada árbol al **pseudo-residuo**

$$r_{ib} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f=\hat{f}_{b-1}}.$$

- Pérdida absoluta: $r_{ib} = \text{sign}(y_i - \hat{f}(x_i))$, robusta a atípicos; pérdida de cuantil: *boosting* para percentiles; pérdida logística: $r_{ib} = y_i - \hat{p}(x_i)$, la sesión 3. AdaBoost es el caso de la pérdida exponencial.
- Un solo algoritmo, cualquier pérdida diferenciable: el mismo motor que entrenará las redes de la sesión 8, allí en el espacio de los pesos.

A3. El objetivo de XGBoost y el peso óptimo de cada hoja

Para el árbol b , con $\hat{f}_{b-1}$ fijo, XGBoost minimiza la aproximación de **segundo orden** de la pérdida más la regularización:

$$\sum_i \left[g_i f^b(x_i) + \frac{1}{2} h_i f^b(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2, \quad g_i = \frac{\partial L}{\partial \hat{f}}, \quad h_i = \frac{\partial^2 L}{\partial \hat{f}^2}.$$

A3. El objetivo de XGBoost y el peso óptimo de cada hoja

Para el árbol b , con $\hat{f}_{b-1}$ fijo, XGBoost minimiza la aproximación de **segundo orden** de la pérdida más la regularización:

$$\sum_i \left[g_i f^b(x_i) + \frac{1}{2} h_i f^b(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2, \quad g_i = \frac{\partial L}{\partial \hat{f}}, \quad h_i = \frac{\partial^2 L}{\partial \hat{f}^2}.$$

1. Fijada la estructura (qué observaciones caen en cada hoja j), con $G_j = \sum_{i \in j} g_i$ y $H_j = \sum_{i \in j} h_i$, el objetivo es una cuadrática separable en los w_j :

$$\sum_j \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T \implies \boxed{w_j^* = -\frac{G_j}{H_j + \lambda}}$$

un paso de **Newton** por hoja, encogido por λ (Ridge).

A3. El objetivo de XGBoost y el peso óptimo de cada hoja

Para el árbol b , con $\hat{f}_{b-1}$ fijo, XGBoost minimiza la aproximación de **segundo orden** de la pérdida más la regularización:

$$\sum_i \left[g_i f^b(x_i) + \frac{1}{2} h_i f^b(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2, \quad g_i = \frac{\partial L}{\partial \hat{f}}, \quad h_i = \frac{\partial^2 L}{\partial \hat{f}^2}.$$

1. Fijada la estructura (qué observaciones caen en cada hoja j), con $G_j = \sum_{i \in j} g_i$ y $H_j = \sum_{i \in j} h_i$, el objetivo es una cuadrática separable en los w_j :

$$\sum_j \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T \implies \boxed{w_j^* = -\frac{G_j}{H_j + \lambda}}$$

un paso de **Newton** por hoja, encogido por λ (Ridge). **2. La ganancia de un corte** que divide una hoja en L y R :

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma.$$

Si es negativa, el corte no se hace: la poda ocurre *mientras* se construye. Con L cuadrática, $h_i = 1$ y todo se reduce a medias de residuos encogidas.