

Big Data y Machine Learning para Economía Aplicada

Week 06: Abrir la caja negra — importancia, dependencia parcial y
SHAP

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 18, 2026

Previously...

- **Los árboles** encuentran solos las no linealidades y las interacciones: la cuenta del corte, hecha a mano en Cali, repetida millones de veces. El **bosque** promedia (baja la varianza) y el **boosting** suma en secuencia (baja el sesgo).
- **El premio fue grande:** con las mismas variables, el bosque bajó el error de 14,7 (Lasso) a 12,9; con el mapa, a 12,1. En clasificación, AUC de 0,951.
- Ganamos capacidad predictiva y **perdimos la lectura:** el líder no tiene coeficientes. La importancia nativa fue un primer vistazo, con tres trampas en titulares.
- Desde la sesión 1: el desempeño fuera de muestra es el *estadístico*; **abrir el modelo es lo que le da sentido económico**. Ninguna de las dos cosas es un efecto causal.

La tabla del líder, al cierre de la semana 5 (2.398 puestos de prueba)

Voto: bosque + coordenadas **12,1** · *boosting* 12,2 · *k*-NN 12,1 · bosque sin mapa 12,9 · Lasso 14,7. **¿Gana?:** bosque **0,951**.

La pregunta de hoy: ¿qué aprendió el líder del territorio, y dónde se equivoca?

Mismo caso, mismos modelos; hoy no entra ningún método nuevo: entramos nosotros a la caja

- **Lo que sabemos:** el ensamble predice el voto de un puesto con un error de 12 puntos y ordena ganadores con AUC de 0,95.
- **Lo que no sabemos:** *por qué*. ¿Qué variables usa? ¿La educación sigue importando cuando el modelo ya sabe dónde queda el puesto? ¿Y a qué puestos les falla?
- **Para quién importa:** el analista quiere saber de qué depende la predictibilidad; la campaña, por qué el modelo da un puesto por seguro; el auditor, si predice por las razones correctas.

Cómo la respondemos

El kit para abrir cualquier caja, aplicado al líder: **importancia** por permutación (y por qué la de impureza engaña), **ablación por bloques**, **dependencia parcial** e ICE, **Shapley** y **SHAP**, y el **error por subgrupos**. Y la lista de lo que la interpretación *no* es. Hoy se entregó el PS1 y se publica el PS2.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

Cuatro razones para interpretar

- 1 **Auditar.** ¿El modelo predice por las razones correctas o por una filtración? ¿Usa una variable sensible, o un proxy de ella? Con los puestos: ¿el modelo “aprendió” composición étnica, o aprendió geografía y la etnia viene en el paquete?
- 2 **Comunicar.** Una campaña no reasigna recursos porque un ensamble “lo dijo”: necesita poder decir *este puesto se da por seguro porque...* Un regulador o un comité, igual.
- 3 **Generar hipótesis.** Lo que el modelo encuentra (un umbral, una interacción, un grupo donde falla) es materia prima para preguntas causales que se responden con otro diseño (Ludwig & Mullainathan, 2024).
- 4 **Saber de qué depende la predictibilidad.** No basta con “AUC de 0,95”: la pregunta del analista es qué características del territorio la sostienen.

Dos escalas

Global: el modelo en promedio (importancias, curvas). **Local:** por qué *esta* predicción para *este* puesto (SHAP). Las dos describen el modelo, no el mundo.

El mapa de herramientas de hoy

La pregunta	La herramienta	Escala	Agnóstica
¿Qué variables usa el modelo?	importancia por permutación; SHAP medio	global	sí
¿Y por impureza?	importancia nativa de los árboles	global	no
¿Cómo depende $\hat{f}$ de x_j ?	dependencia parcial (PDP), ICE, ALE	global	sí
¿Por qué esta predicción?	SHAP local (cascada)	local	sí
¿Qué bloque de información aporta?	ablación por bloques	global	sí
¿Dónde falla y para quién?	error por subgrupos, calibración por grupo	global	sí

- **Agnóstica** significa que sólo necesita evaluar $\hat{f}$ en puntos nuevos: sirve para el bosque, para XGBoost, para la red de la sesión 7 y para la logística.
- Todas responden preguntas sobre **el modelo ajustado**. La diferencia entre “el modelo usa la etnia” y “la etnia causa el voto” es la sesión entera.

El modelo de la sesión: el líder de la semana 5

El objeto: $\hat{f}$, un modelo flexible ya afinado. Hoy, el *boosting* de la semana 5 (mismas columnas que el bosque, prueba 12,2): para los valores de Shapley el cálculo exacto en árboles (TreeSHAP) lo trae xgboost. El bosque acompaña con sus dos importancias nativas.

Sus insumos, en bloques (los usaremos toda la sesión): **geografía** (longitud, latitud, departamento), **educación, edad y género, etnia, servicios, estrato y escala** (población, viviendas, registrados, ruralidad, distancias).

Tres cantidades de toda la sesión: $\hat{f}(x)$, la predicción de un puesto; $\mathbb{E}[\hat{f}(X)]$, la predicción promedio (la “base” de las explicaciones locales: 52,5); y $L(y, \hat{f})$ **en datos que el modelo no vio**: interpretar un modelo sobre los datos que memorizó es interpretar su memoria.

Notación

x_{-j} son todas las variables menos la j ; $\hat{f}(x_j, x_{-j})$ es el modelo evaluado con x_j fijada y el resto en sus valores observados. Casi todas las herramientas de hoy son alguna forma de “mover x_j y ver qué hace $\hat{f}$ ”.

- 1 Para qué abrir la caja
- 2 **Importancia de variables**
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

Importancia por impureza: barata y sesgada

Definición (Breiman et al., 1984): para cada variable j , sumar la reducción de RSS (o de Gini) que produjeron todos los cortes sobre x_j , en todos los árboles. Se calcula *durante* el entrenamiento; es la que los paquetes devuelven por defecto.

Pregunta para la sala: si le agrego al bosque una columna de ruido puro con muchos valores distintos (los últimos dígitos del identificador del puesto), ¿qué importancia por impureza recibe?

Importancia por impureza: barata y sesgada

Definición (Breiman et al., 1984): para cada variable j , sumar la reducción de RSS (o de Gini) que produjeron todos los cortes sobre x_j , en todos los árboles. Se calcula *durante* el entrenamiento; es la que los paquetes devuelven por defecto.

Pregunta para la sala: si le agrego al bosque una columna de ruido puro con muchos valores distintos (los últimos dígitos del identificador del puesto), ¿qué importancia por impureza recibe? Positiva, y a veces alta. Una variable continua ofrece cientos de umbrales donde cortar; aunque sea ruido, en algún nodo pequeño “ayuda” a separar el entrenamiento. Es el **sesgo hacia la cardinalidad** (Strobl et al., 2007): una binaria que sí importa puede quedar por debajo.

- **Se mide en el entrenamiento:** refleja lo que el árbol usó para memorizar, no lo que sirve para predecir.
- **Reparto entre correlacionadas:** dos proxies del mismo factor se turnan en los cortes y cada uno luce a medias.


Uso

Un primer ordenamiento gratis. Nunca el que se reporta.

Importancia por permutación: cuánto duele barajar

Breiman (2001); Fisher, Rudin & Dominici (2019)

datos que el modelo no vio



$$VI_j = L(y, \hat{f}(X^{(j)})) - L(y, \hat{f}(X)), \quad X^{(j)} = X \text{ con la columna } j \text{ permutada.}$$

- Barajar rompe la relación de x_j con y y con las demás, sin reentrenar. Si el error no sube, el modelo no la necesitaba. Se repite K veces y se promedia; la dispersión le pone barras. En validación, prueba u OOB, nunca en el entrenamiento.
- **Con el líder, en la prueba:** barajar la **longitud** sube el error de 12,2 a **21,3**; la latitud, a 17,9; las dos y el departamento a la vez, a **26,7** (peor que la media). Barajar la **educación superior**: 12,4. La población indígena: 13,2. **El modelo respira geografía.**

Las trampas de la importancia (léanlas dos veces)

- ❶ **Permutar fuerza a extrapolar** (Hooker, Mentch & Zhou, 2021). Barajar la longitud dejando el departamento fijo fabrica “puestos del Chocó en la longitud de los Llanos”, que no existen. Remedios: permutar dentro de grupos, reajustar sin la variable (la ablación, ya viene) o permutar **bloques** enteros.
- ❷ **El crédito se reparte.** Dos proxies del mismo factor lucen poco por separado y mucho juntos: la educación barajada sola casi no duele (12,4) *porque* el estrato, los servicios y la geografía cuentan la misma historia.
- ❸ **Depende del modelo.** Dos modelos con el mismo error de prueba pueden apoyarse en variables distintas: el conjunto Rashomon de Fisher, Rudin & Dominici (2019).
- ❹ **Es inestable.** Cien remuestras *bootstrap* y cuántas veces cae cada variable en el top 5: la tabla de estabilidad de la sesión 3, ahora para bosques.

Y la de siempre

Importante $\neq$ causal. La variable más importante del bosque puede no tener efecto alguno: basta con ser el mejor proxy de lo que sí lo tiene.

Ablación por bloques: reentrenar sin cada pedazo del censo

La permutación pregunta por el modelo fijo; la ablación, por un mundo sin ese bloque

Modelo reentrenado	RMSE prueba
Completo	12,2
Sin educación	12,3
Sin edad y género	12,2
Sin etnia	12,3
Sin servicios	12,3
Sin estrato	12,3
Sin escala	12,3
Sin geografía	15,9
Sólo geografía	12,8
Sólo etnia	21,8

- **Quitar cualquier bloque del censo no mueve el error:** cada uno es *redundante dado el resto*. Quitar la geografía cuesta 3,7 puntos; y la geografía sola llega a **12,8**.
- **La lectura correcta:** no es que la educación “no informe” (sola predice: Cali). Es que su información viene *en paquete* con el estrato, los servicios y el lugar.
- **Para la sesión 7:** si las 37 columnas son tan redundantes entre sí, deberían poderse **comprimir** en unas pocas. Ese es el PCA.


Sin orden

“¿Cuánto añade el bloque *entrando de último*?” (esta tabla) y “¿cuánto aporta en promedio, sobre todos los órdenes de entrada?” son preguntas distintas; la segunda es un valor de Shapley sobre el error: la Parte 4.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE**
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

La dependencia parcial y sus curvas individuales

Friedman (2001); Goldstein et al. (2015)




$$\text{PDP: } \hat{f}_j(x_j) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_j, x_{i,-j}) \quad \text{ICE}_i(x_j) = \hat{f}(x_j, x_{i,-j}).$$

- **PDP:** fijar x_j en un valor para *todos* los puestos, dejar el resto como está, promediar las predicciones; repetir sobre una malla. Es una intervención *en el modelo*, no en el mundo.
- **ICE:** la misma curva, una por puesto, sin promediar. El promedio oculta **heterogeneidad**: si la mitad sube y la mitad baja, el PDP sale plano. Curvas que se cruzan son la huella de una **interacción**.

La sorpresa del caso: la estrella de Cali, plana en el país

El PDP de la educación superior, y las ICE que explican por qué




- **El PDP de la educación es plano:** de 52 a 53,5 en toda la malla. La variable que en Cali explicaba el 64% del voto, *dado el resto del modelo*, no mueve la aguja.
- **Las ICE dicen por qué el promedio engaña menos de lo usual aquí:** un puesto de Cali *baja* 4 puntos al subir su educación; uno del Chocó *sube* 2,5. Pendientes opuestas = interacción con la geografía.
- **La edad sí conserva su forma:** el PDP de los mayores de 60–74 cae de 55,8 a 51,8: cuatro puntos con pendiente clara.

La lectura: el modelo no “olvidó” la educación; su información ya vive en la longitud, la latitud y el departamento. Cuando dos insumos cuentan la misma historia, las curvas de uno se aplanan. Es la trampa de la correlación, en vivo: la siguiente diapositiva.

Cuándo el PDP engaña: correlación y extrapolación

Apley & Zhu (2020): efectos locales acumulados (ALE)



- El PDP fija x_1 para todas las observaciones, incluidas aquellas cuyo x_2 es incompatible con ese x_1 : nuestro PDP de la educación le puso 47% de educación superior a puestos rurales del Pacífico, y le pidió al modelo predecir **puestos que no existen**. Es la extrapolación de la sesión 2, escondida dentro de un promedio.
- **ALE** sólo mira *diferencias locales*: dentro de cada franja de x_1 , cuánto cambia $\hat{f}$ al mover x_1 de un borde al otro, para las observaciones que *sí* están ahí; luego acumula (apéndice A4).
- **Regla**: predictores poco correlacionados, PDP con ICE; correlacionados, ALE. Siempre con la distribución de x_j dibujada debajo: la curva no vale donde no hay datos.

Interacciones: lo que el ensamble ganó, visto de frente

- **PDP en dos dimensiones:** fijar (x_j, x_k) en una grilla y promediar. Se dibuja como mapa de calor; si las curvas de nivel no son paralelas, el efecto de x_j depende de x_k . Es la lectura directa de “la educación pesa distinto según dónde”.
- **ICE centradas:** restar a cada curva su valor en el mínimo de x_j ; si se abren en abanico, hay interacción con algo. Es la prueba más barata, y nuestra educación la pasó: Cali baja, el Chocó sube.
- **El estadístico H de Friedman:** la fracción de la varianza de $\hat{f}_{jk}$ que $\hat{f}_j + \hat{f}_k$ no explica. Cero es aditividad; uno, interacción pura.
- **Valores SHAP y sus interacciones** (Parte 4): la versión local, puesto por puesto.

Qué esperar

Si el ensamble le ganó al lineal por 2,5 puntos, esa diferencia *tiene* que aparecer aquí: curvas no lineales, ICE en abanico o H lejos de cero. Si no aparece, revisen la tabla de la sesión 5.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP**
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

El problema de repartir el crédito

Un ejemplo de juguete: tres coautores, un paper

Tres coautores A , B y C producen 22 “puntos” juntos. ¿Cuánto aportó cada uno? Sólo lo sabríamos si conociéramos lo que produce *cada subconjunto*, $v(S)$:

S	$\emptyset$	A	B	C	AB	AC	BC	ABC
$v(S)$	0	10	6	4	18	12	10	22

La idea de Shapley (1953): imaginar que los jugadores entran *en un orden*, apuntar cuánto añade cada uno al entrar y **promediar sobre todos los órdenes**.

Orden	A añade	B añade	C añade
$A B C$	10	8	4
$A C B$	10	10	2
$B A C$	12	6	4
$B C A$	12	6	4
$C A B$	8	10	4
$C B A$	12	6	4
Promedio ϕ	10,67	7,67	3,67

Suman 22: el reparto es **exacto**. A vale más que sus 10 en solitario porque combina bien con B ; C vale menos que sus 4 porque es parcialmente redundante. ¿Les suena? La educación de hoy es C .

El valor de Shapley: la fórmula y por qué es único

$$\phi_j = \sum_{S \subseteq \{1, \dots, p\} \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} \left[v(S \cup \{j\}) - v(S) \right].$$

El peso es la fracción de órdenes en los que j entra justo después del conjunto S .

Es la única regla de reparto que cumple cuatro propiedades razonables (apéndice A1):

- **Eficiencia:** $\sum_j \phi_j = v(\text{todos}) - v(\emptyset)$. Todo el crédito se reparte.
- **Simetría:** dos jugadores intercambiables reciben lo mismo.
- **Jugador nulo:** quien nunca añade nada recibe cero.
- **Aditividad:** el reparto de la suma de dos juegos es la suma de los repartos.

De coautores a variables

Los jugadores son las p variables; el “juego” es una predicción, $v(S)$ = la predicción del modelo usando sólo las variables de S . El reparto explica por qué $\hat{f}(x)$ se aleja del promedio $\mathbb{E}[\hat{f}(X)]$. El costo: 2^p subconjuntos, y hay que definir qué significa “usar sólo S ”.

SHAP: Shapley para modelos de *machine learning*

Lundberg & Lee (2017); Lundberg et al. (2020)

La explicación local es aditiva: para un puesto x ,

$$\hat{f}(x) = \underbrace{\mathbb{E}[\hat{f}(X)]}_{\phi_0, \text{ base}} + \sum_{j=1}^p \phi_j(x),$$


y cada $\phi_j(x)$ es el valor de Shapley de la variable j en el juego “predecir x ”.

Qué es $v(S)$ para un modelo: la predicción esperada cuando sólo se conocen las variables de S . Hay que *rellenar* las ausentes con datos de fondo, y hay dos maneras (apéndice A2):

- **Marginal** (“fiel al modelo”): rellenar con valores de otras observaciones al azar, ignorando la correlación: el PDP en versión local, con su extrapolación.
- **Condicional** (“fiel a los datos”): rellenar con observaciones parecidas en x_S . Respeta la correlación, pero da crédito a variables que el modelo ni usa.

Cómo se calcula: **KernelSHAP** muestrea subconjuntos y ajusta una regresión ponderada (cualquier $\hat{f}$; lento; apéndice A3). **TreeSHAP** es exacto y rápido para árboles, bosques y *boosting*: los 2.398 puestos de la prueba, con 73 columnas, tardan cuatro segundos (predcontrib en xgboost).

De lo local a lo global: las figuras SHAP



- **Importancia global:** $\frac{1}{n} \sum_i |\phi_j(x_i)|$. Ordena como la permutación, pero con una lectura local detrás.
- **Gráfico de dependencia:** $\phi_j(x_i)$ contra x_{ij} , una nube; su forma es la curva de dependencia y su *dispersión vertical* es la interacción con las demás. Coloreado por otra variable, la interacción se ve.

SHAP con nuestros puestos: el reparto del territorio

TreeSHAP sobre el líder, en los 2.398 puestos de prueba

- **La propiedad que lo define, verificada puesto a puesto:** base (52,5) + suma de contribuciones = predicción, exacto.
- **Importancia global** ($|\phi|$ medio; las 33 *dummies* del departamento, sumadas): longitud 9,5, latitud 5,7, departamento 5,0, indígena 2,2, educación técnica 1,8. La jerarquía de la permutación y la ablación, por tercera vía.
- **Un puesto, explicado** (Capitán, Chocó; real 62,2): base 52,5 $\rightarrow$ predicción 75,1. La longitud empuja +25,9; la latitud, -7,2; la población afro, +3,1; la energía, +2,4. “*Vota alto porque está donde está*”, dice el modelo; y se pasó 13 puntos.
- **Dependencia con signo:** la contribución de la población afro crece con su valor, de -1,3 a +1,9 entre quintiles. Pequeña: la geografía ya contó casi toda esa historia.

Cómo reportarlo

Magnitudes sólo dentro de un mismo modelo; entre modelos distintos, **rangos y signos**. Y siempre con la receta escrita: TreeSHAP, en la prueba, con qué columnas.

Qué no es un valor SHAP

- 1 **No es un efecto causal.** Reparte una predicción entre variables *del modelo*. La longitud no “causa” 26 puntos de voto: es la etiqueta que el modelo le pone a todo lo que vive en el occidente del país y no está en el censo.
- 2 **No es único.** Cambia con el relleno, el conjunto de fondo y el modelo: otro ensamble igual de bueno puede repartir distinto (Rashomon otra vez). Reporten con qué se calculó.
- 3 **No es individual cuando la unidad es un agregado.** El puesto no es el votante: la inferencia ecológica (Robinson, 1950).
- 4 **No es un pronóstico.** Explica un modelo *dentro* de la elección de 2022; que el reparto se repita en 2026 es una hipótesis.
- 5 **No sustituye a la tabla de la prueba.** Una explicación bonita de un modelo malo es una historia sobre ruido.

Rudin (2019), en una frase

Explicar una caja negra *después* no la vuelve transparente; cuando la decisión lo exige, comparen con un modelo interpretable por diseño (logística, árbol corto) y midan cuánto se pierde.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién**
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

El error por subgrupos: la interpretación que nadie olvida

Las importancias dicen de qué depende la predicción; esto dice a quién le falla

- **Por zona:** el líder acierta en las cabeceras (RMSE 8,6) y falla en lo rural (14,4), sin sesgo sistemático en ninguna. El error del curso vive en el campo, donde el censo del entorno dice menos.
- **Por nivel de y (la compresión, medida):** donde Petro sacó menos de 20, el modelo predice 19,5 en promedio (real: 12,5); donde sacó más de 80, predice 82,0 (real: 90,1). Los extremos, hacia la media: la firma de promediar hojas.
- **Por territorio:** Guaviare (24,9), Vichada (22,1) y Guainía (20,1) son los departamentos donde el modelo menos sabe; Atlántico (6,6), Cundinamarca (7,5) y Santander (7,6), donde más. Manchas de fallos del mismo signo en el mapa son autocorrelación espacial de los residuos: la validación por bloques de la sesión 3 la castiga.
- **Por modelo:** la recta y el bosque fallan en sitios distintos; donde coinciden, la información no está en los datos.

La regla

Ningún reporte está completo sin al menos un corte del error por subgrupos. Si el error se concentra en un grupo identificable, el promedio miente.

Equidad: cuando el subgrupo es una persona

- **La métrica por grupo.** Falsos positivos, falsos negativos, calibración y precisión *por grupo* (etnia, género, estrato). Un modelo con AUC alta puede tener el doble de falsos negativos en un grupo. Nuestro caso reparte puestos; un modelo que reparte créditos o subsidios reparte vidas.
- **La etiqueta importa más que el algoritmo.** Obermeyer et al. (2019): un modelo de salud usaba el gasto como proxy de la necesidad; los pacientes negros gastan menos a igual enfermedad y quedaban subestimados. Cambiar la etiqueta subía su participación entre los priorizados del 17,7 % al 46,5 %.
- **Quitar la variable sensible no basta.** El código postal, el estrato y el nombre la reconstruyen; la permutación y el SHAP de hoy son la manera de *verlo*: en nuestro modelo, quitar la etnia no cambia nada porque la geografía la reconstruye entera.
- **No se puede tener todo.** Calibración por grupo e igualdad de tasas de error son incompatibles si la prevalencia difiere (Kleinberg, Mullainathan & Raghavan, 2017). Hay que elegir, y decir cuál.

Para sus proyectos

Si la predicción asigna algo a personas, la tabla de métricas por grupo va junto a la tabla de la prueba. Sin excepción.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2**
- 7 Cierre

Aplicación guiada (I): importancias y ablación

El kit completo sobre el líder ([applications/week-06](#); unos 8 minutos: la ablación reentrena nueve veces)

- **Las dos importancias del bosque, lado a lado** ($\text{importance} = T$): permutación e impureza no ordenan igual: la población afro es cuarta por impureza y sale del top 10 por permutación; la edad 75+, al revés.
- **Permutación a mano sobre el boosting**, en la prueba: una función de seis líneas que baraja una columna (o un bloque entero) y mide cuánto sube el RMSE: longitud +9,1; todo el mapa +14,5; educación superior +0,2.
- **Ablación por bloques**: reentrenar sin cada bloque, con sus rondas por CV (la parte lenta). La tabla de hace un rato: el censo, dado el mapa, vale medio punto; el mapa, dado el censo, 3,7.

Lo que hay que ver

Permutación y ablación responden preguntas distintas y aquí *coinciden* en la jerarquía: geografía primero. Cuando no coinciden, la diferencia es información: proxies que se sustituyen al reentrenar.

Aplicación guiada (II): curvas y SHAP

- **PDP a mano** (fijar, predecir, promediar, sobre una muestra de 800): la educación plana, la edad 60–74 con su pendiente. **ICE** de tres puestos concretos: Cali baja, el Chocó sube, Bogotá casi plana: el abanico de la interacción.
- **SHAP con predcontrib**: la matriz de 2.398×73 , el chequeo de eficiencia (base + suma = predicción), el $|\phi|$ medio con las *dummies* del departamento sumadas, y la cascada de Capitán (Chocó): +25,9 de la longitud.
- **La dependencia con signo**: la contribución de la población afro por quintiles, de $-1,3$ a $+1,9$.
- **Dónde falla**: RMSE por zona (8,6 vs. 14,4), la compresión por tramos de y , y el ranking de departamentos (Guaviare 24,9 ... Atlántico 6,6).

La pregunta de la aplicación

¿De qué depende la predicción del líder, con qué forma, y a quién le falla? Y por cada figura, una frase sobre lo que *no* se puede concluir. Es la Parte 2 del Problem Set 2.

El Problem Set 2 se publica hoy

De los árboles al modelo final del curso, con la vivienda de Cali. Entrega: martes 10 de noviembre, 11:59 p. m.

Misma base y mismas reglas del Problem Set 1: los avisos de Cali con su partición fija; el precio de la prueba sigue oculto y se abre una sola vez, para el modelo final del curso.

Parte	Sesión	Pts	Qué hacen
1. Árboles, bosques y <i>boosting</i>	5	20	árbol podado por CV; bosque (<i>mtry</i> , OOB vs. validación); <i>boosting</i> con parada temprana; tabla contra el mejor modelo del PS1
2. Abrir la caja	6	25	permutación vs. lo que conservó el Lasso; PDP e ICE; SHAP global y de dos avisos; ablación por bloques
3. La red contra el bosque	7	10	un perceptrón pequeño, parada temprana, tres semillas: ¿le gana al bosque?
4. Modelo final y lectura	5–7	15	el mejor modelo de los dos problem sets → prueba una vez; una página: qué aprendió el modelo del mercado de vivienda y qué no dice
Ranking del curso		20	por el RMSE de prueba del modelo final; primero 20, último 10
Reproducibilidad		10	00_run.R corre de principio a fin

Las partes 1 y 2 quedan vistas hoy; la 3, el 27 de octubre. **Debrief** del ranking del PS1 en la sesión 7 y del PS2 el 24 de noviembre.

- 1 Para qué abrir la caja
- 2 Importancia de variables
- 3 Dependencia parcial, ICE y ALE
- 4 Valores de Shapley y SHAP
- 5 Dónde falla y para quién
- 6 Aplicación guiada en R y Problem Set 2
- 7 Cierre

Qué dice la caja abierta y qué no dice

- **Dice de qué depende la predictibilidad:** en nuestro caso, del *lugar* antes que de cualquier bloque del censo: permutación, ablación y SHAP coinciden. El censo importa *a través* del lugar: en el territorio, todo viene en paquete.
- **Dice con qué forma:** la educación, plana dado el mapa (y con pendientes opuestas por región); la edad, con su gradiente propio.
- **Dice dónde falla:** en lo rural (14,4 contra 8,6), en los extremos (la compresión) y en la Orinoquía y la Amazonía.
- **Dice cómo se comporta el modelo, no el mundo:** los tres “no” de la sesión: no es causal, no es individual (el puesto no es el votante), no es pronóstico. Y es **frágil**: cambia con el relleno, el fondo, el modelo y la semilla; se reporta con remuestreo y con la receta escrita.

Y, no β , versión caja abierta

El SHAP de la longitud no es β_{lon} . Es la respuesta a “¿cómo usa el modelo esta variable para predecir?”. Para pasar de ahí a “¿qué pasaría si cambiara?” hace falta un diseño de identificación: el curso de Inferencia Causal.

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
Impureza	primer vistazo, gratis	cardinalidad; entrenamiento; nunca reportar
Permutación	ordenar variables en cualquier modelo	extrapola con correlación; inestable; por bloques
PDP + ICE	forma del efecto, predictores poco correlados	el promedio esconde heterogeneidad
ALE	forma del efecto con correlación	menos intuitivo; no local
SHAP	explicación local y global coherente	relleno; costo sin árboles; no causal
Ablación por bloques	preguntas por tipo de información	reentrena; bloques redundantes entre sí
Error por grupo	siempre	que falte

Qué leer: Molnar (2025), capítulos de importancia por permutación, PDP, ALE y SHAP, con código; Lundberg & Lee (2017) por la unificación; Lundberg et al. (2020) por TreeSHAP; Apley & Zhu (2020) por ALE; Rudin (2019) por la objeción.

Recap

- 1 **Interpretar** es auditar, comunicar, generar hipótesis y saber de qué depende la predictibilidad. Global y local. Siempre fuera del entrenamiento.
- 2 **Importancia:** la de impureza es gratis y sesgada; la de permutación mide cuánto duele barajar (la longitud: +9,1) y extrapola con correlación; la **ablación** reentrena sin el bloque (el censo, dado el mapa: medio punto). Importante $\neq$ causal.
- 3 **PDP, ICE y ALE:** mover x_j y ver qué hace $\hat{f}$; el promedio esconde heterogeneidad (Cali baja, el Chocó sube) y la correlación lo distorsiona (la educación, plana).
- 4 **Shapley y SHAP:** el único reparto exacto de una predicción entre variables; TreeSHAP lo hace barato en árboles. Capitán: base 52,5 + 26 de longitud $\rightarrow$ 75. Con la receta escrita.
- 5 **Dónde falla el líder:** en lo rural, en los extremos y donde el censo dice poco. El error por subgrupos va siempre.
- 6 **Lo que no es:** causal, individual, pronóstico.

La tabla del líder no se movió, y la pregunta que abre

Hoy no compitió ningún modelo: aprendimos qué hay dentro del líder

- **El líder sigue siendo el ensamble con coordenadas** (12,1 / 0,951), y ahora sabemos qué hace: aprende *lugar*, y el censo le añade matices. El mejor lineal (14,7) y los vecinos (12,1) quedan como referencias con lecturas distintas.
- **Lo que la caja abierta dejó pendiente:** las 37 columnas del censo son tan redundantes entre sí que quitar cualquier bloque no duele. ¿Cuánta información *distinta* hay realmente en esas 37 columnas? ¿Tres dimensiones? ¿Cinco?

La limitación que nos lleva a la sesión 7

Toda la sesión miramos las variables **una por una** contra el modelo. La próxima semana los datos construyen **sus propios resúmenes**: el PCA comprime la ficha en pocos índices (¿el “estrato social” del entorno?), *k*-medias agrupa los puestos en tipologías de territorio, y una red neuronal aprende la representación y la predicción al mismo tiempo.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, secciones 12.2 (componentes principales) y 12.4.1 (k -medias); secciones 10.1 a 10.3 y 10.6 a 10.7 (redes neuronales).

Guía: la figura 12.1 (las dos primeras componentes) y la 10.4 (la red para dígitos) son las de clase; 10.6 es la sección honesta: cuándo usar *deep learning*.

Problem Set 2: publicado hoy; entrega el martes 10 de noviembre a las 11:59 p. m. La sesión 7 abre con el **debrief del ranking del Problem Set 1**.

Próxima sesión — representar: ¿pueden los datos construir sus propios resúmenes? Sin y : el PCA comprime las 37 columnas del censo en pocos índices y k -medias agrupa los puestos en tipologías de territorio. Con y : una red neuronal aprende las variables intermedias que mejor predicen, y una red preentrenada presta las suyas para leer imágenes. **Aplicación en R:** el índice socioeconómico de los puestos, el mapa de las tipologías y la red contra el bosque.

Referencias esenciales

- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.). <https://christophm.github.io/interpretable-ml-book/>
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in Random Forest Variable Importance Measures. *BMC Bioinformatics*, 8, 25.
- Hooker, G., Mentch, L., & Zhou, S. (2021). Unrestricted Permutation Forces Extrapolation. *Statistics and Computing*, 31, 82.
- Fisher, A., Rudin, C., & Dominici, F. (2019). All Models Are Wrong, but Many Are Useful. *JMLR*, 20(177), 1–81.
- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: ICE. *JCGS*, 24(1), 44–65.
- Apley, D., & Zhu, J. (2020). Visualizing the Effects of Predictor Variables in Black Box Models. *JRSS-B*, 82(4), 1059–1086.
- Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 30.
- Lundberg, S., et al. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2, 56–67.
- Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions. *Nature Machine Intelligence*, 1, 206–215.
- Obermeyer, Z., et al. (2019). Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations. *Science*, 366, 447–453.
- Ludwig, J., & Mullainathan, S. (2024). Machine Learning as a Tool for Hypothesis Generation. *QJE*, 139(2), 751–827.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

8 Apéndice: para profundizar

A1. Por qué el valor de Shapley es único

Un **juego** es una función $v : 2^P \rightarrow \mathbb{R}$ con $v(\emptyset) = 0$ sobre los subconjuntos de $P = \{1, \dots, p\}$. Una **regla de reparto** asigna $\phi_j(v)$ a cada jugador.

1. Los juegos de unanimidad forman una base. Para $T \subseteq P$ no vacío, sea $u_T(S) = \mathbb{I}\{T \subseteq S\}$. Cualquier v se escribe de forma única como $v = \sum_T c_T u_T$: hay $2^p - 1$ juegos y $2^p - 1$ coeficientes.

2. En un juego de unanimidad el reparto está forzado. Los jugadores fuera de T son nulos ($\phi_j = 0$); los de T son simétricos, y por eficiencia se reparten $u_T(P) = 1$: $\phi_j(u_T) = 1/|T|$ para $j \in T$.

3. Aditividad extiende a todo juego: $\phi_j(v) = \sum_{T \ni j} c_T / |T|$. Una sola regla cumple los cuatro axiomas, y desarrollar los c_T da la fórmula de las contribuciones marginales:

$$\phi_j = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)].$$

- **Descomposición de Shapley del R^2** (Shorrocks, 2013; Israeli, 2007): el juego es $v(S) = R^2$ del modelo con los bloques de S . Con cuatro bloques son 16 modelos, cada uno afinado con CV. Es la versión sin orden de la jerarquía de la Parte 2.

A2. Rellenar lo ausente: SHAP marginal y condicional

El juego de una predicción necesita $v(S)$ para cada subconjunto de variables. Dos definiciones:

$$v^{\text{marg}}(S) = \mathbb{E}_{X_{-S}} [\hat{f}(x_S, X_{-S})], \quad v^{\text{cond}}(S) = \mathbb{E}[\hat{f}(x_S, X_{-S}) \mid X_S = x_S].$$

- **Marginal:** muestrea X_{-S} de un conjunto de fondo sin mirar x_S . Fiel al modelo: una variable que $\hat{f}$ no usa recibe exactamente cero. Precio: evalúa $\hat{f}$ en combinaciones imposibles (la extrapolación de la Parte 3).
- **Condicional:** muestrea X_{-S} dado x_S . Fiel a los datos: no extrapola. Precio: una variable que el modelo ignora recibe crédito si está correlacionada con una que sí usa, y estimar la condicional es difícil. Chen, Janizek, Lundberg & Lee (2020) discuten cuándo usar cada una.
- TreeSHAP tiene las dos variantes: la “intervencional”, que es la marginal con un conjunto de fondo, y la “dependiente del camino”, que aproxima la condicional con las frecuencias de los nodos. Reporten cuál usaron.

A3. KernelSHAP: Shapley como regresión ponderada

Lundberg & Lee (2017): el valor de Shapley es la solución de una regresión lineal ponderada. Con $z \in \{0, 1\}^p$ indicando qué variables están “presentes” y $v(z)$ la predicción esperada con sólo esas,

$$\min_{\phi_0, \phi} \sum_z \pi(z) \left[v(z) - \phi_0 - \sum_j \phi_j z_j \right]^2, \quad \pi(z) = \frac{p-1}{\binom{p}{|z|} |z| (p - |z|)},$$

con $|z|$ el número de unos.

- El peso π es enorme para subconjuntos casi vacíos o casi completos y pequeño en el medio; es exactamente el que hace que el mínimo cuadrado coincida con la fórmula de Shapley.
- En la práctica se muestrean unos cientos o miles de z (de 2^p) y se resuelve el mínimo cuadrado: aproximado, agnóstico y lento, porque cada z exige evaluar $\hat{f}$ sobre el conjunto de fondo.
- **TreeSHAP** (Lundberg et al., 2020) evita el muestreo: recorre cada árbol llevando la cuenta de cuántas observaciones pasan por cada rama, y obtiene los ϕ_j exactos en tiempo polinomial en la profundidad. Por eso el SHAP del ensamble sobre los 2.398 puestos de prueba se calcula en segundos.

A4. PDP, gráfico marginal y ALE, en fórmulas

Para un predictor x_j y el resto x_{-j} , tres curvas que responden preguntas distintas:

$$\text{PDP: } f_{\text{PD}}(x_j) = \mathbb{E}_{X_{-j}} [\hat{f}(x_j, X_{-j})] \quad (\text{promedio sobre la marginal de } X_{-j})$$

$$\text{Marginal: } f_{\text{M}}(x_j) = \mathbb{E}[\hat{f}(X) \mid X_j = x_j] \quad (\text{promedio sobre la condicional})$$

$$\text{ALE: } f_{\text{ALE}}(x_j) = \int_{x_{\min}}^{x_j} \mathbb{E} \left[\frac{\partial \hat{f}(X)}{\partial X_j} \mid X_j = z \right] dz - \text{const.}$$

- El PDP extrapola: promedia sobre valores de X_{-j} que no ocurren con ese x_j . El gráfico marginal no extrapola pero *mezcla*: si x_j y x_k van juntas, el efecto de x_k se cuela en la curva de x_j .
- El ALE promedia la **derivada** condicionada a $X_j = z$ (no extrapola) y luego **acumula**; como deriva primero, el efecto de x_k desaparece. En la práctica, diferencias dentro de K franjas de x_j :

$$\hat{f}_{\text{ALE}}(x_j) = \sum_{k=1}^{k(x_j)} \frac{1}{n_k} \sum_{i: x_{ij} \in \text{franja } k} \left[\hat{f}(z_k, x_{i,-j}) - \hat{f}(z_{k-1}, x_{i,-j}) \right],$$

centrado en cero. Con predictores independientes, las tres curvas coinciden.

A5. Permutación condicional, por bloques y la importancia de Rashomon

- **Permutación condicional** (Strobl et al., 2008): permutar x_j sólo *dentro* de grupos definidos por las variables correlacionadas con ella. Mide la importancia de x_j *dado* x_{-j} , como un coeficiente parcial; la incondicional mide la marginal.
- **Permutación por bloques**: permutar juntas las columnas de un bloque (las dos étnicas; los seis grupos de edad). Responde “¿cuánto pierde el modelo sin este tipo de información?” y evita el reparto entre gemelas.
- **Leave-one-covariate-out**: reajustar sin x_j y comparar errores. No extrapola, pero cuesta p ajustes y mide otra cosa: la pérdida cuando *otro* modelo reemplaza a x_j con sus proxies.
- **Model class reliance** (Fisher, Rudin & Dominici, 2019): el rango de importancias de x_j entre todos los modelos casi óptimos (el conjunto Rashomon). Si incluye el cero, ningún dato obliga a usar x_j : “el modelo necesita la etnia” habla de este bosque, no del problema.
- **Regresiones de Shapley** (Joseph, 2020; Bluwstein et al., 2023): regresar y sobre los valores de Shapley de cada variable para ponerles un error estándar. Dicen si la contribución se alinea con el resultado, no si lo causa.