

Big Data y Machine Learning para Economía Aplicada

Week 06: Abrir la caja negra: qué aprendió la máquina

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 25, 2026

Previously...

- **Partir, promediar y corregir:** un árbol parte los puestos en grupos y promedia; un bosque promedia cientos de árboles; el *boosting* suma árboles pequeños que corrigen al anterior.
- **La respuesta de la semana 5:** con los mismos ingredientes del Lasso (la ficha y el departamento), el *boosting* dejó 12,8 contra 14,7. Con árboles de un solo corte, sin cruces, el juez daba 15,5; con seis, 13,2: los cruces que encontró la máquina valen 2,3 puntos.
- **Las dos ligas, juntas:** el promedio del *boosting* y el *k*-NN en el mapa dejó 11,4, el mejor del curso.

Lo que quedó pendiente

El *boosting* predice mejor que todo lo que escribimos, pero no dice qué aprendió: qué variables usa, con qué forma, qué cruces encontró y por qué predice lo que predice en cada puesto.

La pregunta de hoy: ¿qué aprendió la máquina?

Hoy no entra ningún modelo nuevo: entramos nosotros al de la semana 5

- **El modelo:** 738 árboles con 38.330 hojas en total. Nadie lo lee, y predice el voto de un puesto con 12,8 puntos de error.
- **Cuatro preguntas, cuatro herramientas:** ¿qué variables usa? (la importancia); ¿con qué forma? (la dependencia parcial); ¿por qué predice lo que predice en un puesto? (Shapley y SHAP); ¿a quién le falla? (el error por subgrupos).
- **Y una quinta, la más importante:** ¿qué *no* nos dicen estas herramientas?

La idea con la que se van

Cada herramienta de hoy mueve una variable y mira qué hace la predicción. Le pregunta al modelo, no al mundo: dice cómo predice, no qué pasaría si el mundo cambiara.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

El modelo que vamos a abrir

El *boosting* de la semana 5: la ficha de 37 y el departamento, en siete bloques

Bloque	Columnas	Qué dice del entorno del puesto
Educación	3	sin educación, técnica y superior (% de las personas)
Edad y género	7	cinco grupos de edad, mujeres y en edad de votar
Etnia	5	indígena, rom, raizal, palenquera y afro
Servicios	5	acueducto, alcantarillado, energía, gas e internet (% de las viviendas)
Estrato	7	viviendas en cada estrato, del 0 al 6
Escala y ruralidad	10	población, viviendas, manzanas, hogares, distancia, registrados, zona
Departamento	33	una columna de ceros y unos por departamento

- **Tres cantidades, toda la sesión:** $\hat{f}(x)$, la predicción de un puesto; $\mathbb{E}[\hat{f}(X)]$, la predicción promedio o *base* (52,5); y el error **en la prueba**: interpretar un modelo sobre los datos que memorizó es interpretar su memoria.
- **Notación:** x_{-j} son todas las variables menos la j . Casi todo lo de hoy es “mover x_j y ver qué hace $\hat{f}$ ”.

La importancia que trae el modelo: la ganancia

Cuánto bajó el error de entrenamiento en los cortes que usaron cada variable, en los 738 árboles

- **Definición:** cada corte baja la pérdida del entrenamiento; la ganancia de x_j suma esas bajadas en todos los cortes sobre x_j (`xgb.importance`). Es la importancia por impureza del bosque.
- **En nuestro modelo:** el departamento (sus 33 columnas sumadas) se lleva el 29,1 % de la ganancia; la población afro, el 14,5 %; la indígena, el 11,8 %.

Pregunta para la sala

Si le agregamos al modelo una columna de números al azar, ¿cuánta ganancia recibe?

La importancia que trae el modelo: la ganancia

Cuánto bajó el error de entrenamiento en los cortes que usaron cada variable, en los 738 árboles

- **Definición:** cada corte baja la pérdida del entrenamiento; la ganancia de x_j suma esas bajadas en todos los cortes sobre x_j (`xgb.importance`). Es la importancia por impureza del bosque.
- **En nuestro modelo:** el departamento (sus 33 columnas sumadas) se lleva el 29,1 % de la ganancia; la población afro, el 14,5 %; la indígena, el 11,8 %.

Pregunta para la sala


Si le agregamos al modelo una columna de números al azar, ¿cuánta ganancia recibe?

Lo hicimos: reentrenado con una columna de ruido, el ruido queda en el puesto 24 de 39 (0,9 % de la ganancia), por encima de 15 variables reales (la ruralidad queda en el puesto 39). Una variable continua ofrece miles de umbrales, y en algún nodo pequeño el ruido “ayuda” a separar el entrenamiento: es el sesgo hacia la cardinalidad (Strobl et al., 2007). Por permutación, en la prueba, el mismo ruido vale 0,01 puntos.

Importancia por permutación: cuánto duele barajar

Breiman (2001); Fisher, Rudin y Dominici (2019). En la prueba, diez barajadas por variable

$$VI_j = \text{RMSE}(y, \hat{f}(X^{(j)})) - \text{RMSE}(y, \hat{f}(X))$$



- $X^{(j)}$ es la prueba con x_j barajada: se rompe su relación con y , sin reentrenar; si el error no sube, el modelo no la necesitaba. Las líneas negras: una desviación estándar entre las diez barajadas. El departamento se baraja entero, sus 33 columnas a la vez.
- Barajar el departamento sube el error 11,5 puntos; la población afro, 2,2; la indígena, 1,8. La educación superior, la estrella de la semana 2, apenas 0,25. Las dos importancias coinciden arriba y se separan abajo.

Las trampas de la importancia


- ❶ **Permutar fuerza a extrapolar** (Hooker, Mentch y Zhou, 2021). Barajar la población afro dejando fijo el departamento fabrica puestos del Chocó sin población afro, que no existen.
- ❷ **El crédito se reparte.** Dos variables que cuentan la misma historia lucen poco por separado y mucho juntas: se turnan en los cortes y cada una se lleva la mitad.
- ❸ **Depende del modelo.** Dos modelos con el mismo error pueden apoyarse en variables distintas (la parte 4).
- ❹ **Es inestable.** Cambia con la semilla, la remuestra y las barajadas: se reporta con barras.

Y la de siempre

Importante no es causal. La variable más importante puede no tener efecto alguno: basta con que sea el mejor proxy de lo que sí lo tiene.

Permutar contra reentrenar: los bloques

La permutación pregunta por el modelo que tenemos; la ablación, por el mejor modelo sin ese bloque



- **Permutar un bloque del censo** sube el error entre 1,3 y 3,8 puntos: el modelo los usa todos.
- **Reentrenar sin él** cuesta sólo entre 0,3 y 0,4: los otros bloques cuentan la misma historia y lo reemplazan.
- **El departamento** no se reemplaza del todo: permutarlo cuesta 11,4 y quitarlo, 2,9.
- **La información viene en paquete.** ¿Cuántas cosas distintas dicen las 37 columnas? La semana 7 las comprime.


- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

La dependencia parcial y sus curvas individuales

Friedman (2001); Goldstein et al. (2015). La población afro, fijada en cada valor para los 2.398 puestos de prueba

$$\text{PDP: } \hat{f}_j(z) = \frac{1}{n} \sum_{i=1}^n \hat{f}(z, x_{i,-j})$$


$$\text{ICE}_i(z) = \hat{f}(z, x_{i,-j})$$



- **PDP:** fijar $x_j = z$ en todos los puestos, predecir y promediar: de 49,6 con 0 % de población afro a 65,8 con 100 %.
- **ICE:** lo mismo, una curva por puesto. Casi paralelas: la población afro suma lo mismo sobre el nivel de cada puesto.
- **Marcas azules:** los deciles; el 80 % de los puestos tiene menos de 6,2 % de población afro.

La estrella de Cali, en el país


La educación superior: la curva del país y el promedio de las curvas ICE de tres grupos de puestos



- **En el país, casi plana:** el PDP va de 52,4 a 54,4. La variable estrella de la semana 2 casi no mueve la predicción.
- **Pero el promedio esconde pendientes opuestas:** en los 43 puestos de prueba de Cali, subir la educación *baja* la predicción (de 68,8 a 65,2); en los 79 del Chocó, la *sube* (de 82,1 a 86,6). Pendientes que cambian de signo con el lugar son una interacción: el embudo de la semana 3, encontrado sin escribirlo.

Cuando el PDP pregunta por puestos que no existen


Izquierda: la educación superior contra el estrato 1. Derecha: el PDP y el ALE de la educación (Apley y Zhu, 2020)



- **El PDP en 40 %** pone a los 2.398 puestos en 40 % de educación superior, incluidos los 1.208 (el 50 %) con más de la mitad de sus viviendas en estrato 1. Ninguno así pasa de 34,7 %: el modelo predice para puestos que no existen. Es la extrapolación de la semana 2, escondida en un promedio.
- **El ALE** mira sólo diferencias locales: dentro de cada franja de la educación, cuánto cambia $\hat{f}$ entre los bordes para los puestos que sí están ahí, y acumula (apéndice A4). Esta vez coinciden (diferencia máxima: 1,7 puntos); con variables más correlacionadas, el PDP puede inventar una forma.

Los cruces que encontró la máquina

Valores de interacción SHAP en 500 puestos de prueba: el crédito que sólo existe cuando dos variables van juntas



fuerza del cruce: $|\phi_{jk} + \phi_{kj}|$ promedio (puntos de voto)

- El reparto SHAP de un puesto se parte en un efecto propio de cada variable y uno de cada par, ϕ_{jk} : lo que el modelo hace con x_j *porque* vio x_k (Lundberg et al., 2020; apéndice A6).
- **La respuesta a lo pendiente de la semana 5:** los cruces que valían 2,3 puntos son, sobre todo, la etnia en cada departamento. El Lasso de la semana 3 lo había encontrado por otro camino: sus desviaciones por departamento se concentraron en la zona rural, la población indígena y la población afro.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

¿Es el Chocó o es la población afro?

Un puesto de Quibdó, tres jugadores y una regresión por cada coalición

Colegio Pedro Grau Arola (Quibdó; votó 88,8 por Petro). El juego: $v(S)$ es la predicción de una regresión con los bloques de S , menos el promedio (52,5). Los jugadores: la **E**ducación, la **e**Tnia y el **D**epartamento.

S	$\emptyset$	E	T	D	ET	ED	TD	ETD
$v(S)$	0,0	-1,1	31,2	33,0	33,2	34,7	32,2	34,6
Orden de entrada		E añade		T añade		D añade		
E, T, D		-1,1		34,3		1,4		
E, D, T		-1,1		-0,1		35,8		
T, E, D		2,1		31,2		1,4		
T, D, E		2,4		31,2		1,1		
D, E, T		1,7		-0,1		33,0		
D, T, E		2,4		-0,8		33,0		
Promedio, ϕ		1,1		15,9		17,6		

La idea de Shapley (1953): que los jugadores entren en un orden, apuntar cuánto añade cada uno al entrar y promediar sobre todos los órdenes.

Pregunta para la sala: ¿cuánto del voto de este puesto es el Chocó y cuánto la población afro?

¿Es el Chocó o es la población afro?

Un puesto de Quibdó, tres jugadores y una regresión por cada coalición

Colegio Pedro Grau Arola (Quibdó; votó 88,8 por Petro). El juego: $v(S)$ es la predicción de una regresión con los bloques de S , menos el promedio (52,5). Los jugadores: la **E**ducación, la **e**Tnia y el **D**epartamento.

S	$\emptyset$	E	T	D	ET	ED	TD	ETD
$v(S)$	0,0	-1,1	31,2	33,0	33,2	34,7	32,2	34,6
Orden de entrada		E añade		T añade		D añade		
E, T, D		-1,1		34,3		1,4		
E, D, T		-1,1		-0,1		35,8		
T, E, D		2,1		31,2		1,4		
T, D, E		2,4		31,2		1,1		
D, E, T		1,7		-0,1		33,0		
D, T, E		2,4		-0,8		33,0		
Promedio, ϕ		1,1		15,9		17,6		

La idea de Shapley (1953): que los jugadores entren en un orden, apuntar cuánto añade cada uno al entrar y promediar sobre todos los órdenes.

Pregunta para la sala: ¿cuánto del voto de este puesto es el Chocó y cuánto la población afro?

Depende del orden: el que entra primero se lleva casi todo (31,2 o 33,0 puntos) y el segundo, casi nada, porque cuentan la misma historia. Shapley reparte: 15,9 a la etnia, 17,6 al departamento y 1,1 a la educación; suman 34,6, la distancia entre la predicción (87,1) y el promedio.

El valor de Shapley: la fórmula y por qué es único

$$\phi_j = \sum_{S \subseteq \{1, \dots, p\} \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)]$$

El peso es la fracción de los órdenes en los que j entra justo después de los de S : la tabla anterior, escrita en general.

Es la única regla de reparto con cuatro propiedades razonables (apéndice A1):

- **Eficiencia:** $\sum_j \phi_j = v(\text{todos}) - v(\emptyset)$. Todo el crédito se reparte.
- **Simetría:** dos jugadores intercambiables reciben lo mismo.
- **Jugador nulo:** quien nunca añade nada recibe cero.
- **Aditividad:** el reparto de la suma de dos juegos es la suma de los repartos.

De bloques a columnas

Con p columnas hay 2^p coaliciones: con las 70 de nuestro modelo, un número de 22 cifras. Además hay que decidir qué significa “usar sólo las de S ” sin reentrenar 2^p modelos.

SHAP: Shapley para modelos de *machine learning*

Lundberg y Lee (2017); Lundberg et al. (2020)

La explicación local es aditiva: para un puesto x ,



$$\hat{f}(x) = \underbrace{\mathbb{E}[\hat{f}(X)]}_{\phi_0, \text{ la base}} + \sum_{j=1}^p \phi_j(x),$$

y cada $\phi_j(x)$ es el valor de Shapley de la columna j en el juego “predecir x ”.

- **Qué es $v(S)$ para un modelo:** la predicción esperada cuando sólo se conocen las columnas de S ; las ausentes se rellenan con datos de fondo, sin mirar la correlación (*marginal*) o mirándola (*condicional*). Apéndice A2.
- **Cómo se calcula:** KernelSHAP muestrea coaliciones (cualquier modelo; lento; apéndice A3). **TreeSHAP** es exacto y rápido en árboles: los 2.398 puestos de prueba en segundos (`predcontrib = TRUE` en `xgboost`).
- **Verificado puesto a puesto:** base (52,5) + suma de contribuciones = predicción, con un error máximo de 0,0002 puntos (el redondeo de la máquina).

Dos colegios de Cali, 28 puntos de diferencia

El reparto SHAP de cada predicción, de la base a la predicción: las seis columnas que más la mueven




- **Colegio Comfandi:** 41 % de educación superior y 78 % de las viviendas en estratos 4 y 5, que lo bajan. **Colegio Fundación Compartir:** 71 % en estrato 1 y 35 % de población afro.
- **El mismo departamento pesa distinto** (5,5 y 8,2): sin cruces pesaría igual en los dos. Es un cruce, visto en un puesto.

De lo local a lo global: todos los puestos a la vez

El *beeswarm*: una fila por variable, un punto por puesto de prueba; entre paréntesis, el $|\text{SHAP}|$ promedio

cada punto, un puesto de prueba; color: el valor de la variable, **bajo** a **alto** (el departamento, sin orden, en gris)



- **La importancia global** es el promedio del valor absoluto: departamento 10,1, afro 4,0, indígena 3,2. La misma jerarquía que la permutación, con una lectura local detrás.
- **El color da la dirección y la dispersión dentro de una fila es la interacción:** un mismo valor de la variable empuja distinto según el resto del puesto.

Qué no es un valor SHAP

- ❶ **No es un efecto causal.** Reparte una predicción entre las columnas del modelo: la población afro no “causa” sus puntos; es la columna que mejor resume lo que el modelo aprendió del Pacífico.
- ❷ **No es único.** Cambia con el relleno, el fondo y el modelo (la parte 4): hay que reportar con qué se calculó.
- ❸ **No es del votante.** El puesto es un agregado: la inferencia ecológica (Robinson, 1950).
- ❹ **No es un pronóstico.** Explica la elección de 2022; que se repita en 2026 es una hipótesis.
- ❺ **No sustituye a la prueba.** Una explicación bonita de un modelo malo es una historia sobre ruido.


Rudin (2019), en una frase

Explicar una caja negra *después* no la vuelve transparente: cuando la decisión lo exige, comparen con un modelo interpretable por diseño y midan cuánto se pierde.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

El mismo problema, otra explicación

El *boosting* con coordenadas de la semana 5: casi el mismo error, otro reparto




- **Con las coordenadas**, el error baja de 12,8 a 12,1 y el crédito se muda: se llevan lo que era del departamento (de 10,1 a 2,8) y de la población afro (de 4,0 a 1,5).
- **¿Cuál es la verdadera?** Ninguna: dos modelos casi igual de buenos, dos historias del mismo voto: el efecto Rashomon (Breiman, 2001; Fisher, Rudin y Dominici, 2019).
- **El censo, dado el mapa:** sin él, 12,6; con él, 12,1.
- **La regla:** una explicación es de un modelo; pregunten si otro igual de bueno diría lo mismo.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

El error por subgrupos

Las importancias dicen de qué depende la predicción; esto dice a quién le falla

el país: 12,8



- **Por zona:** 9,3 en las cabeceras y 14,9 en lo rural: el error vive en el campo, donde el censo dice menos.
- **Por nivel del voto:** donde Petro sacó menos de 20, el modelo predice 20,1 (real: 12,5); donde sacó más de 80, 80,5 (real: 90,1). Los extremos, hacia la media.
- **Por departamento:** peor en Guaviare (26,9, con 7 puestos), Vichada y Meta; mejor en Atlántico (7,4) y Vaupés.
- **La regla:** sin el error por subgrupos el reporte no está completo; si el error se concentra en un grupo, el promedio miente.

Equidad: cuando el subgrupo es una persona

- **La métrica por grupo.** Falsos positivos, falsos negativos, calibración y precisión *por grupo* (etnia, género, estrato). Un modelo con AUC alta puede tener el doble de falsos negativos en un grupo. Nuestro caso reparte puestos; un modelo que reparte créditos o subsidios reparte vidas.
- **La etiqueta importa más que el algoritmo.** Obermeyer et al. (2019): un modelo de salud usaba el gasto como proxy de la necesidad; los pacientes negros gastan menos a igual enfermedad y quedaban subestimados. Cambiar la etiqueta subía su participación entre los priorizados del 17,7 % al 46,5 %.
- **Quitar la variable sensible no basta.** El código postal, el estrato y el nombre la reconstruyen: en nuestro modelo, quitar el bloque de etnia cuesta 0,3 puntos, porque el departamento y el resto del censo la reconstruyen.
- **No se puede tener todo.** Calibración por grupo e igualdad de tasas de error son incompatibles si la prevalencia difiere (Kleinberg, Mullainathan y Raghavan, 2017). Hay que elegir, y decir cuál.

Para sus proyectos

Si la predicción asigna algo a personas, la tabla de métricas por grupo va junto a la tabla de la prueba.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2**
- 7 Cierre

El Problem Set 2 se publica hoy

De los árboles al modelo final del curso, con la vivienda de Cali. Entrega: martes 10 de noviembre, 11:59 p. m.

Misma base y mismas reglas del Problem Set 1: los avisos de Cali con su partición fija; el precio de la prueba sigue oculto y se abre una sola vez, para el modelo final del curso.

Parte	Sesión	Pts	Qué hacen
1. Árboles, bosques y <i>boosting</i>	5	20	árbol podado por CV; bosque (<i>mtry</i> , OOB vs. validación); <i>boosting</i> con parada temprana; tabla contra el mejor modelo del PS1
2. Abrir la caja	6	25	permutación vs. lo que conservó el Lasso; PDP e ICE; SHAP global y de dos avisos; ablación por bloques
3. La red contra el bosque	7	10	un perceptrón pequeño, parada temprana, tres semillas: ¿le gana al bosque?
4. Modelo final y lectura	5–7	15	el mejor modelo de los dos problem sets → prueba una vez; una página: qué aprendió el modelo del mercado de vivienda y qué no dice
Ranking del curso		20	por el RMSE de prueba del modelo final; primero 20, último 10
Reproducibilidad		10	00_run.R corre de principio a fin

Las partes 1 y 2 quedan vistas hoy; la 3, el 27 de octubre. **Debrief** del ranking del PS1 en la sesión 7 y del PS2 el 24 de noviembre.

- 1 ¿Qué variables usa? La importancia
- 2 ¿Con qué forma? La dependencia parcial
- 3 ¿Por qué este puesto? Shapley y SHAP
- 4 Cuando entra el mapa: la explicación es del modelo
- 5 ¿A quién le falla?
- 6 El Problem Set 2
- 7 Cierre

Qué dice la caja abierta y qué no dice

- **Dice de qué depende la predicción:** del departamento primero y de la etnia después; los bloques del censo importan en paquete: el modelo los usa todos, pero casi ninguno es insustituible.
- **Dice con qué forma:** la población afro empuja hacia arriba; la educación, casi plana en el país y con pendientes opuestas en Cali y el Chocó.
- **Dice qué cruces encontró:** sobre todo la etnia en cada departamento, lo mismo que el Lasso de la semana 3 por otro camino.
- **Dice dónde falla:** en lo rural, en los extremos y en los departamentos donde el censo dice poco.
- **No dice por qué,** ni qué pasaría si algo cambiara, ni nada del votante; y cambia con el modelo: con el mapa, otra historia con casi el mismo error.

Y , no β , con la caja abierta

El SHAP de la población afro no es un β : responde “¿cómo usa el modelo esta variable para predecir?”. Pasar a “¿qué pasaría si cambiara?” exige un diseño de identificación: el curso de Inferencia Causal.

Cuándo usar qué

	Usar cuando	Cuidado con
Ganancia o impureza	un primer vistazo, gratis	la cardinalidad; se mide en el entrenamiento; nunca reportarla sola
Permutación	ordenar variables en cualquier modelo	extrapola con correlación; inestable; barajar bloques enteros
Ablación	preguntar por un tipo de información	reentrena; mide lo insustituible, no lo usado
PDP e ICE	la forma del efecto	el promedio esconde heterogeneidad; extrapola
ALE	la forma, con variables correlacionadas	menos intuitivo; no es local
SHAP	explicación local y global coherente	el relleno; lento sin árboles; no es causal
Interacciones SHAP	qué cruces encontró el modelo	caro: una matriz por puesto
Error por grupo	siempre	que falte

Qué leer: Molnar (2025), con código, por los capítulos de permutación, PDP, ALE y SHAP; Lundberg y Lee (2017) por la unificación; Lundberg et al. (2020) por TreeSHAP; Rudin (2019) por la objeción.

Recap

- 1 **Interpretar** es preguntarle al modelo cómo predice, siempre sobre datos que no vio. Global (el modelo en promedio) y local (un puesto).
- 2 **Importancia:** la ganancia es gratis y sesgada (el ruido quedó de 24 de 39); la permutación mide cuánto duele barajar (el departamento: +11,5); la ablación, lo insustituible (cada bloque del censo, a lo sumo 0,4).
- 3 **Dependencia:** el PDP promedia, las ICE muestran la heterogeneidad (la educación baja en Cali y sube en el Chocó) y el ALE evita los puestos que no existen.
- 4 **Shapley y SHAP:** el único reparto exacto de una predicción; en Quibdó, 15,9 a la etnia y 17,6 al departamento. Las interacciones SHAP dicen qué cruces encontró la máquina: la etnia en cada departamento.
- 5 **La explicación es del modelo:** con el mapa, otra historia. Y el error por subgrupos va siempre: rural 14,9 contra 9,3.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas de esta semana:

- ISL, secciones 12.2 (componentes principales) y 12.4.1 (k -medias); secciones 10.1 a 10.3 y 10.6 a 10.7 (redes neuronales).

Guía: la figura 12.1 (las dos primeras componentes) y la 10.4 (la red para dígitos) son las de clase; 10.6 es la sección honesta: cuándo usar *deep learning*.

Problem Set 2: publicado hoy; entrega el martes 10 de noviembre a las 11:59 p.m. La sesión 7 abre con el **debrief del ranking del Problem Set 1**.

Próxima sesión — representar: hoy vimos que los bloques del censo se reemplazan entre sí. ¿Cuánta información distinta hay en las 37 columnas? Sin y , el PCA las comprime en pocos índices y k -medias agrupa los puestos en tipologías de territorio. Con y , una red neuronal aprende sus propias variables intermedias.

Aplicación en R: los mismos puestos y el mismo modelo de la semana 5: la ganancia, la permutación y la ablación; el PDP, las ICE y el ALE; SHAP con `predcontrib` y sus interacciones; el error por subgrupos.

Referencias esenciales

- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.). <https://christophm.github.io/interpretable-ml-book/>
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*, 16(3), 199–231.
- Fisher, A., Rudin, C., & Dominici, F. (2019). All Models Are Wrong, but Many Are Useful. *JMLR*, 20(177), 1–81.
- Friedman, J. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: ICE. *JCGS*, 24(1), 44–65.
- Apley, D., & Zhu, J. (2020). Visualizing the Effects of Predictor Variables in Black Box Models. *JRSS-B*, 82(4), 1059–1086.
- Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 30.
- Lundberg, S., et al. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2, 56–67.
- Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions. *Nature Machine Intelligence*, 1, 206–215.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

8 Apéndice: para profundizar

A1. Por qué el valor de Shapley es único

Un **juego** es una función $v : 2^P \rightarrow \mathbb{R}$ con $v(\emptyset) = 0$ sobre los subconjuntos de $P = \{1, \dots, p\}$. Una **regla de reparto** asigna $\phi_j(v)$ a cada jugador.

1. Los juegos de unanimidad forman una base. Para $T \subseteq P$ no vacío, sea $u_T(S) = \mathbb{I}\{T \subseteq S\}$. Cualquier v se escribe de forma única como $v = \sum_T c_T u_T$: hay $2^p - 1$ juegos y $2^p - 1$ coeficientes.

2. En un juego de unanimidad el reparto está forzado. Los jugadores fuera de T son nulos ($\phi_j = 0$); los de T son simétricos, y por eficiencia se reparten $u_T(P) = 1$: $\phi_j(u_T) = 1/|T|$ para $j \in T$.

3. La aditividad extiende a todo juego: $\phi_j(v) = \sum_{T \ni j} c_T / |T|$. Una sola regla cumple los cuatro axiomas, y desarrollar los c_T da la fórmula de las contribuciones marginales:

$$\phi_j = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)].$$

La descomposición de Shapley del R^2 (Shorrocks, 2013): el juego es $v(S) = R^2$ del modelo con los bloques de S ; con siete bloques son 2^7 modelos. Es la versión sin orden de la ablación de la parte 1.

A2. Rellenar lo ausente: SHAP marginal y condicional

El juego de una predicción necesita $v(S)$ para cada subconjunto de variables. Dos definiciones:

$$v^{\text{marg}}(S) = \mathbb{E}_{X_{-S}} [\hat{f}(x_S, X_{-S})], \quad v^{\text{cond}}(S) = \mathbb{E}[\hat{f}(x_S, X_{-S}) \mid X_S = x_S].$$

- **Marginal:** muestrea X_{-S} de un conjunto de fondo sin mirar x_S . Fiel al modelo: una variable que $\hat{f}$ no usa recibe exactamente cero. Precio: evalúa $\hat{f}$ en combinaciones imposibles (los puestos que no existen de la parte 2).
- **Condicional:** muestrea X_{-S} dado x_S . Fiel a los datos: no extrapola. Precio: una variable que el modelo ignora recibe crédito si está correlacionada con una que sí usa, y estimar la condicional es difícil (Chen, Janizek, Lundberg y Lee, 2020).
- TreeSHAP tiene las dos variantes: la “intervencional”, que es la marginal con un conjunto de fondo, y la “dependiente del camino”, que aproxima la condicional con las frecuencias de los nodos; `predcontrib` en `xgboost` usa la segunda. Reporten cuál usaron.

A3. KernelSHAP: Shapley como regresión ponderada

Lundberg y Lee (2017): el valor de Shapley es la solución de una regresión lineal ponderada. Con $z \in \{0, 1\}^p$ indicando qué variables están “presentes” y $v(z)$ la predicción esperada con sólo esas,

$$\min_{\phi_0, \phi} \sum_z \pi(z) \left[v(z) - \phi_0 - \sum_j \phi_j z_j \right]^2, \quad \pi(z) = \frac{p-1}{\binom{p}{|z|} |z| (p-|z|)},$$

con $|z|$ el número de unos.

- El peso π es enorme para coaliciones casi vacías o casi completas y pequeño en el medio: es exactamente el que hace que el mínimo cuadrado coincida con la fórmula de Shapley.
- En la práctica se muestrean unos cientos o miles de z (de 2^p) y se resuelve el mínimo cuadrado: aproximado, agnóstico y lento, porque cada z exige evaluar $\hat{f}$ sobre el conjunto de fondo.
- **TreeSHAP** (Lundberg et al., 2020) evita el muestreo: recorre cada árbol llevando la cuenta de cuántas observaciones pasan por cada rama, y obtiene los ϕ_j exactos en tiempo polinomial en la profundidad.

A4. PDP, gráfico marginal y ALE, en fórmulas

Para un predictor x_j y el resto x_{-j} , tres curvas que responden preguntas distintas:

$$\text{PDP: } f_{\text{PD}}(z) = \mathbb{E}_{X_{-j}}[\hat{f}(z, X_{-j})] \quad (\text{promedio sobre la marginal de } X_{-j})$$

$$\text{Marginal: } f_{\text{M}}(z) = \mathbb{E}[\hat{f}(X) \mid X_j = z] \quad (\text{promedio sobre la condicional})$$

$$\text{ALE: } f_{\text{ALE}}(z) = \int_{x_{\min}}^z \mathbb{E}\left[\frac{\partial \hat{f}(X)}{\partial X_j} \mid X_j = u\right] du - \text{const.}$$

- El PDP extrapola: promedia sobre valores de X_{-j} que no ocurren con ese z . El gráfico marginal no extrapola pero *mezcla*: si x_j y x_k van juntas, el efecto de x_k se cuela en la curva de x_j .
- El ALE promedia la **derivada** condicionada a $X_j = u$ (no extrapola) y luego **acumula**; como deriva primero, el efecto de x_k desaparece. En la práctica, con K franjas de x_j de bordes $z_0 < z_1 < \dots < z_K$:

$$\hat{f}_{\text{ALE}}(z) = \sum_{k=1}^{k(z)} \frac{1}{n_k} \sum_{i: x_{ij} \in (z_{k-1}, z_k]} \left[\hat{f}(z_k, x_{i,-j}) - \hat{f}(z_{k-1}, x_{i,-j}) \right],$$

centrado en cero. Con predictores independientes, las tres curvas coinciden.

A5. Permutación condicional, por bloques y la importancia de Rashomon

- **Permutación condicional** (Strobl et al., 2008): permutar x_j sólo *dentro* de grupos definidos por las variables correlacionadas con ella. Mide la importancia de x_j *dado* x_{-j} , como un coeficiente parcial; la incondicional mide la marginal.
- **Permutación por bloques**: permutar juntas las columnas de un bloque (las cinco de etnia; las 33 del departamento). Responde “¿cuánto pierde el modelo sin este tipo de información?” y evita el reparto entre gemelas.
- **Ablación** (*leave-one-covariate-out*): reajustar sin x_j o sin el bloque y comparar errores. No extrapola, pero cuesta un ajuste por bloque y mide otra cosa: la pérdida cuando *otro* modelo reemplaza a x_j con sus proxies.
- **Model class reliance** (Fisher, Rudin y Dominici, 2019): el rango de importancias de x_j entre todos los modelos casi óptimos (el conjunto Rashomon). Si incluye el cero, ningún dato obliga a usar x_j : “el modelo necesita la etnia” habla de este modelo, no del problema.
- **Regresiones de Shapley** (Joseph, 2019): regresar y sobre los valores de Shapley de cada variable para ponerles un error estándar. Dicen si la contribución se alinea con el resultado, no si lo causa.

A6. Los valores de interacción SHAP y el H de Friedman

Interacción SHAP (Lundberg et al., 2020): el valor de Shapley de un par, con la segunda diferencia en vez de la primera,

$$\phi_{jk} = \sum_{S \subseteq P \setminus \{j, k\}} \frac{|S|! (p - |S| - 2)!}{2 (p - 1)!} \nabla_{jk}(S),$$

$$\nabla_{jk}(S) = v(S \cup \{j, k\}) - v(S \cup \{j\}) - v(S \cup \{k\}) + v(S).$$

- $\nabla_{jk}(S) = 0$ si el aporte de j no depende de si está k : sin cruce, no hay crédito compartido.
- El reparto se completa con el efecto propio, $\phi_j = \phi_{jj} + \sum_{k \neq j} \phi_{jk}$. TreeSHAP la calcula exacta (`predinteraction = TRUE`): una matriz de $p \times p$ por puesto, por eso hoy en 500 puestos.
- **El H de Friedman y Popescu (2008)** es la versión global con los PDP:

$$H_{jk}^2 = \frac{\sum_i [\hat{f}_{jk}(x_{ij}, x_{ik}) - \hat{f}_j(x_{ij}) - \hat{f}_k(x_{ik})]^2}{\sum_i \hat{f}_{jk}(x_{ij}, x_{ik})^2},$$

con las curvas centradas: cero es aditividad; uno, interacción pura.

A7. SHAP para gana_petro: la escala de los log-odds

- El *boosting* de clasificación de la semana 5 (ficha y departamento; AUC de prueba 0,941) predice en la escala de los **log-odds**: la base es 0,13 y los valores SHAP se suman ahí,

$$\log \frac{\hat{p}(x)}{1 - \hat{p}(x)} = \phi_0 + \sum_{j=1}^P \phi_j(x), \quad \hat{p}(x) = \frac{1}{1 + e^{-(\phi_0 + \sum_j \phi_j(x))}}.$$

- Lo que más mueve la probabilidad de que gane Petro:** departamento (1,29 en log-odds, en promedio), afro (0,44) y estrato 2 (0,34): la misma jerarquía que en el voto.
- Cuidado al traducir:** el mismo ϕ_j mueve mucho la probabilidad cerca de 0,5 y casi nada cerca de 0 o de 1. Es el efecto $\beta p(1 - p)$ de la logística de la semana 4.

Referencias del apéndice y otras citadas

- Shapley, L. S. (1953). A Value for n -Person Games. En *Contributions to the Theory of Games II*, 307–317.
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in Random Forest Variable Importance Measures. *BMC Bioinformatics*, 8, 25.
- Hooker, G., Mentch, L., & Zhou, S. (2021). Unrestricted Permutation Forces Extrapolation. *Statistics and Computing*, 31, 82.
- Obermeyer, Z., et al. (2019). Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations. *Science*, 366, 447–453.
- Robinson, W. S. (1950). Ecological Correlations and the Behavior of Individuals. *American Sociological Review*, 15(3), 351–357.
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. *ITCS 2017*.
- Strobl, C., Boulesteix, A.-L., Kneib, T., Augustin, T., & Zeileis, A. (2008). Conditional Variable Importance for Random Forests. *BMC Bioinformatics*, 9, 307. [A5]
- Friedman, J., & Popescu, B. (2008). Predictive Learning via Rule Ensembles. *Annals of Applied Statistics*, 2(3), 916–954. [A6]
- Shorrocks, A. F. (2013). Decomposition Procedures for Distributional Analysis: A Unified Framework Based on the Shapley Value. *Journal of Economic Inequality*, 11, 99–126. [A1]
- Chen, H., Janizek, J., Lundberg, S., & Lee, S.-I. (2020). True to the Model or True to the Data? *arXiv:2006.16234*. [A2]
- Joseph, A. (2019). Shapley Regressions: A Framework for Statistical Inference on Machine Learning Models. *Bank of England Staff Working Paper 784*. [A5]