

Big Data y Machine Learning para Economía Aplicada

Week 07: Aprendizaje No Supervisado y Reducción de Dimensión

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 23, 2026

Previously...

- Seis sesiones de aprendizaje **supervisado**: siempre hubo una y que predecir (o un α , $\tau(x)$ que estimar) y un error *out-of-sample* contra el cual rendir cuentas.
- Con DML y *causal forests* cerramos el bloque predicción-causalidad.

Previously...

- Seis sesiones de aprendizaje **supervisado**: siempre hubo una y que predecir (o un α , $\tau(x)$ que estimar) y un error *out-of-sample* contra el cual rendir cuentas.
- Con DML y *causal forests* cerramos el bloque predicción-causalidad.

Hoy: soltamos la y

Solo tenemos los x . Dos familias de preguntas:

- 1 **Clustering**: ¿hay *grupos* naturales? (segmentar consumidores, tipologías de municipios)
- 2 **Reducción de dimensión**: ¿hay *pocas dimensiones* que resuman muchas variables? (índices socioeconómicos, factores latentes)

Previously...

- Seis sesiones de aprendizaje **supervisado**: siempre hubo una y que predecir (o un α , $\tau(x)$ que estimar) y un error *out-of-sample* contra el cual rendir cuentas.
- Con DML y *causal forests* cerramos el bloque predicción-causalidad.

Hoy: soltamos la y

Solo tenemos los x . Dos familias de preguntas:

- 1 **Clustering**: ¿hay *grupos* naturales? (segmentar consumidores, tipologías de municipios)
- 2 **Reducción de dimensión**: ¿hay *pocas dimensiones* que resuman muchas variables? (índices socioeconómicos, factores latentes)

Y una advertencia desde ya: sin y **no hay error de prueba** que arbitre. La validación cambia de naturaleza — y el riesgo de *encontrar* estructura donde no la hay se dispara.

1 El problema no supervisado

2 Clustering: k -means, jerárquico y mezclas

3 PCA: componentes principales

4 Síntesis

Qué cambia cuando no hay y

	Supervisado (S1–S6)	No supervisado (hoy)
Objetivo	predecir y / estimar efectos	describir estructura de los x
Criterio	riesgo $R(f)$, error de prueba	$\hat{L}$? (no hay respuesta correcta)
Validación	CV, conjunto de prueba	estabilidad, interpretación, uso posterior
Peligro	sobreajustar	ver patrones donde no los hay

Qué cambia cuando no hay y

	Supervisado (S1–S6)	No supervisado (hoy)
Objetivo	predecir y / estimar efectos	describir estructura de los x
Criterio	riesgo $R(f)$, error de prueba	¿? (no hay respuesta correcta)
Validación	CV, conjunto de prueba	estabilidad, interpretación, uso posterior
Peligro	sobreajustar	ver patrones donde no los hay

¿Cómo se valida entonces? Tres sustitutos imperfectos del error de prueba:

- 1 **Estabilidad:** ¿los grupos/componentes sobreviven a remuestrear los datos, cambiar semillas, perturbar variables?
- 2 **Interpretabilidad:** ¿la estructura tiene lectura económica coherente?
- 3 **Uso posterior** (*downstream*): si el índice/cluster luego *predice* algo (pobreza, impago), esa tarea supervisada lo audita.

Qué cambia cuando no hay y

	Supervisado (S1–S6)	No supervisado (hoy)
Objetivo	predecir y / estimar efectos	describir estructura de los x
Criterio	riesgo $R(f)$, error de prueba	¿? (no hay respuesta correcta)
Validación	CV, conjunto de prueba	estabilidad, interpretación, uso posterior
Peligro	sobreajustar	ver patrones donde no los hay

¿Cómo se valida entonces? Tres sustitutos imperfectos del error de prueba:

- 1 **Estabilidad:** ¿los grupos/componentes sobreviven a remuestrear los datos, cambiar semillas, perturbar variables?
- 2 **Interpretabilidad:** ¿la estructura tiene lectura económica coherente?
- 3 **Uso posterior** (*downstream*): si el índice/cluster luego *predice* algo (pobreza, impago), esa tarea supervisada lo audita.

Regla de honestidad

Los algoritmos de hoy **siempre** devuelven clusters y componentes — haya o no estructura real. La carga de la prueba es nuestra.

- 1 El problema no supervisado
- 2 Clustering: k -means, jerárquico y mezclas
- 3 PCA: componentes principales
- 4 Síntesis

k -means: el problema de optimización

Objetivo: partir las n observaciones en K grupos $C_1, \dots, C_K$ minimizando la dispersión *dentro* de cada grupo:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2, \quad \mu_k = \text{centroide (media) del grupo } k$$

k -means: el problema de optimización

Objetivo: partir las n observaciones en K grupos $C_1, \dots, C_K$ minimizando la dispersión *dentro* de cada grupo:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2, \quad \mu_k = \text{centroide (media) del grupo } k$$

- Equivalente a minimizar las distancias cuadráticas *intra*-cluster (WSS): grupos compactos y separados.
- El problema exacto es **combinatorio** (NP-duro): hay $\sim K^n$ particiones. Otra vez la salida es una **heurística** inteligente.

k -means: el problema de optimización

Objetivo: partir las n observaciones en K grupos $C_1, \dots, C_K$ minimizando la dispersión *dentro* de cada grupo:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2, \quad \mu_k = \text{centroide (media) del grupo } k$$

- Equivalente a minimizar las distancias cuadráticas *intra*-cluster (WSS): grupos compactos y separados.
- El problema exacto es **combinatorio** (NP-duro): hay $\sim K^n$ particiones. Otra vez la salida es una **heurística** inteligente.

Algoritmo de Lloyd (1957):

- 1 Inicializar K centroides (aleatorios o *k-means++*).
- 2 Repetir hasta converger: (a) **asignar** cada i a su centroide más cercano; (b) **recalcular** cada centroide como la media de sus asignados.

k -means: el problema de optimización

Objetivo: partir las n observaciones en K grupos $C_1, \dots, C_K$ minimizando la dispersión *dentro* de cada grupo:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2, \quad \mu_k = \text{centroide (media) del grupo } k$$


- Equivalente a minimizar las distancias cuadráticas *intra-cluster* (WSS): grupos compactos y separados.
- El problema exacto es **combinatorio** (NP-duro): hay $\sim K^n$ particiones. Otra vez la salida es una **heurística** inteligente.

Algoritmo de Lloyd (1957):

- 1 Inicializar K centroides (aleatorios o *k-means++*).
 - 2 Repetir hasta converger: (a) **asignar** cada i a su centroide más cercano; (b) **recalcular** cada centroide como la media de sus asignados.
- Cada paso baja el objetivo $\Rightarrow$ converge... a un **óptimo local**. En la práctica: correr con 20–50 inicios distintos y quedarse con el mejor.
 - Y como todo lo basado en distancias: **estandarizar primero** (sesión 2, otra


¿Cuántos grupos? El codo y la silueta

K no lo dicen los datos solos: el WSS *siempre* baja con K (con $K = n$, cero).



¿Cuántos grupos? El codo y la silueta


K no lo dicen los datos solos: el WSS *siempre* baja con K (con $K = n$, cero).



- **Codo:** elegir el K donde la ganancia marginal se desploma. (¿Les recuerda el *scree plot* que viene en PCA? No es coincidencia.)
- **Silueta** (Rousseeuw, 1987): comparar la distancia media *intra*-cluster de cada i con la del cluster vecino; el promedio $\in [-1, 1]$ da una nota por K .
- Y el criterio que manda: **el uso** — si solo se pueden gestionar 4 segmentos, $K = 4$. K es una *decisión*, no un parámetro verdadero.


Clustering jerárquico: el árbol de las fusiones

Aglomerativo: empezar con n clusters de una observación; en cada paso, **fusionar los dos más cercanos**; registrar la historia completa.



Clustering jerárquico: el árbol de las fusiones

Aglomerativo: empezar con n clusters de una observación; en cada paso, **fusionar los dos más cercanos**; registrar la historia completa.



- El **dendrograma** muestra *todas* las resoluciones a la vez: cortar a una altura = elegir el número de grupos *después* de ver la estructura.
- ¿“Cercanos” entre grupos? El **linkage**: completo (máx.), promedio, simple (mín. — encadena), Ward (varianza). Completo/promedio/Ward son los sensatos por defecto.
- Costo $O(n^2)$ en distancias: para n muy grande, k -means; para cientos/miles y estructura anidada (municipios, sectores), jerárquico brilla.

Mezclas de gaussianas y EM, en una diapositiva

La versión probabilística del clustering: los datos vienen de una **mezcla** de K normales,

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$$

y pertenecer a un grupo es una **variable latente**.

Mezclas de gaussianas y EM, en una diapositiva

La versión probabilística del clustering: los datos vienen de una **mezcla** de K normales,

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$$

y pertenecer a un grupo es una **variable latente**.

- **Asignaciones suaves:** en vez de “ i está en el grupo 2”, $P(\text{grupo } k \mid x_i)$ — responsabilidades. k -means es el caso límite (varianzas iguales $\rightarrow 0$: asignación dura).

Mezclas de gaussianas y EM, en una diapositiva

La versión probabilística del clustering: los datos vienen de una **mezcla** de K normales,

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$$

y pertenecer a un grupo es una **variable latente**.

- **Asignaciones suaves:** en vez de “ i está en el grupo 2”, $P(\text{grupo } k \mid x_i)$ — responsabilidades. k -means es el caso límite (varianzas iguales $\rightarrow 0$: asignación dura).
- **Algoritmo EM** (esbozo): alternar **E** (calcular responsabilidades dados los parámetros) y **M** (re-estimar π_k, μ_k, Σ_k ponderando por responsabilidades) — la misma coreografía de Lloyd, en versión probabilística; sube la verosimilitud en cada paso, converge a óptimo local.

Mezclas de gaussianas y EM, en una diapositiva

La versión probabilística del clustering: los datos vienen de una **mezcla** de K normales,

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$$

y pertenecer a un grupo es una **variable latente**.

- **Asignaciones suaves:** en vez de “ i está en el grupo 2”, $P(\text{grupo } k \mid x_i)$ — responsabilidades. k -means es el caso límite (varianzas iguales $\rightarrow 0$: asignación dura).
- **Algoritmo EM** (esbozo): alternar **E** (calcular responsabilidades dados los parámetros) y **M** (re-estimar π_k, μ_k, Σ_k ponderando por responsabilidades) — la misma coreografía de Lloyd, en versión probabilística; sube la verosimilitud en cada paso, converge a óptimo local.
- **Qué compra:** clusters elípticos (no solo esféricos), tamaños distintos, incertidumbre de pertenencia — útil cuando la frontera entre segmentos es gris (¿hogar “vulnerable” o “clase media”?).

Mezclas de gaussianas y EM, en una diapositiva

La versión probabilística del clustering: los datos vienen de una **mezcla** de K normales,

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \Sigma_k)$$

y pertenecer a un grupo es una **variable latente**.

- **Asignaciones suaves:** en vez de “ i está en el grupo 2”, $P(\text{grupo } k \mid x_i)$ — responsabilidades. k -means es el caso límite (varianzas iguales $\rightarrow 0$: asignación dura).
- **Algoritmo EM** (esbozo): alternar **E** (calcular responsabilidades dados los parámetros) y **M** (re-estimar π_k, μ_k, Σ_k ponderando por responsabilidades) — la misma coreografía de Lloyd, en versión probabilística; sube la verosimilitud en cada paso, converge a óptimo local.
- **Qué compra:** clusters elípticos (no solo esféricos), tamaños distintos, incertidumbre de pertenencia — útil cuando la frontera entre segmentos es gris (¿hogar “vulnerable” o “clase media”?).

Para profundizar

Las advertencias del clustering (léanlas dos veces)

- 1 **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos (ingreso en pesos aplasta a años de educación). Y la elección de variables ya es media respuesta: clusters de *consumo* $\neq$ clusters de *demografía*.

Las advertencias del clustering (léanlas dos veces)

- 1 **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos (ingreso en pesos aplasta a años de educación). Y la elección de variables ya es media respuesta: clusters de *consumo* $\neq$ clusters de *demografía*.
- 2 **k-means busca esferas.** Grupos alargados, anidados o de densidades muy distintas lo confunden; el jerárquico con Ward o el GMM son más flexibles.

Las advertencias del clustering (léanlas dos veces)

- ❶ **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos (ingreso en pesos aplasta a años de educación). Y la elección de variables ya es media respuesta: clusters de *consumo* $\neq$ clusters de *demografía*.
- ❷ ***k*-means busca esferas.** Grupos alargados, anidados o de densidades muy distintas lo confunden; el jerárquico con Ward o el GMM son más flexibles.
- ❸ **Atípicos:** un outlier puede secuestrar un centroide entero. Inspeccionar antes; considerar removerlos o usar medoides.

Las advertencias del clustering (léanlas dos veces)

- ❶ **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos (ingreso en pesos aplasta a años de educación). Y la elección de variables ya es media respuesta: clusters de *consumo* $\neq$ clusters de *demografía*.
- ❷ ***k*-means busca esferas.** Grupos alargados, anidados o de densidades muy distintas lo confunden; el jerárquico con Ward o el GMM son más flexibles.
- ❸ **Atípicos:** un outlier puede secuestrar un centroide entero. Inspeccionar antes; considerar removerlos o usar medoides.
- ❹ **Estabilidad como hábito:** repetir con submuestras del 80–90%; si los grupos bailan, no eran estructura.

Las advertencias del clustering (léanlas dos veces)

- ❶ **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos (ingreso en pesos aplasta a años de educación). Y la elección de variables ya es media respuesta: clusters de *consumo* $\neq$ clusters de *demografía*.
- ❷ ***k*-means busca esferas.** Grupos alargados, anidados o de densidades muy distintas lo confunden; el jerárquico con Ward o el GMM son más flexibles.
- ❸ **Atípicos:** un outlier puede secuestrar un centroide entero. Inspeccionar antes; considerar removerlos o usar medoides.
- ❹ **Estabilidad como hábito:** repetir con submuestras del 80–90%; si los grupos bailan, no eran estructura.


Y la madre de todas

El algoritmo **siempre** entrega K grupos — también sobre ruido puro. Un cluster no es un hallazgo hasta que sobrevive estabilidad + interpretación + (idealmente) validación *downstream*.

- 1 El problema no supervisado
- 2 Clustering: k -means, jerárquico y mezclas
- 3 PCA: componentes principales
- 4 Síntesis


La idea: las direcciones que concentran la varianza

Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:



La idea: las direcciones que concentran la varianza


Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:



- **PC1**: la dirección w que maximiza la varianza de la proyección $w'x$.
- **PC2**: la de máxima varianza *ortogonal* a PC1; y así sucesivamente.
- Quedarse con las primeras $M \ll p$: comprimir perdiendo lo mínimo.

La idea: las direcciones que concentran la varianza

Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:



- **PC1**: la dirección w que maximiza la varianza de la proyección $w'x$.
- **PC2**: la de máxima varianza *ortogonal* a PC1; y así sucesivamente.
- Quedarse con las primeras $M \ll p$: comprimir perdiendo lo mínimo.
- Requisitos de aseo: **centrar** siempre; **estandarizar** casi siempre (si no, la variable de mayor varianza se roba el PC1 — misma trampa del clustering).

La derivación: PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

La derivación: PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

1. Lagrangiano (¡el de siempre!):

$$\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$$

La derivación: PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

1. Lagrangiano (¡el de siempre!):

$$\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$$

2. Condición de primer orden:

$$\frac{\partial \mathcal{L}}{\partial w} = 2 \Sigma w - 2 \lambda w = 0 \quad \implies \quad \boxed{\Sigma w = \lambda w}$$

w debe ser un **autovector** de Σ , con autovalor λ !

La derivación: PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

1. **Lagrangiano** (¡el de siempre!):

$$\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$$

2. **Condición de primer orden:**

$$\frac{\partial \mathcal{L}}{\partial w} = 2 \Sigma w - 2 \lambda w = 0 \quad \implies \quad \boxed{\Sigma w = \lambda w}$$

w debe ser un **autovector** de Σ , con autovalor λ !

3. **¿Cuál autovector?** Evaluando el objetivo: $w' \Sigma w = \lambda w' w = \lambda$.

- La varianza de la proyección **es** el autovalor $\Rightarrow$ PC1 = autovector del **mayor** autovalor λ_1 ; PC2, el del segundo (la ortogonalidad sale gratis: Σ simétrica); etc.

La derivación: PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

1. **Lagrangiano** (¡el de siempre!):

$$\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1)$$

2. **Condición de primer orden:**

$$\frac{\partial \mathcal{L}}{\partial w} = 2 \Sigma w - 2 \lambda w = 0 \quad \implies \quad \boxed{\Sigma w = \lambda w}$$

w debe ser un **autovector** de Σ , con autovalor λ !

3. **¿Cuál autovector?** Evaluando el objetivo: $w' \Sigma w = \lambda w' w = \lambda$.


- La varianza de la proyección **es** el autovalor $\Rightarrow$ PC1 = autovector del **mayor** autovalor λ_1 ; PC2, el del segundo (la ortogonalidad sale gratis: Σ simétrica); etc.

Para el Taller 2

“PCA como problema de autovalores” es exactamente esta derivación. Sépanla contar de memoria.


¿Cuántos componentes? Varianza explicada

Cada componente explica una fracción $\lambda_j / \sum_k \lambda_k$ de la varianza total.



¿Cuántos componentes? Varianza explicada

Cada componente explica una fracción $\lambda_j / \sum_k \lambda_k$ de la varianza total.




Los tres criterios de siempre (ninguno automático):

- **Umbral acumulado:** conservar componentes hasta explicar 80–90%.
- **El codo del scree plot** (el mismo razonamiento del WSS).
- **Interpretabilidad:** un componente que no se puede nombrar rara vez sirve para comunicar.

¿Cuántos componentes? Varianza explicada

Cada componente explica una fracción $\lambda_j / \sum_k \lambda_k$ de la varianza total.



Los tres criterios de siempre (ninguno automático):

- **Umbral acumulado:** conservar componentes hasta explicar 80–90%.
- **El codo del scree plot** (el mismo razonamiento del WSS).
- **Interpretabilidad:** un componente que no se puede nombrar rara vez sirve para comunicar.

Y si el destino es un modelo supervisado (regresión sobre componentes): elegir M por **CV** — ahí sí hay árbitro.

El uso económico estrella: índices socioeconómicos

Filmer & Pritchett (2001): sin datos de ingreso confiables, construir un índice de riqueza como el **PC1 de los activos del hogar** (materiales de la vivienda, electrodomésticos, acceso a servicios).

El uso económico estrella: índices socioeconómicos

Filmer & Pritchett (2001): sin datos de ingreso confiables, construir un índice de riqueza como el **PC1 de los activos del hogar** (materiales de la vivienda, electrodomésticos, acceso a servicios).

- **Las cargas** (*loadings*) del PC1 son los *pesos* del índice: qué activos “pesan” más en la riqueza latente. Leerlas **es** interpretar el componente.
- La lógica: la dimensión de máxima covariación entre activos es el nivel socioeconómico — el factor latente que los mueve a todos.

El uso económico estrella: índices socioeconómicos

Filmer & Pritchett (2001): sin datos de ingreso confiables, construir un índice de riqueza como el **PC1 de los activos del hogar** (materiales de la vivienda, electrodomésticos, acceso a servicios).

- **Las cargas** (*loadings*) del PC1 son los *pesos* del índice: qué activos “pesan” más en la riqueza latente. Leerlas **es** interpretar el componente.
- La lógica: la dimensión de máxima covariación entre activos es el nivel socioeconómico — el factor latente que los mueve a todos.
- Es el espíritu de los *proxy means tests* (Sisbén incluido): resumir muchas señales observables en un índice focalizable.

El uso económico estrella: índices socioeconómicos

Filmer & Pritchett (2001): sin datos de ingreso confiables, construir un índice de riqueza como el **PC1 de los activos del hogar** (materiales de la vivienda, electrodomésticos, acceso a servicios).

- **Las cargas** (*loadings*) del PC1 son los *pesos* del índice: qué activos “pesan” más en la riqueza latente. Leerlas **es** interpretar el componente.
- La lógica: la dimensión de máxima covariación entre activos es el nivel socioeconómico — el factor latente que los mueve a todos.
- Es el espíritu de los *proxy means tests* (Sisbén incluido): resumir muchas señales observables en un índice focalizable.

Letras menudas del oficio:

- El **signo** de cada componente es arbitrario (autovector por -1 sigue siendo autovector): orientarlo para que “más = más riqueza”.
- Con variables en escalas distintas: PCA sobre la matriz de **correlación** (estandarizar).
- El índice se *audita* con validación *downstream*: ¿predice consumo, salud, educación? (la sesión 1 saluda).

PCA como compresión — y el puente a lo que viene

Tres usos del mismo objeto:

- 1 **Describir:** 2–3 componentes con nombre (riqueza, urbanidad, formalidad).
- 2 **Visualizar:** proyectar en (PC1, PC2) — el mapa lineal de los datos.
- 3 **Comprimir para predecir:** regresión sobre componentes (PCR) — reducir p antes del modelo supervisado; M por CV. Prima hermana de Ridge (ambas encogen en las direcciones de poca varianza).

PCA como compresión — y el puente a lo que viene

Tres usos del mismo objeto:

- 1 **Describir:** 2–3 componentes con nombre (riqueza, urbanidad, formalidad).
- 2 **Visualizar:** proyectar en (PC1, PC2) — el mapa lineal de los datos.
- 3 **Comprimir para predecir:** regresión sobre componentes (PCR) — reducir p antes del modelo supervisado; M por CV. Prima hermana de Ridge (ambas encogen en las direcciones de poca varianza).

El puente conceptual hacia las sesiones 8–9

PCA aprende una **representación de baja dimensión** de los datos — *lineal*. Las redes neuronales aprenderán representaciones **no lineales** (un *autoencoder* es “PCA no lineal”), y los *embeddings* de palabras de la sesión 9 son exactamente eso: coordenadas aprendidas en un espacio de baja dimensión donde la geometría significa algo. Guarden esta frase: **representar es comprimir con sentido**.

t-SNE y UMAP: mapas no lineales (solo para los ojos)

Cuando la estructura no es lineal (clusters curvos, variedades), PCA la aplana mal. **t-SNE** (van der Maaten & Hinton, 2008) y **UMAP** (McInnes et al., 2018) construyen un mapa 2D que preserva **vecindades locales**: quién está cerca de quién.

t-SNE y UMAP: mapas no lineales (solo para los ojos)

Cuando la estructura no es lineal (clusters curvos, variedades), PCA la aplana mal. **t-SNE** (van der Maaten & Hinton, 2008) y **UMAP** (McInnes et al., 2018) construyen un mapa 2D que preserva **vecindades locales**: quién está cerca de quién.

- **Para qué sirven:** exploración visual — ver de un vistazo si hay grupos, subgrupos, transiciones. Espectaculares con datos de alta dimensión (imágenes, texto, genómica).

t-SNE y UMAP: mapas no lineales (solo para los ojos)

Cuando la estructura no es lineal (clusters curvos, variedades), PCA la aplana mal. **t-SNE** (van der Maaten & Hinton, 2008) y **UMAP** (McInnes et al., 2018) construyen un mapa 2D que preserva **vecindades locales**: quién está cerca de quién.

- **Para qué sirven**: exploración visual — ver de un vistazo si hay grupos, subgrupos, transiciones. Espectaculares con datos de alta dimensión (imágenes, texto, genómica).
- **Para qué NO sirven** (y aquí se cometen papers enteros de errores):
 - ▶ Las **distancias globales** en el mapa no significan nada (dos islas lejanas no son “muy distintas” por estar lejos).
 - ▶ El **tamaño y densidad** de los grupos en el mapa es artefacto de los hiperparámetros (*perplexity* / vecinos).
 - ▶ Corridas distintas dan mapas distintos: no es un espacio con coordenadas interpretables.

t-SNE y UMAP: mapas no lineales (solo para los ojos)

Cuando la estructura no es lineal (clusters curvos, variedades), PCA la aplana mal. **t-SNE** (van der Maaten & Hinton, 2008) y **UMAP** (McInnes et al., 2018) construyen un mapa 2D que preserva **vecindades locales**: quién está cerca de quién.

- **Para qué sirven**: exploración visual — ver de un vistazo si hay grupos, subgrupos, transiciones. Espectaculares con datos de alta dimensión (imágenes, texto, genómica).
- **Para qué NO sirven** (y aquí se cometen papers enteros de errores):
 - ▶ Las **distancias globales** en el mapa no significan nada (dos islas lejanas no son “muy distintas” por estar lejos).
 - ▶ El **tamaño y densidad** de los grupos en el mapa es artefacto de los hiperparámetros (*perplexity* / vecinos).
 - ▶ Corridas distintas dan mapas distintos: no es un espacio con coordenadas interpretables.

Regla práctica

UMAP/t-SNE para **mirar**; k -means/jerárquico sobre los datos (o sobre componentes de PCA) para **agrupar**; PCA para **construir índices**. Cada

- 1 El problema no supervisado
- 2 Clustering: k -means, jerárquico y mezclas
- 3 PCA: componentes principales
- 4 Síntesis

Recap

- 1 Sin y no hay árbitro *out-of-sample*: la validación es **estabilidad** + **interpretación** + **uso posterior** — y el algoritmo siempre “encuentra” algo.
- 2 **k-means**: minimizar WSS con Lloyd (óptimos locales $\Rightarrow$ muchos inicios); K por codo/silueta y por uso; estandarizar siempre.
- 3 **Jerárquico**: el dendrograma da todas las resoluciones; el linkage importa; cortar es decidir.
- 4 **GMM/EM**: clustering probabilístico con pertenencias suaves; k -means es su caso límite.
- 5 **PCA** = autovalores de Σ (sépanlo derivar): la varianza de cada componente es su λ ; componentes por codo/umbral/CV; el PC1 de activos es el índice socioeconómico clásico (Filmer–Pritchett).
- 6 **t-SNE/UMAP**: mapas locales para explorar — jamás para medir distancias ni tamaños.
- 7 El hilo a futuro: **representar es comprimir con sentido** — PCA lineal hoy; redes y *embeddings* no lineales en las sesiones 8–9.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 12 (secs. 12.1, 12.2 y 12.4).

Guía: PCA y clustering con las figuras que vimos hoy.

- Filmer & Pritchett (2001).

Guía: secciones 1–3; fíjense cómo *validan* el índice sin observar ingreso.

Recomendadas: Jolliffe (2002), caps. 1–2; McInnes et al. (2018, UMAP) para curiosos.

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 12 (secs. 12.1, 12.2 y 12.4).

Guía: PCA y clustering con las figuras que vimos hoy.

- Filmer & Pritchett (2001).

Guía: secciones 1–3; fíjense cómo *validan* el índice sin observar ingreso.

Recomendadas: Jolliffe (2002), caps. 1–2; McInnes et al. (2018, UMAP) para curiosos.

Próxima sesión — empieza el bloque final: redes neuronales. Del perceptrón a la retropropagación (que derivaremos: va al Taller 2), y de ahí a las redes convolucionales que leen **imágenes satelitales**. Lectura previa: Goodfellow, Bengio & Courville, cap. 6 (secciones 6.1–6.3, sin pánico).

Para aprovechar al máximo la próxima sesión

Lecturas obligatorias de esta semana:

- ISLR, cap. 12 (secs. 12.1, 12.2 y 12.4).

Guía: PCA y clustering con las figuras que vimos hoy.

- Filmer & Pritchett (2001).

Guía: secciones 1–3; fíjense cómo *validan* el índice sin observar ingreso.

Recomendadas: Jolliffe (2002), caps. 1–2; McInnes et al. (2018, UMAP) para curiosos.

Próxima sesión — empieza el bloque final: redes neuronales. Del perceptrón a la retropropagación (que derivaremos: va al Taller 2), y de ahí a las redes convolucionales que leen **imágenes satelitales**. Lectura previa: Goodfellow, Bengio & Courville, cap. 6 (secciones 6.1–6.3, sin pánico).

Aplicación de esta semana en R: segmentar hogares por patrones de consumo (k -means + jerárquico) y construir un índice socioeconómico con PCA, comparándolo con la clasificación oficial.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Cap. 12. [ISLR]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. Cap. 14. [ESL]
- Jolliffe, I. (2002). *Principal Component Analysis* (2. ed.). Springer. Caps. 1–2.
- Rousseeuw, P. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *J. of Computational and Applied Mathematics*, 20, 53–65.
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data — or Tears. *Demography*, 38(1), 115–132.
- van der Maaten, L., & Hinton, G. (2008). Visualizing Data using t-SNE. *JMLR*, 9, 2579–2605.
- McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection. *arXiv:1802.03426*.