

Big Data y Machine Learning para Economía Aplicada

Week 07: Representar — PCA, k -medias y redes neuronales

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 18, 2026

Previously...

- **Abrimos la caja del líder:** permutación, ablación por bloques, PDP e ICE, SHAP y error por subgrupos coincidieron: el modelo respira **geografía**; el censo importa *a través* del lugar, y el error vive en lo rural.
- **El hallazgo incómodo:** quitar cualquier bloque del censo no movió el error: las 37 columnas son **redundantes entre sí**. Y los árboles pierden en un frente marcado desde la sesión 1: cuando la estructura está en la *representación* (imágenes, texto), no hay columnas que cortar.
- Dos hilos que hoy convergen: el **gradiente** como motor de aprendizaje (el *boosting*, la verosimilitud) y la **regularización** como precio de la flexibilidad (sesión 3).

La tabla del líder, al cierre de la semana 6 (sin cambios)

Voto: bosque + coordenadas **12,1** · *boosting* 12,2 · *k*-NN 12,1 · Lasso 14,7.
¿Gana?: bosque **0,951**.

Debrief del Problem Set 1: el ranking

Quince minutos [tabla y comentarios por completar después de calificar]

- 1 **La tabla de posiciones:** el RMSE de prueba del modelo final de cada equipo, junto a su RMSE de validación. ¿Coinciden? Un equipo cuya prueba quedó muy por encima de su validación aprendió algo hoy.
- 2 **Qué hizo distinto el primero:** qué modelo eligió, qué variables construyó dentro del pliegue y qué esquema de validación usó.
- 3 **Los tropiezos frecuentes:** la prueba abierta más de una vez; la receta (imputar, escalar, agrupar) ajustada fuera del pliegue; la CV aleatoria con avisos de la misma zona en entrenamiento y validación.
- 4 **El número del curso:** cuánto ganó la regularización sobre OLS con todas las variables, y cuánto se movió el error al validar por zonas en vez de al azar.

Lo que sigue

El Problem Set 2 continúa desde el modelo final del Problem Set 1: el ranking del curso se vuelve a calcular el 24 de noviembre con el modelo final de los dos.

La pregunta de hoy: ¿pueden los datos construir sus propios resúmenes?

La redundancia de la semana pasada, tomada en serio

- **La semana 6 nos dejó una pista:** las 37 columnas del censo cuentan pocas historias repetidas muchas veces. Si es así, deberían poderse **comprimir** en unos pocos índices sin perder casi nada.
- **Sin y :** ¿cuáles son esos índices (PCA), y cuántas Colombias distintas describen los entornos de los puestos (k -medias)? Nadie mira el voto al construirlos: sólo la estructura de las x .
- **Con y :** ¿y si la representación se aprende *para* predecir? Una **red neuronal** fabrica sus propias variables intermedias y las ajusta junto con la predicción; el examen es el de siempre: ¿le gana al bosque en la prueba?

Cómo la respondemos

Representar es comprimir con sentido, en tres escalas: PCA (lineal, sin y) $\rightarrow$ k -medias (grupos, sin y) $\rightarrow$ redes (no lineal, con y), y una red **preentrenada** que presta su representación para leer imágenes. Con los puestos de principio a fin; antes, quince minutos con el ranking del PS1.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

¿Qué cambia cuando no hay y

	Supervisado (sesiones 1–6)	No supervisado (hoy, primera hora)
Objetivo	predecir y	describir la estructura de las x
Criterio	error de prueba	ninguno: no hay respuesta correcta
Validación	CV, conjunto de prueba	estabilidad, interpretación, uso posterior
Peligro	sobreajustar	ver patrones donde no los hay

¿Cómo se valida entonces? Tres sustitutos imperfectos del error de prueba:

- 1 **Estabilidad:** ¿los grupos o las componentes sobreviven a remuestrear los datos, cambiar la semilla, quitar una variable?
- 2 **Interpretación:** ¿la estructura tiene una lectura económica que se pueda nombrar?
- 3 **Uso posterior:** si el índice o el grupo luego *predice* algo (consumo, mora, voto), esa tarea supervisada lo audita. Así auditaremos el nuestro.


Regla de honestidad

Los algoritmos de hoy **siempre** devuelven grupos y componentes, haya o no estructura real. La carga de la prueba es nuestra.

PCA: las direcciones que concentran la varianza

ISL 12.2

Con p variables correlacionadas, la información *efectiva* vive en menos dimensiones. PCA busca las **combinaciones lineales** de máxima varianza:



- **PC1**: la dirección w_1 (con $\|w_1\| = 1$) que maximiza la varianza de la proyección $z_1 = w_1'x$; **PC2**: la de máxima varianza *ortogonal* a PC1; y así sucesivamente. Los pesos w se llaman **cargas**; los z , **puntajes**.
- Es un problema de autovalores de la covarianza: la varianza de cada componente es su autovalor (apéndice A1). Quedarse con las primeras $M \ll p$ es comprimir perdiendo lo mínimo.
- **Aseo**: centrar siempre; **estandarizar** casi siempre, o la de mayor varianza se roba la PC1. Con medias y desviaciones **del entrenamiento**: también sin y hay *pipeline*.

¿Cuántas componentes? La varianza explicada de la ficha

El scree de nuestras 37 columnas

Cada componente explica una fracción $\lambda_j / \sum_k \lambda_k$ de la varianza total. **Con la ficha:**


Componente	1	2	3	4	5	6	7	8
% de la varianza	32,0	11,4	5,8	5,0	4,1	3,4	3,3	2,9
Acumulada	32,0	43,4	49,2	54,2	58,3	61,7	64,9	67,9

- **Una sola dirección concentra un tercio** de la varianza de 37 columnas: la redundancia de la semana 6, medida. Para el 80% hacen falta 13 componentes; para el 90%, 18.
- **Tres criterios, ninguno automático:** el umbral acumulado (80–90%), el **codo** del *scree plot* (aquí, después de la segunda), y la **interpretación**: una componente que no se puede nombrar rara vez sirve para comunicar.
- Si el destino es un modelo supervisado (regresión sobre componentes, ISL 6.3.1), M se elige **por CV**: ahí sí hay árbitro.

Nuestro índice: la PC1 de la ficha es el eje urbano–rural

Las cargas se leen, el índice se nombra, y la auditoría la hace el voto

- **Las cargas de la PC1** (las mayores): alcantarillado $-0,26$, internet $-0,26$, gas $-0,25$, educación técnica $-0,25$, **rural $+0,24$** , acueducto $-0,23$. Las comodidades de un lado, la ruralidad del otro: **un índice de carencias** construido sin ver el voto.
- **Se audita contra lo que no usó:** correlación de $+0,84$ con la ruralidad, $-0,75$ con la educación superior, $-0,30$ con la participación... y **$+0,09$ con el voto por Petro**. ¿La dirección más informativa del censo no dice nada del voto? Dice, pero no en línea recta:



La U del caso: votan más por Petro los dos extremos del índice (48,8 en el decil más urbano; **71,8** en el más carente) y menos el medio (46,7). El 0,09 escondía una relación fuerte y no lineal: por eso la recta del país fracasaba y el bosque no.

El índice de activos: el mismo objeto en las encuestas de hogares

Filmer & Pritchett (2001)

El problema: en una encuesta de hogares el ingreso es difícil de medir; lo que sí se observa bien es qué tiene el hogar (nevera, moto, piso de cemento, acueducto, celular. . .) y de qué está hecha la vivienda.

La solución estándar: el índice de riqueza es la **PC1 de los activos**: la dimensión de máxima covariación entre ellos es el nivel socioeconómico, el factor latente que los mueve a todos. Exactamente lo que acabamos de hacer con los entornos de los puestos.

- **Las cargas son los pesos del índice:** qué activos “pesan” más en la riqueza latente. Leerlas es interpretar la componente. Es el espíritu de los *proxy means tests*, el Sisbén incluido.
- **Letras menudas:** el signo de una componente es arbitrario (orientarla); con escalas distintas, PCA sobre la matriz de correlación; y las cargas se estiman: con pocos hogares, dos remuestras dan dos índices.
- **La auditoría:** el índice vale si luego predice consumo, salud o educación. Sin esa validación posterior, es sólo la dirección de mayor varianza.

PCA como compresión, y el puente a la segunda hora

Tres usos del mismo objeto:

- 1 **Describir**: componentes con nombre (carencias; nuestra PC2 es el eje demográfico: las edades mayores contra los niños).
- 2 **Visualizar**: proyectar en (PC1, PC2): el mapa lineal de los datos, y los grupos que k -medias buscará.
- 3 **Comprimir para predecir** (PCR): regresión sobre las primeras M componentes. **Con los puestos**: 1 componente, RMSE 26,6; con 5, 23,2; con 20, 21,1; con las 37, 19,8: la ficha en OLS.

Lo que PCA no ve

Sólo direcciones **lineales** y sólo **varianza**: la dirección que más varía no tiene por qué ser la que predice ($\rho = 0,09$, y era una U). Comprimir sin mirar y conserva la estructura de las x , no la señal sobre y : con 20 de 37 componentes aún se pierde un punto de RMSE. Los mapas no lineales (t-SNE, UMAP) sirven para *mirar*, no para medir.

El puente: PCA aprende una representación lineal y sin mirar y ; una red neuronal, una **no lineal y para predecir**: la segunda hora.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

k -medias: el problema y el algoritmo

ISL 12.4.1

Objetivo: partir las n observaciones en K grupos $C_1, \dots, C_K$ minimizando la dispersión *dentro* de cada grupo:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2, \quad \mu_k = \text{centroide (media) del grupo } k.$$


- El problema exacto es **combinatorio**: hay del orden de K^n particiones. Otra vez la salida es una heurística inteligente, como en el árbol.

Algoritmo de Lloyd:

- 1 Inicializar K centroides (al azar o con *k-means++*).
 - 2 Repetir hasta converger: (a) **asignar** cada punto a su centroide más cercano; (b) **recalcular** cada centroide como la media de sus asignados.
- Cada paso baja el objetivo, así que converge... a un **óptimo local**. En la práctica: 20 o 50 inicios distintos y quedarse con el mejor.
 - Como todo lo basado en distancias: **estandarizar primero** (el k -NN de la sesión 2).

¿Cuántos grupos? El codo, la silueta y el uso

K no lo dicen los datos solos: la dispersión dentro de los grupos *siempre* baja con K . **Con la ficha** (SS dentro / SS total): $K = 2$: 0,75; 3: 0,68; 4: 0,62; 5: 0,59; 6: 0,56; 8: 0,52.



- **Codo:** el K donde la ganancia marginal se desploma. El nuestro es suave: baja parejo, sin quiebre nítido; el codo casi nunca decide solo.
- **Silueta** (Rousseeuw, 1987): para cada puesto, su distancia media al propio grupo contra la del grupo vecino; el promedio, entre -1 y 1 , es una nota por K .
- **El uso:** si la campaña sólo puede diseñar cuatro estrategias territoriales, $K = 4$. K es una *decisión*, no un parámetro verdadero.

Cuatro Colombias: las tipologías del censo

k -medias con $K = 4$ sobre la ficha estandarizada; el voto, sólo para auditar

Tipología	Puestos	Rural	Educ. sup.	Afro	Indígena	Voto
Rural étnica (Pacífico, frontera)	2.721	96%	1,9	28,7	19,9	63,0
Urbana dotada	1.388	1%	29,3	2,3	0,4	49,8
Urbana popular	2.686	10%	8,8	6,2	2,2	54,0
Rural andina	2.807	96%	2,6	4,1	4,5	42,2

- **Los grupos se dejan nombrar** (primer requisito): dos Colombias urbanas separadas por la dotación, y **dos ruralidades** separadas por la composición étnica y los servicios (8% de alcantarillado en una, 14% en la otra).
- **El mapa los delata:** el agrupamiento no usó las coordenadas y, al pintarlos, dibujan el país: el Pacífico y las fronteras de un color, el eje andino de otro. La geografía de la semana 6, redescubierta sin mapa.
- **La auditoría con el voto** (que k -medias nunca vio): la ruralidad no es una: la étnica vota 63 y la andina 42. **El “rural” promedio no existe:** por eso el error rural del líder es grande.

Las advertencias del agrupamiento (léanlas dos veces)

- ❶ **La escala manda.** Sin estandarizar, la variable de mayor varianza *define* los grupos. Y la elección de variables ya es media respuesta: grupos del *censo* no son grupos de *resultados electorales*.
- ❷ **k -medias busca esferas** del mismo tamaño. Grupos alargados, anidados o de densidades muy distintas lo confunden; el agrupamiento jerárquico y las mezclas de normales son más flexibles (apéndice A2).
- ❸ **Atípicos:** un solo valor extremo puede secuestrar un centroide entero. Mirar antes.
- ❹ **Estabilidad como hábito:** repetir con submuestras del 80% y otras semillas; si los grupos bailan, no eran estructura. (`kmeans` con `nstart` alto ya promedia arranques.)

Y la madre de todas

El algoritmo **siempre** entrega K grupos, también sobre ruido puro. Un grupo no es un hallazgo hasta que sobrevive estabilidad + interpretación +, idealmente, una validación posterior con una y : nuestras cuatro Colombias pasaron las tres.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

El problema: aprender las variables, no sólo los pesos

- Hasta hoy las variables eran **columnas**: las escribimos (sesión 2), las seleccionamos (sesión 3), el árbol las cortó (sesión 5) o PCA las comprimió sin mirar y (hace un rato).
- Una imagen satelital de 224×224 píxeles a color es un vector de 150.528 números sin significado individual; un texto es una secuencia de palabras. No hay columna que cortar ni *spline* que escribir.
- **Representar es comprimir con sentido.** Aquí la representación se aprende *para* predecir.

Pregunta para la sala

¿Cómo construir una máquina que fabrique sus propias variables derivadas y las use para predecir, todo en un solo ajuste?

El problema: aprender las variables, no sólo los pesos

- Hasta hoy las variables eran **columnas**: las escribimos (sesión 2), las seleccionamos (sesión 3), el árbol las cortó (sesión 5) o PCA las comprimió sin mirar y (hace un rato).
- Una imagen satelital de 224×224 píxeles a color es un vector de 150.528 números sin significado individual; un texto es una secuencia de palabras. No hay columna que cortar ni *spline* que escribir.
- **Representar es comprimir con sentido.** Aquí la representación se aprende *para* predecir.

Pregunta para la sala


¿Cómo construir una máquina que fabrique sus propias variables derivadas y las use para predecir, todo en un solo ajuste?

Componiendo regresiones: la salida de una capa es la entrada de la siguiente. Cada capa oculta es un conjunto de variables derivadas, aprendidas junto con los pesos que las usan. ISL 10.1 lo dice así: las activaciones son *derived features*.

La neurona: una regresión con actitud


La unidad básica no tiene misterio: una combinación lineal de las entradas seguida de una **función de activación** no lineal g ,

$$a = g(w'x + b).$$



- Con g sigmoide, una neurona **es** la regresión logística de la sesión 4. Nada nuevo todavía.
- La novedad no es la neurona: es **componerlas**.
- Sin la no linealidad no hay negocio: componer funciones lineales da otra función lineal. g es lo que hace que apilar capas agregue capacidad.

La red *feedforward*: composición de capas




Capa por capa (ISL 10.1–10.2), con $a^{(0)} = x$:


$$a^{(l)} = g(W^{(l)}a^{(l-1)} + b^{(l)}), \quad l = 1, \dots, L-1; \quad \hat{y} = h(W^{(L)}a^{(L-1)} + b^{(L)}).$$

- La red **es** una composición $\hat{y} = f_L \circ \dots \circ f_1(x)$. Profundidad = cuántas funciones componemos; anchura = unidades por capa. **Parámetros:** todos los W, b .
- **Salida** h según la tarea: identidad (regresión), sigmoide (binaria), **softmax** (K clases).
- **¿Por qué profundo?** Una capa ancha ya aproxima cualquier función continua (apéndice A6), pero la composición **reutiliza**: cada capa oculta es una representación, de cruda a abstracta.


Funciones de activación



sigmoide



tanh



ReLU = $\max(0, z)$

- **Sigmoide y tanh**: elegantes, pero se **saturan**: en las colas su derivada es casi cero y, con muchas capas, el gradiente se *desvanece* al multiplicarse por casi-ceros.
- **ReLU**: tosca (ni siquiera es diferenciable en 0) pero no se satura en la mitad positiva, es baratísima y entrena mejor: el estándar en capas ocultas.
- **Softmax** en la salida multiclase: convierte K puntajes en probabilidades, $e^{z_k} / \sum_j e^{z_j}$.

El contrato de la flexibilidad

Aproximar todo $\Rightarrow$ sobreajustarlo todo. La generalización se compra con datos y regularización. La curva U jamás se fue.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

La pérdida y el descenso de gradiente estocástico

La pérdida es la de siempre (MSE; en clasificación, la verosimilitud de la sesión 4 con signo menos), pero como función de los pesos $\theta = (W, b)$ **no es convexa**: valles, mesetas y puntos de silla. Adiós a las garantías del Lasso.

La regla de siempre, ahora sobre miles o millones de parámetros:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta).$$

- **Mini-lotes**: el gradiente se calcula con 32 a 256 observaciones por paso: ruidoso pero barato, y el ruido ayuda a escapar de valles malos. Una **época** es una pasada por los datos.
- η , **la tasa de aprendizaje**: grande diverge; chica no llega. **Adam** adapta el paso por parámetro y es el *default* moderno (apéndice A4).
- **La sorpresa empírica** que sostiene el campo: sin garantía de óptimo global, SGD encuentra soluciones que generalizan bien. Óptimo local + buen protocolo = herramienta utilizable.
- **Déjà vu del boosting**: en la sesión 5, descenso de gradiente en el espacio de *funciones*, un árbol por paso; aquí, en el de *parámetros*, un mini-lote por paso.

Retropropagación: la regla de la cadena, administrada

ISL 10.7.1; la derivación completa en el apéndice A3


El problema computacional: $\nabla_{\theta} L$ tiene miles de componentes. ¿Cómo calcularlos sin morir?

La respuesta: la red es una composición, así que la derivada de la pérdida respecto a *cualquier* peso es un producto de derivadas locales a lo largo del camino hasta la salida. Esos productos **comparten factores**: computando de la salida hacia atrás, cada factor se calcula una sola vez y se reutiliza.

- Resultado: el gradiente completo cuesta lo mismo que **una pasada hacia adelante más una hacia atrás**, no una pasada por parámetro. Esa economía es lo que hace entrenables las redes grandes.
- El objeto que viaja hacia atrás es el “error” de cada capa, $\delta^{(l)} = \partial L / \partial z^{(l)}$; en la salida, con pérdida cuadrática, $\delta^{(L)} = \hat{y} - y$: **el residuo, otra vez**. El patrón: δ de una capa = (δ de la siguiente $\times$ pesos) $\odot$ derivada de la activación.
- En la práctica nadie deriva a mano: **diferenciación automática** (Keras, PyTorch, torch en R).

Regularizar redes: el kit de siempre, con otros nombres

ISL 10.7.2–10.7.3



- **Weight decay** (L_2): penalizar $\sum \|W\|^2$: Ridge (sesión 3) con otro nombre.
- **Parada temprana**: parar cuando la pérdida de validación deja de bajar: el mínimo de la curva U en vivo, con las épocas como eje de complejidad. Es la perilla que *siempre* se usa; la misma del *boosting*.
- **Dropout** (Srivastava et al., 2014): en cada paso, apagar al azar una fracción de unidades; la red no puede depender de ninguna en particular. Un ensamble implícito: el espíritu del bosque.
- **Aumentar datos**: en imágenes, rotar, recortar, reflejar. El regularizador más honesto: más variación invariante.

Los hiperparámetros de una red, en una tabla

Perilla	Qué controla	Rango típico	Se elige por
capas y unidades	capacidad	1–3 capas; 16–256 unid.	validación
activación	no linealidad	ReLU	<i>default</i>
tasa de aprendizaje η	tamaño del paso	10^{-4} a 10^{-2}	validación
tamaño del mini-lote	ruido del gradiente	32 a 256	fijo
épocas	cuándo parar	hasta 500	parada temprana
<i>dropout</i>	ensamble implícito	0,1 a 0,5	validación
<i>weight decay</i>	Ridge sobre los pesos	10^{-5} a 10^{-3}	validación
semilla	inicialización, orden de lotes	de varias	se <i>promedia</i>

- **Las redes sí necesitan escala:** normalizar los predictores dentro del *pipeline* (regla de oro #3), a diferencia de los árboles.
- **La semilla es un hiperparámetro que no se elige:** el mismo modelo con otra inicialización da otro resultado. Se reporta la media y la dispersión sobre varias semillas, o se promedian las redes.
- La búsqueda es cara: con CV de 5 pliegues cada configuración son cinco entrenamientos. Búsqueda aleatoria (sesión 3) y pocas perillas a la vez.

Datos tabulares: el desafío de los árboles

ISL 10.6: cuando la ganancia es pequeña, gana el modelo simple

- **ISL 10.6:** en los salarios de *Hitters*, la red y el Lasso quedan casi empatados en la prueba. La navaja de Occam: si la red no gana claramente, se usa el modelo que se entiende.
- **Grinsztajn, Oyallon & Varoquaux (2022):** en 45 conjuntos tabulares de tamaño medio, los ensambles de árboles superan a las redes, incluso afinadas con presupuesto grande. Las redes prefieren funciones suaves, sufren con variables irrelevantes y dependen de la escala.
- **Con los puestos, en un momento:** la red densa queda un punto por encima del bosque, con la ficha o con el mapa. Nuestro n y nuestras columnas son exactamente el terreno donde los árboles mandan.

La regla práctica (y la Parte 3 del Problem Set 2)

Con n de miles y columnas con sentido, el *boosting* afinado es el techo razonable. La red paga con **estructura** (imágenes, texto), con **escala**, o para **transferir** una representación aprendida. Que no le gane al bosque es un resultado, y uno bueno.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

Por qué una red densa no puede ver

Una imagen modesta de 200×200 píxeles a color son 120.000 entradas.

- Una primera capa densa de 1.000 unidades tendría **120 millones** de pesos en una sola capa: sobreajuste garantizado y cómputo absurdo.
- Peor: la red densa **ignora la estructura espacial**. Trata el píxel (1, 1) y el (200, 200) como si su relación fuera la de dos vecinos; si el techo se corre diez píxeles, para la red es una entrada completamente nueva.


Las dos ideas que arreglan todo (LeCun et al., 1998; ISL 10.3):

- 1 **Localidad**: los patrones visuales son locales; un borde vive en una ventanita.
- 2 **Invarianza a traslación**: un borde es un borde esté donde esté, así que se usan **los mismos pesos** en toda la imagen.

Juntas se llaman **convolución**, y convierten los 120 millones de pesos en unas decenas por filtro.

La convolución: un filtro que recorre la imagen

ISL 10.3.1–10.3.2



- El filtro, una matriz pequeña de pesos, se **desliza** por la imagen; en cada posición, el producto punto ventana–filtro da un número del mapa de salida.
- Cada filtro aprende a **detectar un patrón** (un borde vertical, una esquina, una textura); su mapa dice *dónde* apareció. Una capa convolucional son varios filtros en paralelo (apéndice A5).
- **Pooling**: quedarse con el máximo de cada bloque 2 × 2; reduce la resolución, gana robustez a desplazamientos pequeños y abarata lo que sigue.

La arquitectura CNN y el *transfer learning*

ISL 10.3.3–10.3.5

El patrón: [convolución $\rightarrow$ ReLU $\rightarrow$ *pooling*] varias veces $\rightarrow$ capas densas $\rightarrow$ salida. Las capas tempranas aprenden **bordes**; las medias, **texturas y partes** (techos, vías, cultivos); las tardías, **objetos y escenas**.

El momento histórico: AlexNet gana ImageNet (2012) por paliza: profundidad, ReLU, *dropout* y GPU. Desde entonces la visión por computadora es aprendizaje profundo.

Transfer learning: el truco que nos habilita

Una CNN entrenada con millones de imágenes genéricas ya sabe ver bordes, texturas y partes; eso es **universal**. Receta: tomar la red preentrenada (ResNet50 en ISL 10.3.5), **congelarla** y usar su penúltima capa como variables derivadas; encima, un Ridge o un bosque con *nuestros* datos (cientos o miles, no millones). El ejemplo canónico en economía: Jean et al. (2016) leen la pobreza africana desde imágenes satelitales con una red prestada.

- El *pipeline* de la sesión 3 no cambia: la red congelada es un paso de preprocesamiento; el Ridge se afina con CV; la prueba se usa una vez. Y la validación respeta el espacio: las imágenes vecinas se parecen.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

Aplicación guiada (I): el índice y las tipologías

applications/week-07; unos 5 minutos: las redes se entrenan tres veces por configuración

- **El PCA a mano limpia:** estandarizar *con medias y desviaciones del entrenamiento*, *prcomp*, el *scree* (32% la primera), las cargas con nombre y el índice de carencias. La auditoría: correlaciones con lo que no usó, y **la U del voto** por deciles.
- **PCR:** el voto sobre 1, 2, 5, 10, 20 y 37 componentes (26,6 $\rightarrow$ 19,8): comprimir sin y conserva varianza, no señal.
- **k-medias:** el codo (suave), `nstart = 25`, la tabla de las cuatro tipologías y el mapa pintado por grupo, sin haber usado coordenadas.

Lo que hay que ver

Dos herramientas sin y que se auditan con una y que nunca vieron: el índice descubre la U y las tipologías separan las dos ruralidades. La estructura era real; el voto sólo la confirmó.

Aplicación guiada (II): la red contra el bosque

- **La red** (`nnet`): una capa oculta de 16 unidades sobre la ficha estandarizada y el departamento, *weight decay* 0,1 (Ridge, sesión 3), y reescalada a $[0, 1]$.
- **Tres semillas, porque la red depende del arranque:** 13,8 / 13,8 / 13,7 de RMSE de prueba. Con las coordenadas: 13,6 / 13,4 / **13,2**. La dispersión entre semillas es parte del reporte.
- **El veredicto:** la mejor red queda un punto por encima del bosque (12,1) y del *boosting* (12,2). Con 9.602 puestos y columnas con sentido, el ensamble de árboles es el techo: **que la red no gane es un resultado, y uno bueno** (ISL 10.6).
- **Lo que habría que cambiar para que ganara:** más datos, estructura (imágenes del territorio en vez de la ficha) o una representación transferida: el guion de Parte 5.

La pregunta de la aplicación

¿Cuánta información cabe en pocas componentes? ¿Los grupos sobreviven? ¿Le gana la red al bosque, y qué tendría que cambiar para que sí? Es la Parte 3 del Problem Set 2.

- 1 Sin y : componentes principales
- 2 Sin y : k -medias
- 3 Con y : qué es una red neuronal
- 4 Cómo se ajusta: gradiente, retropropagación y regularización
- 5 Redes que ven: convolución y *transfer learning*
- 6 Aplicación guiada en R
- 7 Cierre

Qué dicen estos modelos y qué no dicen

- **Una componente principal es una dirección de varianza**, no un concepto: la nuestra se volvió “índice de carencias” cuando sus cargas se dejaron leer y cuando la U del voto la auditó. Un grupo de k -medias es una partición conveniente, no un hallazgo, hasta que sobrevive a otra semilla.
- **Las unidades ocultas de una red no significan nada por sí solas**: no hay coeficientes que leer. El kit de la sesión 6 sí funciona (permutación, PDP, SHAP por muestreo), fuera del entrenamiento y con semillas.
- **En imágenes, la saliencia** (qué píxeles mueven la predicción) sirve para auditar (¿mira los techos o la marca de agua?), no para narrar.
- **La tabla decide**: la red no le ganó al bosque en la prueba, así que la respuesta a “¿usamos *deep learning* aquí?” es no, y es una buena respuesta.

Y , no β , versión representaciones

El índice de carencias ordena entornos; no explica por qué el Pacífico está donde está. Y que los dos extremos del índice voten igual no dice que la carencia “cause” el voto: dice que el territorio viene en paquetes que el censo resume.

Cuándo usar qué, y qué leer

	Usar cuando	Cuidado con
PCA	índices; comprimir antes de un modelo; mirar	estandarizar; el signo; sólo lineal y sólo varianza
k -medias	segmentar para actuar	escala; esferas; siempre entrega K grupos
Red densa	tabular muy grande, o como comparación	escala, semillas, η ; rara vez gana
CNN preentrenada + Ridge	imágenes con cientos o miles de etiquetas	dominio distinto a ImageNet; proxy
Red desde cero	millones de ejemplos y GPU	todo lo anterior, multiplicado
Árboles y <i>boosting</i>	tabular mediano con columnas con sentido	extrapolación; afinado

Qué leer: ISL 12.2 y 12.4 (PCA y k -medias, con el laboratorio); ISL 10.1 a 10.3 y 10.6 a 10.7; Grinsztajn et al. (2022) por la evidencia tabular; Dell (2025) como mapa del *deep learning* para economistas; Gentzkow, Kelly & Taddy (2019) si el proyecto usa texto: cambia la representación, no la evaluación.

Recap

- 1 **Sin y no hay error de prueba:** estabilidad, interpretación y uso posterior lo sustituyen. Los algoritmos siempre devuelven estructura; la carga de la prueba es nuestra.
- 2 **PCA:** las direcciones de máxima varianza. La PC1 de la ficha (32%) es el eje urbano–rural: un índice de carencias que el voto auditó con una U. Comprimir sin y conserva varianza, no señal (PCR).
- 3 **k-medias:** minimizar la dispersión dentro (Lloyd); K por codo, silueta o uso. Cuatro Colombias con nombre, y **dos ruralidades** que votan a 21 puntos de distancia.
- 4 **Una red** compone regresiones con activaciones no lineales: cada capa oculta es un conjunto de variables derivadas aprendidas para predecir. SGD y retropropagación; parada temprana, *weight decay*, *dropout*, semillas.
- 5 **Cuándo:** en nuestro tabular la red quedó a un punto del bosque; paga con estructura, escala o representaciones transferidas (CNN preentrenada como preprocesamiento).
- 6 **La tabla decide**, también aquí: misma partición, misma prueba, semillas y dispersión.

La tabla del líder, y el cierre del caso que viene

La red compitió y no destronó a nadie

Sem.	Modelo	Voto (RMSE)
3	Lasso, ficha larga	14,7
7	red (ficha + departamento; mejor de tres semillas)	13,7
7	red (+ coordenadas; mejor de tres semillas)	13,2
3	k -NN en el mapa ($k = 10$)	12,1
5	<i>boosting</i> + coordenadas	12,2
5	bosque + coordenadas	12,1

- **El podio no cambió:** el bosque sigue de líder en las dos preguntas (12,1 y 0,951), con el *boosting* y los vecinos pegados. La red entra a mitad de tabla, y su papel real en economía aplicada es otro: prestar representaciones (imágenes, texto).
- **La limitación que nos lleva a la sesión 8:** el caso está completo: sabemos cuánto se puede predecir (12 puntos, AUC 0,95), con qué, y dónde falla. Lo que falta es **la síntesis**: ¿qué preguntas de la economía se responden con esta caja de herramientas? Sus papers, la tabla final del caso, y el puente hacia las preguntas causales.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

El martes 3 de noviembre es la sesión de los papers. Seis presentaciones de 15 minutos con los papers por área de la economía elegidos en la sesión 2. Guion: la pregunta y la decisión; los datos y la unidad; la referencia; cómo se evalúa fuera de muestra y dónde falla; el resultado principal; qué método del curso es y qué habríamos hecho distinto. Diapositivas: las que quepan en 15 minutos.

Entrega 1 del proyecto, el mismo día: la idea en una página (la pregunta y la decisión que la motiva; la unidad y la y ; los datos candidatos y qué se sabría en el momento de predecir), enviada antes de clase, y un *pitch* de 5 minutos con retroalimentación del grupo. Vale 10 de los 100 puntos del proyecto.

Problem Set 2: entrega el martes 10 de noviembre a las 11:59 p.m. Con la sesión de hoy ya está todo lo que necesitan; el 10 de noviembre no hay clase, pero sí asesoría.

Lectura para el cierre: Athey & Imbens (2019), *Machine Learning Methods That Economists Should Know About*, secciones 1 a 3, para el puente causal con que cerramos la sesión 8.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 10 y 12. [ISL]
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data—or Tears. *Demography*, 38(1), 115–132.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Caps. 6–9.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep Learning. *Nature*, 521, 436–444.
- Kingma, D., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *ICLR*.
- Srivastava, N., et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *JMLR*, 15, 1929–1958.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- Dell, M. (2025). Deep Learning for Economists. *Journal of Economic Literature*, 63(1), 5–58.
- Gentzkow, M., Kelly, B., & Taddy, M. (2019). Text as Data. *Journal of Economic Literature*, 57(3), 535–574.
- Jean, N., Burke, M., Xie, M., Davis, W., Lobell, D., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794. [El ejemplo de *transfer learning* de la Parte 5.]
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

8 Apéndice: para profundizar

A1. PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de los datos centrados. Buscamos w :

$$\max_w w' \Sigma w \quad \text{sujeto a} \quad w' w = 1$$

(la restricción impide inflar la varianza alargando w).

1. Lagrangiano:

$$\mathcal{L}(w, \lambda) = w' \Sigma w - \lambda (w' w - 1).$$

2. Condición de primer orden:

$$\frac{\partial \mathcal{L}}{\partial w} = 2 \Sigma w - 2 \lambda w = 0 \quad \implies \quad \boxed{\Sigma w = \lambda w}$$

w debe ser un **autovector** de Σ , con autovalor λ .

3. ¿Cuál autovector? Evaluando el objetivo: $w' \Sigma w = \lambda w' w = \lambda$.

- La varianza de la proyección **es** el autovalor: PC1 es el autovector del **mayor** autovalor λ_1 ; PC2, el del segundo (la ortogonalidad sale gratis porque Σ es simétrica); y así sucesivamente. En R, `prcomp` lo hace con la descomposición en valores singulares de la matriz centrada.

A2. Agrupamiento jerárquico y mezclas de normales

- **Jerárquico aglomerativo** (ISL 12.4.2): empezar con n grupos de una observación y fusionar en cada paso los dos más cercanos. El **dendrograma** muestra todas las resoluciones a la vez: cortar a una altura es elegir el número de grupos *después* de ver la estructura. “Cercanos” entre grupos lo define el *linkage*: completo, promedio o Ward son los sensatos; el simple encadena. Cuesta $O(n^2)$ distancias: para cientos o miles y estructura anidada (municipios, sectores), brilla.
- **Mezclas de normales**: los datos vienen de K normales con pesos π_k ; pertenecer a un grupo es una variable latente y cada observación recibe una **probabilidad** de pertenencia. Se estima con el algoritmo EM, la versión probabilística de Lloyd. Compra grupos elípticos, de tamaños distintos, e incertidumbre de pertenencia: útil cuando la frontera es gris (¿hogar vulnerable o clase media?). k -medias es el caso límite de varianzas iguales que tienden a cero.
- **Mapas no lineales** (t-SNE, UMAP): preservan vecindades locales para *mirar* datos de alta dimensión. Las distancias globales y el tamaño de los grupos en el mapa no significan nada, y cada corrida da un mapa distinto. Para agrupar, k -medias o jerárquico; para índices, PCA.

A3. Retropropagación: derivación con una capa oculta

Setup (regresión, pérdida cuadrática de una observación):

$$z = W^{(1)}x + b^{(1)}, \quad h = g(z), \quad \hat{y} = w^{(2)'}h + b^{(2)}, \quad L = \frac{1}{2}(\hat{y} - y)^2.$$

1. Capa de salida (primer eslabón de la cadena):

$$\delta^{(2)} = \frac{\partial L}{\partial \hat{y}} = \hat{y} - y \quad (\text{el residuo}).$$

2. Gradientes de la capa de salida:

$$\frac{\partial L}{\partial w^{(2)}} = \delta^{(2)} h, \quad \frac{\partial L}{\partial b^{(2)}} = \delta^{(2)}.$$

3. Propagar el error hacia atrás (por cada unidad oculta, la cadena pasa por $\hat{y}$ y por g):

$$\delta^{(1)} = (w^{(2)} \delta^{(2)}) \odot g'(z).$$

4. Gradientes de la capa oculta:

$$\frac{\partial L}{\partial W^{(1)}} = \delta^{(1)} x', \quad \frac{\partial L}{\partial b^{(1)}} = \delta^{(1)}.$$

Con ReLU, $g'(z) = \mathbb{I}\{z > 0\}$: el error sólo fluye por las unidades activas. Con más capas, el paso 3 se repite capa por capa.

A4. Momento y Adam

El SGD puro oscila en valles estrechos y avanza despacio en mesetas. Dos remedios que se combinan:

Momento: acumular una media móvil del gradiente y moverse en su dirección,

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad \theta_t = \theta_{t-1} - \eta m_t.$$

Adam (Kingma & Ba, 2015): además, una media móvil del gradiente al cuadrado para *escalar* el paso de cada parámetro por su propia volatilidad,

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t},$$

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}.$$

- Los *defaults* $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 10^{-8}$ casi nunca se tocan; $\eta \approx 10^{-3}$ es el punto de partida. Las correcciones $1 - \beta^t$ compensan que $m_0 = v_0 = 0$.
- Parámetros con gradientes grandes reciben pasos chicos y viceversa: una estandarización implícita del paisaje. Adam tolera predictores mal escalados mejor que SGD, pero no tan bien como normalizar.

A5. La aritmética de una capa convolucional

Tamaño de salida. Una imagen de $n \times n$, un filtro de $k \times k$, relleno (*padding*) p y paso (*stride*) s producen un mapa de

$$\left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1 \times \left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1.$$

Con 224×224 , $k = 3$, $p = 1$, $s = 1$: 224×224 . Un *pooling* 2×2 lo baja a 112×112 .

Parámetros. Una capa con F filtros de $k \times k$ sobre una entrada con C canales tiene $F(k^2C + 1)$ pesos, *independientemente del tamaño de la imagen*. Sesenta y cuatro filtros 3×3 sobre RGB: $64 \times (27 + 1) = 1.792$. La capa densa equivalente sobre $224 \times 224 \times 3$ entradas y 64 salidas tendría $64 \times 150.529 \approx 9,6$ millones.

Cómputo. Cada posición del mapa cuesta k^2C multiplicaciones; la capa completa, $F \cdot k^2C \cdot (\text{posiciones})$. Los pesos son pocos; las operaciones, muchas: por eso las GPU.

- **ResNet50:** unos 25 millones de parámetros y 50 capas con “atajos” que suman la entrada de un bloque a su salida, lo que permite entrenar redes profundas sin que el gradiente se desvanezca. Su penúltima capa, tras el *pooling* global, tiene 2.048 números por imagen: las variables derivadas del *transfer learning*.

A6. Aproximación universal: qué dice y qué no

Enunciado (Cybenko, 1989; Hornik, 1991). Sea g una función de activación no polinómica (sigmoide, ReLU). Para toda función continua f sobre un compacto de $\mathbb{R}^p$ y todo $\varepsilon > 0$ existen K y pesos tales que

$$\sup_x \left| f(x) - \sum_{k=1}^K \beta_k g(w'_k x + b_k) \right| < \varepsilon.$$

- **Es un resultado de densidad**, como el de Weierstrass para polinomios. No dice cuántas unidades (K puede crecer exponencialmente con p y $1/\varepsilon$), ni que SGD las encuentre, ni nada sobre generalización.
- **Profundidad**: hay funciones que una red profunda representa con $O(p)$ unidades y una red de una capa necesita $O(2^p)$ (Telgarsky, 2016): la composición reutiliza piezas. Es la razón teórica de “profundo y no ancho”, y coincide con lo que se ve en las CNN.
- **La analogía con la sesión 2**: los *splines* también aproximan cualquier función suave; la red aprende *dónde* poner los nodos (w_k, b_k) y en qué combinaciones de variables. Con p grande, esa es la diferencia entre lo posible y lo imposible.