

Big Data y Machine Learning para Economía Aplicada

Week 07: Representar: comprimir con sentido

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 25, 2026

Previously...

- **Abrimos la caja del boosting:** el departamento primero, la etnia después; los cruces que encontró la máquina son, sobre todo, la etnia en cada departamento (afro $\times$ departamento: 2,4 puntos).
- **La pista:** permutar un bloque del censo subía el error entre 1,3 y 3,8 puntos; reentrenar sin él, sólo entre 0,3 y 0,4. Los bloques se reemplazan entre sí: las 37 columnas cuentan pocas historias, repetidas.
- **Y dónde falla:** 14,9 de error en lo rural contra 9,3 en las cabeceras. Con el mapa, otra explicación con casi el mismo error (12,1).

Lo que quedó pendiente

¿Cuántas cosas distintas dice el censo de un puesto? Si son pocas, deberían poderse resumir en unos pocos índices o en unos pocos tipos de territorio. ¿Y quién debe decidir cómo resumirlas?

Debrief del Problem Set 1: el ranking

Quince minutos [tabla y comentarios por completar después de calificar]

- 1 **La tabla de posiciones:** el RMSE de prueba del modelo final de cada equipo, junto a su RMSE de validación. ¿Coinciden? Un equipo cuya prueba quedó muy por encima de su validación aprendió algo hoy.
- 2 **Qué hizo distinto el primero:** qué modelo eligió, qué variables construyó dentro del pliegue y qué esquema de validación usó.
- 3 **Los tropiezos frecuentes:** la prueba abierta más de una vez; la receta (imputar, escalar, agrupar) ajustada fuera del pliegue; la validación al azar con avisos de la misma zona en entrenamiento y validación.
- 4 **El número del curso:** cuánto ganó la regularización sobre OLS con todas las variables, y cuánto se movió el error al validar por zonas en vez de al azar. [por completar]

Lo que sigue

El Problem Set 2 parte del modelo final del Problem Set 1: el ranking del curso se vuelve a calcular el 24 de noviembre con el modelo final de los dos.

La pregunta de hoy: ¿cuántas cosas distintas sabe el censo de un puesto?

Y quién decide cómo resumirlas: la varianza de las x o la y

- **Sin y , en línea recta:** ¿cuántas direcciones concentran la información de las 37 columnas? Las componentes principales (PCA).
- **Sin y , en grupos:** ¿cuántos tipos de territorio hay? k -medias. Nadie mira el voto al construirlos: sólo la estructura de las x .
- **Con y :** ¿y si el resumen se aprende *para* predecir? Una **red neuronal** fabrica sus propias variables y las ajusta junto con la predicción. El examen, el de siempre: la prueba contra el *boosting*.
- **Sin columnas:** cuando el dato es una imagen, no hay ficha que resumir: la representación se aprende, o se toma prestada.

La idea con la que se van

Representar es comprimir con sentido. Sin y , el sentido lo pone la varianza de las x ; con y , lo pone la predicción. Lo que más varía no es, necesariamente, lo que predice.

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 Cómo se ajusta una red
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

Qué cambia cuando no hay y


	Supervisado (sesiones 2 a 6)	No supervisado (hoy, la primera hora)
Objetivo	predecir y	describir la estructura de las x
Criterio	error de prueba	no hay respuesta correcta
Validación	CV y conjunto de prueba	estabilidad, interpretación, uso posterior
Peligro	sobreajustar	ver patrones donde no los hay

¿Cómo se valida, entonces? Con tres sustitutos imperfectos del error de prueba:

- 1 **Estabilidad:** ¿los grupos o las componentes sobreviven a otra semilla, a otra muestra, a quitar una variable?
- 2 **Interpretación:** ¿la estructura tiene una lectura económica que se pueda nombrar?
- 3 **Uso posterior:** si el índice o el grupo luego *predice* algo (consumo, mora, voto), esa tarea lo audita. Así auditaremos los nuestros: con el voto, que nunca vieron.

La dirección que concentra la varianza

ISL 12.2.1. Dos columnas de la ficha en 800 puestos de entrenamiento: correlación 0,82



La primera componente es la combinación lineal de las columnas centradas con la mayor varianza:

$$z_{i1} = \sum_{j=1}^p \phi_{j1} x_{ij},$$

$$\max_{\phi_1} \frac{1}{n} \sum_{i=1}^n z_{i1}^2 \quad \text{s.a.} \quad \sum_{j=1}^p \phi_{j1}^2 = 1.$$

- Los ϕ son las **cargas**; los z , los **puntajes** (la proyección de cada puesto).
- La **PC2**: la de mayor varianza entre las perpendiculares a la PC1. Es un problema de autovalores (apéndice A1).
- Aquí la PC1 se lleva el 96 %; sin estandarizar, el internet, que varía más, la inclina hacia su eje.

La otra cara: la aproximación más cercana

ISL 12.2.2 y 12.2.3: maximizar la varianza es lo mismo que minimizar el error de la aproximación

Las primeras M componentes dan la mejor aproximación de dimensión M a los datos:

$$x_{ij} \approx \sum_{m=1}^M z_{im} \phi_{jm},$$


y la varianza total se parte en dos pedazos que suman siempre lo mismo:

$$\underbrace{\sum_j \frac{1}{n} \sum_i x_{ij}^2}_{\text{varianza de los datos}} = \underbrace{\sum_{m=1}^M \frac{1}{n} \sum_i z_{im}^2}_{\text{varianza de las } M \text{ componentes}} + \underbrace{\frac{1}{n} \sum_j \sum_i \left(x_{ij} - \sum_{m=1}^M z_{im} \phi_{jm} \right)^2}_{\text{error de la aproximación}}.$$

- Por eso la **proporción de varianza explicada** (PVE) es un R^2 : el de la aproximación de las x con M componentes, $1 - \text{RSS}/\text{TSS}$.
- **Estandarizar**: con columnas en escalas distintas, la de mayor varianza se roba la PC1 (ISL 12.2.4). Nuestras 37 se estandarizan con las medias y desviaciones **del entrenamiento**: también sin *y* hay *pipeline*.

¿Cuántas componentes? La varianza de nuestras 37 columnas


La ficha estandarizada de los 9.602 puestos de entrenamiento



- **Una dirección concentra casi un tercio (32,0 %)** de la varianza de 37 columnas; la segunda, 11,4 %. Para el 80 % hacen falta 13 componentes; para el 90 %, 18. Es la redundancia de la semana 6, medida.
- **La última explica exactamente cero:** $\text{edad_votar} + \text{edad_0_19} = 100$ en todos los puestos. Son 37 columnas y 36 dimensiones; el PCA delata la columna repetida.
- **Ningún criterio es automático:** el codo, un umbral acumulado o la interpretación. Si el destino es predecir, M se elige con el juez (más adelante).

Qué dice cada componente: las cargas

Las diez cargas más grandes de la PC1 y de la PC2; el signo de una componente es arbitrario




- **La PC1 es un índice de carencias:** los servicios, la educación técnica y el tamaño del puesto de un lado; la ruralidad y los niños del otro. Correlación con la ruralidad 0,84; con la educación superior, -0,75.
- **La PC2 separa los puestos jóvenes y lejanos de los envejecidos:** correlación 0,57 con la población de 0 a 19 años. Nadie le dijo al PCA qué es la edad o la distancia: las encontró porque varían juntas.

Pregunta para la sala: la PC1 resume casi un tercio de la varianza del censo. ¿Qué parte del voto por Petro explica?

El índice sin y, auditado con y


El voto por Petro en cada decil de la PC1 (9.602 puestos de entrenamiento)



- **La correlación con el voto es 0,09:** la dirección que más varía explica el 0,9 % del voto. Pero no en línea recta: sube en el decil 2 (55,9), cae en el medio (46,7) y se dispara en el más carente (71,9), que es también el más afro (33 % contra 2 % en el primero): el Pacífico.
- **El índice de activos** (Filmer y Pritchett, 2001) es este mismo objeto: la PC1 de lo que tiene el hogar es su nivel socioeconómico. Es el índice de riqueza de las encuestas DHS, y la y que Jean et al. (2016) predicen con imágenes satelitales (la parte 5).

Comprimir para predecir, sin mirar y: la regresión sobre componentes

PCR: OLS con los puntajes de las primeras M componentes; el PCA se estima dentro de cada pliegue



- **Comprimir a ciegas cuesta:** con una componente, 26,5 (la media: 26,7); con cinco, 23,2; con todas, 19,8, que es OLS. El juez elige 36: todas las que tienen varianza. Con 9.602 puestos y 37 columnas no hay varianza que ahorrar.
- **El salto del juez tiene nombre:** la PC10 es la columna palenquero sola (carga 0,98), en cero en el 89 % de los puestos. Estandarizada, San Basilio de Palenque es una dirección entera; fuera del pliegue, el PCR le predice 1.465 (votó 95).

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 Cómo se ajusta una red
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

k -medias: el problema y el algoritmo

ISL 12.4.1: partir los puestos en K grupos tan parecidos por dentro como se pueda

El problema: elegir los grupos $C_1, \dots, C_K$ que minimizan la variación dentro de cada uno,

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = \min_{C_1, \dots, C_K} \sum_{k=1}^K 2 \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_{kj})^2.$$



La igualdad (ISL 12.18) dice que las distancias entre parejas del mismo grupo son las distancias al **centroide** $\bar{x}_k$, la media del grupo.

El algoritmo (hay casi K^n particiones: no se pueden probar todas):

- ➊ Asignar al azar un grupo a cada puesto.
 - ➋ Repetir hasta que nada cambie: (a) calcular el centroide de cada grupo; (b) reasignar cada puesto al centroide más cercano.
- Cada paso baja el objetivo, así que converge... a un óptimo **local**: se repite con 25 arranques y se queda el mejor.
 - Como todo lo que usa distancias, con las columnas estandarizadas (el k -NN de la semana 2).

¿Cuántos grupos?


Izquierda: la variación dentro de los grupos sobre la total. Derecha: la silueta en 2.000 puestos al azar



- **La variación dentro siempre baja con K :** de 1 a 0,75 con dos grupos, 0,62 con cuatro, 0,48 con diez. El codo es suave: no hay un quiebre que decida solo.
- **La silueta** compara, para cada puesto, su distancia media al propio grupo con la del grupo vecino (de -1 a 1). Prefiere dos grupos (0,27); con cuatro, 0,17.
- **K es una decisión, no un parámetro verdadero:** si una campaña puede diseñar cuatro estrategias territoriales, $K = 4$.

Cuatro Colombias: las tipologías del censo

k -medias con $K = 4$ sobre la ficha estandarizada; el voto, sólo para auditar



	Puestos	Rural	Educ.	Etnia	Voto
● rural étnica	2.721	96 %	1,9	48,6	63,0
● rural andina	2.807	96 %	2,6	8,6	42,2
● urbana dotada	1.388	1 %	29,3	2,6	49,8
● urbana popular	2.686	10 %	8,8	8,4	54,0

Educ.: educación superior (% de las personas). Etnia: afro + indígena (%).

Voto: por Petro (%).

- **Se dejan nombrar:** dos Colombias urbanas separadas por la dotación y dos ruralidades separadas por la etnia.
- **El mapa los delata:** k -medias no vio las coordenadas, y el Pacífico y las fronteras salen de un color, el eje andino de otro.
- **La ruralidad no es una:** la étnica vota 63,0 y la andina 42,2, 21 puntos de distancia. Por eso el error rural de la semana 6 es grande.

¿Sirven los grupos para predecir?

Describir no es predecir: el voto de prueba con la media de cada grupo

- **Con la media del grupo:** 25,6 de RMSE (la media del país: 26,7). Con la del departamento, 18,0; con la del grupo dentro de cada departamento, 16,1. Cuatro tipos de territorio no alcanzan para predecir un puesto; sirven para *hablar* de él.
- **Estabilidad:** con otras cinco semillas, el 100 % de los puestos queda en el mismo grupo. Estos grupos no bailan.
- **Con $K = 5$** la ruralidad étnica se parte y aparece un núcleo de 867 puestos (afro 36 %, indígena 41 %) que vota 78,2.

Las advertencias del agrupamiento

La escala manda (estandarizar); k -medias busca grupos redondos y del mismo tamaño; un atípico puede secuestrar un centroide; y el algoritmo **siempre** entrega K grupos, también sobre ruido puro. Un grupo es un hallazgo cuando sobrevive a la estabilidad, a la interpretación y a una y que nunca vio.

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 Cómo se ajusta una red
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

Del PCR a la red: la misma fórmula

ISL 10.1: una red de una capa es una regresión sobre variables que ella misma fabrica

El PCR regresa y sobre M direcciones que eligió la varianza de las x :

$$f(x) = \beta_0 + \sum_{m=1}^M \beta_m \underbrace{\phi'_m x}_{\text{la PC } m}.$$

La red neuronal regresa y sobre K direcciones que elige la pérdida sobre y , dobladas por una función g :

$$f(x) = \beta_0 + \sum_{k=1}^K \beta_k \underbrace{g(w_{k0} + w'_k x)}_{A_k: \text{ la unidad } k}.$$

Las **activaciones** A_k son variables derivadas, como las bases de los *splines* de la semana 2, pero **aprendidas**. **Dos diferencias con el PCR**: quién elige las direcciones (la y , no la varianza) y si se doblan (g).

Pregunta para la sala: una red con una sola unidad, ¿le gana a la PC1 doblada? ¿Y a OLS con las 37 columnas?

Del PCR a la red: la misma fórmula

ISL 10.1: una red de una capa es una regresión sobre variables que ella misma fabrica

El PCR regresa y sobre M direcciones que eligió la varianza de las x :

$$f(x) = \beta_0 + \sum_{m=1}^M \beta_m \underbrace{\phi'_m x}_{\text{la PC } m}.$$

La red neuronal regresa y sobre K direcciones que elige la pérdida sobre y , dobladas por una función g :

$$f(x) = \beta_0 + \sum_{k=1}^K \beta_k \underbrace{g(w_{k0} + w'_k x)}_{A_k: \text{ la unidad } k}.$$


Las **activaciones** A_k son variables derivadas, como las bases de los *splines* de la semana 2, pero **aprendidas**. **Dos diferencias con el PCR**: quién elige las direcciones (la y , no la varianza) y si se doblan (g).

Pregunta para la sala: una red con una sola unidad, ¿le gana a la PC1 doblada? ¿Y a OLS con las 37 columnas?

A la PC1, por mucho (19,4 contra 25,8); a OLS, apenas (19,4 contra 19,8). Lo que importa es quién eligió la dirección.

Una sola unidad: ¿quién elige la dirección?

El voto de 800 puestos de prueba contra la PC1 (izquierda) y contra la unidad de una red con $K = 1$ (derecha)



- **Elegir la dirección con y vale más que doblarla:** la PC1 en línea recta deja 26,5 de RMSE y doblada con un *spline*, 25,8; la red con una sola unidad, 19,4 (OLS con las 37: 19,8). Su dirección casi no se parece a la PC1 (correlación $-0,20$).
- **La red fabricó una variable:** sus dos pesos más grandes son el log de la población (5,8) y el de las viviendas ($-5,9$), casi opuestos: su diferencia son las personas por vivienda.

Por qué hace falta la curva g

ISL 10.1: sin g , apilar unidades no agrega nada; con g , aparecen las curvas y los cruces

La g es la sigmoide de la semana 4, $1/(1 + e^{-z})$, o ReLU, $\max(0, z)$; en nuestra red la salida pasa además por una sigmoide para quedar entre 0 y 100. **Sin** g , la red es lineal por más unidades que tenga: $\beta_0 + \sum_k \beta_k(w_{k0} + w'_k x)$ es otra recta en x , la de OLS.

Con g , dos unidades ya fabrican un cruce (ISL 10.6 a 10.8). Con $p = 2$, $g(z) = z^2$, $\beta_1 = \frac{1}{4}$, $\beta_2 = -\frac{1}{4}$ y


$$A_1 = (x_1 + x_2)^2, \quad A_2 = (x_1 - x_2)^2,$$

$$f(x) = \frac{1}{4} [(x_1 + x_2)^2 - (x_1 - x_2)^2] = x_1 x_2.$$

- Es el tipo de interacción que en la semana 3 escribimos a mano (1.291 columnas) y que en la semana 5 encontraban los árboles con un corte dentro de otro. La red la encuentra combinando direcciones dobladas.
- Con sigmoides o ReLU no se obtiene exactamente $x_1 x_2$, pero sí cualquier forma suave con suficientes unidades (apéndice A6). **El precio:** con muchas unidades, la red también aprende el ruido.

Más unidades, más capacidad: la U, otra vez

El juez de la semana 3 (diez pliegues) para $K = 1, 2, 4, 8, 16$ unidades; 270 redes ajustadas



- **Con la ficha y el departamento** el juez elige $K = 16$ y decay 0,1: 14,1 de CV, contra 13,2 del *boosting* con los mismos ingredientes. Con la ficha sola, 17,5 contra 15,8.
- **El weight decay es Ridge** (semana 3): con 16 unidades y poca penalización (0,01) la red sobreajusta (14,9); con 0,1, no. Son 1.153 pesos para 9.602 puestos.

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 **Cómo se ajusta una red**
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

La pérdida no es convexa: bajar por el gradiente

ISL 10.7

El problema es mínimos cuadrados no lineales,

$$\min_{\theta} R(\theta) = \frac{1}{2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2, \quad \theta = (\beta, w_1, \dots, w_K),$$

pero, por el anidamiento de los pesos y la simetría entre unidades, R **no es convexa**: tiene muchos mínimos locales. Adiós a las garantías del Lasso.

El descenso de gradiente: arrancar en pesos al azar θ^0 y dar pasos cuesta abajo,

$$\theta^{t+1} = \theta^t - \rho \nabla R(\theta^t),$$

con ρ la **tasa de aprendizaje**. En redes grandes el gradiente se calcula con mini-lotes de datos (descenso *estocástico*; una **época** es una pasada completa; apéndice A4).

- **Dos estrategias contra el sobreajuste** (ISL): aprender despacio y parar a tiempo, y penalizar los pesos. Son las del *boosting* de la semana 5 y las de Ridge de la semana 3.

Retropropagación: el residuo, repartido

ISL 10.7.1; la derivación completa, en el apéndice A3


Con $z_{ik} = w_{k0} + \sum_j w_{kj} x_{ij}$, la regla de la cadena da, para una observación,

$$\frac{\partial R_i}{\partial \beta_k} = -(y_i - f(x_i)) g(z_{ik}), \quad \frac{\partial R_i}{\partial w_{kj}} = -(y_i - f(x_i)) \beta_k g'(z_{ik}) x_{ij}.$$

- **Las dos fórmulas empiezan por el residuo** $y_i - f(x_i)$: derivar reparte el residuo entre los pesos, primero entre las unidades según cuánto se activaron, después entre las entradas a través de cada unidad. De ahí el nombre: el error viaja de la salida hacia atrás.
- Es el residuo del *boosting* otra vez: allí cada árbol ajustaba el residuo; aquí cada paso mueve cada peso en proporción a su parte del residuo.
- Nadie lo deriva a mano: los paquetes lo hacen solos (diferenciación automática). El costo de todo el gradiente es una pasada hacia adelante y una hacia atrás.

Parar a tiempo y penalizar: las perillas de siempre


Una red de 16 unidades sin *weight decay*, detenida después de 10, 25, ..., 1.600 iteraciones



- **Dentro de muestra el error sólo baja** (de 17,8 a 10,2); en la prueba toca fondo en 50 iteraciones (14,3) y vuelve a subir (15,6). La **parada temprana** es la perilla de rondas del *boosting*; en la práctica se para con un conjunto de validación, no con la prueba.
- **Las otras perillas:** el *weight decay* (Ridge sobre los pesos), el *dropout* (apagar al azar unidades en cada paso: un ensamble implícito, como el bosque) y, en imágenes, aumentar los datos con rotaciones y recortes.

La semilla también es un hiperparámetro

La red elegida por el juez, entrenada con cinco semillas distintas: el error de prueba de cada una y el de su promedio



- **Mismos datos, misma red, otros pesos iniciales:** el error de prueba casi no se mueve (de 13,56 a 13,63), pero no son la misma función: como el problema no es convexo, cada semilla termina en otro mínimo local.
- **Promediar las cinco redes** deja 12,8: mejor que cualquiera, y lo mismo que el *boosting*. Es el bosque otra vez: promediar modelos que se equivocan distinto. Se reporta la dispersión entre semillas, nunca la mejor.

La carrera: ¿le gana la red a los árboles?

RMSE de prueba del voto; los de las semanas 3 y 5, con la misma partición y la misma prueba

Ingredientes	Lineal	Red	Cinco redes	<i>Boosting</i> (S5)
La ficha de 37	OLS 19,8	16,9		15,7
Ficha + departamento	Lasso 14,7	13,6	12,8	12,8
Ficha + departamento + coordenadas	—	13,2		12,1

- **La red le gana a lo lineal y pierde con los árboles** con los tres juegos de ingredientes. ISL 10.6 cuenta lo mismo con los salarios de *Hitters*, y Grinsztajn, Oyallon y Varoquaux (2022) lo documentan en 45 bases tabulares: con n de miles y columnas con sentido, los ensambles de árboles mandan.
- **Promediar cinco redes empata con el boosting** (12,8), pero sumadas al promedio de la semana 5 (*boosting* + k -NN: 11,4) no agregan nada (11,5): sus errores se parecen a los del *boosting* (correlación 0,89).
- **Que no gane es un resultado.** La red paga cuando hay **estructura** que las columnas no traen (imágenes, texto), cuando hay **millones** de datos, o para **prestar** una representación aprendida en otra parte.

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 Cómo se ajusta una red
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

Por qué una red densa no puede ver

ISL 10.3: una imagen no trae columnas con sentido; trae píxeles

Una foto satelital de 224×224 píxeles a color son $224 \times 224 \times 3 = 150.528$ números.

- Una primera capa densa de 1.000 unidades tendría unos **150 millones** de pesos: sobreajuste seguro con los miles de ejemplos que tiene un economista.
- Peor: la red densa **ignora el espacio**. Para ella el píxel de la esquina y su vecino no tienen relación especial; si el techo se corre diez píxeles, es otra entrada.

Las dos ideas que lo arreglan (LeCun et al., 1998):

- 1 **Localidad:** los patrones visuales son locales; un borde vive en una ventana pequeña.
- 2 **Pesos compartidos:** un borde es un borde esté donde esté, así que la misma ventana de pesos recorre toda la imagen.

Juntas se llaman **convolución**, y convierten millones de pesos en unas decenas por filtro.

La convolución: un filtro que recorre la imagen


ISL 10.3.1. A la derecha, el voto de 2022 como una imagen en grises y el mismo mapa después de un filtro de bordes

Una imagen de 4×3 y un filtro de 2×2 (ISL, p. 413):

$$\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \\ j & k & l \end{bmatrix} * \begin{bmatrix} \alpha & \beta \\ \gamma & \delta \end{bmatrix}$$

la primera celda de la salida es $a\alpha + b\beta + d\gamma + e\delta$, y así en cada ventana de 2×2 .

- Cada celda de la salida es una suma ponderada de una ventana: alta donde la ventana **se parece** al filtro.
- En una CNN los pesos del filtro **se aprenden**; aquí usamos uno fijo (Sobel), que detecta cambios bruscos.



el voto (más oscuro, más Petro) los bordes (Sobel 3×3)

Cada píxel es una celda de un cuarto de grado; su tono, el voto por Petro de sus puestos (937 celdas con puestos, en blanco las demás). El filtro no sabe qué es un departamento: encuentra **fronteras** porque son cambios locales.

Pooling, la arquitectura y la red prestada

ISL 10.3.2 a 10.3.5

Max pooling: resumir cada bloque de 2×2 con su máximo; la imagen se achica a la mitad en cada eje y gana tolerancia a pequeños desplazamientos.

$$\begin{bmatrix} 1 & 2 & 5 & 3 \\ 3 & 0 & 1 & 2 \\ 2 & 1 & 3 & 4 \\ 1 & 1 & 2 & 0 \end{bmatrix} \longrightarrow \begin{bmatrix} 3 & 5 \\ 2 & 4 \end{bmatrix}$$

La arquitectura: [convolución $\rightarrow$ ReLU $\rightarrow$ *pooling*] varias veces, y al final capas densas. Las primeras capas aprenden bordes; las del medio, texturas y partes (techos, vías, cultivos); las últimas, escenas.

Transfer learning: la red prestada

Una red entrenada con millones de imágenes genéricas (ResNet50, ISL 10.3.5) ya sabe ver bordes y texturas: se **congela** y su penúltima capa se usa como variables de un Ridge con los datos propios. **Jean et al. (2016)** la ajustan para predecir las luces nocturnas desde fotos diurnas y con esas variables explican el 37 a 55 % del consumo y el 55 a 75 % del índice de activos en aldeas africanas: esa y es una PC1.

- 1 Sin y , en línea recta: las componentes principales
- 2 Sin y , en grupos: k -medias
- 3 Con y : la red neuronal
- 4 Cómo se ajusta una red
- 5 Cuando no hay columnas: redes que ven
- 6 Cierre

Qué dicen estos modelos y qué no dicen

- **Una componente principal es una dirección de varianza**, no un concepto: la nuestra se volvió “índice de carencias” cuando sus cargas se dejaron leer y el voto la auditó. Y la que más varía (la PC1) no es la que más predice (la PC2 explica el 11 % del voto; la PC1, el 0,9 %).
- **Un grupo de k -medias es una partición conveniente** hasta que sobrevive a otra semilla y se deja nombrar. Las nuestras pasaron las dos pruebas; describen mejor de lo que predicen.
- **Las unidades de una red no traen coeficientes que leer**: para abrirla sirve el kit de la semana 6, fuera del entrenamiento y con varias semillas.
- **La tabla decide**: con la ficha, el departamento y las coordenadas, la red no le ganó al *boosting*. ¿Usamos *deep learning* aquí? No, y es una buena respuesta.

Y , no β , versión representaciones

El índice de carencias ordena entornos; no explica el voto. Que el voto se dispare en el decil más carente no dice que la carencia “cause” el voto: ese decil es también el Pacífico. El territorio viene en paquetes que el censo resume.

Cuándo usar qué

	Usar cuando	Cuidado con
PCA	un índice (activos, carencias); mirar los datos; comprimir antes de un modelo con p cerca de n	estandarizar; el signo; sólo lineal y sólo varianza; las columnas casi vacías
k -medias	segmentar para actuar (tipologías, focalización)	la escala; grupos redondos; siempre entrega K grupos
Red densa	tabular muy grande, o como comparación	la escala, las semillas, el <i>decay</i> ; rara vez le gana a los árboles
CNN prestada + Ridge	imágenes con cientos o miles de etiquetas	un dominio muy distinto del de la red prestada
Red desde cero	millones de ejemplos y GPU	todo lo anterior, multiplicado
Árboles y <i>boosting</i>	tabular de tamaño medio con columnas con sentido	la extrapolación; afinar

Qué leer: ISL 12.2 y 12.4 (PCA y k -medias); ISL 10.1 a 10.3 y 10.6 a 10.7 (redes); Filmer y Pritchett (2001) por el índice de activos; Jean et al. (2016) por el *transfer learning* con imágenes; Grinsztajn et al. (2022) por la evidencia tabular; Dell (2025) como mapa del *deep learning* para economistas.

Recap

- 1 **Sin y no hay error de prueba:** lo sustituyen la estabilidad, la interpretación y una y que el método nunca vio.
- 2 **PCA:** las direcciones de máxima varianza, la mejor aproximación de dimensión M . La PC1 (32,0 %) es un índice de carencias que el voto audita (no en línea recta); comprimir sin y para predecir no le gana a OLS.
- 3 **k -medias:** minimizar la variación dentro de los grupos; K por el codo, la silueta o el uso. Cuatro Colombias con nombre y dos ruralidades a 21 puntos.
- 4 **Una red** regresa y sobre variables que ella misma fabrica: direcciones elegidas por la y y dobladas por g . Con una unidad ya le gana a la PC1 (19,4 contra 26,5).
- 5 **Se ajusta** bajando por el gradiente (el residuo, repartido) y se regulariza con las perillas de siempre: parar a tiempo, *weight decay*, promediar semillas.
- 6 **Cuándo:** en nuestra tabla la red no le ganó a los árboles; paga con imágenes, texto, millones de datos o una representación prestada.

Preparación para la próxima clase...

Para aprovechar al máximo la próxima sesión

El martes 3 de noviembre es la sesión de los papers. Seis presentaciones de 15 minutos, una por área de la economía, con los papers elegidos en la sesión 2. Guion: la pregunta y la decisión; los datos y la unidad; la referencia; cómo se evalúa fuera de muestra y dónde falla; el resultado principal; qué método del curso es y qué habríamos hecho distinto.

Entrega 1 del proyecto, el mismo día: la idea en una página (la pregunta y la decisión que la motiva, la unidad y la y , los datos y qué se sabría en el momento de predecir), enviada antes de clase, y un *pitch* de 5 minutos. Vale 10 de los 100 puntos del proyecto.

Problem Set 2: entrega el martes 10 de noviembre a las 11:59 p.m. Con la sesión de hoy ya está todo lo que necesitan (la Parte 3 es la red contra el bosque); el 10 de noviembre no hay clase, pero sí asesoría.

Lectura para el cierre: Athey e Imbens (2019), secciones 1 a 3, para el puente causal con que termina la sesión 8.

Aplicación en R: los mismos puestos: el PCA de la ficha y la U, el PCR con el juez, las cuatro Colombias, la red de una unidad, la grilla de unidades y *decay*, las semillas y la carrera.

Referencias esenciales

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. Caps. 10 y 12. [ISL]
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data—or Tears. *Demography*, 38(1), 115–132.
- Jean, N., Burke, M., Xie, M., Davis, W., Lobell, D., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? *NeurIPS Datasets and Benchmarks*.
- Dell, M. (2025). Deep Learning for Economists. *Journal of Economic Literature*, 63(1), 5–58.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep Learning. *Nature*, 521, 436–444.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Caps. 6 a 9.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

7 Apéndice: para profundizar

A1. PCA es un problema de autovalores

Sea Σ la matriz de covarianza ($p \times p$) de las columnas centradas (y estandarizadas). La PC1 resuelve

$$\max_{\phi} \phi' \Sigma \phi \quad \text{sujeto a} \quad \phi' \phi = 1.$$

1. **Lagrangiano:** $\mathcal{L}(\phi, \lambda) = \phi' \Sigma \phi - \lambda (\phi' \phi - 1)$.

2. **Condición de primer orden:** $2\Sigma\phi - 2\lambda\phi = 0 \implies \boxed{\Sigma\phi = \lambda\phi}$: ϕ es un **autovector** de Σ .

3. **¿Cuál?** La varianza de la proyección es $\phi' \Sigma \phi = \lambda \phi' \phi = \lambda$: la PC1 es el autovector del **mayor** autovalor; la PC2, el del segundo (la ortogonalidad sale gratis porque Σ es simétrica), y así sucesivamente. La PVE de la componente m es $\lambda_m / \sum_k \lambda_k$.

4. **En la práctica**, prcomp usa la descomposición en valores singulares de la matriz centrada, $X = UDV'$: las columnas de V son las cargas, UD los puntajes, y d_m^2/n las varianzas. Truncar la suma en M términos da la mejor aproximación de rango M (Eckart y Young, 1936): la “otra cara” del cuerpo.

A2. Agrupamiento jerárquico y mezclas de normales

- **Por qué cada paso de k -medias baja el objetivo:** en el paso (a), la media es la constante que minimiza la suma de cuadrados dentro de cada grupo; en el (b), mover un puesto al centroide más cercano sólo puede reducir su distancia. El objetivo nunca sube y hay finitas particiones: el algoritmo termina.
- **Jerárquico aglomerativo** (ISL 12.4.2): empezar con n grupos de un puesto y fusionar en cada paso los dos más cercanos. El **dendrograma** muestra todas las resoluciones a la vez; cortarlo a una altura es elegir K después de ver la estructura. “Cercanos” lo define el *linkage* (completo, promedio, Ward). Cuesta del orden de n^2 distancias.
- **Mezclas de normales:** los datos vienen de K normales con pesos π_k ; cada puesto recibe una **probabilidad** de pertenecer a cada grupo (algoritmo EM). Permite grupos alargados y de tamaños distintos; k -medias es el caso límite de varianzas iguales que tienden a cero.
- **Mapas no lineales** (t-SNE, UMAP): sirven para *mirar* datos de alta dimensión; las distancias globales y el tamaño de los grupos en el mapa no significan nada.

A3. Retropropagación: la derivación con una capa oculta

El modelo (regresión, pérdida cuadrática de una observación):

$$z_k = w_{k0} + \sum_j w_{kj} x_j, \quad A_k = g(z_k), \quad f = \beta_0 + \sum_k \beta_k A_k, \quad R = \frac{1}{2} (y - f)^2.$$

1. **La capa de salida:** $\frac{\partial R}{\partial \beta_k} = -(y - f) A_k$: el residuo, repartido según cuánto se activó cada unidad.
2. **La capa oculta,** por la regla de la cadena a través de f y de g :

$$\frac{\partial R}{\partial w_{kj}} = \frac{\partial R}{\partial f} \cdot \frac{\partial f}{\partial A_k} \cdot \frac{\partial A_k}{\partial z_k} \cdot \frac{\partial z_k}{\partial w_{kj}} = -(y - f) \beta_k g'(z_k) x_j.$$

3. **Hacia atrás:** el “error” de la unidad k es $\delta_k = -(y - f) \beta_k g'(z_k)$, y todos sus gradientes son $\delta_k x_j$. Con más capas, el mismo paso se repite capa por capa, de la salida hacia la entrada, reutilizando los δ ya calculados.

Con ReLU, $g'(z) = \mathbb{I}\{z > 0\}$: el error sólo fluye por las unidades activas. Con la sigmoide, $g'(z) = g(z)(1 - g(z))$, casi cero en las colas: el gradiente se desvanece.

A4. Descenso de gradiente estocástico, momento y Adam

Mini-lotes: en vez de sumar el gradiente sobre los n datos, se usa un lote de 32 a 256 en cada paso; una **época** es una pasada completa. Ruidoso pero barato, y el ruido ayuda a salir de valles malos.

Momento: moverse en la dirección de una media móvil del gradiente,

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad \theta_t = \theta_{t-1} - \rho m_t.$$

Adam (Kingma y Ba, 2015): además escala el paso de cada parámetro por su propia volatilidad,

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad \theta_t = \theta_{t-1} - \rho \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}},$$

con $\hat{m}_t = m_t / (1 - \beta_1^t)$ y $\hat{v}_t = v_t / (1 - \beta_2^t)$. Los valores de siempre: $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\rho \approx 10^{-3}$.

- **nnet**, el paquete de la aplicación, no usa lotes: optimiza con BFGS (un cuasi-Newton) sobre todos los datos, lo razonable para redes de cientos de pesos. Las redes de millones usan Adam.

A5. La aritmética de una capa convolucional

Tamaño de la salida. Una imagen de $n \times n$, un filtro de $k \times k$, relleno p y paso s producen un mapa de lado

$$\left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1.$$

Con 224×224 , $k = 3$, $p = 1$ y $s = 1$ la salida sigue siendo de 224×224 ; un *pooling* de 2×2 la baja a 112×112 .

Parámetros. Una capa con F filtros de $k \times k$ sobre una entrada de C canales tiene $F(k^2 C + 1)$ pesos, *sin importar el tamaño de la imagen*. Sesenta y cuatro filtros de 3×3 sobre una foto a color: $64 \times (27 + 1) = 1.792$ pesos. La capa densa equivalente sobre $224 \times 224 \times 3$ entradas y 64 salidas tendría unos 9,6 millones.

ResNet50: unos 25 millones de parámetros y 50 capas con “atajos” que suman la entrada de cada bloque a su salida, para que el gradiente no se desvanezca. Su penúltima capa tiene 2.048 números por imagen: las variables del *transfer learning*.

A6. Aproximación universal: qué dice y qué no

El teorema (Cybenko, 1989; Hornik, 1991). Si g no es un polinomio (la sigmoide, ReLU), para toda función continua f sobre un compacto y todo $\varepsilon > 0$ existen K y pesos tales que

$$\sup_x \left| f(x) - \sum_{k=1}^K \beta_k g(w'_k x + b_k) \right| < \varepsilon.$$

- **Es un resultado de densidad**, como el de Weierstrass para los polinomios. No dice cuántas unidades hacen falta (K puede crecer exponencialmente con p), ni que el descenso de gradiente las encuentre, ni nada sobre el error de prueba.
- **La profundidad**: hay funciones que una red profunda representa con pocas unidades y una de una capa necesita exponencialmente muchas (Telgarsky, 2016): la composición reutiliza piezas.
- **La analogía con la semana 2**: los *splines* también aproximan cualquier función suave con nodos fijos; la red aprende *dónde* poner los nodos y en qué combinaciones de variables.

Referencias del apéndice y otras citadas

- Eckart, C., & Young, G. (1936). The Approximation of One Matrix by Another of Lower Rank. *Psychometrika*, 1(3), 211–218. [A1]
- Rousseeuw, P. J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *JMLR*, 15, 1929–1958.
- Kingma, D., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *ICLR*. [A4]
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR*. [A5]
- Cybenko, G. (1989). Approximation by Superpositions of a Sigmoidal Function. *Mathematics of Control, Signals and Systems*, 2, 303–314. [A6]
- Hornik, K. (1991). Approximation Capabilities of Multilayer Feedforward Networks. *Neural Networks*, 4(2), 251–257. [A6]
- Telgarsky, M. (2016). Benefits of Depth in Neural Networks. *COLT*. [A6]