

Big Data y Machine Learning para Economía Aplicada

Week 08: Los papers y la síntesis del caso

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 25, 2026

Previously... y hoy

- Siete sesiones, un caso (los puestos de votación de 2022) y un mismo flujo de trabajo, de la partición al reporte de dónde falla.
- La semana pasada, representar: lo que más varía no es lo que predice. La PC1 del censo se lleva el 32,0 % de su varianza y explica el 0,9 % del voto.
- La pregunta que no cambió: no cuál es el efecto de X sobre Y , sino **qué tan bien podemos predecir Y y de qué depende**. Hoy se responde.

8:05–9:35	Seis papers, seis presentaciones de 15 minutos
9:35–9:45	Descanso
9:45–10:10	La síntesis del caso
10:10–10:50	<i>Pitches</i> del proyecto: la idea en una página
10:50–11:00	Cierre opcional: el puente causal, con nuestros datos

Hoy no hay método nuevo

Hoy se usan todos. Cada paper responde las mismas siete preguntas; la síntesis es verlas juntas.

- 1 Las presentaciones
- 2 La síntesis del caso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

Seis áreas de la economía, seis papers

Cada equipo eligió su área y su paper el 22 de septiembre [elegidos y presentadores: por completar tras la sesión 2]

Área	Opción 1	Opción 2
Economía política	Kim & Zilinsky (2024, <i>Political Behavior</i>)	Bazzi et al. (2022, <i>REStat</i>)
Crimen y justicia	Kleinberg et al. (2018, <i>QJE</i>)	Angelova, Dobbie & Yang (2026, <i>REStud</i>)
Salud	Mullainathan & Obermeyer (2022, <i>QJE</i>)	Einav et al. (2018, <i>Science</i>)
Desarrollo y pobreza	Aiken et al. (2023, <i>Nature</i>)	Haushofer et al. (2025)
Trabajo y educación	Hoffman, Kahn & Li (2018, <i>QJE</i>)	Chalfin et al. (2016, <i>AER P&P</i>)
Finanzas y crédito	Fuster et al. (2022, <i>J. Finance</i>)	Dobbie et al. (2021, <i>REStat</i>)
Macro y pronóstico	Medeiros et al. (2021, <i>JBES</i>)	Goulet Coulombe et al. (2022)
IO y demanda	Dubé & Misra (2023, <i>JPE</i>)	Bandiera et al. (2020, <i>JPE</i>)

Seis de estas áreas tienen dueño desde la sesión 2; el menú completo, con resúmenes, está en el índice de literature/. Hoy los papers entran por primera vez al curso como protagonistas: hasta aquí, el caso fue el único hilo.

El guion de los 15 minutos, y cómo se evalúa (10% del curso)

El guion (doce minutos de presentación, tres de preguntas):

- 1 La pregunta y la decisión que depende de la predicción.
- 2 Los datos y la unidad de observación; qué se sabe en el momento de predecir.
- 3 La referencia contra la que se mide.
- 4 Cómo se evalúa fuera de muestra, y dónde falla el modelo.
- 5 El resultado principal, en sus unidades.
- 6 Qué método del curso es, y qué habríamos hecho distinto.

Se califica la lectura, no el diseño:

- **Precisión:** qué se predice, con qué datos, contra qué referencia y en qué prueba; un número principal con sus unidades.
- **Protocolo:** partición y validación; si respetan tiempo, espacio y grupos; dónde pudo haber filtración.
- **Interpretación y crítica:** qué dice el modelo y qué no; si alguna conclusión trata una importancia como un efecto; qué habríamos hecho distinto.

Doce minutos son doce minutos, y las preguntas se responden con el paper en la mano.

Mientras escuchan: la ficha de cada paper

Una fila por paper: es el insumo de la síntesis y el modelo de lo que su proyecto debe responder.


Campo	La pregunta
y y unidad	¿Qué se predice y para quién (persona, puesto, país-año, aldea)?
Decisión	¿Qué cambia si la predicción es buena? ¿Quién la usa?
Referencia	¿Contra qué se compara: la media, una regla simple, el juez, las luces nocturnas?
Validación	¿Partición, CV, reserva, pronóstico recursivo? ¿Respetar el tiempo, el espacio y los grupos?
Método	¿Qué familia del curso, y por qué esa?
Caja abierta	¿Qué herramienta de la sesión 6 usan, y qué afirman con ella?
Dónde falla	¿Para quién, cuándo y fuera de qué rango se degrada?

Si un campo queda vacío, esa es la pregunta para el presentador. Cada presentación termina con una pregunta de la sala sobre el punto 4 o el punto 6 del guion: prepárenla mientras escuchan.

- 1 Las presentaciones
- 2 La síntesis del caso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

La pregunta del curso, respondida: de 26,7 a 11,4

Cada escalón agrega una cosa, en el orden en que la agregó el curso; los mismos 2.398 puestos de prueba



- De los 15,3 puntos que se le ganaron a la media, 11,1 (el 73 %) los puso la **información** —el censo y el lugar—, 2,8 la **flexibilidad** —los cruces, a mano o de la máquina— y 1,4 **combinar dos modelos** que se equivocan distinto. La clasificación sube por la misma escalera (la AUC, debajo).
- El reparto depende del orden, como el de Shapley (sesión 6): con la ficha sola, el *boosting* ya le gana 4,1 puntos a la recta (15,7 contra 19,8).

La tabla del curso: información y flexibilidad

RMSE de prueba del voto por Petro: bajar una fila agrega información; moverse a la derecha, flexibilidad


Ingredientes	Lineal	Árbol	Bosque	Boosting	Red	Vecinos
La ficha (37 columnas)	19,8	19,1	15,6	15,7	16,9	
+ departamento	15,6	15,7	12,9	12,8	13,6	
y cruces a mano (Lasso)	14,7					
El mapa (coordenadas)		13,7				12,0
Todo junto		14,4	12,1	12,1	13,2	

La referencia, la media: 26,7. El mejor del curso, el promedio del *boosting* sin mapa y los vecinos: **11,4** (con la red, 11,5).

- **Bajar una fila vale tanto como moverse a la derecha:** el departamento en línea recta (15,6) deja lo mismo que un bosque sin él (15,6).
- **Con el mapa, las familias se juntan** (bosque y *boosting* 12,1, vecinos 12,0) y la red queda atrás (13,2): en datos tabulares mandan los árboles (sesión 7).
- **En ¿gana Petro?, la misma escalera:** la AUC de la ficha lineal es 0,851; con el departamento, 0,916; bosque y *boosting*, 0,943 y 0,941; con el mapa, 0,950; el promedio, 0,954.

¿La estructura viaja? A municipios nuevos

El mismo juez de diez pliegues: los puestos repartidos al azar o municipios enteros fuera (sesiones 3 y 5)



- **Todos pierden, y más quien más se apoyaba en los vecinos:** el k -NN en el mapa (+3,0) cae del segundo al tercer lugar y el *boosting* con coordenadas le gana. El promedio sigue primero (14,0).
- Cada esquema responde su pregunta: el azar, “¿qué tal en puestos como los que ya vi?”; los municipios enteros, “¿qué tal en un municipio nuevo?”.

¿La estructura viaja? A otros grupos y a otro año

- **A otros lugares, no:** la recta campeona de Cali (sesión 2) no viajó al resto del Valle ni al país, donde la educación sola explica el 0,04 % del voto.
- **A otros grupos, a medias** (el *boosting* que se abrió en la sesión 6): el error rural (14,9) es 1,6 veces el de las cabeceras (9,3); por departamento va de 7,4 en Atlántico a 26,9 en Guaviare (7 puestos); y los extremos se comprimen: donde Petro sacó menos de 20, el modelo predice 20,1 (el real, 12,5).
- **A otro año, a medias:** el voto de 2018 *ordena* casi perfecto (AUC 0,95) pero *decide* con un corte viejo (84,3 % de acierto). Y cuál elección es “más predecible” depende de la métrica: la exactitud dice 2010 (0,901 contra 0,832); la AUC, 2022 (0,906 contra 0,878).

La frase que resume el caso

La predictibilidad es una propiedad *del territorio y del momento*, no del algoritmo. En sus proyectos: digan *a qué* quieren que viaje el modelo —otros lugares, otros grupos, otro año— y validen eso.

El flujo de trabajo, con nombre propio

Cada paso del *pipeline*, con la semana del caso que lo dejó grabado:

Paso	Dónde lo vivimos
1. Partir	S2–S3: la partición fija (9.602 y 2.398); la prueba, una vez por semana
2. Preprocesar en el pliegue	S3: el voto municipal calculado con todos prometía 11,2 y valía 13,0; S7: el PCA en cada pliegue
3. Validar según la estructura	S3 y S5: al azar contra municipios enteros
4. Afinar en el entrenamiento	S3–S7: λ , k , la poda, m , las rondas, las unidades, por CV u OOB
5. Evaluar contra la referencia	S2–S4: la media y “gana donde ganó en 2018”
6. Interpretar con advertencias	S6: permutación, ablación, PDP y SHAP le preguntan al modelo
7. Reportar dónde falla	S6: rural o cabecera, los extremos, un departamento u otro

Para el proyecto: estos siete pasos son las secciones del documento del 24 de noviembre. Los papers de hoy son la prueba de que el mismo flujo sostiene un artículo publicable.

El curso en una diapositiva

- 1 **Y, no β .** Predecir y explicar son preguntas distintas; el error de entrenamiento es optimista.
- 2 **La recta como máquina de predecir:** la referencia, la tabla canónica, predicho contra observado, el error por subgrupos; y la recta no viaja.
- 3 **El juez y la perilla:** la validación cruzada decide cuánta complejidad; Ridge divide, Lasso resta, y el Lasso selecciona predictores, no causas.
- 4 **Clasificar es estimar una probabilidad y decidir:** el modelo ordena, la calibración dice si creerle y los costos fijan el umbral.
- 5 **Partir, promediar y corregir:** los árboles encuentran solos los cruces; promediar y sumar en secuencia arregla su varianza.
- 6 **Abrir la caja:** importancia, dependencia parcial y Shapley le preguntan al modelo, no al mundo.
- 7 **Representar es comprimir con sentido:** lo que más varía no es, necesariamente, lo que predice.

Las reglas de oro, por última vez

#1 El error de entrenamiento es optimista. #2 La prueba se usa una sola vez. #3 El CV valida *pipelines* enteros. #4 La referencia es lo que la decisión haría sin el modelo (“gana donde ganó en 2018”).

- 1 Las presentaciones
- 2 La síntesis del caso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

La idea en una página y el *pitch* de cinco minutos

Entrega 1 del proyecto: 10 de los 100 puntos

La página (enviada antes de clase) responde tres cosas:

- 1 **La pregunta y la decisión** que la motiva: quién usaría la predicción y qué haría distinto con ella.
- 2 **La unidad y la y:** qué se predice exactamente, para qué unidad y en qué momento.
- 3 **Los datos candidatos:** fuente, tamaño aproximado, disponibilidad, y qué se sabría *en el momento de predecir*.

El pitch: cinco minutos, sin más de tres diapositivas, seguidos de dos minutos de retroalimentación de la sala.

Las tres preguntas que la sala hace siempre

¿Qué decisión cambia con la predicción? ¿Qué información existe en el momento de predecir, y cuál es filtración disfrazada? ¿Contra qué referencia y con qué prueba se sabrá si funcionó?

Una propuesta que no sobrevive a esas tres preguntas hoy es mejor que una que las descubre el 24 de noviembre.

De la idea al documento del 24 de noviembre

Entrega 2: un documento de máximo 8 páginas (50 puntos) y una presentación de 20 minutos (40 puntos)

Las secciones del documento, que son los pasos del flujo de trabajo:

- ❶ La pregunta y la decisión.
 - ❷ Los datos: fuente, unidad, tamaño, predictores por bloques, qué se sabría al predecir.
 - ❸ Métrica, referencia y estrategia de validación acorde con la estructura de los datos (grupos, tiempo, espacio).
 - ❹ Los métodos que se compararían y por qué: al menos dos familias del curso.
 - ❺ Qué se interpretaría y qué no.
 - ❻ Riesgos: filtración, extrapolación, cambio de régimen, equidad si hay personas.
 - ❼ Plan de trabajo.
-
- Es una **propuesta**, no un informe: no se piden resultados, se pide un diseño que resista las siete preguntas. Una tabla preliminar suma, pero no reemplaza el diseño.
 - **[Individual o en parejas: por definir.]** La presentación del 24 de noviembre dura 20 minutos más 10 de preguntas.

- 1 Las presentaciones
- 2 La síntesis del caso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

El puente causal (I): cuándo una máquina de predecir ayuda a estimar un β

El modelo parcialmente lineal: $y = \theta d + g(x) + \varepsilon$, donde θ es el efecto de interés, d el tratamiento y x muchos controles con forma desconocida.

- **Lo que no funciona:** un Lasso de y sobre (d, x) y leer el coeficiente de d . La penalización sesga $\hat{\theta}$ y omite controles que importan poco para y pero mucho para d : el Lasso selecciona predictores, no causas (sesión 3).
- **Doble selección** (Belloni, Chernozhukov & Hansen, 2014): seleccionar los controles que predicen y y los que predicen d , unirlos y correr OLS con todos. La máquina elige controles; la inferencia es OLS.

La división del trabajo

El ML predice las *molestias* (la parte de y y de d que explican los controles); el economista aporta el supuesto de identificación (que x basta). Sin ese supuesto, ningún algoritmo convierte un predictor en una causa.

El puente causal (II): residuos sobre residuos

Double machine learning (Chernozhukov et al., 2018)


Predecir y con x y d con x con *cualquier* método del curso, en pliegues cruzados, y regresar un residuo sobre el otro:

$$\hat{\theta} = \frac{\sum_i (d_i - \hat{m}(x_i))(y_i - \hat{\ell}(x_i))}{\sum_i (d_i - \hat{m}(x_i))^2}, \quad \hat{m}(x) \approx \mathbb{E}[d \mid x], \quad \hat{\ell}(x) \approx \mathbb{E}[y \mid x].$$

- **Es Frisch–Waugh–Lovell con otras máquinas:** con $\hat{m}$ y $\hat{\ell}$ lineales, $\hat{\theta}$ es el OLS con controles. Con un *boosting*, los controles entran con la forma que los datos pidan.
- **Cross-fitting:** cada residuo viene de un modelo que *no vio* ese puesto (el CV de la sesión 3, al servicio de un β); y el estimador es insensible, a primer orden, a errores pequeños en las dos predicciones (apéndice A1).
- **Con nuestros datos:** ¿los puestos más grandes tienen menos participación? d = log de los registrados; y = participación; x = la composición del entorno (32 columnas de la ficha), el departamento y las coordenadas.

El puente causal (III): ¿los puestos grandes votan menos?

11.984 puestos; errores estándar agrupados por municipio; R^2 fuera del pliegue





	$\hat{\theta}$	R^2 : participación	R^2 : tamaño
Sin controles	+0,68 (0,35)		
OLS, controles en línea recta	-1,67 (0,29)	0,44	0,72
DML con <i>boosting</i>	-2,32 (0,28)	0,55	0,89

- Duplicar el tamaño de un puesto, a igual entorno: unos 1,6 puntos menos de participación. El *boosting* predice mejor el tamaño (0,89 contra 0,72) y el efecto se aleja de la recta.
- **Pregunta para la sala:** ¿qué historia daría el mismo signo sin que el tamaño cause nada?

El puente causal (III): ¿los puestos grandes votan menos?

11.984 puestos; errores estándar agrupados por municipio; R^2 fuera del pliegue



	$\hat{\theta}$	R^2 : participación	R^2 : tamaño
Sin controles	+0,68 (0,35)		
OLS, controles en línea recta	-1,67 (0,29)	0,44	0,72
DML con <i>boosting</i>	-2,32 (0,28)	0,55	0,89

- Duplicar el tamaño de un puesto, a igual entorno: unos 1,6 puntos menos de participación. El *boosting* predice mejor el tamaño (0,89 contra 0,72) y el efecto se aleja de la recta.
- **Pregunta para la sala:** ¿qué historia daría el mismo signo sin que el tamaño cause nada? Inscritos que ya no viven allí inflan los registrados y bajan la participación por construcción. El DML no lo arregla: es identificación, no predicción (A3).

Lo que queda del semestre

Martes 10 de noviembre	Sin clase. Entrega del Problem Set 2 a las 11:59 p. m. Asesoría opcional en el horario de clase para el problem set y el proyecto.
Martes 17 de noviembre	Sin clase.
Martes 24 de noviembre	Entrega 2 del proyecto: el documento, ese mismo día. Presentaciones de 20 minutos más preguntas. Quince minutos iniciales con el ranking del Problem Set 2 y el cierre del curso.

Para el documento: los siete pasos de hoy, las fichas que llenaron esta mañana y los tres papers más cercanos a su pregunta como modelo de reporte. Las carreras de caballos del proyecto (Gu, Kelly & Xiu, 2020; Medeiros et al., 2021) son la lectura para quien compare muchas familias.

Para el Problem Set 2: con la sesión 7 ya está todo lo que necesitan. El modelo final del curso se elige por validación, se reajusta con todo el entrenamiento y se prueba una vez.

Referencias esenciales

- Los papers del menú de áreas están en `literature/`, organizados por carpeta, con el índice (`indice.csv`): autores, revista, métodos y por qué están en el curso.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *JEP*, 28(2), 29–50.
- Chernozhukov, V., et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests. *JASA*, 113(523), 1228–1242.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *RFS*, 33(5), 2223–2273. [Modelo de carrera de caballos para el proyecto.]
- Medeiros, M., Vasconcelos, G., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment. *JBES*, 39(1), 98–119.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

5 Apéndice: para profundizar

A1. Por qué residuos sobre residuos funciona

Frisch–Waugh–Lovell, sin fórmula: el coeficiente de d es el mismo si primero se le quita a y y a d lo que x explica de cada uno y luego se regresa un residuo sobre el otro. Con g lineal eso es OLS; con g desconocida hay que *predecir* $\mathbb{E}[y \mid x]$ y $\mathbb{E}[d \mid x]$, y ahí entra el curso.

Dos ingredientes de Chernozhukov et al. (2018):

- ❶ **Ortogonalidad de Neyman.** El estimador es insensible, a primer orden, a errores pequeños en $\hat{m}$ y $\hat{\ell}$: los errores de las dos predicciones se multiplican entre sí, y el producto de dos cosas pequeñas es más pequeño. Basta con que las máquinas converjan más rápido que $n^{-1/4}$, no con que sean perfectas.
- ❷ **Cross-fitting.** Si $\hat{m}$ y $\hat{\ell}$ se ajustan con las mismas observaciones que luego estiman θ , el sobreajuste de la máquina se cuela en $\hat{\theta}$. Se parte la muestra en K pliegues y las molestias de cada pliegue se predicen con modelos ajustados en los otros: la regla de oro #3.
- **Bosques causales** (Wager & Athey, 2018): árboles “honestos” (una submuestra elige los cortes, otra estima el efecto en cada hoja) para efectos heterogéneos $\theta(x)$. Con supuesto de identificación, siempre.

A2. El puente, por dentro: la muestra, los controles y las molestias

- **La muestra:** de los 12.000 puestos salen 16 con más votos que habilitados (ninguno con más de 97 registrados): son errores de registro, no participación.
- **Los controles** (67 columnas): la composición del entorno (educación, edad, etnia, servicios, estrato, hogares, distancia, ruralidad), el departamento y las coordenadas. Fuera las columnas de tamaño —población, viviendas y manzanas, con correlación 0,91 con d — y el desfase entre la población en edad de votar y los registrados, que está hecho con el tratamiento: controlarlas sería controlar por d .
- **Las molestias:** el *boosting* de la sesión 5 ($d = 6$, $\eta = 0,05$), con las rondas de un juez de cinco pliegues dentro de cada entrenamiento (entre 252 y 604); 60 ajustes en total. Cinco particiones distintas dan de $-2,35$ a $-2,22$; se reporta la mediana, $-2,32$ (ee 0,28 agrupado por municipio; 0,22 sin agrupar). Con molestias lineales, el mismo DML da $-1,70$: la recta con controles.

A3. El puente, por dentro: lo que mueve el número

- **Los 16 puestos que salieron:** con ellos, OLS da $-2,14$ y el DML $-3,46$. 16 de 12.000 puestos mueven el DML en 1,1 puntos: mirar los datos antes de estimar.
- **Los puestos mucho más chicos de lo que su entorno predice** (el 5 % con menor $d - \hat{m}(x)$: 600 puestos, mediana de 105 registrados, el 80 % rurales, participación de 62,1 contra 58,2): sin ellos, el DML da $-1,59$. Son el primer punto de la figura.
- **El signo resiste; la magnitud, no del todo:** depende de pocos puestos pequeños. Esa fragilidad es de los datos, no del método.
- **La historia rival** (la pregunta para la sala): el desfase mediría a los inscritos que ya no viven allí, pero está hecho con el tratamiento. Ningún control disponible la descarta: por eso la identificación es un supuesto.