

Big Data y Machine Learning para Economía Aplicada

Week 08: Los papers y la síntesis — seis presentaciones, el mapa del
curso y los *pitches*

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 20, 2026

Previously... y hoy

- Siete sesiones, un caso (los puestos de votación de 2022) y un mismo flujo de trabajo: partir, preprocesar en el *pipeline*, validar, afinar, evaluar contra una referencia, interpretar con advertencias, reportar dónde falla.
- Seis familias de métodos: la recta y sus parientes, la penalización, la logística, los árboles y sus ensambles, las representaciones sin y (PCA, *k*-medias) y con y (redes).
- Y una pregunta que no cambió: no cuál es el efecto de *X* sobre *Y*, sino **qué tan bien podemos predecir *Y* y de qué depende esa capacidad.**

8:05–9:35	Seis papers, seis presentaciones de 15 minutos
9:35–9:45	Descanso
9:45–10:10	Síntesis: el mapa de los papers, los métodos y el flujo de trabajo
10:10–10:50	<i>Pitches</i> del proyecto: la idea en una página, cinco minutos cada uno
10:50–11:00	Cierre opcional: el puente causal en una diapositiva

Hoy no hay método nuevo

Hoy se usan todos. Cada paper es una respuesta a las mismas siete preguntas; la síntesis es verlas juntas.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

Seis áreas de la economía, seis papers

Cada equipo eligió su área y su paper el 22 de septiembre [elegidos y presentadores: por completar tras la sesión 2]

Área	Opción 1	Opción 2
Economía política	Kim & Zilinsky (2024, <i>Political Behavior</i>)	Bazzi et al. (2022, <i>REStat</i>)
Crimen y justicia	Kleinberg et al. (2018, <i>QJE</i>)	Angelova, Dobbie & Yang (2026, <i>REStud</i>)
Salud	Mullainathan & Obermeyer (2022, <i>QJE</i>)	Einav et al. (2018, <i>Science</i>)
Desarrollo y pobreza	Aiken et al. (2023, <i>Nature</i>)	Haushofer et al. (2025)
Trabajo y educación	Hoffman, Kahn & Li (2018, <i>QJE</i>)	Chalfin et al. (2016, <i>AER P&P</i>)
Finanzas y crédito	Fuster et al. (2022, <i>J. Finance</i>)	Dobbie et al. (2021, <i>REStat</i>)
Macro y pronóstico	Medeiros et al. (2021, <i>JBES</i>)	Goulet Coulombe et al. (2022)
IO y demanda	Dubé & Misra (2023, <i>JPE</i>)	Bandiera et al. (2020, <i>JPE</i>)

Seis de estas áreas tienen dueño desde la sesión 2; el menú completo, con resúmenes, está en el índice de literature/. Hoy los papers entran por primera vez al curso como protagonistas: hasta aquí, el caso fue el único hilo.

El guion de los 15 minutos, y cómo se evalúa (10% del curso)

El guion (doce minutos de presentación, tres de preguntas):

- 1 La pregunta y la decisión que depende de la predicción.
- 2 Los datos y la unidad de observación; qué se sabe en el momento de predecir.
- 3 La referencia contra la que se mide.
- 4 Cómo se evalúa fuera de muestra, y dónde falla el modelo.
- 5 El resultado principal, en sus unidades.
- 6 Qué método del curso es, y qué habríamos hecho distinto.

Se califica la lectura, no el diseño:

- **Precisión:** qué se predice, con qué datos, contra qué referencia y en qué prueba; un número principal con sus unidades.
- **Protocolo:** partición y validación; si respetan tiempo, espacio y grupos; dónde pudo haber filtración.
- **Interpretación y crítica:** qué dice el modelo y qué no; si alguna conclusión trata una importancia como un efecto; qué habríamos hecho distinto.

Doce minutos son doce minutos, y las preguntas se responden con el paper en la mano.

Mientras escuchan: la ficha de cada paper

Una fila por paper: es el insumo de la síntesis y el modelo de lo que su proyecto debe responder.

Campo	La pregunta
y y unidad	¿Qué se predice y para quién (persona, mesa, país—año, aldea)?
Decisión	¿Qué cambia si la predicción es buena? ¿Quién la usa?
Referencia	¿Contra qué se compara: la media, una regla simple, el juez, las luces nocturnas?
Validación	¿Partición, CV, reserva, pronóstico recursivo? ¿Respetar el tiempo, el espacio y los grupos?
Método	¿Qué familia del curso, y por qué esa?
Caja abierta	¿Qué herramienta de la sesión 6 usan, y qué afirman con ella?
Dónde falla	¿Para quién, cuándo y fuera de qué rango se degrada?

Si un campo queda vacío, esa es la pregunta para el presentador. Cada presentación termina con una pregunta de la sala sobre el punto 4 o el punto 6 del guion: prepárenla mientras escuchan.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

La síntesis (I): el caso, cerrado. La tabla final del líder

Siete semanas, una pregunta doble, los mismos 2.398 puestos de prueba

Sem.	Modelo	Voto (RMSE)	¿Gana? (AUC)
2	la media / "gana en todos"	26,7	0,500
2	recta (educación superior)	26,7	0,526
2-4	las nueve variables	22,9	0,763
3-4	la ficha de 37	19,8	0,851
3-4	ficha + departamentos	15,6	0,916
3-4	mejor lineal (Lasso / penalizada, ficha larga)	14,7	0,937
7	red neuronal (mejor de tres semillas)	13,2	
2-4	<i>k</i> -NN en el mapa	12,1	0,945
5	<i>boosting</i> + coordenadas	12,2	0,950
5	bosque + coordenadas	12,1	0,951

- **La respuesta del curso:** el entorno censal y la ubicación predicen el voto de un puesto con un error de 12 puntos y ordenan ganadores 95 de cada 100 veces. La mitad del camino la hizo la *información* (de la recta a la ficha larga); la otra mitad, la *flexibilidad* (del lineal al bosque).
- Y la vara sin modelo: "gana donde ganó en 2018" acierta el 84%; el líder, el 88–89%. Los modelos compiten también contra la historia.

La síntesis (II): ¿la estructura viaja?

Lo que el caso enseñó sobre la pregunta más difícil: predecir fuera de la muestra que se conoce

- **En el espacio, a medias:** la recta de Cali no viajó al Valle rural ni al país (R^2 0,0004). Con la ficha nacional y el mapa sí hay estructura general... que se degrada donde el censo dice poco: el error rural (14,4) dobla al urbano (8,6).
- **En los grupos:** la CV al azar prometía 12,3 para los vecinos del mapa; en municipios nunca vistos valen 15,3. Cada esquema de validación responde su pregunta.
- **En el tiempo, a medias:** el modelo de 2018 aplicado a 2022 pierde 3,8 puntos de RMSE, y buena parte es un **salto de nivel** (Petro subió 9 puntos): corrigiéndolo queda a 1,6 del modelo propio. Y la regla “gana donde ganó en 2018” *ordena* casi perfecto (AUC 0,95) pero *decide* con un corte viejo.
- **La lección para sus proyectos:** digan siempre *a qué* quieren que viaje su modelo (otros lugares, otros grupos, otro año) y validen *eso*. Un solo número de CV no responde tres preguntas.

La frase que resume el caso

La predictibilidad es una propiedad *del territorio y del momento*, no del algoritmo: el mismo bosque que acierta en Atlántico (6,6) no sabe nada de Guaviare (24,9).

El flujo de trabajo, con nombre propio

Cada paso del *pipeline*, con la semana del caso que lo dejó grabado:

Paso	Dónde lo vivimos
1. Partir	S2–S3: la partición fija 80/20; la prueba se abrió una vez por semana
2. Preprocesar en el pliegue	S3: el voto promedio del municipio, mal hecho, prometía 11,3 y valía 13,0
3. Validar según la estructura	S3: al azar vs. por municipio vs. 2018 → 2022
4. Afinar en el entrenamiento	S3 y S5: λ , k , cp , $mtry$ y las rondas, por CV u OOB
5. Evaluar contra la referencia	S2 y S4: la media, y “gana donde ganó en 2018”
6. Interpretar con advertencias	S6: permutación, ablación, SHAP; nada de eso es un efecto
7. Reportar dónde falla	S6: rural vs. urbano, la compresión, Guaviare vs. Atlántico

Para el proyecto: estos siete pasos son las secciones del documento del 24 de noviembre. Y los papers de hoy son la prueba de que el mismo flujo sostiene un artículo publicable.

El curso en una diapositiva

- 1 **Y, no β .** Predecir y explicar son preguntas distintas; el error de entrenamiento es optimista.
- 2 **La recta como máquina de predecir:** la referencia, la tabla canónica, predicho contra observado, el error por subgrupos.
- 3 **El pipeline honesto:** el CV valida *pipelines*; cada esquema responde su pregunta; Ridge y Lasso encogen, y el Lasso selecciona predictores, no causas.
- 4 **Clasificar es decidir:** la probabilidad, el umbral con costos, el AUC y la calibración.
- 5 **Los árboles** encuentran solos lo que nadie escribió; promediar y sumar en secuencia arregla su varianza; la tabla decide.
- 6 **Abrir la caja:** importancia, dependencia parcial, Shapley; describen el modelo, no el mundo.
- 7 **Representar es comprimir con sentido:** PCA sin y, redes con y, y las representaciones se prestan.

Las reglas de oro, por última vez

#1 El error de entrenamiento es optimista. #2 La prueba se usa una sola vez. #3 El CV valida *pipelines* enteros. Y la que enseñó el caso: #4 la referencia es lo que la decisión haría sin el modelo ("gana donde ganó en 2018").

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

La idea en una página y el *pitch* de cinco minutos

Entrega 1 del proyecto: 10 de los 100 puntos

La página (enviada antes de clase) responde tres cosas:

- 1 **La pregunta y la decisión** que la motiva: quién usaría la predicción y qué haría distinto con ella.
- 2 **La unidad y la y:** qué se predice exactamente, para qué unidad y en qué momento.
- 3 **Los datos candidatos:** fuente, tamaño aproximado, disponibilidad, y qué se sabría *en el momento de predecir*.

El pitch: cinco minutos, sin más de tres diapositivas, seguidos de dos minutos de retroalimentación de la sala.

Las tres preguntas que la sala hace siempre

¿Qué decisión cambia con la predicción? ¿Qué información existe en el momento de predecir, y cuál es filtración disfrazada? ¿Contra qué referencia y con qué prueba se sabrá si funcionó?

Una propuesta que no sobrevive a esas tres preguntas hoy es mejor que una que las descubre el 24 de noviembre.

De la idea al documento del 24 de noviembre

Entrega 2: un documento de máximo 8 páginas (50 puntos) y una presentación de 20 minutos (40 puntos)

Las secciones del documento, que son los pasos del flujo de trabajo:

- ❶ La pregunta y la decisión.
 - ❷ Los datos: fuente, unidad, tamaño, predictores por bloques, qué se sabría al predecir.
 - ❸ Métrica, referencia y estrategia de validación acorde con la estructura de los datos (grupos, tiempo, espacio).
 - ❹ Los métodos que se compararían y por qué: al menos dos familias del curso.
 - ❺ Qué se interpretaría y qué no.
 - ❻ Riesgos: filtración, extrapolación, cambio de régimen, equidad si hay personas.
 - ❼ Plan de trabajo.
-
- Es una **propuesta**, no un informe: no se piden resultados, se pide un diseño que resista las siete preguntas. Una tabla preliminar suma, pero no reemplaza el diseño.
 - **[Individual o en parejas: por definir.]** La presentación del 24 de noviembre dura 20 minutos más 10 de preguntas.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

El puente causal (I): cuándo una máquina de predecir ayuda a estimar un β

El modelo parcialmente lineal: $y = \theta d + g(x) + \varepsilon$, donde θ es el efecto de interés, d el tratamiento y x muchos controles con forma desconocida.

- **Lo que no funciona:** un Lasso de y sobre (d, x) y leer el coeficiente de d . La penalización sesga $\hat{\theta}$ y omite controles que importan poco para y pero mucho para d : el Lasso selecciona predictores, no causas (sesión 3).
- **Doble selección** (Belloni, Chernozhukov & Hansen, 2014; apéndice de la sesión 3): seleccionar los controles que predicen y y los que predicen d , unirlos y correr OLS con todos. La máquina elige controles; la inferencia es OLS.

La división del trabajo

El ML predice las *molestias* (la parte de y y de d que explican los controles); el economista aporta el supuesto de identificación (que x basta). Sin ese supuesto, ningún algoritmo convierte un predictor en una causa.

El puente causal (II): residuos sobre residuos

Double machine learning (Chernozhukov et al., 2018)

Predecir y con x y d con x con *cualquier* método del curso, en pliegues cruzados, y regresar residuo sobre residuo:

$$\hat{\theta} = \frac{\sum_i (d_i - \hat{m}(x_i))(y_i - \hat{\ell}(x_i))}{\sum_i (d_i - \hat{m}(x_i))^2}, \quad \hat{m}(x) \approx \mathbb{E}[d \mid x], \quad \hat{\ell}(x) \approx \mathbb{E}[y \mid x].$$

- **Cross-fitting:** cada residuo viene de un modelo que *no vio* esa observación (el CV de la sesión 3 al servicio de un β); el estimador es insensible, a primer orden, a errores pequeños en las dos predicciones.
- **Con nuestros datos:** ¿los puestos grandes tienen menos participación? Sin controles, +0,4 por unidad de log (los grandes son urbanos). Controlando entorno y lugar: OLS lineal -2,1 (ee 0,14); **DML** con *boosting* y 5 pliegues, **-2,0** (ee 0,39): duplicar el tamaño $\approx 1,4$ puntos menos. Que coincidan dice que aquí las molestias eran casi lineales; la *identificación* (que el entorno baste) sigue siendo un supuesto nuestro, no un resultado.

Para seguir

Athey & Imbens (2019), secciones 1 a 3; **bosques causales** (Wager & Athey, 2018) para efectos heterogéneos. Aquí termina el puente: todo lo demás del semestre fue Y , no β .

Lo que queda del semestre

Martes 10 de noviembre	Sin clase. Entrega del Problem Set 2 a las 11:59 p. m. Asesoría opcional en el horario de clase para el problem set y el proyecto.
Martes 17 de noviembre	Sin clase.
Martes 24 de noviembre	Entrega 2 del proyecto: el documento, ese mismo día. Presentaciones de 20 minutos más preguntas. Quince minutos iniciales con el ranking del Problem Set 2 y el cierre del curso.

Para el documento: los siete pasos de hoy, las fichas que llenaron esta mañana y los tres papers más cercanos a su pregunta como modelo de reporte. Las carreras de caballos del proyecto (Gu, Kelly & Xiu, 2020; Medeiros et al., 2021) son la lectura para quien compare muchas familias.

Para el Problem Set 2: con la sesión 7 ya está todo lo que necesitan. El modelo final del curso se elige por validación, se reajusta con todo el entrenamiento y se prueba una vez.

Referencias esenciales

- Los papers del menú de áreas están en `literature/`, organizados por carpeta, con el índice (`indice.csv`): autores, revista, métodos y por qué están en el curso.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *JEP*, 28(2), 29–50.
- Chernozhukov, V., et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests. *JASA*, 113(523), 1228–1242.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *RFS*, 33(5), 2223–2273. [Modelo de carrera de caballos para el proyecto.]
- Medeiros, M., Vasconcelos, G., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment. *JBES*, 39(1), 98–119.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Working paper. [De donde salen los datos del caso.]

5 Apéndice: para profundizar

A1. Por qué residuos sobre residuos funciona

Frisch–Waugh–Lovell, sin fórmula: el coeficiente de d es el mismo si primero se le quita a y y a d lo que x explica de cada uno y luego se regresa un residuo sobre el otro. Con g lineal eso es OLS; con g desconocida hay que *predecir* $\mathbb{E}[y \mid x]$ y $\mathbb{E}[d \mid x]$, y ahí entra el curso.

Dos ingredientes de Chernozhukov et al. (2018):

- 1 **Ortogonalidad de Neyman.** El estimador es insensible, a primer orden, a errores pequeños en $\hat{m}$ y $\hat{\ell}$: los errores de las dos predicciones se multiplican entre sí, y el producto de dos cosas pequeñas es más pequeño. Basta con que las máquinas converjan más rápido que $n^{-1/4}$, no con que sean perfectas.
- 2 **Cross-fitting.** Si $\hat{m}$ y $\hat{\ell}$ se ajustan con las mismas observaciones que luego estiman θ , el sobreajuste de la máquina se cuela en $\hat{\theta}$. Se parte la muestra en K pliegues y las molestias de cada pliegue se predicen con modelos ajustados en los otros: la regla de oro #3.
- **Bosques causales** (Wager & Athey, 2018): árboles “honestos” (una submuestra elige los cortes, otra estima el efecto en cada hoja) para efectos heterogéneos $\theta(x)$. Con supuesto de identificación, siempre.