

Big Data y Machine Learning para Economía Aplicada

Week 08: Los papers y la síntesis — seis presentaciones, el mapa del
curso y los *pitches*

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 17, 2026

Previously... y hoy

- Siete sesiones y un mismo flujo de trabajo: partir, preprocesar dentro del *pipeline*, validar, afinar, evaluar contra una referencia, interpretar con advertencias, reportar dónde falla.
- Seis familias de métodos: la recta y sus parientes, la penalización, la logística, los árboles y sus ensambles, las representaciones sin y (PCA, *k*-medias) y con y (redes).
- Y una pregunta que no cambió: no cuál es el efecto de X sobre Y , sino **qué tan bien podemos predecir Y y de qué depende esa capacidad**.

8:05–9:35	Seis papers, seis presentaciones de 15 minutos
9:35–9:45	Descanso
9:45–10:10	Síntesis: el mapa de los papers, los métodos y el flujo de trabajo
10:10–10:50	<i>Pitches</i> del proyecto: la idea en una página, cinco minutos cada uno
10:50–11:00	Cierre opcional: el puente causal en una diapositiva

Hoy no hay método nuevo

Hoy se usan todos. Cada paper es una respuesta a las mismas siete preguntas; la síntesis es verlas juntas.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

Los seis papers, en el orden del curso

Elegidos el 22 de septiembre [quién presenta cada uno: por asignar]

Paper	Qué predice	Dialoga con
1 Kim & Zilinsky (2024), <i>Political Behavior</i>	el voto y el partido con cinco variables demográficas	sesiones 1–2
2 Bogin & Shui (2020), <i>J. Real Estate Finance and Economics</i>	avalúos de vivienda rural: hedónico contra bosque y <i>boosting</i>	sesiones 2 y 5
3 Blumenstock, Cadamuro & On (2015), <i>Science</i>	riqueza y pobreza con metadatos de celulares	sesión 3
4 Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018), <i>QJE</i>	el riesgo de no comparecer y las decisiones de los jueces	sesión 4
5 Bluwstein, Buckmann, Joseph, Kapadia & Şimşek (2023), <i>J. International Economics</i>	crisis financieras con ensambles de árboles y Shapley	sesiones 5–6
6 Jean, Burke, Xie, Davis, Lobell & Ermon (2016), <i>Science</i>	pobreza desde imágenes satelitales	sesión 7

Los PDF están en literature/. Gelvez et al. (2026) y Deppner & Cajias (2024) no se presentan: son los papers de las sesiones 5 y 3 y entran en la síntesis.

El guion de los 15 minutos, y cómo se evalúa (10% del curso)

El guion (doce minutos de presentación, tres de preguntas):

- 1 La pregunta y la decisión que depende de la predicción.
- 2 Los datos y la unidad de observación; qué se sabe en el momento de predecir.
- 3 La referencia contra la que se mide.
- 4 Cómo se evalúa fuera de muestra, y dónde falla el modelo.
- 5 El resultado principal, en sus unidades.
- 6 Qué método del curso es, y qué habríamos hecho distinto.

Se califica la lectura, no el diseño:

- **Precisión:** qué se predice, con qué datos, contra qué referencia y en qué prueba; un número principal con sus unidades.
- **Protocolo:** partición y validación; si respetan tiempo, espacio y grupos; dónde pudo haber filtración.
- **Interpretación y crítica:** qué dice el modelo y qué no; si alguna conclusión trata una importancia como un efecto; qué habríamos hecho distinto.

Doce minutos son doce minutos, y las preguntas se responden con el paper en la mano.

Mientras escuchan: la ficha de cada paper

Una fila por paper: es el insumo de la síntesis y el modelo de lo que su proyecto debe responder.

Campo	La pregunta
y y unidad	¿Qué se predice y para quién (persona, mesa, país—año, aldea)?
Decisión	¿Qué cambia si la predicción es buena? ¿Quién la usa?
Referencia	¿Contra qué se compara: la media, una regla simple, el juez, las luces nocturnas?
Validación	¿Partición, CV, reserva, pronóstico recursivo? ¿Respetar el tiempo, el espacio y los grupos?
Método	¿Qué familia del curso, y por qué esa?
Caja abierta	¿Qué herramienta de la sesión 6 usan, y qué afirman con ella?
Dónde falla	¿Para quién, cuándo y fuera de qué rango se degrada?

Si un campo queda vacío, esa es la pregunta para el presentador. Cada presentación termina con una pregunta de la sala sobre el punto 4 o el punto 6 del guion: prepárenla mientras escuchan.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

El mapa (I): qué se predice y cómo se evalúa

Paper	y (unidad)	Referencia	Validación
Kim & Zilinsky	voto y partido (encuestado, 1952–2020)	la demografía sola	80/20 por elección; exactitud en el 20% no visto
Bogin & Shui	valor del inmueble (avalúo rural)	el hedónico OLS	80/20; R^2 y RMSE de prueba
Blumenstock et al.	riqueza (suscriptor; Ruanda)	sin metadatos	CV; contra la encuesta, a escala de país
Kleinberg et al.	no comparecer (acusado; NYC)	el juez	40/40/20 y una reserva pura; contrafactuales con jueces
Bluwstein et al.	crisis en 1–2 años (país-año; 17 países)	la logística	CV de 5 pliegues $\times$ 100; pronóstico recursivo
Jean et al.	consumo y activos (aldea; 5 países)	las luces nocturnas	CV de 5 pliegues; por país y entre países
Deppner & Cajias	alquiler (apartamento; Frankfurt)	OLS y modelos espaciales	CV aleatoria vs. espacial; el trimestre siguiente
Gelvez et al.	ganador local y participación (mesa; 2006–2022)	logística y recta	80/20 estratificada; CV bayesiana; la prueba una vez

Ocho referencias distintas y ninguna es “el modelo anterior de la literatura”: es lo que la decisión usaría sin el modelo. Y la validación sigue la estructura de los datos: tiempo (Bluwstein), espacio (Deppner), decisión (Kleinberg), país (Jean).

El mapa (II): los métodos y la frase de cada paper

Paper	Métodos	Caja abierta	La frase
Kim & Zilinsky	logística, bosque	coeficientes vs. exactitud	significativo no es predictivo
Bogin & Shui	OLS, bosque, <i>boosting</i>	—	la tabla canónica; ganar no es automático
Blumenstock et al.	miles de variables, regularización	—	muchos predictores exigen validación
Kleinberg et al.	<i>gradient boosting</i>	—	la decisión es la otra mitad
Bluwstein et al.	seis modelos, del árbol solo a la red	Shapley, con significancia	el ensamble gana; importante no es causal
Jean et al.	CNN preentrenada + Ridge	rasgos visualizados	representar es comprimir con sentido
Deppner & Cajias	OLS, bosque, XGBoost	—	la CV responde la pregunta de su esquema
Gelvez et al.	logística, recta, bosque	SHAP con signo; bloques	el premio de la flexibilidad es una medida

Ningún paper gana por el algoritmo: gana por la pregunta, los datos y el protocolo. Los ensambles de árboles aparecen en seis de ocho; la red, sólo donde la estructura está en la representación. Y donde hay caja abierta hay advertencia: ninguna contribución es un efecto.

El flujo de trabajo, con nombre propio

Cada paso del *pipeline*, con el paper que mejor lo ilustra:

Paso	Quién lo hace ejemplarmente
1. Partir	Kleinberg et al.: una reserva pura que nadie toca hasta el final
2. Preprocesar en el pliegue	Gelvez et al.: la imputación dentro del <i>pipeline</i>
3. Validar según la estructura	Deppner & Cajias (espacio); Bluwstein et al. (tiempo)
4. Afinar en el entrenamiento	Gelvez et al.: búsqueda bayesiana con CV; la prueba no opina
5. Evaluar contra la referencia	Jean et al.: contra las luces nocturnas; Bogin & Shui: contra el hedónico
6. Interpretar con advertencias	Bluwstein et al.: Shapley fuera de muestra, con significancia
7. Reportar dónde falla	Kim & Zilinsky: la curva plana es el resultado; Jean et al.: por tramos de pobreza

Para el proyecto: estos siete pasos son las secciones del documento del 24 de noviembre.

El curso en una diapositiva

- 1 **Y, no β .** Predecir y explicar son preguntas distintas; el error de entrenamiento es optimista.
- 2 **La recta como máquina de predecir:** la referencia, la tabla canónica, predicho contra observado, el error por subgrupos.
- 3 **El pipeline honesto:** el CV valida *pipelines*; cada esquema responde su pregunta; Ridge y Lasso encogen, y el Lasso selecciona predictores, no causas.
- 4 **Clasificar es decidir:** la probabilidad, el umbral con costos, el AUC y la calibración.
- 5 **Los árboles** encuentran solos lo que nadie escribió; promediar y sumar en secuencia arregla su varianza; la tabla decide.
- 6 **Abrir la caja:** importancia, dependencia parcial, Shapley; describen el modelo, no el mundo.
- 7 **Representar es comprimir con sentido:** PCA sin y , redes con y , y las representaciones se prestan.

Las reglas de oro, por última vez

#1 El error de entrenamiento es optimista. #2 La prueba se usa una sola vez. #3 El CV valida *pipelines* enteros. Y la que enseñan los papers: #4 la referencia es lo que la decisión haría sin el modelo.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

La idea en una página y el *pitch* de cinco minutos

Entrega 1 del proyecto: 10 de los 100 puntos

La página (enviada antes de clase) responde tres cosas:

- 1 **La pregunta y la decisión** que la motiva: quién usaría la predicción y qué haría distinto con ella.
- 2 **La unidad y la y:** qué se predice exactamente, para qué unidad y en qué momento.
- 3 **Los datos candidatos:** fuente, tamaño aproximado, disponibilidad, y qué se sabría *en el momento de predecir*.

El pitch: cinco minutos, sin más de tres diapositivas, seguidos de dos minutos de retroalimentación de la sala.

Las tres preguntas que la sala hace siempre

¿Qué decisión cambia con la predicción? ¿Qué información existe en el momento de predecir, y cuál es filtración disfrazada? ¿Contra qué referencia y con qué prueba se sabrá si funcionó?

Una propuesta que no sobrevive a esas tres preguntas hoy es mejor que una que las descubre el 24 de noviembre.

De la idea al documento del 24 de noviembre

Entrega 2: un documento de máximo 8 páginas (50 puntos) y una presentación de 20 minutos (40 puntos)

Las secciones del documento, que son los pasos del flujo de trabajo:

- ❶ La pregunta y la decisión.
 - ❷ Los datos: fuente, unidad, tamaño, predictores por bloques, qué se sabría al predecir.
 - ❸ Métrica, referencia y estrategia de validación acorde con la estructura de los datos (grupos, tiempo, espacio).
 - ❹ Los métodos que se compararían y por qué: al menos dos familias del curso.
 - ❺ Qué se interpretaría y qué no.
 - ❻ Riesgos: filtración, extrapolación, cambio de régimen, equidad si hay personas.
 - ❼ Plan de trabajo.
- Es una **propuesta**, no un informe: no se piden resultados, se pide un diseño que resista las siete preguntas. Una tabla preliminar suma, pero no reemplaza el diseño.
 - **[Individual o en parejas: por definir.]** La presentación del 24 de noviembre dura 20 minutos más 10 de preguntas.

- 1 Las presentaciones
- 2 La síntesis: el mapa del curso
- 3 Los *pitches* del proyecto
- 4 Cierre opcional: el puente causal

El puente causal (I): cuándo una máquina de predecir ayuda a estimar un β

El modelo parcialmente lineal: $y = \theta d + g(x) + \varepsilon$, donde θ es el efecto de interés, d el tratamiento y x muchos controles con forma desconocida.

- **Lo que no funciona:** un Lasso de y sobre (d, x) y leer el coeficiente de d . La penalización sesga $\hat{\theta}$ y omite controles que importan poco para y pero mucho para d : el Lasso selecciona predictores, no causas (sesión 3).
- **Doble selección** (Belloni, Chernozhukov & Hansen, 2014; apéndice de la sesión 3): seleccionar los controles que predicen y y los que predicen d , unirlos y correr OLS con todos. La máquina elige controles; la inferencia es OLS.

La división del trabajo

El ML predice las *molestias* (la parte de y y de d que explican los controles); el economista aporta el supuesto de identificación (que x basta). Sin ese supuesto, ningún algoritmo convierte un predictor en una causa.

El puente causal (II): residuos sobre residuos

Double machine learning (Chernozhukov et al., 2018)

Predecir y con x y d con x usando *cualquier* método del curso (bosque, *boosting*, red), en pliegues cruzados, y regresar el residuo de y sobre el residuo de d :

$$\hat{\theta} = \frac{\sum_i (d_i - \hat{m}(x_i))(y_i - \hat{\ell}(x_i))}{\sum_i (d_i - \hat{m}(x_i))^2}, \quad \hat{m}(x) \approx \mathbb{E}[d \mid x], \quad \hat{\ell}(x) \approx \mathbb{E}[y \mid x].$$

- **Cross-fitting:** cada residuo viene de un modelo que *no vio* esa observación. Es el CV de la sesión 3 puesto al servicio de un β (apéndice A1).
- **Por qué funciona:** el estimador es insensible, a primer orden, a errores pequeños en las dos predicciones; basta con que las máquinas predigan razonablemente bien.
- **Bosques causales** (Wager & Athey, 2018): la misma lógica con árboles honestos para efectos heterogéneos $\theta(x)$.

Para seguir

Athey & Imbens (2019), secciones 1 a 3; el resto es el curso de Inferencia Causal. Aquí termina el puente: todo lo demás del semestre fue Y , no β .

Lo que queda del semestre

Martes 10 de noviembre	Sin clase. Entrega del Problem Set 2 a las 11:59 p. m. Asesoría opcional en el horario de clase para el problem set y el proyecto.
Martes 17 de noviembre	Sin clase.
Martes 24 de noviembre	Entrega 2 del proyecto: el documento, ese mismo día. Presentaciones de 20 minutos más preguntas. Quince minutos iniciales con el ranking del Problem Set 2 y el cierre del curso.

Para el documento: los siete pasos de hoy, las fichas que llenaron esta mañana y los tres papers más cercanos a su pregunta como modelo de reporte. Las carreras de caballos del proyecto (Gu, Kelly & Xiu, 2020; Medeiros et al., 2021) son la lectura para quien compare muchas familias.

Para el Problem Set 2: con la sesión 7 ya está todo lo que necesitan. El modelo final del curso se elige por validación, se reajusta con todo el entrenamiento y se prueba una vez.

Referencias esenciales

- Kim, S.-Y. S., & Zilinsky, J. (2024). Division Does Not Imply Predictability. *Political Behavior*, 46, 67–87.
- Bogin, A., & Shui, J. (2020). Appraisal Accuracy and Automated Valuation Models in Rural Areas. *Journal of Real Estate Finance and Economics*, 60, 40–52.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073–1076.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J., & Mullainathan, S. (2018). Human Decisions and Machine Predictions. *QJE*, 133(1), 237–293.
- Bluwstein, K., Buckmann, M., Joseph, A., Kapadia, S., & Şimşek, Ö. (2023). Credit Growth, the Yield Curve and Financial Crisis Prediction. *Journal of International Economics*, 145, 103773.
- Jean, N., Burke, M., Xie, M., Davis, W., Lobell, D., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.
- Deppner, J., & Cajias, M. (2024). Accounting for Spatial Autocorrelation in Algorithm-Driven Hedonic Models. *Journal of Real Estate Finance and Economics*, 68, 235–273.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Documento de trabajo.
- Chernozhukov, V., et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.

5 Apéndice: para profundizar

A1. Por qué residuos sobre residuos funciona

Frisch–Waugh–Lovell, sin fórmula: el coeficiente de d es el mismo si primero se le quita a y y a d lo que x explica de cada uno y luego se regresa un residuo sobre el otro. Con g lineal eso es OLS; con g desconocida hay que *predecir* $\mathbb{E}[y \mid x]$ y $\mathbb{E}[d \mid x]$, y ahí entra el curso.

Dos ingredientes de Chernozhukov et al. (2018):

- ❶ **Ortogonalidad de Neyman.** El estimador es insensible, a primer orden, a errores pequeños en $\hat{m}$ y $\hat{\ell}$: los errores de las dos predicciones se multiplican entre sí, y el producto de dos cosas pequeñas es más pequeño. Basta con que las máquinas converjan más rápido que $n^{-1/4}$, no con que sean perfectas.
- ❷ **Cross-fitting.** Si $\hat{m}$ y $\hat{\ell}$ se ajustan con las mismas observaciones que luego estiman θ , el sobreajuste de la máquina se cuela en $\hat{\theta}$. Se parte la muestra en K pliegues y las molestias de cada pliegue se predicen con modelos ajustados en los otros: la regla de oro #3.
- **Bosques causales** (Wager & Athey, 2018): árboles “honestos” (una submuestra elige los cortes, otra estima el efecto en cada hoja) para efectos heterogéneos $\theta(x)$. Con supuesto de identificación, siempre.