

Big Data y Machine Learning para Economía Aplicada

Week 09: Texto como Datos y LLMs

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

July 23, 2026

Previously... (y logística de hoy)

El hilo de las últimas sesiones: **representar es comprimir con sentido** — PCA lo hacía linealmente (S7); las redes componen representaciones cada vez más abstractas (S8).

Previously... (y logística de hoy)

El hilo de las últimas sesiones: **representar es comprimir con sentido** — PCA lo hacía linealmente (S7); las redes componen representaciones cada vez más abstractas (S8).

Hoy: el dato más abundante de la economía — el texto

- ➊ **Texto clásico**: de documentos a matrices (bolsa de palabras, TF-IDF, sentimiento, tópicos).
- ➋ **Embeddings**: palabras como vectores con geometría.
- ➌ **Transformers y LLMs**: atención; **entrenaremos un GPT de juguete en vivo** y haremos *fine-tuning* de un modelo abierto.
- ➍ El LLM como **instrumento de medición** económica — y sus riesgos.

Previously... (y logística de hoy)

El hilo de las últimas sesiones: **representar es comprimir con sentido** — PCA lo hacía linealmente (S7); las redes componen representaciones cada vez más abstractas (S8).

Hoy: el dato más abundante de la economía — el texto

- 1 **Texto clásico**: de documentos a matrices (bolsa de palabras, TF-IDF, sentimiento, tópicos).
- 2 **Embeddings**: palabras como vectores con geometría.
- 3 **Transformers y LLMs**: atención; **entrenaremos un GPT de juguete en vivo** y haremos *fine-tuning* de un modelo abierto.
- 4 El LLM como **instrumento de medición** económica — y sus riesgos.

Logística: la sesión corre en **Python sobre Colab** (GPU gratuita, cuadernos preparados) — la excepción anunciada a “R primero”: el ecosistema de LLMs vive en Python. No se asusten: el código está escrito; hoy se trata de *entender* qué hace.

- 1 Texto clásico: contar palabras con inteligencia
- 2 Embeddings: palabras con geometría
- 3 Transformers y LLMs
- 4 El texto en la economía: síntesis y cierre del curso

El texto es un dato económico de primera

Qué hay en el texto que no hay en ninguna encuesta:


- **Comunicados y minutas** de bancos centrales: el tono de la política monetaria.
- **Prensa**: incertidumbre económica, expectativas, narrativas.
- **Informes corporativos, licitaciones, sentencias, redes sociales**: riesgo, corrupción, clima de negocios.

El texto es un dato económico de primera

Qué hay en el texto que no hay en ninguna encuesta:

- **Comunicados y minutas** de bancos centrales: el tono de la política monetaria.
- **Prensa**: incertidumbre económica, expectativas, narrativas.
- **Informes corporativos, licitaciones, sentencias, redes sociales**: riesgo, corrupción, clima de negocios.

El reto (Gentzkow, Kelly & Taddy, 2019): el texto es *no estructurado* y de dimensión gigantesca. El flujo siempre es el mismo:




El texto es un dato económico de primera

Qué hay en el texto que no hay en ninguna encuesta:

- **Comunicados y minutas** de bancos centrales: el tono de la política monetaria.
- **Prensa**: incertidumbre económica, expectativas, narrativas.
- **Informes corporativos, licitaciones, sentencias, redes sociales**: riesgo, corrupción, clima de negocios.

El reto (Gentzkow, Kelly & Taddy, 2019): el texto es *no estructurado* y de dimensión gigantesca. El flujo siempre es el mismo:



La clave de la sesión

Todo el problema está en la casilla azul: **cómo representar**. La historia de hoy es la evolución de esa casilla: contar → ponderar → *embeddings* → atención.

La bolsa de palabras y la matriz documento–término

El pipeline clásico:

- 1 **Tokenizar**: partir en palabras (o n -gramas: “tasa de interés”).
- 2 **Normalizar**: minúsculas, tildes, raíces (*stemming*); quitar *stopwords* (“de”, “la” ...).
- 3 **Contar**: la **matriz documento–término** X (n docs $\times$ p términos): x_{dt} = veces que el término t aparece en el documento d .

La bolsa de palabras y la matriz documento–término

El pipeline clásico:

- 1 **Tokenizar**: partir en palabras (o n -gramas: “tasa de interés”).
 - 2 **Normalizar**: minúsculas, tildes, raíces (*stemming*); quitar *stopwords* (“de”, “la” ...).
 - 3 **Contar**: la **matriz documento–término** X (n docs $\times$ p términos): x_{dt} = veces que el término t aparece en el documento d .
- Se pierde el **orden** (“la banca quebró al gobierno” = “el gobierno quebró a la banca”): por eso “bolsa”. Aún así, para muchas tareas basta.
 - p enorme (decenas de miles) y X **ultra-esparsa**: ¡el hábitat natural de la sesión 3!

La bolsa de palabras y la matriz documento–término

El pipeline clásico:

- 1 **Tokenizar**: partir en palabras (o n -gramas: “tasa de interés”).
 - 2 **Normalizar**: minúsculas, tildes, raíces (*stemming*); quitar *stopwords* (“de”, “la” ...).
 - 3 **Contar**: la **matriz documento–término** X (n docs $\times$ p términos): x_{dt} = veces que el término t aparece en el documento d .
- Se pierde el **orden** (“la banca quebró al gobierno” = “el gobierno quebró a la banca”): por eso “bolsa”. Aún así, para muchas tareas basta.
 - p enorme (decenas de miles) y X **ultra-esparsa**: ¡el hábitat natural de la sesión 3!

Ponderar lo distintivo — TF-IDF:

$$w_{dt} = \underbrace{tf_{dt}}_{\text{frecuencia en } d} \times \underbrace{\log(N/df_t)}_{\text{rareza entre documentos}}$$

un término pesa si es frecuente *en este* documento y raro *en los demás*.
 (“inflación” en todos los comunicados: peso bajo; “desanclaje” en uno: peso alto.)

Con la matriz en la mano, todo el curso aplica

La DTM convierte el texto en un problema que **ya sabemos resolver**:

- **Clasificar** documentos (¿comunicado *hawkish* o *dovish*? ¿queja procedente?): logística penalizada o Naive Bayes — el hábitat estrella de NB (S5), con Lasso para seleccionar términos (S3).

Con la matriz en la mano, todo el curso aplica

La DTM convierte el texto en un problema que **ya sabemos resolver**:

- **Clasificar** documentos (¿comunicado *hawkish* o *dovish*? ¿queja procedente?): logística penalizada o Naive Bayes — el hábitat estrella de NB (S5), con Lasso para seleccionar términos (S3).
- **Sentimiento por diccionarios**: contar palabras positivas/negativas de una lista curada. La lección clave: el diccionario debe ser **del dominio** — Loughran & McDonald (2011) muestran que los diccionarios genéricos fallan en finanzas (“liability” no es triste, es contabilidad).

Con la matriz en la mano, todo el curso aplica

La DTM convierte el texto en un problema que **ya sabemos resolver**:

- **Clasificar** documentos (¿comunicado *hawkish* o *dovish*? ¿queja procedente?): logística penalizada o Naive Bayes — el hábitat estrella de NB (S5), con Lasso para seleccionar términos (S3).
- **Sentimiento por diccionarios**: contar palabras positivas/negativas de una lista curada. La lección clave: el diccionario debe ser **del dominio** — Loughran & McDonald (2011) muestran que los diccionarios genéricos fallan en finanzas (“liability” no es triste, es contabilidad).
- **Agrupar** documentos (k -means sobre TF-IDF, S7) o **reducir dimensión** (PCA/LSA sobre la DTM).

Con la matriz en la mano, todo el curso aplica

La DTM convierte el texto en un problema que **ya sabemos resolver**:

- **Clasificar** documentos (¿comunicado *hawkish* o *dovish*? ¿queja procedente?): logística penalizada o Naive Bayes — el hábitat estrella de NB (S5), con Lasso para seleccionar términos (S3).
- **Sentimiento por diccionarios**: contar palabras positivas/negativas de una lista curada. La lección clave: el diccionario debe ser **del dominio** — Loughran & McDonald (2011) muestran que los diccionarios genéricos fallan en finanzas (“liability” no es triste, es contabilidad).
- **Agrupar** documentos (k -means sobre TF-IDF, S7) o **reducir dimensión** (PCA/LSA sobre la DTM).

Limitaciones honestas del conteo

Negación (“*no* hay riesgo”), sarcasmo, contexto, polisemia. El conteo es un **proxy grueso**: barato, transparente, auditable — y por eso sigue vivo. Cuando el matiz importa, seguimos avanzando.

Modelos de tópicos: LDA

La pregunta: ¿de qué *temas* habla el corpus, sin decírselos de antemano? (No supervisado: la S7 en versión texto.)

Modelos de tópicos: LDA

La pregunta: ¿de qué *temas* habla el corpus, sin decírselos de antemano? (No supervisado: la S7 en versión texto.)

El modelo generativo (Blei, Ng & Jordan, 2003), contado como historia:

- Cada **tópico** k es una distribución sobre palabras (β_k): el tópico “inflación” pone masa en {precios, IPC, expectativas...}.
- Cada **documento** d es una mezcla de tópicos (θ_d): 70% inflación, 30% empleo.
- Cada palabra del documento se genera eligiendo un tópico de θ_d y una palabra de su β_k .

Estimar = invertir la historia: encontrar los β_k y θ_d que mejor explican lo observado.

Modelos de tópicos: LDA

La pregunta: ¿de qué *temas* habla el corpus, sin decírselos de antemano? (No supervisado: la S7 en versión texto.)

El modelo generativo (Blei, Ng & Jordan, 2003), contado como historia:

- Cada **tópico** k es una distribución sobre palabras (β_k): el tópico “inflación” pone masa en {precios, IPC, expectativas...}.
- Cada **documento** d es una mezcla de tópicos (θ_d): 70% inflación, 30% empleo.
- Cada palabra del documento se genera eligiendo un tópico de θ_d y una palabra de su β_k .

Estimar = invertir la historia: encontrar los β_k y θ_d que mejor explican lo observado.

- **Lo que entrega:** tópicos interpretables (leyendo sus palabras top) + la composición de cada documento — series de tiempo de *atención temática*.
- K **se elige** como siempre en no supervisado: coherencia, estabilidad, uso.

Modelos de tópicos: LDA

La pregunta: ¿de qué *temas* habla el corpus, sin decírselos de antemano? (No supervisado: la S7 en versión texto.)

El modelo generativo (Blei, Ng & Jordan, 2003), contado como historia:

- Cada **tópico** k es una distribución sobre palabras (β_k): el tópico “inflación” pone masa en {precios, IPC, expectativas...}.
- Cada **documento** d es una mezcla de tópicos (θ_d): 70% inflación, 30% empleo.
- Cada palabra del documento se genera eligiendo un tópico de θ_d y una palabra de su β_k .

Estimar = invertir la historia: encontrar los β_k y θ_d que mejor explican lo observado.

- **Lo que entrega:** tópicos interpretables (leyendo sus palabras top) + la composición de cada documento — series de tiempo de *atención temática*.
- K **se elige** como siempre en no supervisado: coherencia, estabilidad, uso.
- **La aplicación canónica:** Hansen, McMahon & Prat (2018, QJE) — LDA sobre transcripciones del FOMC para medir cómo la *transparencia* cambió la

- 1 Texto clásico: contar palabras con inteligencia
- 2 Embeddings: palabras con geometría
- 3 Transformers y LLMs
- 4 El texto en la economía: síntesis y cierre del curso

El defecto de nacimiento del conteo

En la DTM, cada palabra es una **columna independiente**: vectores ortogonales.

El defecto de nacimiento del conteo

En la DTM, cada palabra es una **columna independiente**: vectores ortogonales.

- Para la matriz, “crisis” y “recesión” son **tan distintas** entre sí como “crisis” y “banano”. Ninguna noción de similitud.

El defecto de nacimiento del conteo

En la DTM, cada palabra es una **columna independiente**: vectores ortogonales.

- Para la matriz, “crisis” y “recesión” son **tan distintas** entre sí como “crisis” y “banano”. Ninguna noción de similitud.
- Consecuencia práctica: un clasificador entrenado con documentos que dicen “recesión” no aprende *nada* sobre documentos que dicen “contracción”. Desperdicio masivo de estructura.

El defecto de nacimiento del conteo

En la DTM, cada palabra es una **columna independiente**: vectores ortogonales.

- Para la matriz, “crisis” y “recesión” son **tan distintas** entre sí como “crisis” y “banano”. Ninguna noción de similitud.
- Consecuencia práctica: un clasificador entrenado con documentos que dicen “recesión” no aprende *nada* sobre documentos que dicen “contracción”. Desperdicio masivo de estructura.

La salida — la hipótesis distribucional (Firth, 1957):

“Conocerás una palabra por la compañía que mantiene.”

Palabras que aparecen en **contextos similares** significan cosas similares.

Entonces: aprendamos, para cada palabra, un **vector** tal que la geometría capture esa compañía.

El defecto de nacimiento del conteo

En la DTM, cada palabra es una **columna independiente**: vectores ortogonales.

- Para la matriz, “crisis” y “recesión” son **tan distintas** entre sí como “crisis” y “banano”. Ninguna noción de similitud.
- Consecuencia práctica: un clasificador entrenado con documentos que dicen “recesión” no aprende *nada* sobre documentos que dicen “contracción”. Desperdicio masivo de estructura.

La salida — la hipótesis distribucional (Firth, 1957):

“Conocerás una palabra por la compañía que mantiene.”

Palabras que aparecen en **contextos similares** significan cosas similares.
Entonces: aprendamos, para cada palabra, un **vector** tal que la geometría capture esa compañía.

¿Les suena el plan?

Es **reducción de dimensión con sentido** (S7): de la columna ortogonal ($p \sim 10^5$) a un vector denso (~ 300) aprendido de los datos.

Word embeddings: word2vec y la geometría del significado

word2vec (Mikolov et al., 2013): entrenar una red mínima para **predecir el contexto** de cada palabra (o la palabra desde su contexto). Los pesos aprendidos *son* los vectores.

Word embeddings: word2vec y la geometría del significado

word2vec (Mikolov et al., 2013): entrenar una red mínima para **predecir el contexto** de cada palabra (o la palabra desde su contexto). Los pesos aprendidos *son* los vectores.

- El subproducto vale más que la tarea: palabras de contextos parecidos terminan **cerca** en el espacio.
- Y la geometría hace aritmética de significado:

$$\vec{v}_{rey} - \vec{v}_{hombre} + \vec{v}_{mujer} \approx \vec{v}_{reina}$$

Direcciones del espacio capturan relaciones (género, capital–país, tiempo verbal).

Word embeddings: word2vec y la geometría del significado

word2vec (Mikolov et al., 2013): entrenar una red mínima para **predecir el contexto** de cada palabra (o la palabra desde su contexto). Los pesos aprendidos *son* los vectores.

- El subproducto vale más que la tarea: palabras de contextos parecidos terminan **cerca** en el espacio.
- Y la geometría hace aritmética de significado:

$$\vec{v}_{rey} - \vec{v}_{hombre} + \vec{v}_{mujer} \approx \vec{v}_{reina}$$

Direcciones del espacio capturan relaciones (género, capital–país, tiempo verbal).

- En economía: medir cercanía de industrias por descripciones, similitud de patentes, sesgos y estereotipos en prensa histórica, exposición de firmas a riesgos según sus informes.

Word embeddings: word2vec y la geometría del significado

word2vec (Mikolov et al., 2013): entrenar una red mínima para **predecir el contexto** de cada palabra (o la palabra desde su contexto). Los pesos aprendidos *son* los vectores.

- El subproducto vale más que la tarea: palabras de contextos parecidos terminan **cerca** en el espacio.
- Y la geometría hace aritmética de significado:

$$\vec{v}_{rey} - \vec{v}_{hombre} + \vec{v}_{mujer} \approx \vec{v}_{reina}$$

Direcciones del espacio capturan relaciones (género, capital–país, tiempo verbal).

- En economía: medir cercanía de industrias por descripciones, similitud de patentes, sesgos y estereotipos en prensa histórica, exposición de firmas a riesgos según sus informes.

El límite de los embeddings estáticos: una palabra = **un** vector, siempre.

- “El **banco** subió la tasa” vs. “se sentó en el **banco** de la plaza”: mismo vector, significados distintos.
- Necesitamos representaciones que dependan del **contexto de cada**

- 1 Texto clásico: contar palabras con inteligencia
- 2 Embeddings: palabras con geometría
- 3 Transformers y LLMs**
- 4 El texto en la economía: síntesis y cierre del curso

Atención: representaciones que se construyen en contexto

La idea (Vaswani et al., 2017, *Attention Is All You Need*), sin la parafernalia:

- Cada palabra empieza con su embedding... y luego lo **actualiza mirando a las demás palabras de la frase**.
- La actualización es un **promedio ponderado** de (transformaciones de) los vectores de las otras palabras.
- Los **pesos** los calcula la propia red: cuánto “atiende” cada palabra a cada otra — compatibilidad entre lo que una *busca* y lo que otra *ofrece*, pasada por un **softmax** (S5).

Atención: representaciones que se construyen en contexto

La idea (Vaswani et al., 2017, *Attention Is All You Need*), sin la parafernalia:

- Cada palabra empieza con su embedding... y luego lo **actualiza mirando a las demás palabras de la frase**.
- La actualización es un **promedio ponderado** de (transformaciones de) los vectores de las otras palabras.
- Los **pesos** los calcula la propia red: cuánto “atiende” cada palabra a cada otra — compatibilidad entre lo que una *busca* y lo que otra *ofrece*, pasada por un **softmax** (S5).

En “el **banco** subió la *tasa*”, el vector de “banco” atiende fuerte a “tasa” $\Rightarrow$ su representación final es inequívocamente financiera. Polisemia: resuelta por construcción.

Atención: representaciones que se construyen en contexto

La idea (Vaswani et al., 2017, *Attention Is All You Need*), sin la parafernalia:

- Cada palabra empieza con su embedding... y luego lo **actualiza mirando a las demás palabras de la frase**.
- La actualización es un **promedio ponderado** de (transformaciones de) los vectores de las otras palabras.
- Los **pesos** los calcula la propia red: cuánto “atiende” cada palabra a cada otra — compatibilidad entre lo que una *busca* y lo que otra *ofrece*, pasada por un **softmax** (S5).

En “el **banco** subió la *tasa*”, el vector de “banco” atiende fuerte a “tasa” $\Rightarrow$ su representación final es inequívocamente financiera. Polisemia: resuelta por construcción.

- **En una frase para economistas:** la atención es una *regresión ponderada que la red aprende a ejecutar*, con pesos distintos para cada palabra en cada frase.
- Un **transformer** = muchas atenciones en paralelo (*heads*), apiladas en capas (¡composición, S8!), con las representaciones refinándose capa a capa.

Atención: representaciones que se construyen en contexto

La idea (Vaswani et al., 2017, *Attention Is All You Need*), sin la parafernalia:

- Cada palabra empieza con su embedding... y luego lo **actualiza mirando a las demás palabras de la frase**.
- La actualización es un **promedio ponderado** de (transformaciones de) los vectores de las otras palabras.
- Los **pesos** los calcula la propia red: cuánto “atiende” cada palabra a cada otra — compatibilidad entre lo que una *busca* y lo que otra *ofrece*, pasada por un **softmax** (S5).

En “el **banco** subió la *tasa*”, el vector de “banco” atiende fuerte a “tasa” $\Rightarrow$ su representación final es inequívocamente financiera. Polisemia: resuelta por construcción.

- **En una frase para economistas:** la atención es una *regresión ponderada que la red aprende a ejecutar*, con pesos distintos para cada palabra en cada frase.
- Un **transformer** = muchas atenciones en paralelo (*heads*), apiladas en capas (¡composición, S8!), con las representaciones refinándose capa a capa.

¿Qué es, entonces, un LLM?

Definición sin humo: un transformer **gigante** entrenado para **predecir la siguiente palabra** en corpus masivos de texto.

¿Qué es, entonces, un LLM?

Definición sin humo: un transformer **gigante** entrenado para **predecir la siguiente palabra** en corpus masivos de texto.

- La pérdida es la *cross-entropy* de la sesión 5 — máxima verosimilitud sobre el vocabulario, palabra por palabra, billones de veces.
- El optimizador es el SGD/Adam de la sesión 8. La arquitectura, la atención de hace una diapositiva. **No hay ingredientes nuevos: hay escala.**

¿Qué es, entonces, un LLM?

Definición sin humo: un transformer **gigante** entrenado para **predecir la siguiente palabra** en corpus masivos de texto.

- La pérdida es la *cross-entropy* de la sesión 5 — máxima verosimilitud sobre el vocabulario, palabra por palabra, billones de veces.
- El optimizador es el SGD/Adam de la sesión 8. La arquitectura, la atención de hace una diapositiva. **No hay ingredientes nuevos: hay escala.**
- Lo sorprendente (y aún debatido): de esa tarea humilde **emergen** capacidades — sintaxis, hechos, traducción, razonamiento aparente — porque predecir bien la siguiente palabra de *todo* lo escrito exige modelar mucho del mundo que lo escribió.

¿Qué es, entonces, un LLM?

Definición sin humo: un transformer **gigante** entrenado para **predecir la siguiente palabra** en corpus masivos de texto.

- La pérdida es la *cross-entropy* de la sesión 5 — máxima verosimilitud sobre el vocabulario, palabra por palabra, billones de veces.
- El optimizador es el SGD/Adam de la sesión 8. La arquitectura, la atención de hace una diapositiva. **No hay ingredientes nuevos: hay escala.**
- Lo sorprendente (y aún debatido): de esa tarea humilde **emergen** capacidades — sintaxis, hechos, traducción, razonamiento aparente — porque predecir bien la siguiente palabra de *todo* lo escrito exige modelar mucho del mundo que lo escribió.

Desmitificación operativa

Cuando un LLM “responde”, está muestreando, palabra por palabra, de $P(\text{siguiente} \mid \text{todo lo anterior})$. Toda su magia y todos sus defectos (alucinaciones incluidas) salen de ahí: es un **modelo de la distribución del texto**, no un consultor de la verdad.

DEMO 1: entrenemos un GPT de juguete, en vivo

Todo el curso en una pantalla (nanoGPT, Colab, ~10 minutos)

El experimento (cuaderno preparado, corpus: comunicados del Banco de la República):

- 1 Un transformer **minúsculo** (~10M de parámetros, nivel de caracteres).
- 2 Entrenarlo unos minutos en la GPU gratuita de Colab, mirando dos cosas: la **pérdida** cayendo y **muestras de texto** generadas cada pocos pasos.

DEMO 1: entrenemos un GPT de juguete, en vivo

Todo el curso en una pantalla (nanoGPT, Colab, ~10 minutos)

El experimento (cuaderno preparado, corpus: comunicados del Banco de la República):

- 1 Un transformer **minúsculo** (~10M de parámetros, nivel de caracteres).
- 2 Entrenarlo unos minutos en la GPU gratuita de Colab, mirando dos cosas: la **pérdida** cayendo y **muestras de texto** generadas cada pocos pasos.

Lo que van a ver (y por qué es el examen final conceptual del curso):

- Minuto 0: sopa de caracteres aleatorios. Minuto 2: “palabras” en español inventado. Minuto 8: sintaxis de comunicado de banco central, plausible y vacía.

DEMO 1: entrenemos un GPT de juguete, en vivo

Todo el curso en una pantalla (nanoGPT, Colab, ~10 minutos)

El experimento (cuaderno preparado, corpus: comunicados del Banco de la República):

- 1 Un transformer **minúsculo** (~10M de parámetros, nivel de caracteres).
- 2 Entrenarlo unos minutos en la GPU gratuita de Colab, mirando dos cosas: la **pérdida** cayendo y **muestras de texto** generadas cada pocos pasos.

Lo que van a ver (y por qué es el examen final conceptual del curso):

- Minuto 0: sopa de caracteres aleatorios. Minuto 2: “palabras” en español inventado. Minuto 8: sintaxis de comunicado de banco central, plausible y vacía.
- En la pantalla están **todas** las piezas: embeddings (S9), softmax y cross-entropy (S5), mini-batches y Adam (S8), la curva de pérdida train vs. validación separándose — **el sobreajuste de la sesión 1, en vivo** — y el early stopping como respuesta (S8).

DEMO 1: entrenemos un GPT de juguete, en vivo

Todo el curso en una pantalla (nanoGPT, Colab, ~10 minutos)

El experimento (cuaderno preparado, corpus: comunicados del Banco de la República):

- 1 Un transformer **minúsculo** (~10M de parámetros, nivel de caracteres).
- 2 Entrenarlo unos minutos en la GPU gratuita de Colab, mirando dos cosas: la **pérdida** cayendo y **muestras de texto** generadas cada pocos pasos.

Lo que van a ver (y por qué es el examen final conceptual del curso):

- Minuto 0: sopa de caracteres aleatorios. Minuto 2: “palabras” en español inventado. Minuto 8: sintaxis de comunicado de banco central, plausible y vacía.
- En la pantalla están **todas** las piezas: embeddings (S9), softmax y cross-entropy (S5), mini-batches y Adam (S8), la curva de pérdida train vs. validación separándose — **el sobreajuste de la sesión 1, en vivo** — y el early stopping como respuesta (S8).

El punto pedagógico

Un LLM no es magia: es **este mismo cuaderno con 10^5 veces más de todo.**

Del pretraining al modelo útil (y la cuestión abierta/cerrada)

El modelo base solo completa texto. Para volverlo útil:

- *Fine-tuning* supervisado con ejemplos de instrucciones y buenas respuestas.
- Alineación con preferencias humanas (RLHF y variantes) — una línea hoy; no es nuestro foco.

Del pretraining al modelo útil (y la cuestión abierta/cerrada)

El modelo base solo completa texto. Para volverlo útil:

- *Fine-tuning* supervisado con ejemplos de instrucciones y buenas respuestas.
- Alineación con preferencias humanas (RLHF y variantes) — una línea hoy; no es nuestro foco.

La distinción que importa para investigación:

	Modelos abiertos (pesos descargables)	Modelos cerrados (API)
Reproducibilidad	total (versión congelada)	frágil (el modelo cambia)
Datos sensibles	se quedan en tu máquina	viajan a un tercero
Adaptación	<i>fine-tuning</i> completo	limitada
Capacidad tope	alta y subiendo	la frontera
Costo	GPU propia o Colab	por token

Del pretraining al modelo útil (y la cuestión abierta/cerrada)

El modelo base solo completa texto. Para volverlo útil:

- *Fine-tuning* supervisado con ejemplos de instrucciones y buenas respuestas.
- Alineación con preferencias humanas (RLHF y variantes) — una línea hoy; no es nuestro foco.

La distinción que importa para investigación:

	Modelos abiertos (pesos descargables)	Modelos cerrados (API)
Reproducibilidad	total (versión congelada)	frágil (el modelo cambia)
Datos sensibles	se quedan en tu máquina	viajan a un tercero
Adaptación	<i>fine-tuning</i> completo	limitada
Capacidad tope	alta y subiendo	la frontera
Costo	GPU propia o Colab	por token

Para **medición económica seria** — replicable, auditable, con microdatos — los modelos abiertos pequeños y medianos son la herramienta de trabajo. Y adaptarlos es más barato de lo que creen. . .

DEMO 2: fine-tuning eficiente con LoRA

Adaptar un modelo abierto a una tarea económica, en Colab

El problema de ajustar un LLM: tocar miles de millones de parámetros no cabe en ninguna GPU académica.

DEMO 2: fine-tuning eficiente con LoRA

Adaptar un modelo abierto a una tarea económica, en Colab

El problema de ajustar un LLM: tocar miles de millones de parámetros no cabe en ninguna GPU académica.

LoRA (Hu et al., 2021) — la idea en dos líneas:

- **Congelar** los pesos W del modelo; aprender solo una corrección de **rango bajo**: $\Delta W = BA$, con A, B delgadísimas (rango $r \sim 8-16$).
- Parámetros entrenables: $< 1\%$ del total $\Rightarrow$ cabe en Colab. (¿Rango bajo como compresión con sentido? La S7 aprueba.)

DEMO 2: fine-tuning eficiente con LoRA

Adaptar un modelo abierto a una tarea económica, en Colab

El problema de ajustar un LLM: tocar miles de millones de parámetros no cabe en ninguna GPU académica.

LoRA (Hu et al., 2021) — la idea en dos líneas:

- **Congelar** los pesos W del modelo; aprender solo una corrección de **rango bajo**: $\Delta W = BA$, con A, B delgadísimas (rango $r \sim 8-16$).
- Parámetros entrenables: $< 1\%$ del total $\Rightarrow$ cabe en Colab. (¿Rango bajo como compresión con sentido? La S7 aprueba.)

La demo: clasificar comunicados de banca central como *hawkish* / *dovish* / neutral:

- 1 Modelo abierto pequeño ($\sim 1-3B$) + LoRA sobre unos cientos de ejemplos etiquetados.
- 2 Comparar contra las líneas base del curso: diccionarios (hoy) y logística sobre TF-IDF (S5) — **mismo test set, misma vara** (S1–S2, siempre).

DEMO 2: fine-tuning eficiente con LoRA

Adaptar un modelo abierto a una tarea económica, en Colab

El problema de ajustar un LLM: tocar miles de millones de parámetros no cabe en ninguna GPU académica.

LoRA (Hu et al., 2021) — la idea en dos líneas:

- **Congelar** los pesos W del modelo; aprender solo una corrección de **rango bajo**: $\Delta W = BA$, con A, B delgadísimas (rango $r \sim 8-16$).
- Parámetros entrenables: $< 1\%$ del total $\Rightarrow$ cabe en Colab. (¿Rango bajo como compresión con sentido? La S7 aprueba.)

La demo: clasificar comunicados de banca central como *hawkish* / *dovish* / neutral:

- 1 Modelo abierto pequeño ($\sim 1-3B$) + LoRA sobre unos cientos de ejemplos etiquetados.
- 2 Comparar contra las líneas base del curso: diccionarios (hoy) y logística sobre TF-IDF (S5) — **mismo test set, misma vara** (S1–S2, siempre).

El mensaje de método

El LLM no reemplaza el pipeline honesto: **entra en él** como un clasificador más

La tercera vía: el LLM como instrumento de medición

Sin entrenar nada, un LLM ya sirve para **producir variables** (Korinek, 2023; Dell, 2025):

- **Etiquetar a escala** (*zero/few-shot*): clasificar 200.000 noticias por tema/tono con un prompt — lo que antes exigía un ejército de asistentes.
- **Extraer estructura**: convertir sentencias, contratos o licitaciones en tablas (partes, montos, fechas).
- **Embeddings de documentos** como covariables o para medir similitud (firmas, políticas, discursos).

La tercera vía: el LLM como instrumento de medición

Sin entrenar nada, un LLM ya sirve para **producir variables** (Korinek, 2023; Dell, 2025):

- **Etiquetar a escala** (*zero/few-shot*): clasificar 200.000 noticias por tema/tono con un prompt — lo que antes exigía un ejército de asistentes.
- **Extraer estructura**: convertir sentencias, contratos o licitaciones en tablas (partes, montos, fechas).
- **Embeddings de documentos** como covariables o para medir similitud (firmas, políticas, discursos).

Las reglas del oficio (no negociables):

- 1 **Validar contra humanos**: etiquetar a mano una muestra y reportar el acuerdo — el LLM es un **proxy** y se audita como tal (S7–S8).
- 2 **Reproducibilidad**: fijar modelo y versión, temperatura 0, publicar los prompts; preferir modelos abiertos congelados.
- 3 **Ojo con la contaminación temporal**: el modelo “ya leyó” el futuro de sus datos históricos — fatal para ejercicios de predicción retrospectiva (*lookahead bias*).

La tercera vía: el LLM como instrumento de medición

Sin entrenar nada, un LLM ya sirve para **producir variables** (Korinek, 2023; Dell, 2025):

- **Etiquetar a escala** (*zero/few-shot*): clasificar 200.000 noticias por tema/tono con un prompt — lo que antes exigía un ejército de asistentes.
- **Extraer estructura**: convertir sentencias, contratos o licitaciones en tablas (partes, montos, fechas).
- **Embeddings de documentos** como covariables o para medir similitud (firmas, políticas, discursos).

Las reglas del oficio (no negociables):

- 1 **Validar contra humanos**: etiquetar a mano una muestra y reportar el acuerdo — el LLM es un **proxy** y se audita como tal (S7–S8).
- 2 **Reproducibilidad**: fijar modelo y versión, temperatura 0, publicar los prompts; preferir modelos abiertos congelados.
- 3 **Ojo con la contaminación temporal**: el modelo “ya leyó” el futuro de sus datos históricos — fatal para ejercicios de predicción retrospectiva (*lookahead bias*).

- 1 Texto clásico: contar palabras con inteligencia
- 2 Embeddings: palabras con geometría
- 3 Transformers y LLMs
- 4 El texto en la economía: síntesis y cierre del curso

El estante de aplicaciones (para sus proyectos y sus tesis)

- **Incertidumbre de política económica** (Baker, Bloom & Davis, 2016, QJE): el índice EPU — conteo disciplinado de prensa — hoy citado en miles de papers y replicado por países. La prueba de que *contar bien* ya es una contribución.

El estante de aplicaciones (para sus proyectos y sus tesis)

- **Incertidumbre de política económica** (Baker, Bloom & Davis, 2016, QJE): el índice EPU — conteo disciplinado de prensa — hoy citado en miles de papers y replicado por países. La prueba de que *contar bien* ya es una contribución.
- **Deliberación en el FOMC** (Hansen, McMahon & Prat, 2018, QJE): LDA + diseño cuasiexperimental — texto y causalidad en el mismo paper.

El estante de aplicaciones (para sus proyectos y sus tesis)

- **Incertidumbre de política económica** (Baker, Bloom & Davis, 2016, QJE): el índice EPU — conteo disciplinado de prensa — hoy citado en miles de papers y replicado por países. La prueba de que *contar bien* ya es una contribución.
- **Deliberación en el FOMC** (Hansen, McMahon & Prat, 2018, QJE): LDA + diseño cuasiexperimental — texto y causalidad en el mismo paper.
- **La voz de la política monetaria** (Gorodnichenko, Pham & Talavera, 2023, AER): el *tono vocal* de los anuncios de la Fed, medido con deep learning, mueve mercados — datos no estructurados más allá del texto escrito.

El estante de aplicaciones (para sus proyectos y sus tesis)

- **Incertidumbre de política económica** (Baker, Bloom & Davis, 2016, QJE): el índice EPU — conteo disciplinado de prensa — hoy citado en miles de papers y replicado por países. La prueba de que *contar bien* ya es una contribución.
- **Deliberación en el FOMC** (Hansen, McMahon & Prat, 2018, QJE): LDA + diseño cuasiexperimental — texto y causalidad en el mismo paper.
- **La voz de la política monetaria** (Gorodnichenko, Pham & Talavera, 2023, AER): el *tono vocal* de los anuncios de la Fed, medido con deep learning, mueve mercados — datos no estructurados más allá del texto escrito.
- **El survey de la casa**: Ash & Hansen (2023, *Annual Review*): el estado del arte de texto-como-datos en economía, de conteos a LLMs.

El estante de aplicaciones (para sus proyectos y sus tesis)

- **Incertidumbre de política económica** (Baker, Bloom & Davis, 2016, QJE): el índice EPU — conteo disciplinado de prensa — hoy citado en miles de papers y replicado por países. La prueba de que *contar bien* ya es una contribución.
- **Deliberación en el FOMC** (Hansen, McMahon & Prat, 2018, QJE): LDA + diseño cuasiexperimental — texto y causalidad en el mismo paper.
- **La voz de la política monetaria** (Gorodnichenko, Pham & Talavera, 2023, AER): el *tono vocal* de los anuncios de la Fed, medido con deep learning, mueve mercados — datos no estructurados más allá del texto escrito.
- **El survey de la casa**: Ash & Hansen (2023, *Annual Review*): el estado del arte de texto-como-datos en economía, de conteos a LLMs.

Patrón de los cuatro

Ninguno “usa IA” como adorno: en todos, el texto **mide algo** que antes no se podía medir, y esa medición alimenta una pregunta económica clásica.

Recap de la sesión

- ➊ **Texto clásico:** tokenizar $\rightarrow$ DTM $\rightarrow$ TF-IDF; con la matriz, todo el curso aplica (NB, Lasso, k -means). Diccionarios: del dominio o nada (Loughran–McDonald). LDA para tópicos: no supervisado en versión texto.
- ➋ **Embeddings:** la hipótesis distribucional vuelve vectores a las palabras; geometría con significado; su límite: un vector por palabra.
- ➌ **Atención/transformers:** representaciones construidas *en contexto* — una regresión ponderada que la red aprende; apilada en capas, escala sin límite aparente.
- ➍ **LLM** = transformer gigante + predecir-la-siguiente-palabra + cross-entropy + Adam. Sin ingredientes nuevos: escala. El juguete que entrenamos ES el modelo grande, dividido por 10^5 .
- ➎ **LoRA:** adaptar modelos abiertos con $< 1\%$ de parámetros — el LLM como un clasificador más *dentro* del pipeline honesto.
- ➏ **LLM como instrumento de medición:** etiquetar/extraer/representar a escala — validando contra humanos, congelando versiones, publicando prompts.

Cierre del curso...

El curso en una diapositiva (la de verdad)

- 1 **S1**: generalizar es el problema; $MSE = \text{sesgo}^2 + \text{varianza} + \sigma^2$.
- 2 **S2**: medir honestamente (CV) y encoger con criterio (Ridge/Lasso).
- 3 **S3**: la teoría del Lasso — y “selecciona predictores, no causas”.
- 4 **S4**: árboles y ensambles — promediar mata varianza, sumar mata sesgo.
- 5 **S5**: clasificar es decidir — el umbral es economía, no estadística.
- 6 **S6**: la predicción al servicio de β — DML y *causal forests*.
- 7 **S7**: sin y: representar es comprimir con sentido.
- 8 **S8**: redes — composición de representaciones; ver desde el cielo.
- 9 **S9**: el texto como dato; los LLMs como la misma maquinaria, escalada.

El curso en una diapositiva (la de verdad)

- ➊ **S1**: generalizar es el problema; $\text{MSE} = \text{sesgo}^2 + \text{varianza} + \sigma^2$.
- ➋ **S2**: medir honestamente (CV) y encoger con criterio (Ridge/Lasso).
- ➌ **S3**: la teoría del Lasso — y “selecciona predictores, no causas”.
- ➍ **S4**: árboles y ensambles — promediar mata varianza, sumar mata sesgo.
- ➎ **S5**: clasificar es decidir — el umbral es economía, no estadística.
- ➏ **S6**: la predicción al servicio de β — DML y *causal forests*.
- ➐ **S7**: sin y: representar es comprimir con sentido.
- ➑ **S8**: redes — composición de representaciones; ver desde el cielo.
- ➒ **S9**: el texto como dato; los LLMs como la misma maquinaria, escalada.

Los tres mandamientos que se llevan

(1) Evaluar fuera de muestra, siempre, con el pipeline honesto. **(2)** Identificar antes de estimar: el diseño no se delega al algoritmo. **(3)** Toda medición por ML es un proxy: se valida, se declara, se audita.

El curso en una diapositiva (la de verdad)

- ➊ **S1:** generalizar es el problema; $\text{MSE} = \text{sesgo}^2 + \text{varianza} + \sigma^2$.
- ➋ **S2:** medir honestamente (CV) y encoger con criterio (Ridge/Lasso).
- ➌ **S3:** la teoría del Lasso — y “selecciona predictores, no causas”.
- ➍ **S4:** árboles y ensambles — promediar mata varianza, sumar mata sesgo.
- ➎ **S5:** clasificar es decidir — el umbral es economía, no estadística.
- ➏ **S6:** la predicción al servicio de β — DML y *causal forests*.
- ➐ **S7:** sin y: representar es comprimir con sentido.
- ➑ **S8:** redes — composición de representaciones; ver desde el cielo.
- ➒ **S9:** el texto como dato; los LLMs como la misma maquinaria, escalada.

Los tres mandamientos que se llevan

(1) Evaluar fuera de muestra, siempre, con el pipeline honesto. **(2)** Identificar antes de estimar: el diseño no se delega al algoritmo. **(3)** Toda medición por ML es un proxy: se valida, se declara, se audita.

Logística final

Hoy, después del descanso: presentaciones de los proyectos finales (el 30% del proyecto) — orden y tiempos publicados en Intu.

Hoy, después del descanso: presentaciones de los proyectos finales (el 30% del proyecto) — orden y tiempos publicados en Intu.

Para profundizar en lo de hoy (lecturas de despedida):

- Gentzkow, Kelly & Taddy (2019), *Text as Data*, JEL — el mapa clásico.
- Korinek (2023), *Generative AI for Economic Research*, JEL — el manual de uso para investigadores (se actualiza en línea).
- Dell (2025), *Deep Learning for Economists*, JEL — el puente definitivo entre las sesiones 8 y 9 y su investigación.

Logística final

Hoy, después del descanso: presentaciones de los proyectos finales (el 30% del proyecto) — orden y tiempos publicados en Intu.

Para profundizar en lo de hoy (lecturas de despedida):

- Gentzkow, Kelly & Taddy (2019), *Text as Data*, JEL — el mapa clásico.
- Korinek (2023), *Generative AI for Economic Research*, JEL — el manual de uso para investigadores (se actualiza en línea).
- Dell (2025), *Deep Learning for Economists*, JEL — el puente definitivo entre las sesiones 8 y 9 y su investigación.

Entrega final del proyecto: reporte (máx. 10 páginas) + repositorio reproducible, en las fechas publicadas en Intu. La **declaración de uso de IA** va en la primera página del reporte.

Logística final

Hoy, después del descanso: presentaciones de los proyectos finales (el 30% del proyecto) — orden y tiempos publicados en Intu.

Para profundizar en lo de hoy (lecturas de despedida):

- Gentzkow, Kelly & Taddy (2019), *Text as Data*, JEL — el mapa clásico.
- Korinek (2023), *Generative AI for Economic Research*, JEL — el manual de uso para investigadores (se actualiza en línea).
- Dell (2025), *Deep Learning for Economists*, JEL — el puente definitivo entre las sesiones 8 y 9 y su investigación.

Entrega final del proyecto: reporte (máx. 10 páginas) + repositorio reproducible, en las fechas publicadas en Intu. La **declaración de uso de IA** va en la primera página del reporte.

Gracias por el semestre.

Referencias esenciales

- Gentzkow, M., Kelly, B., & Taddy, M. (2019). Text as Data. *JEL*, 57(3), 535–574.
- Loughran, T., & McDonald, B. (2011). When Is a Liability Not a Liability? *Journal of Finance*, 66(1), 35–65.
- Blei, D., Ng, A., & Jordan, M. (2003). Latent Dirichlet Allocation. *JMLR*, 3, 993–1022.
- Mikolov, T., et al. (2013). Distributed Representations of Words and Phrases. *NeurIPS*.
- Vaswani, A., et al. (2017). Attention Is All You Need. *NeurIPS*.
- Hu, E., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *arXiv:2106.09685*.
- Baker, S., Bloom, N., & Davis, S. (2016). Measuring Economic Policy Uncertainty. *QJE*, 131(4), 1593–1636.
- Hansen, S., McMahon, M., & Prat, A. (2018). Transparency and Deliberation within the FOMC. *QJE*, 133(2), 801–870.
- Gorodnichenko, Y., Pham, T., & Talavera, O. (2023). The Voice of Monetary Policy. *AER*, 113(2), 548–584.
- Ash, E., & Hansen, S. (2023). Text Algorithms in Economics. *Annual Review of Economics*, 15, 659–688.
- Korinek, A. (2023). Generative AI for Economic Research. *JEL*, 61(4), 1281–1317.