Big Data y Machine Learning para Economía Aplicada

Week 09: El proyecto final — presentaciones y cierre del curso

Eduard F. Martinez Gonzalez

Departamento de Economía, Universidad Icesi

October 12, 2026

Hoy

8:00–8:15	El ranking del Problem Set 2 y el cierre del curso en una diapositiva
8:15–11:00	Presentaciones del proyecto: 20 minutos más preguntas [individuales: seis de 20 + 5; en parejas: tres de 30 + 15; por definir]
Hoy	Entrega 2: el documento de la propuesta (máximo 8 páginas)

Lo que se presenta hoy no es un informe con resultados: es una **propuesta de investigación predictiva**, el diseño de un estudio que resiste las siete preguntas del curso. Quien tenga resultados preliminares los muestra como lo que son: preliminares.

La regla de la sala

Cada presentación termina con las preguntas de la sala antes que las del profesor. Todos evalúan con la misma lista ("Las preguntas que les vamos a hacer"); la nota la pone el profesor.

Debrief del Problem Set 2: el ranking del curso

Quince minutos [tabla y comentarios por completar después de calificar]

1. **La tabla de posiciones final:** el RMSE de prueba del modelo final del curso de cada equipo, junto al de validación y al del Problem Set 1. ¿Quién subió, quién bajó, y por qué?
2. **Qué modelo ganó:** ¿el *boosting*, el bosque, un promedio de familias, o el modelo regularizado del primer problem set? Cuánto valió la flexibilidad sobre la regresión regularizada.
3. **La comparación con el caso del curso:** con los puestos de votación, pasar del mejor lineal (censo + departamento, 15,6) al *boosting* (12,8) valió 2,8 puntos de RMSE —la flexibilidad—, y combinar las dos ligas dejó 11,4. ¿En la vivienda pasó lo mismo? La explicación de la diferencia vale más que el número.
4. **La caja abierta:** qué bloques y variables sostuvieron la predicción en los mejores modelos, y si el mapa manda en el mercado de vivienda como mandó en el voto.
5. **Los tropiezos frecuentes:** la red sin escala o sin parada temprana; el SHAP sobre el entrenamiento; la prueba abierta dos veces.

1 Las presentaciones del proyecto

2 Cierre del curso

Lo que debe contener la presentación (40 puntos del proyecto)

Las mismas siete secciones del documento, en 20 minutos:

1. **La pregunta y la decisión:** quién usaría la predicción y qué haría distinto con ella.
2. **Los datos:** fuente, unidad, tamaño, predictores por bloques; qué se sabría al predecir.
3. **Métrica, referencia y validación:** la métrica que la decisión necesita; la referencia que usaría sin el modelo; el esquema que respeta la estructura de los datos.
4. **Los métodos y por qué:** al menos dos familias del curso, y la razón de cada una.
5. **Qué se interpretaría y qué no.**
6. **Riesgos:** filtración, extrapolación, cambio de régimen; equidad si hay personas.
7. **Plan de trabajo.**

Cómo se califica: coherencia entre la decisión, la y, la métrica, la referencia y la validación; justificación de los métodos con lo visto en el curso; honestidad sobre lo que el modelo no dirá; y las respuestas a las preguntas. El diseño de las diapositivas no se califica.

Las preguntas que les vamos a hacer

La lista con la que toda la sala evalúa

1. ¿Qué decisión cambia si la predicción es buena? ¿Y si es mala?
2. ¿Qué información existe *en el momento de predecir*? ¿Qué variable de su lista es filtración disfrazada?
3. ¿Cuál es la referencia? ¿Cuánto tendría que ganarle el modelo para que valga la pena?
4. ¿Su validación respeta los grupos, el tiempo o el espacio de los datos? ¿Qué pregunta responde su esquema?
5. ¿Qué harían si el modelo flexible no le gana al simple?
6. ¿Qué van a interpretar, con qué herramienta, y qué frase se niegan a escribir?
7. ¿Dónde se degrada el modelo: qué unidades, qué período, qué rango de las x?
8. Si el proyecto asigna algo a personas, ¿qué métrica por grupo van a reportar?

Una propuesta que responde las ocho ya es un capítulo de tesis. Una que responde cinco es un buen semestre.

El documento: la lista de chequeo antes de entregarlo

- **Máximo 8 páginas**, con las siete secciones y sus nombres; tablas con unidades; figuras legibles.
- La y definida con precisión (unidad, momento, cómo se mide) y la decisión en la primera página.
- La **referencia** explícita, y la métrica en las unidades de la decisión.
- El **esquema de validación** dibujado o descrito: qué queda en cada pliegue y por qué.
- Los métodos con sus hiperparámetros principales y cómo se elegirían.
- Un párrafo de **riesgos** con al menos una filtración concreta que evitarían.
- Las tres frases que *no* van a escribir sobre el modelo (efectos, individuos, pronósticos).
- Si hay datos preliminares: partición, receta, referencia y prueba, con la disciplina de los problem sets.

Entrega: el documento se entrega hoy [hora y medio por confirmar]. Vale 50 de los 100 puntos del proyecto; el proyecto es el 60% del curso.

1 Las presentaciones del proyecto

2 Cierre del curso

Lo que se llevan del curso

Un flujo de trabajo, el mismo de la sesión 2 a la 7: partir $\rightarrow$ preprocesar dentro del *pipeline* $\rightarrow$ validar según la estructura $\rightarrow$ afinar en el entrenamiento $\rightarrow$ evaluar contra la referencia $\rightarrow$ interpretar con advertencias $\rightarrow$ reportar dónde falla.

Un kit de métodos con sus cuándo: la recta y la penalización cuando la señal es suave o los datos pocos; la logística y el umbral cuando la y es una decisión; los árboles y sus ensambles en datos tabulares; PCA y k-medias cuando no hay y; las redes cuando la estructura está en la representación, o se puede prestar.

Una actitud:

- Y, no β: predecir bien y explicar bien son preguntas distintas.
- La tabla decide, en la misma prueba, con intervalos, y una sola vez.
- Significativo no es predictivo; importante no es causal; el Lasso selecciona predictores, no causas.
- Un número de CV responde la pregunta de su esquema.
- Representar es comprimir con sentido.

Lo que no vimos, y dónde seguir

- **Texto y modelos de lenguaje:** contar palabras convierte un documento en una fila con miles de columnas, y desde ahí aplica todo el curso; los *embeddings* y los LLM son representaciones prestadas que se validan contra etiquetas humanas. Gentzkow, Kelly & Taddy (2019); Dell (2025).
- **Machine learning causal:** doble selección, *double machine learning* y bosques causales: el ML predice las molestias y el economista pone la identificación. Athey & Imbens (2019); Chernozhukov et al. (2018). El curso de Inferencia Causal es el lugar.
- **Pronóstico y carreras de caballos:** muchas familias en series largas, con validación hacia adelante. Medeiros et al. (2021); Gu, Kelly & Xiu (2020); Goulet Coulombe et al. (2022).
- **Equidad y decisiones algorítmicas:** qué métrica por grupo, y por qué no se pueden tener todas. Kleinberg, Mullainathan & Raghavan (2017); Obermeyer et al. (2019).
- **Lo que quedó en los apéndices:** CV anidado, búsqueda bayesiana, BART, SVM, mezclas de normales, Adam. Están en los decks para cuando los necesiten.

Cierre

- **Notas:** el ranking del Problem Set 2 queda cerrado hoy; la nota del proyecto sale del documento (50), la presentación (40) y el *pitch* del 3 de noviembre (10). Notas definitivas en el sistema desde el 1 de diciembre.
- **Los materiales** quedan en el repositorio del curso: los decks, las aplicaciones en R con sus datos y los enunciados. Los scripts de las sesiones son el punto de partida de cualquier proyecto que sigan.
- **La evaluación del curso** en el sistema institucional: la lean dos veces, como las desventajas de Molnar.
- **Gracias.** Un curso de predicción termina como debe: con la prueba, una sola vez.

Preguntas y presentaciones. . .

Referencias esenciales del curso

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. [ESL]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.). https://christophm.github.io/interpretable-ml-book/
- Gentzkow, M., Kelly, B., & Taddy, M. (2019). Text as Data. *Journal of Economic Literature*, 57(3), 535–574.
- Dell, M. (2025). Deep Learning for Economists. *Journal of Economic Literature*, 63(1), 5–58.
- Chernozhukov, V., et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Medeiros, M., Vasconcelos, G., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment. *JBES*, 39(1), 98–119.
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. *ITCS*.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Documento de trabajo. [De donde salen los datos del caso.]