

Big Data y Machine Learning para Economía Aplicada

Week 09: El proyecto final — presentaciones y cierre del curso

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

September 20, 2026

8:00–8:15	El ranking del Problem Set 2 y el cierre del curso en una diapositiva
8:15–11:00	Presentaciones del proyecto: 20 minutos más preguntas [individuales: seis de 20 + 5; en parejas: tres de 30 + 15; por definir]
Hoy	Entrega 2: el documento de la propuesta (máximo 8 páginas)

Lo que se presenta hoy no es un informe con resultados: es una **propuesta de investigación predictiva**, el diseño de un estudio que resiste las siete preguntas del curso. Quien tenga resultados preliminares los muestra como lo que son: preliminares.

La regla de la sala

Cada presentación termina con las preguntas de la sala antes que las del profesor. Todos evalúan con la misma lista (“Las preguntas que les vamos a hacer”); la nota la pone el profesor.

Debrief del Problem Set 2: el ranking del curso

Quince minutos [tabla y comentarios por completar después de calificar]

- 1 **La tabla de posiciones final:** el RMSE de prueba del modelo final del curso de cada equipo, junto al de validación y al del Problem Set 1. ¿Quién subió, quién bajó, y por qué?
- 2 **Qué modelo ganó:** ¿el *boosting*, el bosque, un promedio de familias, o el modelo regularizado del primer problem set? Cuánto valió la flexibilidad sobre la regresión regularizada.
- 3 **La comparación con el caso del curso:** con los puestos de votación, pasar del mejor lineal (Lasso, 14,7) al bosque con coordenadas (12,1) valió 2,6 puntos de RMSE, y la ganancia vino sobre todo de la geografía. ¿En la vivienda pasó lo mismo? La explicación de la diferencia vale más que el número.
- 4 **La caja abierta:** qué bloques y variables sostuvieron la predicción en los mejores modelos, y si el mapa manda en el mercado de vivienda como mandó en el voto.
- 5 **Los tropiezos frecuentes:** la red sin escala o sin parada temprana; el SHAP sobre el entrenamiento; la prueba abierta dos veces.

1 Las presentaciones del proyecto

2 Cierre del curso

Lo que debe contener la presentación (40 puntos del proyecto)

Las mismas siete secciones del documento, en 20 minutos:

- 1 **La pregunta y la decisión:** quién usaría la predicción y qué haría distinto con ella.
- 2 **Los datos:** fuente, unidad, tamaño, predictores por bloques; qué se sabría al predecir.
- 3 **Métrica, referencia y validación:** la métrica que la decisión necesita; la referencia que usaría sin el modelo; el esquema que respeta la estructura de los datos.
- 4 **Los métodos y por qué:** al menos dos familias del curso, y la razón de cada una.
- 5 **Qué se interpretaría y qué no.**
- 6 **Riesgos:** filtración, extrapolación, cambio de régimen; equidad si hay personas.
- 7 **Plan de trabajo.**

Cómo se califica: coherencia entre la decisión, la y, la métrica, la referencia y la validación; justificación de los métodos con lo visto en el curso; honestidad sobre lo que el modelo no dirá; y las respuestas a las preguntas. El diseño de las diapositivas no se califica.

Las preguntas que les vamos a hacer

La lista con la que toda la sala evalúa

- 1 ¿Qué decisión cambia si la predicción es buena? ¿Y si es mala?
- 2 ¿Qué información existe *en el momento de predecir*? ¿Qué variable de su lista es filtración disfrazada?
- 3 ¿Cuál es la referencia? ¿Cuánto tendría que ganarle el modelo para que valga la pena?
- 4 ¿Su validación respeta los grupos, el tiempo o el espacio de los datos? ¿Qué pregunta responde su esquema?
- 5 ¿Qué harían si el modelo flexible no le gana al simple?
- 6 ¿Qué van a interpretar, con qué herramienta, y qué frase se niegan a escribir?
- 7 ¿Dónde se degrada el modelo: qué unidades, qué período, qué rango de las x ?
- 8 Si el proyecto asigna algo a personas, ¿qué métrica por grupo van a reportar?

Una propuesta que responde las ocho ya es un capítulo de tesis. Una que responde cinco es un buen semestre.

El documento: la lista de chequeo antes de entregarlo

- **Máximo 8 páginas**, con las siete secciones y sus nombres; tablas con unidades; figuras legibles.
- La *y* definida con precisión (unidad, momento, cómo se mide) y la decisión en la primera página.
- La **referencia** explícita, y la métrica en las unidades de la decisión.
- El **esquema de validación** dibujado o descrito: qué queda en cada pliegue y por qué.
- Los métodos con sus hiperparámetros principales y cómo se elegirían.
- Un párrafo de **riesgos** con al menos una filtración concreta que evitarían.
- Las tres frases que *no* van a escribir sobre el modelo (efectos, individuos, pronósticos).
- Si hay datos preliminares: partición, receta, referencia y prueba, con la disciplina de los problem sets.

Entrega: el documento se entrega hoy [hora y medio por confirmar]. Vale 50 de los 100 puntos del proyecto; el proyecto es el 60% del curso.

1 Las presentaciones del proyecto

2 Cierre del curso

Lo que se llevan del curso

Un flujo de trabajo, el mismo de la sesión 2 a la 7: partir → preprocesar dentro del *pipeline* → validar según la estructura → afinar en el entrenamiento → evaluar contra la referencia → interpretar con advertencias → reportar dónde falla.

Un kit de métodos con sus cuándo: la recta y la penalización cuando la señal es suave o los datos pocos; la logística y el umbral cuando la y es una decisión; los árboles y sus ensambles en datos tabulares; PCA y k -medias cuando no hay y ; las redes cuando la estructura está en la representación, o se puede prestar.

Una actitud:

- Y , no β : predecir bien y explicar bien son preguntas distintas.
- La tabla decide, en la misma prueba, con intervalos, y una sola vez.
- Significativo no es predictivo; importante no es causal; el Lasso selecciona predictores, no causas.
- Un número de CV responde la pregunta de su esquema.
- Representar es comprimir con sentido.

Lo que no vimos, y dónde seguir

- **Texto y modelos de lenguaje:** contar palabras convierte un documento en una fila con miles de columnas, y desde ahí aplica todo el curso; los *embeddings* y los LLM son representaciones prestadas que se validan contra etiquetas humanas. Gentzkow, Kelly & Taddy (2019); Dell (2025).
- **Machine learning causal:** doble selección, *double machine learning* y bosques causales: el ML predice las molestias y el economista pone la identificación. Athey & Imbens (2019); Chernozhukov et al. (2018). El curso de Inferencia Causal es el lugar.
- **Pronóstico y carreras de caballos:** muchas familias en series largas, con validación hacia adelante. Medeiros et al. (2021); Gu, Kelly & Xiu (2020); Goulet Coulombe et al. (2022).
- **Equidad y decisiones algorítmicas:** qué métrica por grupo, y por qué no se pueden tener todas. Kleinberg, Mullainathan & Raghavan (2017); Obermeyer et al. (2019).
- **Lo que quedó en los apéndices:** CV anidado, búsqueda bayesiana, BART, SVM, mezclas de normales, Adam. Están en los decks para cuando los necesiten.

Cierre

- **Notas:** el ranking del Problem Set 2 queda cerrado hoy; la nota del proyecto sale del documento (50), la presentación (40) y el *pitch* del 3 de noviembre (10). Notas definitivas en el sistema desde el 1 de diciembre.
- **Los materiales** quedan en el repositorio del curso: los decks, las aplicaciones en R con sus datos y los enunciados. Los scripts de las sesiones son el punto de partida de cualquier proyecto que sigan.
- **La evaluación del curso** en el sistema institucional: la lean dos veces, como las desventajas de Molnar.
- **Gracias.** Un curso de predicción termina como debe: con la prueba, una sola vez.

Preguntas y presentaciones. . .

Referencias esenciales del curso

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2. ed.). Springer. [ISL]
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2. ed.). Springer. [ESL]
- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *JEP*, 31(2), 87–106.
- Athey, S., & Imbens, G. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Molnar, C. (2025). *Interpretable Machine Learning* (3. ed.).
<https://christophm.github.io/interpretable-ml-book/>
- Gentzkow, M., Kelly, B., & Taddy, M. (2019). Text as Data. *Journal of Economic Literature*, 57(3), 535–574.
- Dell, M. (2025). Deep Learning for Economists. *Journal of Economic Literature*, 63(1), 5–58.
- Chernozhukov, V., et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Medeiros, M., Vasconcelos, G., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment. *JBES*, 39(1), 98–119.
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. *ITCS*.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? Documento de trabajo. [De donde salen los datos del caso.]