

Problem Set 1: ¿Cuánto vale una vivienda en Cali?

Big Data y Machine Learning para Economía Aplicada — 60-121 (NRC 10-993)

Universidad Icesi — Departamento de Economía

Prof. Eduard Fernando Martínez González

Información general

- **Fecha de entrega:** martes 20 de octubre de 2026, antes de clase (8:00 a. m.). Subir al campus virtual un .zip con el .pdf del reporte, el código (00_run.R y scripts auxiliares) y el archivo predicciones.csv que produce 00_run.R.
- **Peso:** 15 % de la nota final. Trabajo en parejas.
- **Datos:** vivienda_cali.rds y su diccionario (diccionario_vivienda.csv), publicados en la carpeta problem-sets/pset-1/ del repositorio del curso: avisos reales de venta de casas y apartamentos en Cali (2019–2020). La partición viene definida en la variable muestra y es la misma para todos los equipos y para los dos problem sets. **En los avisos de prueba, precio y vis están ocultos (NA):** la nota del ranking se calcula comparando sus predicciones con los valores reales, que sólo tiene el profesor.
- **Cómo se califica:** cuatro partes aplicadas que siguen las sesiones 2 a 4, el ranking del curso y la reproducibilidad del código (rúbrica al final). No hay preguntas teóricas. Debrief con el ranking en la sesión 7.
- **IA:** permitida, declarando qué se usó y para qué.

La pregunta y las reglas del juego

Una entidad evaluadora quiere saber cuánto vale una vivienda que sale al mercado en Cali, conociendo sólo lo que dice el aviso: tipo, área, habitaciones, baños y ubicación. La y es el **precio en millones de pesos**. El problem set recorre las sesiones 2 a 4 con esa única pregunta: primero una referencia y una regresión, luego cómo validar y regularizar sin engañarse, después la versión binaria (¿es vivienda de interés social?) y, al final, un modelo elegido con criterio.

Tres reglas que valen para todo el problem set:

1. **La prueba no se puede mirar** (los precios están ocultos), así que toda decisión y toda evaluación intermedia se hace con validación *dentro* del entrenamiento. La prueba se usa una sola vez, al final, para predecir.
2. **Toda comparación va en la tabla del Anexo A:** misma validación, mismas métricas (RMSE, MAE y R^2 de validación), en millones de pesos. Si modela $\log(\text{precio})$, las métricas se reportan igual en millones, sobre el precio.
3. **El ranking del curso.** 00_run.R debe terminar escribiendo predicciones.csv con una fila por aviso de prueba y las columnas id, precio_predicho y prob_vis. El RMSE de prueba del precio, calculado por el profesor, ordena a los equipos y determina 20 de los 100 puntos.

1. Parte 1 — La referencia y la regresión lineal (sesión 2; 15 pts)

Contexto. Antes de cualquier método flexible hacen falta dos cosas: una referencia que no usa predictores (la media) y el modelo que ya saben estimar (una regresión lineal). Todo lo que venga después tiene que ganarles. Como la prueba está oculta, en esta parte cada equipo construye su propia validación: parta el entrenamiento en ajuste y validación (80/20, con semilla).

Pregunta 1.

- (a) Cargue la base y describa lo esencial: número de avisos de entrenamiento y de prueba, media y desviación del precio, composición por tipo, y qué variables tienen faltantes y cuántos. Un mapa sencillo (`plot` de `lon` contra `lat`) coloreado por el precio.
- (b) Estime sobre el ajuste tres modelos: M0, la media del precio; M1, la recta `precio ~ area`; M2, una regresión con área, baños, tipo y coordenadas. Evalúe los tres en su validación con RMSE, MAE y R^2 (contra la media del ajuste): son las filas 0 a 2 del Anexo A.
- (c) Para M2, grafique predicho vs. observado en la validación y el RMSE por quintil del precio observado. ¿Se comprimen las predicciones hacia la media? ¿Dónde falla más el modelo: en las viviendas baratas o en las caras? ¿En qué zonas del mapa?
- (d) En cinco líneas: cuánto reduce el error cada modelo respecto a la media y qué sugiere eso sobre el techo de lo predecible con lo que dice un aviso.

2. Parte 2 — Validación y regularización (sesión 3; 25 pts)

Contexto. Para elegir especificaciones e hiperparámetros sin gastar datos, la herramienta es la validación cruzada. Pero los avisos no son independientes: los de un mismo sector se parecen, y repartirlos al azar puede responder una pregunta distinta de la que le interesa a la evaluadora (tasar viviendas de zonas que conoce vs. de zonas nuevas). Y con interacciones y polinomios los predictores se multiplican: ahí entran Ridge, Lasso y *Elastic Net*.

Pregunta 2.

- (a) Valide M1 y M2 con validación cruzada de 5 pliegues aleatorios sobre el entrenamiento (promedio y desviación del RMSE entre pliegues). Compare con lo que obtuvo en su validación de la Parte 1.
- (b) Repita con pliegues *espaciales*: divida la ciudad en zonas con una grilla sobre `lon` y `lat` (o el método que justifique) y use las zonas como pliegues. Explique qué pregunta responde cada esquema y cuál usará en el resto del problem set.
- (c) Con el esquema elegido, decida entre al menos tres especificaciones: M2; una con interacciones que usted justifique (por ejemplo, `area × tipo`); y una con polinomios o logaritmos de las variables continuas. Todo preprocesamiento que se aprende de los datos (estandarizar, imputar los faltantes de `habitaciones`, crear indicadoras) se estima dentro de cada pliegue; explique en tres líneas por qué hacerlo antes filtra información.
- (d) Construya la matriz ampliada (la especificación más rica del literal anterior) y reporte n y p . Ajuste Ridge, Lasso y *Elastic Net* con `glmnet`, eligiendo λ (y α) con su validación. Grafique el RMSE de validación contra $\log \lambda$; reporte $\lambda_{\min}$ y λ_{1se} .
- (e) Ajuste k -NN sobre `lon` y `lat` estandarizadas (el “avalúo por vecindario”), eligiendo k por la misma validación entre $\{1, 5, 10, 25, 50, 100\}$. Reúna en la tabla del Anexo A el RMSE de validación de todos los modelos hasta aquí. Liste las variables que el Lasso conserva en λ_{1se} y explique en dos líneas por qué eso no dice qué variables *causan* el precio.

3. Parte 3 — Clasificación: ¿es vivienda de interés social? (sesión 4; 15 pts)

Contexto. La versión binaria de la pregunta: `vis` vale 1 si el precio del aviso está en el rango de la vivienda de interés social (hasta 135 salarios mínimos del año de publicación; ver el diccionario). Es una clase rara: la mayoría de los avisos no son VIS. Clasificar es decidir con un umbral sobre una probabilidad, y el umbral correcto depende de los costos de equivocarse. Igual que con el precio, `vis` está oculta en la prueba: todo se evalúa con su validación.

Pregunta 3.

- (a) Reporte la prevalencia de `vis` en el entrenamiento y la exactitud del clasificador trivial que asigna todos los avisos a la clase mayoritaria: la referencia de esta parte. ¿Por qué esa exactitud tan alta no significa nada?
- (b) Estime una regresión logística con los predictores del aviso (sin usar el precio, obviamente). En su validación: curva ROC y AUC; matriz de confusión, precisión y *recall* al umbral 0,5. ¿Cuántas VIS encuentra ese umbral?
- (c) Piense en el usuario: una secretaria de vivienda quiere encontrar oferta VIS para un programa de subsidios, y revisar manualmente un aviso cuesta poco frente a dejar pasar una VIS. Asigne costos, calcule $\tau^* = c_{FP} / (c_{FP} + c_{FN})$, repita la matriz con τ^* y compare con la curva precisión-*recall*. ¿Qué umbral recomienda y cuántos avisos manda a revisar?
- (d) Gráfico de calibración por deciles de la probabilidad estimada. ¿Las probabilidades se pueden usar como probabilidades?

4. Parte 4 — El modelo final y las predicciones (15 pts)

Contexto. El cierre del *pipeline*: elegir con la validación, reajustar con todo el entrenamiento y predecir la prueba una sola vez. La disciplina de esta parte es la del curso entero.

Pregunta 4.

- (a) **Modelo final del precio.** Elija el modelo con menor RMSE de validación (puede ser cualquiera de los de la Parte 2 o una mejora que justifique con la misma validación), reajústelo con todo el entrenamiento y prediga el precio de los avisos de prueba. Escriba en la primera línea del reporte: “Modelo final: ... RMSE de validación: ...”.
- (b) **Modelo final de VIS.** Haga lo mismo con la probabilidad de VIS (logística o logística penalizada) y prediga `prob_vis` en la prueba.
- (c) `00_run.R` debe correr de principio a fin y escribir `predicciones.csv` con las columnas `id`, `precio_predicho` (en millones) y `prob_vis` para los avisos de prueba. Verifique que tiene exactamente una fila por aviso de prueba y ninguna NA.
- (d) Cierre con un párrafo para la evaluadora: qué tan bien se puede tasar una vivienda con lo que dice el aviso, en qué segmentos fallará más el avalúo automático y qué *no* dice el modelo (por qué un coeficiente o una variable seleccionada no es un efecto causal).

Rúbrica (100 puntos)

- (70 pts) Partes 1 a 4, con el peso indicado en cada título: procedimiento correcto, tablas y figuras pedidas, respuestas breves en lenguaje económico.
- (20 pts) Ranking del curso por el RMSE de prueba del precio, calculado por el profesor con `predicciones.csv`: el primer equipo recibe 20 puntos, el último 10 y los demás en proporción a su posición. Un archivo que no se reproduce corriendo `00_run.R`, con filas faltantes o con NA, ubica al equipo en el último lugar.
- (10 pts) Reproducibilidad y reporte: `00_run.R` corre de principio a fin sin intervención manual (rutas relativas a la carpeta del equipo, semilla fija, `sessionInfo()` al final); extensión razonable, tablas con unidades, figuras legibles.

Anexo A: la tabla de resultados

Misma validación y mismas unidades (millones de pesos) para todos los modelos. Las filas 0 a 2 se llenan en la Parte 1 y las demás en la Parte 2; la fila final, en la Parte 4. La tabla se conserva y se amplía en el Problem Set 2 (misma base, misma prueba oculta).

Modelo	RMSE de validación	MAE de validación	R^2 de validación
M0: media del entrenamiento			
M1: recta con el área			
M2: área, baños, tipo y coordenadas			
Mejor especificación lineal (Parte 2)			
Ridge / Lasso / <i>Elastic Net</i> (mejor)			
k -NN en el mapa			
Modelo final del Problem Set 1: ...			