Problem Set 2: ¿Cuál vivienda tiene piscina?

Big Data y Machine Learning para Economía Aplicada — 60-121 (NRC 10-993)

Universidad Icesi — Departamento de Economía
Prof. Eduard Fernando Martínez González

Información general

- **Publicación:** jueves 30 de octubre de 2026.
- **Entrega:** a más tardar el **martes 17 de noviembre de 2026 a las 11:59 p. m.**, **por correo** a efmartinez@icesi.edu.co (no al campus virtual), adjuntando un solo `.zip` con el `.pdf` del reporte, el código (`00_run.R` y scripts auxiliares) y el `predicciones.csv` que produce `00_run.R`.
- **El asunto del correo es obligatorio y exacto:** `[BDML] Problem Set 2 - Apellido1 y Apellido2`. Un correo sin ese asunto no queda registrado como entrega.
- **Peso:** 15 % de la nota final. Trabajo en parejas. Debrief con el ranking el 24 de noviembre.
- **Datos:** dos bases y un diccionario (`diccionario_ps2.csv`) en la carpeta `problem-sets/pset-2/` del repositorio. La base `vivienda_entrenamiento.rds` (12.248 avisos) trae la variable `piscina`; la base `vivienda_prediccion.rds` (3.029 avisos) trae los mismos predictores **sin** `piscina`: ustedes nunca observan esa etiqueta.
- **Verificación:** en la plataforma del curso pueden subir su `predicciones.csv` cuantas veces quieran: devuelve la matriz de confusión y sus métricas sobre una mitad de la base de predicción, escogida al azar (no dice cuál).
- **IA:** permitida, declarando qué se usó y para qué.

La pregunta y las reglas del juego

Un portal inmobiliario quiere completar las fichas de sus avisos: saber, por ejemplo, qué viviendas tienen piscina aunque el anuncio no traiga ese campo diligenciado. La y se construyó leyendo el título y la descripción de los mismos avisos de Cali del Problem Set 1: `piscina` vale 1 si el texto la anuncia (el 48 % del entrenamiento). Ustedes no reciben el texto: la tarea es predecirla con lo estructurado del aviso — tipo, área, habitaciones, baños, ubicación, año y precio. Es una pregunta de **clasificación**, con el kit de la sesión 5: un árbol, y los ensambles que lo mejoran.

Cuatro reglas para todo el problem set:

1. **La validación respeta los grupos.** La variable `grupo` identifica los avisos del mismo punto del mapa (misma `lat` y `lon`: avisos repetidos o apartamentos del mismo edificio), que se parecen demasiado. Los pliegues se construyen de modo que ningún grupo quede partido (`groupKFold` de `caret`, o a mano sorteando grupos). Ojo: **la base de predicción no comparte ningún punto del mapa con la de entrenamiento** — el truco de los gemelos del Problem Set 1 aquí no funciona.
2. **Toda comparación va en la tabla del Anexo A:** misma validación y mismas métricas para todos los modelos — exactitud, sensibilidad, especificidad, precisión y F1.
3. **El ranking del curso.** `00_run.R` debe terminar escribiendo `predicciones.csv`: una fila por aviso de predicción y dos columnas, `id` y `piscina_predicha` (0 o 1, sin probabilidades y sin `NA`). La mitad de la base que la plataforma *no* conoce define el ranking: optimizar contra la plataforma no reemplaza una validación honesta.

4. **Sólo las dos bases publicadas.** Intentar recuperar etiquetas de la plataforma, o usar cualquier dato externo, descalifica del ranking.

1. Parte 1 — El árbol (25 pts)

Contexto. Antes de los ensambles, el modelo que se deja leer: un árbol parte los avisos en regiones y predice la clase mayoritaria de cada hoja. Y antes del árbol, la referencia.

Pregunta 1.

(a) Describa lo esencial: número de avisos, prevalencia de `piscina` (total y por `tipo`), un mapa sencillo (`plot` de `lon` contra `lat`) coloreado por `piscina`, y qué variables tienen faltantes y qué hará con ellas. Reporte la referencia: la exactitud de asignar a todos la clase mayoritaria (fila 0 del Anexo A).

(b) Construya sus pliegues por grupos (regla 1) y explique en tres líneas qué pasaría si validara repartiendo avisos al azar, sabiendo cómo se construyó la base de predicción.

(c) Estime un árbol con `rpart` y sus opciones por defecto. Dibújelo y léalo: el primer corte, la pregunta de cada rama, y dos hojas descritas (qué avisos caen y con qué proporción de piscina). En tres líneas: ¿cómo clasifica este árbol?

(d) Afine la complejidad (la profundidad con `caret::train(method = 'rpart2')`, o `cp` con la tabla de poda) usando su validación por grupos y compare con el árbol por defecto. Estime además el árbol *sin frenos* (`cp = 0`, `minsplit = 2`, `minbucket = 1`) y reporte su exactitud en el entrenamiento y en la validación: ¿qué le pasa y cómo se llama?

2. Parte 2 — Los ensambles: promediar y corregir (30 pts)

Contexto. El árbol es legible pero varía mucho. Los ensambles atacan esa varianza: *bagging* y bosques aleatorios promedian cientos de árboles; el *boosting* suma árboles pequeños que corrigen en fila. Además del árbol, deben presentar **al menos dos modelos más** de los vistos en clase; estos dos son el mínimo.

Pregunta 2.

(a) Estime un *bagging* (un bosque con `mtry` igual al número de predictores) y un bosque aleatorio, afinando `mtry`. Compare las dos varas para su bosque: el error fuera de la bolsa (OOB) y la validación por grupos. ¿Cuál es más optimista aquí y por qué? (Pista: ¿el OOB respeta los grupos?)

(b) Estime un *boosting* (`xgboost`): el número de rondas con parada temprana sobre **pliegues que respeten los grupos** (el argumento `folds` de `xgb.cv` recibe la lista de pliegues que usted construya) y al menos otra perilla (`eta` o `max_depth`). Reporte la combinación elegida y su curva de validación.

(c) Para su mejor ensamble, reporte la importancia de variables (`varImpPlot` o `xgb.importance`) y léala en dos líneas: ¿qué variables mueven la predicción y tiene eso sentido económico? ¿Dice eso que esas variables *causan* la piscina? Complete la tabla del Anexo A y cierre con el veredicto: ¿cuánto le ganan los ensambles al árbol?

3. Parte 3 — El modelo final y la plataforma (15 pts)

Contexto. Elegir con la validación, reajustar con todo el entrenamiento y predecir una sola vez. Las clases están casi balanceadas: el umbral natural es 0,5, pero la decisión es suya y se justifica.

Pregunta 3.

(a) Elija el modelo con mejor exactitud de validación, reajústelo con todo el entrenamiento y prediga la base de predicción. Si su modelo produce probabilidades, diga con qué umbral las vuelve 0/1 y por qué. Escriba en la primera línea del reporte: "Modelo final: ... Exactitud de validación: ...".

(b) Suba su `predicciones.csv` a la plataforma y reporte lo que devuelve. ¿Coincide con su validación por grupos? Si no, ¿qué lo explica?

(c) Cierre con un párrafo para el portal: qué tan bien se completa el atributo con lo estructurado del aviso, en qué segmentos falla más (tipo, zona, precio), y qué *no* dice: por qué ni la importancia ni los cortes del árbol son efectos causales.

Rúbrica (100 puntos)

- (70 pts) Partes 1 a 3, con el peso de cada título: procedimiento correcto, tablas y figuras pedidas, respuestas breves en lenguaje económico.
- (20 pts) Ranking por la exactitud en la mitad de la base de predicción que la plataforma no conoce: el primer equipo recibe 20 puntos, el último 10 y los demás en proporción. Un archivo que no se reproduce con `00_run.R`, con filas faltantes, valores distintos de 0/1 o `NA`, ubica al equipo en el último lugar.
- (10 pts) Reproducibilidad y reporte: `00_run.R` corre de principio a fin sin intervención manual (rutas relativas, semilla fija, `sessionInfo()` al final), leyendo sólo las dos bases publicadas.

Anexo A: la tabla de resultados

Misma validación por grupos y mismas métricas para todos; agregue una fila por cada modelo adicional que presente.

Modelo	Exactitud	Sensibilidad	Especificidad	Precisión	F1
M0: clase mayoritaria					
Árbol por defecto					
Árbol afinado					
Árbol sin frenos					
Bagging					
Bosque aleatorio					
Boosting					
Modelo final del Problem Set 2: ...					