

FACULTAD DE ECONOMÍA Y NEGOCIOS

Departamento de Economía

Big Data y Machine Learning para Economía Aplicada

Prof. Eduard Fernando Martínez González, Ph.D.

- **Código-Materia:** 60-121 (NRC 10-993)
- **Programa:** Maestría en Economía (ME)
- **Prerrequisito:** Econometría I y II (o equivalente). Se recomienda manejo básico de R; no es requisito.
- **Período académico:** 2026-2
- **Horario y lugar:** martes de 8:00 a 11:00 a. m., salón 406-E (Bloque E)
- **Fechas:** del 15 de septiembre al 11 de noviembre de 2026; nueve sesiones, la última el martes 10 de noviembre
- **Intensidad semanal:** 3 horas
- **Créditos:** 3
- **Contacto:** efmartinez@icesi.edu.co

1 Descripción del curso

En Inferencia Causal el objetivo es identificar correctamente un parámetro: el efecto β de una intervención sobre un resultado. En este curso el objetivo cambia de lugar: nos interesa Y , es decir, construir modelos capaces de **predecir bien la variable de interés** con datos que el modelo no ha visto, saber **evaluar** esa capacidad predictiva con honestidad y **abrir el modelo** para entender de qué depende la predicción. Esa distinción entre explicar y predecir organiza todo el semestre y se marca desde la primera sesión.

El curso introduce a los estudiantes de la Maestría en Economía al marco del aprendizaje estadístico y a las herramientas de *machine learning* (ML) más usadas hoy en economía aplicada y finanzas: regresión como máquina de predecir, clasificación, validación cruzada, regularización (Ridge, Lasso, Elastic Net), árboles, *random forests* y *boosting*, herramientas de interpretación (importancia de variables, dependencia parcial, valores SHAP) y redes neuronales. La progresión sigue la de *An Introduction to Statistical Learning* (James, Witten, Hastie y Tibshirani, 2.^a ed.), el texto guía del curso.

El tratamiento combina **formalidad suficiente** con **mucha intuición**. Para cada método se presenta su función objetivo y sus hiperparámetros, se explica qué problema resuelve y cómo funciona, se implementa sobre datos reales en R, se evalúa su desempeño fuera de

muestra frente a un modelo de referencia y se interpretan sus resultados. Las derivaciones extensas viven en apéndices de cada sesión, disponibles para quien quiera profundizar. Tres conjuntos de datos atraviesan el curso: un panel de mesas electorales colombianas con características censales, precios de vivienda en Bogotá e imágenes satelitales.

Cada sesión se organiza alrededor de un artículo aplicado reciente, el *paper de la sesión*, que los estudiantes leen antes de clase y cuyo ejercicio se reproduce en la parte aplicada con los datos del curso; y el semestre culmina en un proyecto en el que los equipos formulan una pregunta predictiva, comparan varios algoritmos y defienden sus resultados.

2 Resultados de aprendizaje

Al finalizar el curso, el estudiante será capaz de:

- Distinguir un problema de predicción de un problema de inferencia causal, y reconocer cuándo la capacidad predictiva fuera de muestra es la cantidad de interés.
- Construir el flujo de trabajo completo de un ejercicio predictivo: partición de los datos, preprocesamiento dentro del *pipeline*, validación cruzada, ajuste de hiperparámetros, evaluación e interpretación.
- Evaluar modelos de regresión y clasificación con las métricas apropiadas (RMSE, MAE, R^2 fuera de muestra, AUC, calibración, errores de inclusión y exclusión), con su incertidumbre y frente a un modelo de referencia, y diagnosticar dónde se concentran los errores.
- Aplicar y comparar regularización, árboles, *random forests*, *boosting* y redes neuronales sobre datos económicos, sabiendo cuándo conviene cada familia.
- Interpretar modelos flexibles con importancia de variables, dependencia parcial y valores SHAP, distinguiendo lo que describen (de qué depende la predicción) de lo que no establecen (efectos causales).
- Leer críticamente y presentar artículos de economía y finanzas que usan ML, evaluando la pertinencia del método, de la validación y de la interpretación.
- Implementar todo lo anterior en R (*tidymodels*, *glmnet*, *ranger*, *xgboost*, DALEX y *shapviz*, *keras*), con traducción opcional a Python.

3 Contenido

Las nueve sesiones siguen la progresión de ISL: marco del aprendizaje estadístico, regresión lineal como *baseline*, clasificación, remuestreo y validación, selección y regularización, métodos basados en árboles y redes neuronales, con una sesión dedicada a la interpretación de modelos y un cierre sobre estructura sin variable de respuesta y la frontera con la inferencia causal. El Problem Set 1 cubre las sesiones 1–5 y el Problem Set 2 las sesiones 6–9.

3.1 Calendario de sesiones y entregas

Las clases son los martes de 8:00 a 11:00 a. m. Las entregas posteriores a la última sesión caen dentro del período de exámenes finales del calendario académico 2026-2 (17 al 28 de noviembre); las notas definitivas se registran a partir del 1 de diciembre.

S	Fecha	Tema	Hitos
1	mar 15 sep	Predecir, no explicar: el marco del aprendizaje estadístico	
2	mar 22 sep	La regresión lineal como máquina de predecir y cómo evaluar una predicción	
3	mar 29 sep	Clasificación: de la logística a las métricas que deciden	Se publica el Problem Set 1
4	mar 6 oct	Remuestreo, validación y el <i>pipeline</i> honesto	
5	mar 13 oct	Selección de variables y regularización	Entrega 1 del proyecto (propuesta)
6	mar 20 oct	Árboles, bosques y <i>boosting</i>	Entrega del Problem Set 1
7	mar 27 oct	Abrir la caja negra: importancia, dependencia parcial y SHAP	Se publica el Problem Set 2
8	mar 3 nov	Redes neuronales: qué son, cuándo usarlas y una aplicación con imágenes	
9	mar 10 nov	Más allá de la predicción: estructura sin Y , la frontera causal y avances del proyecto	Presentación de avances del proyecto
—	mar 17 nov		Entrega del Problem Set 2
—	mar 24 nov		Entrega 2 del proyecto: informe final y repositorio

3.2 Módulo 1: Fundamentos y evaluación

3.2.1 Sesión 1 — Predecir, no explicar: el marco del aprendizaje estadístico

Temas:

- De β a Y : los mismos datos, dos preguntas; *prediction policy problems*; la predictibilidad fuera de muestra como cantidad de interés.
- Qué es aprender f ; paramétrico vs. no paramétrico; flexibilidad vs. interpretabilidad.
- Error de entrenamiento vs. error de prueba; sobreajuste; la curva U; sesgo-varianza con intuición.
- Supervisado y no supervisado; regresión y clasificación; el flujo de trabajo del curso.

Objetivos de aprendizaje: explicar por qué un coeficiente significativo no es una predicción; definir el riesgo de generalización y las tres piezas del error; separar entrenamiento y prueba antes de tocar cualquier modelo.

Lecturas: ISL, caps. 1–2; Mullainathan & Spiess (2017); Kleinberg, Ludwig, Mullainathan & Obermeyer (2015).

Paper de la sesión: Kim & Zilinsky (2024), *Division Does Not Imply Predictability*.

Aplicación en R: primera partición entrenamiento/prueba con un modelo lineal sobre el panel de mesas electorales: R^2 dentro y fuera de muestra.

3.2.2 Sesión 2 — La regresión lineal como máquina de predecir y cómo evaluar una predicción

Temas:

- OLS como predictor: predictores cualitativos, interacciones, transformaciones.
- Más allá de la linealidad: polinomios, escalones, *splines* y GAM; k -NN de regresión y la maldición de la dimensionalidad.
- Métricas de regresión: MSE, RMSE, MAE, MAPE y R^2 fuera de muestra; modelos de referencia.
- Predicho vs. observado y la compresión hacia la media; residuos; error por deciles de Y y por subgrupos; extrapolación.

Objetivos de aprendizaje: usar la regresión como *baseline* honesto; elegir y leer métricas de regresión; localizar dónde falla un modelo.

Lecturas: ISL, caps. 3 y 7 (secciones 7.1–7.7).

Paper de la sesión: Bogin & Shui (2020), *Appraisal Accuracy and Automated Valuation Models in Rural Areas*. Lectura complementaria: Pace & Hayunga (2020).

Aplicación en R: precios de vivienda en Bogotá: lineal vs. polinomios y *splines* vs. k -NN; tabla de métricas, dispersión predicho vs. observado, error por decil de precio.

3.2.3 Sesión 3 — Clasificación: de la logística a las métricas que deciden

Temas:

- Por qué no OLS; regresión logística (binaria y multinomial); LDA, QDA y Naive Bayes en breve; k -NN.
- Probabilidades vs. clases: el umbral como decisión con costos.
- Matriz de confusión; exactitud, precisión, *recall*, F1 y *balanced accuracy*; por qué la exactitud engaña con prevalencia desigual.
- ROC/AUC vs. precisión–*recall*; calibración; desbalanceo de clases y sus remedios.

Objetivos de aprendizaje: predecir categorías con probabilidades calibradas; elegir la métrica y el umbral según el problema económico.

Lecturas: ISL, cap. 4; Fawcett (2006).

Paper de la sesión: Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018). Lectura complementaria: Fuster, Goldsmith-Pinkham, Ramadorai & Walther (2022).

Aplicación en R: ¿ganó el eventual presidente en la mesa? Logit vs. k -NN con partición estratificada; AUC vs. exactitud bajo desbalance; curva ROC y calibración.

3.2.4 Sesión 4 — Remuestreo, validación y el *pipeline* honesto

Temas:

- Conjunto de validación, LOOCV y k -fold; el sesgo–varianza del CV; CV en clasificación.
- CV para elegir hiperparámetros: grilla, búsqueda aleatoria y bayesiana; CV anidado.

- *Leakage* y preprocesamiento dentro del *pipeline*.
- CV temporal y espacial: cuándo el k -fold aleatorio miente.
- *Bootstrap*: intervalos para las métricas y comparación de modelos.

Objetivos de aprendizaje: estimar el error de generalización sin engañarse; construir el *pipeline* que se reutiliza el resto del curso.

Lecturas: ISL, cap. 5; Roberts et al. (2017); Neunhoeffler & Sternberg (2019).

Paper de la sesión: Deppner & Cajias (2024), *Accounting for Spatial Autocorrelation in Algorithm-Driven Hedonic Models*. Lectura de referencia para el proyecto: Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022).

Aplicación en R: `tidymodels` (`recipes`, `rsample`, `tune`): comparación por CV de los modelos de las sesiones 2 y 3 con intervalos *bootstrap*; CV espacial con las mesas electorales.

3.2.5 Sesión 5 — Selección de variables y regularización

Temas:

- Muchos predictores: sobreajuste y colinealidad; selección por subconjuntos y criterios de información frente al CV.
- Ridge (encoger) y Lasso (ceros exactos); Elastic Net; elección de λ por CV; caminos de coeficientes.
- PCR y PLS como compresión; la intuición de PCA.
- Alta dimensión: qué falla; el proxy correlacionado; “el Lasso selecciona predictores, no causas”; doble selección como anticipo de la sesión 9.

Objetivos de aprendizaje: predecir con muchos predictores sin sobreajustar; entender qué significa (y qué no) que una variable sobreviva a la penalización.

Lecturas: ISL, cap. 6; Belloni, Chernozhukov & Hansen (2014, JEP) como lectura complementaria.

Paper de la sesión: Blumenstock, Cadamuro & On (2015), *Predicting Poverty and Wealth from Mobile Phone Metadata*. Lectura de referencia para el proyecto: Gu, Kelly & Xiu (2020), *Empirical Asset Pricing via Machine Learning*.

Aplicación en R: precios de vivienda con muchas covariables (`glmnet`): OLS vs. Ridge vs. Lasso vs. Elastic Net; caminos, curva de CV, comparación fuera de muestra.

3.3 Módulo 2: Árboles, ensambles e interpretación

3.3.1 Sesión 6 — Árboles, bosques y *boosting*

Temas:

- Árboles de regresión y clasificación: particiones, criterio de corte, poda; por qué un árbol solo es inestable.
- *Bagging*: promediar reduce la varianza; *random forest*: m , error *out-of-bag*, importancia nativa.

- *Boosting*: ajustar residuos; tasa de aprendizaje, profundidad, número de árboles y *early stopping*; XGBoost y LightGBM; BART como mención.
- *Random forest* vs. *boosting*; ajuste de hiperparámetros con CV; cuándo ganan los árboles en datos tabulares.

Objetivos de aprendizaje: entender por qué los ensambles de árboles dominan los datos tabulares, ajustarlos y compararlos honestamente con los modelos anteriores.

Lecturas: ISL, cap. 8; Breiman (2001).

Paper hilo conductor: Gelvez, Cardiles, Martínez-González & Muñoz (2026), *How Predictable Is an Election?*

Lectura complementaria: Bertrand & Kamenica (2023). Lectura de referencia para el proyecto: Medeiros, Vasconcelos, Veiga & Zilberman (2021).

Aplicación en R: *random forest* y XGBoost para el *vote share* y el ganador local con búsqueda bayesiana de hiperparámetros; tabla comparativa con logit y Lasso; OOB vs. CV.

3.3.2 Sesión 7 — Abrir la caja negra: importancia, dependencia parcial y SHAP

Temas:

- Para qué interpretar: auditar, comunicar, generar hipótesis; interpretación global y local.
- Importancia por impureza vs. por permutación; sesgos con predictores correlacionados; estabilidad por remuestreo.
- Dependencia parcial, ICE y ALE: qué muestran y cuándo engañan.
- Valores de Shapley y SHAP: importancia con signo, gráficos de dependencia, rangos vs. magnitudes entre modelos.
- Ablación por bloques de variables; descomposición del R^2 ; error por subgrupos y equidad.
- Lo que la interpretación no es: causalidad, inferencia ecológica, pronóstico.

Objetivos de aprendizaje: interpretar y auditar modelos flexibles con herramientas estándar, sabiendo qué miden y cuándo engañan.

Lecturas: Molnar (2025), capítulos de importancia por permutación, PDP, ALE y SHAP; Lundberg & Lee (2017).

Paper de la sesión: Bluwstein, Buckmann, Joseph, Kapadia & Şimşek (2023). Lectura complementaria: Ludwig & Mullainathan (2024).

Aplicación en R: sobre los modelos de la sesión 6: importancia por permutación vs. impureza (DALEX), PDP/ICE, SHAP (*shapviz*), jerarquía de bloques y error por decil; reproducción de las figuras 3, 5 y 6 de Gelvez et al.

3.4 Módulo 3: Redes neuronales, estructura sin Y y cierre

3.4.1 Sesión 8 — Redes neuronales: qué son, cuándo usarlas y una aplicación con imágenes

Temas:

- Neurona, capas y composición de funciones; funciones de activación; la pérdida.
- Ajuste: SGD y *mini-batches*; retropropagación como regla de la cadena; *early stopping*, *dropout* y *weight decay*.
- Cuándo *deep learning* y cuándo no: datos tabulares vs. imágenes y texto.
- Redes convolucionales como aplicación: transferencia de aprendizaje y pobreza desde imágenes satelitales.
- Texto y modelos de lenguaje como lecturas complementarias.

Objetivos de aprendizaje: entender la red como composición de regresiones, ajustarla y regularizarla, y decidir con evidencia cuándo conviene frente a los árboles.

Lecturas: ISL, cap. 10 (secciones 10.1–10.3 y 10.6–10.7); Jean et al. (2016).

Paper de la sesión: Jean, Burke, Xie, Davis, Lobell & Ermon (2016). Lectura complementaria: Glaeser, Kincaid & Naik (2018).

Aplicación en R: red *feedforward* (*keras*) vs. XGBoost sobre los mismos datos tabulares; demostración con una red convolucional preentrenada sobre imágenes satelitales.

3.4.2 Sesión 9 — Más allá de la predicción: estructura sin Y , la frontera causal y avances del proyecto

Temas:

- PCA como índice (Filmer–Pritchett) y k -means como segmentación: qué son, cómo se validan sin Y , advertencias.
- ML al servicio de β : doble selección, *double machine learning* como residuos sobre residuos con *cross-fitting*, *causal forests* para heterogeneidad; identificar antes de estimar.
- El curso en una diapositiva.
- Presentación de avances del proyecto final: cada equipo expone su pregunta, sus datos, el modelo de referencia, al menos un modelo flexible con su validación y una primera interpretación, y recibe retroalimentación para el informe final.

Objetivos de aprendizaje: saber qué se puede hacer sin variable de respuesta y cuándo la predicción ayuda a estimar un efecto causal.

Lecturas: ISL, cap. 12 (secciones 12.2 y 12.4); Athey & Imbens (2019); Filmer & Pritchett (2001).

Aplicación en R: índice socioeconómico con PCA y segmentación con k -means sobre el censo por mesa; un *causal forest* con *grf* como demostración de lectura.

4 Metodología

Las clases estarán organizadas en tres partes principales:

1. **Exposición teórica:** para cada método el profesor sigue la misma secuencia: el problema económico que resuelve, la intuición con una figura, la formulación esencial (función objetivo e hiperparámetros), cómo funciona y cómo se ajusta, y cuándo usarlo. Intuición antes que formalismo; las derivaciones extensas van al apéndice de cada sesión.
2. **Aplicaciones guiadas:** implementación en R con código preparado sobre los tres conjuntos de datos del curso (mesas electorales, vivienda en Bogotá, imágenes satelitales). Cada aplicación reporta desempeño fuera de muestra frente a un modelo de referencia, gráficos de predicho vs. observado y, desde la sesión 6, herramientas de interpretación. Se ofrece traducción opcional a Python (`scikit-learn`).
3. **El paper de la sesión:** cada sesión tiene un artículo aplicado de referencia que los estudiantes leen antes de clase con una guía de tres preguntas:
 - Qué se predice y contra qué modelo de referencia.
 - Cómo se evalúa el desempeño fuera de muestra y dónde falla el modelo.
 - Qué interpreta el artículo y qué no dice.

El artículo abre la sesión, la teoría explica el método que usa y la aplicación guiada reproduce, con los datos del curso, el tipo de ejercicio que hace. A partir de la segunda sesión, un estudiante abre la clase con una presentación de 10 minutos del paper de la sesión: la pregunta, los datos, el modelo de referencia, la evaluación fuera de muestra y el resultado principal. No se le pide explicar el método, que es el tema de ese día. Los artículos con comparaciones amplias de algoritmos (Gu, Kelly & Xiu, 2020; Medeiros et al., 2021; Goulet Coulombe et al., 2022) son lecturas de referencia para el proyecto final, no papers de sesión.

5 Otras obligaciones de los estudiantes

Cada estudiante deberá realizar de manera autónoma una nivelación en R antes de las sesiones aplicadas. Para ello se proporcionará el siguiente material de referencia:

- Introducción a R.
- Manipulación de datos con `dplyr`.
- Visualización de datos con `ggplot2`.
- Buenas prácticas de modelamiento con `tidymodels`.

La revisión de este material es obligatoria y se desarrolla por fuera del horario de clase. Para quienes opten por la vía Python se ofrece material equivalente de referencia.

6 Evaluación

La calificación final del curso se basa en cuatro componentes:

1. **Paper de la sesión: lectura y apertura (10 %)**

Antes de cada sesión, de la segunda a la octava, cada estudiante entrega la guía de lectura del paper de la sesión (media página con las tres preguntas; se califican las mejores cinco de siete, 5 %). Además, cada estudiante abre una de las sesiones con la presentación de 10 minutos del paper correspondiente (5 %); las sesiones se asignan en la primera clase.

2. **Problem Set 1: Fundamentos, evaluación y regularización (15 %)**

Taller extra clase a desarrollar en parejas sobre el material de las sesiones 1 a 5. Combina preguntas conceptuales cortas (por qué el error de entrenamiento es optimista, qué cambia al pasar de OLS a Lasso, qué métrica usar y por qué) con un *pipeline* predictivo completo en R: partición, validación cruzada, comparación de modelos frente a un modelo de referencia y diagnóstico de errores. Se entrega como un único archivo .pdf acompañado de un repositorio reproducible (.R). Se publica el 29 de septiembre y se entrega el 20 de octubre antes de clase.

3. **Problem Set 2: Árboles, interpretación y redes (15 %)**

Taller extra clase en parejas sobre el material de las sesiones 6 a 9, con la misma estructura: preguntas conceptuales y un *pipeline* con *random forest* o *boosting* y redes neuronales, evaluación fuera de muestra e interpretación con importancia de variables, dependencia parcial y SHAP. Se publica el 27 de octubre y se entrega el 17 de noviembre.

4. **Proyecto final (60 %)**

En grupos de 2–3 estudiantes. El equipo define una pregunta económica en la que la predicción es la cantidad de interés, identifica un conjunto de datos, aplica varios algoritmos y evalúa e interpreta su desempeño fuera de muestra. La distribución interna del componente es:

- **Entrega 1 — Propuesta (10 % del proyecto), 13 de octubre:** pregunta, datos, métrica objetivo, modelo de referencia y estrategia de validación.
- **Presentación de avances (30 % del proyecto), 10 de noviembre:** en la última sesión, cada equipo presenta el diseño, el *pipeline*, el modelo de referencia y al menos un modelo flexible con su validación, y defiende la pertinencia de los métodos ante el grupo. La retroalimentación recibida se incorpora en el informe final.
- **Entrega 2 — Informe final (60 % del proyecto), 24 de noviembre:** documento de máximo 10 páginas con comparación de modelos, diagnósticos, interpretación, limitaciones e implicaciones de política, acompañado del repositorio reproducible.

Los lineamientos detallados del proyecto se publican en la carpeta `final-project/` del repositorio del curso.

Resumen de la evaluación:

- Paper de la sesión (guías de lectura y apertura): 10 %
- Problem Set 1 (sesiones 1–5): 15 %
- Problem Set 2 (sesiones 6–9): 15 %
- Proyecto final (propuesta, avances e informe): 60 %

Nota sobre el uso de IA: Se permite el uso de herramientas de IA en cualquier

componente del curso, siempre que se declare explícitamente qué se usó y para qué.

7 Bibliografía

Textos base

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.^a ed.). Springer. [ISL] [\[disponible online\]](#)
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.^a ed.). [\[disponible online\]](#)
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2.^a ed.). Springer. [ESL]
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Marco general: ML en economía

- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Varian, H. R. (2014). Big Data: New Tricks for Econometrics. *Journal of Economic Perspectives*, 28(2), 3–28.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review: Papers & Proceedings*, 105(5), 491–495.
- Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, 25(3), 289–310.
- Kim, S.-y. S., & Zilinsky, J. (2024). Division Does Not Imply Predictability: Demographics Continue to Reveal Little About Voting and Partisanship. *Political Behavior*, 46, 67–87.
- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Documento de trabajo.

Regresión, clasificación y evaluación (sesiones 2–4)

- Bogin, A. N., & Shui, J. (2020). Appraisal Accuracy and Automated Valuation Models in Rural Areas. *Journal of Real Estate Finance and Economics*, 60, 40–52.
- Pace, R. K., & Hayunga, D. K. (2020). Examining the Information Content of Residuals from Hedonic and Spatial Models Using Trees and Forests. *Journal of Real Estate Finance and Economics*, 60, 170–180.
- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J., & Mullainathan, S. (2018). Human Decisions and Machine Predictions. *Quarterly Journal of Economics*, 133(1), 237–293.

- Fuster, A., Goldsmith-Pinkham, P., Ramadorai, T., & Walther, A. (2022). Predictably Unequal? The Effects of Machine Learning on Credit Markets. *Journal of Finance*, 77(1), 5–47.
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Roberts, D. R., et al. (2017). Cross-validation Strategies for Data with Temporal, Spatial, Hierarchical, or Phylogenetic Structure. *Ecography*, 40(8), 913–929.
- Neunhoeffer, M., & Sternberg, S. (2019). How Cross-Validation Can Go Wrong and What to Do About It. *Political Analysis*, 27(1), 101–106.
- Deppner, J., & Cajias, M. (2024). Accounting for Spatial Autocorrelation in Algorithm-Driven Hedonic Models: A Spatial Cross-Validation Approach. *Journal of Real Estate Finance and Economics*, 68, 235–273.
- Goulet Coulombe, P., Leroux, M., Stevanovic, D., & Surprenant, S. (2022). How Is Machine Learning Useful for Macroeconomic Forecasting? *Journal of Applied Econometrics*, 37(5), 920–964.

Regularización (sesión 5)

- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073–1076.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *Journal of Economic Perspectives*, 28(2), 29–50.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.

Árboles, ensambles e interpretación (sesiones 6–7)

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Medeiros, M. C., Vasconcelos, G. F. R., Veiga, Á., & Zilberman, E. (2021). Forecasting Inflation in a Data-Rich Environment: The Benefits of Machine Learning Methods. *Journal of Business & Economic Statistics*, 39(1), 98–119.
- Bertrand, M., & Kamenica, E. (2023). Coming Apart? Cultural Distances in the United States over Time. *American Economic Journal: Applied Economics*, 15(4), 1–45.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in Random Forest Variable Importance Measures. *BMC Bioinformatics*, 8, 25.
- Apley, D. W., & Zhu, J. (2020). Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models. *Journal of the Royal Statistical Society: Series B*,

82(4), 1059–1086.

- Bluwstein, K., Buckmann, M., Joseph, A., Kapadia, S., & Şimşek, Ö. (2023). Credit Growth, the Yield Curve and Financial Crisis Prediction: Evidence from a Machine Learning Approach. *Journal of International Economics*, 145, 103773.
- Ludwig, J., & Mullainathan, S. (2024). Machine Learning as a Tool for Hypothesis Generation. *Quarterly Journal of Economics*, 139(2), 751–827.
- Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence*, 1, 206–215.

Redes neuronales, estructura sin Y y frontera causal (sesiones 8–9)

- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.
- Glaeser, E. L., Kincaid, M. S., & Naik, N. (2018). Computer Vision and Real Estate: Do Looks Matter and Do Incentives Determine Looks. NBER Working Paper 25174.
- Dell, M. (2025). Deep Learning for Economists. *Journal of Economic Literature*, 63(1), 5–58.
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data — or Tears. *Demography*, 38(1), 115–132.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.
- Davis, J., & Heller, S. B. (2020). Rethinking the Benefits of Youth Employment Programs: The Heterogeneous Effects of Summer Jobs. *Review of Economics and Statistics*, 102(4), 664–677.