

FACULTAD DE ECONOMÍA Y NEGOCIOS

Departamento de Economía

Big Data y Machine Learning para Economía Aplicada

Prof. Eduard Fernando Martínez González, Ph.D.

- **Código-Materia:** 60-121 (NRC 10-993)
- **Programa:** Maestría en Economía (ME)
- **Prerrequisito:** Econometría I y II (o equivalente). Se recomienda manejo básico de R; no es requisito.
- **Período académico:** 2026-2
- **Horario y lugar:** martes de 8:00 a 11:00 a. m., salón 406-E (Bloque E)
- **Fechas:** del 15 de septiembre al 24 de noviembre de 2026; nueve sesiones. No hay clase el 10 ni el 17 de noviembre.
- **Intensidad semanal:** 3 horas
- **Créditos:** 3
- **Materiales:** [página del curso](#) y [repositorio en GitHub](#) (presentaciones, prácticas de R con sus datos y talleres)
- **Contacto:** efmartinez@icesi.edu.co

1 Descripción del curso

En Inferencia Causal el objetivo es identificar correctamente un parámetro: el efecto β de una intervención sobre un resultado. En este curso el objetivo cambia de lugar: nos interesa Y , es decir, construir modelos capaces de **predecir bien la variable de interés** con datos que el modelo no ha visto, saber **evaluar** esa capacidad predictiva con honestidad y **abrir el modelo** para entender de qué depende la predicción. Esa distinción entre explicar y predecir organiza todo el semestre y se marca desde la primera sesión.

El curso introduce a los estudiantes de la Maestría en Economía al marco del aprendizaje estadístico y a las herramientas de *machine learning* (ML) más usadas hoy en economía aplicada: la regresión como máquina de predecir, la validación cruzada y la regularización (Ridge, Lasso, Elastic Net), la clasificación, los árboles, los *random forests* y el *boosting*, las herramientas para abrir la caja negra (importancia de variables, dependencia parcial, valores de Shapley) y las redes neuronales, con un puente final hacia el ML al servicio de la inferencia causal. El texto guía es *An Introduction to Statistical Learning* (James, Witten, Hastie y Tibshirani, 2.^a ed.; ISL): cada sesión indica los capítulos y secciones que le corresponden.

El tratamiento combina **formalidad suficiente** con **muchoa intuición**: para cada método se presenta el problema económico que resuelve, la ecuación que explica el mecanismo, una figura construida con los datos del curso y la implicación para la predicción; las derivaciones extensas viven en el apéndice de cada presentación. **Un solo caso empírico atraviesa las sesiones 2 a 8**: los puestos de votación de Colombia en la segunda vuelta presidencial de 2022, con sus características del censo de 2018 (los datos del *working paper* de Gelvez, Cardiles, Martínez-González y Muñoz, 2026). Cada semana la teoría usa como ejemplos los números de ese caso, y la práctica de R que se publica con la sesión los reproduce todos. Los *problem sets* usan una segunda base, avisos de venta de vivienda en Cali, y el proyecto final se hace con una base elegida por el estudiante.

2 Resultados de aprendizaje

Al finalizar el curso, el estudiante será capaz de:

- Distinguir un problema de predicción de un problema de inferencia causal, y reconocer cuándo la capacidad predictiva fuera de muestra es la cantidad de interés.
- Construir el flujo de trabajo completo de un ejercicio predictivo: partición de los datos, preprocesamiento dentro del *pipeline*, validación cruzada, ajuste de hiperparámetros, evaluación e interpretación.
- Evaluar modelos de regresión y clasificación con las métricas apropiadas (RMSE, MAE, R^2 fuera de muestra; matriz de confusión, AUC, calibración), con su incertidumbre y frente a un modelo de referencia, y diagnosticar dónde se concentran los errores.
- Aplicar y comparar regularización, árboles, *random forests*, *boosting* y redes neuronales sobre datos económicos, sabiendo cuándo conviene cada familia.
- Interpretar modelos flexibles con importancia de variables, dependencia parcial y valores SHAP, distinguiendo lo que describen (de qué depende la predicción) de lo que no establecen (efectos causales).
- Leer críticamente y presentar artículos de economía que usan ML, evaluando la pertinencia del método, de la validación y de la interpretación.
- Implementar todo lo anterior en R con código transparente y sin cajas negras de programación (los paquetes del curso: `glmnet`, `rpart`, `randomForest`, `xgboost` y `nnet`): las prácticas escriben cada paso.

3 Contenido

Las nueve sesiones arrancan en el marco del aprendizaje estadístico, construyen la regresión como *baseline* y el par validación cruzada-regularización como el *pipeline* honesto, pasan a la clasificación, los ensambles de árboles, la interpretación y la representación (PCA, *clustering* y redes), y cierran con la sesión de *papers* y síntesis y con la presentación del proyecto final. El Problem Set 1 cubre las sesiones 2 a 4 y el Problem Set 2 las sesiones 5 a 7.

3.1 Calendario de sesiones y entregas

Las clases son los martes de 8:00 a 11:00 a.m. La sesión 9 cae dentro del período de exámenes finales del calendario académico 2026-2 (17 al 28 de noviembre); las notas definitivas se registran a partir del 1 de diciembre.

S	Fecha	Tema (secciones de ISL)	Hitos
1	mar 15 sep	Predecir, no explicar: el marco del aprendizaje estadístico (caps. 1–2)	
2	mar 22 sep	La regresión lineal como máquina de predecir (2.2, 3 y 3.5; cap. 7 en una lámina)	Se eligen las áreas de los <i>papers</i> de la sesión 8
3	mar 29 sep	Validación cruzada y regularización: el juez y la perilla (5.1, 6.2 y 6.4)	
4	mar 6 oct	Clasificación: de la probabilidad a la decisión (4.1–4.3 y 4.7.6)	Se publica el Problem Set 1
5	mar 13 oct	Árboles, bosques y <i>boosting</i> : partir, promediar y corregir (cap. 8)	
6	mar 20 oct	Abrir la caja negra: qué aprendió la máquina (Molnar, caps. seleccionados)	Entrega del PS1 (8:00 a.m.); se publica el PS2
7	mar 27 oct	Representar: PCA, k -medias y redes neuronales (12.2 y 12.4.1; 10.1–10.3 y 10.6–10.7)	<i>Debrief</i> del <i>ranking</i> del PS1
8	mar 3 nov	Los <i>papers</i> y la síntesis del caso; puente causal con DML	Presentaciones de <i>papers</i> ; Entrega 1 del proyecto (idea + <i>pitch</i>)
—	mar 10 nov	Sin clase (asesoría opcional del proyecto)	Entrega del PS2 (11:59 p.m.)
—	mar 17 nov	Sin clase	
9	mar 24 nov	Presentación del proyecto final	Entrega 2 del proyecto (documento); <i>debrief</i> del PS2

3.2 Módulo 1: El marco, el *baseline* y el *pipeline* honesto

3.2.1 Sesión 1 — Predecir, no explicar: el marco del aprendizaje estadístico

Temas: de β a Y (los mismos datos, dos preguntas; *prediction policy problems*); qué es aprender f ; flexibilidad vs. interpretabilidad; error de entrenamiento vs. error de prueba, sobreajuste y la curva U; sesgo-varianza con intuición; las tareas (regresión y clasificación, supervisado y no supervisado) y el flujo de trabajo del curso.

Lecturas: ISL, caps. 1–2; Mullainathan & Spiess (2017); Kleinberg, Ludwig, Mullainathan & Obermeyer (2015).

Aplicación en R: un mismo conjunto de datos, tres modelos: qué pasa con cada uno cuando llega un dato nuevo.

3.2.2 Sesión 2 — La regresión lineal como máquina de predecir

Temas: describir el *target* antes de modelar; la regresión simple (el RSS, la solución como proyección, las métricas en un puesto concreto); más flexible que la recta con una variable (polinomios, escalones y *splines*, k -NN y la maldición de la dimensionalidad); la regresión múltiple (mirar antes de ajustar, el plano, RSE y R^2 releídos, la gemela y la colinealidad); después de predecir (predicho vs. observado, residuos como detector, la referencia y la tabla canónica); extrapolación y la prueba de fuego: la recta no viaja.

Lecturas: ISL, secciones 2.2 y 3.5 y cap. 3 (cap. 7 en una lámina).

Aplicación en R: Cali y su área metropolitana: la media como referencia, la recta, k -NN en el mapa y las 511 combinaciones de nueve covariables; la selección con la prueba queda en evidencia (el gancho de la sesión 3).

3.2.3 Sesión 3 — Validación cruzada y regularización: el juez y la perilla

Temas: *el juez*: una partición de validación es una lotería; la validación cruzada con J pliegues y el error estándar del promedio; el protocolo del curso (el mínimo y la regla de un error estándar); el concurso de los 511 con juez honesto. *La perilla*: cobrar por la complejidad; Ridge divide, el Lasso resta y apaga; Elastic Net; los caminos de coeficientes y la elección de λ por validación cruzada. *En el país*: las 1.291 columnas de censo $\times$ departamento, OLS se desploma, el juez elige al Lasso; dos jueces, dos preguntas (pliegues al azar o municipios enteros).

Lecturas: ISL, secciones 5.1, 6.2 y 6.4; Zou & Hastie (2005) para Elastic Net.

Aplicación en R: las tres partes de la teoría sobre los 12.000 puestos del país, y un segundo script corto que hace *zoom* al juez (el error de cada pliegue y su EE) y a los caminos de Ridge y Lasso.

3.2.4 Sesión 4 — Clasificación: de la probabilidad a la decisión

Temas: la y binaria (gana o no gana el puesto) y su distribución; las referencias sin modelo; del modelo de probabilidad lineal (LPM) a la logística (verosimilitud, log-loss, cómo leer los coeficientes y qué no leer); la matriz de confusión y sus métricas (exactitud, precisión, sensibilidad o *recall* y especificidad), por qué la exactitud engaña con clases desbalanceadas y qué mirar cuando los positivos son raros (precisión-*recall*); el umbral como decisión económica ($\tau^* = c_{FP}/(c_{FP} + c_{FN})$) y la curva de costo; ROC y AUC (ordenar sin fijar umbral), calibración y Brier; los competidores con la perilla de la sesión 3 (LPM con Lasso, la logística con las variables seleccionadas, el Lasso logístico) y los vecinos del mapa.

Lecturas: ISL, secciones 4.1–4.3 (clasificación y regresión logística) y 4.7.6 (el laboratorio de k -NN como clasificador); de la sección 4.4.2, la matriz de confusión y la curva ROC. LDA, QDA y Naive Bayes (secciones 4.4–4.5) quedan en el apéndice de la sesión. Fawcett (2006).

Aplicación en R: ¿gana Petro el puesto? Referencias, LPM vs. logística, matriz de confusión y métricas con el desbalance de 2010, umbral con costos, ROC/AUC, calibración y la tabla final de clasificadores.

3.3 Módulo 2: Árboles, ensambles e interpretación

3.3.1 Sesión 5 — Árboles, bosques y *boosting*: partir, promediar y corregir

Temas: el árbol (el primer corte a mano, la partición binaria recursiva, interacciones sin escribirlas, poda por costo-complejidad, la varianza del árbol); el bosque (*bagging*, la correlación entre árboles, el error *out-of-bag*, la perilla m , por qué no extrapola); el *boosting* (ajustar residuos; las perillas B , η y d con el juez de la sesión 3); la carrera del caso: cuánto valen las interacciones, el mapa como predictor y el promedio de modelos.

Lecturas: ISL, cap. 8 (8.1, 8.2.1–8.2.3 y 8.2.5); Breiman (2001).

Aplicación en R: del corte a mano en diez puestos de Cali a la carrera nacional (`rpart`, `randomForest`, `xgboost`) en las dos preguntas del caso.

3.3.2 Sesión 6 — Abrir la caja negra: qué aprendió la máquina

Temas: la importancia (ganancia, permutación, ablación por bloques y sus trampas); la dependencia (PDP, ICE y ALE; cuando el PDP pregunta por datos que no existen); valores de Shapley y SHAP (el reparto justo, TreeSHAP, cascadas de puestos concretos); el efecto Rashomon cuando entra el mapa; a quién le falla el modelo (subgrupos, extremos y equidad). Hoy no entra ningún modelo nuevo: se abre el *boosting* de la sesión 5.

Lecturas: Molnar (2025), capítulos de importancia por permutación, dependencia parcial y SHAP; Lundberg & Lee (2017).

Aplicación en R: las tres importancias lado a lado, PDP/ICE/ALE, Shapley a mano en un puesto de Quibdó, SHAP con `predcontrib` y el error por subgrupos.

3.3.3 Sesión 7 — Representar: PCA, k -medias y redes neuronales

Temas: comprimir con sentido: PCA (la dirección de máxima varianza, cuántas componentes, las cargas como índice, PCR con el juez); k -medias (el codo y la silueta, las “cuatro Colombias”, ¿los grupos predicen?); la red neuronal (de la componente principal a la unidad oculta, por qué hace falta la no linealidad, capacidad y *weight decay* con el juez, descenso de gradiente y parada temprana, el papel de la semilla); convolución y *transfer learning* con imágenes. Abre con el *debrief* del PS1.

Lecturas: ISL, secciones 12.2 y 12.4.1 (PCA y k -medias) y 10.1–10.3 y 10.6–10.7 (redes); Jean et al. (2016).

Aplicación en R: el PCA de las 37 variables del censo, las cuatro Colombias, la grilla de redes con el juez y la carrera contra el *boosting*; el voto como imagen y un filtro de bordes.

3.4 Módulo 3: Síntesis, papers y proyecto

3.4.1 Sesión 8 — Los *papers* y la síntesis del caso

Temas: seis presentaciones de *papers* por áreas de la economía (15 minutos cada una); la síntesis del caso (la cascada del curso: cuánto aportaron la información, la flexibilidad y la combinación de modelos; la tabla ingredientes $\times$ familias; ¿la estructura viaja a

municipios nuevos, a otros grupos, a otro año?); los *pitches* de la Entrega 1 del proyecto; y el puente causal: ML al servicio de β con *double machine learning* sobre los mismos datos del curso.

Lecturas: Athey & Imbens (2019), secciones 1–3 (preparan el puente causal), y el *paper* elegido de su área; Chernozhukov et al. (2018) como referencia del DML.

Hitos: presentaciones de *papers* (10 % de la nota) y Entrega 1 del proyecto (idea en una página + *pitch*).

3.4.2 Sesión 9 — Presentación del proyecto final

Temas: cada estudiante o pareja presenta su propuesta de investigación predictiva (20 minutos más preguntas); *debrief* del *ranking* del PS2; lo que se llevan del curso, lo que no vimos y dónde seguir.

Hitos: Entrega 2 del proyecto (documento) y presentación.

4 Metodología

Las sesiones combinan tres piezas:

1. **Exposición teórica:** cada concepto entra por una necesidad del caso y sigue la misma secuencia: pregunta $\rightarrow$ intuición $\rightarrow$ formalización $\rightarrow$ figura $\rightarrow$ implicación para la predicción. Los ejemplos numéricos de la teoría son los del caso de la semana: **en la teoría no seguimos un paper; seguimos el ejemplo que después se replica en código**. Las derivaciones extensas viven en el apéndice “Para profundizar” de cada presentación.
2. **Práctica de R:** cada sesión publica en el repositorio un script plano y comentado (con sus datos en `input/` y un `.zip` listo para descargar) que reproduce **todas** las cifras y figuras de la presentación. El código evita atajos opacos: las grillas se llenan con un `for`, el RMSE se escribe en línea y las predicciones se comparan siempre contra el *target* observado.
3. **El caso y los papers:** el hilo empírico de las sesiones 2 a 8 son los puestos de votación de 2022 con el censo de 2018: la pregunta de regresión (el porcentaje de voto) y la de clasificación (¿gana el puesto?) se heredan y mejoran semana a semana, y los mejores modelos del curso tienen memoria. La literatura se organiza **por áreas de la economía** (economía política; crimen y justicia; salud; desarrollo y pobreza; trabajo; vivienda; macroeconomía y pronóstico; finanzas y crédito; organización industrial): en la sesión 2 cada estudiante elige un área, y en la sesión 8 presenta uno de sus dos *papers* candidatos (carpeta `literature/` del repositorio). Los artículos con carreras de caballos de algoritmos (Gu, Kelly & Xiu, 2020; Medeiros et al., 2021; Goulet Coulombe et al., 2022) son lecturas de referencia para el proyecto.

Cuatro reglas de oro se repiten durante el semestre: (1) el error de entrenamiento es optimista; (2) la prueba se abre una sola vez; (3) la validación cruzada valida *pipelines* completos, no modelos sueltos; y (4) la referencia es lo que la decisión haría sin el modelo.

5 Otras obligaciones de los estudiantes

Cada estudiante debe realizar de manera autónoma una nivelación en R (introducción al lenguaje, manipulación de datos con `dplyr` y gráficos básicos) antes de las sesiones aplicadas; se proporciona material de referencia. Las prácticas publicadas de cada semana son, además, el material de estudio aplicado: se espera que el estudiante las corra y las entienda línea a línea antes de la sesión siguiente.

6 Evaluación

La calificación final del curso se basa en cuatro componentes:

1. Presentación de *paper* en la sesión 8 (10 %)

Cada estudiante elige un área de la economía en la sesión 2 y presenta en la sesión 8, en 15 minutos, uno de los dos *papers* candidatos de su área. El guion: la pregunta y la decisión; los datos y la unidad de análisis; el modelo de referencia; la evaluación fuera de muestra y dónde falla; el resultado principal; y qué método del curso es. No hay guías de lectura semanales: los *papers* del semestre se conversan en clase como ejemplos.

2. Problem Set 1: referencia, regresión, validación y clasificación (15 %)

En parejas, sobre una única base de avisos de venta de vivienda en Cali con diccionario y partición fija; el precio y la condición de vivienda VIS de los avisos de prueba están ocultos. Partes y puntos: (1) referencia y regresión (sesión 2, 15 pts); (2) validación y regularización (sesión 3, 25 pts); (3) clasificación (sesión 4, 15 pts); (4) modelo final, con la prueba abierta una sola vez (15 pts); *ranking* del curso por el RMSE de prueba del modelo final (20 pts: el primero 20, el último 10); y reproducibilidad — `00_run.R` corre de principio a fin (10 pts). Se publica el martes 6 de octubre (sesión 4) y se entrega el martes 20 de octubre a las 8:00 a.m.; *debrief* del *ranking* en la sesión 7.

3. Problem Set 2: árboles, caja abierta, redes y el modelo final del curso (15 %)

Misma base y mismas reglas. Partes y puntos: (1) árboles, bosques y *boosting* (sesión 5, 20 pts); (2) abrir la caja (sesión 6, 25 pts); (3) la red contra el bosque (sesión 7, 10 pts); (4) modelo final del curso y lectura de una página (15 pts); *ranking* (20 pts) y reproducibilidad (10 pts). Se publica el martes 20 de octubre (sesión 6) y se entrega el martes 10 de noviembre a las 11:59 p.m.; *debrief* del *ranking* el 24 de noviembre.

4. Proyecto final: una propuesta de investigación predictiva (60 %)

El producto del curso no es un informe con resultados: es una **propuesta de investigación predictiva** sobre una base elegida por el estudiante, con la pregunta y la decisión que la motiva, los datos, la métrica y el modelo de referencia, la estrategia de validación, los métodos que se usarían y por qué, los riesgos y el plan de trabajo. Sobre 100 puntos del componente:

- **Entrega 1 — La idea y el *pitch* (10 pts), 3 de noviembre:** la idea en una página y un *pitch* corto en la sesión 8.
- **Entrega 2 — El documento (50 pts), 24 de noviembre:** máximo 8 páginas.
- **Presentación (40 pts), 24 de noviembre:** 20 minutos más preguntas, en la sesión 9.

Si el proyecto se hace individual o en parejas se confirma en clase. Los lineamientos detallados se publican en la carpeta `final-project/` del repositorio.

Resumen de la evaluación:

- Presentación de *paper* (sesión 8): 10 %
- Problem Set 1 (sesiones 2–4): 15 %
- Problem Set 2 (sesiones 5–7): 15 %
- Proyecto final (idea y *pitch*, documento y presentación): 60 %

Nota sobre el uso de IA: Se permite el uso de herramientas de IA en cualquier componente del curso, siempre que se declare explícitamente qué se usó y para qué.

7 Bibliografía

Textos base

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.^a ed.). Springer. [ISL, el texto guía] [\[disponible online\]](#)
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2.^a ed.). Springer. [ESL]
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.^a ed.). [\[disponible online\]](#)

Marco: ML en economía

- Mullainathan, S., & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Kleinberg, J., Ludwig, J., Mullainathan, S., & Obermeyer, Z. (2015). Prediction Policy Problems. *American Economic Review: Papers & Proceedings*, 105(5), 491–495.
- Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.
- Varian, H. R. (2014). Big Data: New Tricks for Econometrics. *Journal of Economic Perspectives*, 28(2), 3–28.

El caso del curso

- Gelvez, J. D., Cardiles, A., Martínez-González, E. F., & Muñoz, M. (2026). How Predictable Is an Election? A Machine-Learning Approach to Electoral Behavior in Colombia. Documento de trabajo. [De aquí salen los datos de los puestos de votación.]

Literatura por áreas de la economía

La carpeta `literature/` del repositorio organiza los artículos aplicados por área, con dos candidatos por área para las presentaciones de la sesión 8. Una selección:

- **Economía política:** Kim & Zilinsky (2024), Division Does Not Imply Predictability, *Political Behavior*, 46, 67–87 · Gentzkow, Shapiro & Taddy (2019), Measuring Group Differences in High-Dimensional Choices, *Econometrica*, 87(4).
- **Crimen y justicia:** Kleinberg, Lakkaraju, Leskovec, Ludwig & Mullainathan (2018), Human Decisions and Machine Predictions, *Quarterly Journal of Economics*, 133(1) · Angelova, Dobbie & Yang (2023), Algorithmic Recommendations and Human Discretion, documento de trabajo · Ludwig & Mullainathan (2024), Machine Learning as a Tool for Hypothesis Generation, *Quarterly Journal of Economics*, 139(2).
- **Salud:** Mullainathan & Obermeyer (2022), Diagnosing Physician Error, *Quarterly Journal of Economics*, 137(2) · Einav, Finkelstein, Mullainathan & Obermeyer (2018), Predictive Modeling of U.S. Health Care Spending in Late Life, *Science*, 360(6396).
- **Desarrollo y pobreza:** Aiken, Bedoya, Blumenstock & Coville (2023), Program Targeting with Machine Learning and Mobile Phone Data, *Journal of Development Economics*, 161 · Haushofer, Niehaus, Paramo, Miguel & Walker (2025), Targeting Impact versus Deprivation, documento de trabajo · Blumenstock, Cadamuro & On (2015), Predicting Poverty and Wealth from Mobile Phone Metadata, *Science*, 350(6264).
- **Trabajo y capital humano:** Hoffman, Kahn & Li (2018), Discretion in Hiring, *Quarterly Journal of Economics*, 133(2) · Chalfin et al. (2016), Productivity and Selection of Human Capital with Machine Learning, *American Economic Review: P&P*, 106(5).
- **Vivienda y economía urbana** (la base de los *problem sets*): Bogin & Shui (2020), Appraisal Accuracy and Automated Valuation Models in Rural Areas, *J. of Real Estate Finance and Economics*, 60 · Deppner & Cajias (2024), Accounting for Spatial Autocorrelation in Algorithm-Driven Hedonic Models, *J. of Real Estate Finance and Economics*, 68.
- **Macroeconomía y pronóstico:** Medeiros, Vasconcelos, Veiga & Zilberman (2021), Forecasting Inflation in a Data-Rich Environment, *J. of Business & Economic Statistics*, 39(1) · Goulet Coulombe, Leroux, Stevanovic & Surprenant (2022), How Is Machine Learning Useful for Macroeconomic Forecasting?, *J. of Applied Econometrics*, 37(5) · Bluwstein et al. (2023), Credit Growth, the Yield Curve and Financial Crisis Prediction, *J. of International Economics*, 145.
- **Finanzas y crédito:** Fuster, Goldsmith-Pinkham, Ramadorai & Walther (2022), Predictably Unequal? The Effects of Machine Learning on Credit Markets, *Journal of Finance*, 77(1) · Dobbie, Liberman, Paravisini & Pathania (2021), Measuring Bias in Consumer Lending, *Review of Economic Studies*, 88(6) · Gu, Kelly & Xiu (2020), Empirical Asset Pricing via Machine Learning, *Review of Financial Studies*, 33(5).
- **Organización industrial:** Dubé & Misra (2023), Personalized Pricing and Consumer Welfare, *Journal of Political Economy*, 131(1) · Bandiera, Prat, Hansen & Sadun (2020), CEO Behavior and Firm Performance, *Journal of Political Economy*, 128(4).

Metodológicos y de método

- Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320.
- Fawcett, T. (2006). An Introduction to ROC Analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD '16*, 785–794.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1–22. [glmnet]
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.
- Filmer, D., & Pritchett, L. (2001). Estimating Wealth Effects Without Expenditure Data — or Tears. *Demography*, 38(1), 115–132.
- Belloni, A., Chernozhukov, V., & Hansen, C. (2014). High-Dimensional Methods and Inference on Structural and Treatment Effects. *Journal of Economic Perspectives*, 28(2), 29–50.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *Econometrics Journal*, 21(1), C1–C68.